

1. 研究デザインについての短い導入

実験が終わった後に統計家にアドバイスを求めるのは、ほとんどの場合、検死を依頼するようなものです。統計家に言えるのは、せいぜいその実験が何で死んだかということくらいでしょう。

– Sir Ronald Fisher^{*1}

この章では、研究をデザインし、データを集め、そのデータ収集がうまくいっているかどうかをチェックする、といったことについての基本的なアイデアを考えることから始めましょう。あなた自身が研究をデザインするのに十分な情報は得られないかもしれませんが、ほかの人がやった研究を評価するのに必要な基本的ツールの多くは手に入れられると思います。ただ、この本の狙いはデータの収集よりもデータの分析にありますので、ごくあっさり全体像を見るにとどめます。この章は、ふたつの意味で「特別」です。まず、ほかの章よりも心理学に特有の状況を扱っています。次に、研究の方法論についての科学的問題にかなりの重点を置いていて、データ分析の統計的問題にはそれほど重点を置いていません。とはいえ、このふたつの問題はお互いに関係していますから、この問題をちょっとばかり詳しく扱うのが、統計のテキストの伝統的なやり方になっています。この章は、研究デザインについては **Campbell1963** に、測定の尺度に関する議論については **Stevens1946** に依っています。

1.1

心理学的測定への導入

データ収集を理解するにはまず、**測定**について考えなければならない。つまり、ここで我々がやろうとしていることは、人の行動や心についての何かを測るということだ。では「測る」とは何だろう？

^{*1}第1回インド統計会議会長講演, 1938. 出典: http://en.wikiquote.org/wiki/Ronald_Fisher

1.1.1 心理学的測定についてのいくつかの考え方

測定そのものは微妙な概念だが、基本的には「なにか」に数字やラベル、あるいはほかのよく定義された記述を割り当てる方法を見つけること、と言える。であるから、次に挙げるようなものも心理学的測定の中に含まれる。

- 私の **年齢** は 33 歳です。
- 私は**アンチョビ**が 好きではない。
- 私の **染色体的な性別** は 男性である。
- 私の **性自認** は 男性である*2

上の短いリストには**太字になっているところ**が“測定されようとしている対象”であり、**イタリック**になっているところが“測定されたもの”である。じつは、それぞれのケースで生じうる測定全体について考えることで、少し拡張することができる。

- 私の**年齢**は (年単位で数えるから)0, 1, 2, 3 ..., となる。上限がどうなるかはちょっと曖昧だが、現実的には最大でも 150 ぐらいだと思っていれば良い。それ以上生きた人はいないのだから。
- **アンチョビ**が好きかどうかは、答え方として好きあるいは嫌い、はたまたどちらでもないとか、ときどきね、と答えるだろう。
- 私の**染色体的な性別**は、ほぼ間違いなく男性 (XY) か、女性 (XX) だろうが、ごくわずかな例外もある。それは**クラインフェルター症候群 (XXY)** というやつで、ほとんど男性の染色体とおなじである。そのほかにもこうした可能性はあるかもしれない。
- 私の**性自認**は男性か女性のいずれかだが、私の染色体的な性別とは一致していない。私は自分をどちらでもないとするかもしれないし、はっきりとトランスジェンダーだ、と答えるかもしれない。

このように、ある事象 (年齢とか) は取りうる値が明らかなものもあれば、ちょっと特殊なものも

*2うむ... ちょっと引っかかるだろ？ このセクションはこの本の最も古いパートだから、ちょっと時代遅れで小っ恥ずかしいものになっている。これが書かれているのは 2010 年で、ここに書いてある事実は確かに正しい。これを今の 2018 年にも取って考えると、私はもう 33 歳じゃないし、驚くことじゃない。私の染色体が変わったとは思えないし、私の遺伝子は今も XY 型だともう。一方、性自認は... ううん。タイトルページには、今私のことを Daniel じゃなくて Danielle と書いているからわかってもらえると思うけど (訳註；Daniel は男性名的表記, Danielle は女性名的表記)、最近性別に関するアンケートでは男性と答えないようにしていて、むしろ “she/her” で呼ばれる方が嬉しくなっている。話すと長くなるけど！実は、この本ではこのことをどう扱うか少し考えた。この本では作者の声が直接含まれているので、この本での表記を全部 Danielle にすると随分違ったものになるんじゃないかと思う。でもそれはかなりの作業量になるから、この本での私の名前は “Dan” で通そうと思う。とにかく Danielle のニックネームとして Dan はバッチリだと思わない？ ちっちゃいことは気にしない。私のことをどう呼んだら良いかわからない読者のために、少しでも気楽になってもらえればと思ってこれを書いている。あ、アンチョビはまだ好きじゃないけどね (笑)。

ある。しかし、誰かの年齢と言ってもこれよりちょっと微妙なものであることは指摘しておきたい。たとえば、上の例では年齢を一年単位で測定することを想定していた。しかしもしあなたが発達心理学者であったら、これはちょっと雑すぎて、年齢は年と月(月齢)で表現するかもしれない(もし子供が2歳11ヶ月であれば、これを“2.11”と書いたりする)。新生児に興味があれば、年齢は生まれてから何日めかで表現するだろうし、もしかすると生後何時間経ったかで表現するかもしれない。言い換えると、あなたが測定値に何を許容するかというのが重要なのだ。

これをもう少し詳しく見てみると、“年齢”という概念は実際まったく正確ではないことに気づかれるかもしれない。一般的に言って、我々が“年齢”というときは、暗に“生まれてからの時間の長さ”を意味している。しかし、それが常に正しいわけではない。たとえば、新生児の目の動きをどのようにコントロールしているかに興味があったとしよう。もしそれぐらい若い子に興味があれば、あなたは“生まれたとき”から始めることが意味のある点だとは思わなくなるかもしれない。アリスが生後3週間で、ビアンカが1週間後に生まれてきたとして、彼女らに“生まれてから2時間後”に出会った時彼女らが“同じ年齢”だったといえるだろうか？社会的には、日常生活で年齢について語る時に、生まれた時を起点とするが、それは世界に生まれたって独立した存在として自らを扱ってきた人としての時間の総量、として定義しているからだ。科学的な観点からは、興味があるのはそこだけではない。生物としての人間を考えるなら、概念的には意識を持った生き物として成長してきた過程を考える方が便利だし、その観点から行くとアリスとビアンカは同じ年齢だとは言えない。だからあなたが“年齢”という概念を定義しようとするなら、ふたつのやり方があることになる。意識の時間的長さか、生まれてからの時間的長さか、である。大人を対象にしているときは、その差はほとんど意味をなさないが、新生児の場合はそうではないのだ。

この問題を越えた、方法論的な問いがある。どの“測定法”が、誰かの年齢を見出すのに用いられるべきだろうか。上で述べたように、そこにはいくつかの可能性がある。

- 単に“あなたは何歳ですか”と尋ねる。この事故報告式は早くて、やすくて、簡単だ。しかしその人が質問を十分理解している場合に限るし、人によっては歳を誤魔化すことがある。
- 権威者(例えば親御さん)に“あなたのお子さんは何歳ですか?”と尋ねる。この方法は早くて、子供を扱うときには簡単な方法だ。親はいつも周りにいるのだから。でも“意識を持ち始めてから”を考えるとときはうまくいかない。というのも、親はその子がいつ意識を持ち始めたかを知る由がないからだ。そのときは、別の権威者(例えば産科医)に頼る必要があるだろう。
- 公的な記録を調べる。例えば出生証明書とか、死亡証明書である。これは時間はかかるし、手間もかかるが、それなりの利点がある(例えば故人を対象にする場合は。)

1.1.2 操作可能にする：あなたの測定を定義する

上の章で論じられていたことはすべて、**操作化**という概念に関係している。もう少しこの概念を正確にいうと、操作化とは大きな意味があるが、何かしらぼんやりした概念を、正確な測定に落とし込む手続きのことを指す。この操作化のプロセスは、以下のいくつかの異なる要素を含んでいる。

- あなたが測定しようとしているものを明確にすること。例えば“年齢”も“生まれてからの時間”なのか、“意識が芽生えてからの時間”なのか、どちらがあなたの研究の文脈に沿うものなのか？
- それを測定するのにどの手法にするのか決定すること。事故報告式の測定年齢を使うのか、親に聞くのか、公的な記録を取るのか、どれだろう？ もし事故報告式を使うのなら、どういうフレーズでその質問をするだろう？
- 測定が取りうる値のセットを決定すること。この値は常に数量的なものとは限らないことに注意しよう。測定する年齢は数量的かもしれないが、どんな値が許されているのかをよく考えて見てほしい。年単位の年齢なのか、年月なのか、日、時間、どれだろう？ ほかの測定の種類によっては（例えばジェンダー）、値は数量的なものにならない。しかしすでに述べたように、私たちはどんな値が許されているかを考える必要があるのだ。もし事故報告式でジェンダーを尋ねたら、私たちは相手にどんな選択肢を許すだろうか。単に“男性”か“女性”だけで十分なのか？ “その他”のオプションは必要ないのか？ あるいは、特別な選択肢を考えて、回答者自身の言葉を使うことを許すのか？ そしてもしすべての言語報告を可能な値のセットに含めるのであれば、その回答をどのように解釈するのか？

操作化はトリッキーなビジネスで、“唯一の正解”があるものではない。“年齢”や“性別”のインフォーマルな概念を操作化する方法を選択し、それをフォーマルな測定にすることを選んでも、それはあなたが何を測定したいかに依存するのだ。大抵の場合、あなたの領域で活躍している人たちの科学的コミュニティが、どうしたらいいかについて十分に確立されたアイデアをすでに持っていることと思う。いいかえると、操作化はケースバイケースで考える必要があるということだ。とはいえ、個々人の研究プロジェクトにはそれぞれ特別な問題が他にもいっぱいあるが、一般的な側面もあるものだ。

次に進む前に、用語を整理しておきたい。相互に関連する次の四つのことがある。

- **理論的構成概念**。これはあなたが測定しようとしているもの、例えば“年齢”、“性別”、“ジェンダー”や“意見”といったものだ。理論的な構成概念は直接観測されないし、実際にはちょっと曖昧なものであることが多い。
- **測定**。測定はあなたが客観的にしようとする際につかうツールや手法のこと。調査における質問、行動観察や脳のスキャンなど、すべて測定に数えられる。
- **操作化**。“操作化”という用語は、測定と構成概念の論理的なつながりを指す。あるいは、理

論的構成概念から測定を導き出そうとするプロセスのことである。

- **変数**。最後に、新しい用語を。変数とは、世界に存在する何かに対して、私たちが測定を適用した時の結果である。つまり、変数は実際の“データ”で、最終的に我々のデータセットになるものである。

実際には、科学者でさえこれらの擁護間の区別を曖昧にしようとする傾向があるが、その違いを理解しようすることはとても有益である。

1.2

測定の尺度水準

前のセクションで示したように、心理学的な測定の結果は変数と呼ばれる。しかしすべての変数が同じ質的なタイプではないので、どういうタイプがあるのかを知っておく必要がある。変数のタイプの違いを区別する大変便利な概念として**測定の尺度水準**というものがある。

1.2.1 名義尺度水準

名義尺度水準の変数は (**カテゴリーカルな** (質的な) 変数と言われることもあるが)、異なる取りうる可能性との間に特定の関係がないもののことである。この種の変数は、他の値“より大きい”とか“より良い”といったいかなる意味も持たないし、その平均を出しても全くなんの意味もない。典型的な例として、“目の色”を考えてみよう。目はブルー、グリーン、ブラウンだったり他の色であったりするが、そのどれかが他のものよりも“大きい”とは言わない。だから、“平均的な目の色”について語るのも憚られる。同様に、ジェンダーもそうだろう。男性が女性よりも良いとか悪いとかいうものではない。同じく“平均的な性別”というのも意味がない。つまり、名義尺度水準の変数は、異なる変数の値は異なるということしか言えない。それだけだ。

もう少し注意深く見てみよう。私が人の通勤・通学手段について研究しているとしよう。私が測定しようとしている変数は、仕事に行くためにどういう種類の移動手段を使うかである。“移動のタイプ”変数は、それほど多い値を取るものではない。せいぜい“電車”、“バス”、“自家用車”、“自転車”ぐらいだろう。ここでは、この四つの可能性しかないことにしよう。その上で、100 人の人に対して

	移動手段	人数
	(1) 電車	12
どうやって仕事場に行ったかを調べて、次のような結果になったとする。	(2) バス	30
	(3) 自家用車	48
	(4) 自転車	10

さて、移動手段の平均はなんだろう？ 明らかにその答えはひとつではない。愚問としか言いようがない。車で移動することが最もポピュラーな方法で、電車で移動するのがもっともポピュラーでない、それだけである。同時に、私が選択肢を列挙した順番が面白くないことにも注意してほしい。データは次のように表示することだってできるのだ。

移動手段	人数
(3) 自家用車	48
(1) 電車	12
(4) 自転車	10
(2) バス	30

...実質的には何も変わっていない。

1.2.2 順序尺度水準

順序尺度水準にある変数は、名義尺度水準の変数より少し構造化されているが、それほど大きな変化ではない。順序尺度水準の変数は、異なる状態に自然な意味のある順序を与えたものであるが、それ以上のことはない。よく使われる例としては、“レースの最終順位”である。最初にゴールした人に、2位の人よりも早かったということはできるが、どれくらい速かったかということとはできない。結果的に、1位 > 2位ということはわかるし、1位 > 2位ということもわかるが、1位と2位の差が2位と3位の差よりも大きいかもしれない。心理学的に面白い例もある。私が気候変動に対する人々の考え方に興味をもっているとしよう。私は、その人の信念にもっとも当てはまる文章がどれかを、(以下にリストした4つの文章から)ピックアップして人に尋ねる。

- (1) 気温は人間の活動のせいで上昇している
- (2) 気温は上昇しているがなぜかはわからない
- (3) 気温は上昇しているが人間のせいではない
- (4) 気温は上昇していない

この4つの文章は、確かに自然な序列がついている。“現在の科学に対してどれほど同意するか”という意味でだ。文章1は明らかに科学的営みにマッチしているし、2はかなり適合している。3はそれほどでもないし、4は現在の科学と逆の立場だ。だから、私の興味のある用語(人は科学を支持

する度合い) でいうと、項目を $1 > 2 > 3 > 4$ の順に並べることができる。この順序づけがある以上、次のように選択肢を並べると奇妙なことになる。

- (3) 気温は上昇しているが人間のせいではない
- (1) 気温は人間の活動のせいで上昇している
- (4) 気温は上昇していない (2) 気温は上昇しているがなぜかはわからない

...これは項目の自然な“構造”に違反しているように見えるからだ。では、100 人にこの質問をして、以下のような答えを得たとしよう。

反応	度数
(1) 気温は人間の活動のせいで上昇している	51
(2) 気温は上昇しているがなぜかはわからない	20
(3) 気温は上昇しているが人間のせいではない	10
(4) 気温は上昇していない	19

このデータを分析するときは、グループ (1),(2),(3) を一緒にするのは合理的だと思われるし、100 人のうち 81 人が少なくとも一部は現在の科学を支持していると言えそう。また、グループ (2),(3),(4) をまとめることもあり得る話で、100 人のうち 49 人が現在の科学的観点に、少なくともいくらか同意していないといえる。しかし、(1),(2) と (4) を一緒にすることはおかしいことで、100 人のうち 90 人がどうこうしてるとは言えない。これらの反応を一緒にくたにする合理的な根拠がないからだ。

つまり、私たちがこれらの項目が、意味のあるグルーピングで自然に序列づけできるということはできるが、その平均を求めるということはできない。例えば、ここでの例でいうと、“平均的な” 反応は 1.97 である。もしその意味がわかるというのなら、ぜひ知りたいのでどうぞ教えてください！

1.2.3 間隔尺度水準

名義や順序の尺度水準に比べると、**間隔尺度水準**の変数や比率尺度水準の変数は、かなり意味を持った数値である。感覚尺度水準の変数は、数字の間の差分が解釈可能だが、“自然な” ゼロの値をもつものではない。間隔尺度水準の良い例は、セ氏で測られる気温である。例えば、昨日は 15° で今日は 18° だというとき、この 3° の違いに意味がある。もっというと、この 3° の違いは、 7° と 10° の間の 3° と全く同じである。つまり、間隔尺度水準では足し算引き算に意味があるのだ^{*3}。

^{*3}実は、かなり物理学の知識がある読者に教わったのだが、この温度は厳密な間隔尺度水準ではない。というのも、 3° 温度を上げようとするのに必要なエネルギーの量は、その時の気温に依存するらしい。だから、物理学的に注意するというなら、温度は間隔尺度とはいえないのだ。しかし例としていいものなので、このちょっとした不都合な真実は無視しようと思う。

しかし注意してほしいのは、 0° が“温度がない”ことを意味するものではない点だ。これが意味するのは“水が凍る温度”であって、これはちょっと恣意的なものだ。だから、温度を掛け算したり割り算したりしようとするのはポイントがずれていることになる。 20° は 10° の二倍熱いとは言えないし、 20° が -10° のマイナス 2 倍というのも意味がないことだ。

あらためて心理学的な例を見てみよう。大学一年生の態度が時間とともにどう変わっていくかに興味があったとしよう。もちろん、各学生が入学した年を記録するだろう。これは間隔尺度水準の変数だ。2003 年に学生になった人は、2008 に始めた学生よりも 5 年早い。しかし、2008 を 2003 で割って、後者の学生を前者の学生に比べて“1.0024 時間後の人”とは言わないだろう。そんなの全く意味がないじゃないか。

1.2.4 比率尺度水準

四つ目の、そして最後の変数の種類は**比率尺度水準**の変数といわれ、0 がゼロという意味を持つものであり、掛け算や割り算を許すものである。比率尺度水準にある変数の心理学的な例としては、反応時間 (Response time: RT) がいいだろう。人が問題を解いたり質問に答えたりするのに要する時間を図ることは、様々なタスクでよく見られるものである。というにも、それがタスクがいかに難しいかを示す指標になるからだ。アランが質問に回答するまで 2.3 秒かかり、ベンが 3.1 秒かかったとしよう。感覚尺度水準と同じように、足し算や引き算はどちらもここで意味のある操作である。ベンは実際、 $3.1 - 2.3 = 0.8$ 秒長くアランより時間を要した。しかし、今回は掛け算や割り算も意味があるのである。つまり、ベンはアランの $3.1/2.3 = 1.35$ 倍長く時間がかかったとも言える。比率尺度水準にはなぜこんなことができるかという、反応時間はまさに“0秒”が“時間が経過していない”ことを表しているからだ。

1.2.5 連続か離散か

あなたが考えておくべき第二の分類方法がある。それはあなたが分析に持ち込もうとしている変数の種類に関するものだ。連続変数と離散変数という区別があるのだ。この区別は以下の通りである。

- **連続変数**はどの二つの値を取っても、論理的には必ずその両者の間に値がありうるもの。
- **離散変数**とは、連続的でない変数のこと。離散変数は、中間点に対応するものがない。

この定義はおそらくちょっと抽象的なのだが、例を見たらすぐにシンプルなものだとわかってもらえるだろう。たとえば、反応時間は連続変数である。アランが 3.1 秒、そしてベンが 2.3 秒反応に要したとして、キャメロンがその間の 3.0 秒になるかもしれない。デイビッドが 3.031 秒、つまりキャメロンとアランの間に反応時間が来ることもありえる。現実的には、反応時間をそんなに正確に測定することはできないかもしれないが、原則的には確かに可能なのだ。反応時間の 2 つの値の間に、常に新しい値を見つけることができるのであれば、RT は連続変数として考えられる。

Table1.1 尺度水準と離散/連続の関係。チェックマークが入っているセルは可能であることを意味する

	連続	離散
名義		✓
順序		✓
間隔	✓	✓
比率	✓	✓

離散変数はこのルールを破った時に現れる。例えば、名義尺度水準は常に離散変数だ。移動手段の種類の例を思い出してみると、電車と自転車の“間”に何かがあるとは言えないし、数学的に2と3の間に2.3があるという意味をもたない。移動手段は離散変数なのだ。同様に、順序尺度水準も常に離散変数である。“2位”は“1位”と“3位”の間に常に入るが、“1位”と“2位”の間には論理的に何も生じ得ない。間隔尺度水準と比率尺度水準は事情が違う。上で見たように、反応時間は(比率尺度水準の変数だが)連続変数である。セ氏で測られる温度も(間隔尺度水準の変数だが)連続変数である。しかし、学校に通い始めた年(間隔尺度水準)は離散的である。2002年と2003年の間にはX年が存在しないのだ。正誤判定できる問題の正答数も(比率尺度水準の変数だが)、離散変数である。正誤がわかる質問は、“部分的に正解”とすることができないので、5/10と6/10の間というのが考えられない。表??は尺度水準と連続/離散の区別を要約したものである。チェックマークは可能であることに対応している。強調しておきたいのだが、(a)テキストによっては間違えているものがあって、(b)“離散変数”は“名義尺度水準のこと”と言ったりするのだ。残念なことだ。

1.2.6 複雑なもの

いいかい、これを聞いたらショックを受けるだろうことはわかるけど、現実世界はこの小さな分類法が提案するよりもずっと厄介なものがある。現実世界においてはこの綺麗なカテゴリーにぴったり当てはまる変数はないので、測定の尺度を堅苦しいルールのように扱わない方がいい。そういうものではないのだ。

これはガイドラインに過ぎず、違う変数の種類を違うように扱うべき状況について考える助けになるようなものにすぎないのだ。それ以上のものではない。

古い例を取り上げてみよう。多分ほんとうに古典的な例の、心理学的測定ツールである、**リッカートスケール**のことを考えてみる。リッカートスケールはあらゆる調査デザインにつかえるものだ。あなた自身、何百、何千回と回答したことがあるだろうし、もしかするとあなた自身も使ったことがあるかもしれない。以下のような調査の質問をしたとする。

“海賊はみんなすごい” という発言に対するあなたの意見を最もよく表しているのは、次のうちどれですか？

そして選択肢が次のように提示される。

- (1) 全く同意できない
- (2) 同意できない
- (3) どちらとも言えない
- (4) 同意できる
- (5) 強く同意できる

これは5件法のリッカーと尺度の例で、いくつかの(ここでは5つの)順序づけられた可能性の中から一つを選ぶ。一般的にはそれぞれのケースに言葉で説明が加えられる。しかし、全ての項目が正確に記述されているとは限らない。以下のような表示の仕方も、典型的なリッカートの5件法である。

- (1) 全く同意できない
- (2)
- (3)
- (4)
- (5) 強く同意できる

リッカートスケールはとても便利なツールだ。ちょっと限定的だとしても。この質問はどの種類の変数になるだろう？ 明らかに離散的だ。2.5に反応することができないのだから。名義尺度水準でないことも明らかだ。順番通りに並んでいるのだから。そして比率尺度水準でないことも明らかだ。自然なゼロがないのだから。

順序尺度水準か間隔尺度水準なのだろうか？ 一つの意見ではあるが、“強く同意できる”と“同意できる”の差分が、“同意できる”と“どちらとも言えない”の差分と同じサイズだということを、証明するのは不可能に思える。実際、日常生活の感覚では、これらは全く同じなはずがない。これに従うと、リッカート尺度は順序尺度水準として扱うべきだということになる。一方で、実践的にはほとんどの参加者が“1点から5点までの尺度”全体をかなり真面目に扱っているようで、5つの選択肢の違いが互いに似ているように振る舞う傾向がある。このことから、ほとんどの研究者がリッカート尺度のデータを間隔尺度水準として扱っている^{*4}これは感覚尺度水準ではないが、実際は十分近似できていると考えて、**疑似の間隔尺度水準**として扱うのが普通だ。

^{*4}嗚呼、心理学...は何に対しても応えるのが難しいなあ！

測定信頼性を査定する

ここまで、理論的な構成概念をどのように操作化し、それによって心理学的測定に変えるかについて、少し考えてきた。そして心理学的測定によって、多くの異なる種類の変数を得る。そこで、次の質問を検討してみよう。測定はうまくいったのか？ これをふたつの関連する用語で表現するなら、**信頼性**と**妥当性**の話になる。単純にいうなら、**信頼性**とはあなたが測定したものをどれくらい**正確**に測っているかについてのものであり、**妥当性**はその測定がどの程度**精度**があったかについてのものである。このセクションでは**信頼性**について論じよう。**妥当性**についてはセクション??でみていこう。

信頼性は実にシンプルな概念だ。それは測定の反復可能性、あるいは一貫性を表す言葉である。私の体重を“バスルームの体重計”で測定したものは非常に**信頼性**が高い。もし私が体重計に乗ったり降りたりを繰り返しても、同じ答えを示し続けるだろう。私の知能について、“母親に尋ねる”のは非常に**信頼性**が低い。ある日、彼女は私がちょっと賢いと言い、別の日に彼女は私を全くの馬鹿者といった。**信頼性**の概念は測定が正しいかどうかとは異なるものだ（測定の正しさは**妥当性**に関係する）。私がバスルームの体重計に乗り降りする時に、ジャガイモの袋を持っていたとしても、**信頼性**は高いままだ。つまり、同じ答えを出し続けるという意味で。しかし**信頼性**が高いからといって、私の体重と一致しているかというとはそうではなく、間違った値になっている。これを専門的にいうと、**信頼性**はあるが**妥当**ではない測定ということになる。同様に、私の母が私の知能についていうことは**信頼性**がないが、彼女がいつてことはいくらか正しい。たぶん私はものすごく聡明というわけではないし、彼女が私の知能を推定するときは日によって乱高下するものの、基本的には正しいだろう。これは**信頼性**は低い**妥当**ではある測定ということになる。もちろん、もし私の母による推測があまりにも**信頼性**が低いものであると、彼女が私の知能についていうところの数多くのクレームのうち、どれが実際に正しい表現なのかを見極めることは難しくなるだろう。だから、ある意味で、**信頼**できない測定というのは実践的な目的において**妥当**でないものになってしまうのだ。だから、多くの人がいうように、**信頼性**は**妥当性**にとっての必要条件（しかし十分条件ではない）ということになる。

オーケー。では**信頼性**と**妥当性**の違いがはっきりしたところで、違うやり方で**信頼性**を測定する方法を考えよう。

- **再検査信頼性**。これは時間が経っても一貫しているかどうかに関するものである。もし後日同じ測定をしたら、同じ答えが得られるだろうか？
- **評定者間信頼性**。これは人が違っても一貫しているかに関するものである。もし誰かが同じ測定をしたら（たとえば、別の人が私の知能について評定したら）、同じ答えが得られるだろうか？
- **平行検査信頼性**。これは理論的に質が等しい測定を使っての一貫性に関するものである。もし

違う体重計を持ってきて私の体重を測定したとして、同じ答えが得られるだろうか？

- **内的一貫性信頼性**。もし測定が同じ機能を持つ異なるいくつかのパーツから構成されているとしたら (たとえば、性格検査の質問紙の結果はいくつもの問いを通じて迫っていくものだが)、個々のパーツが同じ答えを出す傾向にあるかどうか。

全ての測定が全ての形式の信頼性を満たすというものではない。たとえば、教育評価は測定の一つとして考えることができる。私が教えているある科目、*計算論的認知科学*は、研究課題と試験 (プラス、その他少し) の要素から評価することになっている。試験は研究課題の評価とは幾分異なる側面を評価しようとしているから、評価全体としては内的一貫性が低い。しかし、試験はいくつかの質問から構成されていて、それは同じものを (近似的に) 測定しようとしているから、同じような結果を出す傾向にある。つまり、試験そのものはかなり高い内的一貫性をもっているのだ。これは当然のことである。信頼性を求めるのは、同じものを測定したい場合に限るべきだ！

1.4

変数の “role” : 予測変数と結果変数

変数の話から移る前に、最後にもう一つ用語を説明しておこうと思う。普通、我々は研究の結果として多くの変数を手にすることになる。そこで、我々がデータを分析する時に、他の変数に関連づけである変数を説明しようとするのはよくあることだ。このとき2つの役割、つまり “説明する” と “説明される” という役割の違いを意識することが大事だ。今からこれについて明らかにしていこう。まず、何度も繰り返し参照することになるので、変数を記述するのに数学的な記号を使うことにしよう。“説明される” 変数を Y で、“説明する” 変数を X_1, X_2 のように表記することにする。

X と Y という異なる名前をつけて分析するのは、分析において異なる役割を演じるからだ。これらに対して、古くは**独立変数** (Independent Variable, IV)、**従属変数** (Dependent Variable, DV) と名付けられていた。独立変数は説明に使うもの (つまり X) で、従属変数は説明される変数に使うもの (つまり Y) である。この名前の背後にある意味は次のようなものだ。もし X と Y の間に本当に関連があるのなら、 Y が X に依存している・従属していると言えるし、研究が “適切に” デザインされていたら、 X は他の何物からも独立しているはずである。しかし、個人的にはこのネーミングはマズイと思う。これだと、ミスリーディングであることを忘れそうになるからだ。なぜなら、(a) 独立変数は実際に “何物からも独立である” というわけにはいかないし、(b) 変数間に関係がなかったら、従属変数が独立変数に従属することはないのである。現に、独立変数と従属変数というのがマズいネーミングだと考えるのは私一人ではないので、もっと良さそうな他の名前がいくつかある。この本で使うのは**予測変数**と**結果変数**である。このアイデアは、変数 X (予測変数) を使って Y (結果変数) につ

Table1.2 データセットで分析に使われる変数が担う異なる役割について、区別を明確にした用語。この本では古典的な用語は使わず、新しい用語を使うようにしていることに注意してほしい。

変数の役割	古典的な名称	モダンな名称
“説明される”	従属変数 (DV)	結果変数
“説明する”	独立変数 (IV)	予測変数

いて何らかの推測をしようとするから、というところから来ている^{*5}。これについて、表 ??にまとめておく。

1.5

実験的，あるいは非実験的研究

あなたが気にするべき、大きな区分基準は“実験的研究”なのか、“非実験的研究”なのか、という違いだ。この区別をする時、本当に話をしているのは、実験者がその研究において人と出来事全体をどの程度コントロールしているか、ということについてである。

1.5.1 実験的研究

実験的研究の特徴は、研究者が研究のあらゆる側面をコントロールしていること、特に被験者がその研究の途中でどういう経験をするかをコントロールしていることにある。実際的には、研究者は予測変数 (独立変数) を操作したり変化させたりするが、結果変数 (従属変数) は自然に変化するに任せる。このアイデアは、予測変数 (独立変数) を意図的に変化させ、それが結果に何らかの因果的な効果を与えるかどうかを見るためにある。もっというと、予測変数以外に結果変数の原因となるものが存在する可能性がないことを保証するため、他のものは一定に保つか、ある種“バランスの取れた”やり方で、結果に影響を与えないことを保証するのである。実践上は、他の何ものも実験の結果変数に影響を与えないと考えるのは不可能だし、一定に保つというのも難しい。これについての標準的な解決方法は、**乱打マイゼーション**である。つまり、異なる群にランダムに人を割り付け、群ごとに異なる処置をする (すなわち、違う予測変数の値をもたせる)。ランダマイゼーションについては後ほどもっと詳しく説明するが、ここではランダマイゼーションが群間にみられるあらゆる系統的な変

^{*5}しかし腹立たしいことに、別の名前もよく使われる。それをリストアップしようとは思わない—そんなことをしたって何にもならないからだ。ただし、私が“結果変数”としたところが時折“反応変数”とされることがある、ということだけは指摘しておこう。やれやれ。この種の用語の混乱はとてもよくあることで、まいっちゃうよね。

化の可能性を(無くすことは無理だとしても)最小化するために行われるものであることを確認できれば十分だろう。

ごく単純で、まったく非現実的で、非倫理的な例をみてみよう。喫煙が肺がんを引き起こすことを検証したいとする。これを実現する一つの方法は、タバコをお吸う人と吸わない人を見つけ出して、タバコを吸う人の肺がん率が高いかどうかを見ることだろう。これは全く実験的ではない。なぜなら、研究者がタバコを吸う人と吸わない人に対してコントロールしていないからだ。そしてこれは大問題なのである。たとえば、タバコを吸う人は食生活が良くない傾向があるかもしれないし、アスベスト鉱山で働く傾向があるといったことが考えられるからだ。ここでのポイントは、群(喫煙者と非喫煙者)は多くの点において異なっており、喫煙習慣の違いだけではないということだ。だから喫煙者の方が肺がん率が高いということは、他の何か別の原因があるかもしれない、タバコが原因ではないかもしれないのだ。他の要因のこと(たとえば食習慣とか)は、専門的には“交絡変数”というが、これについてはまた後で話すことにしよう。

今はとりあえず、適切な実験がどのようなものかを考えたい。ここでの問題点は、喫煙者と非喫煙者は多くの点で異なっているということだった。解決策として、もしあなたに倫理観がなかったとしたら、誰が吸うか吸わないかをコントロールすればよい。具体的には、若い非喫煙者を無作為に2つのグループに分けて、その半数を強制的に喫煙者にする。そうすると、半分が喫煙者であるということ以外の点で、量グループが異なるところは非常に低くなる。こうして、もし喫煙者群が非喫煙者群よりも肺がんになる確率が高ければ、(a) 喫煙が癌の原因であり、(b) 我々は殺人者だ、というはっきりした確信を得ることができる。

1.5.2 非実験的研究

非実験的研究は、広い意味で“研究者が実験で行うようなコントロールをしないあらゆる研究”を指していると言えるだろう。もちろん、科学者はいつもコントロールしたがるものだが、上の例にあったように、コントロールできないとかすべきでない状況というものもある。がんになるかどうかを見るために、人に強制的にタバコを吸わせるのは論理的に大きな問題(というかほとんど犯罪)だから、実験者がコントロールすべきでない状況の良い例といえるだろう。しかし別の問題もある。倫理的な問題を横に置いたとしても、“喫煙実験”は他に幾つかの問題があるのだ。たとえば、“強制的に”喫煙させようと言った時、私は非喫煙者のサンプルが喫煙を始めさせるという意味で、喫煙者にするという意味だった。これはマッドサイエンティストが好みそうな、確実かつ悪どい実験デザインのように聞こえるが、現実世界での効果を検証する方法としては、それほど健全ではないだろう。たとえば、喫煙が肺がんの原因になるのは、その人の食生活がわるいからで、普段から喫煙をする人は食生活が悪いのかもしれない。しかし我々の実験における“喫煙者”は“普通の”喫煙者ではないから(つまり、非喫煙者を喫煙者にしたとしても、それは他の普通の、現実の喫煙者が持つ特性を持ってないので)、食生活は良いのかもしれない。そうだとすると、彼らが肺がんになることはないから

我々の研究は失敗だ。これは“普通の”世界の構造を壊してしまったから(専門的には、これは“人為的な”結果といわれる)である。

非実験的な研究をふたつのタイプに分ける区分として注目すべきは、**準実験研究**と**事例研究**である。上で述べた例である、喫煙者と非喫煙者の肺がん発症を検証するために喫煙者と非喫煙者を統制せずに行う研究は、準実験デザインといえる。つまり、これは実験と同じだが、予測変数(独立変数)を操作していないのである。それでも結果を統計的に分析することはできる。ただし、より注意深く、慎重であらなければならない。

別のアプローチである事例研究は、一つ、あるいはごく少数の事例をととても詳細に記述することをねらう。一般的に言って、事例研究の結果に統計的な分析を適用することはできないし、わずかな独立した事例から“人は一般に”，という一般的な結論を引き出すことはかなり難しい。とはいえ、事例研究は状況次第で有用なのである。まず、他の手法がない状況。神経心理学では、この問題はよくあることである。特定の脳の領域にダメージを受けているひとをたくさん集めることはできないし、そうするとできることはいくつかの事例について、できるだけ詳細に記述することだけである。しかし、事例研究にも素晴らしい利点はある。多くの人を研究対象にできないからこそ、各事例における特定の要因が果たす役割を理解するために、時間とエフォートをかなり注ぎ込むことができるからだ。これは十分にやる価値のあることである。結果として、事例研究はあなたが実験、準実験デザインで見られるような、より統計学的なアプローチを補うことができる。この本では事例研究についてそれほど多く触れないが、紛れもなく価値のある手法なのである！

1.6

妥当性を検証する

他の何よりも科学者が欲するものは、研究が“妥当”かどうかである。この**妥当性**という考え方の背後にある考え方は、とてもシンプルなものだ。あなたは自分の研究が信用できるか？ もしできないのなら、それは妥当ではないということだ。しかし、そうやってしまうのは簡単なのだが、信頼性をチェックするよりも妥当性をチェックすることのほうが難しい。本当のことをいうと、妥当性が実際なんなのかについて正確で明確な同意を得ることはできない。現に、様々な種類の妥当性があって、それらは個々別々の問題を扱っている。また、全ての妥当性が全ての研究に当てはまるというものでもない。ここでは5つの異なる妥当性について論じようと思う。

- 内的妥当性
- 外的妥当性
- 構成概念妥当性
- 表面的妥当性
- 生態学的妥当性

はじめに、何が問題なのかについての簡単な紹介をしておこう。(1) 内的・外的妥当性は最も重要なものである。なぜなら、それはあなたの研究が実際に意味があるかどうかという基本的な問いに直結しているから。(2) 構成概念妥当性は、あなたが考えていることをあなたが測定できているかどうか、を問う。(3) 表面的妥当性は“見え方”が重要であること以外、それほど重要な問題ではない。(4) 生態学的妥当性は表面的妥当性の特殊ケースで、注意すべき多くの側面の表面的なものに対応している。

1.6.1 内的妥当性

内的妥当性というのは変数間の因果関係について、正しい結論を導き出せるかどうかということに関わっている。

ここで“内的”といってるのは、これが研究の“中における”関係性を指し示しているからだ。

簡単な例で考えてみよう。大学教育によって文章が書くことが上手くなるかどうかを明らかにしたいとする。

これを検証するために、あなたはまず一年生の学生グループを集め、1000語程度のエッセイを書いてもらい、スペルや文法ミス数を数えたとする。

次に、明らかに一年生よりも大学教育を受けてきているであろう3年生の学生を見つけてきて、同じ実験をする。

そうすると3年生の方がミスが少ないことがわかった、としよう。

そこであなたは、大学教育が文章を書く技術を向上させた、と結論した。あってるかな？

この実験の考える大きな問題点は、3年生は年長なので、書くこと以外にも色々な経験を積んでいるだろうということだ。

だから、因果関係を導き出すのは難しいだろう。年長者は作文がうまい？もっと作文の経験をしている人は？もっと長く教育を受けていたら？

このいずれかが真であれば、3年生のパフォーマンスを向上させる原因になるのではないかな？年齢？経験？教育？答えられないでしょう。

これが内的妥当性の失敗の例である。なぜなら、あなたが異なる変数間の因果関係を適切に切り分けられてなかったからだ。

1.6.2 外的妥当性

外的妥当性は知見の**一般化可能性**や**応用可能性**と関係している。

すなわち、研究で見つかったものが“実生活における”同じパターンを見出すことができる程度を

指す。

もう少し正確にいうなら、あなたが心理学の名のもとに行うあらゆる研究は特定の問いや作業を含んでいるだろうし、特定の環境において生じているだろうし、特定の集団(残念なことに、学生限定であったりする)から選び出した参加者から出来上がっている。だから、もし結果が現実的に一般化できないとか、あなたの対象を超えた状況を超えて一般化することができないという場合、外的妥当性がなかったということになる。

この問題の古典的な例として、心理学におけるかなりの部分の研究が、心理学コースの学部学生を使ったものであるということが挙げられる。しかし、明らかに、研究者は心理学徒だけに注目しているわけではない。研究者は一般の人々に関心があるのだ。であれば、心理学の学生を対象にした研究は常に、外的妥当性を欠いている可能性がある。すなわち、もし心理学の学生に何か“特別な”ことがあれば、あるそれに関した側面について一般とは異なる影響をもたらし、外的妥当性がないかもしれないということを気にし始めなければならない。

とはいえ、心理学の学生だけを対象とした研究が、必ずしも外的妥当性に問題があるわけではない、ということを理解することが重要である。これについては後ほどまた述べるが、非常によくある間違いなのでここで触れておく。研究における外的妥当性は、もし(a)ごく狭い領域(たとえば心理学の学生)からサンプルを取り出して、(b)その狭い母集団があなたが研究したい心理学的現象に関する側面において、系統的に一般人の母集団から異なっている場合には、危うくなる。この強調した部分のことを、多くの人が忘れがちなのである。心理学の学生が一般人と多くの点で異なるということはあるだろうから、心理学の学生を使った研究は外的妥当性がないかもしれない。しかし、その違いがあなたがみようとしている研究と関係ないのなら、なんの問題もない。もう少しはっきりさせるために、次の二つの例をみてみよう。

- あなたが“心理療法に対する態度”を見てみたいと思ったが、被験者全員が心理学の学生であった。この研究は外的妥当性についてかなり問題含みだろう。
- あなたが錯視の効果を測定したいと思い、心理学の学生をたいしょうにした。この研究は外的妥当性についてそれほど問題はないだろう。

最後の段落では参加者の選び方だけを取り上げたが、それは誰もが機にする側面だからであって、外的妥当性はもっと広い概念であることは忘れないでほしい。次の例も外的妥当性を脅かしかねないものであるが、これは研究実践に関わるものである。

- 実生活を反映していないような“心理尺度”に回答させているかもしれない。
- (いわゆる)“人間の学習”についての実験室実験は、実生活で人が直面する学習の問題とは異なる構造を持っている。

1.6.3 構成概念妥当性

構成概念妥当性は基本的にあなたが図りたいものがはかれているかどうかという問いである。理論的な構成概念を正しく測定できているなら、その測度は良い構成概念妥当性を持っていると言えるし、そうでなければ構成概念妥当性がないことになる。単純な(もしかしたら馬鹿馬鹿しい)例を挙げると、大学生が試験でカンニングする割合を調査しようとしているとしよう。その測定方法として、授業中にカンニングした学生は立つようにいい、私がそれを数えるということにしたとする。もしこれを300人の学生の前でやったとして、カンニングをしたと名乗り出た人が0人だった。だから私のクラスではカンニングした人の割合は0%だ、と結論しよう。これは明らかに馬鹿馬鹿しいやりかたである。しかしここでのポイントは、測定法に対する意義深い例を挙げることでなく、構成概念妥当性とは何かという説明なのだ。私が測定しようとしたものが“カンニングする学生の割合”だったのに対し、私が実際に測定したのは“自分の悪事を申告するような馬鹿な学生、あるいは“不正をしたふりをするほど血迷った学生”だったということだ。明らかにこれは同じものではない! だから、私の研究は失敗するだろう。測定が、構成概念妥当性を欠いている、という意味で。

1.6.4 表面的妥当性

表面的妥当性は単に測定が 想定通りのことをしているように“見える”かどうかについてのものであり、それ以上のことはない。もし知能を測るテストをデザインしたとして、人が“いや、これは知能を測定していないよ”というのであれば、この測定は表面的妥当性を欠いている。単純そのものでしょ。たしかに表面的妥当性は、真の科学的観点からはそれほど重要なことではない。結局のところ、測定が実際に想定通りのことをしているかどうかについて注意すべきであって、それがそのように見えるかどうかではないからだ。そうすると、表面的妥当性については一般的にそれほど注意しなくても良いということになる。とはいえ、表面的妥当性は3つの実目的に役立つのである。

- ときには、経験豊かな実験が、特定の測定がうまく行っていないと“直感的に”気づくことがある。この種の気づきは証拠に基づくものではないが、注意を向ける価値はあったりするものだ。なぜなら、多くの場合ひとは言語化できない知識を持っているので、理由をうまく説明できなくても何か気にすべきことがあるのかもしれない。言い換えるなら、あなたの研究に表面的妥当性がないと批判してくる人がいたら、あなたがその研究がうまくいかない理由を考えることができるかどうか、デザインについてより慎重に考える時間を取る価値があるということでもある。注意して欲しいのは、もし確信に至る理由が見つからなかったら、多分気にしなくてもいいということだ。結局のところ、表面的妥当性はそれほど大きな問題ではないのだから。
- まれによくあることだが、全く知識がない人でも、あなたの研究がくだらないという“直感”を得る人がいる。それはネット等で批判してくるだろう。よく考えてみると、その批判は当該研究がどう“見えているか”に焦点化していて、深いところまで考えていないことに気づくだ

ろう。表面的妥当性というのは、そうした主張にさらなる裏付けが必要であることをやんわりと説明するのに役立つ。

- 最後の点を拡張した形で、もし未経験者の批判が的を射ていたら（これは政策立案者になんらかの納得をさせたい応用研究者の場合など、よくあることだが）、あなたは表面的妥当性をしっかりと考えなければならない。というのも、単順に、あなたが好むと好まざるとに関わらず、多くの人は表面的妥当性と実際の妥当性は似たものだと思っているからだ。もしあなたが科学的で心理学的な背景に基づく法律を政府に求むなら、あなたの研究が“実際に”どうものかは問題にならない。表面的妥当性を欠いていたら、政治家はあなたを無視するだろう。もちろん政策がファクトよりも見え方に依存し、それがどうなるかに関係ないというのはアンフェアなことなのだが。

1.6.5 生態学的妥当性

生態学的妥当性は妥当性の異なる側面についてのもので、外的妥当性に似ているがもう少し重要なものである。そのアイデアは、生態学的妥当性があるというためには、研究が調べようとしている現実世界に近似するべきであり、全体的にそのような設定になっているかどうかということである。本質的には、生態学的妥当性は表面的妥当性の一種だといえる。その研究が正しく“見える”かどうかということに関わっているが、もう少し厳密なものではある。生態学的に妥当な研究というのは、専門的な意味で正しく見えるかということである。背後にある考え方は、研究が生態学的に妥当であるというのは、外的妥当性も高いだろうという直感だ。もちろんその保証はない。しかし、生態学的妥当性にとってありがたいことに、その研究が外的妥当性を持つかどうかをチェックするよりも、生態学的妥当性があるかどうかをチェックする方がより簡単である。シンプルな例として、目撃者の識別研究をとりあげよう。この種の研究のほとんどは、大学の中で行われる傾向があり、整列した顔ではなく単順に配置された顔を使うものが多い。犯罪を“目撃している”時間の長さと、“整列した”顔の中で容疑者を特定してくれと言われるまでの時間は、普通短いものだ。“犯罪”は現実のものではないし、目撃者が恐怖を感じることもなく、警察官がそばに立っているわけでもないからプレッシャーを感じることもない。これらは全て、研究がまったくもって生態学的妥当性を欠いていることを意味している。またおそらく、外的妥当性をも欠いていることも意味している（意味していないかもしれないけど）。

1.7

交絡，人工産物，そのほかの妥当性への脅威

妥当性の問題をごく一般的な形で眺めてみると，いちばん大きな心配ごとは交絡変数と人工産物のふたつです。このふたつの用語は，次のように定義されます。

- **交絡変数**: 交絡変数とは，予測変数と結果変数の両方に関係していることがわかった，測定されていないことの多い追加の変数のことです*6。交絡変数があると，予測変数が結果を引き起こしているのか，それとも交絡変数が引き起こしているのかを区別できなくなりますので，研究の内的妥当性が脅かされることになります。
- **人工産物**: ある結果が，たまたまその研究で検討した特殊な状況でしか成り立たないとき，その結果は“人工産物である”と言われます。結果が人工産物かもしれないということは外的妥当性への脅威になります。というのも，その結果を，あなたが本当に興味を持っている母集団へ一般化したり適用したりできない可能性が出てくるからです。

一般的なルールとして，交絡変数は非実験的な研究でより大きな問題になります。まさに，きちんとした実験ではないからです。定義からして，多くのことが統制されないまま放置されているのですから，あなたの研究に交絡変数が紛れ込む余地はいくらでもあります。実験的な研究は，交絡変数に対してずっと強い傾向があります。研究の最中に起こることを統制すればするほど，交絡変数が結果に影響するのを防げるわけです。たとえば無作為割り当てを行えば，交絡変数は異なる群のあいだにランダムかつ均等に散らばることになります。

とはいえ，物事には一長一短がありまして，交絡変数ではなく人工産物のほうを考え始めると，立場はまるきり逆になります。たいていの場合，人工産物としての結果は，非実験的な研究よりも実験的な研究のほうで問題になりがちなのです。このことを理解するには，多くの研究が非実験的である理由が，まさに研究者がより自然な文脈で人間の行動を調べようとしているからだ，ということに気づくのが助けになります。より現実に近い文脈で研究すれば実験的な統制は失われますが（そのぶん交絡変数に弱くなります），人間の心理を“野生の状態”で研究することになりますので，人工産物としての結果を得る可能性は減るわけです。別の言い方をすると，心理学を野生から連れ出して実験室に持ち込むとき（実験的な統制を得るためには普通そうしなければなりません），あなたは本当に研究したかったものとは違うものをうっかり研究してしまうリスクを常に負っているのです。

ただし，気をつけてください。いま述べたのは大まかな目安にすぎません。実験に交絡変数が入り込むことも，非実験的な研究で人工産物としての結果が出ることも，十分にあり得ます。これはいろいろな理由で起こりますが，なかでも大きいのが実験者や研究者のミスです。実際のところ，あらか

*6測定されていない，とわざわざ言ったのは，もし測定しているのであれば，ちょっと洒落た統計的テクニックを使って交絡変数を処理できるからです。交絡変数の問題にはこうした統計的な解決策があるので，測定して処理済みの交絡変数のことを共変量と呼ぶことがよくあります。共変量の扱いはもっと進んだトピックになりますが，そういうものがあると知っておくだけでも少し安心できますから，ここで触れておくことにしました。

じめすべてを考え尽くすというのは本当に難しいことで、とても優秀な研究者でも間違えるのです。

妥当性への脅威はほとんどすべて、交絡変数か人工産物のどちらかとして特徴づけられるという面はあるのですが、これらはかなり漠然とした概念です。そこで、よくある例をいくつか見ていくことにしましょう。

1.7.1 歴史効果

歴史効果とは、研究の最中に特定の出来事が起こって、それが結果の測定値に影響してしまう可能性のことです。たとえば、事前テストと事後テストのあいだに何かが起こるかもしれません。あるいは、23人目の参加者と24人目の参加者のテストのあいだかもしれません。また、当時としては完璧に妥当だった古い研究の論文を読んでいるけれども、その後世界のほうが変わってしまって、結論がもはや信頼できない、ということもあるでしょう。歴史効果にあたるものの例を挙げてみます。

- あなたは、人々がリスクと不確実性についてどう考えるかに関心を持っています。データ収集は2010年12月に始めました。しかし参加者を見つけてデータを集めるには時間がかかりますので、2011年2月になってもまだ新しい人を探しています。あなたにとって不運なことに(そしてもっと不運な人たちがいるわけですが)、2011年1月にクイーンズランド州で洪水が起こり、何十億ドルもの被害と多くの死者を出しました。当然というべきか、2011年2月に調査された人たちは、2010年12月に調査された人たちとはリスクの扱いについてかなり異なる信念を表明します。このうちどちらが参加者の“本当の”信念を反映しているのでしょうか。答えはおそらく両方だろうと私は思います。クイーンズランドの洪水は、たとえ一時的であつたとしても、オーストラリアの人々の信念を実際に変えたのです。ここで重要なのは、2月に調査された人たちの“歴史”が、12月に調査された人たちとはまるで違っているということです。
- あなたは新しい抗不安薬の心理的效果を調べています。そこで、薬を投与する前に不安を測定します(たとえば自己報告と生理的指標によって)。それから薬を投与し、あとで同じ測定を行います。ところがその途中で、あなたの研究室はロサンゼルスにありますので、地震が起きて参加者の不安が高まってしまいました。

1.7.2 成熟効果

歴史効果と同じように、**成熟効果**も基本的には時間経過に伴う変化の話です。ただし成熟効果は、特定の出来事への反応ではありません。そうではなく、人が時間とともに自分自身で変わっていくことに関係しています。歳をとりますし、疲れますし、飽きもします。成熟効果の例をいくつか挙げてみましょう。

- 発達心理学の研究をするときは、子どもがかなり急速に成長することを意識しておく必要があります。たとえば、ある教育的な工夫が3歳児の語彙数を増やすのに役立つかどうかを知りたいとしましょう。ここで気をつけなければならないのは、その年齢の子どもの語彙数は、放っておいてもとんでもない速さで(1日に何語も)増えていくということです。この成熟効果を考慮せずに研究をデザインしてしまうと、あなたの教育的な工夫が効いているのかどうかを判断できません。
- 実験室でとても長い実験(たとえば3時間かかるようなもの)を行うときには、参加者が飽きたり疲れたりし始める可能性が非常に高く、この成熟効果のせいで、実験の中で他に何が起きているようとパフォーマンスが低下してしまいます。

1.7.3 反復測定効果

歴史効果の重要な一種に、**反復測定**の効果があります。ある心理的構成概念(たとえば不安)を2回測定したいとしましょう。心配になるのは、1回目の測定が2回目の測定に影響してしまわないか、ということです。言い換えるなら、2回目の測定に影響する“出来事”が1回目の測定そのものである、という歴史効果です。これはまったく珍しいことではありません。例を挙げましょう。

- **学習と練習**: たとえば、1回目の測定のときに参加者が“知能テスト風”の問題の解き方の一般的なコツを学んでしまったために、2回目の“知能”が1回目より上がったように見える、といったことです。
- **検査場面への慣れ**: たとえば、1回目に緊張していればパフォーマンスは下がるでしょう。しかし1回目を最後まで経験してしまえば、どんな検査なのかを見てしまったわけですから、かなり落ち着くことになります。
- **測定によって生じる副次的な変化**: たとえば、気分を測る質問紙が退屈なものであれば、1回目の測定が退屈だったせいで、2回目の気分評定が“退屈”寄りになりやすくなります。

1.7.4 選択バイアス

選択バイアスというのは、かなり広い意味を持つ言葉です。ふたつの参加者群を使った実験を行っていて、それぞれの群には異なる“処遇”が与えられ、処遇の違いが結果の違いをもたらすかどうかを見たい、としましょう。ところが、最善を尽くしたにもかかわらず、群間で性別の偏りが生じてしまったとします(たとえばA群は女性が80%、B群は女性が50%)。そんなことは起こりっこないと思うかもしれませんが、信じてください、起こります。これが選択バイアスの例で、ふたつの群に“選ばれて入った”人たちの特性が異なっているわけです。もしその特性が結果に関係するもの(たと

えばあなたの処遇が男性より女性によく効く) だとしたら、これは大問題です。

1.7.5 脱落の偏り

脱落の影響について考えるときには、2種類に区別しておく役に立つことがあります。ひとつめは**均質な脱落**で、脱落の効果がすべての群、処遇、条件で同じである場合です。さきほどの例で言えば、飽きっぽい参加者が実験のすべての条件からだいたい同じ割合で抜けていく場合に(そしてその場合に限って)、脱落は均質だということになります。一般に、均質な脱落の主な影響は、標本が代表的でなくなってしまうことです。ですから、いちばんの心配は結果の一般化可能性が下がることになります。つまり、外的妥当性が失われるわけです。

ふたつめの脱落は**不均質な脱落**で、脱落の効果が群ごとに異なる場合です。こちらは**脱落の偏り**と呼ばれることのほうが多く、研究そのものが引き起こす一種の選択バイアスです。心理学の歴史上はじめて、完璧にバランスのとれた代表的な標本を見つけることに成功した、としましょう。その完璧な標本に“ダニのとんでもなく長くて退屈な実験”を実施し始めるのですが、なにしろとんでもなく長くて退屈なものですから、多くの人が脱落し始めます。これを止めることはできません。参加者には、どんな実験であれ、いつでも、どんな理由であれ、やめる権利が絶対にありますし、研究者としての私たちには、その権利があることを伝える道徳的(かつ職業的)な義務があります。さて、“ダニのとんでもなく長くて退屈な実験”の脱落率がとても高かったとしましょう。この脱落がランダムである見込みはどのくらいだと思いますか。答えはゼロです。ほぼ確実に、残った人たちは去った人たちよりも勤勉で、退屈に強い人たちなのです。たとえば勤勉さが、私が関心を持っている心理現象に関係する程度に応じて、この脱落は結果の妥当性を下げることになります。

もうひとつ例を挙げましょう。ふたつの条件からなる実験をデザインしたとします。“処遇”条件では、実験者が参加者を侮辱してから、服従性を測る質問紙に答えてもらいます。“統制”条件では、実験者はどうでもいい世間話を少しして、それから質問紙に答えてもらいます。この研究の怪しい科学的価値と疑わしい倫理性はさておき、何がまずいことになりそうかを考えてみましょう。一般論として、面と向かって侮辱されると、人はぐっと非協力的になるものです。ですから、統制条件よりも処遇条件のほうがずっと多くの人が脱落する可能性がかなり高いわけです。そしてこの脱落はランダムではありません。いちばん脱落しやすいのは、おそらく、実験に従順に最後まで付き合うことの重要性をさほど気にしない人たちでしょう。いちばん反抗的で従順でない人たちが処遇群からは去り、統制群からは去らなかったのですから、ここに交絡が持ち込まれたことになります。つまり処遇群で実際に質問紙に答えた人たちは、統制群の人たちよりもともと従順で言うことを聞きやすい人たちだったのです。要するにこの研究では、侮辱することで人が従順になったのではありません。よ

り反抗的な人たちを実験から追い出ただけなのです。この実験の内的妥当性は完全に台無しです。

1.7.6 無回答バイアス

無回答バイアスは、選択バイアスや脱落の偏りと密接に関係しています。いちばん単純な形はこうです。1000 人に調査票を郵送したところ、返ってきたのは 300 人分だけでした。回答した 300 人は、ほぼ確実にランダムな部分標本ではありません。調査に回答する人は、回答しない人と系統的に異なっているのです。ここから、回答した 300 人から母集団全体へ一般化しようとするときに問題が生じます。標本がまったくランダムではなくなっているからです。ただし、無回答バイアスの問題はこれだけにとどまりません。たとえば回答した 300 人のなかでも、全員がすべての設問に答えているとは限らないでしょう。仮に 80 人がある設問に答えないことを選んだとしたら、これは問題になるでしょうか。いつものように、答えは「場合による」です。答えられなかった設問が質問紙の最終ページにあり、その 80 通が最終ページを欠いた状態で返送されてきたのなら、欠測はたいした問題ではない可能性が高いでしょう。おそらくページが外れてしまっただけです。しかし、80 人が答えなかった設問が、質問紙のなかでもっとも対決的だったり個人に踏み込んだりするものだったなら、ほぼ確実に問題があります。要するにここで扱っているのは、**欠測データ**と呼ばれる問題です。欠けているデータがランダムに“失われた”のであれば、大した問題ではありません。系統的に欠けているのであれば、大問題になり得ます。

1.7.7 平均への回帰

平均への回帰とは、ある指標の極端な値にもとづいてデータを選んだときに起こることを指します。その変数には自然なばらつきがありますから、次に測定したときには、純粋に偶然によって、2 回目の測定値は 1 回目ほど極端ではなくなるのがほぼ確実なのです。

例を挙げましょう。心理学教育がとても優秀な子どもたちに悪影響を与えるかどうかに関心があるとします。そこで、高校の成績が最上位だった心理学 1 の受講生 20 名を選び、大学でどのくらいの成績をとっているかを見ます。すると、平均よりはずっと良い成績なのですが、高校ではクラスの首位だったのに、大学では首位になっていないことがわかりました。どういうことでしょうか。まず自然に思いつくのは、心理学の授業がその学生たちに悪影響を与えているに違いない、ということです。しかし、それが説明になっている可能性は十分にあるものの、ここで見ているのは“平均への回帰”の一例である可能性のほうが高いのです。どういう仕組みかを見るために、高校であれ大学であれ、クラスで最高点をとるには何が必要かを少し考えてみましょう。大きなクラスであれば、とても優秀な人がたくさんいます。最高点をとるには、とても優秀で、とても努力していて、そして少し運が良くなければなりません。試験があなた特有の得意分野にぴったり合った問題を出してくれる必要がありますし、答えるときにばかな間違い（誰にでもたまにあることです）をしないようにしなければなりません。そこが肝心なところで、知性と努力はひとつのクラスから次のクラスへ持ち越

せませんが、運は持ち越せないのです。高校で運が良かった人と、大学で運が良い人は同じではありません。それがまさに“運”の定義というものです。この結果として、ある測定値の極端な値の人たち(上位 20 名)を選ぶとき、あなたは努力と能力と運を同時に選んでいることになります。ところが運のほうは 2 回目の測定に持ち越されません(持ち越されるのは能力と努力だけです)ので、2 回目に測定したとき(大学で)には、この人たちはみな少し下がると予想されるわけです。つまり得点は少し下がり、他のみんなのほうへ戻っていきます。これが平均への回帰です。

平均への回帰は驚くほどよく起こります。たとえば、とても背の高いふたりに子どもができれば、その子どもは平均より背が高くなる傾向はあるものの、親ほどは高くないでしょう。とても背の低い親の場合は逆のことが起こります。とても背の低い親からは背の低い子どもが生まれる傾向がありますが、それでもその子どもたちは親より背が高くなる傾向があるのです。また、この現象はきわめて見えにくいこともあります。たとえば、人は肯定的なフィードバックよりも否定的なフィードバックからよく学ぶ、ということを示唆する研究がありました。しかしこれを示すためにとられた方法は、うまくできたときには正の強化を与え、できなかったときには負の強化を与える、というものでした。そして観察されたのは、正の強化のあとには成績が下がり、負の強化のあとには成績が上がる傾向がある、ということでした。しかしここに選択バイアスがあることに気づいてください。とてもうまくできたときというのは“高い”値を選んでいるわけですから、平均への回帰によって、強化が与えられたかどうかとは無関係に、次の試行の成績は悪くなると予想されるべきなのです。同じように、悪い試行のあとには、放っておいても成績は上がる傾向があります。否定的なフィードバックが優れているように見えるのは、平均への回帰によって生じた人工産物なのです(Kahneman1973)。

1.7.8 実験者バイアス

実験者バイアスにはいろいろな形があります。基本的な考え方は、実験者が善意にもかかわらず、“正解”や“望ましい行動”をそれとなく参加者に伝えてしまい、結果的にうっかり実験結果に影響を与えてしまう、というものです。これは典型的には、実験者が参加者の持っていない特別な知識、たとえば尋ねている質問の正解や、参加者が置かれた条件で期待される成績のパターンについての知識を持っているために起こります。この古典的な例が、1907 年にさかのぼる“賢いハンス”の事例研究です(Pfungst1911; Hothersall2004)。賢いハンスは、字が読めて数が数えられ、そのほか人間のような知的芸当ができるように見えた馬でした。賢いハンスが有名になったあと、心理学者たちがその行動を詳しく調べ始めました。結果はというと、驚くまでもなく、ハンスは計算のやり方など知らなかったのです。そうではなく、ハンスは周囲の人間の観察者に反応していました。人間のほうは数え方を知っていましたし、馬のほうは人が行動を変えたときに自分も行動を変えることを学習していたのです。

実験者バイアスの問題に対する一般的な解決策は二重盲検法で、実験者も参加者も、参加者がどの条件にいるのか、望ましい行動が何なのかを知らないようにするものです。これは非常に良い解決策

なのですが、完璧に理想的というわけではありませんし、きちんとやり切るのは難しいということも認識しておく必要があります。たとえば、二重盲検の研究を組むいちばんわかりやすい方法は、私の博士課程の学生のひとり(その実験について何も知らない学生)に研究を実施してもらうことでしょう。これで十分な気がします。すべての詳細(たとえば設問の正解や、参加者の条件への割り当て)を知っている唯一の人物(私)は参加者と接触しませんし、参加者と話をする人物(博士課程の学生)は何も知らないのですから。ただし、最後の部分が本当である見込みはきわめて低い、という現実があります。博士課程の学生が研究をきちんと実施するためには、研究者である私から説明を受ける必要があります。そして、たまたまですが、その博士課程の学生は私のことを知っていますし、人間や心理学についての私の一般的な考え(たとえば私は、人間は心理学者が評価するよりずっと賢いと考えがちです)もいくらか知っています。そんなわけで、実験者が私の期待を少しも知らずにいるというのは、ほとんど不可能なのです。そして、ほんの少しの知識でも影響を及ぼし得ます。実験者が、この課題では参加者がうまくできると期待されている、ということをうっかり伝えてしまったとしましょう。“ピグマリオン効果”というものがありまして、人に大きな期待をかければ、その人はそれに応えようとする傾向があります。しかし失敗すると期待すれば、そのとおりになるのです。つまり期待が自己成就的予言になってしまうわけです。

1.7.9 要求特性と反応性

実験者バイアスの話では、実験者の知識や実験への期待が参加者に伝わってしまい、それが人の行動を変えてしまうことが心配でした(Rosenthal1966)。しかし、これをうまく防げたとしても、自分が心理学の研究に参加しているという事実を参加者に知らせずにおくことは、ほとんど不可能です。そして、誰かが自分を見ている、研究しているとわかっているというだけで、行動にはかなり大きな影響が出ます。これは一般に**反応性**あるいは**要求特性**と呼ばれます。基本的な考え方はホーソン効果によく表れています。研究が自分に注意を向けているという理由で、人はパフォーマンスを変えてしまうのです。この効果の名前は、シカゴ郊外の“ホーソン工場”で行われた研究に由来します(Adair1984)。1920年代のこの研究は、工場の照明が労働者の生産性に与える影響を調べたものでした。しかし重要なことに、労働者の行動が変わったのは工場の照明のせいではなく、自分たちが研究されていると知っていたからだったのです。

研究に参加しているというだけで人の行動がどう変わるのか、もう少し具体的に見ていきましょう。ここでは社会心理学者のように考えて、実験中にはとるかもしれないけれども、同じ出来事が現実世界で起きていたらとらないかもしれない役割をいくつか見てみると役に立ちます。

- **良い参加者**は、研究者に対して協力的すぎようとします。実験者の仮説を見抜いて、それを確証しようとするのです。
- **否定的な参加者**は、良い参加者のちょうど逆をやります。なんらかの形で研究や仮説を壊してやろうとするのです。
- **忠実な参加者**は不自然なほど従順です。より現実的な場面ならどうしたかとは無関係に、教示

を完璧に守ろうとします。

- 不安な参加者は、テストされたり研究されたりすることに緊張してしまい、その結果として行動がひどく不自然になったり、社会的に望ましすぎるものになったりします。

1.7.10 プラセボ効果

プラセボ効果は、私たちがとても気にしている要求特性の一種です。治療を受けたという事実だけで結果が改善してしまう状況を指します。古典的な例は臨床試験から来ています。化学的にまったく不活性な薬を渡して、これは病気を治す薬だと伝え、まったく治療を受けなかった人よりも早く良くなる傾向があるのです。つまり、結果を改善させているのは薬ではなく、治療を受けているという信念のほうなのです。

ただし医学における現在の合意は、真のプラセボ効果はかなりまれであり、かつてプラセボ効果とされていたものの大部分は、実際には自然治癒 (放っておいても良くなる人がいます)、平均への回帰、そのほか研究デザイン上の癖の組み合わせだ、というものです。心理学にとって興味深いのは、少なくとも何らかのプラセボ効果があるというもっとも強い証拠が、自己報告による結果、とりわけ痛みの治療において得られているという点です (hrobjartsson2010)。

1.7.11 状況・測定・下位母集団の効果

ある意味でこれらの用語は、“そのほかすべての外的妥当性への脅威”をまとめて指す便利な言葉です。参加者をどの下位母集団から集めるかという選択、研究を実施する場所・時期・やり方 (誰がデータを集めるかも含みます)、そして測定に使う道具、これらすべてが結果に影響しているかもしれない、ということを指しています。具体的な心配は、これらが結果に影響することで、より広い範囲の人・場所・測定へ結果が一般化できなくなってしまうことです。

1.7.12 不正、欺瞞、自己欺瞞

ある人にものごとを理解させるのは難しい。その人の給料が、それを理解しないことにかかっている場合には。

– Upton Sinclair

最後にひとつ、触れておくべきだと思うことがあります。研究の妥当性の評価について教科書がよく述べていることを読んでみると、どうしても気になるのが、どの本も研究者は正直であると仮定しているように見えることです。これは笑ってしまいます。少なくとも私の経験では、科学者の大多数

は正直ですが、そうでない人もいますのです*7。それだけでなく、先に述べたように、科学者も信念バイアスと無縁ではありません。研究者が自分自身を欺いて間違っことを信じてしまうのは簡単なことですし、そこから微妙に欠陥のある研究を行い、論文にするときにその欠陥を隠す、ということも起こり得ます。ですから、あからさまな不正という(おそらくありそうにない)可能性だけでなく、研究が意図せず“偏って”しまっているという(おそらくかなりよくある)可能性も考えておく必要があります。標準的な教科書を何冊か開いてみたのですが、この問題についての議論はあまり見当たりませんでしたので、こうした問題が生じうる形を私なりに挙げてみることにします。

- **データの捏造**。単純にデータをでっちあげてしまう人がいます。これは“善意”から行われることもあります。たとえば研究者が、捏造したデータこそ真実を反映していると信じている場合で、実際のデータを“ちょっときれいにした”ものになっていることもあります。一方で、意図的かつ悪意のある不正の場合もあります。データ捏造が指摘されたり明らかになったりした有名な例としては、Cyril Burt(データの一部を捏造したと考えられている心理学者)、Andrew Wakefield(MMR ワクチンと自閉症を結びつけるデータを捏造したと非難されている人物)、そして黄禹錫(幹細胞研究で多くのデータを改竄した人物)などがあります。
- **でっちあげ**。でっちあげはデータ捏造とよく似ていますが、意図する目的が異なります。でっちあげはしばしば冗談であり、その多くは(いずれ)見破られることを意図しています。でっちあげの狙いは、誰かやある分野の信用を失わせることであることが多いのです。長年のあいだにはよく知られた科学上のでっちあげがいくつもありましたし(たとえばピルトダウン人)、特定の研究分野の信用を落とすための意図的な試みもありました(たとえばソーカル事件)。
- **データの不正確な提示**。見出しを飾るのは不正のほうですが、私の経験ではデータが不正確に提示されているのを見ることのほうがずっと多いのです。これは新聞が間違えること(ほとんど毎回間違えています)を言っているのではありません。データが研究者の考えているようなことを実際には語っていない、ということがよくある、という話です。私の推測では、ほとんどの場合これは意図的な不誠実さの結果ではなく、データ分析の洗練が足りないせいです。たとえば、本書のはじめのほうで扱ったシンプソンのパラドックスの例を思い出してください。何らかの形で“集計された”データが提示されるのはごく普通のことですが、掘り下げて生データを自分で見てみると、集計データと非集計データとがまったく違う話をしていることがあります。あるいは、都合の悪い話をするという理由で、データのある側面が隠されているのに気づくこともあります(たとえば研究者が、ある変数について触れないことを選ぶ、など)。この種の変種はたくさんありますし、その多くは見抜くのがとても難しいのです。
- **研究の“デザインミス”**。これは微妙な話です。基本的な問題は、研究者が最初から欠陥を組

*7正直でないなら本物の科学者ではない、と主張する人もいでしょう。それにも一理あるとは思いますが、それは不誠実な言い方です(“本物のスコットランド人”の誤謬を調べてみてください)。実際には、表向きは科学者として雇われ、その仕事も見た目は完全に科学でありながら、まったくの不正を働いている人がたくさんいるのです。そういう人は科学者ではないと言ってその存在をなかったことにするのは、ただの混乱した考え方です。

み込んだ研究をデザインし、その欠陥が論文で報告されることは決してない、というものです。報告されるデータは完全に本物で、正しく分析されているのですが、そのデータを生み出した研究のほうがかかなりおかしい組み立てになっているのです。研究者はどうしてもある効果を見つけないので、その効果が(人工産物として)“簡単に”観察できるように研究を組んでしまいます。もしあなた自身がちょっと不正に手を染めてみたいなら、こんなずるいやり方があります。参加者にとって自分が何をやる“ことになっている”のかが見え見えの実験をデザインし、あとは反応性に魔法をかけてもらうのです。お望みなら二重盲検法の体裁をすべて整えることもできますが、研究の材料そのものが、あなたのしてほしいことをそれとなく参加者に伝えているのですから、何の違いも生みません。結果を論文にしたとき、読者にはこの不正はわかりません。実験の文脈にいる参加者には見え見えのことが、論文を読む人にも見え見えだとは限らないからです。もちろん、こう書くといつでも不正であるかのように聞こえますね。意図的に行われる場合もあるでしょうが、私の経験ではより大きな問題は意図しないデザインミスの方です。研究者が信じてしまっているために、たまたま研究に欠陥が組み込まれ、そして論文にする段階でその欠陥が魔法のように消えてしまうのです。

- **データマイニングと事後的な仮説づくり**。研究の著者がデータを多かれ少なかれ不正確に提示してしまうもうひとつの方法が、“データマイニング”と呼ばれるものです (Gelman2014)。のちほど議論しますが、データをいろいろな方法で分析し続けていけば、いずれは本物の効果に“見える”けれども本物ではないものが見つかります。これが“データマイニング”です。かつてはデータ分析に何週間もかかりましたのでかなりまれなことでしたが、いまや誰もが非常に強力な統計ソフトを自分のコンピュータに持っていますので、ごく普通のことになりつつあります。データマイニングそれ自体が“間違い”なのではありませんが、やればやるほど大きなリスクを負うことになります。間違いなのは、そして私の疑うところではとてもよくあるのは、明示されないデータマイニングです。つまり研究者が、人類の知る限りのあらゆる分析を実行し、うまくいくものを見つけ、そしてそれが最初から唯一実施した分析であるかのようにふるまう、ということです。さらに悪いことに、データマイニングを隠すために、データを見たあとで仮説を“発明”することもよくあります。はっきりさせておきましょう。データを見たあとで自分の考えを変えることも、新しい“事後的な”仮説を使ってデータを再分析することも、間違いではありません。間違いなのは(そして私の疑うところではよくあるのは)、そうしたことを明示しないことです。明示すれば、他の研究者はあなたのふるまいを考慮に入れることができます。明示しなければ、それができません。そしてそれが、あなたのふるまいを人を欺くものにしてしまうのです。よくないことです。
- **出版バイアスと自己検閲**。最後に、広く行き渡っているバイアスが、否定的な結果の“非報告”です。これを防ぐのはほとんど不可能です。雑誌は投稿された論文をすべて掲載するわけではありません。“何か”を見つけた論文のほうを載せたがるのです。ですから、20人がフィネガンズ・ウェイクを読むと人は正気を失うかどうかを調べる実験を行い、そのうち19人が「そんなことはない」という結果を得たとしたら、掲載されるのはどれだと思いますか。もちろ

ん、フィネガンズ・ウェイクが正気を失わせると見つけた 1 本の研究です*8。これが出版バイアスの例です。効果を見つけないかった 19 本の研究は誰も発表しませんでしたので、素朴な読者はそれらが存在したことすら知りません。さらに悪いことに、ほとんどの研究者はこのバイアスを“内面化”してしまい、自分の研究を自己検閲するようになります。否定的な結果は掲載してもらえないとわかっているのに、報告しようとすらしめないのです。私の友人の言葉を借りれば、“掲載される実験 1 本につき、失敗が 10 本ある”のです。彼女の言うとおりで。厄介なのは、そうした研究のいくつか(たぶん大部分)はつまらない理由による失敗(たとえば何かをしくじった)なのですが、中には“うまくいった”実験を論文にするとときに明示すべき、本物の“帰無”の結果もあるということです。そして、どちらがどちらなのかを見分けるのはたいてい難しいのです。手始めには、“なぜ発表される研究知見のほとんどは偽なのか”という気の滅入るタイトルの **Ioannidis2005** の論文がよいでしょう。これが心理学で実際に起きているという統計的証拠を示した **Kuhberger2014** の研究も見てみることをお勧めします。

この種の問題は、考えるべきものがまだたくさんあるでしょうが、手始めとしてはこのくらいでよいでしょう。私が本当に指摘したいのは、現実世界の科学は生身の人間によって行われているという、あまりにも当たり前の事実です。他のみんなが正直で公平だと自動的に仮定してしまうのは、よほど騙されやすい人だけです。実際の科学者はふつうそこまでうぶではないのですが、どういうわけか世間は私たちがそうであるかのように振る舞いたがりますし、私たちが書く教科書もそのステレオタイプを強めているように見えます。

1.8

要約

この章は、心理学の研究法を網羅的に論じようとしたものではありません。このテーマをきちんと扱おうとしたら、本書と同じくらいの分量の本がもう 1 冊必要になるでしょう。とはいえ現実には、統計と研究デザインはとても密接に絡み合っていますので、重要なトピックをいくつか押さえておくにととても役に立ちます。この章では、次のようなトピックを簡単に見てきました。

- 心理学的測定への導入 (セクション ??)。理論的な構成概念を操作化するにはどうやってしようか。変数を持ち、測定を行うにはどうやってしようか。
- 測定の尺度と変数の種類 (セクション ??)。ここにはふたつの異なる区別があったことを思い出してください。ひとつは離散データと連続データの違い、もうひとつは 4 つの尺度水準 (名

*8本当のところは、そもそもフィネガンズ・ウェイクを読もうとするのは正気でない人だけだ、というだけの話でしょうけど。

義・順序・間隔・比率)の違いです。

- **測定信頼性 (セクション ??)**。“同じ”ものを2回測ったら、同じ結果が出ると期待してよいでしょうか。測定が信頼できる場合に限ります。しかし“同じ”ことをする、とはどういう意味でしょうか。だからこそ、信頼性にはいくつもの種類があるのです。それが何だったかをしっかり覚えておいてください。
- **用語: 予測変数と結果変数 (セクション ??)**。分析のなかで変数はどんな役割を果たすのでしょうか。予測変数と結果変数の違いを覚えているのでしょうか。従属変数と独立変数はどうでしょう。
- **実験的な研究デザインと非実験的な研究デザイン (セクション ??)**。実験を実験たらしめているものは何でしょうか。それは立派な白衣でしょうか、それとも研究者が変数を統制することと関係があるのでしょうか。
- **妥当性とその脅威 (セクション ??)**。あなたの研究は、測りたいものを測っているのでしょうか。何がうまくいかなくなり得るのでしょうか。それにしても、うまくいかなくなり得るやり方のリストは、やたらと長くありませんでしたか。気のせいでしょうか。

ここまでの話で、研究デザインが研究方法論のきわめて重要な一部であることがはっきりしたと思います。この章は **Campbell1963** の古典的な小著をもとに組み立てましたが、研究デザインについての教科書はもちろん山ほどあります。お気に入りの検索エンジンで数分も探せば、何十冊も見つかるでしょう。