

1. 仮説検定

推論のプロセスは、我々の経験と調和するもっとも単純な法則を見つけ出すプロセスです。しかし、このプロセスに論理的な基盤はなく、心理学的なものしかありません。もっとも単純なものが事象を引き起こすと信じるに足る、どのような根拠もないことは明らかなのです。明日太陽が登るというのも仮説にすぎず、日が昇るかどうかはわからないものです。

— ルードヴィッヒ・ヴィトゲンシュタイン^{*1}

この前の章で、推定の背後にある考え方に追って論じました。それは推測統計学における2つの“大きな考え方”のひとつです。今度はもうひとつの大きな考え方、仮説検定をみることにしましょう。その最も抽象的な形でいうと、帰無仮説検定はとてもシンプルな考え方です。研究者は世界に対するある理論をもっており、実際のデータはその理論を支持するかどうかを判断したいと思っている、というだけです。しかし細かいところは面倒で、ほとんどの人は統計学の中で仮説検定が一番フラストレーションが貯まる場所だといいます。この章の構成は次のようになっています。まず、仮説検定の仕組みについて簡単な例を使って詳しく説明し、仮説検定がどのように“できあがっているか”をみることにします。このとき過度にならないように注意しつつ、検定手続の背後にあるロジックに注目するようにします。^{*2}その後、仮説検定を取り巻くさまざまな問題点、ルール、異端の考え方を取り上げます。

1.1

^{*1}この一文はヴィトゲンシュタイン (1922) の書籍、*論理哲学論考*からのものです。

^{*2}技術的な注意を。以下の説明は、標準的なテキストの記述とは少し違っています。オーソドックスな帰無仮説検定は、20世紀初頭にロナルド・フィッシャーとイェジ・ネイマンによって作られました。しかしフィッシャーとネイマンは、それがどのように機能するかについて全く異なる視点を持っていました。ほとんどのテキストで使われる標準的な仮説検定の扱いは、このふたつのアプローチを混ぜたものなのです。ここではオーソドックスなやり方よりややネイマンより、特に p 値の意味をどう考えるかについてはネイマンスタイルを取ろうと思います。

さまざまな仮説

結局、我々は狂気に負けてしまうものです。私にとって、その日は教授に昇格した時にやってくるでしょう。象牙の塔に安住し、幸運にも終身在職権に守られるようになれば、いよいよ (いわば) 自分の感覚を捨てて、心理学研究のなかでも最も非生産的な分野である、超感覚 (ESP) の研究に取り掛かろうと思います^{*3}。

さあこの輝かしい日がやってきたとしましょう。最初の研究はシンプルに、千里眼が存在するかどうかを検証するということにします。被験者は席について、実験者がカードを示します。カードの一方は黒で反対は白くなっています。実験者はそのカードを持って行き、隣の部屋のテーブルに置きます。カードは黒い面を上にするか白い面を上にするか完全にランダムに置かれ、そのランダム化は実験者が被験者のいる部屋を出たあとにはじめて行われます。そこへ2人目の実験者が入ってきて、いまカードのどちらの面が上を向いているかを被験者に尋ねます。これは完全に一発勝負の実験です。それぞれの人は1枚のカードしか見ませんし、答えるのも1回だけで、どの段階でも被験者が正解を知っている人と接触することはありません。ですからデータはとても単純です。N人に質問して、そのうちX人が正しく答えた、というだけです。具体的にするために、N = 100人を調べて、そのうちX = 62人が正解したとしましょう。確かに驚くほど大きな数ですが、ESPの証拠を見つけないと安心して主張できるほど大きいでしょうか。仮説検定が役に立つのは、こういう場面です。ただし仮説をどう検定するかを話す前に、仮説とは何を指すのかをはっきりさせておく必要があります。

1.1.1 研究仮説と統計的仮説

まず頭のなかではっきり区別しておかなければならないのが、研究仮説と統計的仮説です。私のESP研究では、全体としての科学的な目標は千里眼が存在することを示すことです。この場合、研究目標ははっきりしています。ESPの証拠を見つけないのです。別の場面ではもっと中立的な立場をとって、千里眼が存在するかどうかを明らかにすることが研究目標だ、と言うかもしれません。自分をどう見せたいかはさておき、ここで伝えたい基本的な点は、研究仮説とは実質的で検証可能な科学的主張をすることだ、ということです。あなたが心理学者なら、研究仮説は基本的に心理学的な構成概念についてのものになります。次のようなものはどれも**研究仮説**にあたります。

- 音楽を聴くと、他のことに注意を向ける能力が下がる。これは心理学的に意味のある2つの概念 (音楽を聴くことと、物事に注意を向けること) のあいだの因果関係についての主張ですから、まったく妥当な研究仮説です。

^{*3}これを本気で信じている人には申し訳ないのですが、ESPについての文献を読むと、現実的であると考えるのは合理的ではありません。しかし、公平にみて、幾つかの研究は合理的にデザインされており、心理学研究デザインについて考えるいい分野であるとは言えます。そしてもちろんここは自由の国ですから、私が間違っていることを証明するためにあなたが時間と労力を費やすこともできますが、あなたの知性のいい使い方とは思えないですね。

- 知能はパーソナリティと関連している。これも前のものと同じく、2つの心理学的構成概念(知能とパーソナリティ)についての関係の主張ですが、主張はより弱いものです。因果ではなく相関だからです。
- 知能とは情報処理の速さである。この仮説はまったく性質が異なります。そもそも関係についての主張ではありません。知能の根本的な性質についての存在論的な主張です(そして私はこれが間違いだとかかなり確信しています)。これについては少し広げておく価値があります。“XはYに影響するか”という形の研究仮説を検証する実験を組み立てるほうが、“Xとは何か”という主張に取り組むよりもふつうは簡単です。そして実際には、存在論的な主張から導かれる関係の主張を検証する方法を見つける、ということになるのが普通です。たとえば、知能とは脳内の情報処理の速さであると信じているなら、実験では知能の指標と速さの指標の関係を探さることが多くなるでしょう。その結果、日常的な研究上の問いの多くは関係についてのものになりがちですが、その動機はほとんど常に、自然のありようについてのより深い存在論的な問いにあるのです。

実際には、研究仮説どうしがかなり重なりうることに注意してください。ESP 実験での最終的な目標は“ESP が存在する”という存在論的な主張を検証することかもしれませんが、操作的には“一部の人は千里眼のようなやり方で物を‘見る’ことができる”といったより狭い仮説に自分を制限するかもしれません。とはいえ、どんな意味でもまともな研究仮説とは言えないものもあります。

- 愛は戦場だ。これは漠然としすぎていて検証できません。研究仮説にある程度の曖昧さがあるのは構わないのですが、理論的な考えを操作化できる必要があります。私の発想力が足りないだけかもしれませんが、これをどうやって具体的な研究デザインに落とし込めるのか、私にはわかりません。もしそうだとすれば、これは科学的な研究仮説ではなく、ポップソングです。だからといって興味深くないという意味ではありません。人間が抱く深い問いの多くはこの部類に入ります。いつか科学が愛についての検証可能な理論を組み立てられるようになったり、神が存在するかどうかを検証できるようになったりするかもしれません。しかし今のところそれはできませんし、どちらについても満足のいく科学的アプローチが現れるほうに賭けようとは思いません。
- トートロジー・クラブの第一のルールは、トートロジー・クラブの第一のルールである。これはいかなる意味でも実質的な主張ではありません。定義上正しいのです。考えうるどんな自然のありようも、この主張と矛盾しえませんが、これは反証不可能な仮説と呼ばれ、そうであるがゆえに科学の領域の外にあります。科学で何をするにせよ、あなたの主張は間違っている可能性を持っていなければなりません。
- 私の実験では“いいえ”より“はい”と答える人のほうが多いだろう。これが研究仮説として失格なのは、心理についてではなくデータについての主張だからです(もちろん、本当の研究上の問いが人には“はい”と答える偏りがあるかどうか、というのであれば話は別ですが)。実

のところこの仮説は、研究仮説というより統計的仮説に近く聞こえてきます。

このように、研究仮説は時にいささか雑然としたものになりますし、結局のところ科学的な主張です。**統計的仮説**はそのどちらでもありません。統計的仮説は数学的に厳密でなければなりませんし、データを生成する仕組み(つまり“母集団”)の特性についての具体的な主張に対応していなければなりません。とはいえ、統計的仮説はあなたが関心を持っている実質的な研究仮説とはっきり関係していることが意図されています。たとえば私の ESP 研究では、研究仮説は「一部の人は壁の向こうか何かを見通せる」というものです。やりたいのは、これをデータがどう生成されたかについての言明へ“写像”することです。ではその言明がどうなるかを考えてみましょう。実験のなかで私が関心を持っている量は P (“正解”), つまり実験の参加者が質問に正しく答える、真ではあるが未知の確率です。この確率をギリシャ文字の θ (シータ) で表すことにしましょう。統計的仮説として、次の 4 つが考えられます。

- ESP が存在せず、実験がうまくデザインされているなら、参加者はただ当て推量しているだけです。ですから半分の割合で正解すると期待されますので、統計的仮説は「正しく選ぶ真の確率は $\theta = 0.5$ である」となります。
- 一方、ESP が存在して参加者にカードが見えるとしましょう。それが本当なら人々は偶然より良い成績をとりますので、統計的仮説は $\theta > 0.5$ となります。
- 3 つめの可能性は、ESP は存在するけれども色がすべて逆転していて、本人はそれに気づいていない、というものです(まあ変な話ですが、わからないものです)。もしそういう仕組みなら、成績は偶然より悪くなると期待されます。これは $\theta < 0.5$ という統計的仮説に対応します。
- 最後に、ESP は存在するけれども、人々が正しい色を見ているのか間違った色を見ているのかはわからない、としましょう。その場合にデータについて言えるのは、正解する確率が 0.5 と等しくないということだけです。これは $\theta \neq 0.5$ という統計的仮説に対応します。

これらはどれも統計的仮説の正当な例です。母集団のパラメータについての言明であり、かつ私の実験と意味のある形で関係しているからです。

この議論からはっきりしたと思いますが、統計的仮説検定を組み立てようとするとき、研究者はまったく異なる 2 つの仮説を考えることになります。まず研究仮説(心理についての主張)があり、それが統計的仮説(データを生成する母集団についての主張)に対応します。私の ESP の例では、次のようになるでしょう。

ダニの研究仮説: “ESP は存在する”

ダニの統計的仮説: $\theta \neq 0.5$

そしてここが肝心なところです。統計的仮説検定が検定しているのは統計的仮説であって、研究仮説

ではありません。研究のデザインが悪ければ、研究仮説と統計的仮説のあいだのつながりは壊れてしまいます。ばかげた例を挙げると、私の ESP 研究が、参加者に窓に映ったカードが実際に見えてしまう状況で行われたとしましょう。そうなれば $\theta \neq 0.5$ という非常に強い証拠が得られるでしょうが、それは“ESP が存在する”かどうかについて何も語ってくれません。

1.1.2 帰無仮説と対立仮説

ここまではよいでしょう。世界についてこう信じたいという研究仮説があり、それをデータがどう生成されたかについてこう信じたいという統計的仮説へ写像できました。多くの人にとって話が少し直感に反してくるのは、ここからです。というのもこれからやるのは、自分が信じたいことのちょうど正反対にあたる新しい統計的仮説 (“帰無” 仮説 H_0) をこしらえて、本当に関心のあるほう (これは “対立” 仮説 H_1 と呼ばれます) をほとんど放っておいて、そちらばかりに注目する、ということだからです。ESP の例では、帰無仮説は $\theta = 0.5$ です。ESP が存在しなかった場合に期待されるのがこれだからです。もちろん私の願いは ESP が本当に実在することですから、この帰無仮説に対する対立仮説は $\theta \neq 0.5$ になります。要するにここでやっているのは、 θ がとりうる値を 2 つに分けることです。本当に真であってほしくない値 (帰無仮説) と、そうだとわかったらうれしい値 (対立仮説) です。そのうえで大事なのは、仮説検定の目的が対立仮説が (おそらく) 正しいことを示すことではない、という点です。目的は、帰無仮説が (おそらく) 誤りであることを示すことなのです。たいていの人はこれをかなり奇妙に感じます。

私の経験では、これを理解するいちばんよい方法は、仮説検定を刑事裁判^{*4}だと考えることです。つまり帰無仮説の裁判です。帰無仮説が被告人、研究者が検察官、そして統計的検定そのものが裁判官です。刑事裁判と同じように、無罪の推定があります。研究者であるあなたが、合理的な疑いを超えて誤りであることを証明できない限り、帰無仮説は真であるとみなされます。実験は好きなようにデザインしてかまいませんし (もちろん常識の範囲でですが)、そのときの目標は、誤りであるという罪で有罪判決が出る見込みをデータが最大にすることです。やっかいなのは、裁判のルールを決めるのは統計的検定であり、そのルールが帰無仮説を守るように作られている、という点です。具体的には、帰無仮説が実際に真である場合に冤罪の確率が低く抑えられることを保証しているのです。これはかなり重要です。なにしろ帰無仮説には弁護人が付きませんし、研究者が必死にそれを誤りだと証明しようとしているのですから、誰かが守ってやらなければならないのです。

1.2

^{*4}この比喩は、イギリス・アメリカ・オーストラリアのような当事者主義の法体系にいる場合にしか通じません。私の理解では、フランスの糾問主義の体系はかなり異なります。

要約

帰無仮説検定は、統計理論のなかでもっとも広く行き渡っている要素のひとつです。学术论文の大多数が、何らかの仮説検定の結果を報告しています。ですから p 値が何を意味するのかを少なくともざっと理解していなければ、科学の世界でやっていくのはほとんど不可能です。この章が本書でもっとも重要な章のひとつであるゆえんです。いつものように、話してきた重要な考え方を手短におさらいして章を終えることにします。

- 研究仮説と統計的仮説。帰無仮説と対立仮説 (セクション ??)。
- タイプ I エラーとタイプ II エラー (セクション ??)。
- 検定統計量と標本分布 (セクション ??)。
- 判断の過程としての仮説検定 (セクション ??)。
- “柔らかい” 判断としての p 値 (セクション ??)。
- 仮説検定の結果を書く (セクション ??)。
- 実際に仮説検定を実行する (セクション ??)。
- 効果量と検定力 (セクション ??)。
- 仮説検定について考えておくべきいくつかの問題 (セクション ??)。

本書の後のほう、Chapter ??では、帰無仮説検定の理論をベイズの視点から捉え直し、正統的なアプローチがあまり好きになれない場合に使える新しい道具をいくつか紹介します。しかし今のところは、抽象的な統計理論はここまでとして、具体的なデータ分析の道具の話に入っていくことにしましょう。

1.3

2 種類のエラー

統計的検定がどのように構成されているのか、具体的に話し始める前に、その背後にある哲学について理解しておくといいでしょう。帰無仮説検定と刑事裁判の類似性を指摘した時にもヒントを出しましたが、今度はもっとはっきり扱ってみます。理想的には、検定を実施してもどんな間違いも犯すべきではありません。でも残念ながら、世界は混乱に満ちていて、決して理想通りにはいきません。時にあなたは不運としか言いようのない状況に陥ることもあるでしょう。たとえば、コインを 10 回トスして 10 回とも表になることもあるでしょう。これは、コインが偏っているという強い証拠のようにも思えますが、全く公平なコインであっても 1024 回に 1 回は偶然でも起こりうることです。言い換えると、現実にはつねに間違いを起こしうる偶然の可能性があるということを受け入れなければならない、ということです。ですから、統計的仮説検定の目標はエラーを完全に無くすことではなく、それを最小化することにある、といえます。

さてここで、“エラー”とは何かをもう少し正確にしておく必要があるでしょう。まず、明らかなことから述べていきます。帰無仮説は正しいか間違っているかのどちらかであり、我々の検定は帰無仮説を支持するか棄却するかのどちらかです。^{*5}ですから、以下の表に示したように、検定をしたあとには、生じた以下4つのうちどれかを選ぶことになるでしょう。

	保持 H_0	棄却 H_0
H_0 が真	正しい決定	エラー (type I)
H_0 が偽	エラー (type II)	正しい決定

結果的に、ここにはふたつの異なる種類の間違い方があることになります。帰無仮説を棄却した時に、実際それが正しかったという場合は、**type I error**を犯したことになります。一方、帰無仮説を保持した時、実際はそれが間違えていたというのであれば、**type II error**だったことになります。

統計的検定は刑事裁判のようだと覚えていますか？ そうまさにそうなのです。刑事裁判では“合理的な疑いを超えて”，被告がやったことを立証しなければなりません。証拠のルールというのはすべて（少なくとも理論的には），無実の被告を不当に有罪にする可能性を（ほとんど）なくすように設計されています。裁判は被告の権利を守るように設計されています。英国の法学者ウィリアム・ブラックストーンが言ったように、「無実のひと1人が傷つけられるより、有罪の10人が逃げてしまう方がマシである」ということです。いいかえると、刑事裁判では二種類のエラーを同じようには扱わないということです。無実の人を投獄するのは、有罪の人を自由にしてしまうよりもずっと悪いことだと考えられているのです。統計的検定も大体同じです。検定の唯一重要な設計規則は、タイプ1エラーの確率を**制御**するというもので、それを固定された確率以下に保持することにあります。この確率、これは α で表現されますが、これが検定の**有意水準**といいます。もう一度言いますが、これが全体的な設計の中心ですから、仮説検定はタイプ1エラーの確率が α を超えない場合、有意水準 α をもつと言えるのです。

さて、ではタイプ2エラーの確率はどうでしょう？ これも制御下におきたいところで、この確率は β と表します。しかしその確率は、帰無仮説が本当は偽だった時にそれを棄却する確率、 $1 - \beta$ で表される検定の**検定力**として参照されるほうが一般的です。これを直接表現できるように、関係する

^{*5}余談ですが、帰無仮説検定における言葉遣いについて考えておきます。まず、避けるべき言葉は“証明する”です。統計的な検定は、帰無仮説の真偽を**証明**することは決してありません。証拠は確実なことを意味しますが、ことわざが言うように、統計は決して確実であるとは言わないものです。これについてはほとんどの人が同意してくれると思います。しかしそれ以上に、非常に混乱することがあります。人によっては、“帰無仮説が棄却された”，“帰無仮説の棄却に失敗した”とか、“帰無仮説を保持した”といった文章しか許さないでしょう。この線に沿って考えると、あなたは“対立仮説を採択した”とか“帰無仮説を採択した”とは言えないことになります。個人的には、それはやり過ぎだと思います。私の考えでは、これは帰無仮説検定をカール・ポパーの、科学的手続の反証主義の考えを誤って捉えているのです。反証主義と帰無仮説検定の間には類似性がありますが、同じものではありません。私個人的には、仮説を採択するという言い方をしてもいい（ただし、“採択する”というのは本質的に真であるということの意味するものではないこと、特に帰無仮説の場合には）と思うのですが、多くの人は同意してくれないでしょう。さらにいえば、このように変な現象が存在することを知っていれば、あなたが自分の結果を記述する時に不意打ちを喰らわなくて済みます。

数字を同じ表に書き込んでおくことにしましょう。

	保持 H_0	棄却 H_0
H_0 が真	$1 - \alpha$ (正しく保持する確率)	α (タイプ 1 のエラー率)
H_0 が偽	β (タイプ 2 のエラー率)	$1 - \beta$ (検定力)

「強い」仮説検定とは、 α がある (小さな) 望ましい水準を維持したままで、 β の値が小さいことです。簡便的に、下 g 区 sh は 3 つの α 水準を使います。 .05, .01 と .001 です。ここに非対称性があることに注意してください。すなわち、検定は α 水準をなるべく小さくするように設計されていますが、 β についてはこれに対応する何かを保証するわけではありません。私たちはもちろんタイプ 2 エラーの確率を小さくしたいと思いますし、検定に際してそれを小さくしておこうと考えますが、タイプ 1 エラーをコントロールするという圧倒的な必要性の前では、二次的な要望になってしまいます。ブラックストーンが統計学者であったなら言ったとおもいますが、これはつまり「1 つの真の帰無仮説を棄却するより、10 回の間違った帰無仮説を採択した方が良い」ということです。正直なところ、私がこの哲学に同意しているかどうかわかりません。これが理にかなっていると思える状況もありますし、そうでないと思う状況もありますが、どちらでもないとも思います。これが検定のしくみです。

1.4

検定統計量と標本分布

ここからは、仮説検定がどう組み立てられるのかを具体的に話していく必要があります。そのために ESP の例に戻しましょう。実際に得られたデータはひとまず脇に置いて、実験の構造について考えてみます。実際の数値がどうであれ、データの形は「 N 人のうち X 人が隠されたカードの色を正しく当てた」というものです。さらに、帰無仮説が本当に正しい、つまり ESP は存在せず、正しい色を選ぶ真の確率がちょうど $\theta = 0.5$ である、と仮定してみましょう。データはとなると期待されるでしょうか。当然ながら、正解した人の割合は 50% にかかなり近くなると期待されます。もう少し数学的に言えば、 X/N がおよそ 0.5 になる、ということです。もちろん、この割合がちょうど 0.5 になるとは期待しません。たとえば $N = 100$ 人を調べて $X = 53$ 人が正解したなら、データは帰無仮説とかなり整合していると認めざるをえないでしょう。一方、参加者のうち $X = 99$ 人が正解したなら、帰無仮説は誤りだとかなり確信するでしょう。同じように、正解したのが $X = 3$ 人だけだったとしても、やはり帰無仮説は誤りだと確信するはずで。これをもう少し専門的に言いましょう。データを見ることで計算できる量 X があります。 X の値を見ただけで、帰無仮説が正しいと信じるか、帰無仮説を棄却して対立仮説をとるかを判断します。このように判断の指針にするために計算する量のことを、**検定統計量**と呼びます。




Figure1.1 帰無仮説が正しいときの検定統計量 X の標本分布。今回の ESP の場面では二項分布になる。帰無仮説は正答の確率を $\theta = .5$ としているので、当然ながら標本分布ではもっとも起こりやすい値が (100 人中)50 人の正答となる。確率の大部分は 40 から 60 のあいだにある。

.....

検定統計量を選んだら、次のステップは、検定統計量のどの値なら帰無仮説を棄却し、どの値なら保持するかを正確に述べることです。そのためには、帰無仮説が実際に正しかった場合に**検定統計量の標本分布**がどうなるかを定める必要があります (標本分布についてはセクション ?? で述べました)。なぜこれが必要なのでしょう。それは、この分布が、帰無仮説のもとで X のどんな値が期待されるかを正確に教えてくれるからです。ですからこの分布を、帰無仮説がデータとどれだけよく合っているかを評価する道具として使えるわけです。

検定統計量の標本分布は、実際にはどうやって決めるのでしょうか。多くの仮説検定ではこの段階はかなり込み入っていて、本書の後のほうでは、いくつかの検定について私が少しごまかしているのを見ることになるでしょう (なかには私自身が理解していないものもあります)。しかし、とても簡単な場合もあります。そして幸いなことに、ESP の例はそのもっとも簡単な部類にあたります。母集団のパラメータ θ は、質問されたときに人が正しく答える全体的な確率にすぎませんし、検定統計量 X は、標本サイズ N のうち正しく答えた人数の数です。このような分布はセクション ?? で見たことがありますし、まさにそれこそが二項分布の表すものです。ですからそのセクションで導入した記法と用語を使えば、帰無仮説は X が二項分布にしたがうと予測している、ということになり、

次のように書けます。

$$X \sim \text{Binomial}(\theta, N)$$

帰無仮説は $\theta = 0.5$ としていますし、実験の人数は $N = 100$ ですから、必要な標本分布が手に入りました。この標本分布を図 ?? に描いてあります。とくに驚きはありません。帰無仮説によれば $X = 50$ がもっとも起こりやすい結果であり、正答数は 40 から 60 のあいだのどこかになるとほぼ確実に言えるわけです。

1.5

判断を下す

さて、もうすぐ完成です。検定統計量 (X) を作りました。この検定統計量は、 X が $N/2$ に近ければ帰無仮説を保持すべきで、そうでなければ棄却すべきだとかなり確信できるように選んであります。残っている問題はこうです。検定統計量のどの値を帰無仮説に対応させ、どの値を対立仮説に対応させればよいのでしょうか。たとえば私の ESP 研究では、 $X = 62$ という値が観測されました。どう判断すべきでしょうか。帰無仮説を信じるべきでしょうか、対立仮説を信じるべきでしょうか。

1.5.1 棄却域と臨界値

この問いに答えるには、検定統計量 X についての**棄却域**という考え方を導入する必要があります。検定の棄却域とは、帰無仮説を棄却することになる X の値の範囲のことです。この棄却域はどうやって見つけるのでしょうか。わかっていることを整理してみましょう。

- 帰無仮説を棄却するには、 X がとても大きいか、とても小さいかでなければなりません。
- 帰無仮説が正しければ、 X の標本分布は $\text{Binomial}(0.5, N)$ です。
- $\alpha = .05$ なら、棄却域はこの標本分布の 5% を覆っていません。

最後の点をきちんと理解しておくことが大切です。棄却域は帰無仮説を棄却することになる X の値の範囲であり、いま問題にしている標本分布は、帰無仮説が実際に正しい場合に X がある値をとる確率を表しています。ここで、標本分布の 20% を覆う棄却域を選んだとして、帰無仮説が実際に正しいとしましょう。帰無仮説を誤って棄却してしまう確率はどうなるのでしょうか。もちろん 20% です。つまり α 水準が 0.2 の検定を作ってしまったことになります。 $\alpha = .05$ にしたいなら、棄却域が覆ってよいのは検定統計量の標本分布の 5% だけ、ということになります。

実は、この 3 つの条件で問題は一意に解けます。棄却域は、分布の**裾**として知られる、もっとも**極端な値**の部分になります。これを図 ?? に示しました。 $\alpha = .05$ にしたいなら、棄却域は $X \leq 40$

Critical Regions for a Two-Sided Test




Figure1.2 有意水準 $\alpha = .05$ の検定における，ESP 研究の仮説検定の棄却域。図は帰無仮説のもとでの X の標本分布（つまり図 ?? と同じもの）を示している。灰色のバーは帰無仮説を保持することになる X の値，青い（濃い）バーは帰無仮説を棄却することになる X の値，すなわち棄却域である。対立仮説は両側（ $\theta < .5$ と $\theta > .5$ の両方を許す）なので，棄却域は分布の両裾を覆う。 α 水準を .05 にするには，2 つの領域がそれぞれ標本分布の 2.5% を含むようにする必要がある。

と $X \geq 60$ になります*⁶。つまり“当たり”と答えた人数が 41 から 59 のあいだなら帰無仮説を保持すべきです。0 から 40 のあいだ，あるいは 60 から 100 のあいだなら，帰無仮説を棄却すべきです。40 と 60 という数値は棄却域の境目を定めるものですので，**臨界値**と呼ばれます。

*⁶厳密に言うと，いま作った検定の α は .057 で，少し甘すぎます。しかし棄却域の境界を 39 と 61 にすると，棄却域は分布の 3.5% しか覆いません。 $\alpha = .05$ にいちばん近いのはこちらですから，40 と 60 を臨界値として使い，5.7% のタイプ I エラー率を受け入れるほうが理にかなっていると考えました。

ここまでで、仮説検定は本質的に完成しています。

1. (1) α 水準を選ぶ (たとえば $\alpha = .05$)。
2. (2) H_0 と H_1 を比較するのに (何らかの意味で) うまく働く検定統計量 (たとえば X) を考え出す。
3. (3) 帰無仮説が正しいという仮定のもとで検定統計量の標本分布を求める (今回の場合は二項分布)。
4. (4) 適切な α 水準になる棄却域を計算する (0 から 40 と 60 から 100)。

あとは実際のデータについて検定統計量の値を計算し (たとえば $X = 62$)、臨界値と比べて判断するだけです。62 は臨界値の 60 より大きいので、帰無仮説を棄却することになります。少し言い方を変えれば、検定は統計的に有意な結果を出した、ということになります。

1.5.2 統計的“有意性”についての注意

他の占いのオカルト的技法と同じく、統計的方法にも、その手法を門外漢から覆い隠すためにわざわざこしらえられた仲間内の専門用語がある。

– G. O. Ashley の言葉とされる^{*7}

ここで“有意”という語について、ごく短い脱線をしておきましょう。統計的有意性という概念は実のところとても単純なのですが、名前がひどく不幸なことになっています。データによって帰無仮説を棄却できる場合、“結果は統計的に有意である”と言い、しばしば“結果は有意である”と短縮されます。この用語はかなり古く、“significant”が“重要である”に近い現代的な意味ではなく、単に“示された”といった意味だった時代にさかのぼります。その結果、現代の多くの読者は統計を学び始めたときにひどく混乱します。“有意な結果”は重要な結果に違いはないと思ってしまうからです。まったくそんな意味ではありません。“統計的に有意”が意味するのは、データによって帰無仮説を棄却できた、ということだけです。その結果が現実世界で本当に重要かどうかはまったく別の問題で、ほかのさまざまなことに左右されます。

1.5.3 片側検定と両側検定の違い

いま作った仮説検定について、もうひとつ指摘しておきたいことがあります。これまで使ってきた統

^{*7}インターネット上では Ashley がこう言ったということはかなり一致しているのですが、どうしても出典を挙げてくれる人が見つかりません。

計的仮説を少し考えてみると、

$$H_0: \theta = .5$$

$$H_1: \theta \neq .5$$

対立仮説が $\theta < .5$ の可能性と $\theta > .5$ の可能性の両方を含んでいることに気づきます。ESP によって偶然より良い成績も偶然より悪い成績も生じうると本当に考えているなら、これは理にかなっています (実際そう考える人もいます)。統計の言葉で言えば、これは**両側検定**の例です。そう呼ばれるのは、対立仮説が帰無仮説の両“側”の領域を覆っているからで、その結果として検定の棄却域は、先ほど図 ?? に示したように、標本分布の両裾を覆うことになります ($\alpha = .05$ ならそれぞれ 2.5% ずつ)。

しかし可能性はそれだけではありません。偶然より良い成績が出た場合にだけ ESP を信じる気になる、ということもあるでしょう。その場合、対立仮説は $\theta > .5$ の可能性だけを含むことになり、帰無仮説は $\theta \leq .5$ になります。

$$H_0: \theta \leq .5$$

$$H_1: \theta > .5$$

こうなると**片側検定**と呼ばれるものになり、棄却域は標本分布の片方の裾だけを覆います。これを図 ?? に示しました。

1.6

検定の p 値

ある意味で、仮説検定はもう完成しています。検定統計量を作り、帰無仮説が正しい場合の標本分布を求め、検定の棄却域を作りました。とはいえ、いちばん重要な数値である **p 値** を省いてきました。これからその話に移ります。 p 値の解釈にはやや異なる 2 つのやり方があり、ひとつは Ronald Fisher 卿が、もうひとつは Jerzy Neyman が提案したものです。どちらも正当なものですが、仮説検定についてのまったく異なる考え方を反映しています。入門的な教科書のほとんどは Fisher のほうしか載せない傾向がありますが、これは少し残念なことだと思います。私の考えでは、Neyman のほうがすっきりしていますし、帰無仮説検定の論理をよりよく反映しています。とはいえ異論もあるでしょうから、両方を載せておきます。まず Neyman のほうから始めましょう。

1.6.1 もう少し柔らかい判断の見方

ここまで説明してきた仮説検定の手続きの問題点のひとつは、“かろうじて有意”な結果と“きわめて有意”な結果をまったく区別しないことです。たとえば私の ESP 研究では、得られたデータはぎりぎり棄却域に入りましたので、有意な効果は得られたものの、かなり際どいところでした。これに対して、 $N = 100$ 人の参加者のうち $X = 97$ 人が正解する研究を行ったとしましょう。これも当

Critical Region for a One-Sided Test




Figure1.3 片側検定の棄却域。この場合、対立仮説は $\theta > .5$ なので、 X が大きい場合にだけ帰無仮説を棄却する。その結果、棄却域は標本分布の上側の裾、具体的には分布の上位 5% だけを覆う。図 ?? の両側検定版と比べてほしい。

然有意になりますが、ずっと大きな余裕をもって有意であり、まったく曖昧さがありません。すでに説明した手続きは、この 2 つを区別しません。許容できるタイプ I エラー率として $\alpha = .05$ を認めるという標準的な慣例をとるなら、どちらも有意な結果なのです。

ここで p 値が役に立ちます。仕組みを理解するために、同じデータに対して α の値をいろいろ変えながら、たくさんの仮説検定を行ったとしましょう。もとの ESP データでそれをやると、次のようになります。

α の値	0.05	0.04	0.03	0.02	0.01
帰無仮説を棄却するか	する	する	する	しない	しない

ESP のデータ ($N = 100$ の観測のうち $X = 62$ が正解) を、 α 水準 .03 以上で検定すると、常に帰無仮説を棄却することになります。 α 水準が .02 以下なら、常に帰無仮説を保持することになります。ですから .02 と .03 のあいだのどこかに、このデータで帰無仮説を棄却できる α の最小値があるはずです。これが p 値です。実際、ESP データの p 値は $p = .021$ です。つまり、

p とは、帰無仮説を棄却したいときに受け入れなければならないタイプ I エラー率 (α) の最小値である、と定義されます。

実質的に p は、ありうるすべての α の値にわたって、実行できたはずのすべての仮説検定を要約したものです。その結果として、判断の過程を“柔軟かく”する働きを持ちます。 $p \leq \alpha$ となる検定では帰無仮説を棄却していたはずですし、 $p > \alpha$ となる検定では帰無仮説を保持していたはずです。私の ESP 研究では $X = 62$ が得られ、結果として $p = .021$ になりました。ですから受け入れなければならないエラー率は 2.1% です。これに対して、実験の結果が $X = 97$ だったとしましょう。 p 値はどうなるのでしょうか。今度は $p = 1.36 \times 10^{-25}$ まで縮みます。とてつもなく小さな*8タイプ I エラー率です。この 2 つめの場合には、はるかに大きな確信をもって帰無仮説を棄却できます。棄却するという判断を正当化するのに受け入れ“なければならない”タイプ I エラー率が、 10^{25} 分の 1 程度でしかないからです。

p 値の 2 つめの定義は Ronald Fisher 卿によるもので、入門的な統計の教科書でよく見かけるのは実はこちらのほうです。棄却域を作ったとき、それが標本分布の裾(つまり極端な値)に対応していたことに気づいたのでしょうか。これは偶然ではなく、ほとんどすべての“良い”検定がこの性質を持っています(ここで良いというのは、タイプ II エラー率 β を最小にするという意味です)。その理由は、良い棄却域はほとんど常に、帰無仮説が正しい場合にもっとも観測されにくい検定統計量の値に対応するからです。このルールが正しいなら、 p 値を「実際に得られたものと少なくとも同じくらい極端な検定統計量が観測される確率」と定義できます。言い換えれば、帰無仮説のもとでデータがきわめてありそうにないのなら、帰無仮説はおそらく誤りだ、ということです。

- 15 -

アプローチの中でさえ、 p 値は帰無仮説が正しい確率には対応しません。この解釈は、 p 値がどう計算されるかという数学とまったく整合しないのです。はっきり言えば、そう考えなくなる直感的な魅力があるにもかかわらず、 p 値をそう解釈することに正当性はまったくありません。決してやらないでください。

1.7

仮説検定の結果を報告する

仮説検定の結果を書くときには報告すべき情報がいくつかありますが、それは検定によってかなり異なります。本書の残りの部分では、それぞれの検定の結果をどう報告するかについて少しずつ触れていきますので(とくに詳しい例はセクション ??を見てください)、普通どうやるのかの感覚がつかめるでしょう。ただし、どの検定をする場合でも必ずやらなければならないのは、 p 値について述べ、結果が有意だったかどうかを述べることです。

これが必要なのは驚くことではありません。検定をする目的そのものだからです。驚くかもしれないのは、それを具体的にどうやるべきかについて、いささかの論争があるということです。帰無仮説検定の枠組みそのものに全面的に反対している人たちはさておき、得られた p 値を正確に報告すべきか、それともあらかじめ選んだ有意水準について $p < \alpha$ と述べるだけにすべきか(たとえば $p < .05$)、という点をめぐって一定の緊張があるのです。

1.7.1 何が問題なのか

なぜこれが問題になるのかを理解する鍵は、 p 値がとてつもなく便利だという点にあります。実際のところ、 p 値を計算できるということは、検定を実行するのに α 水準をまったく指定しなくてよい、ということを意味します。そのかわりに、 p 値を計算してそれを直接解釈すればよいわけです。 $p = .062$ が得られたなら、帰無仮説の棄却を正当化するには 6.2% のタイプ I エラー率を受け入れなければならない、ということです。あなた個人が 6.2% は受け入れがたいと思うなら、帰無仮説を保持します。だったら実際の p 値を報告して、許容できるタイプ I エラー率がどれくらいかは読者自身に判断してもらえばいいではないか、という議論になります。このやり方には、判断の過程を“柔軟かく”できるという大きな利点があります。実際、 p 値の Neyman の定義を受け入れるなら、それこそが p 値の存在意義です。 $\alpha = .05$ という固定した有意水準が“採択”と“棄却”を分ける明確な線であることをやめれば、 $p = .051$ と $p = .049$ を根本的に違うものとして扱わざるをえない、というかなり病的な問題も消えます。

この柔軟さは、 p 値の利点であると同時に欠点でもあります。多くの人が正確な p 値を報告するという考えを好まないのは、それが研究者に少し自由を与えすぎるからです。とくに、データを見たあ

とで、どのくらいの誤りを受け入れるかについて考えを変えられてしまいます。たとえば私の ESP 実験で考えてみましょう。検定を実行したところ p 値が .09 になったとします。採択すべきでしょうか、棄却すべきでしょうか。正直なところ、“本当に”受け入れられるタイプ I エラーの水準がどれくらいかなど、まだ考えてもいません。その点について私は意見を持っていないのです。しかし ESP が存在するかどうかについては意見を持っていますし、自分の研究がまともな学術誌に載るべきかどうかについては間違いなく意見を持っています。そして驚いたことに、データを見たいまとなつては、9% のエラー率もそんなに悪くない気がしてきました。実験が失敗したと世間に認めなければならない煩わしさに比べれば、なおさらです。そこで、後づけででっちあげたように見えないよう、10% のタイプ I エラー率もそう悪くはないという理屈をつけて、 α は .1 だと言うことにします。その水準なら検定は有意です。私の勝ちですね。

つまりここでの心配は、こちらにどれだけ善意があり、どれだけ正直な人間であっても、あちこちで少しずつ“ぼかす”誘惑が本当に、本当に強い、ということです。実験をやったことがある人なら誰でも証言できるでしょうが、実験は長く困難な過程であり、自分の仮説にとっても愛着が湧いてしまうものです。それを手放して、実験が望んだものを見つけられなかったと認めるのは難しいことです。そこに危険があります。“生の” p 値を使うと、人はデータが実際に語っていることではなく、自分が信じたいことにもとづいてデータを解釈し始めます。それを許すのなら、そもそも何のために科学をやっているのでしょうか。事実がどうであれ、誰もが何でも好きなように信じればいいではありませんか。まあ、これは少し極端ですが、心配の出どころはそこにあります。この立場からすれば、 α の値をあらかじめ指定し、検定が有意だったかどうかだけを報告しなければならないということになります。自分たちを正直に保つ方法はそれしかない、というわけです。

1.7.2 提案されている 2 つの解決策

実際には、研究者が α 水準をひとつだけあらかじめ指定することはかなりまれです。そのかわり、科学者は .05・.01・.001 という 3 つの標準的な有意水準を使う、というのが慣例になっています。結果を報告するときには、この有意水準のうちどれで帰無仮説を棄却できるか (あるいはどれでもできないか) を示します。これを表 ?? にまとめました。 $p < .01$ は $p < .05$ よりも強い証拠の基準を満たしていることを意味しますので、これによって判断のルールを少し柔らかくできます。それでいて、これらの水準は慣例によってあらかじめ固定されていますので、データを見てから α 水準を選ぶことは防げます。

とはいえ、正確な p 値を報告するほうを好む人もかなり多くいます。多くの人にとっては、 $p = .06$ をどう解釈するかを読者自身に判断してもらえる利点のほうが、欠点を上回るのです。ただし実際には、正確な p 値を好む研究者のあいだでも、 p が小さい場合には正確な値を報告せず $p < .001$ とだけ書くことがよくあります。これはひとつには、多くのソフトウェアがそこまで小さい p 値を実際には出力しないから (たとえば SPSS は $p < .001$ のとき単に $p = .000$ と書きます) であり、またひ

Table1.1 p 値の報告について広く採用されている慣例。多くの場面では、下に示す 4 つのうちのいずれか (たとえば $p < .05$) を報告するのが慣例になっている。統計ソフトの出力で見かけることがあるので、“有意性の星”の記法 (つまり*が $p < .05$ を示す) も入れてある。また、 $p > .05$ と書くかわりに *n.s.*(有意でない) と書く人もいることも覚えておくとよい。

通常の記法	有意性の星	日本語での言い方	帰無仮説は
$p > .05$		検定は有意でなかった	保持
$p < .05$	*	$\alpha = .05$ では有意だが $\alpha = .01$ や $\alpha = .001$ では有意でない	棄却
$p < .01$	**	$\alpha = .05$ と $\alpha = .01$ では有意だが $\alpha = .001$ では有意でない	棄却
$p < .001$	***	すべての水準で有意だった	棄却

とつには、非常に小さな p 値がある種の誤解を招きうるからです。人間は.0000000001 のような数値を見ると、対立仮説を支持する証拠がほぼ確実だという直感を抑えるのが難しくなります。しかし実際には、たいていそれは間違いです。世の中は大きく、雑然としていて複雑ですし、これまでに考案されたどの統計的検定も、単純化と近似と仮定に依存しています。ですから、どんな統計分析であれ、 $p < .001$ が意味する以上に強い確信をもって立ち去るのは、おそらく妥当ではありません。言い換えれば、 $p < .001$ というのは“この検定に関する限り、証拠は圧倒的である”ということを表す符牒なのです。

こうしたことを踏まえると、結局どうすればよいのか迷うかもしれません。この点についてはかなり矛盾した助言があり、正確な p 値を報告すべきだと言う人もいれば、表 ?? に示した段階的なやり方を使うべきだと言う人もいます。ですから私にできる最善の助言は、自分の分野で書かれた論文や報告書を見て、どんな慣例になっているかを確かめてみることです。一貫したパターンが見当たらないようなら、好きなほうを使ってください。

1.8

実際に仮説検定を実行する

ここまで来ると、これは“本物の”仮説検定なのか、それとも私がでっちあげたおもちゃの例なのか、と思う人もいるかもしれません。本物です。これまでの議論では、現実に出会いうるもっとも単純な問題だと考えて、検定を原理から組み立ててきました。しかしこの検定はすでに存在していま

す。二項検定と呼ばれるもので、JASP では 'Frequencies' のボタンを押すと使える統計分析のひとつとして実装されています。反応の確率が 2 分の 1 であるという帰無仮説 $p = .5^{*9}$ を検定してみましょう。n = 100 人のうち x = 62 人が正しく反応したデータ (binomialtest.jasp データファイルにあります) を使うと、図 ?? のような結果が得られます。




Figure1.4 JASP での二項検定の分析と結果

いまのところこの出力は見慣れないものかもしれませんが、だいたい正しいことを伝えてくれているのはわかると思います。具体的には、p 値の 0.02 は通常選ばれる $\alpha = .05$ より小さいので、帰無仮説を棄却できます。この種の出力の読み方については今後さらに詳しく扱っていきますので、しばらくすれば読んで理解するのがかなり簡単になっているはずです。

1.9

効果量，標本サイズ，検定力

これまでの節では、統計的仮説検定の背後にある主な設計原理がタイプ I エラー率の統制にある，ということを強調してきました。 $\alpha = .05$ と定めるとき、私たちは正しい帰無仮説のうち誤って棄却されるものが 5% だけになるようにしているわけです。とはいえ、タイプ II エラーを気にしていな

^{*9} ここでの p は p 値とは何の関係もないことに注意してください。JASP の二項検定における p という引数は、帰無仮説のもとで正しく反応する確率に対応しています。つまり θ の値です。

いという意味ではありません。実際、研究者の立場からすれば、帰無仮説が本当は誤りなのに棄却できないという誤りは、きわめて腹立たしいものです。そうしたわけで、仮説検定の副次的な目標はタイプIIエラー率 β を最小にすることなのですが、ふつうはタイプIIエラーを最小にするという言い方はしません。そのかわりに、検定の検定力を最大にする、と言います。検定力は $1 - \beta$ と定義されますので、同じことです。

1.9.1 検定力関数




Figure1.5 母集団のパラメータが $\theta = 0.55$ である場合の、対立仮説のもとでの標本分布。分布のかなりの部分が棄却域に入っている。

タイプIIエラーが実際どういうものかを少し考えてみましょう。タイプIIエラーは、対立仮説が正しいのに帰無仮説を棄却できないときに起こります。理想を言えば、タイプIエラー率について $\alpha = .05$ と設定できるのと同じように、タイプIIエラー率を表すひとつの数値 β を計算できるとよいのですが。残念ながら、これはずっと厄介です。それを理解するために、私のESP研究では対立仮説が θ のたくさんの値に対応していることに注目してください。実のところ対立仮説は、0.5を除く θ のすべての値に対応しています。正しく反応する真の確率が55%(つまり $\theta = .55$)だとしましょう。そうすると X の真の標本分布は帰無仮説が予測するものとは違ってきます。 X のもっとも起こりやすい値が100中55になるからです。それだけでなく、図??に示すように標本分布全体が

ずれています。もちろん棄却域は変わりません。定義上、棄却域は帰無仮説が予測することにもとづいているからです。この図が示しているのは、帰無仮説が誤っている場合には標本分布のずっと大きな部分が棄却域に入る、という事実です。そしてもちろん、そうなるべきなのです。帰無仮説が実際に誤っているときには、それを棄却する確率が大きくなるわけですから。ただし、対立仮説と整合する可能性は $\theta = .55$ だけではありません。今度は θ の真の値が 0.7 だとしてみましょう。この場合、標本分布はどうなるでしょうか。答えは図 ?? に示すとおりで、標本分布のほぼ全体が棄却域に移動しています。ですから $\theta = 0.7$ なら、帰無仮説を正しく棄却する確率 (つまり検定力) は $\theta = 0.55$ の場合よりずっと大きくなります。要するに、 $\theta = .55$ も $\theta = .70$ もどちらも対立仮説の一部ですが、タイプ II エラー率は異なるのです。




Figure1.6 母集団のパラメータが $\theta = 0.70$ である場合の、対立仮説のもとでの標本分布。分布のほとんどすべてが棄却域に入っている。

ここからわかるのは、検定の検定力 (つまり $1 - \beta$) が θ の真の値に依存する、ということです。これを示すために、 θ のすべての値について帰無仮説を棄却する期待確率を計算し、図 ?? に描きました。このプロットは、ふつう検定の**検定力関数**と呼ばれるものを表しています。 θ のとりうるすべての値について検定力 ($1 - \beta$) を教えてください、検定の良し悪しをうまく要約したものになっています。見てのとおり、 θ の真の値が 0.5 にとても近いときには検定力が急激に落ち、離れているときには大きくなります。




Figure1.7 帰無仮説を棄却する確率を、 θ の真の値の関数として描いたもの。当然ながら、 θ の真の値が帰無仮説の指定する値 (つまり $\theta = .5$) と大きく異なるほど、検定力は高くなる (正しく棄却できる見込みが大きくなる)。 θ が実際に.5 と等しい場合 (黒い点で示した) には帰無仮説は真であり、このとき帰無仮説を棄却することはタイプ I エラーになることに注意。

1.9.2 効果量

すべてのモデルは間違っているのだから、科学者は何が重要な意味で間違っているのかに注意を払わなければならない。外に虎がいるときにネズミを気にするのは適切ではない。

– George Box (**Box1976**)

図 ?? のプロットは、仮説検定についてのかかなり基本的な点をとらえています。世界の真のありようが帰無仮説の予測と大きく異なるなら検定力はとても高くなりますが、帰無仮説と似ている (ただし同一ではない) なら検定力はとても低くなります。ですから、世界の真のありようが帰無仮説にどれだけ “似ている” かを数量化する方法があると便利です。それを行う統計量は **効果量** の指標と呼ばれます (**Cohen1988**; **Ellis2010**)。効果量は文脈によって少しずつ違うように定義されます (ですからこの節では一般的な話にとどめます) が、とらえようとしている質的な考え方は常に同じです。真の母集団パラメータと、帰無仮説が仮定するパラメータの値との差はどれくらいか、ということです。ESP の例で言えば、帰無仮説が仮定する値を $\theta_0 = 0.5$ 、真の値を θ とすると、効果量の単純な

Table1.2 統計的有意性と効果量の関係を理解するための大雑把な指針。基本的に、有意な結果が得られていないなら、そもそもそれが実在するという証拠がないのですから効果量はほとんど意味を持たない。一方、有意な効果が得られていても効果量が小さいなら、その結果は(実在するとしても)さほど興味深いものではない可能性が高い。ただしこの指針はきわめて大雑把なものである。何を研究しているかに大きく依存する。小さな効果が実務上きわめて重要になる場面もある。だからこの表をあまり真に受けないでほしい。せいぜい大まかな目安である。

	効果量大きい	効果量小さい
有意な結果	差は実在し、 実務上も重要である	差は実在するが、 興味深くないかもしれない
有意でない結果	効果は観測されなかった	効果は観測されなかった

指標は真の値と帰無仮説の値の差(つまり $\theta - \theta_0$) や、その差の大きさ $\text{abs}(\theta - \theta_0)$ といったものになるでしょう。

なぜ効果量を計算するのでしょうか。実験を行い、データを集め、仮説検定をしたら有意な効果が得られたとしましょう。有意な効果が得られたと言うだけでは足りないのでしょうか。それこそが仮説検定の目的ではないのでしょうか。まあ、ある意味では。確かに仮説検定をする目的は帰無仮説が誤りだと示そうとすることですが、私たちの関心はそれだけではありません。帰無仮説が $\theta = .5$ と主張していて、それが誤りだと示したとしても、話の半分しか語っていないのです。帰無仮説を棄却するということは $\theta \neq .5$ だと考えるということですが、 $\theta = .51$ と $\theta = .8$ では大違いです。 $\theta = .8$ だとわかったなら、帰無仮説が誤りであるだけでなく、大幅に誤っているようだ、ということになります。一方、帰無仮説の棄却には成功したものの、 θ の真の値は.51 にすぎないようだ、という場合を考えてみましょう(これは非常に大規模な研究でなければ起こりません)。確かに帰無仮説は誤りですが、効果量がとても小さいので、それを気にする必要があるのかどうかはまったくはっきりしません。私の ESP 研究の文脈なら、本物の超能力が示されるというのはなかなか痺れる話ですから、それでも気にするかもしれません^{*10}が、他の文脈では、たとえ本物の差であっても 1% の差はふつうあまり興味深くありません。たとえば高校の試験成績の男女差を見ていて、女性の得点が平均して男性より 1% 高いとわかったとしましょう。何千人もの生徒のデータがあれば、この差はほぼ確実に統計的に有意になりますが、 p 値がどれだけ小さかろうと、あまり興味深い話ではありません。こんな小さな差をもとに男子教育の危機だと触れ回りたいとは思わないでしょう。こうした理由から、仮説検定の結果とあわせて何らかの標準的な効果量の指標を報告することが、ゆっくりとではあれ確実に標準になりつつあります。仮説検定そのものは、観測された効果が実在すると信じてよいか(つ

^{*10} もっとも実際には、効果量が非常に小さいのは心配なことです。ごく些細な方法論上の欠陥がその効果の原因かもしれないし、完璧な実験など存在しませんから、方法論上の懸念は常にあるのです。

まり単なる偶然ではないか) を教えてくれますが、効果量はそれを気にすべきかどうかを教えてくれるのです。

1.9.3 研究の検定力を高める

当然のことながら、科学者は自分の実験の検定力を最大にすることにかなり執着します。実験がうまくいってほしいのですから、帰無仮説が誤りである場合にそれを棄却できる見込みを最大にしたいわけです(そしてもちろん、たいていは誤りであってほしいと思っています)。見てきたように、検定力に影響する要因のひとつが効果量です。ですから検定力を高めるためにまずできるのは、効果量を大きくすることです。実際には、効果量が大きくなるように研究をデザインしたい、ということになります。たとえば私の ESP 研究なら、超能力は静かで暗く、心を曇らせる雑音の少ない部屋でいちばんよく働くと考えるかもしれません。ですからそういう環境で実験をやろうとするでしょう。なんらかの形で人々の ESP 能力を強められれば、 θ の真の値は上がります^{*11}ので、効果量も大きくなります。要するに、賢い実験デザインは効果量を変えられますので、検定力を高める方法のひとつなのです。

残念ながら、最良の実験デザインをもってしても効果が小さいまま、ということはよくあります。たとえば ESP は本当に存在するけれども、最良の条件でもきわめて弱い、ということもあるでしょう。そうした状況で検定力を高めるいちばんの手は、標本サイズを大きくすることです。一般に、使える観測が多いほど、2つの仮説を区別できる見込みは高くなります。ESP 実験を 10 人でやって 7 人が隠されたカードの色を当てたとしても、あなたはたいして感心しないでしょう。しかし 10,000 人でやって 7,000 人が正解したなら、私が何かを発見したと考える可能性はずっと高くなるはずで、つまり検定力は標本サイズとともに大きくなります。これを図 ?? に示しました。帰無仮説が $\theta_0 = 0.5$ を予測するとして、真のパラメータが $\theta = 0.7$ の場合の検定力を、標本サイズ N が 1 から 100 までのすべてについて描いたものです。

検定力は重要ですから、実験をやろうと考えているときには、どれくらいの検定力が見込めるかを知っておくとかなり役に立ちます。本当の効果量を知ることはできませんので、確実に知ることは決してできません。しかし、どれくらいの大きさになるかを推測できることはよく(まあ、ときどき)あります。そうであれば、必要な標本サイズを推測できるわけです。この考え方は**検定力分析**と呼ばれ、実行可能であればとても役に立ちます。実験をうまくやり切るだけの時間や資金があるかどうかを教えてくれるからです。検定力分析は実験デザインに必須とすべきだと主張する人も増えていきますので、知っておく価値はあります。ただし本書では検定力分析を扱いません。これはひとつにはつまらない理由から、ひとつには実質的な理由からです。つまらない理由は、検定力分析について書く

^{*11} 真の母集団パラメータ θ が、必ずしも自然の不変の事実に対応しているわけではないことに注意してください。この文脈での θ は、別の部屋にあるカードの色を人が正しく当てる真の確率にすぎません。ですから母集団パラメータはさまざまなものの影響を受けます。もちろん、これはすべて ESP が実際に存在するという前提の上での話ですが。




Figure1.8 検定力を標本サイズ N の関数として描いたもの。この場合、 θ の真の値は 0.7 だが、帰無仮説は $\theta = 0.5$ である。全体として、 N が大きいほど検定力は高い。(この関数に見られる小さなギザギザは、 θ と α 、そして二項分布が離散的であることとの奇妙な相互作用によるもので、まじめな目的には影響しない。)

時間がまだないからです。実質的な理由は、私が検定力分析をまだ少し疑っているからです。研究者としての実感では、検定力分析ができる立場に置かれたことはめったにありません。たいていは (a) 自分の実験が少し標準から外れていて効果量をどう定義すればよいかわからないか、(b) 効果量がどうなるか本当に見当がつかず、答えをどう解釈すればよいかわからないか、のどちらかなのです。それだけでなく、統計コンサルティングを生業にしている人 (たまたま私の妻です) とさんざん話をきてきて気づかざるをえないのは、実際に検定力分析を頼まれるのが、助成金の申請書を書く手伝いをしているときだけだ、ということです。つまり現実には科学者が検定力分析を求めるのは、お役所的な手続きによってやらされるときだけのように見えるのです。誰の日常の仕事の一部にもなっていません。要するに私は、検定力は重要な概念だけれども、検定力分析は世間で言われるほど有用ではない、とずっと考えてきました。例外は、(a) あなたの実際の実験デザインについて検定力の計算法が誰かによって明らかにされていて、かつ (b) 効果量がどれくらいになるかについてかなりよい見通し

がある，というまれな場合だけです*12。私よりよい経験をしている人もいるかもしれませんが，個人的には (a) と (b) の両方が成り立つ状況に置かれたことは一度もありません。将来は考えが変わるかもしれませんが，本書の将来の版では検定力分析をもっと詳しく論じることになるかもしれませんが，いまのところこの話題について気持ちよく言えるのはこのくらいです。

1.10

考えておくべきいくつかの問題

この章で説明してきたのは，帰無仮説有意性検定 (NHST) の正統的な枠組みです。NHST の仕組みを理解することは絶対に必要です。20 世紀初頭に台頭して以来，推測統計の支配的なアプローチであり続けてきたからです。現役の科学者の大多数がデータ分析でこれに頼っていますので，嫌いであっても知っておく必要があります。とはいえ，このアプローチに問題がないわけではありません。枠組みにはいくつかの癖がありますし，成立の経緯には歴史的な奇妙さがあり，枠組みが正しいかどうかをめぐる理論的な論争もあり，うっかりすると陥る実践的な罠もたくさんあります。この話題を詳しく扱うつもりはありませんが，いくつかの問題については簡単に触れておく価値があると思います。

1.10.1 Neyman と Fisher

まず知っておくべきなのは，正統的な NHST が実際にはかなり異なる 2 つの仮説検定のアプローチ，つまり Ronald Fisher 卿が提案したものと Jerzy Neyman が提案したものの寄せ集めだ，ということです (Lehmann2011)。歴史がややこしいのは，Fisher も Neyman も生身の人間であり，その意見は時とともに変わりましたし，何十年もあとの私たちが彼らの仕事をどう解釈すべきかについて“決定的な言明”を残したことは一度もなかったからです。そのうえで，この 2 つのアプローチについての私の理解を手短かにまとめておきます。

まず Fisher のアプローチから話しましょう。私の理解する限り，Fisher は仮説はひとつ (帰無仮説) しかなく，やりたいのは帰無仮説がデータと矛盾するかどうかを調べることだ，と考えていました。彼の見方では，やるべきことは帰無仮説のもとでデータが“十分にありそうにない”かどうかを確かめることです。実際，先ほどの議論を思い出せば，それが Fisher の p 値の定義でした。Fisher によれば，帰無仮説がデータをうまく説明できないなら，安心してそれを棄却できます。しかし比較する他の仮説がないのですから，“対立仮説を採択する”ことはできません。明示的に述べられた対立仮説が必ずしもないからです。だいたいそれで全部です。

*12 これに対するひとつの例外は，研究者が新しい医療的治療の効果を調べていて，たとえば既存の治療を上回るものとして，検出すべき重要な効果量をあらかじめ指定する場合でしょう。このやり方であれば，新しい治療の潜在的な価値についてある程度の情報が得られます。

これに対して Neyman は、仮説検定の眼目は行動の指針にあると考えており、そのアプローチは Fisher よりいくらか形式的でした。彼の見方では、取りうる行動は複数あり (帰無仮説を採択するか対立仮説を採択するか)、検定の眼目はデータがどちらを支持しているかを教えることにあります。この立場からすると、対立仮説をきちんと指定することが決定的に重要です。対立仮説が何かわからなければ、検定の検定力もわかりませんし、どの行動が理にかなうのかもわかりません。彼の枠組みは、異なる仮説どうしの競争を本当に必要とするのです。Neyman にとって p 値は、帰無仮説のもとでのデータ (あるいはより極端なデータ) の確率を直接測るものではなく、どの“ありうる検定”が帰無仮説の採択を告げ、どの“ありうる検定”が対立仮説の採択を告げるかについての、より抽象的な記述でした。

このように、今日私たちが手にしているのは 2 つの奇妙な混ぜ物です。帰無仮説と対立仮説の両方があるという話をしますが (Neyman)、 p 値はたいてい^{*13}極端なデータという言葉で定義します (Fisher)。それでいて α の値もあります (Neyman)。統計的検定のなかには対立仮説が明示されているもの (Neyman) もあれば、その点がかなり曖昧なもの (Fisher) もあります。そして少なくとも一部の人のによれば、対立仮説を採択するという言い方は許されません (Fisher)。ごちゃごちゃしていますが、なぜごちゃごちゃしているのかは少なくとも説明できたと思います。

1.10.2 バイズ主義者と頻度主義者

この章の前のほうで、 p 値を帰無仮説が正しい確率として解釈することはできないと強く述べました。NHST は根本的に頻度論の道具であり (Chapter ??参照)、そうであるがゆえに仮説に確率を割り当てることを許しません。帰無仮説は正しいか正しくないかのどちらかです。統計へのバイズのアプローチは確率を信念の度合いとして解釈しますので、帰無仮説が正しい確率は 10% だ、と言ってもまったく問題ありません。それはその仮説に対してあなたが持っている確信の度合いを表しているだけです。頻度論的なアプローチの中では、これは許されません。思い出してください。頻度主義者にとって確率は、独立な繰り返しを多数行った後に何が起こるか (つまり長期的な頻度) によってしか定義できません。この確率の解釈をとるなら、帰無仮説が正しい“確率”について語るのはまったくの戯言です。帰無仮説は正しいか誤りかのどちらかなのですから。この言明について長期的な頻度を語る方法などありません。“帰無仮説の確率”について語ることは、“自由の色”について語るのと同じくらい無意味です。そんなものはないのです。

もっとも重要なのは、これが純粋にイデオロギーの問題ではないということです。自分はバイズ主義者であり、仮説について確率を語ってよいと決めたのなら、その確率を計算するためのバイズのルールにしたがわなければなりません。これについては Chapter ??でさらに述べますが、いま指摘

^{*13}本書は Neyman と Fisher の両方の p 値の定義を説明していますが、ほとんどの本はそうしません。入門的な教科書のほとんどは Fisher のほうしか載せません。

しておきたいのは、 p 値が H_0 の正しい確率の近似としてはひどいものだ、ということです。帰無仮説の確率が知りたいのなら、 p 値はあなたの探しているものではありません。

1.10.3 罨

このように仮説検定の背後にある理論はごちゃごちゃしていて、いまなお統計学の中ではそれが“どう”あるべきかについての議論があります。とはいえ、統計学者どうしの意見の相違はここでの本当の関心事ではありません。本当の関心事は実践的なデータ分析です。帰無仮説有意性検定の“正統的な”アプローチには多くの欠点がありますが、私のような筋金入りのベイズ主義者でさえ、責任をもって使えば有用でありうることは認めます。たいていの場合はまともな答えを出しますし、それを使って興味深いことを学べます。これまで論じてきたさまざまなイデオロギーや歴史的な混乱はさておき、統計全体でいちばん危険なのは考えないことだという事実は変わりません。愚かさという意味ではなく、文字どおり考えないということです。それぞれの検定がデータについて実際に何を語っているのかを時間をかけて考え、自分の解釈がそれと整合しているかを確かめることなく、結果の解釈へ急いでしまうことです。そこにいちばん大きな罨があります。

その例として、次のようなものを考えてみましょう (Gelman2006)。ESP 研究を実施していて、男性参加者と女性参加者でデータを別々に分析することにします。男性参加者では、50 人中 33 人がカードの色を正しく当てました。これは有意な効果です ($p = .03$)。女性参加者では、50 人中 29 人が正しく当てました。これは有意な効果ではありません ($p = .32$)。これを見ると、超能力に男女差があるのはなぜだろうと考え始めたくなる誘惑がきわめて強くなります。しかしこれは間違いです。考えてみれば、男性と女性を明示的に比較する検定を実際には実行していません。やったのは男性を偶然と比べること (二項検定は有意) と、女性を偶然と比べること (二項検定は有意でない) だけです。男性と女性のあいだに本当に差があると主張したいのなら、差がないという帰無仮説の検定を実行すべきでしょう。別の仮説検定^{*14}を使えばそれができますが、やってみると男性と女性が有意に異なるという証拠は得られません ($p = .54$)。それでも 2 つの群のあいだに根本的な違いがあると思うのでしょうか。もちろん思わないはずですが。ここで起きているのは、両方の群 (男性と女性) のデータがどちらもかなり境界線上にある、ということです。純粋な偶然によって、一方が $p = .05$ という線の魔法の側にたまたま落ち、もう一方は落ちなかったのです。それは男性と女性が異なるということを意味しません。この誤りはとてもよくあるものですので、常に警戒しておくべきです。有意と有意でないの違いは、本当の差の証拠ではありません。2 つの群のあいだに差があると言いたいのなら、その差を検定しなければならないのです。

上の例はあくまで一例にすぎません。とてもよくある誤りなので取り上げましたが、大きく言えば、データ分析を正しく行うのは厄介だということです。何を検定したいのか、なぜそれを検定したいのか、そして検定の出す答えが現実世界で何らかの意味をなしうるのかを、よく考えてください。

^{*14} この場合は Pearson のカイ二乗独立性検定です (Chapter ??)。