

1. 二つの平均の比較

第 ?? 章では、アウトカムと予測変数のどちらもが名義尺度である場合について説明しました。この世には実際にそのような場面がたくさんあるので、カイ二乗検定が非常に広く使用されていることがよくわかるでしょう。しかしながら、アウトカムが間隔尺度以上であり、ある群のアウトカム変数の平均値が他の群の平均値よりも高いかどうかに関心をもつ場合がそれ以上に多いかもしれません。例えば、心理学者は、子どものいる親は子どもがいない人よりも不安のレベルが高いかどうかを、あるいは音楽を聴くことで（音楽を聴かないことと比べると）ワーキングメモリー容量が低下するかどうかを知りたいと思うかもしれません。医療の場面では、新薬が血圧を上昇あるいは低下するかどうかを知りたいと思うかもしれません。農業の科学者は、オーストラリアの原生植物にリンを加えることでそれら植物が死滅するかどうかを知りたいかもしれません。^{*1}これらの全ての例で、アウトカム変数はまさに連続尺度、間隔尺度、あるいは比率尺度の変数であって、予測変数は 2 値の“グループ化”変数です。言い換えるならば、2 群の平均を比較したいのです。

平均を比較する問題は、通常 t 検定を用いて答えることができます。 t 検定には、解きたい問題に応じて亜型が存在します。そこで、本章では t 検定の種類の違いに焦点を当てて説明します: 1 標本の t 検定は ?? で、独立した標本の t 検定は ?? と ?? で、対応のある標本の t 検定は ?? で述べられます。続いて、片側検定 (セクション ??) について説明した後で、 t 検定の標準化された効果量の指標である Cohen の d について簡単に説明します (セクション ??)。章の後半では、 t 検定の前提と、その前提を逸脱した場合の対処の仕方に焦点をあてます。それらの役立つ事項について論じる前に、まずは z 検定についての理解を深めることから始めます。

1.1

^{*1}私用の庭で行った非公式な実験によると、リンの付加するとオーストラリア原生植物は死滅することが分かりました。オーストラリアの植物は地球上の他のどの場所よりもリンの濃度が低い地域に適応しています。なので、もし、家を買って庭に外国産の植物と一緒に原生植物を植えたい場合には、それらを分けて植えなければいけません。ヨーロッパの植物にとって栄養となるものがオーストラリアの植物にとって毒になるのです。

1 標本 z 検定

この節では、統計のなかでもっとも役に立たない検定のひとつ、 z 検定について説明します。本当の話です。この検定が実際に使われることはほとんどありません。唯一の存在意義は、統計を教えるときに、おそらく統計でもっとも (使われすぎるほど) 使われている t 検定へ向かう途中の、とても便利な踏み台になることです。

1.1.1 この検定が扱う推測の問題

z 検定の背後にある考え方を紹介するために、簡単な例を使いましょう。私の友人の Zeppo 博士は、統計学入門の授業を相対評価で採点しています。彼のクラスの平均点が 67.5、標準偏差が 9.5 だとしましょう。何百人もいる受講生のうち、20 人は心理学の授業も取っていることがわかりました。好奇心から、心理学の学生は他の全員と同じような成績 (つまり平均 67.5) をとる傾向があるのか、それとも高めか低めなのかが気になってきました。彼が `zeppo.csv` ファイルをメールで送ってくれたので、JASP でその学生たちの成績を見てみます (変数 `x` に入っています)。

50 60 60 64 66 66 67 69 70 74 76 76 77 79 79 79 81 82 82 89

そして 'Descriptives'-'Descriptive Statistics' で平均を計算します。平均値は 72.3 です。

ふむ。心理学の学生は普通より少し高い点をとっているのかもしれませんが。標本平均の $\bar{X} = 72.3$ は仮定された母平均 $\mu = 67.5$ よりかなり高いのですが、一方で標本サイズ $N = 20$ はそれほど大きくありません。単なる偶然かもしれません。

この問いに答えるには、自分が知っていると思っていることを書き出してみると役に立ちます。まず、標本平均が $\bar{X} = 72.3$ であることはわかっています。心理学の学生の標準偏差がクラスの他の学生と同じだと仮定してよいなら、母標準偏差は $\sigma = 9.5$ だと言えます。また、Zeppo 博士が相対評価で採点しているので、心理学の学生の成績は正規分布にしたがうと仮定しておきます。

次に、データから何を知りたいのかをはっきりさせておく役に立ちます。今回の研究仮説は、心理学の学生の成績の母平均 μ に関わるもので、これは未知です。具体的には、 $\mu = 67.5$ かどうかを知りたいわけです。これだけわかっているとして、問題を解く仮説検定を考え出せるでしょうか。データと、それが生じたと考えられる仮定された分布を図 ?? に示しました。正解が何かは、そう自明ではありませんね。そのために統計の出番になります。




Figure1.1 心理学の学生の成績 (棒) が生成されたと想定される理論的な分布 (実線)。

1.1.2 仮説検定を組み立てる

仮説検定を組み立てる第一歩は、帰無仮説と対立仮説が何かをはっきりさせることです。これはさほど難しくありません。帰無仮説 H_0 は「心理学の学生の成績の真の母平均 μ は 67.5% である」で、対立仮説は「母平均は 67.5% ではない」です。これを数式で書くと、次のようになります。

$$H_0 : \mu = 67.5$$

$$H_1 : \mu \neq 67.5$$

正直なところ、この記法が問題の理解を深めてくれるわけではありません。データから何を知ろうとしているのかをコンパクトに書き下しただけです。この検定の帰無仮説 H_0 と対立仮説 H_1 を、どちらも図 ?? に示しました。これらの仮説に加えて、先ほどの場面設定は、役に立ちそうな背景知識をかなり与えてくれています。具体的には、次の 2 つの特別な情報を加えられます。

1. 心理学の学生の成績は正規分布にしたがう。
2. これらの得点の真の標準偏差 σ は 9.5 であるとわかっている。

ここではひとまず、これらが絶対に信頼できる事実であるかのように扱います。現実には、こんな絶

対に信頼できる背景知識など存在しませんので、これらの事実に頼りたいなら、それらが真であるという仮定を置くしかありません。ただしこの仮定は正当化できるとは限りませんので、確認が必要になるかもしれません。とはいえ今のところは、話を単純にしておきます。




Figure1.2 1 標本 z 検定 (両側版) が仮定する帰無仮説と対立仮説の図示。帰無仮説も対立仮説も母集団の分布が正規分布であることを仮定し、さらに母標準偏差が既知である (ある値 σ_0 に固定されている) ことを仮定する。帰無仮説 (左) は母平均 μ が指定された値 μ_0 と等しいというもの。対立仮説は母平均がこの値と異なる、つまり $\mu \neq \mu_0$ というものである。

次のステップは、 H_0 と H_1 を区別する助けになるような、診断のための検定統計量として何がよいかを考えることです。仮説がどれも母平均 μ に関わるものですから、標本平均 $\bar{X}$ から始めるのがよさそうだとかなり確信できるでしょう。やれることは、標本平均 $\bar{X}$ と、帰無仮説が母平均について予測する値との差を見ることです。今回の例では $\bar{X} - 67.5$ を計算するということになります。より一般に、帰無仮説が母平均だと主張する値を μ_0 とすれば、計算したいのは次の量です。

$$\bar{X} - \mu_0$$

この量が 0 に等しいか、とても近ければ、帰無仮説にとって都合のよい状況です。0 から大きく離れていけば、帰無仮説を保持する価値は薄れてきます。しかし H_0 を棄却するには、0 からどれだけ離れていけばよいのでしょうか。

それを知るには少しずる賢くならなければなりませんし、先ほど書き出した 2 つの背景知識、つまり生のデータが正規分布にしたがうことと、母標準偏差 σ の値がわかっていることに頼る必要があります。帰無仮説が実際に正しく、真の平均が μ_0 だとすると、この 2 つを合わせればデータの母集団分布が完全にわかることになります。平均 μ_0 、標準偏差 σ の正規分布です。セクション ?? の記法を使えば、統計学者はこれを次のように書くでしょう。

$$X \sim \text{Normal}(\mu_0, \sigma^2)$$

さて、これが正しいとすると、 $\bar{X}$ の分布について何が言えるでしょうか。先に述べたように (セクション ??参照), 平均 $\bar{X}$ の標本分布もまた正規分布で、その平均は μ です。そしてこの標本分布の標準偏差 $SE(\bar{X})$ は平均の標準誤差と呼ばれ、次のようになります。

$$SE(\bar{X}) = \frac{\sigma}{\sqrt{N}}$$

つまり帰無仮説が正しいければ、平均の標本分布は次のように書けます。

$$\bar{X} \sim \text{Normal}(\mu_0, SE(\bar{X}))$$

ここでひと工夫です。標本平均 $\bar{X}$ を標準得点に変換できます (セクション ??)。慣例的には z と書きますが、ここでは $z_{\bar{X}}$ と呼ぶことにします。(この長めの記法を使うのは、 z 得点が普通指すような 1 つの観測値の標準化ではなく、標本平均の標準化を計算しているのだ、ということを覚えておいてもらうためです。) そうすると、標本平均の z 得点は次のようになります。

$$z_{\bar{X}} = \frac{\bar{X} - \mu_0}{SE(\bar{X})}$$

あるいは、同じことですが、

$$z_{\bar{X}} = \frac{\bar{X} - \mu_0}{\sigma/\sqrt{N}}$$

この z 得点が検定統計量です。これを検定統計量として使うことの良い点は、すべての z 得点と同じように、標準正規分布にしたがうということです。

$$z_{\bar{X}} \sim \text{Normal}(0, 1)$$

(なぜそうなるか忘れてしまったら、またセクション ??を見てください。) つまり、もとのデータがどんな尺度であろうと、 z 統計量そのものの解釈は常に同じです。観測された標本平均 $\bar{X}$ と、帰無仮説が予測する母平均 μ_0 とを隔てている標準誤差の個数に等しいのです。さらに良いことに、生の得点の母集団パラメータが実際どうであろうと、 z 検定の 5% の棄却域は常に同じで、図 ??のようになります。そしてこれは、統計をすべて手計算していた昔の時代には、誰かが次のような表を出版できるということを意味していました。

望む α 水準	z の臨界値	
	両側検定	片側検定
.1	1.644854	1.281552
.05	1.959964	1.644854
.01	2.575829	2.326348
.001	3.290527	3.090232

これはつまり、研究者が z 統計量を手で計算して、教科書で臨界値を調べればよかった、ということです。




Figure1.3 両側 z 検定 (パネル a) と片側 z 検定 (パネル b) の棄却域。

1.1.3 手計算による例

先に述べたように、z 検定が実際に使われることはほとんどありません。あまりに使われないので、JASP には組み込みの機能すらありません。しかしこの検定はきわめて単純ですので、手作業でやるのはとても簡単です。Zeppo 博士のクラスのデータに戻しましょう。grades のデータを読み込んだら、まず標本平均を計算します。これはすでにやりました (72.3)。既知の母標準偏差 ($\sigma = 9.5$) と、帰無仮説が指定する母平均の値 ($\mu_0 = 67.5$) はすでに手元にありますし、標本サイズ ($N = 20$) もわかっています。

次に平均の (真の) 標準誤差を計算しましょう (電卓で簡単にできます)。

$$\begin{aligned}
 se(\bar{X}) &= \frac{\sigma}{\sqrt{N}} \\
 &= \frac{9.5}{\sqrt{20}} \\
 &= 2.124265
 \end{aligned}$$

ここから z 得点を計算します。

$$\begin{aligned} z_{\bar{X}} &= \frac{\bar{X} - \mu_0}{sd(\bar{X})} \\ &= \frac{72.3 - 67.5}{2.124265} \\ &= 2.259606. \end{aligned}$$

ここで、伝統的には 2.26 という値を臨界値の表で調べます。もとの仮説は両側でした (心理学の学生が他の学生より統計が得意か不得意かについて、特に理論があったわけではありません) ので、仮説検定も両側 (両裾) になります。先ほどの小さな表を見ると、2.26 は $\alpha = .05$ で有意になるのに必要な臨界値 1.96 より大きく、 $\alpha = .01$ の水準で有意になるのに必要な 2.58 より小さいことがわかります。ですから有意な効果が得られたと結論でき、次のように書くことになるでしょう。

心理学の学生の標本における平均成績は 73.2 であり、真の母標準偏差を 9.5 と仮定すると、心理学の学生の統計の得点はクラス平均と有意に異なると結論できる ($z = 2.26$, $N = 20$, $p < .05$)。

1.1.4 z 検定の仮定

これまでも述べてきたように、すべての統計的検定は仮定を置いています。妥当な仮定を置く検定もあれば、そうでない検定もあります。いま説明した 1 標本 z 検定は、3 つの基本的な仮定を置いています。次のとおりです。

- **正規性。** 通常の説明では、z 検定は真の母集団分布が正規分布であることを仮定します*2。これはたいてい妥当な仮定ですし、心配なら確認することもできます (セクション ??参照)。
- **独立性。** 2 つめの仮定は、データの観測値どうしが相関していない、あるいは何か妙な形で関連していない、ということです。これは統計的に確認するのがそう簡単ではなく、良い実験デザインに頼る部分があります。この仮定を破る明らかな (そしてばかげた) 例は、同じ観測値をデータファイルの中で何度も “コピー” して、本物の観測値は 1 つしかないのに巨大な “標本サイズ” になっているデータです。より現実的には、それぞれの観測値が関心のある母集団からの完全にランダムな標本だと考えるのが本当にもっともらしいかどうかを、自問しなければなりません。実際にはこの仮定が満たされることはありませんが、関連したデータの問題を最小にするような研究デザインを心がけるわけです。

*2 実のところこれは強すぎます。厳密には、z 検定が要求するのは平均の標本分布が正規分布であることです。母集団が正規分布なら、平均の標本分布も必然的に正規分布になります。しかし中心極限定理の話で見たように、母集団分布そのものが正規でなくても標本分布が正規になることは十分ありえます (むしろよくあります)。とはいえ、真の標準偏差が既知だという仮定のばかばかしさを考えれば、この点を詳しく述べる意味はありません。

- 標準偏差が既知。z 検定の 3 つめの仮定は、母集団の真の標準偏差を研究者が知っている、というものです。これはただのばかげた話です。現実のデータ分析で、母集団の標準偏差 σ はわかっているのに平均 μ についてはまったく知らない、などという場面はありません。つまりこの仮定は常に誤りです。

σ が既知だと仮定することのばかばかしさを踏まえて、それなしでやっていけるかどうかを見てみましょう。これによって z 検定という陰気な領域を抜け出し、t 検定という魔法の王国へ入っていくことになります。

1.2

要約

- 1 標本 t 検定は、ひとつの標本平均を仮定された母平均の値と比較するために使う (セクション ??)。
- 独立標本 t 検定は 2 群の平均を比較するために使い、両群の平均が等しいという帰無仮説を検定する。2 つの形があり、Student の検定 (セクション ??) は両群の標準偏差が等しいと仮定するが、Welch の検定 (セクション ??) は仮定しない。
- 対応のある標本の t 検定は、各人から 2 つの得点が得られていて、その 2 つの得点の平均が等しいという帰無仮説を検定したいときに使う。各人について 2 つの得点の差をとり、その差の得点に 1 標本 t 検定を実行することと同等である (セクション ??)。
- 片側検定は、あらかじめ計画されている限りまったく正当である (セクション ??)。
- 平均の差についての効果量は、Cohen の d 統計量によって計算できる (セクション ??)。
- 標本の正規性は、QQ プロット (現在の JASP では利用できない) と Shapiro-Wilk 検定で確認できる (セクション ??)。
- データが正規でない場合は、t 検定のかわりに Mann-Whitney 検定や Wilcoxon 検定を使える (セクション ??)。

1.3

1 標本 t 検定

少し考えてみて、心理学の学生の成績が Zeppo 博士のクラスの他の学生と必ず同じ標準偏差を持つと仮定するのは危ないかもしれない、と思いました。そもそも平均が同じではないという仮説を検討しているのに、標準偏差だけは絶対に同じだと信じる理由がどこにあるのでしょうか。ですから、 σ の真の値を知っているという仮定はやめるべきです。これは z 検定の仮定を破りますので、ある意

味で振り出しに戻ったことになります。とはいえ、手立てがまったくないわけではありません。生のデータは手元にありますし、そこから母標準偏差の推定値が得られます。9.52 です。つまり $\sigma = 9.5$ であると知っているとは言えませんが、 $\hat{\sigma} = 9.52$ であるとは言えるのです。

なるほど。すぐ思いつくのは、真の標準偏差が 9.5 だという仮定に頼るかわりに、推定された標準偏差 9.52 を使って z 検定を実行することでしょう。そしてそれでも有意な結果が出ると聞いても、おそらく驚かないはずです。このやり方は惜しいのですが、完全に正しいわけではありません。いまや母標準偏差の推定値に頼っているのですから、真の母標準偏差が実際どうなのかについての不確かさを、何らかの形で調整する必要があります。データがたまたまそうなかっただけかもしれません。たとえば真の母標準偏差は 11 かもしれないのです。しかしもしそれが本当で、 $\sigma=11$ と仮定して z 検定を実行したとすると、結果は有意でなくなってしまう。これは問題です、対処しなければならぬ問題です。




Figure1.4 (両側の)1 標本 t 検定が仮定する帰無仮説と対立仮説の図示。 z 検定 (図 ??) とよく似ていることに注意。帰無仮説は母平均 μ が指定された値 μ_0 と等しいというもので、対立仮説はそうでないというもの。 z 検定と同じくデータが正規分布にしたがうことは仮定するが、母標準偏差 σ があらかじめ既知であるとは仮定しない。

1.3.1 t 検定の紹介

この曖昧さは厄介ですが、1908 年に William Sealy Gosset という人物によって解決されました (Student1908)。彼は当時ギネス醸造所で化学者として働いていました (Box1987)。ギネスは従業員が統計分析を公表することを快く思っていなかった (企業秘密だと考えていたようです) ので、彼




Figure1.5 自由度 2(左) と自由度 10(右) の t 分布。比較のため、標準正規分布 (つまり平均 0・標準偏差 1) を点線で描いてある。 t 分布は正規分布より裾が重い (尖鋭的: 尖度が高い) ことに注意。この効果は自由度がとても小さいときにはかなり誇張されるが、値が大きくなると無視できる。つまり自由度 df が大きければ、 t 分布は正規分布と本質的に同じである。

は “A Student” という筆名でこの仕事を発表しました。そのため今日に至るまで、 t 検定の正式名称は **Student の t 検定** なのです。Gosset が明らかにした肝心な点は、真の標準偏差が完全にはわからないという事実をどう取り込むか、ということでした^{*3}。答えは、それによって標本分布が微妙に変わる、というものです。 t 検定では、 t 統計量と呼ばれる検定統計量が、先ほど述べたのとまったく同じやり方で計算されます。帰無仮説が「真の平均は μ である」で、標本の平均が $\bar{X}$ 、母標準偏差の推定値が $\hat{\sigma}$ なら、 t 統計量は次のようになります。

$$t = \frac{\bar{X} - \mu}{\hat{\sigma}/\sqrt{N}}$$

式で変わったのは、既知の真の値 σ のかわりに推定値 $\hat{\sigma}$ を使う、という点だけです。そしてこの推定値が N 個の観測から作られているなら、標本分布は**自由度** (df) $N - 1$ の t 分布になります。 t 分布は正規分布とよく似ていますが、セクション ?? で述べ、図 ?? に示したように、裾が “重く” なっています。ただし自由度が大きくなるにつれて、 t 分布は標準正規分布とほとんど同じに見えてくることに注意してください。そうなるべきなのです。標本サイズが $N = 70,000,000$ なら、標準偏差の “推定値” はほぼ完璧でしょう。ですから N が大きければ t 検定は z 検定とまったく同じようにふる

まうはずです。そして実際そうなります。

1.3.2 JASP で検定を実行する

予想どおり、 t 検定の仕組みは z 検定の仕組みとほとんど同じです。ですから低水準のコマンドで計算する方法を延々と見せる意味はあまりありません。推定された標準偏差を使い、正規分布ではなく t 分布で仮説を検定する、という点を除けば、先ほどの計算とほぼ同じです。ですから 2 度目の退屈な計算の詳細は飛ばして、 t 検定が実際にどう行われるかを見せることにします。JASP には t 検定専用の分析が用意されていて、とても柔軟です (いろいろな種類の t 検定を実行できます)。使い方はごく素直です。‘T-Tests’-‘One Sample T-Test’ を指定し、関心のある変数 (x) を ‘Variables’ のボックスに移し、帰無仮説の平均値 (‘67.5’) を ‘Test value’ のボックスに入力するだけです。簡単ですね。図 ?? を見てください。あとで触れる他の情報とあわせて、 t 統計量が 2.25、自由度が 19、対応する p 値が 0.036 であることが示されています。




Figure1.6 JASP による 1 標本 t 検定。

標本平均の 95% 信頼区間を計算するのも簡単です。‘Additional Statistics’ の下にある ‘Location parameter’ とそれに付随する ‘Confidence interval’ のオプションを選ぶと、JASP の出力に ‘Mean difference’ が 4.800、95% 信頼区間が [0.344, 9.256] と表示されます。これは単に、標本と仮定され

*3まあ、ある意味では、ですが。私の理解する歴史では、Gosset は部分的な解決を与えたにすぎず、この問題の一般的な解決は Ronald Fisher 卿によって与えられました。

た平均 67.5 との差の推定値が 0.344 から 9.256 のあいだにあると 95% の確信をもって言える、という意味です。この“端点”を仮定された平均に足すと、95% 信頼区間は $[67.5+0.344, 67.5+9.256]$, 言い換えれば $[67.844, 76.800]$ になります。よくわからなくても心配しないでください。次の節でもう少し説明します。

さて、この出力をどう使えばよいのでしょうか。おもちゃの例を本気で気にかけているふりをしているので、結果が統計的に有意である (つまり p 値が .05 未満である) ことがわかって大喜びです。結果は次のように報告できるでしょう。

心理学の学生の平均成績は 72.3 であり、平均成績 67.5 をわずかに上回っていた ($t(19) = 2.25, p < .05$)。95% 信頼区間は 67.8 から 76.8 である。

ここで $t(19)$ は、自由度 19 の t 統計量を表す略記です。とはいえ、信頼区間を報告しない人も多いですし、ここで示したよりずっと圧縮した形で書く人もいます。たとえば、次のように統計量のかたまりの一部として信頼区間を入れるのもよく見かけます。

$t(19) = 2.25, p < .05, CI_{95} = [67.8, 76.8]$

これだけの専門用語が半行に詰め込まれていれば、さぞ賢そうに見えるでしょう*4。

1.3.3 1 標本 t 検定の仮定

さて、1 標本 t 検定はどんな仮定を置いているのでしょうか。 t 検定は基本的に、標準偏差が既知だという仮定を取り除いた z 検定ですから、標準偏差についての仮定を除けば z 検定と同じ仮定を置いても驚くにはあたりません。つまり次のとおりです。

- **正規性**。依然として母集団分布が正規分布であることを仮定しています*5。先に述べたように、この仮定が満たされているかを確認する標準的な道具がありますし (セクション ??), 破られている場合には代わりに使える検定もあります (セクション ??)。
- **独立性**。ここでも、標本の観測値が互いに独立に生成されていることを仮定しなければなりま

*4もっとまじめに言うと、私はむしろ逆だと思っています。結果の節を数値だけで埋め尽くした技術報告には、かなり疑いの目を向けます。私が傲慢なだけかもしれませんが、読者に対して分析を説明し解釈しようとしないう著者は、自分でも理解していないか、少し怠けているかのどちらかだとよく感じます。読者は賢いですが、無限に忍耐強いわけではありません。避けられるなら、苛立たせないようにしましょう。

*5技術的な注記です。 z 検定の仮定を弱めて標本分布についてだけ語れるようにできたのと同じように、 t 検定の仮定も弱めて母集団の正規性を仮定しなくてよいようにできます。ただし t 検定でこれやるのはより厄介です。先ほどと同じく、母集団の正規性の仮定は $\bar{X}$ の標本分布が正規であるという仮定に置き換えられます。しかし標準偏差の標本推定値にも頼っていることを思い出してください。ですから σ の標本分布がカイ二乗分布であることも要求されます。話が面倒になりますので、この版が実際に使われることはめったにありません。幸い、母集団分布が正規であれば、この 2 つの仮定はどちらも満たされます。

せん。詳しくは z 検定についての先ほどの議論を見てください (セクション ??)。

全体として、この 2 つの仮定はそれほど無理のあるものではありませんので、1 標本 t 検定は標本平均を仮定された母平均と比較する方法として、実際はかなり広く使われています。

1.4

独立標本 t 検定 (Student の検定)

1 標本 t 検定にも使い道はありますが、 t 検定のもっとも典型的な例ではありません^{*6}。はるかによくあるのは、2 つの異なる観測の群がある場合です。心理学ではこれはたいてい 2 つの異なる参加者群にあたり、それぞれの群が研究の異なる条件に対応します。研究の各参加者について関心のある結果変数を測定し、2 つの群の母平均が同じかどうかを問うわけです。これが独立標本 t 検定の想定する場面です。

1.4.1 データ

Harpo 博士の統計の講義を受けている学生が 33 人いて、Harpo 博士は相対評価をしないとしましょう。実のところ Harpo 博士の採点は謎めいていて、クラス全体の平均点がどれくらいなのかは何もわかりません。このクラスには Anastasia と Bernadette という 2 人のチューターがいます。Anastasia のチュートリアルには $N_1 = 15$ 人、Bernadette のチュートリアルには $N_2 = 18$ 人の学生がいます。私の関心のある研究上の問いは、Anastasia と Bernadette のどちらが優れたチューターなのか、それともたいして違いはないのか、ということです。Harpo 博士が授業の成績を `harpo.csv` ファイルでメールしてくれました。いつものように JASP にファイルを読み込んで、どんな変数が入っているかを見てみます。ID, `grade`, `tutor` の 3 つの変数があります。当然ながら `grade` 変数には各学生の成績が入っています。`tutor` 変数は各学生のチューターが誰だったか、Anastasia か Bernadette かを示す要因です。

‘Descriptives’-‘Descriptive Statistics’ の分析で平均と標準偏差を計算できます (必ず `tutor` で分割してください)。きれいな要約表ができました。

	平均	標準偏差	N
Anastasia の学生	74.53	9.00	15
Bernadette の学生	69.06	5.77	18

^{*6}ただしいちばん単純ではあるので、そこから始めたわけです。

何が起きているかをもう少し詳しくつかんでもらうために、両チューターの成績の分布を示すヒストグラム (図 ??) と、両群の平均と対応する信頼区間を示すより単純なプロット (図 ??) を描きました (JASP ではなく R を使っています)。




Figure 1.7 Anastasia のクラス (パネル a) と Bernadette のクラス (パネル b) の学生の成績の分布を示すヒストグラム。見た目には、Anastasia のクラスの学生のほうが平均してやや良い成績をとっているように見えるが、ばらつきも少し大きいようである。

1.4.2 検定の紹介

独立標本 t 検定には Student のものと Welch のものの 2 つの形があります。この節で説明するものとの Student の t 検定は、2 つのうち単純なほうですが、Welch の t 検定よりずっと制約の強い仮定に頼っています。ひとまず両側検定を実行したいとすると、目的は 2 つの“独立な標本”が同じ平均を持つ母集団から得られたのか (帰無仮説)、異なる平均を持つ母集団から得られたのか (対立仮説) を判断することです。“独立な”標本というとき、ここで本当に意味しているのは、2 つの標本の観測値のあいだに特別な関係がない、ということです。いまはピンとこないかもしれませんが、あとで対応のある標本の t 検定の話をするときにはっきりするでしょう。いまのところは、参加者を 2 つの群のどちらかに無作為に割り当てる実験デザインで、何らかの結果指標について 2 群の平均を比べたいのなら、(対応のある標本の t 検定ではなく) 独立標本 t 検定が求めているものだ、と指摘しておくにとどめます。

それでは、群 1(たとえば Anastasia の学生) の真の母平均を μ_1 、群 2(たとえば Bernadette の学




Figure1.8 Anastasia と Bernadette のチュートリアルの学生の平均成績。エラーバーは平均のまわりの 95% 信頼区間を表す。見た目には群間に本当の差がありそうだが、確かなことは言いにくい。

生) の真の母平均を μ_2 としましょう*7。そしていつものように、この 2 群で観測された標本平均を $\bar{X}_1$ と $\bar{X}_2$ とします。帰無仮説は 2 つの母平均が等しい ($\mu_1 = \mu_2$) というもので、対立仮説はそうではない ($\mu_1 \neq \mu_2$) というものです。数式で書くと次のようになります。

$$H_0: \mu_1 = \mu_2$$

$$H_1: \mu_1 \neq \mu_2$$

この場面を扱う仮説検定を組み立てるにあたって、まず帰無仮説が正しければ母平均の差がちょうどゼロになること、つまり $\mu_1 - \mu_2 = 0$ であることに注目します。ですから診断のための検定統計量は、2 つの標本平均の差にもとづくものになります。帰無仮説が正しければ $\bar{X}_1 - \bar{X}_2$ はゼロにかなり近いと期待されるからです。ただし 1 標本の検定 (つまり 1 標本 z 検定と 1 標本 t 検定) で見たのと同じく、この差がゼロにどれだけ近ければよいのかを正確にしなければなりません。解決策はだいたい同じです。前回と同じく標準誤差の推定値 (SE) を計算し、平均の差をそれで割ります。で

*7 ここで必ずと言っていいほど妙な質問が出ます。この場合の母集団とはいったい何なのか、と。実際に Harpo 博士の授業を受けている学生の集合 (33 人全員) でしょうか。その授業を受けうる人々の集合 (人数は不明) でしょうか。それとも別の何かでしょうか。どれを選ぶかは問題になるのでしょうか。行動科学の統計入門の授業では、ここで口ごもるのが伝統なのですが、毎年学生に聞かれるので簡単に答えておきます。厳密に言えば、問題になります。“現実世界”の母集団が何かという定義を変えれば、観測された平均 $\bar{X}$ の標本分布も変わります。 t 検定は、観測が無限に大きな母集団から無作為に抽出されたという仮定に頼っていますので、現実がそうでない分だけ t 検定は誤りうるのです。ただし実際には、たいがい大した問題にはなりません。この仮定はほとんど常に誤っているのですが、検定が病的なふるまいをすることにはあまりつながりませんので、無視してしまうのが普通です。




Figure1.9 Student の t 検定が仮定する帰無仮説と対立仮説の図示。帰無仮説は両群が同じ平均 μ を持つと仮定し、対立仮説は異なる平均 μ_1 と μ_2 を持つと仮定する。母集団分布が正規分布であることが仮定されていること、そして対立仮説は群が異なる平均を持つことを許すものの、標準偏差は同じであると仮定していることに注意。

すから t 統計量は次の形になります。

$$t = \frac{\bar{X}_1 - \bar{X}_2}{SE}$$

あとはこの標準誤差の推定値が実際どうなるかを考えるだけです。これはここまで見てきた 2 つの検定のどちらよりも少し厄介ですので、仕組みを理解するにはずっと注意深く追っていく必要があります。

1.4.3 標準偏差の“プールされた推定値”

もとの“Student の t 検定”では、2 つの群が同じ母標準偏差を持つという仮定を置きます。つまり母平均が同じかどうかとは関係なく、母標準偏差は等しい ($\sigma_1 = \sigma_2$) と仮定するわけです。2 つの標準偏差が同じだと仮定していますので、添字を落として両方とも σ と呼ぶことにします。これをどう推定すればよいのでしょうか。2 つの標本があるとき、標準偏差のひとつの推定値をどう作ればよいのでしょうか。答えは、基本的には平均する、です。まあ、ある意味では。実際にやるのは、分散の推定値の重みつき平均をとることで、これを**プールされた分散の推定値**として使います。各標本に与えられる重みは、その標本の観測数から 1 を引いたものに等しくなります。

数式で書くと次のようになります。

$$\begin{aligned}w_1 &= N_1 - 1 \\w_2 &= N_2 - 1\end{aligned}$$

各標本に重みを与えたので、2つの分散の推定値 $\hat{\sigma}_1^2$ と $\hat{\sigma}_2^2$ の重みつき平均をとって、プールされた分散の推定値を計算します。

$$\hat{\sigma}_p^2 = \frac{w_1 \hat{\sigma}_1^2 + w_2 \hat{\sigma}_2^2}{w_1 + w_2}$$

最後に、平方根をとってプールされた分散の推定値をプールされた標準偏差の推定値に変換します。

$$\hat{\sigma}_p = \sqrt{\frac{w_1 \hat{\sigma}_1^2 + w_2 \hat{\sigma}_2^2}{w_1 + w_2}}$$

そしてこの式に $w_1 = N_1 - 1$ と $w_2 = N_2 - 1$ を頭の中で代入すると、とても見苦しい式が出てきます。その見苦しい式が、どうやらプールされた標準偏差の推定値を書き表す“標準的な”やり方らしいのです。とはいえ、これは私の好きな考え方ではありません。私はこう考えるほうが好きです。データは実際には、2つの群に振り分けられた N 個の観測の集まりです。そこで、 k 番目のチュートリアル群の i 番目の学生がとった成績を X_{ik} と書くことにしましょう。つまり X_{11} は Anastasia のクラスの1人目の学生の成績、 X_{21} は2人目の学生、という具合です。そして2つの群平均 $\bar{X}_1$ と $\bar{X}_2$ があり、これを“一般的に” $\bar{X}_k$ 、つまり k 番目のチュートリアル群の平均成績と書けます。ここまではよいでしょう。さて、どの学生も2つのチュートリアルのどちらかに属していますので、群平均からの偏差を次の差として書けます。

$$X_{ik} - \bar{X}_k$$

であれば、この偏差（つまり各学生の成績が自分のチュートリアルの平均成績とどれだけ違うか）をそのまま使えばよいのではないのでしょうか。分散とは偏差の二乗の平均にすぎないことを思い出して、やってみましょう。数式では次のように書けます。

$$\frac{\sum_{ik} (X_{ik} - \bar{X}_k)^2}{N}$$

ここで“ $\sum_{ik}$ ”という記法は“すべてのチュートリアルのすべての学生を見て合計を計算する”ということの横着な書き方です。それぞれの“ ik ”が1人の学生に対応しているからです⁴。しかし Chapter ?? で見たように、 N で割って分散を計算すると母分散の偏った推定値になってしまいます。そして以前は、これを直すために $N - 1$ で割る必要がありました。そのとき述べたように、この偏りが生じるのは分散の推定値が標本平均に頼っているからで、標本平均が母平均と等しくない分だけ、分散の推定値が系統的に偏りうるのです。しかし今回は2つの標本平均に頼っています。

ということは偏りが増えるのでしょうか。そのとおりです。では、プールされた分散の推定値を計算するには $N - 1$ ではなく $N - 2$ で割る必要があるのでしょうか。そのとおりです。

$$\hat{\sigma}_p^2 = \frac{\sum_{ik} (X_{ik} - \bar{X}_k)^2}{N - 2}$$

そしてこの平方根をとれば、プールされた標準偏差の推定値 $\hat{\sigma}_p$ が得られます。つまりプールされた標準偏差の計算は特別なものではありません。通常の標準偏差の計算とそれほど変わらないのです。

^aより正確な記法は Chapter ?? で導入します。

1.4.4 検定を完成させる

どちらの考え方をとるにせよ、これでプールされた標準偏差の推定値が手に入りました。これ以降は面倒な添字 p を落として、この推定値を単に $\hat{\sigma}$ と呼ぶことにします。よろしい。では例の仮説検定の話に戻しましょう。このプールされた推定値を計算したそもそもの理由は、標準誤差の推定値を計算するときに役立つとわかっていたからです。しかし何の標準誤差でしょうか。1 標本 t 検定では標本平均の標準誤差 $SE(\bar{X})$ であり、 $SE(\bar{X}) = \sigma/\sqrt{N}$ でしたから、 t 統計量の分母はその形をしていました。しかし今回は標本平均が 2 つあります。そして具体的に關心があるのは、その 2 つの差 $\bar{X}_1 - \bar{X}_2$ です。ですから割るべき標準誤差は、実は平均の差の標準誤差なのです。

2 つの変数が本当に同じ標準偏差を持っている限り、標準誤差の推定値は次のようになります。

$$SE(\bar{X}_1 - \bar{X}_2) = \hat{\sigma} \sqrt{\frac{1}{N_1} + \frac{1}{N_2}}$$

したがって t 統計量は次のとおりです。

$$t = \frac{\bar{X}_1 - \bar{X}_2}{SE(\bar{X}_1 - \bar{X}_2)}$$

1 標本の検定で見たのと同じく、帰無仮説が正しく検定の仮定がすべて満たされている限り、この t 統計量の標本分布は t 分布になります (驚きですね)。ただし自由度は少し異なります。いつものように、自由度はデータ点の数から制約の数を引いたものだと考えられます。今回は N 個の観測 (標本 1 に N_1 個、標本 2 に N_2 個) と 2 つの制約 (標本平均) があります。ですからこの検定の自由度は $N - 2$ になります。

1.4.5 JASP で検定を実行する

当然ながら、JASP では独立標本 t 検定を簡単に実行できます。この検定の結果変数は学生の **grade** で、群は各クラスの **tutor** によって定義されます。ですから JASP でやることは、図 ?? のように該当の分析 ('T-Tests'-'Independent Samples T-Test') を開き、**grade** 変数を 'Variables' のボックスに、**tutor** 変数を 'Grouping Variable' のボックスに移すだけだと聞いても、たいして驚かないでしょう。




Figure1.10 JASP での独立標本 t 検定。有用な結果が得られるようオプションにチェックを入れてある

出力はとても見慣れた形をしています。まずどの検定が実行されたかと、使った従属変数の名前が示されます。次に検定の結果が報告されます。前回と同じく、結果は t 統計量、自由度、 p 値からなります。最後の部分では2つのこと、信頼区間と効果量が報告されます。効果量についてはあとで話します。ただし信頼区間についてはいま述べておくべきでしょう。

この信頼区間が実際に何を指しているのかをはっきりさせておくことは、かなり重要です。これは群平均の差についての信頼区間です。今回の例では、Anastasia の学生の平均成績は 74.533、Bernadette の学生の平均成績は 69.056 でしたから、2つの標本平均の差は 5.478 です。もちろん母平均の差はこれより大きいことも小さいこともありえます。図 ?? に示された信頼区間は、この研究を何度も繰り返したとすると、95% の場合に平均の真の差が 0.197 から 10.759 のあいだに入る、ということを示しています。信頼区間が何を意味するかについては、セクション ?? を見返してください

さい。

いずれにせよ 2 群の差は (かろうじて) 有意ですので、結果は次のように書けるでしょう。

Anastasia のクラスの平均成績は 74.5%(標準偏差 = 9.0), Bernadette のクラスの平均は 69.1%(標準偏差 = 5.8) であった。Student の独立標本 t 検定の結果、この 5.4% の差は有意であり ($t(31) = 2.1, p < .05, CI_{95} = [0.2, 10.8], d = .74$)、学習成果に本当の差が生じたことが示唆された。

統計量のかたまりに信頼区間と効果量を入れていることに注意してください。みんながいつもこうするわけではありません。最低限、 t 統計量・自由度・ p 値は載っていると期待されます。ですから最低でも $t(31) = 2.1, p < .05$ のようなものは入れるべきです。統計学者の思いどおりになるなら、みんなが信頼区間も、おそらく効果量の指標も報告することになるでしょう。知っておくと役に立つものだからです。しかし現実には統計学者の望みどおりには進みませんので、読者の助けになるかどうか、そして学術論文を書いているならその雑誌の編集方針にもとづいて判断すべきです。効果量の報告を求める雑誌もあれば、求めない雑誌もあります。信頼区間の報告が標準になっている学術コミュニティもあれば、そうでないところもあります。読み手が何を期待しているのかを見極める必要があります。ただしはっきりさせておくと、私の授業を取っているのであれば、私の基本的な立場は効果量も信頼区間も両方入れる価値がたいていある、というものです。

1.4.6 t 値の正と負

t 検定の仮定の話に移る前に、 t 検定を実際に使うことについてもう 1 点述べておきたいことがあります。それは t 統計量の符号 (つまり正の数か負の数か) についてです。学生が初めて t 検定を実行するときにとってもよくある心配は、 t 統計量が負の値になってしまい、どう解釈すればよいかかわからない、というものです。実際、別々に作業した 2 人が、一方は負の t 値、他方は正の t 値という点を除いてほぼ同じ結果に行き着く、ということはまったく珍しくありません。両側検定を実行しているなら、 p 値は同じになります。よく見ると、信頼区間も符号が逆になっていることに気づくでしょう。これはまったく問題ありません。こうなるのは、 t 検定の実行のしかたが少し違っているからです。起きていることはとても単純です。ここで計算する t 統計量は常に次の形をしています。

$$t = \frac{(\text{平均 1}) - (\text{平均 2})}{(SE)}$$

“平均 1” が “平均 2” より大きければ t 統計量は正になり、“平均 2” のほうが大きければ t 統計量は負になります。同じように、JASP が報告する信頼区間は “(平均 1) 引く (平均 2)” の差についての信頼区間ですので、“(平均 2) 引く (平均 1)” の差について計算した場合とは逆になります。

考えてみればごく素直な話ですが、では Anastasia のクラスと Bernadette のクラスを比べる t 検

定を考えてみましょう。どちらを“平均 1”と呼び、どちらを“平均 2”と呼ぶべきでしょうか。恣意的です。とはいえ、どちらかを“平均 1”，もう一方を“平均 2”と決めなければなりません。当然ながら，JASP がこれをどう扱うかもかなり恣意的です。本書の以前の版では説明しようとしていたのですが，そのうち諦めました。たいてい重要ではありませんし，正直なところ私自身が覚えられないからです。有意な t 検定の結果が出て，どちらの平均が大きいかを知りたいとき，私は t 統計量を見て考えようとはしません。なぜそんな面倒なことをするのでしょうか。ばかげています。JASP の出力には実際の群平均が出ているのですから，それを見るほうが簡単です。

大事なのはここです。JASP が何を表示するかは本当にどうでもよいので，私はたいてい，数値が文章と合うような形で t 統計量を報告するようにしています。報告書に“Anastasia のクラスは Bernadette のクラスより成績が高かった”と書きたいとしましょう。この言い方は Anastasia の群が先に来ることを含意していますので，Anastasia のクラスを群 1 として t 統計量を報告するのが理にかなっています。その場合は次のように書きます。

Anastasia のクラスは Bernadette のクラスより成績が高かった($t(31) = 2.1, p = .04$)。

(実際には“高かった”に下線を引いたりはしません。“高い”が正の t 値に対応することを強調するためにやっているだけです。) 一方，Bernadette のクラスを先に挙げる言い方をしたい場合はどうでしょうか。その場合は彼女のクラスを群 1 として扱うほうが理にかなっていて，書き方は次のようになります。

Bernadette のクラスは Anastasia のクラスより成績が低かった($t(31) = -2.1, p = .04$)。

今回は一方の群の得点が“低い”という話をしているのですから， t 統計量は負の形を使うほうが自然です。そのほうが読みやすくなります。

最後にひとつ。他の種類の検定統計量ではこれができないことに注意してください。 t 検定では通用しますが，カイ二乗検定や F 検定，実のところ本書で扱うほとんどの検定では意味をなしません。ですからこの助言を一般化しすぎないでください。ここで話しているのは t 検定のことだけです。

1.4.7 検定の仮定

いつものように，仮説検定はいくつかの仮定に頼っています。それは何でしょうか。Student の t 検定には 3 つの仮定があり，そのいくつかは 1 標本 t 検定の文脈ですで見えたものです (セクション ??参照)。

- **正規性。** 1 標本 t 検定と同じく，データが正規分布にしたがうことを仮定します。具体的には，両方の群が正規分布にしたがうと仮定します。正規性の検定についてはセクション ??で，

考えられる対処法についてはセクション ?? で述べます。

- **独立性**。ここでも、観測が独立に抽出されていることを仮定します。Student の検定の文脈では、これには 2 つの側面があります。まず各標本内の観測が互いに独立であると仮定します (1 標本の検定とまったく同じです)。加えて、標本をまたいだ依存関係がないことも仮定します。たとえば研究の両方の実験条件に同じ参加者が入っていた (うっかり同じ人が異なる条件に申し込めてしまった, など) ことがわかったなら, 考慮しなければならない標本間の依存関係があることになります。
- **分散の等質性** (“等分散性” と呼ばれます)。3 つめの仮定は, 母標準偏差が両群で同じであるということです。この仮定は Levene の検定で検討できます。これについては本書の後のほうで述べます (セクション ??)。ただし心配な場合にはこの仮定に対するとても簡単な対処法があり, それを次の節で述べます。

1.5

独立標本 t 検定 (Welch の検定)

Student の検定を実際に使うときの最大の問題は, 前節に挙げた 3 つめの仮定です。両方の群が同じ標準偏差を持つと仮定しているのです。現実これが成り立つことはめったにありません。2 つの標本の平均が同じでないのなら, 標準偏差だけ同じだと期待する理由がどこにあるのでしょうか。この仮定が成り立つと期待する根拠は本当にありません。この仮定をどう確認するかについてはあとで少し述べます。 t 検定だけでなく, いくつかの場面で出てくるからです。ここではまず, この仮定に頼らない別の形の t 検定 (Welch1947) について話します。**Welch の t 検定** がデータについて何を仮定しているかを図 ?? に示しました。図 ?? の Student の検定版と対比してみてください。診断の話より先に治療の話をするのは少し変だと認めますが, たまたま Welch の検定は JASP の 'Independent Samples T-Test' のオプションのひとつとして指定できますので, ここで扱うのがおそらくいちばんよいでしょう。

Welch の検定は Student の検定とよく似ています。たとえば Welch の検定で使う t 統計量は, Student の検定とほぼ同じやり方で計算されます。つまり標本平均の差をとり, その差の標準誤差の推定値で割るのです。

$$t = \frac{\bar{X}_1 - \bar{X}_2}{SE(\bar{X}_1 - \bar{X}_2)}$$

主な違いは, 標準誤差の計算が異なることです。2 つの母集団の標準偏差が異なるなら, プールされた標準偏差の推定値を計算しようとするのはまったくの無意味です。りんごとみかんを平均してい




Figure1.11 Welch の t 検定が仮定する帰無仮説と対立仮説の図示。Student の検定 (図 ??) と同じく両方の標本が正規母集団から得られたと仮定するが、対立仮説はもはや 2 つの母集団が等しい分散を持つことを要求しない。

.....

るようなものだからです*8。

それでも標本平均の差の標準誤差を推定することはできて、ただ見た目が変わるだけです。

$$SE(\bar{X}_1 - \bar{X}_2) = \sqrt{\frac{\hat{\sigma}_1^2}{N_1} + \frac{\hat{\sigma}_2^2}{N_2}}$$

なぜこう計算するのは本書の範囲を超えます。ここで重要なのは、Welch の t 検定から出てくる t 統計量が、Student の t 検定から出てくるものとは実際いくらか異なる、ということです。

Welch と Student の 2 つめの違いは、自由度の計算のしかたがまるで異なることです。Welch の検定では“自由度”はもはや整数である必要がありませんし、ここまで使ってきた“データ点の数から制約の数を引く”という目安にもそれほど近くありません。

*8まあ、りんごとみかんを平均することはできて、おいしいフルーツスムージーができあがるでしょうけど。でも、フルーツスムージーがもとの果物をうまく言い表しているとは、誰も本気で思わないですね。

自由度は実際には次のようになります。

$$df = \frac{(\hat{\sigma}_1^2/N_1 + \hat{\sigma}_2^2/N_2)^2}{(\hat{\sigma}_1^2/N_1)^2/(N_1 - 1) + (\hat{\sigma}_2^2/N_2)^2/(N_2 - 1)}$$

実に素直で明快ですね。まあ、そうでもないかもしれません。ここでの目的にはたいして関係ありません。重要なのは、Welch の検定から出てくる “df” の値が Student の検定で使われるものより少し小さくなる傾向があること、そして整数である必要がないことです。

1.5.1 JASP で Welch の検定を実行する

先ほどの分析で Welch の検定のチェックボックスにチェックを入れると、次のような結果になります (図 ??)。

Independent Samples T-Test ▼

Independent Samples T-Test ▼									
		Statistic	df	p	Mean Difference	SE Difference	95% CI for Mean Difference		Cohen's d
Test							Lower	Upper	
grade	Student	2.115	31.000	0.043	5.478	2.589	0.197	10.759	0.740
	Welch	2.034	23.025	0.054	5.478	2.693	-0.092	11.048	0.724

Figure1.12 JASP で既定の Student の t 検定とあわせて Welch の検定を表示した結果

この出力の解釈はかなり明白でしょう。Welch の検定の出力は、Student の検定と同じように読めばよいのです。記述統計、検定の結果、そのほかの情報が出ています。ですからここは簡単です。

ただし、ただし……結果はもう有意ではありません。Student の検定を実行したときには有意な効果が得られましたが、同じデータに対する Welch の検定では有意ではないのです ($t(23.02) = 2.03$, $p = .054$)。これはどういうことでしょうか。慌てるべきでしょうか。空が燃えているのでしょうか。おそらくそんなことはありません。一方の検定が有意で他方が有意でないという事実そのものは、たいした意味を持ちません。とくに、そうなるように私がデータを仕込んだのですから。一般的なルールとして、 p 値.049 と p 値.051 の差をわざわざ解釈したり説明したりしようとするのはよい考えではありません。現実にはこの種のことが起きたなら、 p 値のこの差はほぼ確実に偶然によるものです。重要なのは、どの検定を使うかを少し注意して考えることです。Student の検定と Welch の検定には、それぞれ長所と短所があります。2つの母集団が本当に等しい分散を持つなら、Student の検定のほうが Welch の検定よりわずかに検定力が高くなります (タイプ II エラー率が低くなります)。しかし分散が同じでないなら、Student の検定の仮定は破られますので信頼できないかもしれません。

し、タイプⅠエラー率が高くなってしまうかもしれません。つまりトレードオフです。とはいえ現実には私は Welch の検定を好みます。母分散が等しいと本気で信じている人はほとんどいないからです。

1.5.2 検定の仮定

Welch の検定の仮定は Student の t 検定のもの (セクション ??参照) とよく似ていますが、Welch の検定は分散の等質性を仮定しません。ですから残るのは正規性の仮定と独立性の仮定だけです。これらの仮定の中身は、Welch の検定でも Student の検定と同じです。

1.6

対応のある標本の t 検定

Student の検定であれ Welch の検定であれ、独立標本 t 検定は、2 つの標本が互いに、まあ、独立である場面で使うことを想定しています。参加者が 2 つの実験条件のどちらかに無作為に割り当てられる場合には自然にこうなりますが、他の種類の研究デザインにはあまり当てはまりません。とくに、各参加者が (同じ結果変数について) 両方の実験条件で測定される反復測定デザインは、独立標本 t 検定による分析には向いていません。たとえば、音楽を聴くとワーキングメモリの容量が下がるかどうかに関心があるとしみましょう。そのために、音楽ありと音楽なしという 2 つの条件で、各人のワーキングメモリ容量を測ることになります。このような実験デザインでは、各参加者が両方の群に登場します。ですから**対応のある標本の t 検定**を使って、別のやり方で問題に取り組む必要があります。

1.6.1 データ

今回使うデータは Chico 博士のクラスのもので^{*9}。彼女のクラスでは学生が大きな試験を 2 回、学期の前半と後半に受けます。彼女の言い分では、これはとても厳しい授業で、ほとんどの学生がかなり手強いと感じるそうです。しかし彼女は、難しい評価を課すことで学生はより努力するようになるのだと主張します。彼女の理屈では、1 回目の試験は学生にとって一種の“目覚まし”なのです。授業が本当はどれだけ厳しいかに気づけば、2 回目の試験に向けてより努力し、よい点をとるだろう、というわけです。彼女は正しいのでしょうか。これを確かめるために、chico.csv ファイルを JASP に読み込みましょう。chico のデータには 3 つの変数があります。クラスの各学生を識別する id 変

^{*9} ここまでに Harpo 博士、Chico 博士、Zeppo 博士が登場しました。Groucho 博士が誰なのかを当てても賞品は出ません。

数, 1 回目の試験の成績を記録した `grade_test1` 変数, 2 回目の試験の成績が入った `grade_test2` 変数です。

JASP のスプレッドシートを見ると, 確かに厳しい授業のようですが (成績のほとんどが 50% から 60% のあいだです), 1 回目の試験から 2 回目の試験にかけて改善が見られるようです。




Figure1.13 chico データの 2 つの `grade_test` 変数の記述統計

図 ?? の記述統計をざっと見ると, この印象は裏づけられているようです。20 人全員で見ると 1 回目の試験の平均成績は 57% ですが, 2 回目には 58% に上がっています。とはいえ標準偏差がそれぞれ 6.6% と 6.4% であることを考えると, この改善は錯覚かもしれない, 単なるランダムな変動かもしれない, と思えてきます。図 ??a の平均と信頼区間のプロットを見ると, この印象はさらに強まります。このプロットだけに頼って, 信頼区間の広さを見れば, 学生の成績が改善したように見えるのは純粋な偶然だと考えたくありません。

しかし, この印象は誤りです。なぜかを見るために, 図 ??b の, 試験 1 の成績に対する試験 2 の成績の散布図を見てください。このプロットでは, それぞれの点がある学生の 2 つの成績に対応しています。試験 1 の成績 (x 座標) と試験 2 の成績 (y 座標) が等しければ, 点は直線の上に乗ります。直線より上にある点は, 2 回目の試験のほうが成績のよかった学生です。重要なのは, ほとんどすべての点が対角線より上にあることです。わずかなではあれ, ほとんどすべての学生が成績を伸ばして




Figure1.14 試験 1 と試験 2 の平均成績と、対応する 95% 信頼区間 (パネル a)。試験 1 と試験 2 の個々の成績を示す散布図 (パネル b)。Chico 博士のクラスの各学生の伸びを示すヒストグラム (パネル c)。パネル c では分布のほとんど全体がゼロより上にあることに注意。大多数の学生が 1 回目の試験から 2 回目の試験にかけて成績を伸ばしている

いるようだということです。これは、各学生が一方の試験から次の試験にかけてどれだけ伸びたかを見て、それを生のデータとして扱うべきだということを示唆しています。そのためには各学生の `improvement`(伸び) についての新しい変数を作り、`chico` のデータに加える必要があります。いちばん簡単なのは、新しい変数を計算することです。JASP では、データ列のいちばん右にある “+” をクリックし、変数名を `improvement` として “R” のボタンを選びます。‘Create column’ のボタンをクリックしたら、R のコード `grade_test2 - grade_test1` を入力できます (図 ??参照)。

この新しい `improvement` 変数を計算したら、図 ??c のように、伸びの得点の分布を示すヒストグラムを描けます。ヒストグラムを見れば、ここに本当の改善があることははっきりしています。大多数の学生が試験 1 より試験 2 で高い点をとっており、それがヒストグラムのほぼ全体がゼロより上にあることに表れています。

1.6.2 対応のある標本の t 検定とは

ここまでの探索を踏まえて、適切な t 検定をどう組み立てるかを考えましょう。ひとつの可能性は、`grade_test1` と `grade_test2` を関心のある変数として独立標本 t 検定を実行することです。しかし独立標本 t 検定は 2 つの標本のあいだに特別な関係がないことを仮定していますので、これは明らかに誤りです。データが反復測定 of 構造を持っている以上、今回それが成り立たないのは明らかです。前節で導入した言い方をすれば、独立標本 t 検定をやろうとすると、検定したい被験者内の差と、関心のない被験者間の変動をごちゃまぜにしてしまうことになります。




Figure1.15 JASP で R のコードを使って **improvement** の得点を計算する。

前節ですでに面倒な作業は済ませていますので、解決策は明らかだと思います。**grade_test1** と **grade_test2** に対して独立標本 t 検定を実行するかわりに、被験者内の差の変数である **improvement** に対して 1 標本 t 検定を実行するのです。少し形式的に書くと、 i 番目の参加者が 1 つめの変数で得た得点を X_{i1} 、同じ人が 2 つめの変数で得た得点を X_{i2} とすれば、差の得点は次のようになります。

$$D_i = X_{i1} - X_{i2}$$

差の得点に変数 1 引く変数 2 であって逆ではないことに注意してください。ですから伸びを正の差に対応させたいなら、“試験 2”を“変数 1”にする必要があります。同じように、この差の変数の母平均を $\mu_D = \mu_1 - \mu_2$ と書きます。これを仮説検定に直すと、帰無仮説はこの平均差がゼロであるというもの、対立仮説はそうでないというものになります。

$$\begin{aligned} H_0 : \mu_D &= 0 \\ H_1 : \mu_D &\neq 0 \end{aligned}$$

ここでは両側検定を想定しています。これは 1 標本 t 検定で仮説を書いたやり方とほぼ同じです。唯一の違いは、帰無仮説が予測する具体的な値が 0 であることです。ですから t 統計量もほぼ同じように定義されます。差の得点の平均を $\bar{D}$ とすれば、

$$t = \frac{\bar{D}}{SE(\bar{D})}$$

- 28 -

つまり,

$$t = \frac{\bar{D}}{\hat{\sigma}_D / \sqrt{N}}$$

となります。ここで $\hat{\sigma}_D$ は差の得点の標準偏差です。これはごく普通の 1 標本 t 検定にすぎず、特別なところは何もありませんので、自由度は依然として $N - 1$ です。これで終わりです。対応のある標本の t 検定は、実のところ新しい検定でも何でもありません。2 つの変数の差に適用した 1 標本 t 検定なのです。実にとても単純です。これだけ長く論じる価値があるのは、対応のある標本の検定が適切なのはどんなときかを見分けられるようになり、独立標本 t 検定よりなぜよいのかを理解する必要があるからにすぎません。

1.6.3 JASP で検定を実行する

JASP で対応のある標本の t 検定はどうやるのでしょうか。ひとつは、いま述べた手順にしたがうことです。つまり“差”の変数を作り、それに 1 標本 t 検定を実行するのです。すでに `improvement` という変数を作っていますので、やってみて結果を見てみましょう。図 ?? です。

One Sample T-Test

One Sample T-Test							
	t	df	p	Mean Difference	95% CI for Mean Difference		Cohen's d
					Lower	Upper	
improvement	6.475	19	< .001	1.405	0.951	1.859	1.448

Note. Student's t-test.
 Note. For the Student t-test, location parameter is given by mean difference d .
 Note. For the Student t-test, effect size is given by Cohen's d .

Figure1.16 対応のある差の得点に対する 1 標本 t 検定の結果

図 ?? の出力は (当然ながら) 前回 'One Sample T-Test' の分析を使ったとき (セクション ??) とまったく同じ形式で、私たちの直感を裏づけています。試験 1 から試験 2 にかけて平均 1.4 点の伸びがあり、これは 0 と有意に異なっています ($t(19) = 6.48, p < .001$)。

とはいえ、面倒くさくて新しい変数を作る手間をかけたくない場合もあるでしょう。あるいは、1 標本の検定と対応のある標本の検定の違いを頭のなかではっきりさせておきたいのかもしれない。その場合は JASP の 'Paired Samples T-Test' の分析を使えます。見てのとおり、数値は 1 標本の検定から出てくるものと同じです。対応のある標本の t 検定は中身が 1 標本の検定にすぎないので、当然そうなるはずで

片側検定

帰無仮説検定の理論を紹介したとき、片側検定を指定するのが適切な場面があると述べました (セクション ??参照)。ここまでの t 検定はすべて両側検定でした。たとえば Zeppo 博士のクラスの成績について 1 標本 t 検定を指定したとき、帰無仮説は真の平均が 67.5% であるというものでした。対立仮説は、真の平均が 67.5% より大きい小さいというものでした。真の平均が 67.5% より大きいかどうかに関心があり、67.5% より低いかどうかを検定することにはまったく関心がない、としましょう。その場合、帰無仮説は真の平均が 67.5% 以下であるというもので、対立仮説は真の平均が 67.5% より大きいというものになります。JASP の 'One Sample T-Test' の分析では、'Alt. Hypothesis' の下にある '> Test Value' のオプションをクリックすることでこれを指定できます。そうすると図 ??のような結果が得られます。

One Sample T-Test ▼

One Sample T-Test							
	t	df	p	Mean Difference	95% CI for Mean Difference		Cohen's d
					Lower	Upper	
x	2.255	19	0.018	4.800	1.119	∞	0.504

Note. Student's t-test.
 Note. For the Student t-test, location parameter is given by mean difference d .
 Note. For the Student t-test, effect size is given by Cohen's d .
 Note. For all tests, the alternative hypothesis specifies that the mean is greater than 67.5.

Figure1.17 仮説が片側、つまり真の平均が 67.5% より大きいというものである場合の、JASP の 'One Sample T-Test' の結果

前回見た出力からいくつか変わっていることに注意してください。もっとも重要なのは、検定が変わったことを反映して仮説そのものが変わっていることです。2 つめは、 t 統計量と自由度は変わっていないのに、 p 値が変わっていることです。これは片側検定の棄却域が両側検定と異なるからです。なぜそうなるのか、それが何を意味するのかを忘れてしまったなら、Chapter ??、とくにセクション ??を読み返すとよいでしょう。3 つめは、信頼区間も変わっていることです。両側ではなく“片側”の信頼区間が報告されています。両側の信頼区間では、研究を何度も繰り返したときに 95% の場合に平均が a と b のあいだに入る、と確信できるような数 a と b を求めています。片側の信頼区間では、95% の場合に真の平均が a より大きいと確信できるような単一の数 a を求めます ('Alt.

Hypothesis' の欄で '< Test Value' を選んだ場合は μ より小さい、となります)。

これが片側の 1 標本 t 検定のやり方です。ただし、どの t 検定も片側にできます。独立標本 t 検定では、群 A が群 B より高い得点かどうかを検定することにだけ関心があり、群 B が群 A より高いかどうかには関心がない場合に、片側検定にできます。Harpo 博士のクラスについて、Anastasia の学生のほうが Bernadette の学生より成績が高いかどうかを見たいとしましょう。この分析では、'Alt. Hypothesis' のオプションで 'Group 1 > Group2' を指定します。図 ?? のような結果が得られるはずです。

Independent Samples T-Test

Independent Samples T-Test								
	t	df	p	Mean Difference	SE Difference	95% CI for Mean Difference		Cohen's d
						Lower	Upper	
grade	2.115	31.000	0.021	5.478	2.589	1.087	∞	0.740

Note. Student's t-test.
Note. For all tests, the alternative hypothesis specifies that group Anastasia is greater than group Bernadette.

Figure1.18 仮説が片側、つまり Anastasia の学生のほうが Bernadette の学生より成績が高いというものである場合の、JASP の 'Independent Samples T-Test' の結果

ここでも出力は予想どおりに変わります。対立仮説の定義が変わり、 p 値が変わり、両側ではなく片側の信頼区間が報告されています。

対応のある標本の t 検定はどうでしょうか。Chico 博士のクラスで試験 1 から試験 2 にかけて成績が上がるという仮説を検定したく、成績が下がるという考えは検討するつもりがない、としましょう。JASP では 'Alt. Hypotheses' のオプションで、`grade_test2`(対応のある変数のボックスに先にコピーしたので JASP では 'Measure 1' です) > `grade_test1`(JASP では 'Measure 2') と指定します。図 ?? のような結果が得られるはずです。

ここでもまた、出力は予想どおりに変わります。仮説が変わり、 p 値が変わり、信頼区間は片側になっています。

1.8

効果量

t 検定の効果量としてもっともよく使われる指標が **Cohen の d** です (Cohen1988)。原理としてはとても単純な指標ですが、細部を掘り下げ始めるとかなり厄介な点が出てきます。Cohen 自身は

Paired Samples T-Test

Paired Samples T-Test									
		t	df	p	Mean Difference	SE Difference	95% CI for Mean Difference		Cohen's d
							Lower	Upper	
grade_test2	- grade_test1	6.475	19	< .001	1.405	0.217	1.030	∞	1.448

Note. Student's t-test.
Note. All tests, hypothesis is measurement one greater than measurement two.

Figure1.19 仮説が片側、つまり `grade_test2('Measure 1') > grade_test1('Measure 2')` である場合の、JASP の 'Paired Samples T-Test' の結果

主に独立標本 t 検定、とくに Student の検定の文脈でこれを定義しました。その文脈では、効果量を定義する自然なやり方は平均の差を標準偏差の推定値で割ることです。つまり、次のような何かを計算しようとしているわけです。

$$d = \frac{(\text{平均 1}) - (\text{平均 2})}{\text{標準偏差}}$$

そして彼は、表 ?? のような d の解釈の大まかな目安を提案しました。これで曖昧さはなくなりそうに思えますが、そうではありません。それは主に、標準偏差の指標として何を使うべきかについて Cohen があまり具体的に述べなかったからです (彼の名誉のために言えば、本の中でもっと大きな話をしようとしていたのであって、細部をつつくつもりはなかったのです)。McGrath2006 が論じているように、一般に使われている版がいくつもあり、著者ごとに少しずつ異なる記法をとる傾向があります。正確さより単純さを優先して、本書では標本から計算するどの統計量も d と呼び、理論的な母集団の効果量を δ と呼ぶことにします。当然ながら、これは d と呼ばれるものがいくつもあるということを意味します。

Cohen の d が欲しくなるのは t 検定を実行するときだけだろうと私は睨んでいますが、JASP には提供しているすべての種類の t 検定について効果量を計算するオプションがあります。

1.8.1 1 標本からの Cohen の d

いちばん単純なのは、1 標本 t 検定に対応する場面です。この場合、標本平均 $\bar{X}$ がひとつと、それと比べる (仮定された) 母平均 μ_0 がひとつあります。それだけでなく、母標準偏差を推定するまともなやり方もひとつしかありません。いつもの推定値 $\hat{\sigma}$ を使うだけです。ですから d の計算は次の一通りだけになります。

$$d = \frac{\bar{X} - \mu_0}{\hat{\sigma}}$$

図 ?? の結果を見返すと、効果量の値は Cohen の $d = 0.504$ です。つまり全体として、Zeppo 博士

Table1.1 Cohen の d の解釈の (とても) 大まかな目安。個人的にはこれを鵜呑みにしないことをお勧めする。 d 統計量はそれ自体で自然な解釈を持っている。平均の差を、その平均どうしを隔てる標準偏差の個数として言い換えたものである。ですからそれが実務的に何を意味するのかを考えるほうがたいいよい。文脈によっては“小さい”効果が実務上きわめて重要なこともある。逆に“大きい”効果がさほど興味深くない場面もある。

d の値	大まかな解釈
0.2 くらい	“小さい” 効果
0.5 くらい	“中程度の” 効果
0.8 くらい	“大きい” 効果

のクラスの心理学の学生は、他の学生と同じ水準であれば期待される値 (67.5%) より、標準偏差にして約 0.5 だけ高い成績 (平均 = 72.3%) をとっているということです。Cohen の大まかな目安に照らせば、これは中程度の効果量です。

1.8.2 Student の t 検定からの Cohen の d

Cohen の d についての議論の大部分は、Student の独立標本 t 検定にあたる場面に焦点を当てています。そしてこの文脈で話がややこしくなります。この場面で使いたくなる d の版がいくつもあるからです。 d に複数の版がある理由を理解するには、真の母集団の効果量 δ に対応する式を書き下してみると役に立ちます。ごく素直です。

$$\delta = \frac{\mu_1 - \mu_2}{\sigma}$$

ここでいつものように μ_1 と μ_2 はそれぞれ群 1 と群 2 に対応する母平均で、 σ は標準偏差 (両方の母集団で同じ) です。 δ を推定するわかりやすいやり方は、 t 検定そのものでやったのとまったく同じこと、つまり分子に標本平均を、分母にプールされた標準偏差の推定値を使うことです。

$$d = \frac{\bar{X}_1 - \bar{X}_2}{\hat{\sigma}_p}$$

ここで $\hat{\sigma}_p$ は、 t 検定に出てくるのとまったく同じプールされた標準偏差の指標です。これは Student の t 検定の結果に適用する場合にもっともよく使われる Cohen の d の版であり、JASP が提供しているものです。Hedges の g 統計量と呼ばれることもあります (Hedges1981)。

とはいえ他の可能性もありますので、簡単に述べておきます。まず、標準偏差の計算の基礎として 2 群のうち一方だけを使いたい理由がある場合もあるでしょう。このやり方 (しばしば Glass の Δ , デルタと読みます, と呼ばれます) がいちばん意味を持つのは、2 群のうち一方をもう一方より純粋に“自然な変動”を反映したものとして扱うもっともな理由がある場合だけです。たとえば 2 群のうち一方が統制群である場合などです。次に、プールされた標準偏差の通常の計算では、標本分散の偏

りを補正するために $N - 2$ で割ったことを思い出してください。Cohen の d のある版ではこの補正を省き、かわりに N で割ります。この版が意味を持つのは主に、母集団の効果を推定するのではなく標本における効果を計算しようとしている場合です。最後に、**Hedges1985** にもとづく版があります。彼らは Cohen の d の通常の (プールされた) 推定に小さな偏りがあることを指摘しました。そこで通常の d の値に $(N - 3)/(N - 2.25)$ を掛ける小さな補正を導入しています。

いずれにせよ、使おうと思えば使えるこうした変種はさておき、JASP の既定の版を見てみましょう。図 ?? では Cohen の $d = 0.740$ であり、Anastasia のクラスの学生の成績が Bernadette のクラスの学生の成績より平均して標準偏差 0.74 だけ高いことを示しています。Welch の検定でも、推定される効果量は同じです (図 ??)。

1.8.3 対応のある標本の検定からの Cohen の d

最後に、対応のある標本の t 検定ではどうすべきでしょうか。この場合、答えは何をしようとしているかによります。JASP は差の得点の分布を基準に効果を測りたいものと想定しており、計算される d は次のようになります。

$$d = \frac{\bar{D}}{\hat{\sigma}_D}$$

ここで $\hat{\sigma}_D$ は差の標準偏差の推定値です。図 ?? では Cohen の $d = 1.45$ であり、2 回目の成績が 1 回目の成績より平均して標準偏差 1.45 だけ高いことを示しています。

これが JASP の 'Paired Samples T-Test' の分析で報告される Cohen の d の版です。唯一やっかいなのは、これが自分の欲しい指標かどうかを見極めることです。研究の実務的な帰結を気にかけるのであれば、差の得点ではなくもとの変数を基準に効果を測りたいことが多いでしょう (たとえば Chico 博士のクラスでの 1 点の伸びは、学生間の成績のばらつきに照らせばかなり小さいものです)。その場合は Student や Welch の検定で使うのと同じ版の Cohen の d を使います。JASP でこれをするのはそう簡単ではなく、本質的にはスプレッドシート画面でデータの構造を変える必要がありますので、ここでは立ち入りません。

1.9

標本の正規性を確認する

この章でここまで扱ってきた検定はすべて、データが正規分布にしたがうことを仮定していました。中心極限定理 (セクション ??) のおかげで、現実世界の多くの量は正規分布に近くなる傾向がありますので、この仮定はたいがい十分に妥当です。自分の変数が実はいろいろなものの平均なのではないかと思うときには、それが正規分布にしたがうか、少なくとも t 検定を使ってもよい程度には正規に近い可能性がかなり高いでしょう。とはいえ人生に保証はありませんし、そもそも変数がひどく正規から外れてしまう道筋はいくらでもあります。たとえば、自分の変数が実はいろいろなも

の最小値なのではないかと思うときには、かなり歪んだ分布になる可能性が非常に高くなります。心理学では反応時間 (RT) のデータがそのよい例です。人間の参加者から反応を引き起こしうるものがたくさんあるとすると、実際の反応はそうした引き金となる出来事のどれかが最初に起きたときに生じます^{*10}。ですから RT のデータは系統的に正規から外れることになります。さて、すべての検定が正規性を仮定していて、現実のデータは (少なくとも近似的には) たいてい満たすけれども常にではない、というのなら、標本の正規性はどう確認すればよいのでしょうか。この節では QQ プロットと Shapiro-Wilk 検定の 2 つの方法を扱います。

1.9.1 QQ プロット






Figure1.20 100 個の観測からなる正規分布する標本 `normal.data` のヒストグラム (パネル a) と正規 QQ プロット (パネル b)。このデータの Shapiro-Wilk 統計量は $W = .99$ で、正規性からの有意な逸脱は検出されなかった ($p = .73$)。

標本が正規性の仮定を破っていないかを確認するひとつの方法は、“QQ プロット”(分位点-分位点プロット)を描くことです。これによって、系統的な違反が見られないかを視覚的に確認できます。QQ プロットでは、それぞれの観測が 1 つの点として描かれます。x 座標は、データが正規分布にしたがう (平均と分散は標本から推定) としたときにその観測が入るはずの理論的な分位点で、y 座標は標本の中でのそのデータの実際分位点です。データが正規なら、点は直線を描くはずで、たとえば正規分布から標本を取ってデータを生成し、QQ プロットを描くとどうなるかを見てみましょ


^{*10} これはほとんどない単純化です。




(a)



(b)



(c)



(d)

Figure1.21 上段は、`skewed.data` に含まれる 100 個の観測のヒストグラム (パネル a) と正規 QQ プロット (パネル b)。このデータの歪度は 1.94 で、それが QQ プロットの上向きの曲がりに表れている。その結果 Shapiro-Wilk 統計量は $W = .80$ となり、正規性からの有意な逸脱を示している ($p < .001$)。下段は、同じく 100 個の観測からなる裾の重いデータについての同じプロット。この場合はデータの重い裾によって尖度が高くなり (2.80)、QQ プロットは中央で平らになり、両端で急に曲がる。結果として Shapiro-Wilk 統計量は $W = .93$ となり、やはり有意な非正規性を示している ($p < .001$)。

う。結果は図 ?? に示しました。見てのとおり、このデータはかなりまっすぐな直線を描いています。正規分布から取ったのですから驚くことではありません。これに対して、図 ?? の 2 つのデータを見てください。上のパネルは大きく歪んだデータのヒストグラムと QQ プロットで、QQ プロットが上向きに曲がっています。下のパネルは裾の重い (つまり尖度の高い) データについての同じプロットで、この場合 QQ プロットは中央で平らになり両端で急に曲がります。

1.9.2 Shapiro-Wilk 検定

QQ プロットはデータの正規性を略式に確認するよい方法ですが、もう少し形式的なことをやりたくなることもあるでしょう。そのときに探しているのはおそらく **Shapiro-Wilk 検定** です (Shapiro1965)*11。予想どおり、検定される帰無仮説は「 N 個の観測が正規分布にしたがう」というものです。

計算される検定統計量は慣例的に W と書かれ、次のように計算されます。まず観測を小さい順に並べ替え、標本のなかで最小の値を X_1 、2 番目に小さい値を X_2 、という具合に置きます。すると W の値は次のように与えられます。

$$W = \frac{\left(\sum_{i=1}^N a_i X_i\right)^2}{\sum_{i=1}^N (X_i - \bar{X})^2}$$

ここで $\bar{X}$ は観測の平均で、 a_i の値は……ごによごによ……入門書の範囲を少し超える、何やら複雑なものです。

W 統計量の背後にある数学を説明するのは少し難しいので、そのふるまいを大づかみに述べるほうがよいでしょう。本書で出会う検定統計量の多くとは違って、正規性からの逸脱を示すのは W の小さい値のほうです。 W 統計量の最大値は 1 で、データが“完全に正規”に見えるときにそうなります。 W の値が小さいほど、データは正規から遠いということです。ただし W の標本分布は、Chapter ?? で論じた標準的なもののどれでもありませんし、実際扱うのがまったく面倒なしろものですが、標本サイズ N に依存します。この標本分布がどんな形か感覚をつかんでもらうために、図 ?? に 3 つ描きました。標本サイズが大きくなるにつれて標本分布が $W = 1$ の近くにぎゅっと集まること、その結果として標本が大きい場合には W が 1 よりそれほど小さくなくても検定が有意になることに注意してください。

JASP の t 検定で Shapiro-Wilk 統計量を得るには、‘Assumption checks’の下にある ‘Normality’

*11 あるいは Kolmogorov-Smirnov 検定でしょう。こちらのほうが Shapiro-Wilk よりおそらく伝統的です。私が読んだものの多くは Shapiro-Wilk のほうが正規性の検定として優れていると示唆しているようですが、Kolmogorov-Smirnov は分布の同等性についての汎用の検定で、他の種類の分布の検定にも応用できます。JASP では Shapiro-Wilk 検定が採用されています。





Figure1.22 データが正規分布にしたがうという帰無仮説のもとでの、標本サイズ 10・20・50 の Shapiro-Wilk の W 統計量の標本分布。正規性からの逸脱を示すのは W の小さい値であることに注意。

のオプションにチェックを入れます。QQ プロットに使った無作為抽出のデータ ($N = 100$) では、Shapiro-Wilk の正規性検定の統計量は $W = 0.99$, p 値は 0.69 でした。ですから当然ながら、このデータが正規性から逸脱しているという証拠はありません。Shapiro-Wilk 検定の結果を報告するときは、(いつものように) 検定統計量 W と p 値を必ず入れるべきですが、標本分布が N に大きく依存することを考えると、 N も入れておくのが親切でしょう。

1.9.3 例

ここで、データが正規でなかった場合に QQ プロットと Shapiro-Wilk 検定がどうなるかの例を示しておく価値があるでしょう。そのために、AFL の勝ち点差のデータの分布を見てみましょう。Chapter ??を思い出せば、これはまったく正規分布から来たようには見えませんでした。QQ プロットは次のようになります。



そして AFL の勝ち点差のデータに Shapiro-Wilk 検定を実行すると、Shapiro-Wilk の正規性検定の統計量は $W = 0.94$, p 値 $= 9.481\text{e-}07$ となります。これは明らかに正規性からの有意な逸脱です。

1.10

正規でないデータを Wilcoxon 検定で検定する

さて、データがかなりはっきり正規から外れているのに、それでも t 検定のようなものを実行したい場合はどうすればよいでしょうか。この状況は現実によく起こります。たとえば AFL の勝ち点差のデータでは、Shapiro-Wilk 検定によって正規性の仮定が破られていることがはっきりしました。こうした場面で Wilcoxon 検定を使いたくなるわけです。

t 検定と同じく、Wilcoxon 検定にも 1 標本と 2 標本の 2 つの形があり、対応する t 検定とほぼまったく同じ場面で使われます。 t 検定と違って Wilcoxon 検定は正規性を仮定しません。これはありがたいことです。実際、どんな種類の分布であるかについて何の仮定も置きません。統計の専門用語では、これを **ノンパラメトリック検定** と呼びます。正規性の仮定を避けられるのはよいことです。が、欠点もあります。Wilcoxon 検定はふつう t 検定より検定力が低い (つまりタイプ II エラー率が高い) のです。Wilcoxon 検定を t 検定ほど詳しくは扱いませんが、概略を述べておきます。

1.10.1 2 標本の Mann-Whitney の U 検定

まず **Mann-Whitney の U 検定** から説明します。実は 1 標本版より単純だからです。10 人のある検査の得点を見ているとしましょう。もう想像力が完全に尽きましたので、これは “すごさの検査” だということにして、“A” と “B” の 2 つの群があるとしします。どちらの群がよりすごいのかを知りたいわけです。データは `awesome.csv` ファイルに入っていて、いつもの `ID` 変数のほかに `scores` と `group` の 2 つの変数があります。

同順位 (つまりすごさの得点がまったく同じ人) がない限り、やりたい検定は驚くほど単純です。群 A のすべての観測を群 B のすべての観測と比較する表を作るだけです。群 A のデータのほうが大きいときには、表にチェックマークを入れます。

		群 B				
		14.5	10.4	12.4	11.7	13.0
群 A	6.4	.	.	.	.	.
	10.7	.	✓	.	.	.
	11.9	.	✓	.	✓	.
	7.3	.	.	.	.	.
	10.0	.	.	.	.	.

そしてチェックマークの数を数えます。これが検定統計量 W です^{*12}。 W の実際の標本分布はやや複雑ですので、詳細は省きます。ここでの目的には、 W の解釈が t や z の解釈と質的に同じだと知っておけば十分です。つまり両側検定なら W が非常に大きいか非常に小さいときに帰無仮説を棄却し、方向性のある (つまり片側の) 仮説ならどちらか一方だけを使います。

JASP で ‘Independent Samples T-Test’ を、`scores` を従属変数、`group` を群分け変数として実行し、‘tests’ のオプションで ‘Mann-Whitney’ にチェックを入れると、 $U = 3$ (つまり上に示したチェックマークの数と同じ)、 p 値 = 0.05556 という結果が得られます。

1.10.2 1 標本の Wilcoxon 検定

1 標本の Wilcoxon 検定 (あるいは同じことですが、対応のある標本の Wilcoxon 検定) はどうでしょうか。統計の授業を受けることが学生の幸福感に影響するかどうかを知りたいとしましょう。データは `happiness.csv` ファイルに入っています。ここで測ったのは、授業を受ける `before` (前) と `after` (後) の各学生の幸福感で、`change` の得点はその 2 つの差です。 t 検定で見たのと同じく、`before` と `after` を使って対応のある標本の検定をすることと、`change` の得点を使って 1 標本の検定

^{*12}実は検定統計量には、定数分だけ異なる 2 つの版があります。ここで説明したのは JASP が計算するほうです。

をすることのあいだに、本質的な違いはありません。先ほどと同じく、この検定をいちばん単純に考えるには表を作ることです。今回のやり方は、正の差である変化の得点を取り、それを標本全体と突き合わせて表にすることです。できあがるのは次のような表です。

		すべての差									
		-24	-14	-10	7	-6	-38	2	-35	-30	5
正の差	7	.	.	.	✓	✓	.	✓	.	.	✓
	2	.	.	.	.	.	.	✓	.	.	.
	5	.	.	.	.	.	.	✓	.	.	✓

今回チェックマークを数えると、検定統計量は $W = 7$ になります。先ほどと同じく、両側検定なら W が非常に大きいのか非常に小さいときに帰無仮説を棄却します。JASP での実行は、だいたい予想どおりです。1 標本版では、'One Sample T-Test' の分析ウィンドウの 'Tests' の下にある 'Wilcoxon signed-rank' のオプションを指定します。すると Wilcoxon の $W = 7$, p 値 = 0.037 が得られます。これが示すように、有意な効果があります。どうやら統計の授業を受けることは幸福感に影響するようです。対応のある標本の版に切り替えても、もちろん違う答えにはなりません。図 ?? を見てください。




Figure1.23 1 標本および対応のある標本の Wilcoxon ノンパラメトリック検定の結果を示す JASP の画面