

1. 因子分析

ここまでの章では、2つ以上のグループ間の差についての統計的検定を扱ってきました。しかし研究をしていると、複数の変数がどのように共変するかを調べたくなることがあります。つまり、変数どうしがどう関連しているのか、そしてその関連のパターンが何か興味深く意味のあることを示唆していないか、ということです。たとえば、データセットの中で観測された、直接測定された変数の背後に、観測されていない**潜在因子**があるかどうかを探りたい、ということはよくあります。統計学という潜在因子とは、もともと隠れている変数のことで、直接観測されるのではなく、観測された (直接測定された) 他の変数から (統計的分析を通じて) 推測されるものです。

この章では、因子分析とその関連手法をいくつか取り上げます。まずは探索的因子分析 (EFA) から始めましょう。EFA は、データセットの背後にある潜在因子を特定するための統計的手法です (セクション ??)。次にセクション ??では主成分分析 (PCA) を扱います。これはデータを縮約するための手法で、厳密に言えば背後にある潜在因子を特定するものではありません。PCA は単に、観測変数の線形結合を作り出すだけのものです。続く確認的因子分析 (CFA) のセクション (??) では、EFA とは違って、CFA ではデータの中の変数がどう関連しているかについての考え、つまりモデルから出発することを示します。そのうえで、そのモデルを観測データに対して検証し、モデルの当てはまりがどのくらいよいかを評価します。CFA をさらに洗練させたものが、いわゆる多特性多方法 (MTMM) アプローチです (セクション ??)。ここでは潜在因子と方法による分散の両方をモデルに含めます。これは、測定に異なる方法論的アプローチが使われていて、方法による分散が重要な検討事項になる場合に役立ちます。最後に、関連する分析として内的整合性による信頼性分析を取り上げます。これは、ある尺度が心理学的な構成概念をどれだけ一貫して測定しているかを検討するものです (セクション ??)。

1.1

探索的因子分析

探索的因子分析 (EFA) は、観測データから推測できる隠れた潜在因子を明らかにするための統計的手法です。この手法は、測定された変数の集まり、たとえば V_1, V_2, V_3, V_4, V_5 が、背後にある潜在因子の測定値としてどの程度表現できるかを計算します。この潜在因子は、たったひとつの観測変数で測ることはできず、観測変数の集まりのあいだに生じる関係として現れてきます。

図 ??では、それぞれの観測変数 V が、背後にある潜在因子 (F) によってある程度 “引き起こされて” おり、それが b_1 から b_5 の係数 (因子負荷量とも呼ばれます) で描かれています。それぞれの観測変数には、 e_1 から e_5 までの誤差項も付いています。それぞれの誤差項は、対応する観測変数 V_i の分散のうち、背後にある潜在因子では説明されない部分を表しています。




Figure1.1 複数の観測変数の関係の背後にある潜在因子

心理学では、潜在因子は直接観測したり測定したりするのが難しい心理現象や構成概念を表します。たとえばパーソナリティ、知能、思考スタイルなどです。図 ??の例では、行動や態度についての具体的な5つの質問をしたことになりますが、そこからたとえば外向性と呼ばれるパーソナリティ構成概念の姿をつかむことができます。別の具体的な質問群からは、その人の内向性や誠実性の姿がつかめるかもしれません。

もうひとつ例を挙げましょう。統計不安を直接測ることはできないかもしれませんが、質問紙のいくつかの質問によって、統計不安が高いか低いかを測ることはできます。たとえば “Q1: 統計の授業

の課題をやる”，“Q2: 学術論文に書かれている統計を理解しようとする”，“Q3: 授業でわからないことを先生に質問する”といった項目に対して、それぞれ不安が低いから高いまでで評定してもらうわけです。統計不安の高い人は、その不安の高さゆえに、これらの観測変数に対して同じように高い反応をする傾向があります。同じように、統計不安の低い人は、その不安の低さゆえに、これらの変数に対して同じように低い反応をすることになります。

探索的因子分析 (EFA) がやっているのは、本質的には、観測変数間の相関を探索することで、観測変数が共変するときに特定される、興味深く重要な背後の (潜在) 因子を見つけ出すことです。統計ソフトを使えば潜在因子を推定し、どの変数がどの因子に高い負荷量^{*1}を持つか (たとえば負荷量が > 0.5) を特定できます。負荷量が高い変数は、その潜在因子の有用な測定値、つまり指標であることを示唆します。この過程には回転と呼ばれる手続きが含まれています。正直に言うとかかなり奇妙な考え方なのですが、幸いなことに私たちがそれを理解しようと悩む必要はありません。因子ごとの負荷量のパターンをずっとはっきりさせてくれるので役に立つ、ということだけ知っておけば十分です。つまり回転は、どの変数がどの因子と実質的に結びついているかをよりはっきり見えるようにしてくれます。また、手元のデータからしていくつの因子が妥当なのかも決めなければなりません。ここで役に立つのが固有値と呼ばれるものです。

1.1.1 EFA は何の役に立つのか

EFA がよい解 (つまり因子モデル) を与えてくれたなら、次は手に入れたぴかぴかの新しい因子をどうするかを決めなければなりません。研究者は心理尺度を開発するときに EFA をよく使います。1 つ以上の心理学的構成概念に関係すると思われる質問項目のプールを作り、EFA を使ってどの項目が潜在因子として“まとまる”かを見て、そのうえで、潜在因子を有効に、あるいは明確に測っていない項目を削除すべきかどうかを判断するのです。

この考え方に沿って、EFA のもうひとつの帰結は、それぞれの因子に負荷する変数をまとめて因子得点、尺度得点と呼ばれることもあるもの、にすることです。変数をまとめて尺度得点にするには 2 つのやり方があります。

- その因子に寄与する各項目の因子負荷量で重みづけした得点として、新しい変数を作る。
- その因子に寄与する各項目にもとづいて、ただしすべて等しく重みづけして新しい変数を作る。

1 つめのやり方では、合成得点への各項目の寄与は、その項目が因子とどれだけ強く関係しているかによって決まります。2 つめのやり方では、ふつうは因子に実質的に寄与するすべての項目を単純に平均して、合成尺度得点の変数を作ります。どちらを選ぶかは好みの問題ですが、1 つめのやり方

^{*1}ありがたいことに、因子負荷量は標準化回帰係数のように解釈できます。

には、負荷量が標本ごとにかなり変わりうるという欠点があります。行動科学や健康科学では、異なる研究や異なる標本にまたがって使える合成尺度得点を開発し利用したいことが多いのです。その場合には、別の標本から得られた標本固有の負荷量で重みづけするよりも、実質的な項目が等しく寄与する合成指標を使うほうが理にかなっています。いずれにせよ、合成変数を項目の平均として理解するほうが、標本固有の最適重みづけによる合成を使うよりも単純で直感的です。

本書の範囲を超えるより進んだ統計手法として、潜在因子を別の潜在因子の予測モデルに用いる回帰モデリングがあります。これは“構造方程式モデリング”と呼ばれ、このアプローチに特化したソフトウェアや R パッケージがあります。しかし先を急ぐのはやめましょう。いま集中すべきなのは、JASP で EFA をどうやるか、です。

1.1.2 JASP での EFA

まずデータが必要です。International Personality Item Pool(<http://ipip.ori.org>) から取られた 25 個のパーソナリティ自己報告項目 (図 ??参照) が、Synthetic Aperture Personality Assessment(SAPA) というウェブベースのパーソナリティ測定プロジェクト (SAPA: <http://sapa-project.org>) の一部として使われました。この 25 項目は、協調性、誠実性、外向性、神経症傾向、開放性という想定される 5 つの因子によって構成されています。

項目データは 6 件法の反応尺度で収集されました。

1. まったく当てはまらない
2. あまり当てはまらない
3. やや当てはまらない
4. やや当てはまる
5. かなり当てはまる
6. 非常によく当てはまる

$N = 250$ の回答からなる標本が、データセット `bfi_sample.csv` に入っています。研究者としての私たちの関心は、`bfi_sample.csv` データファイルの 25 の観測変数によってそれなりにうまく測定されている潜在因子があるかどうかを、データを探索して確かめることです。データセットを開いて、25 の変数が連続変数としてコード化されていることを確認してください (厳密には順序変数ですが、JASP で EFA を行う分にはたいい問題になりません。ただし重みづけ因子得点を計算する場合には連続変数である必要があります)。JASP で EFA を実行するには、次のようにします。

- JASP のメインのボタンバーから **Factor - Exploratory Factor Analysis** を選び、EFA の分析ウィンドウを開きます (図 ??)。
- 25 のパーソナリティ項目を選択し、'Variables' のボックスに移します。
- 'Assumption Checks' をはじめ、回転の 'Method'、抽出する 'Number of Factors'、'Additional

Variable name	Question / Item (short phrases that you should respond to by indicating how accurately the statement describes your typical behaviour or attitudes)	Coding (R: reverse)
A1	<u>Am</u> indifferent to the feelings of others.	R
A2	Inquire about others' well-being.	
A3	Know how to comfort others.	
A4	Love children.	
A5	Make people feel at ease.	
C1	<u>Am</u> exacting in my work.	
C2	Continue until everything is perfect.	
C3	Do things according to a plan.	
C4	Do things in a half-way manner.	R
C5	Waste my time.	R
E1	Don't talk a lot.	R
E2	Find it difficult to approach others.	R
E3	Know how to captivate people.	
E4	Make friends easily.	
E5	Take charge.	
N1	Get angry easily.	
N2	Get irritated easily.	
N3	Have frequent mood swings.	
N4	Often feel blue.	
N5	Panic easily.	
O1	<u>Am</u> full of ideas.	
O2	Avoid difficult reading material.	R
O3	Carry the conversation to a higher level.	
O4	Spend time reflecting on things.	
O5	Will not probe deeply into a subject.	R

Figure1.2 データセット bfi_sample.csv に含まれる、想定される 5 つのパーソナリティ因子で構成された 25 の観測変数項目

Output' などの適切なオプションにチェックを入れます。この例示のための EFA で推奨されるオプションは図 ??を見てください。なお、回転の 'Method' と抽出する 'Number of Factors' は、後述するように、最良の結果を見つけるために分析の途中で研究者が調整していくのが普通です。

これでいくつの因子を使うか (データから “抽出” するか) の検討を始められます。3 つの異なるやり方があります。




Figure1.3 JASP の探索的因子分析のウィンドウ

- ひとつの慣例は、固有値が 1 より大きい成分をすべて選ぶというものです^{*2}。今回のデータでは 4 因子になります (実際に試してみてください)。
- 図 ?? のようなスクリープロットを調べると “変曲点” を見つけることができます。これはスクリー曲線の傾きがはっきりと平らになる点で、“肘” の下にあたります。今回のデータでは 5 因子になります。スクリープロットの解釈は少し職人芸的なところがあります。図 ?? では 5 因子から 6 因子にかけてははっきりした段差がありますが、他のスクリープロットではここまではっきりしないこともあります。
- 平行分析という手法を使い、得られた固有値をランダムなデータから得られるであろう固有

^{*2}固有値は、その因子が観測変数の分散のどれだけを説明するかを示します。固有値が > 1 の因子は、観測変数 1 つ分より多くの分散を説明していることになります。

値と比較します。抽出される因子数は、ランダムなデータで得られる値より大きい固有値を持つ因子の数になります。




Figure1.4 JASP の EFA によるパーソナリティデータのスクリープロット。5 の地点 (“肘”) ではっきりした変曲と平坦化が見られる

.....

Fabrigar1999 によれば 3 つめのやり方がよいということですが、実際には研究者は 3 つすべてを見たうえで、もっとも解釈しやすい、あるいは解釈に役立つ因子数を判断する傾向があります。これは “意味の解釈可能性による基準” と理解できます。研究者はふつう、上のいずれかのやり方で得られた解に加えて、因子数を 1 つか 2 つ増やした解や減らした解も検討します。そのうえで、もっとも納得のいく解を採用するのです。

同時に、最終的な解をどう回転させるのがよいかも考える必要があります。回転には大きく 2 つのやり方があります。直交回転 (たとえば ‘varimax’) は選ばれた因子が無相関になるように強制するのに対し、斜交回転 (たとえば ‘oblimin’) は因子間に相関があることを許します。心理学者や行動科学者が関心を持つ次元は、直交していると期待できるようなものであることはあまりありませんので、

Factor Statistics

Summary			
Factor	SS Loadings	% of Variance	Cumulative %
1	2.578	10.313	10.313
2	2.380	9.518	19.831
3	2.246	8.985	28.816
4	2.337	9.349	38.165
5	1.878	7.514	45.679

Correlation Matrix					
	1	2	3	4	5
1	—	-0.195	0.015	0.208	-0.128
2		—	0.184	-0.398	0.261
3			—	-0.300	0.303
4				—	-0.311
5					—

Figure1.5 jamovi の EFA による 5 因子解の因子要約統計量と因子間相関

.....

斜交解のほうが理にかなっていると言えるでしょう*3。

実際には、斜交回転で因子間にかなりの相関 (正でも負でもよく、 > 0.3) が見られた場合、たとえば図 ??で抽出された因子のうち 2 つの相関が -0.398 であるような場合には、斜交回転を選ぶという直感が裏づけられたことになります。因子が実際に相関しているのであれば、斜交回転のほうが直交回転よりも真の因子のよい推定値と、よりよい単純構造を与えてくれます。そして、斜交回転の結果、因子間の相関がほぼゼロだとわかったのであれば、研究者はそのまま直交回転を実行すればよいのです (その場合、斜交回転とほぼ同じ解が得られるはずです)。

抽出された因子間の相関を確認したところ、少なくともひとつは 0.3 を超えていました (図 ??) ので、抽出された 5 因子には斜交回転 ('oblimin') を使うのがよさそうです。図 ??からは、5 因子が

*3斜交回転では 2 つの因子行列が得られます。ひとつは構造行列、もうひとつはパタン行列と呼ばれるものです。jamovi では結果にパタン行列だけが表示されます。解釈にはこちらがもっとも有用なのが普通だからですが、専門家のなかには両方を見るとよいと言う人もいます。構造行列の係数は、その因子と他のすべての因子との関係を見無視したうえで、変数と因子の関係を示します (つまり 0 次の相関です)。パタン行列の係数は、その変数に対する他の因子の効果を統制したうえで、ある因子がその変数に対して持つ独自の寄与を示します (標準化偏回帰係数に似たものです)。直交回転のもとでは、構造係数とパタン係数は同じになります。

データ全体の分散の 46% を説明していることもわかります。第 1 因子が分散の約 10%, 第 2 因子から第 4 因子がそれぞれ約 9%, 第 5 因子が 7% 強を説明しています。これはあまり立派な数字ではありません。解全体がデータの分散のもっと大きな割合を説明していればよかったのですが。

どんな EFA でも、原理的には観測変数と同じ数だけ因子を取ることができますが、因子を 1 つ増やすごとに、追加で説明される分散の量は小さくなっていくということに注意してください。最初のいくつかの因子がもとの 25 変数の分散のかなりの部分を説明しているなら、それらの因子は 25 変数の代わりになる、明らかに有用でより単純なものだということになります。残りは、もとの変動をそれほど失うことなく捨てられるわけです。しかし、25 変数の分散の大部分を説明するのにたとえば 18 個の因子が必要なのであれば、もとの 25 変数をそのまま使えばよい、ということになります。

図 ?? は因子負荷量を示しています。つまり、25 のパーソナリティ項目が、選ばれた 5 つの因子のそれぞれにどう負荷しているかということです。0.3 未満の負荷量は非表示にしてあります (図 ?? のオプションで設定します)。

第 1, 第 2, 第 3, 第 4 因子については、因子負荷量のパターンが図 ?? で想定されていた因子とよく一致しています。やれやれ。そして第 5 因子もかなり近く、“開放性” を測ると想定されていた 5 つの観測変数のうち 4 つが、この因子にきれいに負荷しています。ただし変数 O4 はどうも収まりが悪いようです。図 ?? の因子解を見ると、この変数は (比較的低い負荷量ではありますが) 第 3 因子に負荷しており、第 5 因子には実質的に負荷していません。

もうひとつ注目すべきは、図 ?? で “R: 逆転項目” と示されていた変数が、負の因子負荷量を持っているということです。項目 A1 (“他人の気持ちに無関心である”) と A2 (“他人の様子を気にかける”) を見てください。A1 の得点が高いことは協調性が低いことを意味するのに対し、A2 の得点が高いこと (そのほかの “A” の変数すべてについても同様です) は協調性が高いことを意味します。ですから A1 は他の “A” の変数と負の相関を持つことになり、図 ?? にあるように負の因子負荷量を持つわけです。

図 ?? では、各変数の “独自性” も見ることができます。独自性とは、その変数に “固有” で因子によって説明されない分散の割合のことです^{*4}。たとえば、‘A1’ の分散の 74% は 5 因子解の因子では説明されていません。これに対して ‘N1’ は、因子解で説明されない分散が比較的小さくなっています (31%)。“独自性” が大きいほど、その変数の因子モデルにおける関連性や寄与は小さいということに注意してください。

正直なところ、EFA でこれほどきれいな解が得られるのは珍しいことです。ふつうはもっとごちゃごちゃしていますし、因子の意味を解釈するのももっと骨が折れます。ここまではっきりと切り分けられた項目プールを持っていることは、そう多くありません。たいていの場合は、いくつかの潜在因子の指標かもしれないと思われる観測変数の山を抱えているものの、どの変数がどこに行くのかに

^{*4} 因子分析では “共通性” が報告されることもあります。これは、その変数の分散のうち因子解によって説明される量のことです。独自性は $(1 - \text{共通性})$ に等しくなります。

Factor Loadings						
	Factor					Uniqueness
	1	2	3	4	5	
A1			-0.465			0.738
A2			0.702			0.502
A3			0.687			0.444
A4			0.453			0.667
A5			0.543			0.515
C1		0.720				0.478
C2		0.664				0.542
C3		0.501				0.753
C4		-0.647				0.469
C5		-0.571				0.536
E1				0.561		0.663
E2				0.697		0.352
E3				-0.441	0.419	0.486
E4			0.390	-0.569		0.426
E5				-0.391		0.587
N1	0.818					0.309
N2	0.814					0.359
N3	0.687					0.477
N4	0.461			0.483		0.463
N5	0.451					0.649
O1					0.576	0.626
O2					-0.487	0.689
O3					0.704	0.407
O4			0.307			0.745
O5					-0.493	0.698

Note. 'oblimin' rotation was used

Figure1.6 jamovi の EFA による 5 因子解の因子負荷量

.....

ついてそこまで強い見通しは持っていない，というものです。

さて，全体として説明される観測分散の割合は比較的低いものの，かなりよい 5 因子解が得られたようです。この解に満足していて，これらの因子をさらに別の分析に使いたいとしましょう。いち

ばん素直なやり方は、その因子に実質的に負荷している各変数の得点を合計し、変数の数で割ることで、因子ごとの全体的な (平均) 得点を計算することです。データセットの各人について、たとえば協調性因子であれば、 $A1 + A2 + A3 + A4 + A5$ を合計して 5 で割る、ということになります^{*5}。つまり、こうして計算した因子得点は、含まれる各変数の得点を等しく重みづけしたのものにもとづいている、ということです。jamovi では 2 つのステップでこれができます。

1. jamovi の変数変換コマンドを使って、A1 の値を逆転 (つまり $6 = 1; 5 = 2; 4 = 3; 3 = 4; 2 = 5; 1 = 6$) し、“A1R”として再コード化します (図 ??参照)。
2. A1R, A2, A3, A4, A5 の平均を計算して、“Agreeableness”という新しい変数を作ります。これは jamovi の新変数計算コマンドで行います (図 ??参照)。




Figure1.7 jamovi の Transform コマンドによる変数の再コード化

もうひとつのやり方は、最適に重みづけした因子得点の指標を作ることです。jamovi の Rj エディタを使えば、R でこれを行えます。これも 2 つのステップに分かれます。

^{*5}必要なら、先に一部の変数を逆転処理しておくのを忘れずに。




Figure1.8 jamovi の Computed variable コマンドによる新しい尺度得点変数の計算

1. Rj エディタを使い、jamovi で行ったのと同じ指定 (つまり 5 因子・oblimin 回転) で R 上の EFA を実行し、最適重みづけ因子得点を計算します。因子得点を含む新しいデータセットをファイルに保存します。図 ??を参照してください。
2. その新しいファイルを jamovi で開き、変数の型が正しく設定されているか確認します。新しい因子得点変数に、対応する因子名や定義にしたがってラベルを付けます (なお、因子が期待した順序で並んでいないこともありますので、必ず確認してください)。

これで、因子にもとづく得点 (平均尺度得点のやり方) を使うか、Rj エディタで計算した最適重みづけ因子得点を使うかして、さらに分析を進められます。どちらを使うかは好み次第です。たとえば、パーソナリティの各尺度に性差があるかどうかを見てみたくなるかもしれません。因子にもとづく得点のやり方で計算した協調性の得点についてこれを行ってみたところ、プロット (図 ??) では男性のほうが女性より協調性が低いように見えたましたが、有意な差ではありませんでした (Mann-Whitney の $U = 5760.5, p = .073$)。




Figure1.11 因子にもとづく協調性得点の男女差の比較

1.1.3 EFA の結果をどう書くか

ここまでで、EFA とは何か、jamovi で EFA をどう実行するかについて、ある程度の感覚をつかんでいただけたのではないかと思います。では、EFA を終えたあと、それをどう書けばよいのでしょうか。EFA の書き方に公式の標準があるわけではなく、実例は分野や研究者によってまちまちです。とはいえ、書くときに含めるべきかなり標準的な情報というものはあります。

1. 研究している領域、とくに EFA によって明らかにしようとしている構成概念について、どのような理論的裏づけがあるのか。
2. 標本の記述 (たとえば人口統計学的情報、標本サイズ、標本抽出の方法)。
3. 使用したデータの種類 (たとえば名義尺度か連続量か) と記述統計。
4. EFA の仮定をどのように検討したか。球面性の確認と標本妥当性の指標についての詳細を報告すべきです。
5. どの因子抽出法 (たとえば最尤法) を使ったかの説明。
6. 最終的な解で因子をいくつ抽出するか、どの項目を選ぶかを決めるのに用いた基準と過程の説明。EFA の過程における重要な判断の根拠をはっきり説明してください。
7. どの回転法を試したか、その理由、そして結果の説明。

8. 最終的な因子負荷量は、結果のなかで表として報告すべきです。この表には各変数の独自性 (または共通性) も (最後の列に) 入れます。因子負荷量は項目番号だけでなく、内容のわかるラベルとともに報告してください。因子間相関も、この表の下部か別表として含めるべきです。
9. 抽出された因子には意味のある名前を付けるべきです。以前から使われている因子名を使ってもよいのですが、実際の項目と因子を検討した結果、別の名前のほうが適切だと思うこともあるでしょう。

1.2

主成分分析

前の節では、EFA が背後にある潜在因子を特定するために働くことを見ました。そして見てきたように、ひとつの使い方として、少数の潜在因子を何らかの合成因子得点の形にして、さらに別の統計分析に使うことができます。

このようなとき EFA は “データ縮約” の手法として使われています。データ縮約の手法にはもうひとつ、EFA の仲間とみなされることもある**主成分分析 (PCA)** があります。ただし PCA は、背後にある潜在因子を特定するものではありません。そうではなく、より多数の測定変数から線形の合成得点を作り出すものです。

PCA は、変数がどう共変するかについての仮定を置かずに、もとのデータに数学的な変換を施すだけのものです。PCA のねらいは、情報をあまり失わずに観測データを要約できるような、もとの変数の少数の線形結合 (成分) を計算することにあります。しかし、背後にある構造を特定することが分析の目的なのであれば、EFA のほうを選ぶべきです。そして見てきたように、EFA は主成分得点と同じようにデータ縮約の目的に使える因子得点を出してくれます (**Fabrigar1999**)。

PCA はいくつかの理由から心理学で広く使われてきましたので、取り上げる価値はあります。もっとも、いまではデスクトップ計算機の性能からすれば EFA も同じくらい簡単に実行できますし、とくに因子数や変数の数が少ない場合には、EFA のほうが PCA よりバイアスを受けにくいこともあります。先ほどと同じ `bfi_sample.csv` のデータを使います。手順の多くは EFA と似ていますので、概念的な違いはあるものの、実際の操作は同じです^{*6}。そして標本が大きく、因子と変数の数が十分にあれば、PCA と EFA の結果はかなり似たものになるはずです。

^{*6}... ということは、次の節で説明する PCA の手順にはかなりの繰り返しがあるということです。申し訳ありませんが、そこまでひどくはないと思いたいところです。

1.2.1 jamovi で PCA を実行する

bfi_sample.csv のデータを読み込んだら、jamovi のメインのボタンバーから **Factor - Principal Component Analysis** を選び、PCA の分析ウィンドウを開きます (図 ??)。次に 25 のパーソナリティ項目を選択し、'Variables' のボックスに移します。'Assumption Checks' をはじめ、回転の 'Method'、抽出する 'Number of Factors'、'Additional Output' などの適切なオプションにチェックを入れます。この PCA で推奨されるオプションは図 ??を見てください。なお、回転の 'Method' と抽出する 'Number of Factors' は、後述するように、最良の結果を見つけるために分析の途中で調整していくのが普通です。

Figure1.12 jamovi の PCA 分析ウィンドウ

まず仮定を確認すると、(1) Bartlett の球面性検定が有意ですので、この仮定は満たされています。(2) 標本妥当性の KMO 指標 (MSA) は全体で 0.81 であり、標本妥当性は非常に良好だと言えます。ここでは問題なさそうですね。

次に確認すべきなのは、いくつの成分を使うか (データから “抽出” するか) です。EFA と同じく、3 つの異なるやり方があります。

- ひとつの慣例は、固有値が 1 より大きい成分をすべて選ぶというものです。今回のデータでは 2 成分になります。
- 図 ?? のようなスクリープロットを調べると “変曲点” を見つけることができます。これはスクリー曲線の傾きがはっきりと平らになる点で、“肘” の下にあたります。これも、第 2 成分のあとではっきりと平坦になっていますので、2 成分ということになります。
- 平行分析という手法を使い、得られた固有値をランダムなデータから得られるであろう固有値と比較します。抽出される成分数は、ランダムなデータで得られる値より大きい固有値を持つ成分の数になります。

Fabrigar1999 によれば 3 つめのやり方がよいということですが、実際には研究者は 3 つすべてを見たうえで、もっとも解釈しやすい、あるいは解釈に役立つ成分数を判断する傾向があります。これは “意味の解釈可能性による基準” と理解できます。研究者はふつう、上のいずれかのやり方で得られた解に加えて、成分数を 1 つか 2 つ増やした解や減らした解も検討します。そのうえで、もっとも納得のいく解を採用するのです。

同時に、最終的な解をどう回転させるのがよいかも考える必要があります。これも EFA と同じで、回転には大きく 2 つのやり方があります。直交回転 (たとえば “varimax”) は選ばれた成分が無相関になるように強制するのに対し、斜交回転 (たとえば “oblimin”) は成分間に相関があることを許します。心理学者や行動科学者が関心を持つ次元は、直交していると期待できるようなものであることはあまりありませんので、斜交解のほうが理にかなっていると言えるでしょう。実際には、斜交回転で成分間にかなりの相関 (つまり > 0.3) が見られた場合には、斜交回転を選ぶという直感が裏づけられたことになります。成分が実際に相関しているのであれば、斜交回転のほうが直交回転よりも真の成分のよい推定値と、よりよい単純構造を与えてくれます。そして、斜交回転の結果、成分間の相関がほぼゼロだとわかったのであれば、研究者はそのまま直交回転を実行すればよいのです (その場合、斜交回転とほぼ同じ解が得られるはずです)。図 ?? を見ると相関はどれも > 0.3 ではありませんので、直交回転 (varimax) に切り替えるのが適切です。

図 ?? には、2 つの成分が説明するデータ全体の分散の割合も出ています。第 1 成分と第 2 成分は、それぞれ分散の 12% 強を説明しています。合わせると、5 成分解は観測データの分散の半分強 (56%) を説明していることになります。どんな PCA でも、原理的には観測変数と同じ数だけ成分を取ることができますが、成分を 1 つ増やすごとに、追加で説明される分散の量は小さくなっていく

Assumption Checks

Bartlett's Test of Sphericity

χ^2	df	p
2183.322	300	<.00001

KMO Measure of Sampling Adequacy

	MSA
Overall	0.809
A1	0.568
A2	0.838
A3	0.808
A4	0.837
A5	0.858
C1	0.804
C2	0.797
C3	0.754
C4	0.809
C5	0.851
E1	0.834
E2	0.843
E3	0.854
E4	0.870
E5	0.911
N1	0.737
N2	0.714
N3	0.762
N4	0.819
N5	0.800
O1	0.840
O2	0.688
O3	0.823
O4	0.742
O5	0.738

Figure1.13 パーソナリティ項目データについての jamovi PCA の仮定チェック

Scree Plot




Figure1.14 jamovi PCA によるパーソナリティ項目データのスクリープロット。第 5 成分のあとに平坦化の点, “肘”が見られる

.....

ということに注意してください。最初のいくつかの成分がもとの 25 変数の分散のかなりの部分を説明しているなら, それらの成分は 25 変数すべての代わりになる, 明らかに有用でより単純なものだということになります。残りは, もとの変動をそれほど失うことなく捨てられるわけです。しかし, 25 変数の分散の大部分を説明するのに 18 個の成分が必要なのであれば, もとの 25 変数をそのまま使えばよい, ということになります。

図 ??は成分負荷量を示しています。つまり, 25 のパーソナリティ項目が, 選ばれた成分のそれぞれにどう負荷しているかということです。実質的な負荷量を持つ項目に関心があったこと, また閾値を 0.4 と高めに設定したほうがすっきりしたわかりやすい解になったことから, 0.4 未満の負荷量は非表示にしています (図 ??のオプションで設定します)。

第 1, 第 2, 第 3, 第 4 成分については, 成分負荷量のパターンが図 ??で想定されていた因子とよく一致しています。そして第 5 成分もかなり近く, “開放性” を測ると想定されていた 5 つの観測変数のうち 4 つが, この成分にきれいに負荷しています。ただし変数 04 はどうも収まりが悪いようです。図 ??の成分解を見ると, この変数は (比較的低い負荷量ではありますが) 第 4 成分に負荷しており, 第 5 成分には実質的に負荷していません。

図 ??では, 各変数の “独自性” も見ることができます。独自性とは, その変数に “固有” で成分に

Component Statistics

Summary				
Component	SS	Loadings	% of Variance	Cumulative %
1		3.136	12.542	12.542
2		3.090	12.361	24.903
3		2.856	11.425	36.328
4		2.682	10.729	47.056
5		2.272	9.086	56.143

Correlation Matrix					
	1	2	3	4	5
1	—	−0.136	−0.124	0.025	−0.090
2		—	0.259	0.175	0.136
3			—	0.091	0.108
4				—	0.118
5					—

Figure1.15 jamovi PCA による 5 成分分解の成分要約統計量と成分間相関

よって説明されない分散の割合のことです。たとえば、'A1' の分散の 58% は 5 成分分解の成分では説明されていません。これに対して 'N1' は、成分分解で説明されない分散が比較的小さくなっています (30%)。“独自性” が大きいほど、その変数の成分モデルにおける関連性や寄与は小さいということに注意してください。

ここまでで、jamovi で PCA をどう実行するか、そして PCA が概念的には EFA と異なるものの、実際には (適切なデータであれば) かなり似たものであることについて、おおよその見当がついたのではないかと思います。

成分得点の作成も、EFA とほぼ同じやり方で進められます。ただし、最適に重みづけした成分得点の指標を作る道を選んだ場合には、jamovi の Rj エディタでのコマンドと文法が少し異なります。図 ?? を見てください。

Component Loadings

	Component					Uniqueness
	1	2	3	4	5	
A1				-0.554		0.581
A2				0.743		0.411
A3				0.735		0.384
A4				0.515		0.544
A5				0.597		0.463
C1			0.746			0.392
C2			0.741			0.395
C3			0.621			0.582
C4			-0.673			0.399
C5			-0.634			0.430
E1		-0.664				0.547
E2		-0.746				0.318
E3		0.656				0.387
E4		0.661		0.409		0.362
E5		0.585				0.492
N1	0.809					0.298
N2	0.812					0.314
N3	0.785					0.370
N4	0.652	-0.405				0.386
N5	0.592					0.503
O1					0.634	0.486
O2					-0.632	0.505
O3					0.673	0.361
O4				0.429		0.557
O5					-0.669	0.496

Note. 'varimax' rotation was used

Figure1.16 jamovi PCA による 5 成分分解の成分負荷量

.....




Figure1.17 5成分分解の最適重みづけ成分得点を作成するための Rj エディタのコマンド

確認的因子分析

さて、パーソナリティの項目プールから注意深く選んだ質問を使い、EFAで背後の潜在因子を特定しようとした試みは、かなりうまくいったように見えました。役に立つパーソナリティ測定尺度を開発するという道のりの次のステップは、最初のEFAで特定した潜在因子を、別の標本で確認することです。その因子が持ちこたえるかどうか、別のデータでその存在を確認できるかどうかを見たいのです。これから見るように、こちらはより厳密な確認になります。これは**確認的因子分析 (CFA)**と呼ばれます。当然といえば当然ですが、あらかじめ指定した潜在因子構造を確認しようとするからです*7。

CFAでは、探索的な意味でデータがどうまとまるかを見る分析をするのではなく、図 ??のような構造をデータに課したうえで、あらかじめ指定した構造にデータがどれだけよく当てはまるかを見ます。この意味で、あらかじめ指定した**モデル**が観測データによってどれだけ確認されるかを見る、

*7余談ですが、最初の“想定される”因子についてかなりしっかりした見通しを持っていたのですから、EFAの段階を飛ばしていきなりCFAに進むこともできました。EFAをやってからCFAに進むか、いきなりCFAに進むかは判断の問題で、モデル(因子数と変数について)がおおよそ正しいという確信が最初にどれだけあるかによります。尺度開発の初期や、背後にある潜在的な構成概念を特定する段階では、研究者はEFAを使う傾向があります。その後、最終的な尺度に近づいてきた段階や、確立された尺度を新しい標本で確認したい場合には、CFAがよい選択肢になります。

確認的な分析を行っているわけです。

ですからパーソナリティ項目の素直な確認的因子分析 (CFA) は、図 ?? に示したように 5 つの潜在因子を指定し、それぞれが 5 つの観測変数で測定される、という形になります。各変数は、背後にある潜在因子の測定値です。たとえば A1 は、背後にある潜在因子である協調性によって予測されます。そして A1 は協調性因子の完全な測定値ではありませんので、誤差項 e が付いています。つまり e は、A1 の分散のうち協調性因子では説明されない部分を表しています。これは測定誤差と呼ばれることもあります。

次に考えるべきは、モデルの中で潜在因子どうしが相関することを許すかどうかです。先に述べたように、心理学や行動科学では構成概念どうしが関連していることが多いですし、今回のパーソナリティ因子のいくつかも互いに相関しているだろうと考えられます。ですからモデルでは、図 ?? の双方向の矢印で示されているように、これらの潜在因子が共変することを許すべきです。

同時に、誤差項のいくつかが互いに相関することについて、何かもっともな系統的理由があるかどうかとも考えるべきです。その理由のひとつは、観測変数の特定の部分集合に共通する方法論的な特徴があって、実質的な潜在因子ではなく方法論的な理由で観測変数が相関している、という場合でしょう。この可能性についてはあとの節で扱いますが、いまのところ、誤差項どうしを相関させることを正当化できるような明らかな理由は見当たりません。

誤差項の相関がないとすると、観測データとの当てはまりを検討するモデルは、図 ?? に指定したとおりのものになります。モデルに含まれるパラメータだけがデータに存在すると想定されますので、CFA ではそれ以外のありうるパラメータ (係数) はすべてゼロに固定されます。ですから、それらのパラメータがゼロでない場合 (たとえば観測データでは A1 が潜在因子である外向性にかなり負荷しているのに、モデルにはその経路がない場合)、モデルと観測データの当てはまりは悪くなるでしょう。

それでは、この CFA 分析を jamovi でどう設定するかを見ていきましょう。

1.3.1 jamovi での CFA

bfi_sample2.csv ファイルを開き、25 の変数が順序尺度 (あるいは連続量。この分析では違いはありません) としてコード化されていることを確認してください。jamovi で CFA を実行するには、次のようにします。

- jamovi のメインのボタンバーから **Factor - Confirmatory Factor Analysis** を選び、CFA の分析ウィンドウを開きます (図 ??)。
- 5 つの **A** 変数を選んで 'Factors' のボックスに移し、"Agreeableness" というラベルを付けます。
- 'Factors' のボックスに新しい因子を作り、"Conscientiousness" というラベルを付けます。5 つの **C** 変数を選び、"Conscientiousness" のラベルの下に移します。




Figure1.18 CFA で用いる, 5 因子パーソナリティ尺度の潜在因子構造の当初の事前指定

- さらに新しい因子を作り，“Extraversion”というラベルを付けます。5つのE変数を選び，“Extraversion”のラベルの下に移します。
- さらに新しい因子を作り，“Neuroticism”というラベルを付けます。5つのN変数を選び，“Neuroticism”のラベルの下に移します。
- さらに新しい因子を作り，“Openness”というラベルを付けます。5つのO変数を選び，“Openness”のラベルの下に移します。
- そのほかのオプションも適宜チェックします。最初にひととおりやってみる分には既定のままで問題ありませんが、‘Plots’の下にある“Path diagram”のオプションにチェックを入れると、図 ??とかなりよく似た図をjamoviが描いてくれます。

分析の設定ができれば、jamoviの結果ウィンドウに目を移して、どうなっているかを見ていきましょう。まず見るべきは**モデル適合度**(図 ??)です。これがモデルと観測データの当てはまりのよさを教えてくれます。なお今回のモデルでは、あらかじめ指定した共分散だけが推定されます。既定では因子間相関も含まれます。それ以外はすべてゼロに固定されています。

モデル適合度の評価にはいくつかのやり方があります。ひとつめはカイ二乗統計量で、値が小さければモデルがデータによく当てはまっていることを示します。しかしモデル適合度の評価に使うカイ二乗統計量は標本サイズにかなり敏感です。つまり標本が大きければ、モデルとデータの当てはまりが十分によくて、ほとんど常に大きく有意($p < .05$)なカイ二乗値が出てしまうということです。

ですから、モデル適合度を評価する別のやり方が必要になります。jamoviでは既定でいくつか提供されています。比較適合度指標(CFI)、Tucker-Lewis指標(TLI)、そして近似の平均二乗誤差平方根(RMSEA)と、そのRMSEAの90%信頼区間です。役に立つ経験則としては、 $CFI > 0.9$ 、 $TLI > 0.9$ 、RMSEAが0.05から0.08程度であれば満足できる当てはまりだとされます。よい当てはまりは、 $CFI > 0.95$ 、 $TLI > 0.95$ 、RMSEAとRMSEAの信頼区間上限が < 0.05 です。

さて図 ??を見ると、カイ二乗値は大きく、非常に有意です。標本サイズはそれほど大きくありませんので、これは当てはまりが悪いことを示しているのかもしれませんが。CFIは0.762、TLIは0.731で、モデルとデータの当てはまりが悪いことを示しています。RMSEAは0.085、90%信頼区間は0.077から0.092で、これもよい当てはまりを示すものではありません。

がっかりですね。とはいえ、先ほど似たデータセットで行ったEFA(セクション ??)でも、5因子モデルが説明していたのはデータの分散の半分程度でしたから、それほど驚くことでもないかもしれません。

続いて、図 ??と図 ??に示された因子負荷量と因子間共分散の推定値を見てみましょう。これらのパラメータのZ統計量とp値を見ると、どれもモデルにそれなりの寄与をしている(つまりゼロではない)ことがわかりますので、指定した変数と因子のあいだの経路や、因子間の相関をモデルから取り除く理由はなさそうです。標準化推定値のほうが解釈しやすいことが多く、これは‘Estimates’のオプションで指定できます。これらの表は、報告書や学術論文にそのまま載せるのに便利です。

Confirmatory Factor Analysis

→

ID

A1

A2

A3

A4

A5

C1

C2

C3

C4

→

Factors

N1

N2

N3

N4

N5

Openness

O1

O2

O3

> | Residual Covariances

> | Options

▼ | Estimates

Results

☒ Factor covariances

☐ Factor intercepts

☐ Residual covariances

☐ Residual intercepts

Statistics

☒ Test statistics

☐ Confidence interval

Interval %

☒ Standardized estimate

> | Model Fit

▼ | Additional Output

Post-Hoc Model Performance

☒ Residuals observed correlation matrix

Highlight values above

☒ Modification indices

Highlight values above

Plots

☐ Path diagram

Figure1.19 jamovi の CFA 分析ウィンドウ

Model Fit

Test for Exact Fit				
χ^2	df	p		
739.726	265	<.00001		

Fit Measures				
CFI	TLI	RMSEA	RMSEA 90% CI	
			Lower	Upper
0.762	0.731	0.085	0.077	0.092

Figure1.20 今回の CFA モデルについての jamovi CFA のモデル適合度の結果

.....

どうすればモデルを改善できるでしょうか。ひとつの選択肢は、何段階か戻って、使っている項目や測定について、どう改善したり変更したりできるかを考え直すことです。もうひとつの選択肢は、当てはまりをよくするためにモデルへ事後的な手直しを加えることです。そのやり方のひとつが“修正指標”を使うことで、jamovi では‘Additional output’ のオプションで指定します (図 ??参照)。

探すのは、もっとも大きい修正指標 (MI) の値です。そのうえで、事後的な理由づけによって、その項をモデルに追加することが理にかなっているかどうかを判断します。たとえば図 ??を見ると、まだモデルに入っていない因子負荷量のうち MI が最大なのは、N4(“よく気分が落ち込む”) の潜在因子である外向性への負荷で、値は 28.786 です。これは、この経路をモデルに追加すればカイ二乗値がおよそ同じだけ減る、ということを示しています。

しかし今回のモデルでこの経路を追加することは、理論的にも方法論的にもあまり意味がないと言えますので、よい考えではありません(“よく気分が落ち込む” が神経症傾向と外向性の両方を測っているという説得力のある議論を思いつけるなら別ですが)。私にはもっともな理由が思いつきません。とはいえ議論のために、意味があるということにして、この経路をモデルに追加してみましょう。CFA の分析ウィンドウ (図 ??参照) に戻り、N4 を外向性の因子に追加します。すると CFA の結果が変わります (結果は省略します)。カイ二乗値は 709 程度まで下がり (約 30 の減少で、MI の大きさとだいたい同じです)、他の適合度指標も少しではありますが改善します。しかしそれでは足りません。依然としてよく当てはまるモデルではないのです。

MI の値を使ってモデルに新しいパラメータを追加していく場合には、追加のたびに必ず MI の表を確認し直してください。MI は毎回更新されるからです。

Factor Loadings						
Factor	Indicator	Estimate	SE	Z	p	Stand. Estimate
Agreeableness	A1	-0.468	0.099	-4.727	<.00001	-0.328
	A2	0.771	0.079	9.761	<.00001	0.621
	A3	1.061	0.082	13.002	<.00001	0.788
	A4	0.749	0.096	7.830	<.00001	0.516
	A5	0.941	0.082	11.443	<.00001	0.711
Conscientiousness	C1	0.802	0.076	10.531	<.00001	0.670
	C2	0.747	0.087	8.558	<.00001	0.569
	C3	0.539	0.087	6.191	<.00001	0.421
	C4	-1.067	0.086	-12.414	<.00001	-0.760
	C5	-1.121	0.104	-10.775	<.00001	-0.678
Extraversion	E1	-0.898	0.106	-8.512	<.00001	-0.550
	E2	-1.261	0.100	-12.667	<.00001	-0.761
	E3	0.911	0.092	9.889	<.00001	0.627
	E4	1.040	0.092	11.278	<.00001	0.692
	E5	0.778	0.083	9.370	<.00001	0.596
Neuroticism	N1	1.339	0.094	14.174	<.00001	0.821
	N2	1.215	0.093	13.067	<.00001	0.765
	N3	1.217	0.097	12.487	<.00001	0.747
	N4	0.956	0.110	8.715	<.00001	0.574
	N5	0.842	0.110	7.631	<.00001	0.494
Openness	O1	0.665	0.082	8.119	<.00001	0.580
	O2	-0.653	0.115	-5.660	<.00001	-0.403
	O3	0.999	0.088	11.301	<.00001	0.831
	O4	0.233	0.085	2.735	0.00624	0.197
	O5	-0.514	0.093	-5.521	<.00001	-0.405

Figure1.21 今回の CFA モデルについての jamovi CFA の因子負荷量の表

jamovi は残差共分散の修正指標の表も出力します (図 ??)。つまり、どの誤差間相関をモデルに追加すればモデル適合度がもっとも改善するかを示す表です。2 つの MI の表を同時に見渡して最大の MI を見つけ、示されたパラメータの追加が妥当に正当化できるかどうかを考え、できるならモデルに追加する、というやり方がよいでしょう。そして再計算された結果で、また最大の MI を探し始めるわけです。

最大の MI にもとづいてパラメータを追加していけば、好きなだけこのやり方を続けられますし、いずれは満足のいく当てはまりに到達するでしょう。しかしそうしているうちに、怪物を作り出してしまう可能性も大いにあります。醜くゆがんでいて、理論的な意味も純粋さも持たないモデルです。

Factor Covariances		Estimate	SE	Z	p	Stand. Estimate
Agreeableness	Agreeableness	1.000 ^a				
	Conscientiousness	0.335	0.074	4.507	<.00001	0.335
	Extraversion	0.581	0.063	9.213	<.00001	0.581
	Neuroticism	-0.164	0.077	-2.140	0.03233	-0.164
	Openness	0.424	0.071	5.948	<.00001	0.424
Conscientiousness	Conscientiousness	1.000 ^a				
	Extraversion	0.504	0.065	7.756	<.00001	0.504
	Neuroticism	-0.289	0.074	-3.917	0.00009	-0.289
	Openness	0.277	0.081	3.440	0.00058	0.277
Extraversion	Extraversion	1.000 ^a				
	Neuroticism	-0.238	0.076	-3.122	0.00179	-0.238
	Openness	0.532	0.067	7.949	<.00001	0.532
Neuroticism	Neuroticism	1.000 ^a				
	Openness	-0.182	0.078	-2.320	0.02033	-0.182
Openness	Openness	1.000 ^a				

^a fixed parameter

Figure1.22 今回の CFA モデルについての jamovi CFA の因子間共分散の表

つまり、くれぐれも気をつけてください。

ここまでで、EFA で得られた因子構造を、第 2 の標本と CFA を使って検討してきました。残念ながら、EFA で得られた因子構造が CFA で確認されるという結果にはなりませんので、このパーソナリティ尺度の開発については振り出しに戻る、ということになります。

修正指標を使って CFA を手直しすることもできたのですが、示された追加の因子負荷量や残差共分散を含めるもっともな理由は (私が思いつく限り) 本当にありませんでした。とはいえ、残差の共変 (相関) を許すもっともな理由がある場合もあります。そのよい例が、次の節で扱う **多特性多方法 (MTMM)** の CFA です。その前に、CFA の結果をどう報告するかを見ておきましょう。

1.3.2 CFA の結果をどう報告するか

CFA の書き方に公式の標準があるわけではなく、実例は分野や研究者によってまちまちです。とはいえ、書くときに含めるべきかなり標準的な情報というものはあります。

1. 仮定したモデルの理論的・経験的な正当化。
2. モデルをどう指定したかの完全な記述 (たとえば各潜在因子の指標変数、潜在変数間の共分散、誤差項間の相関)。図 ?? のようなパス図も入れるとよいでしょう。

Factor Loadings – Modification Indices

	Agreeableness	Conscientiousness	Extraversion	Neuroticism	Openness
A1		11.138	14.214	1.532	0.391
A2		1.203	1.018	3.645	0.534
A3		1.760	4.695	2.952	0.001
A4		6.992	4.152	0.060	2.299
A5		3.843	11.412	8.179	3.501
C1	4.215		1.962	0.545	0.147
C2	1.399		0.009	12.077	0.007
C3	0.849		1.542	12.774	0.863
C4	0.960		1.053	2.708	0.214
C5	0.226		1.028	4.746	0.206
E1	13.545	0.501		1.357	3.139
E2	5.360	1.670		19.013	2.334
E3	4.395	5.853		6.202	28.017
E4	22.831	1.511		0.302	9.370
E5	2.400	8.775		2.507	2.894
N1	1.147	0.591	1.083		0.147
N2	1.034	9.833	7.580		3.178
N3	0.207	0.007	0.013		0.009
N4	1.653	14.031	28.786		0.652
N5	1.129	0.028	0.843		2.896
O1	0.069	0.190	1.889	0.280	
O2	6.429	2.426	8.060	6.849	
O3	2.711	2.093	7.699	1.037	
O4	1.851	13.387	10.541	8.873	
O5	1.584	4.494	2.974	2.188	

Figure1.23 jamovi CFA の因子負荷量の修正指標

-
3. 標本の記述 (たとえば人口統計学的情報, 標本サイズ, 標本抽出の方法)。
 4. 使用したデータの種類 (たとえば名義尺度か連続量か) と記述統計。
 5. 仮定の検討と, 用いた推定法。
 6. 欠測データの記述と, 欠測データをどう扱ったか。
 7. モデルの推定に用いたソフトウェアとそのバージョン。
 8. モデル適合度の判断に用いた指標と基準。
 9. モデル適合度や修正指標にもとづいて当初のモデルに加えた変更。
 10. すべてのパラメータ推定値 (つまり負荷量, 誤差分散, 潜在変数の分散・共分散) とその標準

Residual Covariances – Modification Indices																									
	A1	A2	A3	A4	A5	C1	C2	C3	C4	C5	E1	E2	E3	E4	E5	N1	N2	N3	N4	N5	O1	O2	O3	O4	O5
A1																									
A2	7.930																								
A3		4.452																							
A4			0.082																						
A5				0.012																					
C1					3.049																				
C2						1.326																			
C3							1.987																		
C4								1.010																	
C5									3.241																
E1										5.870															
E2											0.040														
E3												0.102													
E4													0.057												
E5														0.835											
N1															2.511										
N2																1.660									
N3																	1.165								
N4																		0.946							
N5																			0.200						
O1																				1.632					
O2																					2.131				
O3																						0.846			
O4																							0.803		
O5																								8.111	

Figure1.24 jamovi CFA の残差共分散の修正指標

誤差。おそらく表の形で。

1.4

多特性多方法 CFA

この節では、測定の技法や質問の違いが、データの変動の重要な源になりうることを考えます。これは**方法分散**として知られています。そのために、“帰属スタイル”についてのデータを含む、別の心理学のデータセットを使います。

帰属スタイル質問紙 (ASQ) を用いた **Hewitt2004** は、イギリスとニュージーランドの若者から心理的ウェルビーイングのデータを集めました。彼らが測定したのはネガティブな出来事に対する帰属スタイル、つまり自分の身に起きた悪い出来事の原因を人が習慣的にどう説明するか、というものです (**Peterson1984**)。帰属スタイル質問紙 (ASQ) は、帰属スタイルの3つの側面を測定します。

- 内在性は、悪い出来事の原因が自分自身の行動によるものだと、その人がどの程度信じているかです。
- 安定性は、悪い出来事の原因が時間を通じて安定していると、その人がどの程度習慣的に信じているかです。
- 全般性は、ある領域での悪い出来事の原因が生活の他の領域にも影響すると、その人がどの程度習慣的に信じているかです。

仮想的な場面が6つあり、各場面について回答者は (a) 内在性、(b) 安定性、(c) 全般性をねらった質問に答えます。ですから全部で $6 \times 3 = 18$ 項目になります。詳しくは図 ?? をご覧ください。

研究者の関心は、ASQ の 18 の観測変数によってそれなりにうまく測定されている潜在因子があるかどうかを、データを確認して調べることにあります。

まず彼らはこの 18 変数で EFA を試してみますが (結果は省略します)、どう抽出しても、どう回転しても、よい因子解が見つかりません。帰属スタイル質問紙 (ASQ) の背後にある潜在因子を特定しようという試みは、実を結びませんでした。こうした結果が出た場合、理論が間違っている (帰属スタイルには潜在因子構造など存在しない、というのはありうる話です) か、標本が不適切である (イギリスとニュージーランドの若年成人からなるこの標本の大きさと特性からすると、これは考えにくいでしょう) か、あるいは分析手法がこの仕事に適した道具ではなかった、のいずれかです。ここでは3つめの可能性を見ていくことにします。

ASQ で測定されていた次元は内在性・安定性・全般性の3つで、図 ?? に示すように、それぞれ6つの質問で測られていたことを思い出してください。

探索的な意味でデータがどうまとまるかを見る分析をするのではなく、図 ?? のような構造をデー

1. YOU HAVE BEEN LOOKING FOR A JOB UNSUCCESSFULLY FOR SOME TIME

(a) Is the cause of your unsuccessful job search due to something about you or something about other people or circumstances?

Totally due to other people or circumstances 1 2 3 4 5 6 7 **Totally due to me**

(b) In the future, when looking for a job, will this cause again be present?

Will never again be present 1 2 3 4 5 6 7 **Will always be present**

(c) Is the cause something that just influences looking for a job, or does it also influence other areas of your life?

Influences just this particular situation 1 2 3 4 5 6 7 **Influences all situations in my life**

Other hypothetical scenarios, each answered with (a), (b) and (c) in the same sort of way

2. A FRIEND COMES TO YOU WITH A PROBLEM AND YOU DON'T TRY TO HELP

3. YOU GIVE AN IMPORTANT TALK IN FRONT OF A GROUP AND THE AUDIENCE REACTS NEGATIVELY

4. YOU MEET A FRIEND WHO IS HOSTILE TOWARDS YOU

5. YOU CAN'T GET ALL THE WORK DONE THAT OTHERS EXPECT OF YOU

6. YOU GO OUT ON A DATE AND IT GOES BADLY

Figure1.25 ネガティブな出来事についての帰属スタイル質問紙 (ASQ)

Internality	Stability	Globality
Q1a	Q1b	Q1c
Q2a	Q2b	Q2c
Q3a	Q3b	Q3c
Q4a	Q4b	Q4c
Q5a	Q5b	Q5c
Q6a	Q6b	Q6c

Figure1.26 ASQ における内在性・安定性・全般性の各次元の 6 つの質問

タに課したうえで、あらかじめ指定した構造にデータがどれだけよく当てはまるかを見る、としたらどうでしょうか。この意味で、あらかじめ指定したモデルが観測データによってどれだけ確認されるかを見る、確認的な分析を行うことになります。




Figure1.27 ASQ の潜在因子構造の当初の事前指定

ですから ASQ の素直な確認的因子分析 (CFA) は、図 ?? の列に示したように 3 つの潜在因子を指定し、それぞれが 6 つの観測変数で測定される、という形になります。

これは図 ?? のように描くことができます。各変数が背後にある潜在因子の測定値であることが示されています。たとえば INT1 は、背後にある潜在因子である内在性によって予測されます。そして INT1 は内在性因子の完全な測定値ではありませんので、誤差項 e1 が付いています。つまり e1 は、INT1 の分散のうち内在性因子では説明されない部分を表しています。これは“測定誤差”と呼ばれることもあります。

次に考えるべきは、モデルの中で潜在因子どうしが相関することを許すかどうかです。先に述べたように、心理学や行動科学では構成概念どうしが関連していることが多いですし、内在性・安定性・全般性も互いに相関しているだろうと考えられますので、モデルでは、図 ?? に示すようにこれらの潜在因子が共変することを許すべきです。

同時に、誤差項のいくつかが互いに相関することについて、何かもっともな系統的理由があるかどうかとも考えるべきです。ASQ の質問を思い返すと、主要な質問 (1 から 6) のそれぞれに、3 つの下位質問 (a・b・c) がありました。Q1 は就職活動がうまくいかないことについての質問でしたので、この質問には他の質問 (2 から 5) にはない独特の人工的あるいは方法論的な側面が、おそらく就職活動に関わる何かとして、あると考えるのはもっともです。同じように Q2 は、困っている友人を助けなかったことについての質問でしたので、他の質問 (1 と 3 から 5) にはない、友人を助けないことに関わる独特の人工的あるいは方法論的な側面があるかもしれません。

つまり ASQ には複数の因子だけでなく、複数の方法論的特徴もあるわけです。質問 1 から 6 はそれぞれ少しずつ異なる“方法”を持っていますが、その“方法”は下位質問 a・b・c で共有されています。こうした異なる方法論的特徴をモデルに取り込むために、特定の誤差項どうしが相関していると指定することができます。たとえば INT1, STAB1, GLOB1 に付いている誤差は、Q1a・Q1b・Q1c に固有で共有されている方法論的分散を反映して、互いに相関しているとすべきです。図 ?? で言えば、列で表される潜在因子に加えて、表の各行の変数について測定誤差が相関している、ということになります。

図 ?? に示したような基本的な CFA モデルを観測データに対して検討することもできますが、実際には図 ?? に示すような、より洗練されたモデルにたどり着きました。この洗練された CFA モデルは **多特性多方法 (MTMM)** モデルとして知られており、これを jamovi で検討していきます。

1.4.1 jamovi での MTMM CFA

ASQ.csv ファイルを開き、18 の変数 (“内在性”6 つ, “安定性”6 つ, “全般性”6 つ) が連続変数として指定されていることを確認してください。

jamovi で MTMM CFA を実行するには、次のようにします。




Figure1.28 CFA MTMM モデルにおける，ASQ の潜在因子構造の最終的な事前指定。潜在因子間の相関と，観測変数 INT1・STAB1・GLOB1 について共有された方法による誤差項の相関を含む。見やすさのため，そのほかの事前指定された誤差項の相関は示していない。

- jamovi のメインのボタンバーから **Factor - Confirmatory Factor Analysis** を選び、CFA の分析ウィンドウを開きます (図 ??)。
- 6 つの INT 変数を選んで 'Factors' のボックスに移し、"Internality" というラベルを付けます。
- 'Factors' のボックスに新しい因子を作り、"Stability" というラベルを付けます。6 つの STAB 変数を選び、"Stability" のラベルの下に移します。
- さらに新しい因子を作り、"Globality" というラベルを付けます。6 つの GLOB 変数を選び、"Globality" のラベルの下に移します。
- Residual Covariances のオプションを開き、あらかじめ指定した相関のそれぞれについて、該当する変数を右の 'Residual Covariances' のボックスに移します。たとえば INT1 と STAB1 の両方を選択して矢印をクリックし、移動させます。同じことを INT1 と GLOB1, STAB1 と GLOB1, INT2 と STAB2, INT2 と GLOB2, STAB2 と GLOB2, INT3 と STAB3, という具合に続けていきます。
- そのほかのオプションも適宜チェックします。最初にひととおりやってみる分には既定のままでも問題ありませんが、'Plots' の下にある "Path diagram" のオプションにチェックを入れると、図 ?? とかなりよく似た図を、ただし上で追加した誤差項の相関をすべて含んだ形で、jamovi が描いてくれます。

分析の設定ができれば、jamovi の結果ウィンドウに目を移して、どうなっているかを見ていきましょう。まず見るべきは "Model fit" です。これがモデルと観測データの当てはまりのよさを教えてくれます。なお今回のモデルでは、あらかじめ指定した共分散だけが推定され、それ以外はすべてゼロに固定されています。ですからモデル適合度は、あらかじめ指定した "自由な" パラメータがゼロでないかどうかと、逆にデータの中のそれ以外の関係、つまりモデルで指定しなかった関係をゼロのままにしておけるかどうかの、両方を検討していることになります。

モデル適合度の評価にはいくつかのやり方があります。ひとつめはカイ二乗統計量で、値が小さければモデルがデータによく当てはまっていることを示します。しかしモデル適合度の評価に使うカイ二乗統計量は標本サイズに非常に敏感です。つまり標本が大きい (300 から 400 ケースを超える) 場合、モデルとデータの当てはまりが十分によっても、ほとんど常に大きく有意なカイ二乗値が出てしまうということです。

ですから、モデル適合度を評価する別のやり方が必要になります。jamovi では既定でいくつか提供されています。比較適合度指標 (CFI), Tucker 適合度指標 (TFI), そして近似の平均二乗誤差平方根 (RMSEA) と、その RMSEA の 90% 信頼区間です。先に述べたように、役に立つ経験則としては、CFI > 0.9, TFI > 0.9, RMSEA が 0.05 から 0.08 程度であれば満足できる当てはまりだとされます。よい当てはまりは、CFI > 0.95, TFI > 0.95, RMSEA と RMSEA の信頼区間上限が < 0.05 です。

さて図 ??を見ると、カイ二乗値は非常に有意ですが、標本サイズが大きい ($N = 2748$) ことを考えれば驚くことではありません。CFI は 0.98, TLI も 0.98 で、非常によい当てはまりを示していま




Figure1.29 jamovi の CFA 分析ウィンドウ

す。RMSEA は 0.02, 90% 信頼区間は 0.02 から 0.02 で, かなり狭いですね。

全体として, あらかじめ指定したモデルが観測データに非常によく当てはまっていると考えて満足してよいでしょう。ASQ についての MTMM モデルは支持されたわけです。

Model Fit

Test for Exact Fit				
χ^2	df	p		
243.97	114	<.00001		

Fit Measures				
CFI	TLI	RMSEA	RMSEA 90% CI	
			Lower	Upper
0.98	0.98	0.02	0.02	0.02

Figure1.30 今回の CFA MTMM モデルについての jamovi CFA のモデル適合度の結果

続いて, 図 ??のように因子負荷量と因子間共分散の推定値を見ていきましょう。標準化推定値のほうが解釈しやすいことが多く, これは 'Estimates' のオプションで指定できます。これらの表は, 報告書や学術論文にそのまま載せるのに便利です。

図 ??を見ると, あらかじめ指定した因子負荷量と因子間共分散はすべてゼロと有意に異なっていることがわかります。つまりどれもモデルに有用な寄与をしているようです。

今回の分析は運がよく, 最初の試みで非常によい当てはまりが得られました。これはかなり珍しいことで, CFA では当てはまりをよくするために, モデルへ事後的な手直しが加えられることがよくあります。そのやり方のひとつが "修正指標" を使うことで, jamovi では 'Additional output' のオプションで指定します。

探すのは, もっとも大きい修正指標 (MI) の値です。そのうえで, 事後的な理由づけによって, その項をモデルに追加することが理にかなっているかどうかを判断します。たとえば図 ??を見ると, まだモデルに入っていない因子負荷量のうち MI が最大なのは, INT6 の潜在因子である全般性への負荷で, 値は 24.52 です。これは, この経路をモデルに追加すればカイ二乗値がおよそ 25 減る, ということを示しています。しかし今回のモデルでこの経路を追加することは, 理論的にも方法論的にもあまり意味がありませんので, 修正版のモデルにこの経路を含めることはしません。

同じように残差項の MI(図 ??)を見ると, 最大の MI は INT1 と INT3 の誤差の共変を許す, つま

Confirmatory Factor Analysis

Factor Loadings

Factor	Indicator	Estimate	SE	Z	p	Stand. Estimate
Internality	INT1	0.55	0.05	12.28	<.00001	0.34
	INT2	0.50	0.05	10.52	<.00001	0.28
	INT3	0.61	0.04	13.95	<.00001	0.38
	INT4	0.64	0.05	13.45	<.00001	0.36
	INT5	0.54	0.04	12.52	<.00001	0.33
	INT6	0.66	0.04	16.50	<.00001	0.45
Stability	STAB1	0.53	0.04	14.97	<.00001	0.35
	STAB2	0.48	0.03	14.54	<.00001	0.34
	STAB3	0.69	0.03	20.20	<.00001	0.46
	STAB4	0.65	0.03	20.72	<.00001	0.47
	STAB5	0.67	0.03	21.47	<.00001	0.49
	STAB6	0.66	0.03	22.17	<.00001	0.51
Globality	GLOB1	0.71	0.04	18.16	<.00001	0.40
	GLOB2	0.73	0.04	20.32	<.00001	0.44
	GLOB3	0.93	0.04	25.10	<.00001	0.54
	GLOB4	0.83	0.03	24.99	<.00001	0.53
	GLOB5	0.76	0.03	22.71	<.00001	0.48
	GLOB6	0.96	0.03	27.66	<.00001	0.59

Factor Estimates

Factor Covariances

		Estimate	SE	Z	p	Stand. Estimate
Internality	Internality	1.00 ^a				
	Stability	0.52	0.03	17.10	<.00001	0.52
	Globality	0.45	0.03	14.96	<.00001	0.45
Stability	Stability	1.00 ^a				
	Globality	0.70	0.02	35.47	<.00001	0.70
Globality	Globality	1.00 ^a				

^a fixed parameter

Figure1.31 今回の CFA MTMM モデルについての jamovi CFA の因子負荷量と共分散の表

りモデルに含めることについての 13.48 です。しかしこれはとくに高い MI ではありませんし、このパラメータをモデルに含める妥当な根拠もありませんし、すでにより当てはまりが得られています。ですからここでも答えは、修正しない、です。

MI を使ってモデルに新しいパラメータを追加していく場合には、追加のたびに (あるいは除外のたびに)。ソフトウェアによっては、モデル適合度を改善するために取り除くべきパラメータを MI が

示すこともあります) 必ず MI の表を確認し直してください。MI は毎回更新されるからです。

Factor Loadings – Modification Indices			
	Internality	Stability	Globality
INT1		1.41	0.16
INT2		4.86e-4	0.03
INT3		5.47	6.61
INT4		1.05e-6	2.66
INT5		0.24	1.68
INT6		12.60	24.52
STAB1	1.48		1.62
STAB2	3.06		0.12
STAB3	1.31		1.08
STAB4	3.10		2.88
STAB5	0.01		8.40
STAB6	1.31		1.05
GLOB1	0.52	0.23	
GLOB2	0.60	0.53	
GLOB3	2.85	0.04	
GLOB4	4.33	12.72	
GLOB5	7.23	0.12	
GLOB6	3.44	6.03	

Figure1.32 jamovi CFA の因子負荷量の修正指標

1.5

内的整合性による信頼性分析

EFA と CFA を使った最初の尺度開発の過程を経ると、異なる標本を使った CFA でも尺度がしっかり持ちこたえる段階に到達しているはずです。この段階でもうひとつ関心を持ちそうなのが、観測変数を合成した尺度によって因子がどれだけうまく測定されているかを見ることです。

心理測定では、ある尺度が心理学的な構成概念をどれだけ一貫して測定しているかについての情報を得るために、信頼性分析を用います (セクション ??参照)。ここで問題にするのは**内的整合性**で、これは測定尺度を構成する個々の項目すべてにわたる一貫性のことです。ですから V1, V2, V3, V4, V5 という観測項目変数があるとき、これらの項目が背後の構成概念を測るうえでどれだけ内的

Residual Covariances – Modification Indices																		
	INT1	INT2	INT3	INT4	INT5	INT6	STAB1	STAB2	STAB3	STAB4	STAB5	STAB6	GLOB1	GLOB2	GLOB3	GLOB4	GLOB5	GLOB6
INT1		0.85	13.48	0.57	11.62	11.83		0.02	2.16	0.18	0.05	0.11		0.13	1.04	1.51	1.76	0.02
INT2			1.17	2.93e-4	0.22	1.32	4.33		0.02	0.15	1.73	0.21	0.09		0.13	0.07	2.65	0.84
INT3				2.43	0.26	1.52	0.04	1.67		1.53	0.01	0.26	4.24	0.02	0.11	1.27	0.07	0.07
INT4					1.08	0.30	2.73	3.24	0.46		1.70	0.14	0.05	0.86	0.43	0.89	5.99	1.73
INT5						2.79	0.74	0.00	1.82	1.86		1.96	0.03	0.22	0.18	0.20		
INT6							0.29	2.92e-4	1.84	0.37	0.01		6.88	0.14	2.75	0.74	1.72	
STAB1								5.21	8.32	9.64	2.07	2.54		6.10e-6	0.35	1.34	0.66	1.67
STAB2									2.20	11.04	0.04	0.23	3.32		0.06	2.16	0.77	1.88
STAB3										7.41	11.37	1.38	4.36	2.45		0.04	10.30	0.62
STAB4											0.03	1.99		0.72	0.78		0.95	0.95
STAB5												1.14	0.94	0.11	7.63	4.34	0.09	1.64
STAB6													3.21	3.49			1.34	
GLOB1														0.02	1.67	1.66	0.16	0.56
GLOB2															0.88	2.48	1.82	4.37
GLOB3																3.30	0.94	2.20
GLOB4																	0.41	3.60
GLOB5																		1.49e-6
GLOB6																		

Figure1.33 jamovi CFA の残差共分散の修正指標

に整合しているかを示す統計量を計算できます。

尺度の内的整合性を確認するのによく使われる統計量が **Cronbach のアルファ** です (**Cronbach1951**)。Cronbach のアルファは等価性の指標です (尺度項目の異なる組み合わせが同じ測定結果を与えるかどうか、ということです)。等価性は、尺度項目を 2 つのグループに分け (“折半法”), その 2 つの部分の分析が同程度の結果を与えるかどうかを見ることで検討されます。もちろん項目の分け方はいくらでもあります, ありうるすべての分割を行えば, 折半係数の全体的なパターンを反映した統計量を作ることができます。Cronbach のアルファ (α) がまさにその統計量で, 尺度のすべての折半係数の関数になっています。ある構成概念を測る項目群 (たとえば外向性尺度) のアルファが 0.80 であれば, その尺度の誤差分散の割合は 0.20 です。つまり, アルファが 0.80 の尺度にはおよそ 20% の誤差が含まれているということです。

ただし (そしてこれは大きな “ただし” です), Cronbach のアルファは次元性の指標ではありません (つまり尺度が複数の関連する構成概念ではなく単一の因子や構成概念を測っていることを示すもの, ではないということです)。多次元的な尺度は, 次元ごとに別々に評価しなければアルファを過小推定させますが, アルファが高いからといって次元性の証拠になるわけではありません。ですからアルファが 0.80 であっても, 背後にある単一の構成概念の 80% が説明されているという意味にはなりません。その 80% が, 複数の背後の構成概念から来ている可能性もあるのです。だからこそ, 先に EFA や CFA をやっておくことが役に立つわけです。

さらにアルファのもうひとつの特徴は, 標本固有になりやすいことです。つまり尺度の性質というより, その尺度が使われた標本の性質なのです。偏った標本, 代表性のない標本, 小さな標本は, 大きく代表的な標本とはまるで違うアルファ係数を出すことがあります。大きな標本どうしてもアルファは変わりうるのです。それでもこうした限界にもかかわらず, Cronbach のアルファは内的整合性による信頼性の推定として心理学で広く使われてきました。計算も理解も解釈もかなり簡単ですので, たとえば別の場面や母集団の別の標本に尺度を実施したときに, 尺度の性能を最初に確認するのに役立ちます。

代わりになるのが **McDonald のオメガ** (ω) で, jamovi はこの統計量も出力します。アルファは (a) 残差間に相関がない, (b) 項目の負荷量が等しい, (c) 尺度が次元である, という仮定を置きますが, オメガはこれらを置きませんので, より頑健な信頼性の統計量になります。これらの仮定が破られていなければアルファとオメガは似た値になりますが, 破られているならオメガを使うべきです。

アルファやオメガについて, “十分によい” 値の目安となる閾値が示されることがあります。たとえばアルファが 0.70 なら “許容できる”, 0.80 なら “よい” 信頼性だ, といったものです。しかしこれは, その尺度が何を測ろうとしているかによりますので, こうした閾値は慎重に使うべきです。アルファやオメガが 0.70 なら尺度の誤差分散は 30%, 0.80 なら 20% である, と単純に述べるほうがよいかもしれません。

アルファは高すぎる可能性があります。おそらくあります。アルファ係数が 0.95 を超えている場合、項目間の相関が高く、測定に冗長すぎる特殊性が入り込んでいる可能性を示しており、測定している構成概念が狭すぎるおそれがあります。

1.5.1 jamovi での信頼性分析




Figure1.34 jamovi の信頼性分析ウィンドウ

信頼性分析を行うための第3のパーソナリティデータの標本が、bfi_sample3.csv ファイルにあります。ここでも、25 のパーソナリティ項目変数が連続量としてコード化されていることを確認し

てください。jamovi で信頼性分析を実行するには、次のようにします。

- jamovi のメインのボタンバーから **Factor - Reliability Analysis** を選び、信頼性分析のウィンドウを開きます (図 ??)。
- 5 つの A 変数を選んで 'Items' のボックスに移します。
- “Reverse Scaled Items” のオプションで, “Normal Scaled Items” のボックスにある変数 **A1** を選び, “Reverse Scaled Items” のボックスへ移します。
- そのほかのオプションも図 ??のように適宜チェックします。

終わったら, jamovi の結果ウィンドウに目を移してください。図 ??のようなものが見えるはずです。これは協調性尺度の Cronbach のアルファ係数が 0.70 であることを示しています。つまり協調性尺度得点の 30% 弱が誤差分散だということです。McDonald のオメガも出ていて, こちらは 0.72 で, アルファとあまり変わりません。

特定の項目を尺度から落とした場合にアルファやオメガがどれだけ改善するかも確認できます。たとえば項目 A1 を落とすと, アルファは 0.72 に, オメガは 0.74 に上がります。大きな増加ではありませんので, おそらくやる価値はないでしょう。

Reliability Analysis

Scale Reliability Statistics					
	mean	sd	Cronbach's α	McDonald's ω	
scale	4.650	0.900	0.701	0.720	

Item Reliability Statistics					
	mean	sd	item-rest correlation	if item dropped	
				Cronbach's α	McDonald's ω
A1 ^a	4.628	1.374	0.287	0.722	0.735
A2	4.676	1.237	0.544	0.619	0.652
A3	4.640	1.301	0.608	0.588	0.607
A4	4.828	1.422	0.404	0.676	0.701
A5	4.480	1.327	0.474	0.645	0.664

^a reverse scaled item

Figure1.35 協調性因子についての jamovi の信頼性分析の結果

.....

尺度の統計量 (アルファとオメガ) を計算して確認する手順は, 他のすべての尺度でも同じです (結果は省略します)。誠実性 (アルファ = 0.73, オメガ = 0.74), 外向性 (アルファ = 0.76, オメガ = 0.76), 神経症傾向 (アルファ = 0.81, オメガ = 0.82), 開放性 (アルファ = 0.60, オメガ = 0.62) と

なりました。つまり開放性については尺度得点の誤差分散が 40% あり、これは高い値です。開放性は、パーソナリティ特性の信頼できる測定として、他のパーソナリティ尺度よりかなり一貫性が低いということを示しています。

1.6

要約

因子分析とその関連手法を扱ったこの章では、データセットの中の関係のパターンを検討する統計分析を紹介し、実際にやってみました。具体的には次のものを扱いました。

- 探索的因子分析 (EFA)。EFA はデータセットの背後にある潜在因子を特定するための統計的手法です。各観測変数は、因子負荷量で示される程度に潜在因子を表しているものとして概念化されます。研究者は EFA をデータ縮約の手段としても使います。つまり、後続の分析のために新しい因子変数へまとめられる観測変数を特定するのです (セクション ??)。
- 主成分分析 (PCA) はデータ縮約の手法で、厳密に言えば背後にある潜在因子を特定するものではありません。PCA は単に、観測変数の線形結合を作り出すだけのものです (セクション ??)。
- 確認的因子分析 (CFA)。EFA とは違い、CFA ではデータの中の変数がどう関連しているかについての考え、つまりモデルから出発します。そのうえでモデルを観測データに対して検証し、モデルがデータにどれだけよく当てはまるかを評価します (セクション ??)。
- 多特性多方法 (MTMM) の CFA では、潜在因子と方法分散の両方をモデルに含めます。異なる方法論的アプローチが使われていて方法分散が重要な検討事項になる場合に役立つやり方です (セクション ??)。
- 内的整合性による信頼性分析。この形の信頼性分析は、ある尺度が測定しようとしている (心理学的) 構成概念をどれだけ一貫して測定しているかを検討します (セクション ??)。