

1. ベイズ統計学

現実の問題に関する我々の推論には、想像可能なあらゆる確信の度合いが存在する。最も確からしいものから、道徳的な証拠という最も不確かなものまで。ゆえに、賢人は信念を証拠に釣り合わせる。

– David Hume^{*1}

本書で私がこれまでに紹介してきたアイディアは、頻度主義の立場から見た推測統計学でした。このようなやり方を採用しているのは私だけではありません。実際、心理学の学部生向けに書かれたほぼ全ての教科書では、推測統計学の理論として頻度主義の統計学者の意見が紹介されています。これはひとつの正しいやり方です。私は実用上の理由からこの教育方法を用いてきました。頻度主義の考え方は20世紀の大半に渡って統計学の学術領域を席巻しました。この席巻は応用科学者の間で殊更顕著でした。頻度主義の手法は昔も今も心理学者たちの間で使われています。頻度主義の手法は科学論文の至るところで用いられているため、統計学を学ぶ全ての学生は頻度主義の手法を理解しなければならず、さもなくば科学論文の内容を理解できません。しかし残念なことに、少なくとも私の意見では、心理学における現行の統計手法は誤用を招きやすいものであり、頻度主義への依存には批判されるべき点もあります。

この章では、私がそうように考える理由を説明した上でベイズ統計学の紹介をします。ベイズ統計学は伝統的なアプローチよりも一般に優れたアプローチであると私は考えています。

この章は2つのパートに分かれています。

セクション ??から??ではベイズ統計学の全てについて説明します。ベイジアンアプローチが有用である理由だけでなく、基本となる数学の公式もカバーしています。その後で、 t 検定のベイズ版を実行する方法を簡単に説明します (セクション ??)。

^{*1}http://en.wikiquote.org/wiki/David_Hume.

合理的エージェントによる確率的推論

ベイジアン立場では、統計的推測は信念の修正に他なりません。まずは、この世界に関する仮説の候補 h の集合について考えてみましょう。どの仮説が真であるかは分かりませんが、どの仮説が正しそうで、どの仮説が正しくなさそうかについての信念を私は多少なり持っています。データ d を観測したとき、私は元々持っていた信念を修正しなければなりません。もしある仮説とデータが整合的であれば、その仮説についての私の信念は強められます。もしその仮説とデータが整合的でなければ、その仮説についての私の信念は弱められます。これが全てなのです！ このセクションの最後にはベイジアン推論がどのように作用するかを正確に記述するつもりですが、まずは鍵となるアイデアを紹介するために簡単な例を示したいと思います。以下の推論問題を考えてみましょう。

私は傘を持ち歩いています。あなたは雨が降ると思いますか？

この問題では、私はあなたに一片のデータ (d = 私は傘を持ち歩いている) を提示しています。そして、雨が降るかどうかに関するあなたの信念あるいは仮説を私に教えてくれることを求めています。あなたが選ぶことのできる2つの選択肢 h は、今日雨が降るか、降らないかです。どうやってこの問題を解決しますか？

1.1.1 事前確率: 以前あなたが信じていたもの

あなたが最初にするべきことは、私が傘について話したことを無視して、雨についてあなたが事前に抱いていた信念を書き出すことです。これは重要なことです。新しい証拠 (データ) に照らして信念がどのように修正されたのかについてあなたが正直でありたいのであれば、あなたは絶対に、そのデータが現れる前に信じていたことについて何かを言わねばなりません！ では、あなたは今日雨が降るかどうかについて何を信じているのでしょうか？ 私がオーストラリアに住んでいること、そしてオーストラリアの多くの地域が暑くて乾燥しているということをおそらくあなたは知っていることでしょう。私が住んでいるアデレード市は地中海性気候に属しており、南カリフォルニアや南ヨーロッパや北アフリカと非常によく似た気候です。私は1月にこの文章を執筆しているので、真夏であることをあなたは仮定できるでしょう。実際に、あなたは Wikipedia^{*2} をざっと見て、アデレード市では1月の31日間に平均4.4日雨が降るという情報を見つけたかもしれませんね。他に何も知らないのであれば、アデレード市で1月に雨が降る確率はおよそ15%であり、乾燥した日である確率はおよそ85%であるとあなたは結論付けることでしょう。もしこれが本当にアデレード市の降水

^{*2}http://en.wikipedia.org/wiki/Climate_of_Adelaide

についてあなたが信じていることだとしたら (それを私が今あなたに伝えたのだから、これこそが本当にあなたが信じていることであると私は確信しています), 私がここに書いたことがあなたの**事前分布**ということになります。これを $P(h)$ と書くことにしましょう。

仮説	信念の度合い
雨の日	0.15
乾燥した日	0.85

1.1.2 尤度: データに関する理論

この推論問題を解くためには私の行動についての理論が必要となります。ダンはいつ傘を持ていくのでしょうか？ あなたはおそらく、私が大馬鹿者ではないこと、^{*3}そして私が雨の日だけに傘を持ち歩こうとしていると推察するでしょう。一方で、私に幼い子どもがいることもあなたは知っていますし、私がこの種のことについてかなり忘れっぽいと分かってもあなたは驚きはしないでしょう。

そこで、私が傘のことを思い出せるのは雨が降っている日のうちのおよそ 30% であると仮定してみましょう (私は本当にこれが苦手です)。対照的に、乾燥した日に傘を持っていくことはおよそ 5% しかないということにしましょう。こうすると、以下のような小さな表を作ることができます。

仮説	データ	
	傘あり	傘なし
雨の日	0.30	0.70
乾燥した日	0.05	0.95

この表の各セルは、特定の仮説 h が真であるという条件のもとでどのようなデータ d が観測されるかについてのあなたの信念を記述したものです。これを覚えておくことが大切です。

この“条件付き確率”は $P(d|h)$ と書き、“ h のもとでの d の確率 (the probability of d given h)”と読みます。ベイズ統計学ではこれを、仮説 h のもとでのデータ d の**尤度**と呼びます。^{*4}

^{*3}これは根拠のない盲信ですが、そういうことにして議論を進めていきましょう。

^{*4}うーん、この話はしたくないのですが、私がここで“尤度”という言葉を使うことに異を唱える統計学者もいることでしょう。“尤度”という言葉は頻度主義統計学では非常に特殊な意味を持っているので、ベイズ統計学における尤度の意味と完全に同じという訳ではない点が問題なのです。私が知る限りでは、ベイジアンにはもともと尤度に対する合意の取れた名称がなかったので、頻度主義の用語を使うことが一般的な慣習となってしまったのです。ベイジアンが頻度主義者とはずいぶん異なる使い方での言葉を使っていることが判明したという事実を除けば、このことは問題にはならなかったことでしょう。ここはさらにもうひとつの長い歴史について勉強する場所ではないのですが、大雑把に言えば、ベイジアンが“あるひとつの尤度関数”と言うときには、この表の行のひとつを指しているのが普通です。頻度主義者が同じことを言うときにも同じ表を参照するのですが、彼らにとっての“あるひとつの尤度関数”はほとんどいつでも列のひとつを指すのです。この区別は文脈によっては重要ですが、本章の目的においては重要ではありません。

1.1.3 データと仮説の同時分布

これで全ての要素が揃いました。

事前分布と尤度を書き出したので、あなたはベイズ推論に必要な全ての情報を手にしています。次に問題となるのは、この情報を私たちがどのように使うかです。結論から言えば、この状況で使うことのできる非常に簡単な等式があるのですが、重要なのは、なぜ私たちがその式を使うのかをあなたに理解してもらうことです。そこで、より基本的なアイディアからその式を構築することを試みてみたいと思います。

確率論の公式の1つから出発することにしましょう。私はその公式をかなり前に Table ?? に掲載したのですが、そのときはあまり大々的に取り上げなかったもので、おそらく無視されていたことでしょう。ここで取り上げるのは、2つのことが同時に真である確率について語る公式です。先ほどの例でいえば、今日雨が降り (i.e., 仮説 h が真である), かつ 私が傘を持っていく (i.e., データ d が観測される) 確率を計算したいということです。仮説とデータの同時確率を $P(d, h)$ と書きます。この同時確率は、事前確率 $P(h)$ と尤度 $P(d|h)$ の掛け算で計算できます。数学的には、

$$P(d, h) = P(d|h)P(h)$$

ということです。では、今日雨が降り、かつ私が傘を持っていく確率はどのくらいでしょうか？先ほど議論したように、事前確率が教えてくれるのは雨の日である確率が 15% であるということです。尤度が教えてくれるのは雨の日に私が傘のことを思い出せる確率が 30% であるということです。したがって、これらが両方とも真である確率は、これら 2 つを掛け合わせて、

$$\begin{aligned} P(\text{雨, 傘あり}) &= P(\text{傘あり}|\text{雨}) \times P(\text{雨}) \\ &= 0.30 \times 0.15 \\ &= 0.045 \end{aligned}$$

と計算することができます。別の言い方をすれば、あなたは実際に何が起こったかを知らされるよりも前に、今日雨が降ってしかも私が傘のことを思い出す確率が 4.5% であると考えることになります。ただしもちろん、起こり得る可能性は 4 通りありますよね？なので、このエクササイズを全 4 通りについて繰り返してみましょう。すると、以下のような表ができます。

	傘あり	傘なし
雨の日	0.045	0.105
乾燥した日	0.0425	0.8075

この表には 4 つの可能性のうちどれが尤もらしいかに関する全ての情報が含まれていますが、全体像をきちんと把握するためには、この表に行と列の合計を加えるのが役に立ちます。そうすると次の表が得られます。

	傘あり	傘なし	合計
雨の日	0.0450	0.1050	0.15
乾燥した日	0.0425	0.8075	0.85
合計	0.0875	0.9125	1

この表はとても便利なので、この表に書かれた全ての数字が何を教えてくれるのかについて少し考えてみましょう。まずは、行の和が新しいことを何も語っていないことに注目してください。例えば一行目の和は、傘の問題を無視したときに、今日が雨の日である確率が 15% であることを示しています。もちろんこれは私たちの事前確率なので、何も驚くことはありません。^{*5} 重要なのは数値そのものではありません。むしろ重要なのは、私たちの計算が理にかなったものであるという自信がこの数値が与えてくれることです。行の和から降水確率が分かるのと同様に、列の和からは、私が傘を持っていく確率が分かります。具体的には、一列目の和は、私が傘を持っていく確率が、平均的には (i.e., 雨の日かどうかを無視すれば) 8.75% であることを示しています。最後に、論理的に可能な 4 つの事象の総和が 1 になることに注目してください。つまり、私たちが書き下したこの表は、データと仮説の全ての可能な組み合わせに対して定義された、正則な (proper) 確率分布であるということになります。さて、この表はとても有用なので、全ての要素が何に対応しどのように書かれているのかをきちんと理解してもらいたいと思います。

	傘あり		傘なし
雨の日	$P(\text{傘あり, 雨の日})$	$P(\text{傘なし, 雨の日})$	$P(\text{雨の日})$
乾燥した日	$P(\text{傘あり, 乾燥した日})$	$P(\text{傘なし, 乾燥した日})$	$P(\text{乾燥した日})$
	$P(\text{傘あり})$		$P(\text{傘なし})$

最後に、“正しい (proper)” 統計的記法を用いてみましょう。雨の日の問題においてデータに対応するのは、私が傘を持っているか持っていないかという観測です。そこで d_1 を「私が傘を持っていくところをあなたが観測する可能性」とし、そして d_2 を「私が傘を持っていかないところをあなたが観測する可能性」とします。

同様に、 h_1 を「今日が雨の日であるという仮説」、 h_2 を「今日が雨の日ではないという仮説」とします。この記法を用いると、先ほどの表は次のようになります。

^{*5} ここではっきりさせておきたいのは、“事前” (prior) 情報とは既存の知識や信念のことであり、その情報を改善するためにデータを収集または使用する前に存在するものです。

	d_1	d_2	
h_1	$P(h_1, d_1)$	$P(h_1, d_2)$	$P(h_1)$
h_2	$P(h_2, d_1)$	$P(h_2, d_2)$	$P(h_2)$
	$P(d_1)$	$P(d_2)$	

1.1.4 ベイズの公式を使って信念を更新する

前節で作った表は、雨の日の問題を解くためのとても強力な道具です。論理的に可能な4通りをすべて考慮し、データを与えられる前にそれぞれをどれだけ確信しているかを正確に述べているからです。そろそろ、実際にデータを与えられたときに信念がどうなるかを考える番です。雨の日の問題では、私が実際に傘を持っていると告げられます。これはいささか驚くべき出来事です。表によれば、私が傘を持っていく確率は8.75%しかありません。しかしそれは納得のいく話でしょう。暑く乾燥した夏の日に傘を持っている男というのはかなり珍しいので、あなたはそんなことは予想していなかったのです。それでもデータは、それが本当だと告げています。どれだけありそうにないと思っていたにせよ、私が傘を持っているとわかったという事実を受け入れるように信念を調整しなければなりません^{*6}。この新しい知識を反映するには、修正した表は次の数値を持たなければなりません。

	傘あり	傘なし
雨の日		0
乾燥した日		0
合計	1	0

つまり事実が“傘なし”の可能性をすべて消し去りましたので、私が傘を持っていないことを意味するセルにはすべてゼロを入れなければなりません。また私が傘を持っていることは事実としてわかっていますので、 $P(\text{傘あり}) = 1$ という事実を正しく表すために、左の列の合計は1でなければなりません。

空いた2つのセルにはどんな数値を入れればよいのでしょうか。ここでも数学のことは気にせず、直感で考えてみましょう。最初に表を書き出したとき、この2つのセルはほとんど同じ数値でした。“雨で傘あり”の同時確率は4.5%，“乾燥していて傘あり”の同時確率は4.25%と計算しましたね。言い換えれば、私が実際に傘を持っていると告げる前なら、この2つの事象の確率はほとんど同じだと言ったはずですが。しかし、この2つの可能性はどちらも、私が実際に傘を持っているという事実と整合していることに注意してください。この2つの可能性の観点からすれば、ほとんど何も変

^{*6}もう少し凝るなら、傘について私が嘘をついている可能性も含めるように例を拡張できるでしょう。でも話は単純にしておきましょう。

わっていないのです。この2つの可能性が同じくらいもっともらしいということは依然として正しい、と同意していただけたと思います。ですから最終的な表に期待されるのは、“雨で傘あり”が“乾燥していて傘あり”よりわずかにもっともらしいという事実を保ちつつ、表の数値の合計が合うような数値です。たとえばこんな具合でしょうか。

	傘あり	傘なし
雨の日	0.514	0
乾燥した日	0.486	0
合計	1	0

この表が語っているのは、私が傘を持っていると告げられたあとでは、今日が雨の日である確率を51.4%，そうでない確率を48.6%だとあなたが考える，ということです。これが問題の答えです。私が傘を持っているという条件のもとでの、雨の事後確率 $P(h|d)$ は51.4%になります。

この数値はどうやって計算したのでしょうか。おそらく想像がつくでしょう。“雨”の確率が0.514だと求めるためにやったのは、“雨で傘あり”の確率0.045を“傘あり”の確率0.0875で割ることだけです。こうすると、全体の合計が1になるという要請と、データと実際に整合する2つの事象の相対的なもっともらしさを損なわないという要請の両方を満たす表ができます。同じことを気取った統計用語で言えば、ここでやったのは仮説とデータの同時確率 $P(d, h)$ をデータの周辺確率 $P(d)$ で割ることであり、これによって観測されたデータを与えられたもとでの仮説の事後確率が得られます。これを式で書くと*7次のようになります。

$$P(h|d) = \frac{P(d, h)}{P(d)}$$

ただし前節のはじめに述べたこと、つまり同時確率 $P(d, h)$ が事前確率 $P(h)$ と尤度 $P(d|h)$ の積で計算されることを思い出してください。現実には書き下せるのは事前確率と尤度ですから、それを式に戻して代入してみましょう。そうすると、事後確率について次の式が得られます。

$$P(h|d) = \frac{P(d|h)P(h)}{P(d)}$$

そしてこの式こそが**ベイズの公式**として知られているものです。これは、学習者がさまざまな仮説のもっともらしさについての事前の信念から出発し、データに直面したときにその信念をどう改めるべきかを述べています。ベイズのパラダイムでは、すべての統計的推測がこのひとつの単純なルールから流れ出てくるのです。

*7 この式が実は、前節のはじめに挙げたのと同じ基本ルールの言い換えであることに気づいたかもしれません。式の両辺に $P(d)$ を掛ければ $P(d)P(h|d) = P(d, h)$ となり、これは同時確率の計算のルールそのものです。ですからここで“新しい”ルールを導入しているわけではなく、同じルールを違うやり方で使っているだけなのです。

ベイズ的仮説検定

Chapter ??では、仮説検定への正統的なアプローチを説明しました。説明に1章まるごと必要だったのは、帰無仮説検定がとても入り組んだ仕掛けで、人々が理解に苦しむものだからです。これに対して、仮説検定へのベイズ的アプローチは驚くほど単純です。正統的な場面とよく似た設定を考えてみましょう。比較したい仮説が2つ、帰無仮説 h_0 と対立仮説 h_1 があります。実験を行う前に、どちらの仮説が正しいかについての信念 $P(h)$ を持っています。実験を行ってデータ d を得ます。頻度論の統計とは違い、ベイズ統計では帰無仮説が正しい確率について語ることが許されます。それどころか、ベイズの公式を使って**帰無仮説の事後確率**を計算できます。

$$P(h_0|d) = \frac{P(d|h_0)P(h_0)}{P(d)}$$

この式は、データ d を観測したあとに帰無仮説をどれだけ信じるべきかを正確に教えてくれます。同じように、本質的に同じ式を使って対立仮説をどれだけ信じるべきかも求められます。添字を変えるだけです。

$$P(h_1|d) = \frac{P(d|h_1)P(h_1)}{P(d)}$$

あまりに単純なので、こんな式をわざわざ書き下すのはばかげているようにさえ思えます。前節のベイズの公式をそのまま写しているだけなのですから*8。

1.2.1 ベイズファクター

実際には、ベイズ的なデータ分析者の多くは生の事後確率 $P(h_0|d)$ と $P(h_1|d)$ の形では語りません。そのかわりに**事後オッズ**比の形で語る傾向があります。賭けのようなものだと考えてください。たとえば帰無仮説の事後確率が25%、対立仮説の事後確率が75%だとしましょう。対立仮説は帰無仮説の3倍ありそうですので、対立仮説に有利なオッズが3:1である、と言います。数学的には、事後オッズを計算するには一方の事後確率をもう一方で割るだけです。

$$\frac{P(h_1|d)}{P(h_0|d)} = \frac{0.75}{0.25} = 3$$

*8もちろん、これはきわめて単純化した話です。現実のベイズ的仮説検定の複雑さはすべて、仮説 h が複雑で漠然としたものである場合に尤度 $P(d|h)$ をどう計算するかに帰着します。本書ではその複雑さには触れませんが、この単純な話はそれ自体としては正しいものの、現実入門的な統計の教科書で扱える範囲よりずっと雑然としている、ということは強調しておきたいと思います。

あるいは、同じことを上の式で書けば次のようになります。

$$\frac{P(h_1|d)}{P(h_0|d)} = \frac{P(d|h_1)}{P(d|h_0)} \times \frac{P(h_1)}{P(h_0)}$$

実のところ、この式は詳しく見ておく価値があります。ここには知っておくべき3つの項があります。左辺には事後オッズがあり、データを見たあとで帰無仮説と対立仮説の相対的なもってもらしさをどう信じているかを表します。右辺には**事前オッズ**があり、データを見る前にどう考えていたかを示します。その中間にあるのが**ベイズファクター**で、データが与える証拠の量を表します。

$$\begin{array}{ccccc} \frac{P(h_1|d)}{P(h_0|d)} & = & \frac{P(d|h_1)}{P(d|h_0)} & \times & \frac{P(h_1)}{P(h_0)} \\ \uparrow & & \uparrow & & \uparrow \\ \text{事後オッズ} & & \text{ベイズファクター} & & \text{事前オッズ} \end{array}$$

ベイズファクター (**BF** と略されることもあります) はベイズ的仮説検定のなかで特別な位置を占めています。正統的な仮説検定における p 値と似た役割を果たすからです。ベイズファクターはデータが与える証拠の強さを数量化しますので、ベイズ的仮説検定を実行したときに報告されるのはたいていベイズファクターです。事後オッズではなくベイズファクターを報告する理由は、研究者ごとに事前確率が異なるからです。帰無仮説が正しいと信じる強い偏りを持つ人もいれば、誤りだと信じる強い偏りを持つ人もいるでしょう。ですから応用研究者としての礼儀は、ベイズファクターを報告することです。そうすれば論文を読む人は誰でも、ベイズファクターに自分個人の事前オッズを掛けて、事後オッズがどうなるかを自分で求められます。いずれにせよ慣例として、帰無仮説と対立仮説を同等に扱っているふりをするのが好まれます。その場合、事前オッズは1になり、事後オッズはベイズファクターと同じになります。

1.2.2 ベイズファクターを解釈する

ベイズファクターの本当に良いところのひとつは、その数値がそれ自体で意味を持っていることです。実験を行ってベイズファクターが4と計算されたなら、データが与える証拠は対立仮説に有利な4:1の賭け率に相当する、ということです。とはいえ、科学的な文脈で意味があるとみなされる証拠の基準を数量化しようという試みもいくつかあります。もっとも広く使われているのは **Jeffreys1961** と **Kass1995** によるものです。2つのうち、私は少し保守的な **Kass1995** の表のほうを好みます。それがこちらです。

ベイズファクター	解釈
1 - 3	無視できる証拠
3 - 20	積極的な証拠
20 - 150	強い証拠
>150	非常に強い証拠

正直に言えば、**Kass1995** の基準ですら少し甘いと思います。私に決めさせてもらえるなら、“積極的な証拠”の区分は“弱い証拠”と呼んだでしょう。私にとって 3:1 から 20:1 の範囲は、せいぜい“弱い”か“ささやかな”証拠です。とはいえここに厳格なルールはありません。何を強い証拠とし何を弱い証拠とするかは、あなたがどれだけ保守的かと、ある知見を“真”と呼ぶためにあなたの属するコミュニティが求める基準に完全に依存します。

いずれにせよ、上に挙げた数値はベイズファクターが 1 より大きい場合 (つまり証拠が対立仮説に有利な場合) に意味を持つことに注意してください。とはいえ、正統的なアプローチに対するベイズ的アプローチの大きな実務上の利点のひとつは、帰無仮説を支持する証拠も数量化できることです。その場合、ベイズファクターは 1 より小さくなります。1 より小さいベイズファクターをそのまま報告することもできますが、正直なところ私には紛らわしく感じられます。たとえば帰無仮説のもとでのデータの尤度 $P(d|h_0)$ が 0.2、対立仮説のもとでの対応する尤度 $P(d|h_1)$ が 0.1 だとしましょう。上に示した式を使えば、ベイズファクターは次のようになります。

$$BF = \frac{P(d|h_1)}{P(d|h_0)} = \frac{0.1}{0.2} = 0.5$$

文字どおり読めば、この結果は対立仮説に有利な証拠が 0.5 対 1 だと言っていることになります。私にはこれが理解しにくいのです。私には、式を“ひっくり返して”帰無仮説に有利な証拠の量を報告するほうがずっと納得がいきます。つまり次のように計算するわけです。

$$BF' = \frac{P(d|h_0)}{P(d|h_1)} = \frac{0.2}{0.1} = 2$$

そして帰無仮説に有利なベイズファクターが 2:1 である、と報告します。こちらのほうがずっとわかりやすいですし、上の表を使って解釈できます。

1.3

なぜベイズ主義者になるのか

ここまでは、ベイズ統計を支える論理だけに焦点を当ててきました。“信念の度合いとしての確率”という考え方と、それが合理的な主体が世界についてどう推論すべきかについて何を含意するかを話してきました。あなたが自分で答えなければならない問いはこうです。あなたはどうやって統計をやりたいのか。標本分布と p 値に判断を委ねる正統派の統計家になりたいのか。それとも事前の信念やベイズファクター、合理的な信念改訂のルールに頼るベイズ主義者になりたいのか。正直に言って、この問いに私が代わりに答えることはできません。結局は、あなたが何を正しいと考えるかによります。決めるのはあなたであり、あなただけです。そのうえで、私がベイズ的アプローチを好む理由については少し語れます。

1.3.1 思っているとおりの意味を持つ統計

あんたはその言葉を使い続けているが、それがあんたの思っている意味だとは思えないね。

– Inigo Montoya, プリンセス・ブライド^{*9}

私にとってベイズ的アプローチの最大の利点のひとつは、正しい問いに答えてくれることです。ベイズの枠組みでは、“仮説が正しい確率”について語ることがまったく理にかなっていませんし、許されてもいます。その確率を計算しようとするさえできます。結局のところ、それこそ統計的検定に教えてもらいたいことではないでしょうか。生身の人間からすれば、何が真で何がそうでないかを判断することこそ、統計をやる目的そのものに思えるはずです。真実が何かははっきりわからないときはいつでも、確率論の言葉を使って“理論 A が正しい確率は 80%、理論 B が正しい確率は 20% だ”というように言うべきです。

人間にとってはあまりにも当たり前に思えるのに、正統的な枠組みではこれが明確に禁じられています。頻度主義者にとって、“理論が正しい”というのは繰り返し可能な事象ではありませんので、そうした言明は無意味なのです。理論は正しいか正しくないかのどちらかであり、どれだけ言いたくても確率的な言明は許されません。セクション ?? で、 p 値を帰無仮説が正しい確率として解釈しないように繰り返し警告したのは理由があるのです。ほとんどすべての統計の教科書がその警告を繰り返さざるをえないのにも理由があります。それは、人々がその解釈であってほしいと切に願っているからです。頻度主義の教義はさておき、学部生を教え、日々データ分析をしてきた経験から私が思うのは、たいていの生身の人間は“仮説が正しい確率”が意味を持つと考えているだけでなく、それこそがもっとも関心のあることだと考えている、ということです。あまりに魅力的な考えなので、訓練を受けた統計家でさえ p 値をこう解釈しようとする誤りに陥ります。たとえば次は、2013 年の Newspoll の公式報告からの引用で、彼らの (頻度論的な) データ分析をどう解釈するかを説明したものです^{*10}。

本報告書では、該当する箇所統計的に有意な変化を記している。有意性検定はすべて 95 パーセントの信頼水準にもとづいている。これはつまり、ある変化が統計的に有意だと記されている場合、本当の変化が起きた確率が 95 パーセントであるということであり、単なる偶然の変動によるものではないということである。(強調は引用者による)

違います。それは $p < .05$ の意味ではありません。頻度論の統計家にとって 95% の信頼というのは、

^{*9}<http://www.imdb.com/title/tt0093779/quotes>。ついでに言っておくと、頻度論的な手法に文句を言うためにこの引用を使ったのは私が最初ではありません。Rich Morey らが先に思いつきました。この文脈で使うには最高の引用ですし、プリンセス・ブライドを引用する機会は逃したくないので、恥ずかしげもなく拝借しています。

^{*10}<http://about.abc.net.au/reports-publications/appreciation-survey-summary-report-2013/>

そういう意味ではありません。太字の部分は端的に誤りです。正統的な手法は“本当の変化が起きた確率は 95% である”と告げることはできません。これは頻度論的な確率を割り当てられる種類の事象ではないからです。イデオロギー的な頻度主義者にとって、この文は無意味であるはずで、より実用主義的な頻度主義者であっても、これは p 値の誤った定義です。正統的な統計の道具に頼りたいのであれば、これは単純に言うてはいけない、正しくない言い方なのです。

一方、あなたがベイズ主義者だとしましょう。太字の箇所は p 値の定義としては誤りですが、ベイズ主義者が対立仮説の事後確率が 95% を超えると言うときの意味とほぼぴったり一致します。そしてここが肝心なところ。本当に報告したいのがベイズの事後確率なのだとしたら、なぜ正統的な手法を使おうとするのでしょうか。ベイズ的な主張をしたいのなら、ベイズ主義者になってベイズの道具を使えばよいだけです。

私自身について言えば、ベイズの立場に移って何がいちばん解放感があったかというと、この点でした。いったん飛び移ってしまえば、 p 値の直感に反する定義に頭を悩ませる必要はもうありません。真の平均がある区間に入ると 95% の確信をもって言えない理由を、わざわざ覚えておく必要もありません。やるべきことは、研究を行う前に何を信じていたかを正直に述べ、それによって何を学んだかを報告することだけです。よさそうでしょう。私にとって、これがベイズ的アプローチの大きな約束です。本当にやりたい分析をやり、データが語っていると本当に信じることを述べるのです。

1.3.2 信頼できる証拠の基準

[p が].02 を下回るなら、[帰無] 仮説が事実の全体を説明できていないことが強く示唆される。慣例的な線を .05 に引き、[それより小さい p の値が] 本当の食い違いを示していると考えたら、我々が道を誤ることはそう多くないだろう。

– Sir Ronald Fisher 1925

上の Ronald Fisher 卿の言葉について考えてみましょう。彼は今日の正統的な統計のアプローチの創始者のひとりです。 p 値が本来果たすべき役割について意見を述べる資格のある人がいるとすれば、それは Fisher です。古典的な手引き *Statistical Methods for Research Workers* からのこの一節で、彼は $p < .05$ で帰無仮説を棄却することが何を意味するかをかなりはっきり述べています。彼の考えでは、 $p < .05$ を“本当の効果がある”という意味にとるなら“我々が道を誤ることはそう多くない”のです。この見方は珍しいものではありません。私の経験では、実務家の多くが Fisher とよく似た見方を口にします。要するに $p < .05$ という慣例は、かなり厳しい証拠の基準を表していると思われるわけです。

では、それはどこまで本当でしょうか。この問いに迫るひとつの方法は、 p 値をベイズファクターに変換してみて、両者を比べることです。 p 値はベイズファクターとは根本的に異なる種類の計算ですし、測っているものも同じではありませんので、これは簡単ではありません。とはいえ両者の関

係を明らかにしようという試みはいくつかあり、その結果はいささか驚くべきものです。たとえば **Johnson2013** は、(少なくとも t 検定については) $p < .05$ という閾値が、対立仮説に有利な 3:1 から 5:1 程度のベイズファクターにおおよそ対応する、というかなり説得力のある議論を示しています。もしそれが正しいなら、Fisher の主張は少し無理があります。帰無仮説が半分くらいの割合で正しい (つまり H_0 の事前確率が 0.5) として、この数値から $p < .05$ で棄却されたという条件のもとでの帰無仮説の事後確率を求めてみましょう。**Johnson2013** のデータを使うと、 $p < .05$ で帰無仮説を棄却したとき、正しいのは 80% 程度だとわかります。あなたはどうか知りませんが、私に言わせれば、判断の 20% で間違えることが確実な証拠の基準では不十分です。Fisher の主張とはまったく逆に、 $p < .05$ で棄却していればかなり頻繁に道を誤る、という事実は変わりません。まったく厳しい証拠の閾値ではないのです。

1.3.3 p 値は嘘である

ケーキは嘘だ。

ケーキは嘘だ。

ケーキは嘘だ。

ケーキは嘘だ。

– Portal^{*11}

さて、ここまで読んで、本当の問題は正統的な統計そのものではなく $p < .05$ という基準だけだ、と思っているかもしれません。ある意味ではそのとおりです。**Johnson2013** の推奨は“誰もが今すぐベイズ主義者になるべきだ”というものではありません。そうではなく、慣例的な基準を $p < .01$ の水準あたりに移すほうが賢明だろう、という提案です。これは無理のない見方ですが、私の見るところ問題はもう少し深刻です。私の意見では、ほとんどの (すべてではありませんが) 正統的な仮説検定の組み立て方には、かなり大きな問題が組み込まれています。人間が実際にどう研究しているかについてあまりにも素朴であり、そのせいでほとんどの p 値は誤っているのです。

ばかげた主張に聞こえるでしょう。では次の場面を考えてみてください。とてもわくわくする研究仮説を思いついて、それを検証する研究をデザインしました。あなたはとても几帳面なので、標本サイズを決めるために検定力分析を行い、研究を実施します。仮説検定を実行すると、 p 値 0.072 が出てきました。実に腹立たしいですね。

どうすべきでしょうか。いくつか可能性を挙げてみます。

1. 効果はないと結論し、帰無の結果として発表しようとする。
2. 効果があるかもしれないと考え、“有意傾向”の結果として発表しようとする。

^{*11}<http://knowyourmeme.com/memes/the-cake-is-a-lie>

3. あきらめて新しい研究に取りかかる。
4. データをもう少し集めて、 p 値が上がるか、あるいは (できれば) $p < .05$ という“魔法の”基準を下回るかを見る。

あなたはどれを選ぶでしょうか。読み進める前に、少し時間をとって考えてみてください。自分に正直に。とはいえ気に病みすぎないでください。どれを選んでも詰んでいるからです。著者・査読者・編集者としての自分の経験と、人から聞いた話にもとづくと、それぞれの場合に起こるのは次のようなことです。

- まず選択肢 1 から。帰無の結果として発表しようとする、論文はなかなか通りません。 $p = .072$ は本当の帰無の結果ではないと考える査読者もいるでしょう。有意傾向だと主張するはず。帰無の結果だと認めつつ、発表に値する帰無の結果もあるけれどもあなたのものはそうではない、と言う査読者もいるでしょう。1 人か 2 人は味方になってくれるかもしれませんが、通すには相当な苦戦を強いられます。
- では選択肢 2 を考えてみましょう。有意傾向の結果として発表しようとする、これは帰無の結果だから発表すべきでない主張する査読者もいれば、証拠が曖昧なのではっきり有意な結果が出るまでデータを集めるべきだと主張する査読者もいるでしょう。ここでも出版の過程はあなたに味方しません。
- $p = .072$ のような“曖昧な”結果を発表する難しさを考えると、選択肢 3、つまりあきらめて別のことをやる、が魅力的に見えるかもしれませんが、しかしそれはキャリアの自殺行為です。曖昧さに直面するたびにあきらめて新しいプロジェクトに移っていたら、あなたの仕事は決して発表されません。そして学術界で業績がなければ職を失いかねません。ですからこの選択肢もなしです。
- どうやら選択肢 4 しか残っていないようです。決定的な結果が出ていないので、データをもう少し集めて分析をやり直すことにします。もっともらしく思えますが、あいにくそうすると、あなたの p 値はすべて誤りになります。すべてです。この研究で計算した p 値だけではありません。全部です。過去に計算したすべての p 値も、これから計算するすべての p 値もです。幸いなことに、誰も気づきません。あなたの論文は掲載され、そしてあなたは嘘をついたことになります。

えっ、何ですって。最後の部分がどうして本当なのでしょう。まったく理にかなった方針に聞こえますよね。データを集めたけれども結果が決定的でなかった、決定的になるまでデータを集めたい、というだけです。何がいけないのでしょうか。

正直なところ、何もいけなくはありません。理にかなった、まっとうで合理的な行いです。現実には、まさにどの研究者もそうしています。残念ながら、Chapter ??で説明した帰無仮説検定の理論

は、これを禁じています^{*12}。理由は、この理論が実験は終了しデータはすべて揃っていると仮定しているからです。実験が終わっていると仮定していますので、考えられる判断は2つしかありません。慣例的な $p < .05$ の閾値を使っているなら、その判断は次のとおりです。

結果	行動
p が .05 未満	帰無仮説を棄却する
p が .05 より大	帰無仮説を保持する

あなたがやっているのは、判断の問題に3つめの行動を加えることです。具体的には、 p 値そのものを実験を続ける理由として使っているわけです。その結果、判断の手続きは次のようなものになります。

結果	行動
p が .05 未満	実験をやめて帰無仮説を棄却する
p が .05 から .1 のあいだ	実験を続ける
p が .1 より大	実験をやめて帰無仮説を保持する

帰無仮説検定の“基本的な”理論は、少なくとも Chapter ?? で説明した形では、こうしたことを扱えるようには作られていません。現実に“データをもっと集める”ほうを選ぶような人であれば、あなたは帰無仮説検定のルールにしたがって判断していないということになります。たまたま仮説検定と同じ判断に至ったとしても、その含意する判断の過程にはしたがっていません。そして問題を引き起こしているのは、この過程にしたがっていないことなのです^{*13}。あなたの p 値は嘘です。

さらに悪いことに、それは危険な形の嘘です。どれも小さすぎるからです。どれほどひどくなりうるかの感覚をつかんでもらうために、次の(最悪の)場面を考えてみてください。予算の乏しい、きわめて熱心な研究者で、しかも上の警告をまったく気にしていない、としましょう。2つの群を比較する研究をデザインします。 $p < .05$ の水準で有意な結果をどうしても見たいけれども、(高くつくので)必要以上のデータは集めたくありません。費用を抑えるためにデータを集め始め、新しい観測が届くたびにデータに t 検定を実行します。 t 検定が $p < .05$ と言えば実験をやめ、有意な結果を報告します。そうでなければデータを集め続けます。この実験のためにあらかじめ決めた支出の上限に達するまで、これを続けます。その上限が $N = 1000$ の観測だとしましょう。実のところ、真実は「見つかるべき本当の効果などない」、つまり帰無仮説が正しいのです。では、実験の最後まで到達し

^{*12}完全に正直であるために断っておくと、正統的な統計的検定のすべてがこのばかげた仮定に頼っているわけではありません。臨床試験などで使われることのある逐次解析の道具がいくつもあります。これらの手法はデータが到着するたびに分析されるという前提の上に作られていますので、ここで私が文句を言っているようなひどい壊れ方はしていません。ただし逐次解析の手法は、“標準的な”帰無仮説検定とはまったく異なる形で組み立てられています。入門的な教科書には載りませんし、心理学の文献でもあまり広く使われていません。ここで挙げている懸念は、これまで示したすべての正統的な検定と、私が読む論文で報告されているほとんどすべての検定に当てはまります。

^{*13}関連する問題: <http://xkcd.com/1478/>。




Figure1.1 新しいデータが届くたびに検定をやり直すと、どれだけひどいことになるのか。頻度主義者であれば、答えは“きわめてひどいことになる”である。

.....

て(正しく)効果はないと結論する確率はどれくらいでしょうか。理想的な世界なら、答えは95%の
はずです。そもそも $p < .05$ という基準の眼目はタイプIエラー率を5%に抑えることですから、こ
の状況で帰無仮説を誤って棄却する確率は5%しかないと期待したいところです。しかしそうなる保
証はありません。あなたはルールを破っているのです。有意な結果が出たかどうかを見るためにデー
タを“覗き見”しながら検定を繰り返しているのですから、何の保証もありません。

では、どれだけひどいのでしょうか。答えは図 ??の黒い実線に示してあり、驚くほどひどいもの
です。1つ観測が増えるたびにデータを覗き見していると、タイプIエラーを犯す確率は49%にな
ります。これは、まあ、本来あるべき5%よりかなり大きいですね。比較のために、次のような方針
をとった場合を想像してみてください。データを集め始めます。観測が届くたびにベイズ的な t 検
定(セクション ??)を実行し、ベイズファクターを見ます。**Johnson2013** が正しいと仮定して、3:1
のベイズファクターを p 値.05 とおおよそ同等に扱うことにします^{*14}。今回、この撃ちたがりの研究

^{*14} **Johnson2013** は $p = .05$ がその範囲のどこかにあると示唆しているのに、なぜ5:1ではなく3:1を選んだのかと思う読
者もいるでしょう。 p 値に対して寛大であろうとしたからです。5:1のベイズファクターを選んでいたら、結果はベイズ的ア
プローチにとってさらに有利に見えたはずでした。

者は次の手続きを使います。ベイズファクターが帰無仮説に有利な 3:1 以上なら、実験をやめて帰無仮説を保持する。対立仮説に有利な 3:1 以上なら、実験をやめて帰無仮説を棄却する。それ以外なら検定を続ける。さて、先ほどと同じく帰無仮説が正しいとしましょう。どうなるでしょうか。この場面についてもシミュレーションを走らせてあり、結果は図 ?? の破線に示してあります。タイプ I エラー率は、正統的な t 検定で得られていた 49% よりはるかに低くなります。

ある意味でこれは注目に値します。正統的な帰無仮説検定の眼目はタイプ I エラー率を抑えることそのものです。ベイズの手法はそもそもそれを目指して設計されてはいません。それなのに、データが入るたびに仮説検定を実行し続ける“撃ちたがりの”研究者を前にすると、ベイズ的アプローチのほうがはるかに効果的なのです。ほとんどのベイズ主義者が受け入れがたいほど緩いと考える 3:1 という基準でさえ、 $p < .05$ のルールよりずっと安全です。

1.3.4 本当にそこまでひどいのか

前節で挙げた例は、かなり極端な状況です。現実には、新しい観測が届くたびに仮説検定を実行する人はいません。ですから $p < .05$ という閾値が“実際には”49% のタイプ I エラー率 (つまり $p = .49$) に対応する、と言うのは公平ではありません。しかし、 p 値を正直なものにしたいなら、仮説検定のやり方をまったく別のものに切り替えるか、覗き見禁止という厳格なルールを徹底するかしかない、という事実は変わりません。実験をいつ終えるかをデータにもとづいて決めることは許されません。“境界線上”の p 値を見てデータをもっと集めると決めることも許されません。データを見たあとで分析の方針を変えることすら許されません。これらのルールに厳格にしたがうことが求められ、さもなければ計算した p 値は無意味になります。

そう、このルールは驚くほど厳格です。数年前に授業の演習として、学生に次の場面を考えてもらいました。 $N = 80$ 人を集めるつもりで研究を始めたとします。研究の初めのうちはルールを守り、データを見ることも検定を実行することも拒んでいます。しかし $N = 50$ に達したところで意志が折れて……覗き見してしまいます。どうでしょう、有意な結果が出ています。確かに標本サイズ $N = 80$ まで研究を続けると言ったのは覚えています、いまとなっては無意味に思えますよね。 $N = 50$ の標本サイズで結果が有意なのですから、データを集め続けるのは無駄で非効率ではないでしょうか。やめたい誘惑に駆られませんか。ほんの少しでも。しかし覚えておいてください。そうすると $p < .05$ のタイプ I エラー率は 8% まで膨れ上がるのです。論文で $p < .05$ と報告するとき、本当は $p < .08$ と言っていることになります。“たった一度の覗き見”の結果は、それほどひどいものになりうるのです。

さらに考えてみてください。学術文献は t 検定・分散分析・回帰・カイ二乗検定であふれています。本書を書くとき、私はこの検定を適当に選んだわけではありません。この 4 つの道具がほとんどの入門的な統計の本に登場するのは、これらが科学の主食だからです。そのどれもが“データの覗

き見”に対処する補正を含んでいません。どれもあなたがそれをしていないと仮定しているのです。しかしその仮定はどれだけ現実的でしょうか。現実には、実験が終わる前にデータを“覗き見”して、データの様子を見てからその後の行動を変えた人がどれだけいると思いますか。標本抽出の手続きが外的な制約で固定されている場合を除けば、答えは“ほとんどの人がやっている”だろうと私は推測します。それが起きているなら、報告された p 値は誤りだと推論できます。さらに悪いことに、彼らが実際にどんな判断過程にしたがったかがわかりませんので、 p 値が本来どうあるべきだったかを知る術がありません。研究者が使った判断の手続きがわからなければ、 p 値は計算できないのです。ですから報告された p 値は嘘のままです。

以上を踏まえて、持ち帰るべきメッセージは何でしょうか。ベイズの手法が万全だ、ということではありません。研究者がごまかそうと決めているなら、いつでもそうできます。ベイズの公式は人が嘘をつくの止められませんが、実験を仕込むのも止められません。私が言いたいのはそこではありません。私の言いたいことは、本書のいちばん初めのセクション ?? で述べたのと同じです。統計的検定を実行するのは、自分自身から自分を守るためなのです。そして“データの覗き見”がこれほど問題になるのは、正直な研究者にとってさえそれがあまりにも誘惑的だからです。統計的推測の理論はこれを認めなければなりません。 p 値を擁護して、適切に使わない研究者が悪いのだと言うこともできるでしょうが、私に言わせればそれは的外れです。研究者が自分のデータを見る可能性すら考慮しないほど人間について徹底的に素朴な統計的推測の理論は、持つ価値のある理論ではありません。要するに、私の言いたいことはこうです。

よき法は悪しき道徳から生まれる。

– Ambrosius Macrobius^{*15}

統計的検定のよいルールは、人間の弱さを認めなければなりません。罪のない者はいません。誘惑を超越した者もいません。統計的推測のよい体系は、生身の人間に使われてもなお機能すべきです。正統的な帰無仮説検定はそうではありません^{*16}。

1.4

^{*15}http://www.quotationspage.com/quotes/Ambrosius_Macrobius/

^{*16}さて、これを読んだ物知りの頻度主義者がこの節に文句を言い始めることはわかっています。いいですか、私はばかではありません。逐次解析の立場をとれば、正統的な枠組みの中でもこうした誤りを避けられることは百も承知です。中間解析を念頭に置いて研究を明示的にデザインできることも知っています。ですから確かに、ある意味で私は正統的な手法の“藁人形”版を叩いています。しかし私が叩いている藁人形は、ほとんどすべての実務家が使っているものなのです。逐次的な手法が実験心理学者のあいだで標準になり、きわめて怪しい分散分析を1日に20本読まされずに済むようになった暁には、この節を書き直して毒を弱めると約束します。しかしその日が来るまでは、現実に行われているデータ分析の慣行を前にすれば既定のベイズファクターの手法のほうがはるかに頑健である、という主張を貫きます。既定の正統的な手法はひどいものですし、それは誰もが知っていることです。

ベイズ的 t 検定

本書で扱う統計的推測の重要な問題のひとつが2つの平均の比較で、 t 検定の章 (Chapter ??) でやや詳しく論じました。そこまで思い出せるなら、 t 検定にはいくつかの版があったことを覚えているでしょう。この節では、独立標本 t 検定と対応のある標本の t 検定のベイズ版について少し話します。

1.4.1 独立標本 t 検定

もっともよくある t 検定は独立標本 t 検定で、先の t 検定の章 (Chapter ??) で使った `harpo.csv` のようなデータがあるときに出てきます。このデータには、Anastasia の授業を受けた学生と Bernadette の授業を受けた学生という2つの群がありました。答えたい問いは、この2群の学生が得た成績に差があるかどうかです。Chapter ??では、この種のデータは JASP の独立標本 t 検定で分析できると述べ、図 ??の結果が得られました。 p 値が 0.05 未満でしたので、帰無仮説を棄却します。

Results

Bayesian Independent Samples T-Test

Bayesian Independent Samples T-Test		
	BF ₁₀	error %
grade	1.755	7.565e -4

Independent Samples T-Test

Independent Samples T-Test			
	t	df	p
grade	2.115	31.000	0.043

Note. Student's t-test.

Figure1.2 JASP でのベイズ的独立標本 t 検定の結果

t 検定のベイズ版はどんなものでしょうか。‘T-Tests’-‘Bayesian Independent Samples T-Test’ のオプションを選べば、ベイズファクターの分析が得られます。ダイアログは先ほどの通常の t 検定と似ていますので、何をすればよいかはもうわかるはずです。ここでは JASP の既定の設定をそのまま受け入れましょう。そうすると図 ?? の表の結果が得られます。この表で得られるのはベイズファクター 1.755 で、このデータが与える証拠は対立仮説に有利な約 1.8:1 だということです。

先へ進む前に、正統的な検定の結果とベイズの結果の違いを強調しておく価値があります。正統的な検定によれば、かろうじてではあれ有意な結果が得られました。それでも多くの人は $p = .043$ を効果のそれなりに強い証拠として喜んで受け入れるでしょう。これに対してベイズの検定は、効果に有利なオッズが 2:1 にすら届いておらず、せいぜい非常に弱い証拠とみなされることに注意してください。私の経験では、これはかなり典型的な結果です。ベイズの手法は、帰無仮説を棄却するのにふつうより多くの証拠を求めるのです。

1.4.2 対応のある標本の t 検定

セクション ?? では `chico.csv` のデータを扱いました。学生の成績が 2 回の試験で測定されていて、試験 1 から試験 2 にかけて成績が上がったかどうかに関心がありました。どの学生も両方の試験を受けていますので、データの分析に使った道具は対応のある標本の t 検定でした。図 ?? は、通常の対応のある t 検定の結果表と、ベイズファクターの分析を並べた JASP の出力です。ここまで来れば、この出力を難なく読めるようになっていると思います。データは対立仮説に有利な約 6000:1 の証拠を与えています。かなりの確信をもって帰無仮説を棄却できそうです。

1.5

要約

この章の前半では、主にベイズ統計の理論的な土台に焦点を当てました。ベイズ推測がどう働くかの数学を紹介し (セクション ??), ベイズ的仮説検定がふつうどう行われるかのごく基本的な概観を示しました (セクション ??)。最後に、ベイズの手法が使う価値のあるものだと私が考える理由に紙幅を割きました (セクション ??)。

そのうえで実践的な例として、ベイズ的 t 検定を示しました (セクション ??)。ベイズ的アプローチをもっと学びたいのであれば、読むとよい本がたくさんあります。John Kruschke の *Doing Bayesian Data Analysis* は出発点としてかなりよく (Kruschke2011), 理論と実践のバランスがとれています。彼のアプローチはここで論じた “ベイズファクター” のアプローチとは少し異なりますので、同じ内容を繰り返すことにはなりません。認知心理学者であれば、Michael Lee と E.J. Wagenmakers の *Bayesian Cognitive Modeling* (Lee2014) を見てみるとよいでしょう。この 2 冊を挙げたのは私の

Results ▼

Paired Samples T-Test

Paired Samples T-Test

			t	df	p
grade_test2	-	grade_test1	6.475	19	< .001

Note. Student's t-test.

Bayesian Paired Samples T-Test ▼

Bayesian Paired Samples T-Test

			BF ₁₀	error %
grade_test2	-	grade_test1	5991.577	6.088e -8

Figure1.3 JASP での対応のある標本の t 検定とベイズファクターの結果

.....

分野の人にとってとくに有用だと思うからですが、よい本は他にもたくさんありますので、ぜひ探してみてください。