

Learning Statistics with JASP

A Tutorial for Psychology Students
and Other Beginners

Danielle J. Navarro
David R. Foxcroft
Thomas J. Faulkenberry



Learning Statistics with JASP:
A Tutorial for Psychology Students and Other Beginners

(Version $\frac{1}{\sqrt{2}}$)

Danielle Navarro
University of New South Wales
d.navarro@unsw.edu.au

David Foxcroft
Oxford Brookes University
david.foxcroft@brookes.ac.uk

Thomas J. Faulkenberry
Tarleton State University
faulkenberry@tarleton.edu

<http://www.learnstatswithjasp.com>

概要

Learning Statistics with JASP は、心理学を専攻する学部生に向けてふつう教えられる統計学入門の授業の内容を扱っています。本書では JASP の使い始め方に加えて、データ操作への導入も述べます。統計の観点からは、まず記述統計とグラフの作成を扱い、続いて確率論、標本抽出と推定、帰無仮説検定の章が並びます。理論を紹介したあと、分割表の分析、相関、 t 検定、回帰、分散分析、因子分析を扱います。ベイズ統計は本書の最後で扱います。

引用

Navarro, D.J., Foxcroft, D.R., & Faulkenberry, T.J. (2019). *Learning Statistics with JASP: A Tutorial for Psychology Students and Other Beginners*. (Version $\frac{1}{\sqrt{2}}$).

日本語版について

この本は **JASP ユーザの会**の有志が翻訳を担当しています。日本語の翻訳メンバーは下記の通りです (50 音順)。

- 紀ノ定保礼 (静岡理工科大学)
- 国里愛彦 (専修大学)
- 小杉考司 (専修大学；代表者。連絡先は kosugi@psy.senshu-u.ac.jp です)
- 小林穂波 (関西学院大学)
- 五島光
- 竹林由武 (福岡県立医科歯科大学)
- 徳岡大 (高松大学)
- 難波修史 (国立研究開発法人理化学研究所)
- 北條大樹 (東京大学)
- 平川真 (広島大学)
- 武藤拓之 (京都大学 こころの未来研究センター)
- 山根嵩史 (川崎医療福祉大学)

この本は完全にオープンソースです。つまり、あなたが望む方法で自由に改変することができます (ただし著者に適切なクレジットを与える限りにおいて、です。ライセンス条項を確認してください)。

最新バージョン

この本は、翻訳の進捗に合わせて随時コンパイルされ、バージョンアップしていきます。最後にコンパイルされたのは 2026 年 7 月 27 日です。

本書はクリエイティブ・コモンズ BY-SA ライセンス (CC BY-SA) バージョン 4.0 のもとで公開されています。つまり著者に適切なクレジットが与えられる限り、本書を再利用・改変・保持・改訂・再配布 (商業利用を含む) することができます。このオープン教科書のもとの版を改変したり修正したりした場合は、そのすべての版を同じライセンス、すなわち CC BY-SA のもとで再配布しなければなりません。

<https://creativecommons.org/licenses/by-sa/4.0/>

Navarro と Foxcroft による原著を JASP 向けに改訂できたのは, Tarleton State University Center for Instructional Innovation から Tom Faulkenberry へ寛大な助成が与えられたおかげです。また, 本書の美しい表紙と裏表紙のアートを制作してくださった Kristen Bowman に深く感謝します。

Table of Contents

Preface	ix
I 背景	1
第 1 章 なぜ統計学を学ぶのでしょうか?	3
1.1 心理学における統計	3
1.2 シンプソンのパラドックスへについての警告	7
1.3 心理学における統計	10
1.4 毎日の生活における統計	12
1.5 研究法は統計だけではありません	12
第 2 章 研究デザインについての短い導入	15
2.1 心理学的測定への導入	15
2.2 測定の尺度水準	19
2.3 測定の信頼性を査定する	25
2.4 変数の “role” : 予測変数と結果変数	26
2.5 実験的, あるいは非実験的研究	27
2.6 妥当性を検証する	29
2.7 交絡, 人工産物, そのほかの妥当性への脅威	34
2.8 要約	44
II Describing and displaying data with JASP	47
第 3 章 JASP 入門	49
3.1 JASP のインストール	50
3.2 分析	52
3.3 JASP へのデータ読み込み	52
3.4 スプレッドシート	54
3.5 データの尺度水準を別のものに変える	56
3.6 JASP を終了する	56
3.7 要約	57
第 4 章 記述統計	59

4.1	傾向の測定	60
4.2	変動性の指標	69
4.3	歪度と尖度	78
4.4	グループごとの記述統計	81
4.5	標準得点	82
4.6	要約	84
第 5 章	グラフを描く	87
5.1	ヒストグラム	89
5.2	ボックスプロット	90
5.3	JASP で画像を保存する方法	93
5.4	要約	94
III	統計理論	97
第 6 章	確率への招待	105
6.1	確率と統計はどちらがうの?	106
6.2	確率が意味するものは?	108
6.3	確率の理論の基礎	113
6.4	二項分布	116
6.5	正規分布	119
6.6	そのほかの便利な分布	126
6.7	要約	129
第 7 章	サンプルから未知の量を推定する	131
7.1	標本, 母集団, そして標本抽出	131
7.2	大数の法則	139
7.3	標本分布と中心極限定理	141
7.4	母数の推定	145
7.5	信頼区間を推定する	150
7.6	要約	154
第 8 章	仮説検定	163
8.1	さまざまな仮説	164
8.2	要約	168
8.3	2 種類のエラー	168
8.4	検定統計量と標本分布	170

8.5	判断を下す	172
8.6	検定の p 値	175
8.7	仮説検定の結果を報告する	178
8.8	実際に仮説検定を実行する	180
8.9	効果量, 標本サイズ, 検定力	181
8.10	考えておくべきいくつかの問題	188
IV 統計の道具		191
第 9 章	カテゴリカルデータの分析	193
9.1	The χ^2 (カイ二乗) 適合度検定	193
9.2	独立性 (もしくは連関) に関する χ^2 検定	207
9.3	連続性の補正	212
9.4	効果量	213
9.5	検定の前提条件	214
9.6	Summary	215
第 10 章	二つの平均の比較	217
10.1	1 標本 z 検定	218
10.2	要約	224
10.3	1 標本 t 検定	224
10.4	独立標本 t 検定 (Student の検定)	229
10.5	独立標本 t 検定 (Welch の検定)	238
10.6	対応のある標本の t 検定	241
10.7	片側検定	246
10.8	効果量	247
10.9	標本の正規性を確認する	250
10.10	正規でないデータを Wilcoxon 検定で検定する	255
第 11 章	相関と線形回帰	259
11.1	相関	259
11.2	回帰分析の仮定	269
11.3	モデルのチェック	270
11.4	モデル選択	278
11.5	要約	280
11.6	散布図	281

11.7	線形回帰モデルとは?	282
11.8	回帰モデルの推定	284
11.9	重回帰分析	287
11.10	回帰モデルの適合を評価する	289
11.11	回帰モデルの仮説検定	293
11.12	回帰係数について	297
第 12 章	平均を比較する (一元配置 ANOVA)	301
12.1	データセットについて	302
12.2	ANOVA と Student の t -検定との関係	302
12.3	要約	303
12.4	ANOVA のしくみ	304
12.5	ANOVA を JASP で実行する	316
12.6	効果量	317
12.7	多重比較と事後の (Post hoc) 検定	318
12.8	一要因 ANOVA の仮定	322
12.9	正規性の仮定を取り除く	326
12.10	反復測定の一要因 ANOVA	329
12.11	反復測定 ANOVA についての Friedman ノンパラメトリック検定	332
第 13 章	多元配置分散分析	337
13.1	多元配置分散分析 1: 釣合型デザイン, 交互作用なし	337
13.2	計画的比較の方法	349
13.3	多元配置分散分析 3: 非釣合型デザイン	351
13.4	要約	362
13.5	多元配置分散分析 2: 釣合型デザイン, 交互作用あり	363
13.6	効果量	368
13.7	仮定の確認	371
13.8	共分散分析 (ANCOVA)	372
13.9	線形モデルとしての分散分析	373
13.10	対比の指定を行う別の方法	380
13.11	事後検定	383
第 14 章	因子分析	395
14.1	探索的因子分析	396
14.2	主成分分析	409
14.3	確認的因子分析	416

14.4	多特性多方法 CFA	426
14.5	内的整合性による信頼性分析	437
14.6	要約	440
V 結び，代替案，そして展望		443
第 15 章	ベイズ統計学	445
15.1	合理的エージェントによる確率的推論	446
15.2	ベイズ的仮説検定	452
15.3	なぜベイズ主義者になるのか	454
15.4	ベイズ的 t 検定	463
15.5	要約	464
第 16 章	エピローグ	467
16.1	まだ見ぬ統計学	467
16.2	基礎を学ぶこと，そしてそれを JASP で学ぶこと	475
第 17 章	References	479

第 1/ $\sqrt{2}$ 版に向けた前書き

素晴らしい姉妹本 “jamovi で学ぶ統計” や “R で学ぶ統計” のアレンジ版, “JASP で学ぶ統計” をご紹介できて嬉しく思っています。このバージョンは Dani Navarro と David Foxcroft による素晴らしい前作の上に成り立っています。前作に投入された努力がなければ, この品質は達成できなかったでしょう。このアレンジ版を出そうと思ったとき, 私はシンプルな目標を持っていました。私は Navarro と Foxcroft のテキストを私自身の授業で使いたかったのですが, 直ぐにはそうでないと思ったのは, jamovi ではなく JASP を使っていたからです。どちらも素晴らしいツールなのですが, 私は JASP のほうがちょっとばかり好きなのです。というのも, jamovi がプロジェクトとして独立する前から JASP を使っていたからです。ですから, この本を世界の JASP ユーザに提供できることを嬉しく思っています。

2019 年夏、このオープン教育リソース (Open Educational Resource, OER) の執筆ための助成金を与えてくれたタールトン州立大学の Center for Instructional Innovation に感謝します。私の未来の学生 (そして世界中の学生諸君) に向けて, 高品質な統計テキストを (おそらく未来永劫) 100/

(誤字脱字などを見つけるなどして) このテキストをよくしてくれる読者を待っています。もし何か貢献できるとしたら私にメールを送ってください (あるいは Githubg ページに参加してフォークしてください)。やっちゃおうぜ!

Thomas J. Faulkenberry

July 12, 2019

バージョン 0.70 に向けた前書き

バージョン 0.65 から今回へのアップデートでは, いくつかの新しい分析が導入されました。ANOVA の章では, 反復測定 ANOVA や共分散分析 (ANCOVA) のセクションも追加しました。因子分析やそれに関連する技術の章も導入しました。この新しい要素のスタイルは, 本書の他の章と一貫していますが, 目の肥えた読者は少し概念的で実用的な説明が強調され, 代数的要素が減っていることに気づくかもしれませんね。このことが良いことかどうか分かりませんが, 代数については少し後で追加するかもしれません。しかしそれは, 私が統計を理解して教えるときの両方のアプローチ, そして私がコース内で教えているとき学生から受け取ったフィードバックを反映したものです。これに合わせて, 私も本の残りの部分に目を通し, 代数の一部を箱や枠に入れて分離してみました。これらが重要でないとか, 役に立たないというのではなく, 学生の中にはこれらを読み飛ばしたいと思うかもしれないので, 独立したパートにすることでそうした読者の役に立てばと思うのです。

このバージョンについて, 私の学生や同僚, 特に Wakefield Morys-Carter から多くのコメントやフィードバックを受けたことに感謝しています。また世界中のみなさんから提案や修正をいただきま

したことに感謝しています！新しい試みの一つとして、この本のサンプルデータファイルが jamovi にアドオンモジュールとして読み込むことができるようになった、というのがあります。Jonathon Love がこれを援助してくれたことに感謝します。

David Foxcroft
February 1st, 2019

バージョン 0.65 に向けた前書き

本書は Danielle Navarro による 'R で学ぶ統計' の応用で、統計的なソフトウェアや分析例を jamovi に置き換えたものです。R はパワフルな統計プログラミング言語ですが、教師や学生が統計学習の最初に選択するものではありません。教師や学生によっては、ポイントしてクリックするだけで分析できるタイプのソフトウェアを好みますし、それこそ jamovi でできることです。jamovi は R を使う上で二つの側面だけに狙いを定めています。ポイントしてクリックする、グラフィカルユーザインタフェース (GUI) と、多くの機能を組み合わせた関数を提供しており、SPSS や SAS のような方法を R でプログラミングする方法を提供しています。重要なことは、jamovi はいつもフリーでオープンであること、それが中心的な価値の一つであることです。jamovi は科学コミュニティによって作られ、科学コミュニティのためのものなのですから。

このバージョンでは、多くの人に下書きを読んでもらって、幾つもの提案や訂正をもらいました。特に Dr David Emery and Kirsty Walter に感謝しています。

David Foxcroft
July 1st, 2018

バージョン 0.6 にむけた前書き

この本は 2015 年にバージョン 0.5 をリリースしてからそれほど大きく変わってはいません。それでも、前より変わったと言った方がいいと思います。私は 2016 年にアデレードからシドニーに移動し、UNSW での経歴はアデレードの頃に比べて変わってしまったので、こちらにきてから取り組む機会がずいぶん減ってしまったのです。実際に振り返ってみると、少し奇妙な感じもします。ちょっとコメントすると...

- 奇妙なことですが、この本では一貫して私の性別を間違えています。これについては私自身に責任があると思います (笑)。12 ページにこのことについて言及した短い脚注があります。現実の生活では、私はジェンダー多様性を認める活動をしていて、この 2 年ほどはほとんど she/her の代名詞を使っています。しかし私は、面倒くさがりなので、この本での文章を訂正しようとは思ってません。
- バージョン 0.6 にむけて、私はそれほど大きく変更せず、指摘してもらったタイプミスやその他の間違いぐらいの、いくつかのマイナーチェンジだけにしました。ただ、セクション 14.4 で触れている **lsr** パッケージ (これはもうメンテナンスされていません) に含まれる `etaSquared` 関数に関する問題については注目してもらいたいと思います。この関数は、本書のようなシンプルな例ではうまく機能するのですが、見つけ切ってはないのですが確かにバグがあるんです! ですから、これについては注意しておいてください。
- 最も大きな変更はライセンスで、私はこれをクリエイティブ・コモンズライセンス (特に CC BY-SA 4.0) のもとでリリースすることにし、誰でも利用できるように全てのソースファイルを GitHub レポジトリに置きました。

おそらく **tidyverse** を使ったバージョンを誰かが書いてくれると思うのですが... これな近々 R にとってもっと重要なトピックになってくるでしょう。:-) では。Danielle Navarro

バージョン 0.5 にむけた前書き

今年もまたアップデートです。今回のアップデートは、本書の理論セクション全体に関わるものです。第 9,10,11 章は書き直しました。よくなっているといいんですが。同時に、17 章も全体的に新しくして、ベイズ統計にフォーカスしました。この変更によって本書は大きく改良されたと思います。私は常に、推測統計全体についての事実が従来型の観点から描かれていることに不満を感じていました。私もすでにベイズ流のデータ分析を自分の仕事に取り入れているのに、です。本書のどこかにベイズの手法を入れることで、本全体として良くなったなと思えるようになりました。今回のアップデートでは他にもやりたいことがいくつかあったのですが、私はいつも授業の締め切りに追われているので、アップデートが後回しになってしまいます! Dan Navarro

February 16, 2015

バージョン 0.4 に向けた前書き

前回の前書きを書いてから一年経ってしまいました。今回はいくつか重要な変更点があります。第 3,4 章は RStudio の特徴について書くのを抑えたので、読みやすくなりましたし、第 12,13 章はカイ二乗検定と t 検定を実行するための lsr パッケージの新しい関数を使うようにしたので、補正に関する議論が lsr パッケージの新しい関数を参照するように対応させました。バージョン 0.4 の電子版では、内部参照 (すなわち、セクションごとの実際のハイパーリンクです) が改良されています。これはバージョン 0.3.1 から導入されたものです。あちこちに新しいことを入れています。多くは誤字脱字の修正 (タイポを見つけてくれたひと全てに感謝します!) で、バージョン 0.3 と 0.4 が全体的に全く違うというようなことはありません。この 12 ヶ月の間、もっと中身を充実させたいと思ってきました。反復測定 ANOVA や混合モデルについての議論がないのは、全く心苦しいところです。言い訳になりますが、進捗が出ないのは私の二人目の子供が 2013 年の初めに生まれたからで、私は昨年のほとんどを生活の維持に注力したからです。結果的に、この本のように報酬のないプロジェクトは、実際に私に賃金が支払われる仕事に追いやられることになりました。今は状況が幾分改善されましたので、バージョン 0.5 ではもっと前進できるでしょう。

私を驚かせたことの一つは、この本を入手するためのダウンロード数です。ウェブサイトの基本的なトラッキング情報を、数ヶ月前から入手できたのですが、(明らかなロボットツールを除いて) この本は一日平均 90 回ダウンロードされています。これには勇気づけられます。少なくとも何人かはこの本が便利だと思ってくれてるってことですから!

Dan Navarro

February 4, 2014

バージョン 0.3 に向けた前書き

心の中では本当にこの本を出版したくないと思ってるんです。完成してないんですから。

私がこういうときは、その言葉通りなんです。参考文献はまた十うんではないし、章のようやぐはセクションタイトルのリストに過ぎないし、索引はないし、読者向けの練習問題はないし、構成は最適とは言えないし、トピックのカバーしている範囲は私の好みを十分に反映していません。さらに、内容的に満足していないところや、書き直さないといけない図もあり、矛盾点や誤字脱字を直す時間も十分にありませんでした。言い換えると、この本は未完成なんです。もし授業の締め切りや数週間後に予定されている赤ちゃんの存在がなければ、私は本当に後悔しなかったと思います。

つまり、もしあなたが大学での教材を探しているとか、Ph.D. の学生さんで R を勉強する方法を探しているとか、統計学の一般的な興味を持っているという人であれば、注意が必要だよと言いたい

のです。あなたが見ているのは最初の下書きで、あなたの目的に沿ったものではないかもしれないからです。もし出版にお金がかかり、インターネットが周りにない世界であれば、こんな形で公開することは決して考えられないでしょう。この本に\$80のお金を出す人がいるかと思うと(これは出版社が販売するにあたって、小売価格を申し出てくれたのです)、ちょっと申し訳なく思います。しかし今は21世紀で、フリーで私のウェブサイトにはPDFを乗せることができ、プリント・オン・デマンドサービスでハードコピーを配布すれば、出版社の教科書の半額ですみます。そして私の罪悪感を和らげるため、シェアしたいと思います!覚えておいてほしいのですが、次のサイトからみなさんは無料でソフトコピー(電子版)を入手できますし、安価なハードコピーもオンラインで入手できます。

Soft copy: <http://www.compcogscisydney.com/learning-statistics-with-r.html>

Hard copy: www.lulu.com/content/13570633

とは言え、溪谷はまだ残っています: あなたが見ているのは、作業中のバージョン0.3です。もしいつの日かバージョン1.0になれば、この仕事に責任を持って、これは誰にでも使って欲しいテキストですと言いたいです。そのとき、私はおそらくインターネットに恥ずかしげもなく後悔し、道具として活用するでしょう。しかしその日が来るまでは、私ははっきりした態度は持てずに、この仕事についてアンビバレントな状態にあるというほかありません。

これを踏まえてですが、この本を強くお勧めするあるグループがあります。2013年の学部生向け研究法(DRIPとDRIP-A)を受講する心理学の学生です。あなたにとって、この本は理想出来なものになるでしょう。というのも、あなたの統計に関する講義に合わせて書かれたものだからです。もしこのノートによる欠点が発覚した場合、直ぐにそのコメントを適用して問題を修正することができます。効果的なことに、あなたのクラスに特化されたテキストを使うことができますし、それは無料で(電子版)あるいは手数料だけで(紙版)利用できるのです。さらに良いことに、このノートはすでに検証済みです。このノートのバージョン0.1は2011年のクラスですでに使われていて、バージョン0.2は2012年のクラスで使われたのです。そして今あなたが見ているのは、新しく改良されたバージョン0.3というわけです。このノートがチタンにメッキされたスティックだというつもりはありません—あなたが学生評価フォームでそう言いたいと思ったかもしれませんが、そのときはどうぞそうしてください—というのも、実際そこまでではないからです。しかし既に何年間か検証されてきていて、うまく機能してきたんだということは言っておきたいと思います。とはいえ、何か問題が生じたときにはわたしたちが直ぐに対応しますし、少なくとも教師の先生方のうち少なくとも一人は隅々までこの本を読んでいることは間違いないのです。

さてそれはさておき、この本が目指しているものが何なのかについて述べておきましょう。中心にある考えは、心理学を学ぶ人に向けて作られた統計の導入的教科書であること、です。ですから、類似の本にあなたが期待するような標準的トピックスはカバーしています。: 研究デザイン、記述統計、仮説検証の理論、 t 検定、 χ^2 検定、ANOVA、回帰などです。しかし、いくつかの章ではRの統計パッケージに言及しています。データの操作やそのほかのスクリプト、プログラミングなんかについての章も。さらにいえば、この本の目次を見たらお気づきになると思いますが、心理学の学生に統

計を教える際、これまでは無視されてきたようなことも多く含まれています。ベイズアンカ頻度主義か、という分断は確率の章で議論されますが、ネイマンとフィッシャーの仮説検定に関する不一致も扱います。確率と密度の違いについても説明します。ANOVA のアンバランスデザインにおける平方和の計算式、タイプ I, II, III の扱いについても触れます。またエピログを見ていただければ、私が追加したかったもっと発展的な要素について明らかになるでしょう。

このアプローチを取る理由は全くシンプルなものです。すなわち、学生が乗りこなせるように、そして楽しめるように、したかったのです。最近の数年間は、心理学の学部生が R を習得するのにほとんど苦労しないことに驚かされています。それは全く簡単だというわけではないですし、成績をつける基準を設定するときは少し優しめにする必要はありますが、最終的にはそこに到達できます。同様に、統計的な考え方に現れる複雑で曖昧な表現を受け入れることに対しても、学生さんはそれほど問題を感じないようです。評価基準が適切に設定されていて、それが提示されている場合は。ですから学生が習得できるのに、教えないわけにいかないでしょう？ その潜在的な能力はとても魅力的でうす。もし彼らが R を学べば、おそらく最大で最も包括的な統計ツールライブラリである CRAN にアクセスできるということでもあるのですから。そしてもし確率理論の詳細について学べば、オーソドックスな帰無仮説検定からベイズアンカの方法に乗り換えようと思ったとき、より乗り換えが容易になるのです。さらに、データ解析技術を学ぶときに高価で独自仕様になっているソフトウェアに捉われることなく、仕事に持って行くこともできます。

残念ながら、この本は全ての問題を解決する決定打ではありません。私の作業は作業中で、いつかは便利な道具になってくれると思います。数あるものの中の一つになる、そう思います。R を使う統計の基本的な導入をしようとする類書はたくさんあります。そして私の本が優れていると考えるほど、私は傲慢ではありません。でも、他の本よりも私はこの本を気に入ってますし、もしかしたら他の人もそう思ってくれるかもしれませんね。

Dan Navarro

January 13, 2013

Part I.

背景

1. なぜ統計学を学ぶのでしょうか？

「汝、質問紙調査に応えるべからず
世界情勢に関するクイズにも答えてはならぬ、
コンプライアンス上、
いかなるテストも受けてはならない。
統計学者のよかに座ることも
社会科学に関わることも許されない。」

– W.H. Auden^{*1}

1.1

心理学における統計

ほとんどの学生が驚くのですが、統計学は心理学教育のとても重要な要素です。誰も驚かないことですが、統計学は心理学教育の中でほとんど好まれることのない要素です。つまり、もしあなたが本当に統計学を愛するのであれば、心理学のクラスではなく統計のクラスに今すぐ入るべきだということです。ですから、それほど驚くべきことでもないですが、心理学がその営みの中でかなり統計学を使っているという事実を、快く思っていないほうが学生の多数派です。ですから、統計について人か持っている一般的な疑問に答えるところから始めるのがいいだろうと思います。

この問題の大半は、統計学についての考え方に大きく関係します。それは何なの？ 何のためにあるの？ そしてなぜ科学者がそれに血眼になるの？ 考えてみれば、いずれも良い質問です。最後の一つから始めましょう。全体として、科学者は何にでも統計的検定をかけることにこだわっているようです。事実、統計を使うときに、なぜわたしたちがそうするのかを人に説明するのを忘れてしまいがち

^{*1}この詩は Auden の 1946 年、*Under Which Lyre: A Reactionary Tract for the Times* が出典で、ハーバード大学の卒業式での演説の一部から持ってきました。この種のポエムの歴史は面白いですね。<http://harvardmagazine.com/2007/11/a-poets-warning.html>

です。まるで科学者間、特に社会科学者の間では、統計にかけるまでは自身の発見も信用できないという信仰じみたものがあるようです。学生諸君は、誰も次の単純な質問に答えてくれないので、わたしたちが完全にトチ狂っているのではないかと思わずにいられません。

なぜ統計をするのですか？ なぜ科学者は 常識的に 考えないんですか？

これはある意味素朴な質問ですが、良い質問でもあります。いい答え方もいくつかありますが^{*2}、私に言わせると、ベストな答えは単純な次のものです：私たちは私たち自身のことをそれほど信用してないのです。私たちは人間なので、あらゆるバイアス、誘惑、弱さから影響を受けてしまうことを心配しているのです。統計のほとんどは基本的に安全装置なのです。“常識”を使って証拠を表kするのは、直感を得ることを信用することを意味しますが、それは言語的な表現に依存しますし、正しい答えに辿り着くための人の理由づけに対する力そのものを利用するということです。ほとんどの科学者は、そのアプローチがうまく行くとは思っていません。

現に、そう考えることは心理学的な質問を投げかけているように思えます。そして私は心理学の大学で働いていますから、この少し根深い問題を掘り下げてみるのもいいかもしれないと思うのです。この“常識的に”考えるというアプローチが信用に足る、という考え方は本当に妥当でしょうか？言葉による表現は言語で構成されていて、全ての言語はバイアスを含みます－あるものは他のものよりも言いにくいですよ。それが間違っているわけでもないのに（例えば、量子電気力学は良い理論ですが、言葉で説明するのはとても難しい）。わたしたちの“肚に落ちる”という直感は、科学的な問題を解決するのには向いておらず、日々の推論のためにデザインされたものです－そしてこの生理学的な評価は文化的な変化よりも遅く、それらはわたしたちが今生きているのとは異なる世界における、日々の問題を解決するためにデザインされたもの、というべきでしょう。最も基本的なことですが、理由づけは人が“帰納的に”考えるためのもので、うまく推論し、感覚的な証拠を超えて世界を一般化するためのものなのです。もしあなたが、自分は世界のさまざまな障壁から影響されることなく考えられるんだ、と思うのであれば、そうだな、ロンドンにかかっている橋を一つあなたに売ってあげますよ。次のセクションで説明するように、私たちは既に存在するバイアスからの影響を離れて、“演繹的な”問題（推論を必要としないもの）解決をすることはできないのです。

1.1.1 信念バイアスの呪い

人は大抵の場合、とても賢いものです。私たちはこの星に共生する他のどの種よりも賢いでしょう（ほとんどの人は同意しないかもしれませんが）。私たちの心は不思議なもので、思考と理性について信じられないような特徴を発揮できるように思えます。しかしそれは、わたしたちが完璧に思考できるということではありません。そして心理学者が何年にもわたって示してみせたことのほとんどは、私た

^{*2}科学者には常識が欠如している、というのを含みます。

ちは自然な状態にいること、エビデンスを公平に評価することはとても難しく、既に存在するバイアスによってそれらが揺らいでしまうということです。これの良い例が論理的思考における**信念バイアスの影響**です。人に特定の表現が論理的に妥当かどうか (例えば、前提が正しいければ結論が正しいといえるかどうか) 判断させるとき、そうすべきではないとわかって吐いても、その結論が信じられる程度に影響される傾向があるのです。例えば、ここに結論が信じやすい妥当な議論があります。

全てのタバコは高価である (前提 1)

中毒性のあるものは安価である (前提 2)

ゆえに、中毒性のあるものの中には、タバコでないものがある (結論)

さて、結論が信じにくい、妥当な議論もあります。

中毒性のあるものは全て高価である (前提 1)

タバコの中には安価なものがある (前提 2)

ゆえに、タバコの中には中毒性がないものがある (結論)

議論#2 の論理的な構造は、議論#1 のそれと同じで、どちらも妥当なものです。しかし、第二の議論については、前提 1 が正しくないと思われる十分な理由がありますから、結果的に結論もまた正しくないと思われます。しかしトピックがどうであるかは全体には無関係です。結論が前提条件から論理的に導かれる以上、この議論は疑うべくもなく妥当なのです。つまり、妥当な議論というのは含まれる命題が真である必要はないのです。

一方で、妥当でないのに結論が信じやすい議論の例もあります。

中毒性があるものは全て高価である (前提 1)

タバコの中には安価なものがある (前提 2)

ゆえに、中毒性のないタバコもある (結論)

最後に、信じられないような結論を導く妥当でない議論の例も挙げておきましょう。

全てのタバコは高価である (前提 1)

中毒性のあるもののなかには、安価なものもある (前提 2)

ゆえに、中毒性のないタバコもある (結論)

さて、人に何が正しくて何が正しくないかに関する事前にあるバイアスを完璧に避け、論理的な美しさだけを純粋に評価できるものとしましょう。100% のひとが、妥当な議論は妥当であり、妥当でない議論を妥当だという人は 0% だと期待しますよね。さてこの実験をやってみると、あなたの取るデータは次のような感じになります。

	結論が正しそう	結論が間違っていそう
議論は妥当	100% が「妥当である」という	100% が「妥当である」という
議論は妥当でない	0% が「妥当である」という	0% が「妥当である」という

心理学のデータがこのよなものであれば (あるいは、これによく似た感じになっていれば), 私たちは安心して肚の奥底で感じた直感を信じてしまうかもしれません。つまり, 科学者の常識に基づいてデータを評価させてこそ, 完璧に OK な状態になって曖昧な統計情報に惑わされることはなくなるのです。しかし, みなさんは心理学の授業を受けてきているので, これがどうなるかはわかるでしょう。

昔の研究では, Evans1983 がほぼこれと同じような実験を実施しました。彼らが見つけたのは, 既存のバイアス (例えば信念) がデータの構造と一致していれば, 全てその人の希望する通りに進んでいくことがわかりました。:

	結論が正しそう	結論が間違っていそう
結論が妥当	92% が「妥当である」という	
結論が妥当でない		8% が「妥当である」という

完璧ではないですが, 結構いいでしょう。しかし結論の真偽についての直感が, 議論の論理的構造に反するときはどうなるのでしょうか。

	結論が正しそう	結論が間違っていそう
結論が妥当	92% が「妥当である」という	46% が「妥当である」という
結論が妥当でない	92% 「妥当である」という	8% が「妥当である」という

やれやれ, これではお話にならないですね。どうやら, 人が私たちが事前に持っている信念に矛盾する正しい議論を表示されたとき, それが正しい議論になっているということを受け止めるのはかなり難しいようです (たった 46% がそうしただけです)。さらに悪いことに, わたしたちが事前に持っているバイアスに合致する, 間違った議論を提示されたとき, ほぼ誰もその議論が間違っていると認識できないのです (間違った方を取るのが 92% もいます!)*³

そう考えたとしても, これらのデータがそれほど恐ろしいものであるわけではありません。全体的に, 偶然よりも高い確率で人は事前のバイアスを補正できているのです。なぜなら 60% のひとが正

*³皮肉なことに, この事実から私がインターネットで読んだものの 95% を説明できてしまうような気がします。

しく判断しているのですから (偶然は 50% ですからね)。そうであったとしても、もしあなたが “” 証拠に基づいて判断する” ことのプロであり、誰かが正しい判断をする確率を 60% から 95% にまで上げてくれる魔法の道具を提供してくれることになったら、あなたはそれに飛びつくでしょうね? もちろんね。有難いことに、そういうことができるツールがあるのです。マジックじゃありません。スタティスティクス (統計) です。これが #1 なぜ科学者が統計を愛するのか、の理由です。私たちは “意図も容易く” 信じたいものを信じる” のです。言い換えれば, “” データを信じる” ようになるためには、個人的なバイアスを制御するためのちょっとした手助けが必要です。これこそ統計のすることであり、統計は私たちを正直者にしてくれるのです。

1.2

シンプソンのパラドックスへの警告

以下の話は実話 (だと思う!) です。1973 年、カリフォルニア大学バークレー校では、大学院への入学者数についてある悩みが生じていました。特に問題になったのは、入学者の性別の内訳が以下のようになっていたことです。:

	志願者	合格率
男性	8442	44%
女性	4321	35%

これを見て、大学関係者は訴えられるのではないかと思ったのです*4 約 13,000 人の志願者がいて、男女の合格率に 9% の差が出たのは、偶然にしては大きすぎるからです。かなり説得力のあるデータだと思いませんか? そしてもし私が、女性に対して実際には弱いバイアスしかないとデータが示している、といったらあなたは私の頭がおかしいか、性差別主義者だと考えるでしょうね。

ところがどっこい、これは正しいのです。この志願者のデータをもっと注意深く見てみると、別の話が見えてきます (Bickel, Hammel, and O'Connell 1975)。特に、学部ごとのバイアスを見てみると、ほとんどの学部において女性志願者の方が男性志願者よりも少し高い合格率になっていることがわかります。以下に示す表は、6 大学部における志願者の概観です (プライバシーの観点から学部名は削除しています):

*4以前の版では実際に訴えられた、と書いていましたが、事実ではありませんでした。これについてはここに素敵な解説があります:<https://www.refsmmat.com/posts/2016-05-08-simpsons-paradox-berkeley.html> これを教えてくれたウィルフライド・ヴァン・ハートンに感謝します。

学部	男性		女性	
	志願者	合格率	志願者	合格率
A	825	62%	108	82%
B	560	63%	25	68%
C	325	37%	593	34%
D	417	33%	375	35%
E	191	28%	393	24%
F	272	6%	341	7%

驚くべきことに、ほとんどの学部では女性の方が男性よりも高い合格率を示しています！大学全体での合格率を見ると、女性が男性よりも低いのに。なんでこんなことに？なぜこれらの説が同時に成立するのでしょうか。

ここで何が起こったか見ていきましょう。まず、学部ごとで合格率が等しくないことに注意が必要です。すなわち、ある学部 (例えば A,B) では有資格者を高い割合で合格させていますが、他では (例えば F) 質の高い志願者であってもほとんどの候補者を不合格にするのです。ですから、ここで示した 6 学部の間で、A 学部は最も寛大で、B,C,D,E,F の順で変わっていきます。次に、男女の傾向も学部ごとで違うことがわかります。男性志願者数で学部を順序づければ、**A>B>D>C>F>E** の順になりますね (より “簡単” な学部を太字にしました)。全体として、男性は合格率の高い学部挑戦する傾向があるようです。では女性志願者の分布はどうなっているか、比べてみましょう。女性志願者の総数が多い順に学部を並べると、少し違った並びで次のようになります。**C>E>D>F>A>B**。言い換えると、このデータは女性がより “困難な” 学部へ挑戦する傾向があることを示しています。そして事実、図 1.1 を見るとわかるように、この傾向が全体的で顕著であることがわかります。この効果は**シンプソンのパラドクス**として知られています。これは一般的ではないですが、実際の生活でも起こりうることで、ほとんどの人は最初驚き、現実であることさえ信じようとしません。現実なんです。そして、そこには非常に微妙な統計学的教訓が含まれているのですが、そこから私はより重要な点を指摘したいと思います。すなわち、研究することは難しく、そこには多くの微妙な問題があり、直感に反する罠があちこちにある、ということです。これがなぜ科学者が統計を愛するのか、なぜ研究法を教えるのかについての第二の理由なのです。科学的営みは難しく、真実は時に複雑なデータの隅々に、うまく隠されているのです。

この話から離れる前に、研究法のクラスでは見過ごされがちな、重要な点を指摘しておきたいと思っています。統計は問題の一部を解くだけです。思い出して欲しいのですが、我々はバークレー校の入試が女性志願者に対して不当なバイアスをかけているのではないかと、という懸念から始めたのでした。“総合的な” データを見た時、大学は女性に対して差別的であるように見えたが、“バラバラにして” 個々人の行動を全ての学部についてみると、実際学部レベルでは、微妙ではありましたが、やや女性に有利なように動いていたのです。入試全体の女性に対するバイアスは、女性がより難しい学部へ挑戦しようと自ら選択する傾向が引き起こしたものでした。法律的な観点からは、大学に




Figure1.1 1973 年、バークレー校の入試データ。この図は少なくとも一人の女性志願者がいた 85 の学部と、女性の志願者割合の関数をプロットしたもの。このプロットは [Bickel, Hammel, and O'Connell \(1975\)](#) の図 1 を描き直したもの。円は 40 名以上の志願者がいた学部を表している。円の面積は志願者の総数の割合。十字は応募者が 40 人未満の学部を表している。

.....

非はないとするでしょう。大学院の入試は個々の学部のレベルに応じて決められますが、そうするには真っ当な理由があるのです。個々の学部のレベルにおいて、判断はほぼ偏りがありません(この微かな女性最員のバイアスは小さなものですし、学部間で一貫したものではありません)。大学は受験生にどの学部が良いかをあてがうことはできませんし、学部レベルで判断がなされますから、その選択が生み出すバイアスに対して責任を取ることはできないのです。

とまあ私のいつもの軽口が出ましたが、それで全部というわけではないですね。もちろん、社会学や心理学的な観点から考えると、「実際には、なぜこんなに大きなジェンダー差があるのか」、ということを知りたいくなります。なぜ男性が女性よりも工学部を志望するのか、そしてなぜ英文学ではそれが逆転するのでしょうか？ さらに、なぜ女性が出願しがちなバイアスがある学部は全体的に低い入学率で、男性が出願しがちな学部がそうならないのでしょうか？ それぞれの学部ではバイアスがな

いのに、ジェンダーバイアスが反映されていないのでしょうか。そうかもしれません。仮に、男性は“”“ハードサイエンス”を、女性は“” 人文科学”を好む傾向があると仮説を立ててみましょう。そしてさらに、なぜ人文学部が低い合格率なのかという理由について、政府は人文学に投資していないからだと考えてみましょう（例えば、Ph.D は政府の資金提供を受けたプロジェクトと繋がっていますから）。これがジェンダーバイアスを生み出しているのでしょうか？あるいは人文科学の価値についての、無教養なものの見方が表れているだけでしょうか？もし政府の高官が人文科学に対して、“役に立たない学問だ”ということで資金援助をカットしたらどうでしょう。これはあからさまなジェンダーバイアスに見えます。これらはいずれも統計学の範疇から外れますが、研究プロジェクトとしては重要な点です。もしあなたがジェンダーバイアスの全体的な構造的影響に興味があるのなら、おそらく集計されたデータも集計されていないデータもいずれもみたいと思うでしょう。もしバークレー校の意思決定プロセスに興味があるのなら、あなたは集計されていないデータだけ注目するでしょう。

要するに、あなたが統計学をつかって答えられない決定的な質問というのは多く存在しますが、これらの質問に対する答えはあなたがどのようにデータを分析し、解釈するかに大きな影響を与えるのです。そしてこれこそ、あなたがいつもあなたのデータを学ぶ手がかりになる道具として統計学を考えるべきだという、理由なのです。それ以上でもそれ以下でもありません。強力なツールではありますが、慎重に考えることの代わりになるものではないのです。

1.3

心理学における統計

ここまでの説明で、なぜ化学全体において統計学に注目するのか、伝わっていれば幸いです。しかし心理学で統計がどういう役割を果たしているのか、とくになぜ心理学のクラスで統計に関しての講義が多いのかについては、まだ多くの疑問を持たれているのではないかと思います。ここではそれに少し答えてみようと思います。

■ なぜ心理学はそんなに多くの統計をやるの？

もっとも正直に答えるなら、これにはいくつかの異なる答えがあり、あるものは他の理由より良いものでしょう。もっとも重要な理由は、心理学は統計科学だということです。ここでいいたいのは、私たちが学ぶ“” こと”は、人間であるということです。リアルで、複雑で、素晴らしいぐらい煩雑で、腹が立つほどネジクリ曲がった人間なのです。物理学が学ぶ“” こと”は、電子のような物質であり、物理の中では複雑な振る舞いを見せますが、電子自体は心を持っていません。意見も持っていないし、それぞれが互いに異なる奇妙で気まぐれな動きをするわけでもないし、実験の途中で飽きたりすることもないし、実験者に腹を立ててわざとデータを妨

害しようなんて考えません (私は決してそんなことしませんけど!)。基本的なレベルで、心理学は物理学よりも厳しいのです。^{*5}

基本的に皆さんには心理学者として統計を学んでもらいますが、それは皆さんが物理学よりも統計に強くなってもらう必要があるからです。実際に物理ではよく言われることなのですが、“もし統計が必要になったのなら、もう少し良い実験をするべきだ”ということがあります。このように贅沢なことを言われるのは、彼らの研究の対象が、社会学者が立ち向かっている膨大な混乱に比べると、悲しいほど単純だからです。心理学だけではありません。社会科学のほとんどが、統計学にどっぷり依存しているのです。私たちが実験者として未熟なのではなく、私たちが解くべき問題がより難しいからなのです。私たちが皆さんに統計を教えるのは、みなさんが本当に、本当にそれを必要としているからです。

■ 誰か他の人に統計をやってもらえないの？

ある程度はできるかもしれませんが、完全には無理です。皆さんが心理学をするにあたって、完璧に訓練された統計学者になる必要はありませんが、あるレベルの統計的能力に届いている必要があります。私の考えでは、全ての心理学研究者が基本的な統計力を持つべき3つの理由があります。

- － 第一に、基本的な理由から。：統計は研究デザインに深く関わっています。もしあなたが心理学的研究をうまくデザインしようと思うなら、基本的な統計について最低限の理解をしていなければなりません。
- － 第二に、研究の心理学的な側面について強くなりたいのなら、心理学的な文法を理解できるようになる必要がありますよね？心理学の文法に沿った論文のほとんどは、統計的な分析の結果を報告しています。ですから、もしあなたが本当に心理学を理解しようとするなら、他の人がそのデータをどう扱ったのかを理解する必要があります。そしてそのためには、ある程度の統計を理解していなければなりません。
- － 第三に、あなたの統計に関する部分を他の人に完全に依存することは、現実的な問題があります。：統計分析は高価なんです。もしあなたが嫌になって、でもオーストラリア政府が大学の学費にどれぐらい補助を出しているのか知りたいと思ったら、面白いことに気づくでしょう。：統計学は“国家的優先事項”のカテゴリに配置されており、他の研究領域よりもずっとずっと、やすい学費で学べるのです。これは統計学者が圧倒的に不足しているからです。ですから、心理学研究者の観点からみれば、需要と供給のルールはあなたに味方してくれません！結果として、心理学研究がしたいというあなたの実生活上の環境において、統計屋さんを雇う十分な資金がないという決定的な事実がつきつけられます。経済的な事情から、あなたは自分でやらなければならないのです。

これらの理由は研究者一般に適用できます。あなたが心理学の実践家として、その領域のトップを目指すなら、科学的な文法を読めるようになるべきですし、それらはかなり統計に依存し

^{*5}これが、物理学が私たちよりも進んでいる理由かもしれません。

ていることなのです。

■ **仕事や研究，臨床的な仕事に興味はないよ。それでも統計が必要？**

オーケー，冗談はよしこさん。それでも統計はあなたにとって重要なことだと思いますよ。統計は誰にとっても重要なものであるのと同じく，あなたにとっても重要なのです。私たちは21世紀に生きていて，データはそこらじゅうにあります。率直に言って，我々が生きているこの世界では，統計の基礎知識はサバイバルツールに近いものです！これについては次のセクションで論じましょう。

1.4

毎日の生活における統計

*“私たちは情報に溺れているが、
知識を欲しているんだ”*

－ 著者多数，オリジナルはおそらく John Naisbitt

私がレクチャーノートを書き始めた頃，最新のニュース 20 件が ABC ニュースウェブサイトにもポストされていました。これら 20 件の記事は，私が統計的トピックと呼んでいるものを何かしら含んだディスカッションが 8 件，そしてそのうち 6 件にミスがありました。もっとも一般的な間違いは，ベースラインのデータを示し忘れているというものです（たとえば，ある状況 X である特徴 Y をする人が 5% いた，という記事がありますが，それが誰にとっても共通するどれだけ一般的な特徴であるかは言わないのです！）ここで明らかにしたいことは，ジャーナリストが統計に弱いということではなくて（本当にそうかもしれないけど），統計の基礎知識は誰かがミスをしたりあなたに嘘をつくことを見つけ出す役に立つということです。実際，統計知識があると，新聞やインターネットに腹を立てることがはるかに増えます。これについてはセクション 4.1.5 で好例を見ることができるでしょう。この本の後の版では，このようなエピソードをもっと多く紹介するつもりです。

1.5

研究法は統計だけではありません

ここまで私が話してきたのは統計についてであり，私は統計が人生の全てだと思っている人だと思われたかもしれませんが。正直に言って，全くそんなことはなくて，研究法は統計よりも広い概念です。研究法についてのコースは，研究デザインのパラダイムに関するもっと多くのトピックス，特に皆さんが人間を相手に研究しようとするときに出くわす問題を扱います。とはいえ，学生の不安の

99% は統計に関するところですから、私はこのディスカッションで統計に注目して、統計の問題が便利で、重要で、恐れるものではないことを知ってもらいたいと思います。とはいえ、研究入門のクラスは統計偏重になりがちです。これは (普通) 講師が悪い人だから、ということではありません。実は、全く逆の理由です。入門クラスで統計に集中するのは、皆さんが他の研究法トレーニングを必要とする前に、統計が必要になることが常だからです。なぜかって? あなたに割り当てられる他のどの授業も、統計のトレーニングの上に成り立っているし、他の方法論的ツールよりも統計が担うところが大きいからです。学部学生にとって、自身の研究を一からデザインするよう求められることは一般的ではありません (その場合研究デザインについてもっとよく知る必要があります) が、誰かが既に設計した研究計画で収集されたデータを分析して解釈することは、まさに一般的な課題になるからです (その場合、統計が必要になるでしょう)。そういう意味で、あなたが他のどんな授業に行ってもうまくやれるようにという観点から、統計学はより緊急性が高いのです。

しかし “緊急” は “重要” とは違いますが、どちらも大事なことです。研究デザインはデータ分析と同じぐらい重要だと強調したいですし、この本はまさにそれらに時間をとっています。とはいえ、統計が普遍性を持っていて、ほとんど全ての心理学的研究にとって有用な中心的ツールを提供してくれているのに比べて、研究法はそこまで普遍的なものではありません。誰もが知っておくべき一般的原則はありますが、研究デザインは非常に個別的なもので、皆さんが取り掛かろうとする領域ごとに特殊なものでもあります。細かいことが重要な領域であって、そうした詳細については統計入門や研究法のクラスでは普通扱いません。

2. 研究デザインについての短い導入

実験が終わった後に統計家にアドバイスを求めるのは、ほとんどの場合、検死を依頼するようなものです。統計家に言えるのは、せいぜいその実験が何で死んだかということくらいでしょう。

– Sir Ronald Fisher^{*1}

この章では、研究をデザインし、データを集め、そのデータ収集がうまくいっているかどうかをチェックする、といったことについての基本的なアイデアを考えることから始めましょう。あなた自身が研究をデザインするのに十分な情報は得られないかもしれませんが、ほかの人がやった研究を評価するのに必要な基本的ツールの多くは手に入られると思います。ただ、この本の狙いはデータの収集よりもデータの分析にありますので、ごくあっさり全体像を見るにとどめます。この章は、ふたつの意味で「特別」です。まず、ほかの章よりも心理学に特有の状況を扱っています。次に、研究の方法論についての科学的問題にかなりの重点を置いていて、データ分析の統計的問題にはそれほど重点を置いていません。とはいえ、このふたつの問題はお互いに関係していますから、この問題をちょっとばかり詳しく扱うのが、統計のテキストの伝統的なやり方になっています。この章は、研究デザインについては [Campbell and Stanley \(1963\)](#) に、測定の尺度に関する議論については [Stevens \(1946\)](#) に依っています。

2.1

心理学的測定への導入

データ収集を理解するにはまず、**測定**について考えなければならない。つまり、ここで我々がやろうとしていることは、人の行動や心についての何かを測るということだ。では「測る」とは何だろう？

^{*1}第1回インド統計会議会長講演, 1938. 出典: http://en.wikiquote.org/wiki/Ronald_Fisher

2.1.1 心理学的測定についてのいくつかの考え方

測定そのものは微妙な概念だが、基本的には「なにか」に数字やラベル、あるいはほかのよく定義された記述を割り当てる方法を見つけること、と言える。であるから、次に挙げるようなものも心理学的測定の中に含まれる。

- 私の **年齢** は 33 歳です。
- 私は**アンチョビ**が 好きではない。
- 私の **染色体的な性別** は 男性である。
- 私の **性自認** は 男性である^{*2}

上の短いリストには**太字になっているところ**が“測定されようとしている対象”であり、**イタリックになっているところ**が“測定されたもの”である。じつは、それぞれのケースで生じうる測定全体について考えることで、少し拡張することができる。

- 私の**年齢**は (年単位で数えるから)0, 1, 2, 3 ..., となる。上限がどうなるかはちょっと曖昧だが、現実的には最大でも 150 ぐらいだと思っていれば良い。それ以上生きた人はいないのだから。
- **アンチョビ**が好きかどうかは、答え方として好きあるいは嫌い、はたまたどちらでもないとか、ときどきね、と答えるだろう。
- 私の**染色体的な性別**は、ほぼ間違いなく男性(XY)か、女性(XX)だろうが、ごくわずかな例外もある。それは**クラインフェルター症候群(XXY)**というやつで、ほとんど男性の染色体とおなじである。そのほかにもこうした可能性はあるかもしれない。
- 私の**性自認**は男性か女性のいずれかだが、私の染色体的な性別とは一致していない。私は自分をどちらでもないとするかもしれないし、はっきりとトランスジェンダーだ、と答えるかもしれない。

このように、ある事象(年齢とか)は取りうる値が明らかなものもあれば、ちょっと特殊なものも

^{*2}うむ... ちょっと引かかるだろ? このセクションはこの本の最も古いパートだから、ちょっと時代遅れで小っ恥ずかしいものになっている。これが書かれているのは 2010 年で、ここに書いてある事実は確かに正しい。これを今の 2018 年にも取って考えると、私はもう 33 歳じゃないし、驚くことじゃない。私の染色体が変わったとは思えないし、私の遺伝子は今も XY 型だともう。一方、性自認は... ううん。タイトルページには、今私のことを Daniel じゃなくて Danielle と書いているからわかってもらえると思うけど(訳註; Daniel は男性名的表記, Danielle は女性名的表記)、最近では性別に関するアンケートでは男性と答えないようにしていて、むしろ“she/her”で呼ばれる方が嬉しくなっている。話すと長くなるけど! 実は、この本ではこのことをどう扱うか少し考えた。この本では作者の声が直接含まれているので、この本での表記を全部 Danielle にすると随分違ったものになるんじゃないかと思う。でもそれはかなりの作業量になるから、この本での私の名前は“Dan”で通そうと思う。とにかく Danielle のニックネームとして Dan はバッチリだと思わない? ちっちゃいことは気にしない。私のことをどう呼んだら良いかわからない読者のために、少しでも気楽になってもらえればと思ってこれを書いている。あ、アンチョビはまだ好きじゃないけどね(笑)。

ある。しかし、誰かの年齢と言ってもこれよりちょっと微妙なものであることは指摘しておきたい。たとえば、上の例では年齢を一年単位で測定することを想定していた。しかしもしあなたが発達心理学者であったら、これはちょっと雑すぎて、年齢は年と月(月齢)で表現するかもしれない(もし子供が2歳11ヶ月であれば、これを“2.11”と書いたりする)。新生児に興味があれば、年齢は生まれてから何日めかで表現するだろうし、もしかすると生後何時間経ったかで表現するかもしれない。言い換えると、あなたが測定値に何を許容するかというのが重要なのだ。

これをもう少し詳しく見てみると、“年齢”という概念は実際まったく正確ではないことに気づかれるかもしれない。一般的に言って、我々が“年齢”というときは、暗に“生まれてからの時間の長さ”を意味している。しかし、それが常に正しいわけではない。たとえば、新生児の目の動きをどのようにコントロールしているかに興味があったとしよう。もしそれぐらい若い子に興味があれば、あなたは“生まれたとき”から始めることが意味のある点だとは思わなくなるかもしれない。アリスが生後3週間で、ビアンカが1週間後に生まれてきたとして、彼女らに“生まれてから2時間後”に出会った時彼女らが“同じ年齢”だったといえるだろうか？社会的には、日常生活で年齢について語る時に、生まれた時を起点とするが、それは世界に生まれたって独立した存在として自らを扱ってきた人としての時間の総量、として定義しているからだ。科学的な観点からは、興味があるのはそこだけではない。生物としての人間を考えるなら、概念的には意識を持った生き物として成長してきた過程を考える方が便利だし、その観点から行くとアリスとビアンカは同じ年齢だとは言えない。だからあなたが“年齢”という概念を定義しようとするなら、ふたつのやり方があることになる。意識の時間的長さか、生まれてからの時間的長さか、である。大人を対象にしているときは、その差はほとんど意味をなさないが、新生児の場合はそうではないのだ。

この問題を超えた、方法論的な問いがある。どの“測定法”が、誰かの年齢を見出すのに用いられるべきだろうか。上で述べたように、そこにはいくつかの可能性がある。

- 単に“あなたは何歳ですか”と尋ねる。この事故報告式は早くて、やすくて、簡単だ。しかしその人が質問を十分理解している場合に限るし、人によっては歳を誤魔化すことがある。
- 権威者(例えば親御さん)に“あなたのお子さんは何歳ですか?”と尋ねる。この方法は早くて、子供を扱うときには簡単な方法だ。親はいつも周りにいるのだから。でも“意識を持ち始めてから”を考えるとときはうまくいかない。というのも、親はその子がいつ意識を持ち始めたかを知る由がないからだ。そのときは、別の権威者(例えば産科医)に頼る必要があるだろう。
- 公的な記録を調べる。例えば出生証明書とか、死亡証明書である。これは時間はかかるし、手間もかかるが、それなりの利点がある(例えば故人を対象にする場合は。)

2.1.2 操作可能にする：あなたの測定を定義する

上の章で論じられていたことはすべて、**操作化**という概念に関係している。もう少しこの概念を正確にいうと、操作化とは大きな意味があるが、何かしらぼんやりした概念を、正確な測定に落とし込む手続きのことを指す。この操作化のプロセスは、以下のいくつかの異なる要素を含んでいる。

- あなたが測定しようとしているものを明確にすること。例えば“年齢”も“生まれてからの時間”なのか、“意識が芽生えてからの時間”なのか、どちらがあなたの研究の文脈に沿うものなのか？
- それを測定するのにどの手法にするのか決定すること。事故報告式の測定年齢を使うのか、親に聞くのか、公的な記録を取るのか、どれだろう？ もし事故報告式を使うのなら、どういうフレーズでその質問をするだろう？
- 測定が取りうる値のセットを決定すること。この値は常に数量的なものとは限らないことに注意しよう。測定する年齢は数量的かもしれないが、どんな値が許されているのかをよく考えて見てほしい。年単位の年齢なのか、年月なのか、日、時間、どれだろう？ ほかの測定の種類によっては（例えばジェンダー）、値は数量的なものにならない。しかしすでに述べたように、私たちはどんな値が許されているかを考える必要があるのだ。もし事故報告式でジェンダーを尋ねたら、私たちは相手にどんな選択肢を許すだろうか。単に“男性”か“女性”だけで十分なのか？ “その他”のオプションは必要ないのか？ あるいは、特別な選択肢を考えて、回答者自身の言葉を使うことを許すのか？ そしてもしすべての言語報告を可能な値のセットに含めるのであれば、その回答をどのように解釈するのか？

操作化はトリッキーなビジネスで、“唯一の正解”があるものではない。“年齢”や“性別”のインフォーマルな概念を操作化する方法を選択し、それをフォーマルな測定にすることを選んでも、それはあなたが何を測定したいかに依存するのだ。大抵の場合、あなたの領域で活躍している人たちの科学的コミュニティが、どうしたらいいかについて十分に確立されたアイデアをすでに持っていることと思う。いいかえると、操作化はケースバイケースで考える必要があるということだ。とはいえ、個々人の研究プロジェクトにはそれぞれ特別な問題が他にもいっぱいあるが、一般的な側面もあるものだ。

次に進む前に、用語を整理しておきたい。相互に関連する次の四つのことがある。

- **理論的構成概念**。これはあなたが測定しようとしているもの、例えば“年齢”、“性別”、“ジェンダー”や“意見”といったものだ。理論的な構成概念は直接観測されないし、実際にはちょっと曖昧なものであることが多い。
- **測定**。測定はあなたが客観的にしようとする際につかうツールや手法のこと。調査における質問、行動観察や脳のスキャンなど、すべて測定に数えられる。
- **操作化**。“操作化”という用語は、測定と構成概念の論理的なつながりを指す。あるいは、理

論的構成概念から測定を導き出そうとするプロセスのことである。

- **変数**。最後に、新しい用語を。変数とは、世界に存在する何かに対して、私たちが測定を適用した時の結果である。つまり、変数は実際の“データ”で、最終的に我々のデータセットになるものである。

実際には、科学者でさえこれらの擁護間の区別を曖昧にしようとする傾向があるが、その違いを理解しようすることはとても有益である。

2.2

測定の尺度水準

前のセクションで示したように、心理学的な測定の結果は変数と呼ばれる。しかしすべての変数が同じ質的なタイプではないので、どういうタイプがあるのかを知っておく必要がある。変数のタイプの違いを区別する大変便利な概念として**測定の尺度水準**というものがある。

2.2.1 名義尺度水準

名義尺度水準の変数は (**カテゴリーカルな** (質的な) 変数と言われることもあるが), 異なる取りうる可能性との間に特定の関係がないもののことである。この種の変数は、他の値“より大きい”とか“より良い”といったいかなる意味も持たないし、その平均を出しても全くなんの意味もない。典型的な例として、“目の色”を考えてみよう。目はブルー、グリーン、ブラウンだったり他の色であったりするが、そのどれかが他のものよりも“大きい”とは言わない。だから、“平均的な目の色”について語るのも憚られる。同様に、ジェンダーもそうだろう。男性が女性よりも良いとか悪いとかいうものではない。同じく“平均的な性別”というのも意味がない。つまり、名義尺度水準の変数は、異なる変数の値は異なるということしか言えない。それだけだ。

もう少し注意深く見てみよう。私が人の通勤・通学手段について研究しているとしよう。私が測定しようとしている変数は、仕事に行くためにどういう種類の移動手段を使うかである。“移動のタイプ”変数は、それほど多い値を取るものではない。せいぜい“電車”、“バス”、“自家用車”、“自転車”ぐらいだろう。ここでは、この四つの可能性しかないことにしよう。その上で、100 人の人に対して

	移動手段	人数
	(1) 電車	12
どうやって仕事場に行ったかを調べて、次のような結果になったとする。	(2) バス	30
	(3) 自家用車	48
	(4) 自転車	10

さて、移動手段の平均はなんだろう？ 明らかにその答えはひとつではない。愚問としか言いようがない。車で移動することが最もポピュラーな方法で、電車で移動するのがもっともポピュラーでない、それだけである。同時に、私が選択肢を列挙した順番が面白くないことにも注意してほしい。データは次のように表示することだってできるのだ。

移動手段	人数
(3) 自家用車	48
(1) 電車	12
(4) 自転車	10
(2) バス	30

...実質的には何も変わっていない。

2.2.2 順序尺度水準

順序尺度水準にある変数は、名義尺度水準の変数より少し構造化されているが、それほど大きな変化ではない。順序尺度水準の変数は、異なる状態に自然な意味のある順序を与えたものであるが、それ以上のことはない。よく使われる例としては、“レースの最終順位”である。最初にゴールした人に、2位の人よりも早かったということはできるが、どれくらい速かったかということとはできない。結果的に、1位 > 2位ということはわかるし、1位 > 2位ということもわかるが、1位と2位の差が2位と3位の差よりも大きいかもしれない。心理学的に面白い例もある。私が気候変動に対する人々の考え方に興味をもっているとしよう。私は、その人の信念にもっとも当てはまる文章がどれかを、(以下にリストした4つの文章から)ピックアップして人に尋ねる。

- (1) 気温は人間の活動のせいで上昇している
- (2) 気温は上昇しているがなぜかはわからない
- (3) 気温は上昇しているが人間のせいではない
- (4) 気温は上昇していない

この4つの文章は、確かに自然な序列がついている。“現在の科学に対してどれほど同意するか”という意味でだ。文章1は明らかに科学的営みにマッチしているし、2はかなり適合している。3はそれほどでもないし、4は現在の科学と逆の立場だ。だから、私の興味のある用語(人は科学を支持

する度合い) でいうと、項目を $1 > 2 > 3 > 4$ の順に並べることができる。この順序づけがある以上、次のように選択肢を並べると奇妙なことになる。

- (3) 気温は上昇しているが人間のせいではない
- (1) 気温は人間の活動のせいで上昇している
- (4) 気温は上昇していない (2) 気温は上昇しているがなぜかはわからない

...これは項目の自然な“構造”に違反しているように見えるからだ。では、100 人にこの質問をして、以下のような答えを得たとしよう。

反応	度数
(1) 気温は人間の活動のせいで上昇している	51
(2) 気温は上昇しているがなぜかはわからない	20
(3) 気温は上昇しているが人間のせいではない	10
(4) 気温は上昇していない	19

このデータを分析するときは、グループ (1),(2),(3) を一緒にするのは合理的だと思われるし、100 人のうち 81 人が少なくとも一部は現在の科学を支持していると言えそう。また、グループ (2),(3),(4) をまとめることもあり得る話で、100 人のうち 49 人が現在の科学的観点に、少なくともいくらか同意していないといえる。しかし、(1),(2) と (4) を一緒にすることはおかしなことで、100 人のうち 90 人がどうこうしてるとは言えない。これらの反応を一緒にくたにする合理的な根拠がないからだ。

つまり、私たちがこれらの項目が、意味のあるグルーピングで自然に序列づけできるということはできるが、その平均を求めるということはできない。例えば、ここでの例でいうと、“平均的な” 反応は 1.97 である。もしその意味がわかるというのなら、ぜひ知りたいのでどうぞ教えてください！

2.2.3 間隔尺度水準

名義や順序の尺度水準に比べると、**間隔尺度水準**の変数や比率尺度水準の変数は、かなり意味を持った数値である。感覚尺度水準の変数は、数字の間の差分が解釈可能だが、“自然な” ゼロの値をもつものではない。間隔尺度水準の良い例は、セ氏で測られる気温である。例えば、昨日は 15° で今日は 18° だというとき、この 3° の違いに意味がある。もっというと、この 3° の違いは、 7° と 10° の間の 3° と全く同じである。つまり、間隔尺度水準では足し算引き算に意味があるのだ^{*3}。

^{*3}実は、かなり物理学の知識がある読者に教わったのだが、この温度は厳密な間隔尺度水準ではない。というのも、 3° 温度を上げようとするのに必要なエネルギーの量は、その時の気温に依存するらしい。だから、物理学的に注意するというなら、温度は間隔尺度とはいえないのだ。しかし例としていいものなので、このちょっとした不都合な真実は無視しようと思う。

しかし注意してほしいのは、 0° が“温度がない”ことを意味するものではない点だ。これが意味するのは“水が凍る温度”であって、これはちょっと恣意的なものだ。だから、温度を掛け算したり割り算したりしようとするのはポイントがずれていることになる。 20° は 10° の二倍熱いとは言えないし、 20° が -10° のマイナス 2 倍というのも意味がないことだ。

あらためて心理学的な例を見てみよう。大学一年生の態度が時間とともにどう変わっていくかに興味があったとしよう。もちろん、各学生が入学した年を記録するだろう。これは間隔尺度水準の変数だ。2003 年に学生になった人は、2008 に始めた学生よりも 5 年早い。しかし、2008 を 2003 で割って、後者の学生を前者の学生に比べて“1.0024 時間後の人”とは言わないだろう。そんなの全く意味がないじゃないか。

2.2.4 比率尺度水準

四つ目の、そして最後の変数の種類は**比率尺度水準**の変数といわれ、0 がゼロという意味を持つものであり、掛け算や割り算を許すものである。比率尺度水準にある変数の心理学的な例としては、反応時間 (Response time: RT) がいいだろう。人が問題を解いたり質問に答えたりするのに要する時間を図ることは、様々なタスクでよく見られるものである。というにも、それがタスクがいかに難しいかを示す指標になるからだ。アランが質問に回答するまで 2.3 秒かかり、ベンが 3.1 秒かかったとしよう。感覚尺度水準と同じように、足し算や引き算はどちらもここで意味のある操作である。ベンは実際、 $3.1 - 2.3 = 0.8$ 秒長くアランより時間を要した。しかし、今回は掛け算や割り算も意味があるのである。つまり、ベンはアランの $3.1/2.3 = 1.35$ 倍長く時間がかかったとも言える。比率尺度水準にはなぜこんなことができるかという、反応時間はまさに“0秒”が“時間が経過していない”ことを表しているからだ。

2.2.5 連続か離散か

あなたが考えておくべき第二の分類方法がある。それはあなたが分析に持ち込もうとしている変数の種類に関するものだ。連続変数と離散変数という区別があるのだ。この区別は以下の通りである。

- **連続変数**はどの二つの値を取っても、論理的には必ずその両者の間に値がありうるもの。
- **離散変数**とは、連続的でない変数のこと。離散変数は、中間点に対応するものがない。

この定義はおそらくちょっと抽象的なのだが、例を見たらすぐにシンプルなものだとわかってもらえるだろう。たとえば、反応時間は連続変数である。アランが 3.1 秒、そしてベンが 2.3 秒反応に要したとして、キャメロンがその間の 3.0 秒になるかもしれない。デイビッドが 3.031 秒、つまりキャメロンとアランの間に反応時間が来ることもありえる。現実的には、反応時間をそんなに正確に測定することはできないかもしれないが、原則的には確かに可能なのだ。反応時間の 2 つの値の間に、常に新しい値を見つけることができるのであれば、RT は連続変数として考えられる。

Table2.1 尺度水準と離散/連続の関係。チェックマークが入っているセルは可能であることを意味する

	連続	離散
名義		✓
順序		✓
間隔	✓	✓
比率	✓	✓

離散変数はこのルールを破った時に現れる。例えば、名義尺度水準は常に離散変数だ。移動手段の種類の例を思い出してみると、電車と自転車の“間”に何かがあるとは言えないし、数学的に2と3の間に2.3があるという意味をもたない。移動手段は離散変数なのだ。同様に、順序尺度水準も常に離散変数である。“2位”は“1位”と“3位”の間に常に入るが、“1位”と“2位”の間には論理的に何も生じ得ない。間隔尺度水準と比率尺度水準は事情が違う。上で見たように、反応時間は(比率尺度水準の変数だが)連続変数である。セ氏で測られる温度も(間隔尺度水準の変数だが)連続変数である。しかし、学校に通い始めた年(間隔尺度水準)は離散的である。2002年と2003年の間にはX年が存在しないのだ。正誤判定できる問題の正答数も(比率尺度水準の変数だが)、離散変数である。正誤がわかる質問は、“部分的に正解”とすることができないので、5/10と6/10の間というのが考えられない。表2.1は尺度水準と連続/離散の区別を要約したものである。チェックマークは可能であることに対応している。強調しておきたいのだが、(a) テキストによっては間違えているものがあって、(b) “離散変数”は“名義尺度水準のこと”と言ったりするのだ。残念なことだ。

2.2.6 複雑なもの

いいかい、これを聞いたらショックを受けるだろうことはわかるけど、現実世界はこの小さな分類法が提案するよりもずっと厄介なものがある。現実世界においてはこの綺麗なカテゴリーにぴったり当てはまる変数はないので、測定の尺度を堅苦しいルールのように扱わない方がいい。そういうものではないのだ。

これはガイドラインに過ぎず、違う変数の種類を違うように扱うべき状況について考える助けになるようなものにすぎないのだ。それ以上のものではない。

古い例を取り上げてみよう。多分ほんとうに古典的な例の、心理学的測定ツールである、**リッカートスケール**のことを考えてみる。リッカートスケールはあらゆる調査デザインにつかえるものだ。あなた自身、何百、何千回と回答したことがあるだろうし、もしかするとあなた自身も使ったことがあるかもしれない。以下のような調査の質問をしたとする。

“海賊はみんなすごい” という発言に対するあなたの意見を最もよく表しているのは、次のうちどれですか？

そして選択肢が次のように提示される。

- (1) 全く同意できない
- (2) 同意できない
- (3) どちらとも言えない
- (4) 同意できる
- (5) 強く同意できる

これは5件法のリッカーと尺度の例で、いくつかの(ここでは5つの)順序づけられた可能性の中から一つを選ぶ。一般的にはそれぞれのケースに言葉で説明が加えられる。しかし、全ての項目が正確に記述されているとは限らない。以下のような表示の仕方も、典型的なリッカートの5件法である。

- (1) 全く同意できない
- (2)
- (3)
- (4)
- (5) 強く同意できる

リッカートスケールはとても便利なツールだ。ちょっと限定的だとしても。この質問はどの種類の変数になるだろう？ 明らかに離散的だ。2.5に反応することができないのだから。名義尺度水準でないことも明らかだ。順番通りに並んでいるのだから。そして比率尺度水準でないことも明らかだ。自然なゼロがないのだから。

順序尺度水準か間隔尺度水準なのだろうか？ 一つの意見ではあるが、“強く同意できる”と“同意できる”の差分が、“同意できる”と“どちらとも言えない”の差分と同じサイズだということを、証明するのは不可能に思える。実際、日常生活の感覚では、これらは全く同じなはずがない。これに従うと、リッカート尺度は順序尺度水準として扱うべきだということになる。一方で、実践的にはほとんどの参加者が“1点から5点までの尺度”全体をかなり真面目に扱っているようで、5つの選択肢の違いが互いに似ているように振る舞う傾向がある。このことから、ほとんどの研究者がリッカート尺度のデータを間隔尺度水準として扱っている^{*4}これは感覚尺度水準ではないが、実際は十分近似できていると考えて、**疑似の間隔尺度水準**として扱うのが普通だ。

^{*4}嗚呼、心理学...は何に対しても応えるのが難しいなあ！

測定信頼性を査定する

ここまで、理論的な構成概念をどのように操作化し、それによって心理学的測定に変えるかについて、少し考えてきた。そして心理学的測定によって、多くの異なる種類の変数を得る。そこで、次の質問を検討してみよう。測定はうまくいったのか？ これをふたつの関連する用語で表現するなら、**信頼性**と**妥当性**の話になる。単純にいうなら、**信頼性**とはあなたが測定したものをどれぐらい正確に測っているかについてのものであり、**妥当性**はその測定がどの程度精度があったかについてのものである。このセクションでは信頼性について論じよう。妥当性についてはセクション 2.6 でみていこう。

信頼性は実にシンプルな概念だ。それは測定の反復可能性、あるいは一貫性を表す言葉である。私の体重を“バスルームの体重計”で測定したものは非常に信頼性が高い。もし私が体重計に乗ったり降りたりを繰り返しても、同じ答えを示し続けるだろう。私の知能について、“母親に尋ねる”のは非常に信頼性が低い。ある日、彼女は私がちょっと賢いと言い、別の日に彼女は私を全くの馬鹿者といった。信頼性の概念は測定が正しいかどうかとは異なるものだ（測定の正しさは妥当性に関係する）。私がバスルームの体重計に乗り降りする時に、ジャガイモの袋を持っていたとしても、信頼性は高いままだ。つまり、同じ答えを出し続けるという意味で。しかし信頼性が高いからといって、私の体重と一致しているかというとはそうではなく、間違った値になっている。これを専門的にいうと、**信頼性はあるが妥当ではない測定**ということになる。同様に、私の母が私の知能についていうことは信頼性がないが、彼女がいつてことはいくらか正しい。たぶん私はものすごく聡明というわけではないし、彼女が私の知能を推定するときは日によって乱高下するものの、基本的には正しいだろう。これは**信頼性は低い**が**妥当ではある測定**ということになる。もちろん、もし私の母による推測があまりにも信頼性が低いものであると、彼女が私の知能についていうところの数多くのクレームのうち、どれが実際に正しい表現なのかを見極めることは難しくなるだろう。だから、ある意味で、信頼できない測定というのは実践的な目的において妥当でないものになってしまうのだ。だから、多くの人がいうように、**信頼性は妥当性にとっての必要条件（しかし十分条件ではない）**ということになる。

オーケー。では信頼性と妥当性の違いがはっきりしたところで、違うやり方で信頼性を測定する方法を考えよう。

- **再検査信頼性**。これは時間が経っても一貫しているかどうかに関するものである。もし後日同じ測定をしたら、同じ答えが得られるだろうか？
- **評定者間信頼性**。これは人が違っても一貫しているかに関するものである。もし誰かが同じ測定をしたら（たとえば、別の人が私の知能について評定したら）、同じ答えが得られるだろうか？

- **平行検査信頼性**。これは理論的に質が等しい測定を使つての一貫性に関するものである。もし違う体重計を持ってきて私の体重を測定したとして、同じ答えが得られるだろうか？
- **内的一貫性信頼性**。もし測定が同じ機能を持つ異なるいくつかのパーツから構成されているとしたら (たとえば、性格検査の質問紙の結果はいくつもの問いを通じて迫っていくものだが)、個々のパーツが同じ答えを出す傾向にあるかどうか。

全ての測定が全ての形式の信頼性を満たすというものではない。たとえば、教育評価は測定の一つとして考えることができる。私が教えているある科目、*計算論的認知科学*は、研究課題と試験 (プラス、その他少し) の要素から評価することになっている。試験は研究課題の評価とは幾分異なる側面を評価しようとしているから、評価全体としては内的一貫性が低い。しかし、試験はいくつかの質問から構成されていて、それは同じものを (近似的に) 測定しようとしているから、同じような結果を出す傾向にある。つまり、試験そのものはかなり高い内的一貫性をもっているのだ。これは当然のことである。信頼性を求めるのは、同じものを測定したい場合に限るべきだ！

2.4

変数の “role” : 予測変数と結果変数

変数の話から移る前に、最後にもう一つ用語を説明しておこうと思う。普通、我々は研究の結果として多くの変数を手にすることになる。そこで、我々がデータを分析する時に、他の変数に関連づけてある変数を説明しようとすることはよくあることだ。このとき2つの役割、つまり“説明する”と“説明される”という役割の違いを意識することが大事だ。今からこれについて明らかにしていこう。まず、何度も繰り返し参照することになるので、変数を記述するのに数学的な記号を使うことにしよう。“説明される”変数を Y で、“説明する”変数を X_1, X_2 のように表記することにする。

X と Y という異なる名前をつけて分析するのは、分析において異なる役割を演じるからだ。これらに対して、古くは**独立変数** (Independent Variable, IV)、**従属変数** (Dependent Variable, DV) と名付けられていた。独立変数は説明に使うもの (つまり X) で、従属変数は説明される変数に使うもの (つまり Y) である。この名前の背後にある意味は次のようなものだ。もし X と Y の間に本当に関連があるのなら、 Y が X に依存している・従属していると言えるし、研究が“適切に”デザインされていたら、 X は他の何物からも独立しているはずである。しかし、個人的にはこのネーミングはマズイと思う。これだと、ミスリーディングであることを忘れそうになるからだ。なぜなら、(a) 独立変数は実際に“何物からも独立である”というわけにはいかないし、(b) 変数間に関係がなかったら、従属変数が独立変数に従属することはないのである。現に、独立変数と従属変数というのがマズいネーミングだと考えるのは私一人ではないので、もっと良さそうな他の名前がいくつもある。この本で使うのは**予測変数**と**結果変数**である。このアイデアは、変数 X (予測変数) を使って Y (結果変数) につ

Table2.2 データセットで分析に使われる変数が担う異なる役割について、区別を明確にした用語。この本では古典的な用語は使わず、新しい用語を使うようにしていることに注意してほしい。

変数の役割	古典的な名称	モダンな名称
“説明される”	従属変数 (DV)	結果変数
“説明する”	独立変数 (IV)	予測変数

いて何らかの推測をしようとするから、というところから来ている^{*5}。これについて、表 2.2 にまとめておく。

2.5

実験的，あるいは非実験的研究

あなたが気にすべき、大きな区分基準は“実験的研究”なのか、“非実験的研究”なのか、という違いだ。この区別をする時、本当に話をしているのは、実験者がその研究において人と出来事全体をどの程度コントロールしているか、ということについてである。

2.5.1 実験的研究

実験的研究の特徴は、研究者が研究のあらゆる側面をコントロールしていること、特に被験者がその研究の途中でどういう経験をするかをコントロールしていることにある。実際的には、研究者は予測変数 (独立変数) を操作したり変化させたりするが、結果変数 (従属変数) は自然に変化するに任せる。このアイデアは、予測変数 (独立変数) を意図的に変化させ、それが結果に何らかの因果的な効果を与えるかどうかを見るためにある。もっと言うと、予測変数以外に結果変数の原因となるものが存在する可能性がないことを保証するため、他のものは一定に保つか、ある種“バランスの取れた”やり方で、結果に影響を与えないことを保証するのである。実践上は、他の何ものも実験の結果変数に影響を与えないと考えるのは不可能だし、一定に保つというのも難しい。これについての標準的な解決方法は、**乱打マイゼーション**である。つまり、異なる群にランダムに人を割り付け、群ごとに異なる処置をする (すなわち、違う予測変数の値をもたせる)。ランダマイゼーションについては後ほどもっと詳しく説明するが、ここではランダマイゼーションが群間にみられるあらゆる系統的な変

^{*5}しかし腹立たしいことに、別の名前もよく使われる。それをリストアップしようとは思わない—そんなことをしたって何にもならないからだ。ただし、私が“結果変数”としたところが時折“反応変数”とされることがある、ということだけは指摘しておこう。やれやれ。この種の用語の混乱はとてもよくあることで、まいっちゃうよね。

化の可能性を(無くすことは無理だとしても)最小化するために行われるものであることを確認できれば十分だろう。

ごく単純で、まったく非現実的で、非倫理的な例をみてみよう。喫煙が肺がんを引き起こすことを検証したいとする。これを実現する一つの方法は、タバコをお吸う人と吸わない人を見つけ出して、タバコを吸う人の肺がん率が高いかどうかを見ることだろう。これは全く実験的ではない。なぜなら、研究者がタバコを吸う人と吸わない人に対してコントロールしていないからだ。そしてこれは大問題なのである。たとえば、タバコを吸う人は食生活が良くない傾向があるかもしれないし、アスベスト鉱山で働く傾向があるといったことが考えられるからだ。ここでのポイントは、群(喫煙者と非喫煙者)は多くの点において異なっており、喫煙習慣の違いだけではないということだ。だから喫煙者の方が肺がん率が高いということは、他の何か別の原因があるかもしれないし、タバコが原因ではないかもしれないのだ。他の要因のこと(たとえば食習慣とか)は、専門的には“交絡変数”というが、これについてはまた後で話すことにしよう。

今はとりあえず、適切な実験がどのようなものかを考えたい。ここでの問題点は、喫煙者と非喫煙者は多くの点で異なっているということだった。解決策として、もしあなたに倫理観がなかったとしたら、誰が吸うか吸わないかをコントロールすればよい。具体的には、若い非喫煙者を無作為に2つのグループに分けて、その半数を強制的に喫煙者にする。そうすると、半分が喫煙者であるということ以外の点で、量グループが異なるところは非常に低くなる。こうして、もし喫煙者群が非喫煙者群よりも肺がんになる確率が高ければ、(a) 喫煙が癌の原因であり、(b) 我々は殺人者だ、というはっきりした確信を得ることができる。

2.5.2 非実験的研究

非実験的研究は、広い意味で“研究者が実験で行うようなコントロールをしないあらゆる研究”を指していると言えるだろう。もちろん、科学者はいつもコントロールしたがるものだが、上の例にあったように、コントロールできないとかすべきでない状況というものもある。がんになるかどうかを見るために、人に強制的にタバコを吸わせるのは論理的に大きな問題(というかほとんど犯罪)だから、実験者がコントロールすべきでない状況の良い例といえるだろう。しかし別の問題もある。倫理的な問題を横に置いたとしても、“喫煙実験”は他に幾つかの問題があるのだ。たとえば、“強制的に”喫煙させようと言った時、私は非喫煙者のサンプルが喫煙を始めさせるという意味で、喫煙者にするという意味だった。これはマッドサイエンティストが好みそうな、確実かつ悪どい実験デザインのように聞こえるが、現実世界での効果を検証する方法としては、それほど健全ではないだろう。たとえば、喫煙が肺がんの原因になるのは、その人の食生活がわるいからで、普段から喫煙をする人は食生活が悪いのかもしれない。しかし我々の実験における“喫煙者”は“普通の”喫煙者ではないから(つまり、非喫煙者を喫煙者にしたとしても、それは他の普通の、現実の喫煙者が持つ特性を持ってないので)、食生活は良いのかもしれない。そうだとすると、彼らが肺がんになることはないから

我々の研究は失敗だ。これは“普通の”世界の構造を壊してしまったから(専門的には、これは“人為的な”結果といわれる)である。

非実験的な研究をふたつのタイプに分ける区分として注目すべきは、**準実験研究**と**事例研究**である。上で述べた例である、喫煙者と非喫煙者の肺がん発症を検証するために喫煙者と非喫煙者を統制せずに行う研究は、準実験デザインといえる。つまり、これは実験と同じだが、予測変数(独立変数)を操作していないのである。それでも結果を統計的に分析することはできる。ただし、より注意深く、慎重であらなければならない。

別のアプローチである事例研究は、一つ、あるいはごく少数の事例をととても詳細に記述することをねらう。一般的に言って、事例研究の結果に統計的な分析を適用することはできないし、わずかな独立した事例から“人は一般に”，という一般的な結論を引き出すことはかなり難しい。とはいえ、事例研究は状況次第で有用なのである。まず、他の手法がない状況。神経心理学では、この問題はよくあることである。特定の脳の領域にダメージを受けているひとをたくさん集めることはできないし、そうするとできることはいくつかの事例について、できるだけ詳細に記述することだけである。しかし、事例研究にも素晴らしい利点はある。多くの人を研究対象にできないからこそ、各事例における特定の要因が果たす役割を理解するために、時間とエフォートをかなり注ぎ込むことができるからだ。これは十分にやる価値のあることである。結果として、事例研究はあなたが実験、準実験デザインで見られるような、より統計学的なアプローチを補うことができる。この本では事例研究についてそれほど多く触れないが、紛れもなく価値のある手法なのである！

2.6

妥当性を検証する

他の何よりも科学者が欲するものは、研究が“妥当”かどうかである。この**妥当性**という考え方の背後にある考え方は、とてもシンプルなものだ。あなたは自分の研究が信用できるか？もしできないのなら、それは妥当ではないということだ。しかし、そうやってしまうのは簡単なのだが、信頼性をチェックするよりも妥当性をチェックすることのほうが難しい。本当のことをいうと、妥当性が実際なんなのかについて正確で明確な同意を得ることはできない。現に、様々な種類の妥当性があって、それらは個々別々の問題を扱っている。また、全ての妥当性が全ての研究に当てはまるというものでもない。ここでは5つの異なる妥当性について論じようと思う。

- 内的妥当性
- 外的妥当性
- 構成概念妥当性
- 表面的妥当性
- 生態学的妥当性

はじめに、何が問題なのかについての簡単な紹介をしておこう。(1) 内的・外的妥当性は最も重要なものである。なぜなら、それはあなたの研究が実際に意味があるかどうかという基本的な問いに直結しているから。(2) 構成概念妥当性は、あなたが考えていることをあなたが測定できているかどうか、を問う。(3) 表面的妥当性は“見え方”が重要であること以外、それほど重要な問題ではない。(4) 生態学的妥当性は表面的妥当性の特殊ケースで、注意すべき多くの側面の表面的なものに対応している。

2.6.1 内的妥当性

内的妥当性というのは変数間の因果関係について、正しい結論を導き出せるかどうかということに関わっている。

ここで“内的”といってるのは、これが研究の“中における”関係性を指し示しているからだ。

簡単な例で考えてみよう。大学教育によって文章が書くことが上手くなるかどうかを明らかにしたいとする。

これを検証するために、あなたはまず一年生の学生グループを集め、1000語程度のエッセイを書いてもらい、スペルや文法ミス数を数えたとする。

次に、明らかに一年生よりも大学教育を受けてきているであろう3年生の学生を見つけてきて、同じ実験をする。

そうすると三年生の方がミスが少ないことがわかった、としよう。

そこであなたは、大学教育が文章を書く技術を向上させた、と結論した。あってるかな？

この実験の考えうる大きな問題点は、三年生は年長なので、書くこと以外にも色々な経験を積んでいるだろうということだ。

だから、因果関係を導き出すのは難しいだろう。年長者は作文がうまい？もっと作文の経験をしている人は？もっと長く教育を受けていたら？

このいずれかが真であれば、三年生のパフォーマンスを向上させる原因になるのではないかな？年齢？経験？教育？答えられないでしょう。

これが内的妥当性の失敗の例である。なぜなら、あなたが異なる変数間の因果関係を適切に切り分けられてなかったからだ。

2.6.2 外的妥当性

外的妥当性は知見の**一般化可能性**や**応用可能性**と関係している。

すなわち、研究で見つかったものが“実生活における”同じパターンを見出すことができる程度を

指す。

もう少し正確にいうなら、あなたが心理学の名のもとに行うあらゆる研究は特定の問いや作業を含んでいるだろうし、特定の環境において生じているだろうし、特定の集団(残念なことに、学生限定であったりする)から選び出した参加者から出来上がっている。だから、もし結果が現実的に一般化できないとか、あなたの対象を超えた状況を超えて一般化することができないという場合、外的妥当性がなかったということになる。

この問題の古典的な例として、心理学におけるかなりの部分の研究が、心理学コースの学部学生を使ったものであるということが挙げられる。しかし、明らかに、研究者は心理学徒だけに注目しているわけではない。研究者は一般の人々に関心があるのだ。であれば、心理学の学生を対象にした研究は常に、外的妥当性を欠いている可能性がある。すなわち、もし心理学の学生に何か“特別な”ことがあれば、あるそれに関した側面について一般とは異なる影響をもたらす、外的妥当性がないかもしれないということを気にし始めなければならない。

とはいえ、心理学の学生だけを対象とした研究が、必ずしも外的妥当性に問題があるわけではない、ということを理解することが重要である。これについては後ほどまた述べるが、非常によくある間違いなのでここで触れておく。研究における外的妥当性は、もし(a)ごく狭い領域(たとえば心理学の学生)からサンプルを取り出して、(b)その狭い母集団があなたが研究したい心理学的現象に関する側面において、系統的に一般人の母集団から異なっている場合には、危うくなる。この強調した部分のことを、多くの人が忘れがちなのである。心理学の学生が一般人と多くの点で異なるということはあるだろうから、心理学の学生を使った研究は外的妥当性がないかもしれない。しかし、その違いがあなたがみようとしている研究と関係ないのなら、なんの問題もない。もう少しはっきりさせるために、次の二つの例をみてみよう。

- あなたが“心理療法に対する態度”を見てみたいと思ったが、被験者全員が心理学の学生であった。この研究は外的妥当性についてかなり問題含みだろう。
- あなたが錯視の効果を測定したいと思い、心理学の学生をたいしょうにした。この研究は外的妥当性についてそれほど問題はないだろう。

最後の段落では参加者の選び方だけを取り上げたが、それは誰もが機にする側面だからであって、外的妥当性はもっと広い概念であることは忘れないでほしい。次の例も外的妥当性を脅かしかねないものであるが、これは研究実践に関わるものである。

- 実生活を反映していないような“心理尺度”に回答させているかもしれない。
- (いわゆる)“人間の学習”についての実験室実験は、実生活で人が直面する学習の問題とは異なる構造を持っている。

2.6.3 構成概念妥当性

構成概念妥当性は基本的にあなたが図りたいものがはかれているかどうかという問いである。理論的な構成概念を正しく測定できているなら、その測度は良い構成概念妥当性を持っていると言えるし、そうでなければ構成概念妥当性がないことになる。単純な(もしかしたら馬鹿馬鹿しい)例を挙げると、大学生が試験でカンニングする割合を調査しようとしているとしよう。その測定方法として、授業中にカンニングした学生は立つようにいい、私がそれを数えるということにしたとする。もしこれを300人の学生の前でやったとして、カンニングをしたと名乗り出た人が0人だった。だから私のクラスではカンニングした人の割合は0%だ、と結論しよう。これは明らかに馬鹿馬鹿しいやりかたである。しかしここでのポイントは、測定法に対する意義深い例を挙げることでなく、構成概念妥当性とは何かという説明なのだ。私が測定しようとしたものが“カンニングする学生の割合”だったのに対し、私が実際に測定したのは“自分の悪事を申告するような馬鹿な学生、あるいは“不正をしたふりをするほど血迷った学生”だったということだ。明らかにこれは同じものではない! だから、私の研究は失敗するだろう。測定が、構成概念妥当性を欠いている、という意味で。

2.6.4 表面的妥当性

表面的妥当性は単に測定が 想定通りのことをしているように“見える”かどうかについてのものであり、それ以上のことはない。もし知能を測るテストをデザインしたとして、人が“いや、これは知能を測定していないよ”というのであれば、この測定は表面的妥当性を欠いている。単純そのものでしょ。たしかに表面的妥当性は、真の科学的観点からはそれほど重要なことではない。結局のところ、測定が実際に想定通りのことをしているかどうかについて注意すべきであって、それがそのように見えるかどうかではないからだ。そうすると、表面的妥当性については一般的にそれほど注意しなくても良いということになる。とはいえ、表面的妥当性は3つの実目的に役立つのである。

- ときには、経験豊かな実験が、特定の測定がうまく行っていないと“直感的に”気づくことがある。この種の気づきは証拠に基づくものではないが、注意を向ける価値はあったりするものだ。なぜなら、多くの場合ひとは言語化できない知識を持っているので、理由をうまく説明できなくても何か気にすべきことがあるのかもしれない。言い換えるなら、あなたの研究に表面的妥当性がないと批判してくる人がいたら、あなたがその研究がうまくいかない理由を考えることができるかどうか、デザインについてより慎重に考える時間を取る価値があるということでもある。注意して欲しいのは、もし確信に至る理由が見つからなかったら、多分気にしなくてもいいということだ。結局のところ、表面的妥当性はそれほど大きな問題ではないのだから。
- まれによくあることだが、全く知識がない人でも、あなたの研究がくだらないという“直感”を得る人がいる。それはネット等で批判してくるだろう。よく考えてみると、その批判は当該研究がどう“見えているか”に焦点化していて、深いところまで考えていないことに気づくだ

ろう。表面的妥当性というのは、そうした主張にさらなる裏付けが必要であることをやんわりと説明するのに役立つ。

- 最後の点を拡張した形で、もし未経験者の批判が的を射ていたら（これは政策立案者になんらかの納得をさせたい応用研究者の場合など、よくあることだが）、あなたは表面的妥当性をしっかりと考えなければならない。というのも、単順に、あなたが好むと好まざるとに関わらず、多くの人は表面的妥当性と実際の妥当性は似たものだと思っているからだ。もしあなたが科学的で心理学的な背景に基づく法律を政府に求むなら、あなたの研究が“実際に”どういものかは問題にならない。表面的妥当性を欠いていたら、政治家はあなたを無視するだろう。もちろん政策がファクトよりも見え方に依存し、それがどうなるかに関係ないというのはアンフェアなことなのだが。

2.6.5 生態学的妥当性

生態学的妥当性は妥当性の異なる側面についてのもので、外的妥当性に似ているがもう少し重要なものである。そのアイデアは、生態学的妥当性があるというためには、研究が調べようとしている現実世界に近似するべきであり、全体的にそのような設定になっているかどうかということである。本質的には、生態学的妥当性は表面的妥当性の一種だといえる。その研究が正しく“見える”かどうかということに関わっているが、もう少し厳密なものではある。生態学的に妥当な研究というのは、専門的な意味で正しく見えるかということである。背後にある考え方は、研究が生態学的に妥当であるというのは、外的妥当性も高いだろうという直感だ。もちろんその保証はない。しかし、生態学的妥当性にとってありがたいことに、その研究が外的妥当性を持つかどうかをチェックするよりも、生態学的妥当性があるかどうかをチェックする方がより簡単である。シンプルな例として、目撃者の識別研究をとりあげよう。この種の研究のほとんどは、大学の中で行われる傾向があり、整列した顔ではなく単順に配置された顔を使うものが多い。犯罪を“目撃している”時間の長さと、“整列した”顔の中で容疑者を特定してくれと言われるまでの時間は、普通短いものだ。“犯罪”は現実のものではないし、目撃者が恐怖を感じることもなく、警察官がそばに立っているわけでもないからプレッシャーを感じることもない。これらは全て、研究がまったくもって生態学的妥当性を欠いていることを意味している。またおそらく、外的妥当性をも欠いていることも意味している（意味していないかもしれないけど）。

2.7

交絡、人工産物、そのほかの妥当性への脅威

妥当性の問題をごく一般的な形で眺めてみると、いちばん大きな心配ごとは交絡変数と人工産物のふたつです。このふたつの用語は、次のように定義されます。

- **交絡変数**: 交絡変数とは、予測変数と結果変数の両方に関係していることがわかった、測定されていないことの多い追加の変数のことです^{*6}。交絡変数があると、予測変数が結果を引き起こしているのか、それとも交絡変数が引き起こしているのかを区別できなくなりますので、研究の内的妥当性が脅かされることになります。
- **人工産物**: ある結果が、たまたまその研究で検討した特殊な状況でしか成り立たないとき、その結果は“人工産物である”と言われます。結果が人工産物かもしれないということは外的妥当性への脅威になります。というのも、その結果を、あなたが本当に興味を持っている母集団へ一般化したり適用したりできない可能性が出てくるからです。

一般的なルールとして、交絡変数は非実験的な研究でより大きな問題になります。まさに、きちんとした実験ではないからです。定義からして、多くのことが統制されないまま放置されているのですから、あなたの研究に交絡変数が紛れ込む余地はいくらでもあります。実験的な研究は、交絡変数に対してずっと強い傾向があります。研究の最中に起こることを統制すればするほど、交絡変数が結果に影響するのを防げるわけです。たとえば無作為割り当てを行えば、交絡変数は異なる群のあいだにランダムかつ均等に散らばることになります。

とはいえ、物事には一長一短がありまして、交絡変数ではなく人工産物のほうを考え始めると、立場はまるきり逆になります。たいていの場合、人工産物としての結果は、非実験的な研究よりも実験的な研究のほうで問題になりがちなのです。このことを理解するには、多くの研究が非実験的である理由が、まさに研究者がより自然な文脈で人間の行動を調べようとしているからだ、ということに気づくのが助けになります。より現実に近い文脈で研究すれば実験的な統制は失われますが(そのぶん交絡変数に弱くなります)、人間の心理を“野生の状態”で研究することになりますので、人工産物としての結果を得る可能性は減るわけです。別の言い方をすると、心理学を野生から連れ出して実験室に持ち込むとき(実験的な統制を得るためには普通そうしなければなりません)、あなたは本当に研究したかったものとは違うものをうっかり研究してしまうリスクを常に負っているのです。

ただし、気をつけてください。いま述べたのは大まかな目安にすぎません。実験に交絡変数が入り込むことも、非実験的な研究で人工産物としての結果が出ることも、十分にあり得ます。これはいろいろな理由で起こりますが、なかでも大きいのが実験者や研究者のミスです。実際のところ、あらか

^{*6}測定されていない、とわざわざ言ったのは、もし測定しているのであれば、ちょっと洒落た統計的テクニックを使って交絡変数を処理できるからです。交絡変数の問題にはこうした統計的な解決策があるので、測定して処理済みの交絡変数のことを共変量と呼ぶことがよくあります。共変量の扱いはもっと進んだトピックになりますが、そういうものがあると知っておくだけでも少し安心できますから、ここで触れておくことにしました。

じめすべてを考え尽くすというのは本当に難しいことで、とても優秀な研究者でも間違えるのです。

妥当性への脅威はほとんどすべて、交絡変数か人工産物のどちらかとして特徴づけられるという面はあるのですが、これらはかなり漠然とした概念です。そこで、よくある例をいくつか見ていくことにしましょう。

2.7.1 歴史効果

歴史効果とは、研究の最中に特定の出来事が起こって、それが結果の測定値に影響してしまう可能性のことです。たとえば、事前テストと事後テストのあいだに何かが起こるかもしれません。あるいは、23人目の参加者と24人目の参加者のテストのあいだかもしれません。また、当時としては完璧に妥当だった古い研究の論文を読んでいるけれども、その後世界のほうが変わってしまって、結論がもはや信頼できない、ということもあるでしょう。歴史効果にあたるものの例を挙げてみます。

- あなたは、人々がリスクと不確実性についてどう考えるかに関心を持っています。データ収集は2010年12月に始めました。しかし参加者を見つけてデータを集めるには時間がかかりますので、2011年2月になってもまだ新しい人を探しています。あなたにとって不運なことに(そしてもっと不運な人たちがいるわけですが)、2011年1月にクイーンズランド州で洪水が起こり、何十億ドルもの被害と多くの死者を出しました。当然というべきか、2011年2月に調査された人たちは、2010年12月に調査された人たちとはリスクの扱いについてかなり異なる信念を表明します。このうちどちらが参加者の“本当の”信念を反映しているのでしょうか。答えはおそらく両方だろうと私は思います。クイーンズランドの洪水は、たとえ一時的であつたとしても、オーストラリアの人々の信念を実際に変えたのです。ここで重要なのは、2月に調査された人たちの“歴史”が、12月に調査された人たちとはまるで違っているということです。
- あなたは新しい抗不安薬の心理的效果を調べています。そこで、薬を投与する前に不安を測定します(たとえば自己報告と生理的指標によって)。それから薬を投与し、あとで同じ測定を行います。ところがその途中で、あなたの研究室はロサンゼルスにありますので、地震が起きて参加者の不安が高まってしまいました。

2.7.2 成熟効果

歴史効果と同じように、**成熟効果**も基本的には時間経過に伴う変化の話です。ただし成熟効果は、特定の出来事への反応ではありません。そうではなく、人が時間とともに自分自身で変わっていくことに関係しています。歳をとりますし、疲れますし、飽きもします。成熟効果の例をいくつか挙げてみましょう。

- 発達心理学の研究をするときは、子どもがかなり急速に成長することを意識しておく必要があります。たとえば、ある教育的な工夫が3歳児の語彙数を増やすのに役立つかどうかを知りたいとしましょう。ここで気をつけなければならないのは、その年齢の子どもの語彙数は、放っておいてもとんでもない速さで(1日に何語も)増えていくということです。この成熟効果を考慮せずに研究をデザインしてしまうと、あなたの教育的な工夫が効いているのかどうかを判断できません。
- 実験室でとても長い実験(たとえば3時間かかるようなもの)を行うときには、参加者が飽きたり疲れしたりし始める可能性が非常に高く、この成熟効果のせいで、実験の中で他に何が起きているようとパフォーマンスが低下してしまいます。

2.7.3 反復測定効果

歴史効果の重要な一種に、**反復測定**の効果があります。ある心理的構成概念(たとえば不安)を2回測定したいとしましょう。心配になるのは、1回目の測定が2回目の測定に影響してしまわないか、ということです。言い換えるなら、2回目の測定に影響する“出来事”が1回目の測定そのものである、という歴史効果です。これはまったく珍しいことではありません。例を挙げましょう。

- **学習と練習**: たとえば、1回目の測定のときに参加者が“知能テスト風”の問題の解き方の一般的なコツを学んでしまったために、2回目の“知能”が1回目より上がったように見える、といったことです。
- **検査場面への慣れ**: たとえば、1回目に緊張していればパフォーマンスは下がるでしょう。しかし1回目を最後まで経験してしまえば、どんな検査なのかを見てしまったわけですから、かなり落ち着くことになります。
- **測定によって生じる副次的な変化**: たとえば、気分を測る質問紙が退屈なものであれば、1回目の測定が退屈だったせいで、2回目の気分評定が“退屈”寄りになりやすくなります。

2.7.4 選択バイアス

選択バイアスというのは、かなり広い意味を持つ言葉です。ふたつの参加者群を使った実験を行っていて、それぞれの群には異なる“処遇”が与えられ、処遇の違いが結果の違いをもたらすかどうかを見たい、としましょう。ところが、最善を尽くしたにもかかわらず、群間で性別の偏りが生じてしまったとします(たとえばA群は女性が80%、B群は女性が50%)。そんなことは起こりっこないと思うかもしれませんが、信じてください、起こります。これが選択バイアスの例で、ふたつの群に“選ばれて入った”人たちの特性が異なっているわけです。もしその特性が結果に関係するもの(たと

えばあなたの処遇が男性より女性によく効く) だとしたら、これは大問題です。

2.7.5 脱落の偏り

脱落の影響について考えるときには、2種類に区別しておく役に立つことがあります。ひとつめは**均質な脱落**で、脱落の効果がすべての群、処遇、条件で同じである場合です。さきほどの例で言えば、飽きっぽい参加者が実験のすべての条件からだいたい同じ割合で抜けていく場合に(そしてその場合に限って)、脱落は均質だということになります。一般に、均質な脱落の主な影響は、標本が代表的でなくなってしまうことです。ですから、いちばんの心配は結果の一般化可能性が下がることになります。つまり、外的妥当性が失われるわけです。

ふたつめの脱落は**不均質な脱落**で、脱落の効果が群ごとに異なる場合です。こちらは**脱落の偏り**と呼ばれることのほうが多く、研究そのものが引き起こす一種の選択バイアスです。心理学の歴史上はじめて、完璧にバランスのとれた代表的な標本を見つけることに成功した、としましょう。その完璧な標本に“ダニのとんでもなく長くて退屈な実験”を実施し始めるのですが、なにしろとんでもなく長くて退屈なものですから、多くの人が脱落し始めます。これを止めることはできません。参加者には、どんな実験であれ、いつでも、どんな理由であれ、やめる権利が絶対にありますし、研究者としての私たちには、その権利があることを伝える道徳的(かつ職業的)な義務があります。さて、“ダニのとんでもなく長くて退屈な実験”の脱落率がとても高かったとしましょう。この脱落がランダムである見込みはどのくらいだと思いますか。答えはゼロです。ほぼ確実に、残った人たちは去った人たちよりも勤勉で、退屈に強い人たちなのです。たとえば勤勉さが、私が関心を持っている心理現象に関係する程度に応じて、この脱落は結果の妥当性を下げることになります。

もうひとつ例を挙げましょう。ふたつの条件からなる実験をデザインしたとします。“処遇”条件では、実験者が参加者を侮辱してから、服従性を測る質問紙に答えてもらいます。“統制”条件では、実験者はどうでもいい世間話を少しして、それから質問紙に答えてもらいます。この研究の怪しい科学的価値と疑わしい倫理性はさておき、何がまずいことになりそうかを考えてみましょう。一般論として、面と向かって侮辱されると、人はぐっと非協力的になるものです。ですから、統制条件よりも処遇条件のほうがずっと多くの人が脱落する可能性がかなり高いわけです。そしてこの脱落はランダムではありません。いちばん脱落しやすいのは、おそらく、実験に従順に最後まで付き合うことの重要性をさほど気にしない人たちでしょう。いちばん反抗的で従順でない人たちが処遇群からは去り、統制群からは去らなかったのですから、ここに交絡が持ち込まれたことになります。つまり処遇群で実際に質問紙に答えた人たちは、統制群の人たちよりもともと従順で言うことを聞きやすい人たちだったのです。要するにこの研究では、侮辱することで人が従順になったのではありません。よ

り反抗的な人たちを実験から追い出ただけなのです。この実験の内的妥当性は完全に台無しです。

2.7.6 無回答バイアス

無回答バイアスは、選択バイアスや脱落の偏りと密接に関係しています。いちばん単純な形はこうです。1000 人に調査票を郵送したところ、返ってきたのは 300 人分だけでした。回答した 300 人は、ほぼ確実にランダムな部分標本ではありません。調査に回答する人は、回答しない人と系統的に異なっているのです。ここから、回答した 300 人から母集団全体へ一般化しようとするときに問題が生じます。標本がまったくランダムではなくなっているからです。ただし、無回答バイアスの問題はこれだけにとどまりません。たとえば回答した 300 人のなかでも、全員がすべての設問に答えているとは限らないでしょう。仮に 80 人がある設問に答えないことを選んだとしたら、これは問題になるでしょうか。いつものように、答えは「場合による」です。答えられなかった設問が質問紙の最終ページにあり、その 80 通が最終ページを欠いた状態で返送されてきたのなら、欠測はたいした問題ではない可能性が高いでしょう。おそらくページが外れてしまっただけです。しかし、80 人が答えなかった設問が、質問紙のなかでもっとも対決的だったり個人に踏み込んだりするものだったなら、ほぼ確実に問題があります。要するにここで扱っているのは、**欠測データ**と呼ばれる問題です。欠けているデータがランダムに“失われた”のであれば、大した問題ではありません。系統的に欠けているのであれば、大問題になり得ます。

2.7.7 平均への回帰

平均への回帰とは、ある指標の極端な値にもとづいてデータを選んだときに起こることを指します。その変数には自然なばらつきがありますから、次に測定したときには、純粋に偶然によって、2 回目の測定値は 1 回目ほど極端ではなくなるのがほぼ確実なのです。

例を挙げましょう。心理学教育がとても優秀な子どもたちに悪影響を与えるかどうかに関心があるとします。そこで、高校の成績が最上位だった心理学 1 の受講生 20 名を選び、大学でどのくらいの成績をとっているかを見ます。すると、平均よりはずっと良い成績なのですが、高校ではクラスの首位だったのに、大学では首位になっていないことがわかりました。どういうことでしょうか。まず自然に思いつくのは、心理学の授業がその学生たちに悪影響を与えているに違いない、ということです。しかし、それが説明になっている可能性は十分にあるものの、ここで見ているのは“平均への回帰”の一例である可能性のほうが高いのです。どういう仕組みかを見るために、高校であれ大学であれ、クラスで最高点をとるには何が必要かを少し考えてみましょう。大きなクラスであれば、とても優秀な人がたくさんいます。最高点をとるには、とても優秀で、とても努力していて、そして少し運が良くなければなりません。試験があなた特有の得意分野にぴったり合った問題を出してくれる必要がありますし、答えるときにばかな間違い（誰にでもたまにあることです）をしないようにしなければなりません。そこが肝心なところで、知性と努力はひとつのクラスから次のクラスへ持ち越

せませんが、運は持ち越せないのです。高校で運が良かった人と、大学で運が良い人は同じではありません。それがまさに“運”の定義というものです。この結果として、ある測定値の極端な値の人たち(上位 20 名)を選ぶとき、あなたは努力と能力と運を同時に選んでいることになります。ところが運のほうは 2 回目の測定に持ち越されません(持ち越されるのは能力と努力だけです)ので、2 回目に測定したとき(大学で)には、この人たちはみな少し下がると予想されるわけです。つまり得点は少し下がり、他のみんなのほうへ戻っていきます。これが平均への回帰です。

平均への回帰は驚くほどよく起こります。たとえば、とても背の高いふたりに子どもができれば、その子どもは平均より背が高くなる傾向はあるものの、親ほどは高くなりません。とても背の低い親の場合は逆のことが起こります。とても背の低い親からは背の低い子どもが生まれる傾向がありますが、それでもその子どもたちは親より背が高くなる傾向があります。また、この現象はきわめて見えにくいこともあります。たとえば、人は肯定的なフィードバックよりも否定的なフィードバックからよく学ぶ、ということを示唆する研究がありました。しかしこれを示すためにとられた方法は、うまくできたときには正の強化を与え、できなかったときには負の強化を与える、というものでした。そして観察されたのは、正の強化のあとには成績が下がり、負の強化のあとには成績が上がる傾向がある、ということでした。しかしここに選択バイアスがあることに気づいてください。とてもうまくできたときというのは“高い”値を選んでいるわけですから、平均への回帰によって、強化が与えられたかどうかとは無関係に、次の試行の成績は悪くなると予想されるべきなのです。同じように、悪い試行のあとには、放っておいても成績は上がる傾向があります。否定的なフィードバックが優れているように見えるのは、平均への回帰によって生じた人工産物なのです(議論については [Kahneman and Tversky 1973](#), を参照)。

2.7.8 実験者バイアス

実験者バイアスにはいろいろな形があります。基本的な考え方は、実験者が善意にもかかわらず、“正解”や“望ましい行動”をそれとなく参加者に伝えてしまい、結果的にうっかり実験結果に影響を与えてしまう、というものです。これは典型的には、実験者が参加者の持っていない特別な知識、たとえば尋ねている質問の正解や、参加者が置かれた条件で期待される成績のパターンについての知識を持っているために起こります。この古典的な例が、1907 年にさかのぼる“賢いハンス”の事例研究です([Pfungst 1911](#); [Hothersall 2004](#))。賢いハンスは、字が読めて数が数えられ、そのほか人間のような知的芸当ができるように見えた馬でした。賢いハンスが有名になったあと、心理学者たちがその行動を詳しく調べ始めました。結果はというと、驚くまでもなく、ハンスは計算のやり方など知らなかったのです。そうではなく、ハンスは周囲の人間の観察者に反応していました。人間のほうは数え方を知っていましたし、馬のほうは人が行動を変えたときに自分も行動を変えることを学習していたのです。

実験者バイアスの問題に対する一般的な解決策は二重盲検法で、実験者も参加者も、参加者がどの条件にいるのか、望ましい行動が何なのかを知らないようにするものです。これは非常に良い解決策

なのですが、完璧に理想的というわけではありませんし、きちんとやり切るのは難しいということも認識しておく必要があります。たとえば、二重盲検の研究を組むいちばんわかりやすい方法は、私の博士課程の学生のひとり(その実験について何も知らない学生)に研究を実施してもらうことでしょう。これで十分な気がします。すべての詳細(たとえば設問の正解や、参加者の条件への割り当て)を知っている唯一の人物(私)は参加者と接触しませんし、参加者と話をする人物(博士課程の学生)は何も知らないのですから。ただし、最後の部分が本当である見込みはきわめて低い、という現実があります。博士課程の学生が研究をきちんと実施するためには、研究者である私から説明を受ける必要があります。そして、たまたまですが、その博士課程の学生は私のことを知っていますし、人間や心理学についての私の一般的な考え(たとえば私は、人間は心理学者が評価するよりずっと賢いと考えがちです)もいくらか知っています。そんなわけで、実験者が私の期待を少しも知らずにいるというのは、ほとんど不可能なのです。そして、ほんの少しの知識でも影響を及ぼし得ます。実験者が、この課題では参加者がうまくできると期待されている、ということをうっかり伝えてしまったとしましょう。“ピグマリオン効果”というものがありまして、人に大きな期待をかければ、その人はそれに応えようとする傾向があります。しかし失敗すると期待すれば、そのとおりになるのです。つまり期待が自己成就的予言になってしまうわけです。

2.7.9 要求特性と反応性

実験者バイアスの話では、実験者の知識や実験への期待が参加者に伝わってしまい、それが人の行動を変えてしまうことが心配でした(Rosenthal 1966)。しかし、これをうまく防げたとしても、自分が心理学の研究に参加しているという事実を参加者に知らせずにおくことは、ほとんど不可能です。そして、誰かが自分を見ている、研究しているとわかっているというだけで、行動にはかなり大きな影響が出ます。これは一般に**反応性**あるいは**要求特性**と呼ばれます。基本的な考え方はホーソン効果によく表れています。研究が自分に注意を向けているという理由で、人はパフォーマンスを変えてしまうのです。この効果の名前は、シカゴ郊外の“ホーソン工場”で行われた研究に由来します(Adair 1984, を参照)。1920年代のこの研究は、工場の照明が労働者の生産性に与える影響を調べたものでした。しかし重要なことに、労働者の行動が変わったのは工場の照明のせいではなく、自分たちが研究されていると知っていたからだったのです。

研究に参加しているというだけで人の行動がどう変わるのか、もう少し具体的に見ていきましょう。ここでは社会心理学者のように考えて、実験中にはとるかもしれないけれども、同じ出来事が現実世界で起きていたらとらないかもしれない役割をいくつか見てみると役に立ちます。

- **良い参加者**は、研究者に対して協力的すぎようとします。実験者の仮説を見抜いて、それを確証しようとするのです。
- **否定的な参加者**は、良い参加者のちょうど逆をやります。なんらかの形で研究や仮説を壊してやろうとするのです。
- **忠実な参加者**は不自然なほど従順です。より現実的な場面ならどうしたかとは無関係に、教示

を完璧に守ろうとします。

- 不安な参加者は、テストされたり研究されたりすることに緊張してしまい、その結果として行動がひどく不自然になったり、社会的に望ましすぎるものになったりします。

2.7.10 プラセボ効果

プラセボ効果は、私たちがとても気にしている要求特性の一種です。治療を受けたという事実だけで結果が改善してしまう状況を指します。古典的な例は臨床試験から来ています。化学的にまったく不活性な薬を渡して、これは病気を治す薬だと伝えと、まったく治療を受けなかった人よりも早く良くなる傾向があるのです。つまり、結果を改善させているのは薬ではなく、治療を受けているという信念のほうなのです。

ただし医学における現在の合意は、真のプラセボ効果はかなりまれであり、かつてプラセボ効果とされていたものの大部分は、実際には自然治癒 (放っておいても良くなる人がいます)、平均への回帰、そのほか研究デザイン上の癖の組み合わせだ、というものです。心理学にとって興味深いのは、少なくとも何らかのプラセボ効果があるというもっとも強い証拠が、自己報告による結果、とりわけ痛みの治療において得られているという点です ([Hróbjartsson and Gøtzsche 2010](#))。

2.7.11 状況・測定・下位母集団の効果

ある意味でこれらの用語は、“そのほかすべての外的妥当性への脅威”をまとめて指す便利な言葉です。参加者をどの下位母集団から集めるかという選択、研究を実施する場所・時期・やり方 (誰がデータを集めるかも含みます)、そして測定に使う道具、これらすべてが結果に影響しているかもしれない、ということを指しています。具体的な心配は、これらが結果に影響することで、より広い範囲の人・場所・測定へ結果が一般化できなくなってしまうことです。

2.7.12 不正、欺瞞、自己欺瞞

ある人にものごとを理解させるのは難しい。その人の給料が、それを理解しないことにかかっている場合には。

– Upton Sinclair

最後にひとつ、触れておくべきだと思うことがあります。研究の妥当性の評価について教科書がよく述べていることを読んでみると、どうしても気になるのが、どの本も研究者は正直であると仮定しているように見えることです。これは笑ってしまいます。少なくとも私の経験では、科学者の大多数

は正直ですが、そうでない人もいます*⁷。それだけでなく、先に述べたように、科学者も信念バイアスと無縁ではありません。研究者が自分自身を欺いて間違っただけを信じてしまうのは簡単なことですし、そこから微妙に欠陥のある研究を行い、論文にするときにその欠陥を隠す、ということも起こり得ます。ですから、あからさまな不正という(おそらくありそうにない)可能性だけでなく、研究が意図せず“偏って”しまっているという(おそらくかなりよくある)可能性も考えておく必要があります。標準的な教科書を何冊か開いてみたのですが、この問題についての議論はあまり見当たりませんでしたので、こうした問題が生じうる形を私なりに挙げてみることにします。

- **データの捏造**。単純にデータをでっちあげてしまう人がいます。これは“善意”から行われることもあります。たとえば研究者が、捏造したデータこそ真実を反映していると信じている場合で、実際のデータを“ちょっときれいにした”ものになっていることもあります。一方で、意図的かつ悪意のある不正の場合もあります。データ捏造が指摘されたり明らかになったりした有名な例としては、Cyril Burt(データの一部を捏造したと考えられている心理学者)、Andrew Wakefield(MMR ワクチンと自閉症を結びつけるデータを捏造したと非難されている人物)、そして黄禹錫(幹細胞研究で多くのデータを改竄した人物)などがあります。
- **でっちあげ**。でっちあげはデータ捏造とよく似ていますが、意図する目的が異なります。でっちあげはしばしば冗談であり、その多くは(いずれ)見破られることを意図しています。でっちあげの狙いは、誰かやある分野の信用を失わせることであることが多いのです。長年のあいだにはよく知られた科学上のでっちあげがいくつもありましたし(たとえばピルトダウン人)、特定の研究分野の信用を落とすための意図的な試みもありました(たとえばソーカル事件)。
- **データの不正確な提示**。見出しを飾るのは不正のほうですが、私の経験ではデータが不正確に提示されているのを見ることのほうがずっと多いのです。これは新聞が間違えること(ほとんど毎回間違えています)を言っているのではありません。データが研究者の考えているようなことを実際には語っていない、ということがよくある、という話です。私の推測では、ほとんどの場合これは意図的な不誠実さの結果ではなく、データ分析の洗練が足りないせいです。たとえば、本書のはじめのほうで扱ったシンプソンのパラドックスの例を思い出してください。何らかの形で“集計された”データが提示されるのはごく普通のことですが、掘り下げて生データを自分で見てみると、集計データと非集計データとがまったく違う話をしていることがあります。あるいは、都合の悪い話をするという理由で、データのある側面が隠されているのに気づくこともあります(たとえば研究者が、ある変数について触れないことを選ぶ、など)。この種の変種はたくさんありますし、その多くは見抜くのがとても難しいのです。
- **研究の“デザインミス”**。これは微妙な話です。基本的な問題は、研究者が最初から欠陥を組

*⁷正直でないなら本物の科学者ではない、と主張する人もいます。それにも一理あるとは思いますが、それは不誠実な言い方です(“本物のスコットランド人”の誤謬を調べてみてください)。実際には、表向きは科学者として雇われ、その仕事も見た目は完全に科学でありながら、まったくの不正を働いている人がたくさんいるのです。そういう人は科学者ではないと言ってその存在をなかったことにするのは、ただの混乱した考え方です。

み込んだ研究をデザインし、その欠陥が論文で報告されることは決してない、というものです。報告されるデータは完全に本物で、正しく分析されているのですが、そのデータを生み出した研究のほうがかかなりおかしい組み立てになっているのです。研究者はどうしてもある効果を見つけないので、その効果が(人工産物として)“簡単に”観察できるように研究を組んでしまいます。もしあなた自身がちょっと不正に手を染めてみたいなら、こんなずるいやり方があります。参加者にとって自分が何をやる“ことになっている”のかが見え見えの実験をデザインし、あとは反応性に魔法をかけてもらうのです。お望みなら二重盲検法の体裁をすべて整えることもできますが、研究の材料そのものが、あなたのしてほしいことをそれとなく参加者に伝えているのですから、何の違いも生みません。結果を論文にしたとき、読者にはこの不正はわかりません。実験の文脈にいる参加者には見え見えのことが、論文を読む人にも見え見えだとは限らないからです。もちろん、こう書くといつでも不正であるかのように聞こえますね。意図的に行われる場合もあるでしょうが、私の経験ではより大きな問題は意図しないデザインミスの方です。研究者が信じてしまっているために、たまたま研究に欠陥が組み込まれ、そして論文にする段階でその欠陥が魔法のように消えてしまうのです。

- **データマイニングと事後的な仮説づくり**。研究の著者がデータを多かれ少なかれ不正確に提示してしまうもうひとつの方法が、“データマイニング”と呼ばれるものです(統計分析における“分岐する小径の庭”の一部としてのより広い議論は [Gelman and Loken 2014](#), を参照)。のちほど議論しますが、データをいろいろな方法で分析し続けていけば、いずれは本物の効果に“見える”けれども本物ではないものが見つかります。これが“データマイニング”です。かつてはデータ分析に何週間もかかりましたのでかなりまれなことでしたが、いまや誰もが非常に強力な統計ソフトを自分のコンピュータに持っていますので、ごく普通のことになりつつあります。データマイニングそれ自体が“間違い”なのではありませんが、やればやるほど大きなリスクを負うことになります。間違いなのは、そして私の疑うところではとてもよくあるのは、明示されないデータマイニングです。つまり研究者が、人類の知る限りのあらゆる分析を実行し、うまくいくものを見つけ、そしてそれが最初から唯一実施した分析であるかのようにふるまう、ということです。さらに悪いことに、データマイニングを隠すために、データを見たあとで仮説を“発明”することもよくあります。はっきりさせておきましょう。データを見たあとで自分の考えを変えることも、新しい“事後的な”仮説を使ってデータを再分析することも、間違いではありません。間違いなのは(そして私の疑うところではよくあるのは)、そうしたことを明示しないことです。明示すれば、他の研究者はあなたのふるまいを考慮に入れることができます。明示しなければ、それができません。そしてそれが、あなたのふるまいを人を欺くものにしてしまうのです。よくないことです。
- **出版バイアスと自己検閲**。最後に、広く行き渡っているバイアスが、否定的な結果の“非報告”です。これを防ぐのはほとんど不可能です。雑誌は投稿された論文をすべて掲載するわけではありません。“何か”を見つけた論文のほうを載せたがるのです。ですから、20人がフィネガンズ・ウェイクを読むと人は正気を失うかどうかを調べる実験を行い、そのうち19人が

「そんなことはない」という結果を得たとしたら、掲載されるのはどれだと思いますか。もちろん、フィネガンズ・ウェイクが正気を失わせると見つけた 1 本の研究です^{*8}。これが出版バイアスの例です。効果を見つけないかった 19 本の研究は誰も発表しませんでしたので、素朴な読者はそれらが存在したことすら知りません。さらに悪いことに、ほとんどの研究者はこのバイアスを“内面化”してしまい、自分の研究を自己検閲するようになります。否定的な結果は掲載してもらえないとわかっているのに、報告しようとするしないのです。私の友人の言葉を借りれば、“掲載される実験 1 本につき、失敗が 10 本ある”のです。彼女の言うとおりです。厄介なのは、そうした研究のいくつか(たぶん大部分)はつまらない理由による失敗(たとえば何かをしくじった)なのですが、中には“うまくいった”実験を論文にするとときに明示すべき、本物の“帰無”の結果もあるということです。そして、どちらがどちらなのかを見分けるのはたいてい難しいのです。手始めには、“なぜ発表される研究知見のほとんどは偽なのか”という気の滅入るタイトルの [Ioannidis \(2005\)](#) の論文がよいでしょう。これが心理学で実際に起きているという統計的証拠を示した [Kühberger, Fritz, and Scherndl \(2014\)](#) の研究も見てもいいとお勧めします。

この種の問題は、考えるべきものがまだたくさんあるでしょうが、手始めとしてはこのくらいでいいでしょう。私が本当に指摘したいのは、現実世界の科学は生身の人間によって行われているという、あまりにも当たり前の事実です。他のみんなが正直で公平だと自動的に仮定してしまうのは、よほど騙されやすい人だけです。実際の科学者はふつうそこまでうぶではないのですが、どういうわけか世間は私たちがそうであるかのように振る舞いたがりますし、私たちが書く教科書もそのステレオタイプを強めているように見えます。

2.8

要約

この章は、心理学の研究法を網羅的に論じようとしたものではありません。このテーマをきちんと扱おうとしたら、本書と同じくらいの分量の本がもう 1 冊必要になるでしょう。とはいえ現実には、統計と研究デザインはとても密接に絡み合っていますので、重要なトピックをいくつか押さえておくとても役に立ちます。この章では、次のようなトピックを簡単に見てきました。

- 心理学的測定への導入 (セクション 2.1)。理論的な構成概念を操作化するとはどういうことでしょうか。変数を持ち、測定を行うとはどういうことでしょうか。

^{*8}本当のところは、そもそもフィネガンズ・ウェイクを読もうとするのは正気でない人だけだ、というだけの話でしょうけど。

- **測定の尺度と変数の種類** (セクション 2.2)。ここにはふたつの異なる区別があったことを思い出してください。ひとつは離散データと連続データの違い、もうひとつは4つの尺度水準(名義・順序・間隔・比率)の違いです。
- **測定の信頼性** (セクション 2.3)。“同じ”ものを2回測ったら、同じ結果が出ると期待してよいでしょうか。測定が信頼できる場合に限ります。しかし“同じ”ことをする、とはどういう意味でしょうか。だからこそ、信頼性にはいくつもの種類があるのです。それが何だったかをしっかり覚えておいてください。
- **用語: 予測変数と結果変数** (セクション 2.4)。分析のなかで変数はどんな役割を果たすのでしょうか。予測変数と結果変数の違いを覚えているでしょうか。従属変数と独立変数はどうでしょう。
- **実験的な研究デザインと非実験的な研究デザイン** (セクション 2.5)。実験を実験たらしめているものは何でしょうか。それは立派な白衣でしょうか、それとも研究者が変数を統制することと関係があるのでしょうか。
- **妥当性とその脅威** (セクション 2.6)。あなたの研究は、測りたいものを測っているでしょうか。何がうまくいかなくなり得るでしょうか。それにしても、うまくいかなくなり得るやり方のリストは、やたらと長くありませんでしたか。気のせいでしょうか。

ここまでの話で、研究デザインが研究方法論のきわめて重要な一部であることがはっきりしたと思います。この章は [Campbell et al. \(1963\)](#) の古典的な小著をもとに組み立てましたが、研究デザインについての教科書はもちろん山ほどあります。お気に入りの検索エンジンで数分も探せば、何十冊も見つかるでしょう。

Part II.

Describing and displaying data with JASP

3. JASP 入門

ロボットは良く働く。

–Roger Zelazny^{*1}

この章では、JASP の入門方法について説明します。JASP をダウンロードしてインストールする方法について簡単に説明しますが、この章のほとんどでは、JASP ユーザーインターフェースの使用法の入門に焦点を当てます。この章の目標は、統計の概念を学ぶことでは**ありません**。そうではなく、JASP の仕組みとソフトと快適にやり取りする方法について学びます。これを行うために、データセットと変数を検討することに時間を費やします。そうすることで、JASP での作業がどのようなものかを少し感じることができます。

ただし、詳細に進む前に、JASP を使用する理由について少し説明することには少なからず価値があります。本書を読んでいるということは、あなたにはすでに JASP を使用する理由があるのでしょう。ただ、その理由が「統計の授業で使用しているから」である場合、なぜ教授が授業で JASP を使用することを選択したのかについて少し説明する価値があります。もちろん、他の人々がなぜ JASP を選択するのかは本当のところ知らないのですが、私が使う理由について話します。

- 当たり前のことですが、手動で行うよりもコンピューターで統計を行うことは、速く、簡単で、強力であるということは述べる価値があります。コンピューターは頭を使わない反復作業に優れており、統計計算の多くは頭を使わない反復作業です。ほとんどの人にとって、鉛筆と紙で統計計算を行う唯一の理由は、学習のためです（新しい概念を学ぶ時は専門家でさえこれを行います）。私の授業では、そのようにいくつかの計算を行うことを時々提案しますが、その唯一の真の価値は教育です。自分でいくつか計算することは、統計の「感覚」を得るのに役立ちますので、一度行う価値があります。しかし、一度だけです！
- 従来のスプレッドシート（例えば、Microsoft Excel）で統計を行うことは、一般的には長期的に見ると良くない考えです。多くの人はそれらに馴染みがあると感じるかもしれませんが、スプレッドシートでは、分析できる範囲が非常に限られています。スプレッドシートを使用し

^{*1}Source: *Dismal Light* (1968).

て実際のデータ分析を行う習慣を身につけた場合、非常に深い穴に掘り込まれることになります。

- プロプライエタリ・ソフトウェア^{*2}を避けることは、とても良い考えです。購入できる商用パッケージはたくさんあります。私が好きなものもあれば、そうでないものもあります。通常、商用パッケージは外観の体裁がとても良く、一般に非常に強力です（スプレッドシートよりもはるかに強力です）。しかし、非常に高価です。通常、企業は「学生版」（本物の一部が使えない版）を非常に安く販売し、その後、びっくりするような価格で完全版の「教育版」を販売しています。また、驚愕するほど高い値段で、商用ライセンスを販売しています。ここでのビジネスモデルは、学生時代にあなたを引き込んで、現実の世界に出かけるときに彼らのツールに依存したままにすることです。しゃくにさわるからといって彼らを責めるのは難しいですが、個人的には、避けることができるなら、何千ドルも払いたくはありません。そして、あなたはそれを避けることができます。JASP のような、オープンソースで無料のパッケージを利用すれば、法外なライセンス料を支払う必要がなくなります。

これらが JASP を使用する主な理由です。ただし、欠点がないわけではありません。JASP は、比較的新しいため^{*3}、それをサポートする教科書やその他のリソースがあまりありません。私たちがよく陥ってしまういくつかの迷惑な癖がありますが、全体的には長所が短所を上回っていると思います。これまでに出会った他のどの選択肢よりもそうです。

3.1

JASP のインストール

さて、セールストークは十分でしょう。始めましょう。他のソフトウェアと同じように、JASP はコンピューターにインストールする必要があります。幸いなことに、JASP はオンラインで無料で配布されており、JASP ホームページからダウンロードできます。

<https://jasp-stats.org/>

ページの上の方で、「ダウンロード」という見出しをクリックします。次に、Windows ユーザー、Mac ユーザー、および Linux ユーザー用の個別のリンクが表示されます。関連リンクをたどると、読んで字のと通りのオンラインの説明があります。この原稿の執筆時点では、JASP の現在のバージョンは 0.9.2.0 ですが、通常は数か月ごとに更新されるので、おそらく新しいバージョンが必要になり

^{*2}訳注 ソフトウェアの配布者が、ソフトの使用・改変・複製などを制限しているソフトウェア

^{*3}これが執筆された 2019 年 5 月

ます。^{*4}

3.1.1 JASP の起動

いずれにせよ、使用しているオペレーティングシステムに関係なく、JASP を開いて、起動させましょう。JASP の初回起動時に、図 3.1 のようなユーザーインターフェイスが表示されます。




Figure3.1 起動時の JASP

他の統計ソフトウェアの使用経験がある場合、データの入力を開始する場所がないことに少しがっかりするかもしれません。これは JASP 開発者側の意図的な決定です。彼らの哲学は、ユーザーが最も快適なエディターを使用できるようにすることです^{*5}。したがって、JASP にデータを読み込むため上で推奨される方法は、CSV ファイル (.csv) を読み込むことです。CSV ファイルは、スプレッドシートプログラムで作成（と開くことが）できるテキストベースのデータ形式です。これについて

^{*4} この本でやる作業とは違って JASP は頻繁に更新されます。実際、この本の執筆中に何度かアップグレードがありました。が、この本の内容に大きな違いはありませんでした。

^{*5} この重要な問題についての議論が、<https://jasp-stats.org/2018/05/15/data-editing-in-jasp/> にあるので、参照ください

の詳細は、このあとすぐに説明します。

3.2

分析

分析は、上にあるいくつかのボタンから選択できます。分析を選択すると、特定の分析のための「options panel」が表示されます。あなたは、分析のさまざまな部分にさまざまな変数を割り当てたり、さまざまなオプションを選択できます。同時に、分析結果は右側の「Results panel」に表示され、オプションを変更するとリアルタイムで更新されます。

分析を正しく設定したら、オプションパネルの右上にある「OK」ボタンをクリックして、分析オプションを閉じることができます。これらのオプションに戻りたい場合は、結果をクリックすることでできます。このようにして、あなた（または同僚）が以前に作成した分析に戻ることができます。

特定の分析が不要になった場合は、結果のコンテキストメニューで削除できます。特定の結果のヘッダー（もしくは、▼）をクリックしてメニューを表示して、「Remove Analysis」を選ぶと、分析を削除できます。しかし、これについては後で詳しく説明します。まず、JASP にいくつかのデータを入れてみましょう。

3.3

JASP へのデータ読み込み

データ分析を行う時に、私たちに関係があると思われるファイル形式がいくつかあります。この本の観点から特に重要なのは 2 つです:

- *.jasp files* は、拡張子が *.jasp* のファイルです。これは、JASP がデータ、変数、および分析を保存するために使用する標準的なファイル形式です。
- **コンマ区切り (CSV)** ファイルは、拡張子が *.csv* のファイルです。これは、一般的な古いテキストファイルであり、さまざまなソフトウェアプログラムで開くことができます。csv ファイルは非常にシンプルなので、csv ファイルにデータを保存するのにかなりよく使われます。

3.3.1 CSV ファイルからデータをインポートする

かなり広く使用されているデータ形式の 1 つは、地味な「カンマ区切り」ファイルです。CSV ファ




Figure3.2 booksales.csv のデータファイル。左側は、スプレッドシートソフトを使用してファイルを開きました。ファイルが基本的にテーブルであることを示しています。右側は、同じファイルが標準のテキストエディター（Mac の TextEdit）で開きました。ファイルがどのようにフォーマットされているか示しています。テーブルへの記入は、コンマで区切られます。

イルとも呼ばれ、通常は拡張子.csv を持ちます。CSV ファイルは、昔からある単にシンプルなテキストファイルであり、保存されるのは基本的に単なるデータのテーブルです。これを Figure 3.2 に示します。この図は、私が作成した booksales.csv というファイルを示しています。ご覧のとおり、各行は 1 ヶ月間の書籍販売データを表します。最初の行には実際のデータは含まれませんが、変数の名前があります。

CSV ファイル（あなたが作成したファイルか、誰かが提供したファイル）があれば、左上隅にある「File」タブをクリックして「Open」を選択し、表示されたオプションから選択をすることで、JASP でファイルを開けます。最も一般的には、「Computer」を選択してから「Browse」を選択します。これにより、あなたが使っているオペレーティングシステムに特有のファイルブラウザーが開きます。Mac を使用している場合は、ファイルの選択に使用する通常の Finder ウィンドウのように見えるでしょう。Windows では、エクスプローラーウィンドウのように見えます。Mac での表示例は、




Figure3.3 JASP がインポートする CSV ファイルを選択するように求める Mac 上のダイアログボックス。Mac ユーザーはこれをすぐに理解すると思います。これは、Mac があなたにファイルを探す時に要求する一般的な方法です。Windows ユーザーにはこれは表示されませんが、代わりに、ファイルを選択するときに Windows がいつも出してくる通常のエクスプローラーウィンドウが表示されます。

Figure 3.3 に示されています。あなたはきっと自分のコンピュータに慣れているでしょうから、インポートしたい csv ファイルを見つけるのに問題はないはずです！ 必要なものを見つけて、「Open」ボタンをクリックしてください。

3.4

スプレッドシート

JASP に読み込まれたデータは、スプレッドシートの形で表示されます。各列が「変数」を、各行が「ケース」あるいは「参加者」を表します。

3.4.1 変数

JASP で最もよく使われる変数は「データ変数 (Data Variables)」で、CSV ファイルから読み込んだデータがこれにあたります。データ変数は 3 つの測定水準のいずれかをとり、どれであるかは変数の列の見出しにある記号で示されます。

名義 (*Nominal*) 変数は、テキストのラベルであるようなカテゴリカル変数のためのものです。たとえば Gender という列に Male と Female という値が入っていれば、これは名義変数です。人の名前もそうですね。名義変数の値は数値であってもかまいません。こうした変数は、値をテキストではなく数字でコード化したデータを読み込むときに最もよく使われます。たとえば、データセットのある列に、男性なら 1、女性なら 2 という値が入っている、といった場合です。こうした値には、変数エディタを使って「人が読んで分かる」きれいなラベルを付けることができます (これについては後で詳しく述べます)。

順序 (*Ordinal*) 変数は名義変数に似ていますが、値に特定の順序があるという点が違います。例としては、3 が「強くそう思う」、-3 が「まったくそう思わない」であるようなリッカート尺度が挙げられます。

スケール (*Scale*) 変数は、連続的な尺度の上にある変数です。身長や体重が例になるでしょう。これは「間隔尺度」や「比率尺度」とも呼ばれるものです。

なお、データファイルを開くとき、JASP は各列のデータから変数の型を推測しようとします。ただしこの自動判定が正しいとはかぎりませんので、変数エディタを使って手作業で変数の型を指定する必要が生じることもあります。

3.4.2 計算変数

計算変数 (Computed Variables) とは、他の変数に対して計算を行うことで値が決まる変数のことです。計算変数は、対数変換、 z 得点、合計点、逆転項目の得点化、平均値など、さまざまな目的に使えます。

計算変数は、データのスプレッドシートの見出し行にある「+」ボタンでデータセットに追加できます。ボタンを押すとダイアログボックスが現れ、R のコードを書くか、ドラッグ・アンド・ドロップのインターフェースを使うかして、計算式を指定できます。ここではそういう機能があるということだけ知っておいてもらえれば十分で、その使い方の説明は今の話題からは少し外れます。詳しくは後ほど!

3.4.3 コピーとペースト

最後に触れておきますと、JASP はアメリカ心理学会 (APA) の書式にのっとったきれいな表と、見

栄えのよい図を作ってくれます。これらをコピーして Word の文書に貼り付けたり、同僚あてのメールに貼り付けたりできると、何かと便利です。結果をコピーするには、目的の出力の見出しをクリックし、メニューからコピーしたいものを選びます。“copy”を選ぶと内容がクリップボードにコピーされ、通常のやり方で他のプログラムに貼り付けられます。これは後で分析をするときに練習してみるとよいでしょう。また、 $\text{\LaTeX}$ という文書作成システムを使っているのであれば、“Copy special”から“LaTeX code”を選ぶことができます。そうすると $\text{\LaTeX}$ の記法がクリップボードに入ります。

3.5

データの尺度水準を別のものに変える

変数の水準を変えたいことがあります。これはいろいろな理由で起こります。ファイルからデータを読み込んだとき、間違った形式で入ってきてしまうことがあります。数値が名義のテキスト値として読み込まれてしまうこともあります。日付がテキストとして読み込まれることもあるでしょう。参加者 ID の値が連続変数として読まれることもありますし、名義の値が順序、さらには連続として読まれてしまうこともあります。ですから、ある変数の測定水準を別の測定水準に変換したくなる場面は、十分にありうるわけです。あるいは正確な用語を使うなら、変数のあるクラスから別のクラスへ**強制変換 (coerce)** したい、ということです。

3.4 節では、さまざまな変数の水準をどう指定するかを見てきました。ある変数の測定水準を変えたいのであれば、その変数について JASP のデータビューで変更できます。連続、順序、名義のうち、したい測定水準のチェックボックスをクリックするだけです。

3.6

JASP を終了する

この章で最後に扱っておくべきことが 1 つあります。JASP の終了のしかたです。難しいことはありません。他のプログラムと同じようにプログラムを閉じるだけです。ただし、終了する前にやっておきたいのは、作業を保存することでしょう！これには 2 つの側面があります。データセットに加えた変更を保存することと、実行した分析を保存することです。

データセットに加えた変更は、新しいデータセットとして保存するのがよい習慣です。そうしておけば、いつでも元のデータに戻ることができます。JASP で変更を保存するには、‘File’ タブから ‘Export Data’ を選び、‘Browse’ をクリックしてファイルを保存したいディレクトリまで移動し、変更後のデータセットに新しいファイル名を付けます。

あるいは、.jasp ファイルとして保存すれば、変更後のデータと実行した分析の両方を保存する

ことができます。そうするには、'File' タブから 'Save as' を選び、'Browse' をクリックしてファイルを保存したいディレクトリまで移動し、この .jasp ファイルのファイル名を入力します。後で自分が見つけられる場所に保存することを忘れないでください。私はたいてい、そのデータセットと分析のために新しいフォルダを作るようにしています。

3.7

要約

初学者に新しい統計ソフトウェアを教えようとする本は、どれもだいたい同じ話題を、だいたい同じ順序で扱うことになります。本書も例外ではありません。みんなと同じやり方でやるという偉大な伝統にのっとり、この章では次の話題を扱いました。

- 3.1 節。JASP をダウンロードしてインストールし、起動しました。
- 3.2 節。分析を実行し結果が表示される JASP の部分について、ごく簡単に見ておきましたが、詳しくは本書の後の方に譲りました。
- 3.3 節。JASP でデータファイル (.csv 形式のもの) を読み込む方法を見ました。
- 3.4 節。JASP のスプレッドシートの部分をもう少し時間をかけて見て、さまざまな変数の型について考え、新しい変数を計算する方法にも簡単に触れました。
- 3.5 節。そして、データがある型から別の型へ強制変換する必要があることがある、ということを見ました。
- 3.6 節。最後に、作業を終えて JASP を終了しようというときに、データセットと分析をどう保存しておくのがよいかを見ました。

私たちはまだ、データ分析と呼べるようなものには何もたどり着いていません。次の章では、もう少し近づけるかもしれませんね!


4. 記述統計

新しいデータを手に入れたときはいつでも、最初にやるべきことの一つは、データを簡単にまとめ、その傾向を理解しやすくする方法を見つけることです。これこそ**記述統計**の全てです(この反対は推測統計です)。実際、多くの人が“統計”という言葉で、記述統計の同義語だと思っています。この章で話そうとしているのがそれなのですが、詳細に入る前に、なぜ記述統計が必要なのかという感覚を掴んでもらいたいと思います。そうするためにまず、`aflsmall_margins` ファイルを開いて、ファイルの中にある変数を見てみましょう。

このように、一つの変数 `afl.margins` しかありません。この章ではこの変数に注目しますので、これが何なのか少し説明します。この本に含まれるデータセットとは違って、これは実際に得たデータであり、オーストラリアのフットボールリーグ (AFL) に関するデータです^{*1}変数 `afl.margins` は、2010 年シーズンのホームゲーム、アウェイゲーム含めた全 176 ゲームの得点差 (獲得点数) が含まれています。

このアウトプットから、このデータが何を言おうとしているのか掴み取るのは簡単ではありません。“データを眺めている”だけでは、データを理解するのに全く効果的ではないのです。このデータが何を言おうとしているか、それを掴み取るためには、記述統計を計算する必要があり(この章で扱います)、わかりやすい図を描くことです(第 5 章で扱います)。二つのやり方のうち、記述統計の方がより簡単なのですが、私たちが見ようとしているデータがどんなものなのかのイメージを掴むために、この `afl.margins` データのヒストグラムをお見せすることにしましょう。図 4.2 を見てください。どうやってヒストグラムを描くかについては、セクション 5.1 で説明しますから。今は、ヒストグラムを見てそれが `afl.margins` データを正しく理解する方法であることがわかってもらえれば結構です。

^{*1}オーストラリア人ではない人にむけた注意：AFL はオーストラリアのルールで行われるフットボール競技です。この章を読むためにオーストラリアのルールを調べる必要は全くありません。



	afl.margins
1	56
2	31
3	56
4	8
5	32
6	14
7	36
8	56
9	19
10	1
11	3
12	104
13	43
14	44

Figure4.1 JASP が aflsmall_margins.csv ファイルを開いて変数を見させているスクリーンショット

.....

4.1

傾向の測定

図 4.2 で示したようなデータの絵を描くというのは、データがどうなっているのかの“要点”をもたらす優れた方法です。データをいくつかの単純な“集約された”統計量に凝縮してみることが、特に便利です。いろんな場面で、まず計算してもらいたいのは中心傾向についての測定です。すなわち、あなたのデータの“平均”や“真ん中”がどのあたりにあるのかを捉えて欲しいのです。最もよく使われる三つの数字は、平均値、中央値、最頻値です。これを順番に説明していきますので、その後でそれぞれがどういうときに便利なのかをみていきましょう。




Figure4.2 2020 年の AFL 得点差データ (変数 `af1.margins`) のヒストグラム。ご想像の通り、より大差がつくゲームはより少ないのが見て取れます。

4.1.1 平均値

観測値のセットの**平均値**は、普通の、昔ながらの平均値です。全ての値を足し上げて、足した値の数で割ります。最初の 5 つの AFL の得点差は、56,31,56,8,32 ですが、これらの平均値を計算するには単に次のようにするだけです。

$$\frac{56 + 31 + 56 + 8 + 32}{5} = \frac{183}{5} = 36.60$$

もちろん、この平均の定義は誰にとっても新しいものではないでしょう。アベレージ (すなわち平均値) は、日常生活でもよく使われていますから、みなさんにとってもなじみ深い物でしょう。平均の概念についてはみなさん理解しているでしょうから、この計算を表記するために統計学者が使う数学的表記法について説明する機会とさせてもらって、その後で JASP でどのように計算するか紹介することにしましょう。

最初に導入する表記法は N です。これは平均するときの観測度数の数を表すのに使います (今回の場合は $N = 5$ です)。つぎに、観測値そのものについてのラベルをつけます。これには伝統的に X が用いられ、具体的にそのどれを指し示すのかについて、添字を使います。つまり、 X_1 とすれば最

初の観測値, X_2 とすれば 2 番目の観測値, 以下同様に X_N までいきます。あるいは, 同じことをもう少し抽象的に表現するために, X_i で i 番目の観測値を指すことにします。表記法についてははっきりさせるために, 以下の表では `afl.margins` 変数にある 5 つの観測について, 数学的表記法と対応する実際の値の関係をリストアップしています。

観測値	記号	観測された値
得点差, 第 1 試合	X_1	56 点
得点差, 第 2 試合	X_2	31 点
得点差, 第 3 試合	X_3	56 点
得点差, 第 4 試合	X_4	8 点
得点差, 第 5 試合	X_5	32 点

オウケイ，では平均の式を書いてみましょう。伝統的に，平均を表すのに $\bar{X}$ を使います。平均の計算は以下の式で表現できます。

$$\bar{X} = \frac{X_1 + X_2 + \dots + X_{N-1} + X_N}{N}$$

この式はまったく正しいのですが，ちょっとばかり長ったらしいので，**総和記号**である Σ を導入してこれを短縮しましょう^a。ここでは最初の 5 つの観測について足しあわせをしたいわけですから，長い書き方ですと $X_1 + X_2 + X_3 + X_4 + X_5$ となりますが，ここで総和の記号を使ってこれを次のように短縮します。

$$\sum_{i=1}^5 X_i$$

文字通り，これは「1 から 5 までの全ての i について， X_i の値を足し合わせる」と読みます。しかしその意味は基本的に「最初の 5 つの観測値を足す」，です。どちらにせよ，これは平均を使うための記号として使われ，次のように書きます。

$$\bar{X} = \frac{1}{N} \sum_{i=1}^N X_i$$

正直なところ，この数学的な表記法が平均の概念を明確にするのに役立つとは思えません。実際には，私が言葉で言ったのと同じことを書き出しているだけです。すなわち，全ての数字を足しあわせて，足した項の数で割る，です。しかし詳細に書き込んだ本当の理由はこれではありません。私のゴールは，誰もがこの本を読むときに使われるであろう記号について，はっきりと理解しておいてもらうことにあります。 $\bar{X}$ は平均， Σ は総和， X_i は i th 番目の観測値で N は観測の総数，ということをね。これらの記号は再利用されるので，みなさんがこれを使った式を「読む」ことができるように，さらに「多くのものを足しあわせて別のもので割る」と言えるように理解してもらうことが重要なのです。

^a総和に対して Σ を使うのは，勝手に決めたわけではありません。これはギリシア文字シグマの大文字で，アルファベットで言う S のアナロジーだからです。同様に，全ての積を示すための記号もあって，それは “products”(総積) と呼ばれるので文字としては Π を使います (ギリシアのパイの大文字で，これはアルファベットの P のアナロジーだからです)。

4.1.2 JASP での平均の計算

数学の話はここまで。計算してくれる魔法の箱はどうやって手に入れたらいいでしょうか？ 観測値の数が大きくなったら，コンピュータを使って計算させるのが何より簡単です。全てのデータを使って平均の計算をするために，JASP を使しましょう。最初のステップは ‘記述’ のボタンをクリックして，次に ‘記述統計’ をクリックしてください。それから変数 `afl.margins` をハイライト

させて、'右矢印' をクリックしてそれを '変数ボックス' に移します。するとすぐに画面の右側に表が現れます。そこには '記述' についての情報があります。図 4.3 をご覧ください。




Figure4.3 AFL における 2010 年得点差データ (変数 `afl.margins`) のデフォルトで示される記述統計

図 4.3 に見て取れるように、変数 `afl.margins` の平均値は 35.301 です。他の情報として、観測度数の総数 (N=176) や、欠損値の数 (ありません)、変数の中央値、最小値、最大値も含まれていますね。

4.1.3 中央値

中心化傾向の二つ目の測度としてよく使われるのは、**中央値**です。この説明は平均よりも簡単です。変数セットの中央値というのは、ちょうど真ん中の値という意味です。AFL データの最初の 5 つの値、56,31,56,8,32 に興味があると思ってください。これらの数字の中央値を探すために、これを昇順に並べ替えます。

8, 31, **32**, 56, 56

見てみると、これら 5 つの観測値の中央値は 32 ですね。並べ替えたリストの真ん中にあるからです (より分かりやすくするために、太字にしました)。簡単なことです。でも 5 つでなくて 6 つの観測値に興味があったらどうでしょう? シーズン 6 番目のゲームが得点差 14 点だったとすると、並べ替

えリストは今や次のようになります。

8, 14, **31, 32**, 56, 56

そして真ん中の数字はふたつあって、31 と 32 になります。中央値は、この二つの数字の平均値として定義されるので、31.5 になります。前と同じで、数字がもっとたくさんあると人の手でやるのはとても難しくなります。実際には、もちろん、誰も真ん中の値を探すためにデータを並べ替えるなんてことはしません。コンピュータを使って、この面倒な作業をやらせるのです。JASP はお願いしたら中央値を出してくれます; 単に '統計' をクリックして、ドロップダウンメニューから '中心化傾向' メニューの '中央値' を選んでください。結果は自動的に中央値を含むものにアップデートされ、JASP は `afl.margins` 変数の中央値が 30.500 であるとレポートしてくれます。

4.1.4 平均値か中央値か?その違いは?

平均値と中央値の計算方法を知ること、このお話の一部に過ぎません。あなたはそれぞれがデータの何についてものを言い、それらを使うときに何が仄めかされることになるのかを理解する必要があります。図 4.4 にそれを描いてみました。平均は、データセットの“重心”のようなもので、中央値はデータの“真ん中の値”です。これが意味することは、あなたがこれらのどちらかを使うときに、データの種類が何であって、それで何をやろうとしているのかに関わってきます。ざっくりいうと、

- データが名義尺度水準であれば、平均値も中央値も使うべきではありません。平均値も中央値も数字が割り当てられた値に意味がある、という考え方に依存しているからです。
- データが順序尺度水準であれば、平均値よりも中央値を使う方が良いでしょう。中央値はあなたのデータの順序情報 (すなわち、どの数字が大きい) にだけ関わり、正確な数字には依存しないからです。これこそあなたのデータが順序尺度水準である状況でしょう。それに対して平均は、正確な量的値が観測対象に割り当てられているときに使われるので、順序尺度データには適していないのです。
- 間隔尺度あるいは比率尺度水準のデータであれば、どちらでも一般的に受け入れられます。どちらを選ぶかは、あなたが何をしたいかによります。平均値はデータの全ての情報を使います (あなたが大量のデータを持っているときには便利です)。が、極端な、外れ値には敏感です。

最後のパートを少し拡張しましょう。一つの結論として、平均値と中央値の間の体系的な違いは、ヒストグラムが非対称であるとき (歪んでいるとき; セクション 4.3 を参照) に現れます。これは図 4.4 に描かれています。中央値は (右図)、ヒストグラムの“ボディ”' 近くにありますが、平均値 (左図) は“尻尾”(極端な値があるところ) に引っ張られています。わかりやすい例を示すために、ボブ (年収\$50,000)、ケイト (年収\$60,000)、ジェーン (年収\$65,000) が席についていると思ってください。テーブルの平均値は\$58,333 で、中央値は\$60,000 です。ここにビルが座ります。彼の年収は(\$100,000,000) です。年収の平均値は\$25,043,750 に跳ね上がりますが、中央値は\$62,500 にあが




Figure 4.4 平均値と中央値の違いをどう解釈するかについてのイラスト。平均値は基本的にデータセットの“重心”です。データのヒストグラムが固形物だと考えたら、そのバランスを取る点(シーソーみたいに)が平均値です。それに対して、中央値は真ん中の観測で、それより小さいデータが半分、それより大きいデータが半分あるということです。

るだけです。席についている人の全体的な年収に興味があるのなら、平均が正しい答えになるでしょう。しかし典型的な年収の人が知りたいのであれば、中央値がより良い選択肢になるのです。

4.1.5 現実的な例

平均値と中央値の違いについて、何故注意を払うべきなのかの感覚を得るために、現実生活での例で考えてみましょう。私は科学的・統計的知識の足りないジャーナリストを馬鹿にする傾向があるのですが、信頼すべきところは信頼すべきだと思っています。これは 2010 年 9 月 24 日の ABC ニュース^{*2} になった、ある素晴らしい論文です。

コモンウェルス銀行の上級幹部がこの数週間、世界各地を訪問し、オーストラリアの住宅価格と所得に対する主要な価格の比率が、類似国と比較してどのように優れているかを示すプレゼンテーションを行いました。“住宅価格はこの 5.6 年、実質的に横ばい状態である”と銀行トレーディング部門のチーフエコノミスト Carig James は言っています。

これはおそらく、住宅ローンを抱えている人や、住宅ローンを希望している人、家賃を払っている人、オーストラリアの住宅市場でここ数年続いていることに全く気がついていない人にとっては、大きな驚きではないでしょうか。元の論文に戻ってみましょう。

CBA(コモンウェルス銀行のこと)は、グラフ、数字、国際比較などで住宅の運命が決まると信じている人と戦ってきました。プレゼンテーションの中には、オーストラリアの家賃は収入に比べて割高であるという議論を、銀行が否定しているとされています。オーストラリアにおいて、世帯主の価格に対する住宅価格は大都市において 5.6、全国的には 4.3 であり、他の多くの先進国と同じぐらいであるとしています。また、サンフランシスコとニューヨークではこの比率は 7、

^{*2}www.abc.net.au/news/stories/2010/09/24/3021480.htm

オークランドでは 6.7, バンクーバーでは 9.3 にもなります。

もっとびっくりなニュースです! だけど、この論文は次のように見立てています。

アナリストの多くは、これは銀行によってミスリーディングな図、比較がなされたからだと言います。CBA の資料 4 ページ目をみて、グラフや表の下に書いてある情報ソースをみたら、国際比較の追加的なソースがあることに気づくでしょう – 人口動態学についての。コモンウェルス銀行が人口動態学の情報を使ってオーストラリアの住宅価格・収入比率の分析をしていたとすると、その実態は 5.6 とか 4.3 ではなく 9 近くになります。

うーむ、かなりの違いがありますね。一方では 9 といい、他方では 4-5 だ、と言っています。この違いを区分して、本当の値はこの間にあるんだとでもしたほうがよいのでしょうか? 全く違います! 正しい答えと、間違った答えがあるような状態なのです。人口動態学は正しく、コモンウェルス銀行は間違っています。論文では次のように指摘しています。:

コモンウェルス銀行の住宅価格対収入の図には明らかな問題があり、平均年収と住宅価格の中央値を比較しているのです (人口動態学の図は収入の中央値と価格の中央値の比較をしているのに)。中央値は真ん中にある点で、極端に高いあるいは低い値を効率よくカットしますが、平均値は年収や資産価値については高所得者が含まれるので高くなる傾向があります。別の言い方をすれば、コモンウェルス銀行の図は Ralph Norris の数百万ドルにも及ぶ給料を収入が話に入れ、かれの (間違いなく) 高価な住宅価格は図の中に入れないようにしているので、住宅価格はオーストラリアの中級ぐらいの年収と比較していることになります。

これ以上いうことはありません。人口動態学的に計算した比率の方が正しいのです。銀行がやったやり方は間違っています。なぜ数字に得意なはずの銀行がこのような基本的なミスをしたのかというと... 彼らが何を考えていたのかは分からないので、ここまでにしましょう。しかしこの論文が以下の事実についての注意を促しています。関係があるかどうか分かりませんが。

オーストラリア最大の住宅業界牽引者であるコモンウェルス銀行は、住宅価格の上昇については最大級の興味を持っています。住宅ローンや多くの中小企業向けローンの担保として、オーストラリアの住宅の大部分を事実上所有しています。

むにゃむにゃ。

4.1.6 最頻値

サンプルの最頻値は、とても単純です。それは最も頻度が多い値、なのです。AFL の別の変数を使ってこれを説明してみましょう。決勝で最も多くプレーしている選手は誰でしょう? `aflsmall_finalists` ファイルを開いて、`afl.finalists` 変数をみてみましょう。図 4.5 がそれです。この変数には全 400 チームの、1987 年から 2010 年までの間に開催された 200 回の決勝戦情報が載っています。

我々がやるべきことは、全 400 試合を読み通して、決勝戦リストに出てくるチームの名前を数え上げ、**度数分布表**を作ることです。しかしこれは頭を使わない退屈な作業で、まさにコンピュータが得意とするような作業ですね。だから JASP を使いましょう。‘記述’の下にある‘記述統計’の、`afl.finalists` 変数を選び‘変数’ボックスに移し、‘度数分布表’と書かれた小さなチェックボックス




Figure4.5 aflsmall_finalists.csv ファイルに修められた変数の JASP スクリーンショット

.....

スをクリックします。すると図 4.6 のようなものが得られるでしょう。




Figure4.6 afl.finalists 変数の度数分布表を示した JASP スクリーンショット

.....

さて度数分布表を入手したわけですが、これをみると 24 年間ずっと、Geelong が他のどのチームよ

りも多く決勝に進んでいることがわかります。ですから `afl.finalists` データの最頻値は"Geelong" だということになります。Geelong(39 回決勝進出) が 1987 年から 2010 年の間で他のどのチームよりも多く決勝に進んでいるのです。また、'記述統計' の表では平均値、中央値、最大値、最小値が計算されていないのも注目です。なぜなら `afl.finalists` 変数は名義的な文字変数であって、これらの値を計算する意味がないからです。

最後に最頻値に関するポイントをもう一つ。名義尺度のデータを持っていたら最頻値を計算するのが最もよくあるケースです。というのも、平均や最頻値はこの種の変数には向いていないからです。順序、間隔、比率尺度水準の変数の最頻値を知りたいという時もあります。例えば、`afl.margins` 変数にもどってみましょう。この変数は明らかに比率尺度水準 (もしピンとこないのなら、もう一度セクション 2.2 を読んでみてください) であり、あなたが知りたいのはこの中心に関する測度であれば平均値や中央値を求めるところです。しかしこんなことを考えてみてください：あなたの友達が賭けようぜと言ってきて、ランダムにフットボールのゲームを選ぶとします。誰がプレイするのかを知らずに、正確な得失点差を推測しないとイケないのです。正しく当てられたら 50 ドルもらえます。でなければ 1 ドル失います。ほとんど正解に近かった、という残念賞はないものとします。正確に点差を推測しなければならないのです。この賭けをする時、平均や中央値は全くあなたの役に立ちません。最頻値にかけるべきです。`afl.margins` 変数の最頻値を JASP で計算するには、データセットに戻って '記述'- '記述統計' 画面から、'統計量' と書いてあるセクションを拡大してください。'最頻値' のチェックボックスをクリックして、'記述統計量' テーブルにある最頻値をみます。図 4.7 にあるやつです。そうすると、2010 年のデータでは 3 点差に賭けるべきだということがわかります。

4.2

変動性の指標

ここまで話してきた統計の話は、*中心化傾向*に関するものでした。つまり、そこでの話はデータの“真ん中”とか“代表的な”値についてでした。しかし、中心化傾向は計算したい要約統計量の唯一の種類、というわけではありません。計算したい第二のものとして、データの**変動性**があります。つまり、どれくらいデータが“散らばっているか”？とか、どれくらい平均や中央値から観測値が“遠くにある”傾向があるか？というものです。ここでは、データが間隔あるいは比率尺度水準で得られていると考えますから、`afl.margins` データを例に使い続けましょう。このデータを使うことで、散らばりの指標としていくつかのものを示すことにし、その長所と短所も見ていくことにしましょう。




Figure4.7 afl.margins 変数の中央値を示す JASP 画面

4.2.1 範囲

変数の**範囲**はとてもシンプルなものですが。最大値から最小値を引いたもののことを指します。AFL 得点差データの最大値は 116 で最小値は 0 でした。“変動”を表す量として範囲は最も単純なものですが、最も悪いものでもあります。要約統計量を頑健なものにするために、平均について議論していたことを思い出してください。もしデータセットの中に一つ二つ変な値があると、我々の統計量はそうしたデータに角に影響されないようにしたいところです。

例えば、変数が極端な外れ値を持っていたとします。

-100, 2, 3, 4, 5, 6, 7, 8, 9, 10

範囲が頑健な値ではないことは明らかですよね。変数の範囲は 110 になりますが、外れ値を除くとたったの 8 になります。

4.2.2 四分位範囲

四分位範囲 (interquartile range, IQR) は範囲に似ていますが、最大値と最小値の差を使うのではなく、25 パーセンタイルと 75 パーセンタイルの差を使います。**パーセンタイル**をまだ知らないかもし

れませんが、データの 10 パーセンタイルというのはある点 x よりも小さいのがデータの 10% になるような点 x のこと、という意味です。実は、既にこの考え方は出てきているのです。データの中央値とは、50 パーセンタイルのことですから！ JASP では、簡単に 25,50,75 パーセンタイルを見つけることができます。‘記述’の‘記述統計’から‘統計量’の画面にある‘四分位’チェックボックスをクリックするだけです。

Descriptive Statistics

Descriptive Statistics	
afl.margins	
Valid	176
Missing	0
Mean	35.301
Mode	3.000
Std. Deviation	26.074
Minimum	0.000
Maximum	116.000
25th percentile	12.250
50th percentile	30.500
75th percentile	51.500

Figure4.8 afl.margins 変数の四分位を示す JASP のスクリーンショット

驚くには値しませんが、図 4.8 において 50 パーセンタイルは中央値と同じになっています。そして、 $50.50 - 12.75 = 37.75$ ですから、2010 年の AFL 得点差データの四分位範囲は 37.75 ということになります。範囲の解釈は明らかですが、IQR の解釈の仕方はそこまで明らかなというわけではないですね。これは次のように考えるのが最も単純な方法でしょう。すなわち、四分位範囲はデータの“中半分の”範囲だということです。つまり、データの一つの四分位が 25 パーセンタイル点で、もう一つの点が 75 パーセンタイル点ですから、この二つの間にデータの“中半分”が位置していることになります。IQR はこの中半분을カバーする範囲なのです。

4.2.3 平均絶対偏差

二つの尺度、範囲と四分位範囲を’みてきましたが、どちらもデータのパーセンタイルをみて、データの散らばりを測ろうとするアイデアに基づいているものでした。しかし、これだけがこの問題唯一の解決策ではありません。別のアプローチとして、意味のある参照点 (ふつう平均値や中央値ですが) を選び、その参照点からの“典型的な”偏差を報告する、というのがあります。“典型的な”

偏差，というのは何を意味しているでしょう？ 普通これは偏差の平均値や中央値を指します。実際，ここからは二つの尺度が導かれます。“平均絶対偏差”(平均値からの) と，“中央値絶対偏差”(中央値からの)，です。私がこれまでみてきたところ，中央値に基づく尺度が統計的に使われているようで，そちらの方が優れているようです。しかし正直に言って，心理学でこれらが使われてきたのをあまり見たことがありません。平均に基づく尺度の方が，心理学ではよく出てきます。このセッションでは前者について最初説明しますが，その後で2 番目についても触れていきます。

前のパラグラフではちょっと抽象的だったかもしれませんが，平均からの**平均絶対偏差**についてもう少しゆっくりみていきましょう。この尺度が便利なことの一つに，この名前が実際にどうやって計算するのかを表している，というのがあります。AFL の得点差データについて，もう一度最初の5 ゲームをみると，得点差は 56, 31, 56, 8, 32 でしたね。ここでの計算はある参照点 (今回は平均) からの偏差を見るものですから，最初にするべきことは平均つまり $\bar{X}$ を計算することです。最初の5 ケースでは，平均は $\bar{X} = 36.6$ になりました。次のステップは各観測値， X_i を偏差のスコアに変換することです。これは観測値 X_i と平均 $\bar{X}$ の差を計算することでできます。つまり，偏差スコアの定義は $X_i - \bar{X}$ となるのです。今回のサンプルにおける最初の観測値は， $56 - 36.6 = 19.4$ になります。オーケー，十分シンプルですね。このプロセス，次のステップはこれらの偏差を絶対偏差にすることです。これは負の値を正の値にすることでできます。数学的には -3 の絶対値を $|-3|$ と書き， $|-3| = 3$ とします。この絶対値を使うのは，平均よりも高かったのか低かったのかを気にしないということであり，興味は平均にどれくらい近かったのかというだけだということです。このプロセスをできるだけ明白にするために，下の表では，5 つの観測値すべてについてのこれらの計算を示しています。

用語: 表記:	どのゲームで i	値 X_i	平均偏差 $X_i - \bar{X}$	絶対偏差 $ X_i - \bar{X} $
	1	56	19.4	19.4
	2	31	-5.6	5.6
	3	56	19.4	19.4
	4	8	-28.6	28.6
	5	32	-4.6	4.6

さてデータセットの各観測値について絶対偏差を計算できたので，これらのスコアの平均を計算しましょう。次のようになります。

$$\frac{19.4 + 5.6 + 19.4 + 28.6 + 4.6}{5} = 15.52$$

はいおしまい。これら5 つのスコアについて，平均絶対偏差は 15.52 でした。

ところで、この簡単な例はこれでおしまいますが、少し話が残っています。まず、数学的な定式化をしておくべきです。しかしこれをしようとすると、平均絶対偏差についての数学的表記が必要です。腹立たしいことに、“平均絶対偏差”と“中央値絶対偏差”はどちらも同じ頭文字 (MAD) なので、曖昧になってしまいますから、平均絶対偏差に何か別の表現を考えないといけません。やれやれ。average absolute deviation を短くして、AAD とすることにしましょう。これでもいづらか曖昧な表記ですが、計算は次のように書くことができます。

$$\text{AAD}(X) = \frac{1}{N} \sum_{i=1}^N |X_i - \bar{X}|$$

4.2.4 分散

平均絶対偏差は使いでがありますが、変動の尺度として最適というわけではありません。純粋に数学的な観点からは、絶対偏差よりも二乗した偏差の方が好ましい理由があります。これを使うと分散とよばれる尺度を手に入れることになります。それは本当にステキな統計的特徴を持っているのですが、それは横に置いておくとして^{*3}、今から取り上げるとも大きな心理学的欠陥も持っていることを説明します。データセット X の分散は $\text{Var}(X)$ と表記されますが、もっと一般的には s^2 と書きます (その理由はすぐにわかります)。

観測されたデータセットの分散を計算する式は次の通りです。

$$\text{Var}(X) = \frac{1}{N} \sum_{i=1}^N (X_i - \bar{X})^2$$

ご覧の通り、基本的には平均絶対偏差で使ったものと同じ形をしています。違うのは“絶対偏差”のかわりに“偏差平方”を使っているところです。このため、分散は“平均偏差平方”とも言われます。

さて、基本的な概念を手に入れましたので、具体例でみてみましょう。もう一度、AFL ゲームの最初の 5 つのデータを使います。前回同じアプローチをした時に習って、次のような表にしてみました。

^{*3}えーっと、ちょっとだけ何が最高にクールなのか、“クール”の定義をしてから説明してみましょう。分散は加算的なのです。その意味はこんな感じです。私が二つの変数 X と Y を持っていて、それらの分散がそれぞれ $\text{Var}(X)$ と $\text{Var}(Y)$ だとしましょう。ここで新しい変数 Z を、二つの和、 $Z = X + Y$ で定義したとします。そうすると、 Z の分散は $\text{Var}(X) + \text{Var}(Y)$ になるのです。これがとても便利な特徴なのですが、このセクションで私が説明しようとする他の尺度にはないものなのです。

用語: 表記:	どのゲームで i	値 X_i	平均偏差 $X_i - \bar{X}$	偏差平方 $(X_i - \bar{X})^2$
	1	56	19.4	376.36
	2	31	-5.6	31.36
	3	56	19.4	376.36
	4	8	-28.6	817.96
	5	32	-4.6	21.16

最後の列には全ての偏差平方が入っていますので、これの平均を取れば良いのです。手計算する、つまり電卓を使うと、この分散の値が 324.64 であることがわかります。興奮してきたでしょう?このとき、多分あなたの考えに火がついた問題 (すなわち、324.64 の分散って本当に平均なのか?) は横に置いて、JASP でこれをどう計算するかをみてみましょう。というのも、これで奇妙なことが明らかになるからです。

まず最初の 5 行だけを含んだ新しいデータを読み込みます。ファイル `aflsmall_margins_first5.csv` を読み込んでください。次に '統計' メニューの '記述'-'記述統計' をクリックし、'分散' チェックボックスをクリックします ('ばらつき' グループの中にあるのがわかると思います)。手計算した値 (324.64) と同じ数字になりましたか? いや、ちょっと待って、あなたは全く違う答えを手にしたではありませんか (405.800)!おかしいなあ。JASP は壊れてるの? タイポですか? 何が起きている?

起こった通りのことで、答えは no です。タイポではなく、JASP が間違っているわけでもありません。現に、JASP がここで何をしているのかを説明するのはとても簡単なのですが、JASP がなぜそれをしたのか、というのはちょっと説明に苦労します。ですから "何が起こったのか" から始めましょう。JASP は上で示したのとは少し違う数式を評価したのです。偏差平方の平均を計算したのではありません。平均はデータ点の数 N で割りますが、JASP は $N - 1$ で割ったのです。

言い換えると、JASP は次の式を使って計算したのです。

$$\frac{1}{N-1} \sum_{i=1}^N (X_i - \bar{X})^2$$

これが何をやったかです。本当に知りたいのは、なぜ JASP が N ではなく $N - 1$ で割ったのか、ですよね。結局のところ、分散は偏差平方の平均なのですよね? だったら N で割るべきじゃないか、サンプルの実際の観測数でね。全くその通りです。しかし、第 7 章で論じるように、"サンプルを記述する" ことと "サンプルのもとになった母集団を推測すること" とのあいだにはちょっとした違いがあるのです。ここまでは、この差の区別をしませんでした。あなたが表現したいのがサンプルなのか、母集団の推測するものなのかどうかにかかわらず、平均は同じように計算できたのです。しかし分散や標準偏差、そのほかの尺度ではそうならないのです。私が最初に説明したこと (つまり、

N で割ることによる実際の平均)は、標本の分散を計算することを想定したものでした。しかしほとんどの場合、標本そのものに興味をもってるわけではないでしょう。むしろ、その標本は世界について何かを伝えるために存在しているはずです。そうであれば、あなたが実際に計算したいのは“標本統計量”ではなくて、“母集団の母数”を推定するためのものになるはずです。しかしこの話は、少し先走りすぎています。今は、JASP がすることをただ信じて、第 7 章で推定について論じるときまでこの問題をおいておくことにしましょう。

最後にもう一つ。このセクションはちょっとした推理小説のようになっていました。先ほど分散の式を示し、JASP では“ $N - 1$ ”でやっていること、そしてなぜそうするのかのヒントを書きましたが、最も大事なことは触れていなかったのです。みなさんは分散をどういうものだと理解していますか?記述統計は記述することだけを目的としています。今のところ分散は意味不明な数字でしかありません。残念なことに、分散の解釈について人間味のない説明しかできない理由は、それがそもそも人間味のないものだからです。これが分散について最も深刻な問題点です。分散は本当は変動を表現する基本的な量であるというある種の美しい数学的特性はあるのですが、現実的に他者との会話に使いたいと思うときには全く役に立たないのです。分散は元の変数に関しては全く意味のない数字になります! 全ての数字は二乗されてしまうので、それは何も意味しないことになるのです。これは大問題だ。例えば、以前示した表について言うと、ゲーム 1 における点差は“376.36 ポイントの二乗分、平均より高い”と言うことになります。これはまったく馬鹿馬鹿しい表現ではないですか。計算した分散の 324.64 の時も同じことがいえます。多くのフットボールゲームを見てきましたが、誰も“ポイントの二乗分”なんて言ってるのを聞いたことがありません。これは測定の実際の単位ではなく、分散は意味のない単位を持っているので、人間にとって全く意味のないことになるのです。

4.2.5 標準偏差

オーケー、分散を使う理由は分かってもらえたとしましょう。説明はしてませんが、分散は数学的に良い特性持っていますからね。でもあなたが人間で、ロボットでないなら、データと同じ単位を持っている(つまり二乗した値ではないもの)尺度を使う方がいいと思うでしょう。じゃあどうしましょう?答えは簡単です!分散の平方根を取れば良くて、これは**標準偏差**として知られています。“偏差平方平均の根”、つまり RMSD とも呼ばれます。これで問題がスッキリ解決しました。だれも“分散は 324.68 ポイントの二乗”ということの意味を理解することはできませんが、“標準偏差 18.01 ポイント”は簡単に理解できます。元の単位で表現されているからです。

標準偏差は分散の正の平方根に等しいので、次の式を見ても驚かないと思います。

$$s = \sqrt{\frac{1}{N} \sum_{i=1}^N (X_i - \bar{X})^2}$$

JASP では、‘分散’のチェックボックスと同じセクションに‘標準偏差’のチェックボックスもあります。図 4.8 をみると、JASP は `afl.margins` の標準偏差を 26.074 と答えてくれています。標準偏差はとてもよく使われるので、チェックするのがデフォルトになっていますが、あなた自身で選んでみてください!!

しかし、分散についての議論でお気づきかもしれませんが、JASP は実際にはこれとちょっと違ったやり方で計算します。分散を見るだけなら、JASP は N ではなく $N - 1$ で割る方で計算するのです。

第 7 章で再びこのトピックに触れると意味がわかると思いますが、この新しい量を $\hat{\sigma}$ (“シグマ・ハット”と読みます) とし、次のように定式化します。

$$\hat{\sigma} = \sqrt{\frac{1}{N-1} \sum_{i=1}^N (X_i - \bar{X})^2}$$

標準偏差を解釈するのも少し複雑です。標準偏差は分散から導出されています。そして分散は人にとってあまり意味のない量になっていますから、標準偏差は単純な解釈では済みません。結果的に、私たちのほとんどはちょっとした経験則を用いています。一般的に、平均から標準偏差 1 つぶん離れたところにデータの 68% が含まれ、データの 95% は平均から標準偏差 2 つ分離れたところに 99.7% が、平均から標準偏差 3 つ分離れたところに含まれる、ということが期待できます。このルールはほとんどの場合うまく当てはまりますが、多少の例外はあります。これがちゃんと計算できるのはヒストグラムが対称的で“ベル型”になっているという仮定に基づいています^{*4}。図 4.2 にある AFL の得点差ヒストグラムを見ると、この経験則は私たちのデータに合っているとは思えません! しかし大まかに合っているのです。AFL データの 65.3% が実際に平均から 1 標準偏差の範囲にあります。このことは、図 4.9 に視覚的に示されています。

4.2.6 どの尺度を使いましょうか?

いくつかの範囲についての尺度を紹介してきました。範囲、IQR、平均絶対偏差、分散、標準偏差

^{*4}厳密にいうと、この仮定はデータが正規分布にしがっているということで、この重要な概念については第 6 章で議論することになります。またこのことは本書で何度も何度も出てきます。




Figure4.9 AFL 得点差データについての標準偏差を描いたもの。色がついているヒストグラムの箇所は平均から 1 標準偏差のなかに入ったデータの数を表しています。今回は 65.3% のデータセットがこの範囲内に入り、次のメインボックスである“約 68%”のルールに近い結果になっています。

です。そしてその長所と短所についてもみてきました。簡単にまとめておきましょう。

- **範囲** データのちらばり全体を見ます。外れ値に弱く、データの極端な部分を見たいという理由がない場合はあまり使われることはありません。
- **四分位範囲** データの“真ん中あたり”がある場所を教えてください。多少、外れ値に強くて中央値を含んでいます。これはよく使われます。
- **平均絶対偏差** 平均から観測度数が“平均的に”どれくらい離れているかを教えてください。解釈しやすいのですが、いくつかの小さな問題点があって（ここでは触れていませんが）、そのせいで統計家は標準偏差ほど魅力を感じていません。時々使われますが、それほど頻度は多くありません。
- **分散** 平均偏差の二乗の平均です。数学的にはエレガントで、平均周りの散らばりを描写するにはたぶん“正しい”方法なのですが、データと同じ単位を使っていないので意味不明な数字になります。数学的なツール以外の用途はほとんどありませんが、非常に多くの統計技法の中に“埋もれて”います。
- **標準偏差分散の平方根**です。これは数学的にも非常にエレガントで、データと同じ単位で表現されていますから、解釈も簡単です。平均が中心化傾向の尺度として使われる時は、これが基本です。散らばりの尺度の中で最もポピュラーなものになります。

まとめると、IQR と標準偏差が簡単で、データのばらつきを報告するのに最もよく使われる二大尺度，ということになります。しかし他のものが使われることもあります。この本に載せたのは，わずかなではありますがみなさんがどこかで出会うかもしれないからです。

4.3

歪度と尖度

みなさんが心理学の文献で見かけるかもしれない記述統計量が，あと二つあります。歪度と尖度です。実践上はどちらもこれまで話してきた中心化傾向や変動性の尺度ほど，使われるものでもありません。歪度はちょっと大事なので見かけることはあるかもしれませんが，私は科学的レポートの中で尖度を目にしたことはありません。




Figure4.10 歪度のイメージ。左側は歪度が負 (歪度 = $-.93$)，真ん中は歪みなし (実際ほとんどありません。歪度 = $-.006$)，そして右が正の歪度 (歪度 = $-.006$) をもつデータです。

歪度の方が面白いので，こちらから話を始めましょう。歪度は基本的に非対称性の尺度で，図を書いてみれば理解は簡単です。図 4.10 にあるように，データに極端に小さな値 (下の裾が上の裾よりも“長い”) を持っていて，極端に大きな値はそれほど持っていない (左図) 場合，このデータは負の歪度をもつといいます。一方，極端に大きな値が小さい値より大きくも多くあるようであれば (右図)，このデータは正の歪度をもつといいます。これが歪度の背後にある考え方です。平均よりも大きな値が相対的に多くあれば，分布は正，すなわち右に歪んでおり，裾も右に寄っています。負，すなわち左への歪みはその逆です。対称的な分布をしていれば，歪み度は 0 です。正に歪んだ分布の歪度は正の値であり，負の値は負の歪み分布だと言えます。

データセットの歪みについての定式化は次のとおりです。

$$\text{skewness}(X) = \frac{1}{N\hat{\sigma}^3} \sum_{i=1}^N (X_i - \bar{X})^3$$

ここで N は観測度数の数であり、 $\bar{X}$ は標本平均、 $\hat{\sigma}$ は標準偏差 (ただし “ $N - 1$ で割ったバージョン”) です。

ありがたいことに、JASP で歪度の計算をすることができます。‘記述’ - ‘記述統計量’ の下にある ‘統計量’ チェックボックスのオプションがそれです。変数 `afl.margins` について、その歪度を計算すると **0.780** です。この歪度の推定値を歪度の標準誤差で割れば、このデータがどれほど歪んでいるかの指標を得ることができます。経験的に行って、小さいサンプルでは ($N < 50$)、この値が 2 以下であればそれほど歪みは大きくなく、2 以上であればデータが統計的な分析をするに許される限界を超えて歪んでいる、と考えるのが目安です。これは経験則に過ぎず、この解釈にはっきりした共通見解があるわけではないことに注意してください。ということで、この分析をすると AFL の得点差データはちょっと歪んでいることになります ($0.780 / 0.183 = 4.262$ で、これは明らかに 2 より大きいです)。

時々つかわれる最後の尺度は、実際に使われることは非常に稀なのですが、データセットの**尖度**です。簡単にいえば、尖度は “尖っているかどうか” の尺度で、図 4.11 にその状況を示しています。慣例によって、“正規分布”(黒い線) は尖度ゼロであり、データセットの尖り具合はこのカーブに比べて相対的に評価されます。

この図にあるように、左のデータはそれほど尖っておらず、尖度は負でこのデータは緩く尖った *platykurtic* データだと言われます右図はとても尖っており、尖度は正でこのデータは尖度の大きい *leptokurtic* データだと言われます。一方、真ん中のデータはちょうどいいぐらいの尖度で、これは中程度の尖度 *mesokurtic* と呼ばれ、尖度はゼロです。下の表にこれをまとめました。

一般的な言い方	専門的な言い方	尖度の値
“かなりフラット”	platykurtic	負
“ちょうどいいぐらい”	mesokurtic	ゼロ
“とても尖っている”	leptokurtic	正




Figure4.11 尖度の図。左側は“緩く尖った”データセット (尖度 = -0.95) であり、これが意味するのはこのデータセットは“かなりフラット” だということです。真ん中の図は“中程度の尖り”をもったデータセット (尖度はほとんど 0) であり、これが意味するのはこのデータの尖度がちょうどいい感じであるということです。最後に、右側の図ですが、“尖度の大きい”データセット (尖度 = 2.12) であり、このデータセットは“とても尖っています”。尖度は正規分布 (黒い線) と比べて評価されていることに注意してください。

尖度の式は既に見た分散や歪度の式とかなり似ています。分散が偏差の二乗、歪度が偏差の三乗であったのに対し、尖度は四乗になっています。^a

$$\text{kurtosis}(X) = \frac{1}{N\hat{\sigma}^4} \sum_{i=1}^N (X_i - \bar{X})^4 - 3.$$


^aこの“-3”については正規分布の尖度がゼロになるように統計家が付け加えたものです。“-3”を式の最後に引っ付けておくのはちょっと馬鹿みたいですが、こうすることの数学的な理由があるのです。

大事なのは、JASP で尖度を計算するには歪度の下をチェックボックスをクリックするだけだということ、そうすると尖度の値 0.101 がその標準誤差 0.364 と共に表示されます。歪度をその標準誤差で割ったのと同じように計算すると、この値は 2 より小さい ($0.101/0.364 = 0.277$) ことがわかります。これは AFL の得点差データの尖度がちょうどいいぐらいだったことを意味しています。

4.4

グループごとの記述統計

よくあることのひとつとして、記述統計量のあるグループ変数ごとに分割してみたいと思うことがあります。JASP ではすごく簡単にできます。例えば、ある `clin.trial` データについて、`therapy` のタイプごとに記述統計量を見たいなと思ったとしましょう。これは今まで見せていない、新しいデータセットです。このデータセットは `clinicaltrial.csv` ファイルにあって、第 12 章でよく使うようになります (このデータの詳細についてはその時に説明します)。読み込んで、見てみましょう。



	ID	drug	therapy	mood.gain
1	1	placebo	no.therapy	0.5
2	2	placebo	no.therapy	0.3
3	3	placebo	no.therapy	0.1
4	4	anxifree	no.therapy	0.6
5	5	anxifree	no.therapy	0.4
6	6	anxifree	no.therapy	0.2
7	7	joyzepam	no.therapy	1.4
8	8	joyzepam	no.therapy	1.7
9	9	joyzepam	no.therapy	1.3
10	10	placebo	CBT	0.6
11	11	placebo	CBT	0.9
12	12	placebo	CBT	0.3
13	13	anxifree	CBT	1.1
14	14	anxifree	CBT	0.8
15	15	anxifree	CBT	1.2
16	16	joyzepam	CBT	1.8
17	17	joyzepam	CBT	1.3
18	18	joyzepam	CBT	1.4

Figure4.12 `clinicaltrial.csv` ファイルにある変数を写した JASP スクリーンショット

三つのドラッグがあるのがわかりますね。プラセボと、“anxifree”と“joyzepam”と呼ばれるものです。そしてそれぞれに 6 人割り当てられてます。そして 9 人が認知行動療法 (CBT) を受けていて、

9 人が心理療法は何も受けていない状態です。そして `mood.gain` 変数の '記述' をみると、ほとんどの人が気分の向上 (平均 = 0.88) を示していますが、この尺度が何なのか分からないままでは、それ以上のことは言えません。でも、それはそれでわるくないのです。全体的には何か勉強になった気になります。

さて、さらに他の記述統計量を見て行きましょう。こんどはセラピーのタイプごとに分けて。JASP で '統計量' オプションから標準偏差、歪度、尖度にチェックを入れます。同時に、`therapy` 変数を '分割' ボックスに入れます。すると図 4.13 のような結果が得られます。




Figure4.13 セラピータイプごとに分割した記述統計量を示した JASP のスクリーンショット

4.5

標準得点

私の友人が “不機嫌さ” を測定するための新しい質問紙を作ろうとしているとしましょう。この調査票は 50 の質問からなり、不機嫌かどうかについて答えるものとしします。大きなサンプルをとって

(仮に百万人ぐらいとったとしましょう!), このデータが正規分布しており, 50 問中 17 点が平均不機嫌スコアで, 標準偏差が 5 だとしましょう。これに比べて, 私の得点は 50 問中 35 点だったとします。私はどれぐらい不機嫌なんでしょうね?これについて考える一つの方法は, 私は 35/50 が不機嫌なのだから, 70% ぐらい不機嫌だと考えることです。しかしちょっと考えてみれば, おかしい気がしますよね。もし私の友人が, その質問紙を少し違った捉え方で答えていたとしたら, その問いが本当に問うていることに比べて, 全体的な分布が簡単に上がったり下がったりしてしまいます。ですから, 私が 70% 不機嫌だというのは, 調査票の質問セットに応じて変わることになります。とても良い質問項目であったとしても, これではあまり意味のある表現にはなりません。

これについての良いやり方の一つは, 私の不機嫌の程度を周りの人と比べることです。驚くべきことに, 私の友人は 1,000,000 人のサンプルを持っていて, その中でたった 159 人だけが私と同じ程度の不機嫌さ (本当ははそんなことはありませんよ) であれば, 私はトップ 0.016% の不機嫌度ということになります。このほうが, ロウデータを解釈しようとする時にはより意味があるのではないのでしょうか。この考え方は, 私の不機嫌さの程度を人の全体的な不機嫌分布にあわせて記述しようとするものであり, 標準化がしようとしているのはまさにこれなのです。これを正しくやる方法の一つは, さっきやって見せたように, パーセンタイルで表現することです。しかし問題があるのは, この方法だと “トップが寂しい” ということです。私の友人が集めたサンプルが 1000 人に過ぎなかったとしましょう (これでもまだ新しい質問紙を検証するためには大きいサンプルですが)。そして今回, 平均が 50 問中 16 点で標準偏差が 5 だったとします。問題は, このサンプルでは私と同じぐらいの不機嫌度を持っている人が一人もいないということです。

しかし, 全てが失われたわけではありません。もう一つのアプローチとして, 私の不機嫌さスコアを標準スコアに変換するのです。これは z -スコアとも言われています。標準スコアは私の不機嫌さスコアが平均から標準偏差いくつ分上にあるかを表すのです。これを “数学っぽく” いうと, 標準偏差は次のように計算できます。:

$$\text{標準スコア} = \frac{\text{ロースコア} - \text{平均}}{\text{標準偏差}}$$

実際数学的には, z スコアについての式は次のようになります。

$$z_i = \frac{X_i - \bar{X}}{\hat{\sigma}}$$

不機嫌さデータに戻っていうと, ダニーの生の不機嫌さデータを標準化された不機嫌さスコアに変換することができます。

$$z = \frac{35 - 17}{5} = 3.6$$

この値を解釈するときに, セクション 4.2.5 で触れた, 平均から 3 標準偏差範囲にだいたい 99.7%

が入るという、概算を思い出してください。ですから、私の不機嫌さスコアを z スコアにして 3.6 になったということは、実際私はかなり不機嫌状態にあるということです。実際この推論からいくと、私は全体の 99.98% の人よりも不愉快なのです。そうですね。

ロースコアをより大きな母集団に広げて解釈することを許すとするなら (そしてそれによって任意の尺度の変数を意味のあるものにするなら)、標準スコアは第二の便利な機能を持っていると言えます。標準スコアはロースコアができないような状況でも互いに比較することができます。たとえば、私の友人が 24 項目からなる外向性を測る別の質問紙を持っていたとしましょう。この尺度が全体的に、平均が 13 で標準偏差 4 であり、私のスコアが 2 だったとしましょう。想像の通り、私の外向性のロースコア 2 を、不機嫌さ質問紙のロースコア 35 と比較するのは意味がありません。この二つの変数のロースコアは基本的に違うもので、いわばりんごとオレンジを比較するようなものです。

標準スコアではどうでしょう？ これはちょっと事情が違います。標準スコアを計算すると、不機嫌さは $z = (35 - 17)/5 = 3.6$ 、外向性は $z = (2 - 13)/4 = -2.75$ となります。この二つの数字は相互に比較することができます^{*5}私はほとんどの人の中では外向性が低く ($z = -2.75$)、不機嫌さが高い ($z = 3.6$) のです。しかし私のハズレ具合は外向性よりも不機嫌さの方が大きいといえます。3.6 が 2.75 よりも大きな数字だからです。それぞれの標準化スコアはその観測値がその母集団においてどのあたりに落ちるのかを示すので、全く異なる変数についても標準スコア同士を比較することができるのです。

4.6

要約

基礎統計量を計算することは、あなたが実際にデータを取ったとき真っ先にすべきことの一つであり、記述統計量は推測統計よりも単純で理解しやすいので、他の統計の教科書と同じように私も記述統計から説明しました。この章では、以下のトピックスについて議論しました。

- **中心化傾向の指標** 一般的に、中心化傾向はデータがどのあたりにあるのかを教えてください。典型的に報告される指標は次の三つでしょう；平均値、中央値、最頻値です (セクション 4.1)。
- **変動の指標** それに対して、変動の指標はデータがどのように“散らばっているか”を教えてください。鍵になる指標としては、次のものがあるでしょう；範囲、標準偏差、四分位範囲です (セクション 4.2)。

^{*5}いくつかの注意は必要です。変数 A についての 1 標準偏差が、変数 B の 1 標準偏差と“ある意味”対応しているとは言えないからです。二つの変数に関する z スコアが意味のある比較ができるかどうかを決めるには、常識をはたらかせねばなりません。

- 歪みと尖りの指標 変数の分布が非対称さの指標 (歪度) と、尖り具合 (尖度) もみてきました (セクション 4.3)。
- JASP で群ごとに変数の要約をする この本では JASP でデータ分析をすることに焦点化していますから、異なるサブグループそれぞれについて記述統計量を計算するにはどうするかについても触れました (セクション 4.4)。
- 標準化スコア z-スコアはちょっと変わった野獣です。これは記述統計量とはちょっと違いますし、推測統計の話でもありません。これについてはセクション 4.5 で触れました。この章も理解してもらえたと思います。また後で触れることになります。

次の章では、どうやって絵を描くのかについての話題に移りたいと思います! 誰だって可愛い絵が好きですもんね? しかしその前に、重要な点を抑えておきたいと思います。統計の伝統的な入門コースは、記述統計について小さな配分しかせず、1,2 回授業で触れる程度です。授業時間のほとんどの時間は、推測統計学に使われます。というのも、そこが本当に大変なところだからです。それはそれで意味があるのですが、良い記述統計量を選択するという、日々の重要な実践を覆い隠してしまいます。このことを覚えておいて欲しいのです...

4.6.1 エピローグ: 良い記述統計量とは記述的である!

一人の死は悲劇である。

数百万の死は統計である。

– Josef Stalin, Potsdam 1945

950,000 – 1,200,000

– ソ連における弾圧の死者数,
1937-1938 (Ellman 2002)

スターリンの悪名高き、数百万人の死に関する統計の特性についての引用は、少し考えてみる必要があります。彼の主張意図は明らかに、個々人の死は我々の心に触れ、無視することはできないけれども、非常に多くの死については理解できないし、結果的に単なる統計であって、無視してしまうことも簡単である、というところにあります。スターリンは、半分は正しいと思います。統計というのは抽象化であり、個々人の経験を超えた出来事の記述であり、可視化されにくいものです。百万人の死が“本当に”どういうことなのかを想像できる人はほとんどいませんが、一人の死は簡単に想像できることができますし、孤独な死は悲劇の感情を呼び起こし、Ellman の冷たい統計的記述の感覚が失われたように感じます。

これはそんなに簡単な話ではないのです。数字がなければ、数えなければ、何が起こったのかの記述がなければ、われわれは本当に何が起こったのかを理解する機会すらもせず、この失われた感覚を

呼び起こす機会さえ持つことができません。そして実際には、私はこれを気持ちの良い土曜日の朝に腰掛けながら書いており、世界の半分そしてこれまでの人生でずっと、ソ連の強制収容所から離れたところにいるのですが、Ellman の推定値とスターリンの引用を書く時には鈍い恐怖がズッシリ胃にきて、寒気を覚えます。スターリン主義の弾圧は私の経験を超えたところにありますが、統計データと結びつき、そこに記録された個人史を思うと、私の理解を完全に超えているとはいえません。なぜなら、Ellman の数字は私たちに教えてくれるからです。2年以上のスターリンの弾圧によって、私の住んでいる街に今生きている全ての男性、女性、子供たちと同じ数の人が消え去ってしまったのだ、ということ。この死の一つ一つに、独自の物語があって、それぞれの悲劇があって、その幾らかは私たちにも知られています。ですから、注意深く選ばれた統計量を見ながら、残虐行為のスケールに焦点化していきましょう。

統計家と科学者の最初の仕事である、データを集めて要約し、何が起こったのかを聴衆に知らせる数字を見つけてくるというのは、簡単なことではないのです。これは記述統計の仕事ですが、数字だけを使って何が言えるかはその仕事ではありません。あなたはデータアナリストであり、統計ソフトウェアではないのです。あなたがすべきはこれらの統計量を取り出して、記述に持っていくことなのです。あなたがデータを分析するとき、数字のコレクションをリストアップするだけでは十分ではありません。忘れてはいけないのは、あなたは人間の、聴衆を相手にコミュニケーションしようとしているということです。数字は重要ですが、あなたの聴衆が理解できるような意味のあるストーリーと一緒になければなりません。あなたはフレーミングについて考える必要がある、ということです。文脈について考えなければなりません。あなたの統計量が要約した、一つ一つの出来事について考えなければなりません。

5. グラフを描く

何よりもまず、データを見せろ

—Edward Tufte^{*1}

データを可視化することは、データを分析しようとするものにとって最も重要な課題です。これが重要なのは、二つの異なる、しかし相互に関係し合う理由によります。まず、“提示するグラフ”を描くこととは、あなたのデータをスッキリと提示し、読者にとってあなたが言いたいことを簡単に理解させるために視覚的に訴えかけるようにすることです。同じぐらい、あるいはもっと重要なことは、グラフを描くことであなた自身がデータを理解できるようになることです。そのために、“探索的なグラフ”を描くことは、あなたがいざ分析しようとしているデータについて理解するのを助けることになるのが重要なのです。このことは当たり前のようでもあります、私はこれを人に何回言ったかわからないほどです。

この章の重要さを示すために、優れたグラフというものがいかに有用なのかを示す典型例から始めたいと思います。そのために、図 5.1 に最も有名なデータの可視化の例の一つを示しています。これは 1854 年、John Snow によるコロナの死亡者数の地図です。この図はその単純さにおいて、非常にエレガントだといえます。背景として、われわれは見る人の方向性を示すストリートマップを持っている、というのがあります。地図上には多数の小さな点があり、それぞれがコロナの発祥地点を表しています。大きな文字は水のポンプの位置を示していて、その名前ラベルがついています。この図をちょっと見ただけでも、アウトブレイクの源は Broad Street ポンプを中心に行っていることが明らかです。このグラフを見て、Dr.Snow はポンプからハンドルを取り除き、500 人以上を殺したアウトブレイクを終わらせたのです。これが、良いデータの可視化の力です。

この章の目標は二つあります。まず、データを分析したり表示したりするとき、私たちがよく使うグラフについて説明し、続いてこれらのグラフを JASP で作成するにはどうすれば良いかを示します。このグラフそのものは、直接的なもののなので、この章のある側面は非常にシンプルだと言えるでしょう。人がよく困惑するのは、グラフをどうやって作るかを学ぶとき、特に良いグラフをどうやっ

^{*1}この言葉の原典は、Tufte の本『量的情報を可視化する』です。

て作れば良いかを学ぶときです。幸い、JASP でのグラフの書き方は、あなたがグラフの見え方にそれほどこだわらなければ、かなりシンプルなものです。私がこれをいうことの意味は、JASP のデフォルトのグラフがかなり良いものだということで、ほとんどの場合すっきりとクオリティの高いグラフィックを提供できるということです。しかし、標準的でない図を描きたいとあなたが思ったとき、あるいは図にかなり特殊な変更を加える必要があるとき、JASP のグラフィック関数は発展的な仕事や詳細な編集にはまだ向いていないということがあります。

Snow's cholera map of London




Figure5.1 John Snow のスタイリッシュなコロナマップのオリジナル。小さな各点はコロナ発生点で、大きな円は井戸の位置を示しています。このプロットが明らかにしたように、コロナのアウトブレイクは Broad St のポンプを中心に行っていることがわかります。

5.1

ヒストグラム

普通の**ヒストグラム**の話から始めましょう。ヒストグラムは最もシンプルで最も一般的な、データ可視化手法の一つです。あなたが間隔尺度水準、あるいは比率尺度水準のデータ (例えば、第 4 章の `afl.margins` データなど) を持っていて、その辺図字野全体的な印象を掴みたいと思った時に、ヒストグラムは有効です。ヒストグラムがどんなものかは、ほとんどの人が知っていると思います。広く使われていますからね。でも完璧を期すために、しっかり説明しておきます。あなたがすべきことは、あり得る値を**ビン**幅に分割し、各区間に入る観測度数の数を数え上げることだけです。この数のことを頻度とかビンの密度といい、それが垂直に伸びるバーとして表示されます。AFL の勝利数データでは、得点が 10 点未満だったゲームが 33 ゲームあり、これが以前示した第 4 の 図 4.2 中、左端のバーの高さとして表されています。以前のグラフは JASP の能力を超えた、R の発展的プロットパッケージの力を使って描かれていました。しかし JASP もそれに近いことをしてくれます。JASP でのヒストグラムの描画はとても簡単です。‘記述’ - ‘記述統計’ メニューの下にある ‘プロット’ をひらき、‘分布のプロット’ チェックボックスをクリックしたのが、図 5.2 に示されています。JASP のデフォルトでは、y 軸が ‘度数’ とラベルされていて、x 軸が変数名になっています。**ビン**は自動的に選択されます。度数が表示されますが、実際の数字はそれほど問題にならないことに注意してください。むしろ、われわれが本当に興味を持っているのは、分布の形状からくる印象なのです。それが正規分布しているのか、それが尖っていたり歪んでいたたりしないか? 私たちの第一印象は、**ヒストグラム**から作られるのです。

JASP の特徴の一つ付け加えるなら、‘密度’ 曲線をこのヒストグラムの上に書き加えられるというところです。これをするには ‘プロット’ の下にある ‘密度を表示’ のチェックボックスをクリックしてください。これが図 5.3 に示されているプロットです。密度プロットは連続した区間や時系列全体をカバーする分布を可視化します。この図は、プロットされた値に**カーネルスMOOTHING**を使ったヒストグラムの一種で、ノイズを除去した平滑化によって分布をよりスムーズにしたものです。密度プロットのピークは、区間中の値がどこに集中しているかを示してくれています。ヒストグラムの上に密度プロットを描くことの利点は、分布の形をわかりやすくすることにあります。なぜならこれはビン (ヒストグラムで使われている各バー) の数に影響されないからです。たった 4 つのビンしかないヒストグラムは、20 のビンをもつヒストグラムに比べて分布の形をうまく表現できません。でも密度プロットでは、そういう問題が生じません。

この画像はプレゼンテーション用のグラフィック (例えばレポートに入れるもの) にするには、かなり修正する必要がありますが、データを描画する分にはかなりいい仕事してくれます。実際、ヒストグラムや密度プロットの強みは (適切に使えば)、データの全体的な広がりを表示し、それがどんな形をしているのかについてかなり良い直感を与えてくれることです。ヒストグラムの欠点は、コンパクトさに欠けることです。他のプロットと違って、20 から 30 ものヒストグラムを一つの図に詰め込んで人に説明するのはとても難しいのです。そしてもちろん、データが名義尺度水準であれば




Figure5.2 ‘分布のプロット’ オプションによって作られたヒストグラムを描いた JASP のスクリーンショット

ヒストグラムは適用できません。

5.2

ボックスプロット

ヒストグラムの代わりになるのは、**ボックスプロット**，別名“箱ヒゲ図”と呼ばれるものです。ヒストグラムのように、間隔あるいは比率尺度水準のデータに適しています。ボックスプロットの背後にある考え方は、中央値、四分位範囲、データの幅を単純に示して見せようというものです。ボックスプロットによる表現は非常にコンパクトで、特にデータ分析の探索的な段階でデータがどんなものかを理解しようとする時の手法としてとてもポピュラーなものになっています。ではそれがどういものか、`afl.margins` のデータを例にしてみいきましょう。

ボックスプロットがどんなものかを見るために、まず描いてみるのがいいでしょう。‘ボックスプロット’をクリックすれば、右下に図 5.4 のようなものが示されると思います。デフォルトでは、JASP は最も基本的なボックスプロットを示します。このプロットを見れば、そこから何がわかるか




Figure5.3 afl.margins 変数の JASP による密度プロット

一目瞭然です。箱の中心にある太い線が中央値です。箱の幅は 25 パーセンタイルと 75 パーセンタイルの幅になっています。そして“ひげ”の部分はある限界値を超えない最も極端なデータポイントです。デフォルトでは、この限界値は四分位範囲 (IQR) の 1.5 倍で、下限は **25 パーセンタイル点 - (1.5*IQR)**、上限は **75 パーセンタイル点 + (1.5*IQR)** になっています。この範囲の外に入る点は、髭でカバーできないので円あるいは点で示され、これは一般的に**外れ値**とよばれます。私たちの AFL 勝率データでは、二つの観測点がこの範囲の外に落ちており、この観測データは点で表されています (上限は 107 で、スプレッドシートのデータをみると 2 件これより大きいもの、108 と 116 があり、それぞれの点が打たれています)。

5.2.1 バイオリンプロット

伝統的なボックスプロットのバリエーションとして、バイオリンプロットというのがあります。バイオリンプロットはボックスプロットに似ていますが、異なる値におけるデータのカーネル確率密度も表示してくれます。典型的には、バイオリンプロットはデータの中央値と、標準的なボックスプロットと同じような四分位範囲を示すボックスも同時に示します。JASP では、この種の機能は 'バイオリンの要素' と 'ボックスプロット要素' のチェックボックスをチェックすることでできます。図 5.5 では、データ点もプロットしました (これは 'Jitter 要素' のチェックボックスを選択することで、




Figure5.4 JASP による afl.margins 変数のボックスプロット

プロットに実際のデータ点を追加します)。

5.2.2 複数のボックスプロットを描画する

最後にもう一つだけ。複数のボックスプロットを一度に書くにはどうしたらいいでしょう？ 例えば、2010 年の AFL 勝率データだけでなく、1987 年から 2010 年までの各年度のボックスプロットを個別に描きたいと思ったとしましょう。これをするためには、まずデータを見つけなければなりません。このデータは aflsmall12.csv ファイルにあります。では JASP に読み込んで、みてみましょう。これはちょっと大きなデータセットであることがわかんと思います。ここには 4296 ゲームとその変数が含まれています。JASP で **勝率** 変数についてのボックスプロットを描く時に、**年度**ごとに分けたいですね。それをするためには、**年度**変数を名義尺度水準の変数に変換し、**年度**にわたってボックスの '分割' をします。

その結果が図 5.6 です。このバージョンのボックスプロットは、年度ごとに分割されており、ヒストグラムよりボックスプロットを使った方がいいこともあるのはなぜか、ということがすぐにわかりますね。これを見ると、データの詳細に入り込まなくても年度ごとにどうなっているか、わかりやすくなっています。もしこのスペースに 24 個のヒストグラムを詰め込もうとしたら、何が起ころか

Boxplots

afl.margins




Figure5.5 JASP における afl.margins 変数のバイオリンプロットにボックスプロットとデータ点も重ねてみました

考えてみてください。そんなことをしても、読者が何かを学べるとは思いませんけどね。

5.3

JASP で画像を保存する方法

ちょっと待って、と思ってるかもしれませんね。JASP でいい図が欠けてもそれを保存したり友達に送り、私のデータがいかに素晴らしいかを語れないようでは意味がありません。図を保存するにはどうしたらいいでしょう？ 簡単です。プロットの上部、横についている三角形をクリックして、‘名前をつけて画像を保存’を選ぶだけです。いくつかのフォーマットを選んで保存することができ、選択できる形式は ‘png’, ‘pdf’, ‘eps’, ‘tif’ があります。これらのフォーマットで友達に画像を送ったり、(もしかするとさらに重要なことには) それらを課題や論文に含めることができます。

5.4




Figure5.6 JASP における複数ボックスプロット。af1small12 データセットにおける、年度変数ごとの 勝率

要約

多分私は単純な心の持ち主なんですが、絵が好きなんです。新しい論文を書き始めるとき、まず私がすることはどっしり座ってどんな絵を描こうかなと考えるのです。頭の中で、その論文は実際にストーリーに沿った一連の図を思い浮かべています。残りは飾りに過ぎません。私がここで伝えたいことは、人間の視覚システムはとても強力なデータ分析ツールであるということです。図は正しい情報を与え、大量の情報を瞬時に読者に伝えることができます。“百聞は一見にしかず”という諺の通りです。そう考えると、この章はこの本の中で最も重要なものの一つではないかと思うのです、本章で扱ったのは次のとおりです。:

- 一般的なプロット. この章のほとんどは統計学者が好んで使う標準的なグラフを紹介しました。: ヒストグラム (セクション 5.1) とボックスプロット (セクション 5.2) です。
- 画像の保存. 重要なことで、あなたの描いた図を出力することについても言及しました (セクション 5.3)

最後にひとつ。JASP は美しいグラフを提供してくれますが、プロットの編集はできるようにはなっていません。もっと発展的なグラフやプロットの可能性を引き出すには、R におけるパッケージ

ジを使うことでさらに強力に進めることができます。最も有名な廟 g システムの一つは、`ggplot2` パッケージ (<http://ggplot2.org/> を参照) によって提供されています。これは “グラフィックスの文法”(Wilkinson, Wills, Rope, Norton, and Dubbs 2006). という考え方に基づいているのです。それは初心者向けではありません。それを使い始める前に、まず R の全体像を掴む必要がありますし、コツを掴むのには少し時間がかかります。ですが、準備ができれば学ぶ価値はあります。それは本当にパワフルでよりスッキリしたシステムなのですから。

Part III.

統計理論

第 IV 部への序奏

本書の第 IV 部は、統計的推測の理論を扱うという性格上、飛び抜けて理論的な部分です。続く 3 つの章での目標は、確率論 (Chapter 6)、標本抽出と推定 (Chapter 7)、統計的仮説検定 (Chapter 8) への導入を示すことです。ただし始める前に、大きな見取り図について述べておきたいと思います。統計的推測とは何よりもデータから学ぶことです。目標はもはやデータを記述することだけではなく、データを使って世界について結論を導くことになります。議論の動機づけとして、帰納の謎として知られる哲学的なパズルに少し時間を割きたいと思います。というのも、これは本書を通じて何度も顔を出す問題、つまり統計的推測は仮定に頼っているという問題に触れているからです。これは悪いことのように聞こえます。日常生活では“決して仮定を置くべきではない”といったことが言われますし、心理学の授業でも仮定やバイアスは避けるべき悪いものとして語られがちです。私自身の苦い経験から言えば、哲学者のそばでそんなことを言うてはいけません。

論理的推論の限界について

戦の技術のすべては、丘の向こう側に何があるかを見抜くこと、言い換えれば、知っていることから知らないことを学ぶことにある。

– 初代ウェリントン公爵 Arthur Wellesley

上の言葉は、田舎を馬車で移動していたときに生まれたものだそうです^{*2}。彼と同乗者の J. W. Croker は当てっこ遊びをしていて、丘のたびにその向こう側に何があるかを予測し合っていました。そして毎回、Wellesley が正しく Croker が間違っていたのです。何年もあとにその遊びについて尋ねられた Wellesley は、“戦の技術のすべては、丘の向こう側に何があるかを見抜くことにある”と説明しました。実際、この点で戦は特別ではありません。人生はすべて何らかの形の当てっこ遊びであり、日々をやり過ごすには良い推測をする必要があります。ですから、私たちも当てっこ遊びをしてみましょう。

あなたと私が Wellesley と Croker の勝負を眺めていて、3 つの丘ごとに次の丘でどちらが勝つかを予測しなければならないとしましょう。W を Wellesley の勝ち、C を Croker の勝ちとします。3 つの丘のあと、データは次のようになっています。

WWW

^{*2}出典: <http://www.bartleby.com/344/400.html>。

そこで私たちの会話はこうなります。

あなた: 3連勝くらいではたいした意味はないわね。WellesleyのほうがCrokerより上手なのかもしれないけど、単なる運かもしれない。でも私はちょっとギャンブラーだから。Wellesleyに賭けるわ。

私: 3連勝が情報を持たないという点には同意しますし、WellesleyのほうがCrokerより優れていると考える理由も見当たりません。この段階で賭けを正当化することはできませんね。すみませんが、私は賭けません。

あなたの賭けは当たりました。さらに3つの丘を越え、Wellesleyがその3つとも勝ったのです。次のラウンドに入る時点で、私たちの遊びのスコアはあなたの1-0のリードで、データは次のようになっています。

WWW WWW

私たちのささやかな余興の各段階でどの観測が手元にあったかがわかるように、データを3つずつのまとまりに整理してあります。この新しいまとまりを見て、会話は続きます。

あなた: ウェリントン公が6連勝ね。さすがに怪しくなってきたわ。まだ確信はないけれど、次も勝つと踏んでいる。

私: 私にはそう見えません。確かにWellesleyが6連勝したことには同意しますが、それが7つめも勝つことを意味する論理的な理由は見当たりません。賭けません。

あなた: 本気でそう思っているの。まあいいわ。でも前回の賭けはうまくいったし、私は自分の選択に納得している。

2度目もあなたが正しく、2度目も私が間違っていました。Wellesleyは次の3つの丘でも勝ち、Crokerに対する戦績を9-0に伸ばします。手元のデータはこうなりました。

WWW WWW WWW

そして会話はこう続きます。

あなた: もう明らかでしょう。Wellesleyのほうがこの遊びはずっと上手なのよ。次の丘も彼が勝つ、これは二人とも同意よね。

私: 本当にそれを支える論理的な証拠がありますか。この遊びを始める前、最初の10回の結果にはたくさんの可能性があって、どれを予想すればよいか私には見当もつきませんでした。WWW WWW WWW Wもひとつの可能性でしたが、WCC

CWC WWC C も、WWW WWW WWW C も、CCC CCC CCC C さえもそうでした。何が起るか見当もつかなかったのですから、どれも同じくらいありそうだと
言ったはずですよ。あなたもそうでしょう。“見当もつかない”と言うのは、そ
ういう意味ではありませんか。

あなた: まあそうですね。

私: でしたら、これまでの観測は論理的に、WWW WWW WWW C と WWW WWW WWW W
の 2 つを除くすべての可能性を排除しました。この 2 つはどちらも、ここま
でに出会った証拠と完全に整合していますよね。

あなた: ええ、もちろんそうよ。それで何が言いたい。

私: では、何が変わったのでしょうか。遊びを始めた時点で、あなたはこの 2 つ
が同じくらいもっともらしいと私に同意したはずですし、これまでに出会っ
た証拠はこの 2 つの可能性を区別していません。ですからこの 2 つは依然と
して同じくらいもっともらしく、一方を他方より好む論理的理由が私には
見当たりません。Wellesley の 9 連勝が注目に値するという点には同意しま
すが、10 個めの丘でも彼が勝つと考えるもっともな理由は思いつかないです。
賭けません。

あなた: 言いたいことはわかるけれど、それでも私は運を試すわ。Wellesley に賭
ける。

Wellesley の連勝は次の 3 つの丘でも続きます。Wellesley と Croker の勝負は 12-0、私たちの遊びの
スコアは 3-0 になりました。4 回目のラウンドに入る時点で、データはこうなっています。

WWW WWW WWW WWW

そして会話は続きます。

あなた: ほらね。Wellesley がさらに 3 連勝で、私もまた勝ち。認めなさいよ、彼
については私が正しかったの。今度はさすがに二人とも Wellesley に賭けるわ
よね。

私: どう考えればよいのかわかりません。前のラウンドとまったく同じ状況で、た
いして何も変わっていないように感じます。13 個の丘の系列でまだ排除され
ていない正当な可能性は、WWW WWW WWW WWW C と WWW WWW WWW WWW W の 2
つだけです。前回言ったとおりです。遊びが始まる前にありうる結果がすべて
同じくらいもっともらしかったのなら、私たちの観測がどちらも排除してい
ない以上、この 2 つはいまも同じくらいもっともらしいはずではありません
か。Wellesley が見事な連勝中だという感じには同意しますが、その連勝が続
くという論理的な証拠はどこにあるのでしょうか。

あなた: あなたは理不尽だと思うわ。証拠が必要ななら、私たちのスコアを見てみたら。あなたは統計の専門家で、その洒落た論理的な分析とやらを使ってきたけれど、事実としてあなたは負けている。私はただの常識に頼っていて、勝っている。方針を変えたほうがいいんじゃない。

私: うーん、それはもっともな指摘ですし、私も負けたくはありません。しかし残念ながら、あなたの方針が私のものより優れているという論理的な証拠は見当たらないのです。私たちの遊びを誰か別の人が見ていたとしたら、その人が観測したのはあなたの3連勝でしょう。その人のデータはYYYとなります。論理的には、これはWellesleyとCrokerを見ていた最初のラウンドと何ら変わらないように思えます。あなたの3連勝はたいした証拠には見えませんが、あなたの方針が私のものよりうまくいっていると考えられる理由も見当たりません。WWWが彼らの遊びでWellesleyのほうが上手だという良い証拠だと思わなかったのなら、YYYが私たちの遊びであなたのほうが上手だという良い証拠だと、いま考える理由もないはずでしょう。

あなた: わかった、あなたはいいじわるね。

私: その論理的な証拠も見当たりません。

仮定を置かずに学ぶというのは神話である

この対話はいろいろな形で分析できますが、本書は心理学者向けの統計の本であって推論の哲学や心理学の入門書ではありませんので、手短かにすませます。上で述べたものは、帰納の謎と呼ばれることがあります。Wellesleyの12-0という戦績が、13回目も彼が勝つというかなり強い証拠だと考えるのはまったく理にかなっているように思えますが、この信念にきちんとした論理的な正当化を与えるのは簡単ではありません。それどころか、答えが自明であるにもかかわらず、論理的な正当化を持たない何らかの仮定に頼らずにWellesleyへの賭けを正当化することは、実際には不可能なのです。

帰納の謎はDavid Hume、そしてより最近ではNelson Goodmanの哲学的な仕事と結びつけられることが多いのですが、文学(Lewis Carroll)から機械学習(“ノーフリーランチ”定理)まで、さまざまな分野でこの問題が顔を出す例を見つけられます。“知っていることから知らないことを学ぶ”という営みには、確かにどこか奇妙なところがあるのです。決定的に重要なのは、世界について何かを学びたいのなら仮定とバイアスは避けられない、ということです。これから逃れる術はありませんし、人間の推論についてと同じく統計的推測についても当てはまります。対話のなかで私は、人間としてまったくまっとうなあなたの推論に矛先を向けていましたが、あなたが頼った常識的な推論は、統計家がやったであろうことと何ら変わりません。対話のあなたの側の“常識”は、WellesleyとCrokerのあいだに何らかの技量の差が存在するという暗黙の仮定に頼っていて、あなたはその技量

差がどれくらいかを見極めようとしていたのです。私の“論理的分析”はその仮定を完全に拒否します。私が受け入れる気があったのは、勝ち負けの系列が存在すること、そしてどの系列が観測されるかを私は知らないということだけでした。対話を通じて私は、Wellesley と Croker の勝負が始まる時点では論理的に可能なデータはすべて同じくらいもっもらしい、と主張し続けましたし、私が信念を改めた唯一のやり方は、観測と事実として矛盾する可能性を消していくことだけでした。

それ自体としては、まったくまっとうに聞こえます。実際、よい演繹的推論の証しのようにさえ聞こえます。シャーロック・ホームズのように、私のやり方は不可能なものを排除して、残ったものが真実であることを期待する、というものでした。しかし見てきたように、不可能なものを排除することは、私を予測へ決して導きませんでした。それ自体としては、対話の私の側で述べたことはすべて完全に正しかったのです。何の予測もできないというのは、“仮定を置かない”ことの論理的な帰結です。結局私が遊びに負けたのは、あなたが仮定を置き、その仮定が正しかったからでした。技量は実在するものですし、技量の存在を信じていたからこそ、あなたは Wellesley のほうが Croker より技量が高いと学べたのです。もし学習を導く仮定としてもっとまっとうでないものに頼っていたなら、あなたはこの遊びに勝てなかったかもしれません。

最終的に、ここから持ち帰るべきことが2つあります。第一に、述べてきたとおり、データから何かを学びたいのなら仮定を置くことは避けられません。しかし第二に、仮定が必要だと気づいたなら、正しい仮定を置くことが重要になります。仮定の少ないデータ分析が、仮定の多いものより必ず優れているわけではありません。すべては、その仮定が手元のデータにとって良いものかどうかにかかっています。本書の残りを進めるなかで、特定の統計手法を支えている仮定と、その仮定がまっとうかどうかをどう確認できるかを、しばしば指摘していきます。

6. 確率への招待

[神] は私たちに黄昏だけを与えたもうた ...確率の。

– John Locke

本書のここまでは、実験デザインにおける鍵となる概念のいくつかを紹介し、またデータセットをどのように要約することができるかについてお話ししてきました。多くの人にとっては、それが統計の全てです。すなわち、全ての数字を集め、平均値を計算し、図を書いて、それら全てをレポートのあちこちに配置することが。切手の収集のようなかんじでしょうか。ただし使うのは数字ですが。しかし、統計学はそれ以上の範囲をカバーするものです。実際、記述統計は統計学の最も小さい領域の一つで、最も影響力のないところでしかありません。統計におけるもっと広大で有用な領域とは、データについての推論ができるような情報を提供してくれるものです。

あなたが統計的に考えることを始めたら、統計はデータから推論を導き出す助けになるし、至る所で使われている例を目にすることになるでしょう。例えば、新聞 Sydney Morning Herald 誌の 2010 年 10 月 30 日に、次のような記事が掲載されていました。

選挙結果に対して、“私は大変な仕事を抱えている”と首相はコメントしました。彼女の政府が今やこれまでにない支持率の低い労働党であり、予備選挙での支持率が 23 パーセントしかなかったのです。

この種の発言は新聞や日々の生活にあっても特に目立つものではないですが、それが何を言わんとしているのかを考えてみましょう。調査会社が調査を実施するときは、彼らには余裕があるので非常に大きな調査を企画するのが普通です。私は面倒くさがりやなので元の調査を調べなかったのですが、調査会社がニューサウスウェールズ (NSW) の有権者からランダムに 1000 人集め、そのうち 230 人 (23%) がオーストラリア労働党 (ALP) に投票するつもりだと答えたとします。2010 年の選挙では、オーストラリア選挙委員会は NSW で 4,610,795 人が投票した、と公表していますから、残る 4,609,795 人 (有権者の約 99.98%) の意見がどうだったか、私たちにはわかりません。調査会社に対して誰も嘘をついていないと仮定しても、我々が 100% の自信を持って言えることは、真の ALP 予備選挙有権者は $230/4610795$ (約 0.005%) から $4610025/4610795$ (約 99.83%) の間のどこ

かにいる，ということだけです。それでは調査会社，新聞，その読者が，ALP の予備選挙の支持率が 23% に過ぎないと正当化する根拠は一体どこにあるのでしょうか？

答えはかなりはっきりしています。もし私が 1000 人の人を無作為に呼んできて，そのうち 230 人が ALP に投票するつもりだと答えたとなると，実際に ALP に投票するつもりの人たち全体のうちの，この 230 人だけということはありません。言い方を変えると，調査会社が集めてきたデータはもっと大きい母集団の代表であることを，我々は想定するのです。さて，どの程度代表しているでしょう？ 本当に ALP 予備投票が 24% であれば私たちは驚くのでしょうか。29% なら？ それとも 37% のとき？ ここまでくると，日々の直感は少し崩れてきます。

もし 24% であっても誰も驚かないでしょうが，37% であればみんな驚くでしょう。しかし，29% になりそうだと言うのは少し厳しい気がします。数字を見て推測するだけでなく，もう少し強力なツールが必要です。

推測統計学がこの種の問題に答えるために私たちに必要なツールであり，この種の問いが科学的営みの中心にあるので，統計学や科学的手法についてのあらゆる入門コースの大半を占めているのです。しかし，統計的推論の理論は**確率理論**の頂点の上に作られています。ということで，今から確率理論を学ぶことにしましょう。確率理論についての議論は，基本的にバックグラウンドを細かく見ていくようなものです。この章にはそれほど統計の話は出てきませんし，この本の他の章ほど数学的な詳細を深く理解する必要もありません。ですが，確率理論は統計を深いところから支える支柱ですから，その基礎をカバーしておくことに価値があるのです。

6.1

確率と統計はどちらがうの？

確率理論の話をする前に，確率と統計学の関係についてちょっと触れておきましょう。この二つの学問は密接な関係にありますが，全く同じものではありません。確率理論は“偶然の原理”です。それは数学の分野の一つで，異なる種類の出来事がどの程度の頻度で生じるのかを教えてくれるものです。例えば，次のような問いは確率理論を使って答えることができるものです。

- 公平なコインが 10 回連続で表になる確率はどれくらいですか？
- 6 面サイコロを二回振った時，二つとも 6 が出るのはどれくらいありえることですか？
- 完全にシャッフルされたデッキからカードを 5 枚引いた時，全てハートのカードになることはどれくらいありえることですか？ くじを引いて当たりが出る確率はどれくらいでしょう？

これらの質問は，いずれも一般的にありふれたものであることに注意してください。どの場合でも，“世界の真理’ が分かっている時に，“どんな種類の出来事が” 生じるのだろうか，という形に

なっています。最初の質問では、私はコインが公平である、つまり毎回のコイントスで表が出るのは 50% の確率であると知っているのです。第二の質問では、私はサイコロで 6 が出る確率は $1/6$ であることを知っているのです。第 3 の質問では、私はデッキがうまくシャッフルされていることを知っているのです。第 4 の質問では、私はくじが特定のルールに従うことを知っているのです。気づきましたね。決定的な点は、確率的な問いは世界について既知のモデルから始まり、私たちはそのモデルを使ってなんらかの計算をするのです。そのモデルはかなりシンプルにできます。例えば、コイントスの例では私たちはモデルを次のように書くことができます。

$$P(\text{heads}) = 0.5$$

これは「表が出る確率は 0.5」と読むことができます。後で見るように、0% から 100% の範囲にある比率の数字と同様に、確率は 0 から 1 の数字になります。この確率モデルを使って最初の問いに答えるのですが、私はこれから起こることを実際には知りません。この質問がいうように、10 回表が出るかもしれません。でも、3 回しか出ないかもしれません。これが大事なところなのです。確率理論では、モデルはわかっていますが、データはわからないのです。

それが確率なのです。では統計学とは何でしょう？統計学の問いは、その周りにあって別の働きをするものです。

統計学では、私たちは世界の真理について知りません。私たちが持っているのはデータだけであり、世界の真理について学びたいことはデータから得られるのです。統計的な問いは次のようになることが多いようです。

- もし友達がコイントスを 10 回やって表が 10 回出たとしたら、彼は私をからかっているんじゃないだろうか？
- もしデッキの上から 5 枚カードを取り出して、それが全部ハートだったら、そのデッキがシャッフルされていた可能性はどれぐらい？
- もし宝くじ主催者の配偶者がくじに当選したら、その宝くじがイカサマだった可能性はどれぐらい？

この時、私たちが知っているのはデータだけです。私が知っていることは、友達が 10 回コイントスをして、全部表であったことだけです。そして私が推論したいことは、実際に公平なコインが連続して 10 回表になったのだと結論づけて良いかどうか、あるいは私の友達が私をからかっていると疑って良いかどうかです。ここでのデータは次のようになります。

表 表 表 表 表 表 表 表 表 表

そして、私がやろうとしていることは、どの“世界についてのモデル”を信用すべきか、ということです。もしコインが公平なものであれば、私が受け入れるべきモデルのひとつは表が出る確率が 0.5、つまり $P(\text{heads}) = 0.5$ であるというものです。もしコインが公平なものでなければ、表が出る

確率は 0.5 ではないことになるので、それを我々は $P(\text{heads}) \neq 0.5$ と書くでしょう。言い換えると、統計的な推論の問題は、どちらの確率モデルが正しいかということです。これで明らかなように、統計的な問いは確率の問いと同じではないのですが、お互い深く関係し合っているのです。だから統計理論のよい入門書は、確率についての議論とそれがどのように機能するか、というところから始めるのです。

6.2

確率が意味するものは？

いくつかの質問から始めましょう。“確率”とはなんでしょう？ あなたは少し驚くかもしれませんが、これについて統計学者や数学者が(ほとんど)同意してくれるのは確率のルールであって、それが本当は何を意味するのかについては、ほとんど同意が得られません。私たちは“偶然 (chance)”とか、“ありそう (likely)”とか、“ありえる (possible)”とか、“たぶん (probable)”という言葉を変に便利に使うので、この問題に答えるのが難しそうだとされても奇妙に感じます。しかし実生活の中でも、会話がうまくいってないように感じてそれから距離を置いていたけど、(多くの日常的な概念について) あなたがそれが何なのか本当は分かっていたことがあとでわかる、という経験をしたことがあるでしょう。

さて始めましょうか。私が二台のロボットチーム、アーセナルとミランが戦うサッカーゲームに賭けたいとします。いろいろ考えて、アーセナルが 80% の確率で勝つだろう、と判断したとします。さてこれは何を意味しているのでしょうか？ これには三つの可能性があります。

- これはロボットチームなので、私は何度も試合を試すことができ、実際そうすると 10 ゲーム中 8 回アーセナルが勝つだろう、ということ。
- どんなゲームであっても、このゲームに賭けるときは、\$1 をミランに賭けたら \$5 戻ってくる (つまり、私の \$1 は賭けに勝つと \$4 儲けさせてくれる) し、アーセナルには \$4 を賭けないと \$5 戻ってこない (つまり、私の \$4 プラス \$1 の儲け)、という時に初めて“公平な”賭けが成立する、ということ。
- アーセナルの勝利について、私の主観的な“信念”とか“自信”は、ミランの勝利についての信念より 4 倍強い、ということ。

どれも微妙ですねえ。しかし、いずれも同じ、ではないし、全ての統計学者がこれら全てを認めているわけでもないのです。その理由は、そこには統計学的イデオロギーの違いがあるからで(本当です！)、どれを認めるかによって、この表現のいくつかは無意味だとか不適切だと言いたくなるでしょう。このセクションでは、ここにある二つの大きなアプローチについて簡単な導入を行います。

アプローチは一つだけということは決してありませんが、その二つは大きな流れなのです。

6.2.1 頻度主義者の観点から

確率への 2 大アプローチのうち最初のものは、統計学においてより支配的な考え方であり、**頻度主義者の観点**と言われます。それは**長期的な頻度**として確率を定義するからです。私たちが何度も何度もコインフリップをし続けるとしましょう。定義から、このコインは $P(H) = 0.5$ です。私たちは何を観測するでしょう？一つの可能性として、最初の 20 回は次のようになったとします。

T, H, H, H, H, T, T, H, H, H, H, T, H, H, T, T, T, T, T, H

この例では 20 回中 11 回 (55%) が面を向いています。今度は、私がずっとコインフリップをしながら表が出る回数 (ここでは N_H としておきましょう) を数え、その最初から N 回目までで確率を N_H/N として毎回計算していくとしましょう。そうすると、次のようになります (これを書くために、私は文字通りコインフリップをしたんですよ!):

コインフリップの回数	1	2	3	4	5	6	7	8	9	10
表が出た回数	0	1	2	3	4	4	4	5	6	7
割合	.00	.50	.67	.75	.80	.67	.57	.63	.67	.70

コインフリップの回数	11	12	13	14	15	16	17	18	19	20
表が出た回数	8	8	9	10	10	10	10	10	10	11
割合	.73	.67	.69	.71	.67	.63	.59	.56	.53	.55

この流れの最初のうちは、表が出る割合は広く変動し、最初は.00 ですが.80 まで上昇します。続けていくと、“正しい” 答えである.50 に徐々に近づいていくような印象を持つ人もいかもしれません。これがごく簡単にいうところの、頻度主義者の確率の定義です。公平なコインを何度もフリップしつづけ、 N が大きくなれば (無限に近づけば、というのを $N \rightarrow \infty$) と書きますが)、表が上になる割合は 50% に収束して行きます。ここには数学的に注意が必要なちょっとしたテクニックがありますが、内容的にはこれが頻度主義者が確率を定義する方法です。残念ながら、私はコインを無限回フリップしたことはないですし、無限回コインをフリップするのに耐えうる無限の精神力も持ち合わせていません。でも私はコンピュータを持っているし、コンピュータはこの辛い作業を厭わないのです。ですから、私はコンピュータに、1000 回コインフリップのシミュレーションをやるようお願いし、 N_H/N が N の増加とともにどうなるかの図を描いてもらいました。実際には、私はそれがまぐれではないことを確認するために 4 回繰り返しました。その結果が Figure 6.1 です。ご覧いただいたように、表が観測される割合は最終的に変動するのをやめ、落ち着いて行きます。そうすると、

最終的に落ち着いた数字が表の出る確率，ということになります。

頻度主義者の確率の定義は，いくつかの望ましい性質を持っています。まず，それは客観的です。出来事の確率は世界に根ざしたものである必要があります。確率の言葉が意味を持つのは，それが物理的な宇宙の中で生じる（一連の）出来事について言及しているからです^{*1}第二に，曖昧さがありません。同じ一連の出来事を観測した人は誰でも，その出来事の確率を計算しようとすれば，確実に同じ答えに到達します。

しかし，望ましくない特徴もあります。まず，無限の連続というのは物理的な世界にはありません。あなたがポケットからコインを取り出して，コインフリップをし始めたと思ってください。コインが着地するたびに，それは地面に衝撃を与えます。毎回の衝撃で，コインは少しずつ欠けていきます。最終的に，コインは破壊されてしまうかもしれません。だから，“無限の”コインフリップの連続，というのが意味のある概念で客観的なものであるとして，意味のあるフリをするべきかどうか，疑問に思うかもしれません。私たちは出来事の“無限の連続”が物理的な宇宙において現実的なものであるということではできません。なぜなら，物理的な宇宙は無限の何かを許容しないからです。もっと厳密にいうと，頻度主義者の定義は対象が狭いのです。日々の生活の中で人が確率に割り当てて満足していることはたくさんあるのですが，（理論の中でも）仮想的な出来事の連続に割り当てられないものがたくさんあります。例えば，気象学者がテレビで「2048年，12月2日のアデレードで雨が降る確率は60%です」といったとしても，私たちはこれを喜んで受け入れます。ですが，これを頻度主義者の用語でどうやって定義するのかわかりません。アデレードは一つしかない街ですし，2048年12月2日も一回しかありません。またこれは無限の出来事の連続はありません，一度きりのことです。頻度主義者の確率は，一度しか起きない出来事について確率でものをいうことを本気で禁じます。頻度主義者の物の見方からすると，明日は雨が降るか降らないかのどちらかです。一度きりの繰り返しのない出来事に“確率”は付随させられないのです。では，頻度主義者がこれを回避するために使う，非常に巧妙なトリックがあることを指摘しなければなりません。一つの可能性として，気象学者が言わんとしているのは，“私が60%の偶然で雨が降る日々，というカテゴリーがあって，もしそうした日だけみてこの予測をしたとすると，その日のうちの60%が実際に雨が降るのです”，とまあこういうようなことにするのです。これは非常に奇妙で，直観に反したものですが，頻度主義者がこのような言い方をするのを実際に目にするでしょう。そしてこの本の後でもこのことがきっと出てくるでしょう（Section 7.5をみてください）。

6.2.2 ベイジアンの観点から

確率についての**ベイジアンの観点**は，時に主観的な観点だと言われ，統計学者の中ではマイノリ

^{*1}これはもちろん，頻度主義者が仮説的な発言ができないことを意味するものではありません。単に，もしあなたが確率について表明したいことがあれば，それは潜在的に観測する一連の出来事についての言葉を，違う結果の相対的な頻度と共に，表現しなおせるものでなければならないということです。




Figure6.1 頻度主義者の確率がどのように働くかの図。コインフリップを何度も何度も繰り返すと、表が出る割合は徐々に落ち着いていき、真の確率である 0.5 に収束していきます。各パネルが示すのは、四つの異なるシミュレーション実験の結果です。それぞれのケースについて、コインを 1000 回フリップして表が出る割合を追跡し続けたものです。どのケースも最終的にちょうど 0.5 になりはしませんが、もしこれを無限回実験し続けるようにすれば、最終的にはそうなるはずです。

ティでしたが、この数十年の間はかなり牽引力を持ってきました。ベイズ主義的精神は多くの楽しみ方があるので、“これぞ” ベイジアン の 観 点、と 正 確 に 言 い 切 る の は 難 し い も の が あ り ま す。主観的確率について考えるもっとも一般的な方法は、出来事についての確率を、出来事の真実に対して知るかつ合理的なエージェントが割り振る **信念の程度** として定義することです。この観点からいくと、確率は現実世界に存在していないことになり、むしろ人やその他の知的存在の思考や仮定の中に存在することになります。

しかし、このアプローチにしたがって仕事をすると、私たちはなんらかの方法で“信念の程度”を操作可能なものにする必要があります。いろいろな方法がありますが、一つのやり方としては、“合理的なギャンブル” の用語で定式化することです。明日雨が降る確率が 60% だ、と私が信じているとします。ここで誰かが、もし明日雨が降ったら私に 5\$あげるけど、雨が降らなかったら 5\$よこせ、という賭けを申し出てきたとします。もちろん、私の立場からすれば、これはちょっといい話です。しかし一方で、もし私が明日雨が降る確率は 40% だと考えていたのなら、この賭けをするのは悪い手ということになります。つまり、私たちは“主観的確率” の本質を、私がこの賭けを受け入れるかどうかという用語で操作したことになります。

ベジアンアプローチの利点と欠点はなんでしょう？ 主な利点は確率を割り当てたいどんな出来事にも適用できるということです。繰り返しのある出来事に限定する必要はありません。(多くの人にとっての) 主な欠点は、私たちは完全に客観的にはなれないということです。確率を割り当てるということは、関連する信念の程度についての実態を特定する必要があります。その実態は人間、エイリアン、ロボット、統計学者、誰のものでもいいのです。しかし物事を信じる知的なエージェントがそこにいなければなりません。多くの人にとってはこれが不満のタネになります。幾分曖昧になりますからね。ベジアンアプローチは、そのエージェントが合理的であること(すなわち確率のルールに従うこと)を要求しますが、誰もが自分自身の信念を持つことを許します。私はコインが公平なものであると信じられるし、あなたは必ずしもそうでなくていいのです。私もあなたも合理的なままです。頻度主義者の観点は、二人の観測者が同じイベントに異なる確率を割り当てることを許しません。もしそういう事態が生じたら、二人のうちどちらかが間違っているのです。ベジアン の 観 点 で は この 問 題 が 生 じ る こ と を 止 め ま せ ん。異なる背景知識を持つ二人の観測者が、同じ出来事に対して合法的に異なる信念を持ちうるのです。簡単にいうと、頻度主義者の観点が時折見識が狭すぎるように見える(確率を割り当てたい出来事の多くを許してくれない)のに対し、ベジアン の 観 点 は 時 折 懐 が 広 す ぎ る (観測者間であまりにも多くの異なる状態を許す) のです。

6.2.3 違いは何？ 誰が正しいの？

さて、異なる二つの観点をそれぞれ見てきたわけですが、この二つを比較してみることにしましょう。このセクションの最初に提示した、ロボットサッカーゲームの例に戻りましょうか。この三つの表現について、頻度主義者やベジアンがどう考えると思いますか？ 頻度主義者がいう正しい確率の定義に当てはまるのは、どの表現でしょう？ ベジアンが選ぶのはどの表現でしょう？ 頻度主義

者やベイジアンにとって、意味を持たない表現はどれでしょう？ もしあなたが二つの観点を理解できたなら、これらの問いにどう答えたらいいかわかるはずです。

オーケー、あなたは両者の違いを理解していて、その上でどちらが正しいのか、迷っているんですね？ 正直にいうと、どちらが正しい答えなのか私も知りません。言えることは、頻度主義者のように一連の出来事を考えることは数学的に間違えているわけではないし、ベイジアンの合理的エージェントの信念で定義するのも数学的に間違えているわけではない、ということです。実際、深く掘り下げていくと、ベイジアンと頻度主義者は多くの点で合意できることがあります。多くの頻度主義者の方法は、ベイジアンの合理的なエージェントがするであろう意思決定と同じことを言います。多くのベイジアンの方法は、頻度主義者の良い特徴をもっています。

ほとんどの部分において、私は現実主義的ですから、私は信頼できるあらゆる統計的な手法を使います。結局、この本での説明は、ベイズ的手法の方が好ましいようになっているかもしれません。しかし私は頻度主義的な方法について、基本的に反対の立場にないのです。誰もそこまで満足しているわけではありません。例えば、R. フィッシャー卿のことを考えてみます。彼は 20 世紀の統計学者の巨人で、ベイジアンのあらゆることに対する猛烈な敵の一人であり、ベイジアンの確率について、その統計の数学的基礎に関する論文を“より精緻な統計的概念への発展を阻むジャングル”(Fisher 1922b, p.311) といったぐらいです。一方、心理学者の P. ミールは、頻度主義的方法に傾倒すると、あなたを“夢見る乙女の楽しい長旅だが科学的な成果を残すことのない、納得はするけど不毛な知的探索”(Meehl 1967, p.114) に連れていくのだ、と言ったりしています。聞いたことがあるかもしれませんが、統計の歴史はエンターテインメント性を欠きません。

どちらにせよ、私はベイジアンの観点が好きですが、統計分析の多数派は頻度主義的アプローチを基盤にしています。私の理由はプラグマティックなものです。この本のゴールは心理学における典型的な学部統計教育の領域をざっとカバーしていますので、ほとんどの心理学者が使っているような統計的ツールを理解したいと思うのなら、頻度主義者の方法を掴み取る必要があるでしょう。その努力は無駄にならないと約束します。あなたがもしベイジアンの観点到に切り替えたいと思うのなら、“オーソドックスな” 頻度主義者の観点到で書かれた本を一冊は読み通すべきです。とはいえ、私はベイジアンの観点到を全く無視するわけではありません。今までもそしてこれからも、私はベイジアンの観点到からコメントを追加するでしょうし、Chapter 15. ではより深い内容を掘り下げていきたいと思っています。

6.3

確率の理論の基礎

ベイジアンと頻度主義者の思想的な議論はさておき、確率が従うべきルールについてはほとんど同意がとれています。これらのルールに到達するには様々な異なる道があります。もっとも一般的に使

われるアプローチは、20 世紀の最も優れたロシアの数学者、アンドレイ・コルモゴロフによって基礎が作られたものです。詳細に立ち入ることはしませんが、それがどのようなものか、ちょっとした感覚をお伝えしようと思います。そのためには、私は私のズボンについて話さなければなりません。

6.3.1 確率分布入門

私の人生における困った真実の一つは、私がズボンを 5 本しか持っていないということです。ジーンズのものが 3 つ、スーツの下が一つ、トレーニングウェアのズボンが一つ、です。さらに悲しいことに、私はそれに名前をつけています。わたしはそれを、 X_1, X_2, X_3, X_4, X_5 と呼んでいます。本当にそうなんです。だから私はミスター想像力、と呼ばれています。さてある日、私がそのズボンの一つを取り出して履きました。ズボンを二つ同時に身につけようとするほど愚かではないですし、トレーニングのおかげでズボンを履かずに外に出ることはもうなくなりました。この状況を確率理論の言葉を使って表現するなら、それぞれのズボン (つまり各 X) のことは、**根元事象**といいます。根源事象のキーポイントは、私たちが観測するとき (例えば、私がズボンを身につけようとするとき) はいつでも、結果は一つ、そしてその出来事のどれか一つでしかない、ということです。言ったように、私はいつもズボンを 1 着しか身につけませんから、私はこの制約を満たしていることになります。同様に、あらゆる確率事象のセットのことを、**標本空間**といいます。確かに、これを“衣装部屋”と呼ぶ人もいるかもしれませんが、それは確率の用語で私のズボンについて語ることを拒否しているからです。残念。

オーケー、私たちは今や標本空間 (衣装部屋) を手にしたわけで、それは可能な根元事象 (ズボン) から出来上がっているのです、この各要素である事象に**確率**を割り振っていきたいと思います。事象 X に対して、事象の確率 $P(X)$ は 0 から 1 の間の数字です。より大きな $P(X)$ の値は、その事象がより生じやすいことを意味します。そう例えば、もし $P(X) = 0$ なら、事象 X は生じ得ない (つまり、私は決してそのズボンを履かない) ことを意味します。あるいは、もし $P(X) = 1$ なら、事象 X は確実に生じる (つまり、私はいつもそのズボンを履く) ことを意味します。その間にある確率の数字が意味するのは、私は時々それらのズボンを履くということです。たとえば、もし $P(X) = 0.5$ なら、私は二回に一回そのズボンを履く、ということの意味します。

ここまできたら、ほとんど終わったようなものです。最後にやらなければならないことは、“いつも生じるなにか”を認識する必要があるということです。私がズボンを履く時はいつも、本当にズボンをちゃんと履いているのです (おかしなことを言ってるようですが、正しいですね?)。確率の言葉で幾分古臭い表現になりますが、根元事象の確率を足し合わせると 1 になる、ということです。これは**確率の総和の法則**として知られているもので、誰もが本当に気にしているわけではありません。

より大事なことは、これらの必然性が満たされたなら、私たちが手にしたのは**確率分布**である、ということです。例えば、ここに確率分布の例があります。

どのズボン?	ラベル	確率
hline 青いジーンズ	X_1	$P(X_1) = .5$
灰色ジーンズ	X_2	$P(X_2) = .3$
黒いジーンズ	X_3	$P(X_3) = .1$
黒いスーツ	X_4	$P(X_4) = 0$
黒いトレーニングウェア	X_5	$P(X_5) = .1$

各事象は 0 から 1 の間の確率についての数字を持っていて、全ての確率を足し合わせると 1 になります。驚きました。この分布を可視化するために、棒グラフを書くこともできます。図 6.2 を見てください。さて、ここにきて、私たちはすべて成し遂げたようです。すでにあなたは確率分布の何たるかを学びましたし、私はズボン全体に注目したグラフの作り方を見つけ出したのです。私たちの勝利です！




Figure 6.2 “ズボン” 確率分布の視覚的記述. ここには 5 つの “根元事象” があって、それは私の持っている 5 本のズボンに対応しています。各事象はなんらかの生起確率を持っています。この数字は 0 から 1 の間の値です。これらの確率すべてを足すと 1 になります。

もう一つ指摘しておかなければならないことがあります。それは、確率理論は**非根元的事象**についても、根元事象と同じように語ることを許してくれるということです。この考え方を表現する最も簡単な方法として、例をあげましょう。ズボンの例では、私がジーンズを履く確率を完全に適切な

Table6.1 確率が満たすべきいくつかの基礎的ルール。この本でこの後お話しする分析を理解するために、これらのルールを知っておく必要は必ずしもありませんが、もう少し深く確立理論を理解しておきたいのなら、重要なことです。

英語で	表記	数式
not A	$P(\neg A)$	$= 1 - P(A)$
A or B	$P(A \cup B)$	$= P(A) + P(B) - P(A \cap B)$
A and B	$P(A \cap B)$	$= P(A B)P(B)$
.....		

方法で参照できるのでした。このシナリオの中ですと、適当な出来事の一つとして実際に生じうる根元事象である限り、“ダンがジーンズを履く”という事象が生じたということができます。この場合、“青いジーンズ”、“黒いジーンズ”、“灰色ジーンズ”が該当します。数学用語で私たちが“ジーンズ”事象を E と定義する時、それは根元事象 (X_1, X_2, X_3) のセットに対応します。これらの根源事象のどれが生じて、 E が生じたと言っても良いでしょう。 E の定義をこのように書き下したとして、確率 $P(E)$ について言及するなら、ちょっと直接的すぎますが、単にこれらを数え上げればいいですね。この場合ですと、

$$P(E) = P(X_1) + P(X_2) + P(X_3)$$

とすることであり、青、灰色、黒のジーンズの確率がそれぞれ.5,.3,.1 なので、私がジーンズを履く確率は.9 だ、ということができます。

この時点で、あなたはこれが非常に明白でシンプルだと思うかもしれません。それは正しいです。私たちがここでやったのは、いくつかの常識的な考え方にある基本的な数学のラップをかけただけ、なのです。とはいえ、これらの単純な始まりから、とてつもなく強力な数学的道具を作り上げることができるのです。この本では決してその詳細にまで立ち入りませんが、そのほかの確率を守るべきルールについてはリストにして、表 6.1 に示してあります。これらのルールは私がすでに上で述べたシンプルな仮定から導出できますが、この本のどこにもこのルールを適用するところがありませんので、やらないでおきます。

6.4 二項分布

あなたの想像通り、確率分布は非常に様々に変化しますし、分布の範囲は広大な範囲に及びます。ですが、それら全てが同程度に重要だということではありません。実際、この本の内容の大部分は、5 つの分布のどれかに依存しています。その 5 つとは、二項分布、正規分布、 t 分布、 χ^2 (“カイ二乗”) 分布、 F 分布です。次のいくつかのセクションで私がやろうとしているのは、これら 5 つ全て

にいての簡単な導入です。特に二項分布と正規分布に注目していきます。私は二項分布から始めようと思います。これが5つの中では最もシンプルですから。

6.4.1 二項分布の導入

確率の理論は偶然のゲームがどのようなになっているのかを記述しようとする試みから始まりました。ですから、私たちの**二項分布**についての議論は、サイコロをふったりコインをフリップするお話にするのがよいでしょう。単純な“実験”を想像してみてください。私の小さなあったかい手には、6面サイコロが20個握り締められています。各サイコロの一つの面にはドクロの絵が書いてあって、残りの5つの面には何も書いていないものとします。20個のサイコロ全てを転がした時、ちょうど4つのドクロが出る確率はどれぐらいでしょう？サイコロにいかさまがないとすると、サイコロのドクロのある面が上を向く確率が1/6であることがわかります。これを言い換えると、一つのサイコロについてドクロの出る確率は約.167であるということです。これで私たちの問いに答えるには十分な情報ですね。ではどうなるかみてみましょう。

Table6.2 二項分布と正規分布の式。私たちはこの本で他にこの式を使うことは本当はないのですが、より発展的な話に進むためにはちょっと重要なので、ここで文章の邪魔にならない表の形で示しておくのが良いと考えました。二項分布の式の中で、 $X!$ とあるのは階乗関数（つまり、1から X までの全ての数字を掛け合わせたもの）であり、正規分布の‘exp’は指数関数を表します。もしこれらの式があなたにとってあまりわかりやすいものでなかったとしても、そんなに恐れることはありません。

<u>Binomial</u>	<u>Normal</u>
$P(X \theta, N) = \frac{N!}{X!(N-X)!} \theta^X (1-\theta)^{N-X}$	$p(X \mu, \sigma) = \frac{1}{\sqrt{2\pi}\sigma} \exp\left(-\frac{(X-\mu)^2}{2\sigma^2}\right)$

普通、名前とか表記法について少し説明するものですよね。ここでは N を、実験におけるサイコロを振った回数としますが、これは**サイズ・パラメータ**といわれ、二項分布ではよく参照されるものになります。私たちは θ を、一つのサイコロについてドクロの目が出る確率を表すために使います。この量は、二項分布では普通**成功確率**と呼ばれます。^{*2}最後に、 X はその名の通り、私たちのやる実験においてサイコロをふった時に得たドクロの数を意味します。 X の実際の数字は偶然によるものなので、これを**確率変数**といいます。どの場合でも、これら全ての用語と表記を手に入れたのですから、この問題をもう少し正確に記述することができるようになったわけです。私たちが計算したい数

^{*2}“成功”という言葉がちょっと曖昧なことに注意してください。アウトカムが実際は望ましくないものであったとしても、このようにいいます。もし θ が、バスの事故における怪我をした乗員の数を表す確率であったとしても、私はこれを成功確率と言い続けますが、私はバスの乗員が怪我をすることを望んでいるわけではありません！

字は $X = 4$ の確率ですから、 $\theta = .167$ で $N = 20$ ですね。計算したいと思っていることの一般的な“数式”は次のように書くことができます。

$$P(X \mid \theta, N)$$

そしてここでは $X = 4, \theta = .167, N = 20$ という特別なケースに興味があるわけです。

この問題を解決する議論にうつる前に、表記について一つだけ言及しておきたいことがあります。私が X がパラメータ θ と N による二項分布からランダムに生成されるという時、私は次のような表記をします。

$$X \sim \text{Binomial}(\theta, N)$$

はいはい、あなたが何を言いたいかはわかりますよ。表記法、表記法、表記法。誰がそんなものを気にするんだ、ってことですよね。表記法の話のためにここにいる読者はほとんどいないでしょうから、私は二項分布をどうやって使うのかという話に進んだ方がいいのかもしれませんが、ほとんどの人はそんなに注意深く見なかったでしょう。この本に数式は必要ないですし、それ以上詳細について語るつもりもありませんから。その代わり、二項分布がどんなものをあなたにお見せしたいと思います。

つまり、図 6.3 は私たちのサイコロ実験で有り得る全ての X の値についての二項分布の確率をプロットしたものであり、 $X = 0$ (ドクロが出ない) から $X = 20$ (全部ドクロ) までの全てについてプロットしたことになります。これは基本的な棒グラフで、私が図 6.2 に示した“ズボンの確率”と違うところはありません。横軸は起こりうる全ての事象であり、縦軸はそれらの各事象の確率だと読むことができます。ですから、20 回のうち 4 回ドクロが出るのは大体 0.20 (すぐにわかることですが、正確な答えは 0.2022036) です。言い換えると、あなたがこの実験を繰り返すと、そのうち 20% の偶然性でそうなると期待できます。

二項分布がどのように変化するかを感覚を掴んでもらうために m 、 θ と N の値を変えてから、サイコロを転がす代わりにコインフリップをやったらどうなるか想像してみましょう。今度は、私の実験は公平なコインを繰り返しフリップするにせよ、私が興味を持っているアウトカムはコインが表を向いた回数だと考えます。このシナリオだと、成功確率は $\theta = 1/2$ になります。コインを $N = 20$ 回フリップするつもりだとしましょう。この実験では、成功確率を変えましたが、実験の回数は同じなわけです。こうすると私たちの二項分布はどうなるのでしょうか？ そう、図 6.4 が示すように、こうすることの主な効果は分布全体を動かすことになる、と思いますよね。オッケー、じゃあコインを $N = 100$ 回フリップしたらどうなりますか？ そう、この場合は図 6.4b のようになりますね。この分布が示すのは、大まかな中心傾向ですが、確率的な結果におけるちょっとした散らばりもあるのです。




Figure6.3 サイズパラメータが $N = 20$ で成功確率 $\theta = 1/6$ の二項分布。縦のバーそれぞれがそのアウトカムの確率を表しています (すなわち、値 X の確率)。これは確率分布なので、それぞれの確率は 0 から 1 の間に入る数字であり、バーの高さを足し合わせると 1 にならなければなりません。

6.5

正規分布

二項分布は概念的に最も簡単な分布でしたから理解しやすかったと思いますが、それが最も重要な分布だったかと言われるとそうではありません。その名誉ある称号は**正規分布**に贈られます。正規分布は“ベルカーブ”や“ガウス分布”とも言われます。正規分布は二つのパラメータをつかって表されます。すなわち、分布の平均を表す μ と、分布の標準偏差を表す σ です。

私たちがよく使う表記法で、変数 X が正規分布に従うというときは、次のように表します。

$$X \sim \text{Normal}(\mu, \sigma)$$

もちろん、これは単なる表記法に過ぎません。これは正規分布そのものについて、なんら面白いことを教えてくれるものではありません。二項分布の時のように、私はこの本に正規分布の数式を含めてはいます。というのも、統計学を学ぶどんな人にとっても、少なくともそれを目にしておくこ





Figure6.4 私が公平なコインをフリップするシナリオについての二項分布で，想定される確率は $\theta = 1/2$ とします。パネル a では，コインを $N = 20$ 回，パネル b では $N = 100$ 回フリップしたものです。




Figure 6.5 平均 $\mu = 0$ で標準偏差が $\sigma = 1$ の正規分布。x-軸はある変数の値に対応しており、y-軸はその値を我々がどの程度観測しやすいかを教えてください。ですが、y 軸にあるのは“確率密度”であって“確率”ではないことに注意してください。ここには連続的分布ならではの、微妙でちょっと腹立たしい特徴があって、y 軸の振る舞いはちょっと奇妙なのです。すなわち、このカーブの高さは、実際には x の値を観測する確率を表しているわけではないのです。一方で、このカーブの高さは、どの x の値がより生じやすいか (より高いほうがそうなのですが) をあなたに教えてくれるものです。(この面倒な詳細については、Section 6.5.1 をみてください)

とは重要だと考えるからなのですが、これは入門書でもあるのでそこにフォーカスすることはせず、表 6.2 の中に入れておくに止めておきます。

数学的側面に注目する代わりに、正規分布に従う変数が意味することの感覚を掴んでみましょう。そのために、図 6.5 にある、平均 $\mu = 0$ と標準偏差 $\sigma = 1$ の正規分布プロットをみてみましょう。“ベルカーブ”という名前の由来がわかるといいます。そう、ベルみたいに見えますよね。二項分布を描いたときのプロットとは違って、図 6.5 にある正規分布の図では“ヒストグラムのような”バーの代わりにスムーズなカーブが描かれていることに注意してください。これは曖昧な選択を表しているのではなく、二項分布が離散的だったのに対し、正規分布は連続的なのです。例えば、前のセクションでやったサイコロを転がす例では、ドクロが 3 つ、4 つの確率を得ることはできましたが、3.9 個のドクロを考える、というのは不可能です。前のセクションで私が描いた図は、このことを反映していたのです。図 6.3 では、例えば、バーは $X = 3$ や、 $X = 4$ に位置することはありましたが、




Figure6.6 正規分布の平均を変えたら何が起こるかを描いたもの。実線は平均 $\mu = 4$ の正規分布。点線は平均 $\mu = 7$ の正規分布を表しています。どちらも、標準偏差は $\sigma = 1$ です。はたして、二つの分布は同じ形をしており、点線が右側にずれています。

その間には何もありません。連続的な量というのは、この制限に当てはまらないのです。例えば、天気のことについて考えてみましょう。ある快適な春の日の温度は、23 度でも、24 度でも、23.9 度でも、そのほかどんな間の数字でもあり得ます。というのも、気温というのが連続変数だからです。ですから、正規分布で春の気温を記述するのがまあ適当だろう、ということになります^{*3}

これを念頭において、正規分布がどのような動きをするのか直観的につかめるかどうか、見てみましょう。まず、分布のパラメータ周りで遊んでみた時に、何が起こるかをみてみたいと思います。そのために、図 6.6 に標準偏差が同じで平均が異なる正規分布をプロットしました。あなたが想像した通り、全ての分布は同じ“幅”をもっています。違いはそれらが右、あるいは左にシフトすることだけです。そのほかの特性については全て同じです。それに対して、平均を一定にしたまま標準偏差を大きくしていくと、分布の頂点は同じ場所のままですが、分布がどんどん幅広くなることが図 6.7 にみてとれますね。しかし注意して欲しいのは、分布の幅を広くした時に、頂上のの高さが縮小してい

^{*3}実際には、正規分布はとても便利なので、変数が現実的に連続的でない場合であっても、それを使う傾向があります。十分なカテゴリー数があれば (例えば、質問紙におけるリッカートスケールなどです)、正規分布をその近似として適用するというのが標準的な実践例になっています。あなたが思っているよりも、実戦ではそれでうまくいくのです。





Figure6.7 正規分布の標準偏差を変えた時に何が起こるかを描いたもの。どちらの分布も平均が $\mu = 5$ ですが、標準偏差が異なります。実線は標準偏差 $\sigma = 1$ の分布で、点線は標準偏差 $\sigma = 2$ の分布です。結果として、分布は同じスポットに“中心化”していますが、点線が実線にくらべて幅が広がっています。


くことです。これは起こるべくして起こることです。というのも離散的な二項分布のを描いた時に、バーの高さの合計が1になったと同じように、正規分布のカーブの下の領域を合計したのも1にならなければならないのです。次に進む前に、正規分布の重要な特徴をもう一つ、指摘しておきたいと思います。具体的な平均と標準偏差がどんな値であるかにかかわらず、平均周りの1標準偏差の間に全体の68.3%が含まれるということです。同様に、平均周りの2標準偏差の間に全体の95.4%が、平均周りの3標準偏差の間に全体の99.7%が含まれます。このことは図6.8に描かれています。

6.5.1 確率密度

正規分布に関する議論について、私が触れていないことがあります。一部の入門書では、それは完全に省略されています。多分そうした方がいいのです。その“触れていないこと”というのは、統計




(a)




(b)

Figure6.8 カーブの下の面積は観測値が特定の範囲で得られる確率を教えてください。点線の正規分布は、平均 $\mu = 0$ で標準偏差 $\sigma = 1$ です。影のついた領域は、二つの重要なケースにおける“カーブの下の面積”です。パネル a では、平均周りの 1 標準偏差の中に観測値が得られる確率が 68.3% であることを見てとることができます。パネル b では、平均周り 2 標準偏差の中に観測値が得られる 確率が 95.4% であることを見てとることができます。



(a)



(b)

Figure6.9 “カーブの下の領域”についてのさらに二つの例です。平均より 1 標準偏差下より小さい観測値が得られる確率は 15.9% で (パネル a), 平均と平均より 1 標準偏差下の区間に観測値が得られる確率は 34.1% です (パネル b)。この二つの数字を足し合わせると、 $15.9\% + 34.1\% = 50\%$ になることがわかりますね。正規分布するデータでは、平均より下の観測値が得られる確率は、50% になります。そしてもちろん、このことは平均以上の観測値が得られる確率が 50% になることも意味します。

学において応用される確かに歪んだ基準に照らしてみても、奇妙で直感に反するように思えるからです。幸いにも、基本的な統計学を実行する上では、そこまで深いレベルの理解は必要になるようなことではありません。というより、基本的な領域を越えようとしたときになって初めて、そのことが重要になってくるのです。ですから、もし意味が分からなくてもそれほど恐れることはないですが、その要点を遵守することだけは心がけてください。

正規分布についての議論を通じて、一つか二つ、ちょっと意味が分からないことがありますね。おそらく気付いたと思うのですが、図の y 軸には“確率密度”というラベルがあります。密度、ではなく。また、私が正規分布の式を書いたときに、 $P(X)$ の代わりに $p(x)$ を使っていることに気づいた人もいるかもしれません。

後々わかるのですが、ここで示されているのは実際には確率ではなく、それ以外の何かなのです。その何かを理解するためには、 X が連続変数であるということが本当は何を意味しているのかについて、少し考える時間を取る必要があります。外の気温について話をしてみましょう。温度計はそれが 23 度であることを教えてくれますが、私は本当はそうではない、と知っています。ぴったり 23 度ではないのです。23.1 度なのかもしれません。もちろんそれが本当かどうかはわかりません。というのも実際には 23.09 度かもしれないのですから。しかし私が思うに... というわけです。わかりますね。本当に連続的な量に伴うトリッキーな考え方は、あなたは正確にそれがどれくらいであるかを決して知ることができない、ということです。

では、これが確率について考えるときに何をもちたすか、を考えてみましょう。明日の最大気温が平均 23、標準偏差 1 の正規分布からサンプルとして得られるとしましょう。気温が正確に 23 度になる確率はどれくらいでしょう？ その答えは“ゼロ”，あるいは“ほとんどゼロになるゼロに近い数字”になるでしょう。何故そうなるのかですって？ それは無限に小さいダーツの的に、ダーツの矢を投げようとしているようなものだからです。あなたがどれほど優れた腕前の持ち主でも、決して当たることはないでしょう。実生活においては、あなたが決して 23 度ちょうどの値を得ることがないのです。それはいつだって、23.1 度とか、22.99998 度とか、そんな感じになっているはずです。言い換えると、気温がちょうど 23 度になる確率について語るということは、全く無意味だということです。日常用語で、私はあなたに外の気温は 23 度だと言ったりします。でもそのあとで実は 22.9998 度だったということが分かっても、あなたは私を嘘つき呼ばわりしたりしないでしょう。日常用語での“23 度”というのは普通、“22.5 度から 23.5 度の間のどこか” ぐらいの意味しかないのです。ですから、ちょうど 23 度である確率について尋ねることがそれほど意味のあることではないとしても、気温が 22.5 度から 23.5 度の間、あるいは 20 度と 30 度の間、もしくはそれ以外の範囲について、確率を問うことは意味があるのです。

この議論のポイントは、私たちが連続変数について議論しているとき、特定の値についての確率について言及するのは意味がない、ということを明らかにしておくことです。私たちが話すことができることは、ある値についての確率は常に特定の範囲を持った値についてなのです。あなたが必要とする特定の範囲についての確率を見つけるためには、“カーブの下領域”を計算しなければなりません。

ん。このことは既にみてきた通りで、図 6.8 の影がついた領域が表しているのは本当の確率です (例えば図 6.8a は平均周りの 1 標準偏差の観測値が得られる確率を表しています)。

オーケー、これでストーリーの一部が説明されます。私は連続的な確率分布をどのように理解すれば良いかについて (例えば、カーブの下領域というのが鍵です)、少しばかり説明してきました。しかし $p(x)$ についての数式で実際に表していたのは何でしょう? $p(x)$ が確率を表していないことは明らかですが、ではそれは何でしょう? $p(x)$ で表される量の名前は、**確率密度**で、先ほどの図で書いてあったカーブの高さに対応するものです。密度そのものは、それだけでは意味がありませんが、カーブの下領域が本当の確率として常に理解できるように“工夫された仕掛け”なのです。正直にいうと、今あなたが知っておくべきことがそれです*4。

6.6

そのほかの便利な分布

正規分布は統計学で最もよく使われる分布ですが (その理由については少し触れましたが)、二項分布もいろいろな目的のために使える便利なものです。しかし統計学の世界は確率分布で埋め尽くされていて、中にはふと通りがかりに出会うものがあります。特にこの本では 3 つの分布が出てきます。 t 分布、 χ^2 分布、そして F 分布です。それぞれの数式を提示しようとは思いませんし、そこまで詳細に語るつもりもないのですが、ちょっとした図をお見せしましょう。

*4ちょっとした計算を知っている人のために、もう少し正確な説明をしておきます。確率は非負で総和が 1 になるのと同じで、確率密度も非負で積分すると 1 にならなければなりません (積分は全てのとりうる値 X に対して行われます)。 X が a と b の間に落ちる確率を計算するためには、該当する範囲の密度関数に対する積分、 $\int_a^b p(x) dx$ を定義します。この計算を覚えていない、あるいは習ったことがないと言うのでも心配なくて結構です。この本ではそれは必要ないからです。




Figure6.10 自由度3の t 分布 (実線)。正規分布に似ているようですが、全く同じというわけではありません。比較のために、標準正規分布を点線でプロットしました。

- **t 分布**は連続分布で正規分布によく似ています。図 6.10 を参照してください。 t 分布の“尻尾”は正規分布よりも“重い”(つまり、より外れた値まで広がっている)ことに注意してください。両者の間には重要な違いがあります。この分布は、データが実際は正規分布に従っていても、その平均と標準偏差がわからないという時に現れるものです。この分布については、第 10 章でまた触れることになります。
- **χ^2 分布**は様々な場面で出てくるもう一つの分布です。私たちがこの分布に出会う状況は、カテゴリカルなデータ分析 (第 9 章参照) ですが、実際に至るところで見ることができるものの一つです。数学的な意味を掘り下げていきますが (嫌いな人なんていませんよね?)、なぜ χ^2 分布が至る所で見られるのかについての主たる理由は、正規分布する変数がたくさんあれば、その変数を二乗して足し合わせる (この手続きは“平方和 (sum of squares)”といいます) と、その合計が χ^2 分布に従うからです。このことが便利であると気づくことが多いことに驚くでしょう。ともかく、ここでは χ^2 分布がどんな形なのかを見ておくことにしておきましょう。: 図 6.11.
- **F 分布**は χ^2 分布に少し似ていて、二つの χ^2 分布を比較する必要があるときに出ってきます。確かに、正気の人間で誰がそんなことをしたがるのかと思えますが、実際のデータ分析においてはとても重要であることがわかります。 χ^2 の話をした時に、“平方和”を使う際の大事な分布だと言ったことを覚えていますか? そうです、もしあなたが二つの異なる“平方和”を比較したいと思ったら、おそらく F 分布について話をしなければならなくなるでしょう。もちろん私は平方和について、まだ何の例も挙げていませんが、第 12 章で触れることになります。




Figure6.11 自由度3の χ^2 分布。観測値は0より大きくなければなりませんし、この分布は少し歪んでいることに注意が必要です。そこにカイ二乗分布の特徴があります。




Figure6.12 自由度3と5の F 分布。定性的にいうなら、カイ二乗分布に少し似ているように見えますが、一般的には全く似ていません。

その時 F 分布について説明していくことになるでしょう。そうそう、図 6.12 も見ておいてくださいね。

さて、このセクションを切り上げる時間がきたようです。ここでは三つの新しい分布を見ました。すなわち χ^2 分布、 t 分布、そして F 分布です。これらは全て連続分布で、何も正規分布に密接に関係しています。ここでの主な目的は、これらの分布が全て互いに、また正規分布と深いレベルで関係していることを理解することです。この本の後の方で、正規分布しているデータ、あるいは少なくとも正規分布していると仮定できるデータを扱っていきます。ここで知っておいて欲しいことはそれだけです。もしあなたのデータが正規分布していると仮定するなら、データ分析を始める時にあちこちで χ^2 分布や t 分布、 F 分布が顔を出してきても、驚くことはありません。

6.7

要約

この章では確率について考えてきました。確率が何を意味するのか、なぜ統計学者はそれが意味することに同意できないのかについて論じました。確率が従わなければならないルールについても話しました。そして確率分布の概念を導入し、統計学者がよく使うより重要な確率分布をいくつか導入するのに、この章のかなりの部分を費やしました。セクションごとに分解すると、次のようになっています。

- 確率理論と統計 (セクション 6.1)
- 頻度主義者とベイズ主義者それぞれの確率の見方 (セクション 6.2)
- 確率理論の基礎 (セクション 6.3)
- 二項分布 (セクション 6.4)、正規分布 (セクション 6.5)、その他の分布 (セクション 6.6)

あなたの想像通り、私の取材した範囲は網羅的ではありません。確率理論は数学の中でも大きな分野であり、統計学やデータ分析への応用からは全体的に別れたものになっています。ですから、このテーマで書かれた本は何千とあるし、大学では一般に確率論を専門に扱う複数のクラスを提供しています。標準的な確率分布についての解説作業という“単純な”ことでさえも、大きなトピックになってしまうのです。この章で私は5つの確率分布を紹介しましたが、私の本棚には45章からなる“統計的分布”(Evans, Hastings, and Peacock 2011) という本があって、そこにはもっとたくさんの確率分布が含まれています。あなたにとっては幸運なことかもしれませんが、必要なのはこのごく一部です。表に出て実世界でデータ分析をするときに、このたくさんの確率分布を知っておく必要はありませんし、この本にあるような分布を必要とすることもないと思いますが、他にも多くの確率分布があることを知っておいて損はありません。

この最後の点から考えると、この章全体がちょっとした余談みたいになりますね。学部生用の心理学のクラスで統計をやる場合はほとんど、この内容については素早く通り過ぎるものですが(私がそうしていることも自覚しています)、より専門的なクラスではこの領域の基本的な基礎をおさらいすることを“忘れて”しまわれることがよくあります。大学心理学者のほとんどは確率と確率密度の違いを知りませんし、ベイズアンと頻度主義者の確率の間の違いに気付いた人も最近までほとんどいませんでした。しかし、私はこれらを応用の前に知っておくことが重要だと考えています。例えば、私たちが推測的推論をするときに“許される”言い方についてのルールがたくさんあり、それらの多くは恣意的で奇妙なものに見えます。ところが、ベイズアンと頻度主義者の違いがあることを理解すれば、すぐにそれらが意味をなすのです。同様に、10章では t 検定について説明しますが、もしあなたが t 検定の数理を理解したいと思うのなら、 t 分布がどういう見え方をするものなのかを知っていると役立つことでしょう。そういう気付きを得てくれるよう、願っています。

7. サンプルから未知の量を推定する

前のチャプターを始める時に、記述統計と推測統計の決定的な違いを強調しました。第4章で議論したように、記述統計の役割は私たちがまさに知りたいものを簡潔に要約することにあると言えます。それに比べて、推測統計学の目的は“私たちがやったことから私たちが知らないことを学ぶ”ことにあります。私たちは確率の基礎を知っていますから、統計的推測の問題についてもうまく考えることができるでしょう。どういうことを学べばいいでしょう？ どうやって学べばいいでしょう？ 推測統計の本質にある問いは、伝統的に2つの“大きなアイデア”に分割されてきました。推定と仮説検定です。この章のゴールは、この2つの大きな課題の前者、推定理論についてですが、まずはサンプリング理論について説明します。というのも、推定理論はサンプリングを理解しなければ意味を成さないからです。結果的にこの章は2つのパート、セクション7.1からセクション7.3を通じてサンプリング理論にフォーカスし、セクション7.4と7.5ではサンプリング理論を使って推定を統計的にどう考えるのかを議論します。

7.1

標本、母集団、そして標本抽出

パートIIIの前触れとして、帰納法の謎と、すべての学びには仮定が必要だという事実を強調しました。これが正しいとして、最初にすべきことは、データが意味をなすような一般的な仮定を考えることでしょう。そこで**標本理論**の登場です。確立理論はすべての統計理論を成り立たせる基礎だとすると、標本理論は家を建てる場合の枠組みとでもいえるでしょう。標本理論は、統計的な推論をするときに採用する仮定をたてるときに、かなり大きな役割を果たします。そして統計学者が考えるような“推測をする”ことについて話すとき、私たちが何から推論をするのか(標本)、そして何に対して推論をするのか(母集団)を明確にする必要があります。

ほとんどすべての状況で、私たちが研究者として手にすることができるのはデータについてのある**標本**です。ある特定の参加者に対して実験をしたのかもしれないし、調査会社が投票意図について

何人かに質問紙調査をしたのかもしれませんが。このやり方では、データセットは有限で不完全なものにしかありません。世界中の全員に対して実験したりできませんし、例えば調査会社だってその国の全有権者に電話する時間もお金もないでしょう。記述統計のところで以前議論したときに(第4章)、この標本だけが我々の関心事でした。標本を記述して、要約して、グラフを描くことだけが目的だったのです。それを変えていくことになります。

7.1.1 母集団を定義する

標本というのは具体的な対象です。データファイルを開いてみれば、そこにはあなたの標本から得たデータがあるはずですが、**母集団**は、それに対して、もっと抽象的な概念です。ば集団は、あなたが結論を引き出したいと思っている、あるいは標本よりかなりひろく一般化したいと思っている、すべての可能な人、すべての可能な観測の集合を指します。理想的な世界では、研究者はどの母集団に関心があるかを明確にしなければなりません。なぜなら、研究をデザインし、データの仮説検証をすることは、あなたが何か主張したいであろう母集団に依存するからです。

対象となる母集団を明確にするのが難しいこともあります。例えば、この章のはじめにあった“調査会社”の例では、母集団は研究を開始するときの全ての有権者であり、何百万もの人になります。標本は母集団に属する1000人ということになります。ほとんどの研究では、状況はそこまでストレートではないのです。典型的な心理学の実験においては、研究対象の母集団はもう少し複雑です。私が参加者100人の学部生を使って実験をしたとしましょう。私の目標は、認知的な科学ですから、心がどのようにして働くのかについて知ることです。であれば、次のどれが“母集団”としてカウントされるでしょうか。

- Adelaide大学の心理学コースの学部生全員?
- 世界中のどこかでもいい、あらゆる心理学の学生?
- オーストラリアに今住んでいる人?
- 私の標本と近い年齢のオーストラリア人?
- 今生きてる人なら誰でも?
- 現在、過去、未来にわたって、とにかく人であればよい?
- 地球環境にいる十分な知的操作ができる生命体であればなんでも良い?
- 知的生命体であればなんでも良い?

これらはそれぞれ心的過程を持つ実際のグループを定義するもので、いずれも認知科学者である私にとって興味のある対象であり、私の興味関心に対してどれが正しい母集団なのかははっきりさせることはできません。別の例として、前置きのところで話したウェルズリー・コッカーゲームを考えてみましょう。このときの例は、ウェルズリーが12勝0敗という特殊な流れがありました。母集団はどれでしょう?




Figure7.1 母集団からの非復元単純ランダムサンプリング

- ウェルズリーとコッカーが、シーズン中に到達する全ての結果
- もしウェルズリーとコッカーが残りの人生の間ずっとゲームをしていたら得られるであろう全ての結果
- もしウェルズリーとコッカーが永遠に生きて世界の終わりまでずっとゲームをし続けていたら得られるであろう全ての結果
- 無数の並行世界において、ウェルズリーとコッカーのペアが同じ 12 回のゲームをそれぞれの宇宙でやっていたとしたら得られるであろう、全ての結果

もう一度言いますが、何が母集団なのかというのは、はっきりしないんです。

7.1.2 単純無作為標本

母集団をどのように定義するかに関係なく、重要なポイントは、サンプルは母集団の部分集合であり、目的はサンプルについての知識を使って母集団の特徴に関する推論を引き出すことです。両者の関係はどんな標本が選択するかという手続きに依存します。この手続きは[サンプリング法](#)に関係しており、なぜそれが問題になるかを理解することが重要です。

話を簡単にするために、10 個のチップが入った袋を想定してみましょう。各チップには重複しない文字が印字されているので、10 個のチップはそれぞれ区別することができます。またこのチップは、黒と白の 2 色に分けられます。このチップのセットが我々の興味がある母集団であり、図 7.1 の左側にそれが描画されています。この図を見て貰えば分かるように、4 枚の黒いチップと 6 枚の白いチップに分かれているのですが、現実世界と同じように、袋の中を見ないとこれを知ることはいけません。ここで次のような“実験”をしてみると考えてみましょう： 袋を振って、目を閉じて、4 枚のチップを復路に戻すことなくとりだすのです。最初に取り出したのが a チップ (黒) で、次が c チッ




Figure7.2 有限母集団から復元なしの偏ったサンプリングをする

プ (白), 続いて j (白), 最後に b (黒) だったとします。もし望むなら, これらのチップを全て袋に戻し, 実験を繰り返すことができます。それを表したのが図 7.1 の右側です。毎回結果は違うことになりませんが, いずれも手続きは同じです。同じ手続きでも異なる結果になるということを, 我々は確率過程といいます^{*1}。しかし, チップを取り出す前にバッグを振るので, 全てのチップが選択される確率は同じぐらいだと考えることができます。母集団に含まれるどのメンバーも等確率で選出される手順のことを, **単純無作為抽出**といいます。取り出したチップを元の袋にもどさないというのは, 同じことを 2 回観察することはないということですし, このような場合のことを非復元抽出をしたといいます。

この抽出手順の重要性に気づいて守るために, 別の方法でこの実験をしたらどうなるか考えてみましょう。わたしの 5 歳になる息子が袋を開けて, 4 つの黒いチップを取り出そうとしたとします。非復元で, です。この偏ったサンプリング方法を図 7.2 に表してみました。ここで, 4 つが黒で白いチップが 0 である時の証拠となる価値を考えてみましょう。これは明らかにサンプリング方法に依存すると思いませんか? サンプリング方法が黒いチップだけを選ぶように偏っていて, その結果, 標本が黒いチップだけだったというのでは, 母集団についての情報が何も得られません! これが理由で, 統計家はデータセットが単純無作為抽出であることを好みますし, そうであるからこそデータ分析がぐっと簡単なものになるのです。

第三の方法は注目に値します。今回, 私たちは目を閉じて, 袋を振って, チップを取り出します。しかし今回は, 取り出したものを記録してから, そのチップを袋に戻すのです。そしてまた目を閉じて, 袋を振って, チップを取り出します。この手順を 4 回繰り返します。このやり方でできたデータ

^{*1}ランダムであることについてのより適切な数学的定義は, 本当に技巧的でこの本の範囲を超えてしまいます。ここではそこまで技巧的にならず, プロセスをくりかえていて毎回違う答えが出る場合はいつでも, 確率的な要素を持ったプロセスであるということにします。




Figure7.3 有限母集団から復元ありの単純無作為抽出

セットは、これもまた単純無作為抽出ですが、取り出した後すぐ袋にチップを戻していますので、**復元**サンプリングといわれます。このやり方と最初の方法との違いは、同じ母集団メンバーを複数回観測することがあるかどうかで、図 7.3 に表してみました。

私の経験上、ほとんどの心理学実験は非復元サンプリングをしているようです。というのも、同じ人が実験に 2 回参加することが許されていないからです。しかしほとんどの統計理論は、復元ありの単純無作為標本からデータができていることを仮定しています。現実的にこの違いはほとんど問題になりません。興味のある母集団が大きければ (10 個以上の中身があれば!)、復元あり、なしの違いは気にする必要がないくらい小さいものです。これに対して、単純無作為サンプリングと、偏ったサンプリングの間の違いは決して見過ごせるものではありません。

7.1.3 ほとんどのサンプルは単純無作為標本ではない

先ほど示した考えられる母集団リストをざっとみればわかるように、興味のある母集団から単純無作為標本を得るのはほとんど不可能です。私が実験する時に、もし参加者がアデレード大学の心理学コースの学生から無作為抽出されたものであるということが明らかになったとしたら、ちょっとした奇跡だともうでしょう。一般化したい対象に比べて、圧倒的に狭い母集団でしかなくてもです。他のサンプリング方法に関する議論を深く議論するのは本書の範囲を超えますが、より重要なものをいくつか示しておきますので、知っておいてください。

- 層別サンプリングあなたの考える母集団が、いくつかの下位集団、すなわち層になっている (あるいはそう考えられる) としてみましょう。たとえば、いくつかの異なるサイトを通じて研究を走らせている場合などです。母集団全体からランダムに標本を取ってくる代わりに、別々の無作為標本をそれぞれの層から集めてくることになります。層別サンプリングは単純無作為抽出よりも簡単なことがあります。特に母集団が既にいくつかの層に分割されているときはそうです。いくつかの下位集団が減多にない場合は特に、単純無作為抽出よりも効率的

です。例えば統合失調症を研究する時、母集団を二つの層 (統合失調症患者と、そうでない患者)^{*2}に分けて、それ俺の群から同数のサンプルを取れば良いでしょう。人を無作為に選べば、統合失調症の人がほとんど標本に含まれず、あなたの研究の役に立たないものになるでしょう。この特殊なやり方である層別サンプリングは、オーバーサンプリングとも呼ばれます。というのも、めずらしい群を過剰に代表させようとしているからです。

- スノーボールサンプリングは“隠れた”，あるいはアクセスしにくい母集団からサンプリングする時に特に有用な技術で，特に社会科学で一般的な方法です。例えば，研究者がトランスジェンダーの人たちから意見を聞きたいと思ったとします。研究チームはトランスジェンダーの人たちの連絡を数人しか知らず，研究はその参加者をお願いするところから始まります (第一段階)。調査が終わる頃，参加者は他に調査に協力してくれそうな人に連絡を取ってくれないか，と頼まれます。第二段階では，この新しい連絡先が調査対象になります。このプロセスが，十分なデータが得られるまで続くのです。スノーボールサンプリングの大きな利点は，他の方法では得ることが不可能な状況でもデータが得られることです。統計的な意味では，この方法の主な問題点として標本がかなりランダムから外れていることであり，無作為でないやり方をどう扱っていいかは難しい問題になります。一方現実的な意味では，うまくやらないとこの方法は非倫理的になるということです。というのも，隠れている人々は理由があって隠れているのですから。この問題に注目するために，私はトランスジェンダーの人を選びました。注意しないと，暴露されたくない人を暴露してしまうことになるかもしれず (それはとても，とても悪いことです)，ミスをしたわけでもないとしても人の社会的ネットワークを使って人を研究するということは，侵入的ではあるのです。コンタクトを取る前にインフォームド・コンセントを得るのはとても難しいですし，その人たちにコンタクトを取って，“やあ，君の研究をしたいんだけど”という単純な行為さえ傷つけてしまうことが少なくありません。社会的ネットワークは複雑なものですから，データが手に入るからといって，常に使える手法というわけではありません。
- コンビニエンス・サンプリングはその言葉の響き以上のものでも以下のものでもありません。このサンプルを選ぶ方法は，研究者にとっては便利なものですが，興味のある母集団から無作為に選ぶものではありません。スノーボールサンプリングはコンビニエンス・サンプリングの一種ですが，他にもいろいろなものがあるのです。心理学におけるよくある例ですが，研究が心理学コースの学部生に頼っているところがあります。このサンプルは一般に，2つの意味でランダムではありません。まず，心理学コースの学生に頼っているということは，‘あなたのデータがある単一のサブグループに制限されているということです。次に，学生は普通どんな研究に参加するか選んでいるので，そのサンプルは心理学学生自身に選択されたサブセットになっており，ランダムに選択されたサブセットではないことになります。実際には，ほとん

^{*2}現実的には単純ではありません。“統合失調症”と“統合失調症ではない”のような二分割できる明確な基準はありません。しかしこれは臨床心理学のテキストではありませんので，私があちこちでやってる単純化には目をつむってください。

どの研究は何らかの形でのコンビニエンス・サンプルです。これは時に厳しい制約になりますが、いつもそうだというわけではありません。

7.1.4 もし単純無作為抽出ができなかったら、どれほどの問題が？

オウケイ、実際のデータ収集ではステキな単純無作為抽出ができないかもしれない、ということでした。そのどこに問題が？ ちょっと考えれば、データが単純無作為抽出でないときにどんな問題になりえるかがわかると思います。図 7.1 と 7.2 の違いを考えてみてください。しかし、思ったほど悪くはありません。偏ったサンプルの中には、それほど問題にならないタイプのものもあるのです。例えば、層別サンプリングを使う時はどんなバイアスがあるのかははっきりわかっているわけです。研究効率をあげるために自分でそのバイアスをうんだわけですから。そしてそういう時は、統計的な手法であなたが作り出したバイアスを補正することができます (この本では扱わない技術ですけど!) ですからこういう時は、それほど問題になりません。

もっと一般的に言えば、無作為抽出は目的に対する手段であって、目的そのものではないことを忘れないようにすることが重要です。コンビニエンス・サンプリングのような、偏りがあることがわかっている場合を考えてみましょう。そのサンプリング手法に含まれる偏りは、そこから間違った結論を引き出したときに限って問題になるのです。その観点から言えば、あらゆる側面において標本が無作為でなければならないとはいえ、関心対象である心理学的に関係のある現象について無作為が必要なのだと私は思うのです。私がワーキングメモリの容量について研究しているとしましょう。研究 1 では、今生きている人間から無作為抽出することもできますが、唯一の例外として月曜日生まれの人だけしか集められません。研究 2 では、オーストラリアの人からしか無作為抽出できないとします。私は研究結果を今生きているあらゆる人間に一般化したいと思っています。どちらの研究がマシでしょうか？ 答えは、明らかに研究 1 ですよね。どうしてかって？ それは“月曜日生まれ”ということがワーキングメモリの容量に興味深い関係があるとはとても思えないからです。それに比べて、“オーストラリア人である”ということが問題になるかもしれない、ということについてはいくつか思い当たるふしがあります。オーストラリアは豊かな工業国家であり、十分に教育システムが発達しています。そういう教育システムの中で成長した人の人生経験は、ワーキングメモリの容量のテストを設計した人と似たような経験をたくさんしているでしょう。この共有された経験というのがどうやって“テストを受ける”のかについて、似たような信念を形成しやすくするかもしれませんし、心理学的な実験がどういうものかについて共有された仮定があるかもしれません。こうしたことが、実際に影響するかもしれないのです。例えば“テストを受ける”というスタイルはオーストラリア人の実験参加者に、同じような環境で育っていない人に比べて、かなり抽象的なテストの要素に限定的な注意を向けるやり方を教えたかもしれません。このことがワーキングメモリの容量が何であるか、ということを考えるにあたって、誤解させるように導いてしまうかもしれないのです。

この議論には2つのポイントがあります。第一に、あなたが研究をデザインするとき大事なのは、何が母集団なのかに注意を払わなければいけないこと、そしてその母集団に適したやり方でサンプルをとることに注力すべきということです。実際には、みなさんは普通“便利なサンプル”をとりたくなるでしょう(例えば、心理学教員が、データを集めるのが最もコストが低く、財源が金で溢れかえっているわけではないという理由で心理学の学生からサンプリングするなど)が、もしそうするのなら、少なくともこの槍かたがどんな危険を孕んでいるのかについて、しっかり考えてみるべきでしょう。第二に、あなたが誰かの研究について、人類全体からの無作為標本ではなくコンビニエンス・サンプリングをしているからという理由で批判するとしたら、少なくともそのことがどれほど結果を歪めたのかについてのしっかりした理論を提示する礼儀があるだろう、ということです。

7.1.5 母集団パラメータと標本統計

オーケー。無作為標本の方法論的な問題は少し横に置いて、違う問題に目を向けてみましょう。ここまで私たちは科学者のいうところの母集団について考えてきました。心理学者にとって、母集団とはひとの集団ということになるでしょう。環境学者にしてみれば、母集団がクマの集団になるかもしれない。ほとんどの場合において、科学者が考える母集団というのは現実世界に存在する具体的な何かです。しかし、統計学者は少し変わったひとたちなのです。一方では、彼らは科学者と同じように現実的な科学と現実世界のデータに興味があるのです。他方で、彼らは数学者が考えるような純粋に抽象的な領域を操作しようとも思っています。その結果、統計的な理論は母集団をどのように定義するかについて、少し抽象的なものになる傾向があります。心理学の研究者が、我々の抽象的で理論的な概念でもって具体的な測定ができるようにする(セクション 2.1)のと同じやり方で、統計学者はそれがどう働かがわかっている数学的対象の用語で“母集団”の概念を操作可能にするのです。これについては、第6章で既に触れているのです。それは確率分布と呼ばれるものです。

アイデアは本当に単純です。IQ スコアについて考えてみましょう。心理学者にとって、興味ある母集団とは IQ スコアを持っている実際の人による集団です。統計学者は母集団を図 7.4a に描かれているような確率分布として操作的に定義することで、これを“単純化”します。IQ テストは平均 IQ が 100 で、標準偏差が 15 の、正規分布に従うようにデザインされています。この値は母集団全体の特徴であり、**母集団パラメータ**として参照することができます。すなわち、我々は母平均 μ が 100 で、母標準偏差 σ が 15 ということができます。

ここで、私が実験しようとしているとしましょう。私は 100 人をランダムに選びだして、IQ テストを実施することで母集団からの単純無作為標本を得ます。私のサンプルが次のような数字から構成されているとしましょう：

106 101 98 80 74 ... 107 72 100

これらの IQ スコアそれぞれは、平均 100 で標準偏差 15 の正規分布から得られた標本です。ですから私が得たこの標本のヒストグラムを描けば、図 7.4b のようになるでしょう。ご覧になれば分かる




Figure 7.4 IQ スコアの母集団分布 (パネル a) と、そこからランダムに抽出された二つの標本。
 パネル b には 100 の、パネル c には 10,000 人のサンプルが観測されています。

.....

ように、このヒストグラムは図 7.4a にある本当の母集団をみくらべると、だいたい正しい形をしています。非常に荒い近似でしかないことがわかります。標本の平均を計算すると、母集団の平均である 100 にかなり近い数字を得るでしょうが、ピッタリ同じとはいきません。今回の場合、私の標本の IQ スコアの平均は 98.5 で、IQ スコアの標準偏差は 15.9 でした。この**標本統計量**は、私のデータセットの特徴であり、真の母集団の値にかなり近くはありますが、同じものではありません。一般に、標本統計量は自分のデータセットから計算できるもので、母集団パラメータはあなたが知りたいと思っているもの、です。この章の後半で、母集団パラメータを標本統計量から推測する方法について話します (セクション 7.4) し、その推定にどの程度確信を持てるかを表す方法について議論します (セクション 7.5) が、その前に知るべきサンプリング理論についてのいくつかの概念があります。

7.2

大数の法則

前セクションでは、架空の IQ 実験例で、サンプルサイズ $N = 100$ ということでした。真の母集団平均が 100 で、標本平均が 98.5 ですから、まあまあ妥当な近似として勇気づけられる結果でしたね。多くの科学研究において、この正確さのレベルは完璧に受け入れられるものですが、状況が違えばもっと正確さが欲しいと思うかも知れません。もしもっと母集団パラメータに近い標本統計量が欲しいと思えば、何をすれば良いのでしょうか？

その答えは明らかに、もっとデータを集めるということになるでしょう。もっと大掛かりな実験をして、今度は 10,000 人から IQ のスコアを得たとします。この実験の結果は JASP を使ってシミュ

レーションできます。IQsim.jasp ファイルが JASP のデータファイルです。このファイルには、`mean = 100` と `sd = 15` の正規分布する母集団から、10,000 点の無作為標本を得たものが入っています。ところで、これは JASP の新しい変数を作る機能から、R コード `rnorm(10000, 100, 15)` でもって作ったものです。この大サンプルのヒストグラムと密度プロットは、小サンプルのものよりも真の母集団分布によりよい近似を見せています。標本統計量にもこれが反映されています。大サンプルの IQ の平均は `100.107` で標準偏差は `14.995` です。この値は今や、真の母集団の値にかなり近くなっています。図 7.5 をみてください。

こんなことを言うときちょっと馬鹿馬鹿しく感じるんですが、ここで皆さんに汲み取ってもらいたいのは、より大きなサンプルがあればより良い情報をもたらしてくれますよ、ということです。馬鹿馬鹿しく感じるというのは、わざわざ言う必要がないほど明らかなことだからですね。事実、Jacob Bernoulli という確率理論の始祖の一人がこのアイデアを 1713 年に定式化したとき、彼もこれにちょっと変な感じを覚えたわけです。この直感を共有していることを、彼は次のように表現しています。

最も愚かな男であっても、本質的な直感によって、あるいは自分自身で、何の指示がなくても (これは驚くべきことだが)、観測が増えれば増えるほど目的の不明確さがより少なくなっていくことについては、確信を持っている。(see [Stigler 1986](#), p65)

たしかに、この表現は少しばかり人を見下したような感じですが (性差別的であることは言うまでもないですが)、彼の主たるポイントは正しいのです。より多くのデータがあれば、より良い答えができる、というのは全く明らかなことです。問題は、なぜそうなのか、ということです。驚かないでほしいのですが、私たちが共有しているこの直感が正しいことがわかり、統計家はこれを**大数の法則**と呼んでいます。大数の法則は数学的な法則で、多くの異なる標本統計量に適用されますが、最も単純に考えるならば、平均 average に関する法則だということになります。標本平均は平均にかんする統計量の例として最もわかりやすいもので (だって平均 mean というのは... 平均 average のことですから)、これでみてみましょう。大数の法則が入っていることを標本平均に応用する時は、標本がより多く手に入れば、標本平均が真の母平均に近づいていくということを言ってることになります。あるいは、もう少し正確に言うならば、標本サイズが無限大に“近づく” ($N \rightarrow \infty$ と書きます)、とき、標本平均が母平均に近づく ($\bar{X} \rightarrow \mu$)、ということです。^{*3}

大数の法則が正しいことを証明しろとは言いませんが、統計理論の中で最も重要なツールの一つであることは間違いありません。大数の法則は、より多くのデータが私たちを真実に導いてくれる、という信念を正当化するのに使えます。それぞれのデータセットについて計算している標本統計量

^{*3}技術的には、大数の法則は独立した量の平均として記述される標本統計に関するものです。標本平均はまさにこれにあたります。しかし他の多くの標本統計量も、ある種の平均として記述することができます。例えば標本分散はある種の平均であり、それは大数の法則に近づく。しかし、標本の最小値は、平均の形で描くことができないので、大数の法則に支配されないものです。

は間違っていますが、大数の法則は、より多くのデータを集めれば、それらの標本統計量は真の母集団パラメータにどんどん近づいていくことを教えてくれます。

7.3

標本分布と中心極限定理

大数の法則はとても強力なツールですが、私たちの全ての問いに答えてくれるのに十分というわけではありません。特に、それが与えてくれるのは“長期保証”でしかないのです。長期というのは、我々が何とかしてデータの収集を無限に続けられれば、大数の法則は標本統計量が正しくなることを保証してくれる、ということです。しかしジョン・メイヤード・ケインズが経済学の文脈で言った有名な言葉にあるように、長期保証は実際の人生においてあまり役立つものではありません。

長期保証は現在の問題を考える上でミスリーディングを招く。長期的に見れば、我々ばみな死んでしまうのだから。経済学者はこれをあまりにも簡単に、あまりにも役に立たないタスクを設置した。荒天の季節に彼らが言えるのは、いずれ嵐は去るし、海も穏やかさを取り戻すということだけだ。(Keynes 1923, p. 80)

経済学の例にあるように、心理学や統計学にも同じことが言えます。標本平均を計算する時に、最終的に正しい答えに到達することを知っていると言うだけでは、十分ではありません。十分に大きなデータセットを持っていると母平均の正確な値になることを知っていても、実際のデータセットのサンプルサイズが $N = 100$ でしかないときには、悲しい慰めにしかなりません。現実では、より控えめなデータセットから計算された標本平均の振る舞いについて、知っておかなければなりません!

7.3.1 平均の標本分布

このことを心に留めおいて、私たちの研究がいずれ標本サイズ 10,000 に到達するだろうという考えを捨て、もっと控えめな実際の実験について考えることにしましょう。今回は、 $N = 5$ のサンプルをとって、IQ スコアを測定したとしましょう。前と同じように、JASP でこの実験をシミュレートします。`rnorm` 関数を変更して、`IQsim` というデータ列を作りました。`IQsim` ラベルの横にある f_x をダブルクリックすると、JASP は「計算列」ダイアログを表示し、そこには R コードで `rnorm(10000, 100, 15)` と書いてあるでしょう。今回は被験者 5 人分だけでいいので、10000 を 5 に変えて「列を計算する」とするだけです (図 7.6 をみてください。)。JASP が私のために 5 つの数字を生成してくれました (あなたの値はきっと違うものになっているでしょう)。便宜上、数字は整数に丸めてあります。

124 74 87 86 109

Table7.1 IQ 実験の再現, 毎回標本サイズは $N = 5$ です。

	1 人目	2 人目	3 人目	4 人目	5 人目	標本平均
再現 1 回目	124	74	87	86	109	96.0
再現 2 回目	91	125	104	106	109	107.0
再現 3 回目	111	122	91	98	86	101.6
再現 4 回目	98	96	119	99	107	103.8
再現 5 回目	105	113	103	103	98	104.4
再現 6 回目	81	89	93	85	114	92.4
再現 7 回目	100	93	108	98	133	106.4
再現 8 回目	107	100	105	117	85	102.8
再現 9 回目	86	119	108	73	116	100.4
再現 10 回目	95	126	112	120	76	105.8

今回のサンプルにおける IQ の平均は 96 ちょうどになります。驚くことはないですが、これは先ほどの実験よりも正確さの面で劣ります。次にこの実験を**再現する**ことにしたと思ってください。つまり、私がこの手続きをできるだけ同じように繰り返し、新しく 5 人のサンプルを取って IQ を測定したとします。もう一度 JASP を使って、この手続きによる結果をシミュレートし、5 つの数字を生成しましょう。

91 125 104 106 109

今回、IQ の平均は 107 になりました。もしこの実験を 10 回繰り返したら、表 7.1 にあるような結果を得て、標本平均が毎回の再現実験ごとに変化することがわかります。

このやり方をずっと続けましょう。この“5 つの IQ スコア”の再現実験を、何度も何度もするのです。この実験を繰り返すたびに、標本平均を記録していきます。時間が経つにつれて、新しいデータセットを蓄積していきます。毎回の実験が 1 つのデータポイントを生むのです。私のデータセット例では、最初の 10 回の標本平均が表 7.1 にありますが、次のようにデータが始まっています。

96.0 107.0 101.6 103.8 104.4 ...

これを 10,000 回繰り返して、ヒストグラムを書いたらどうでしょう。まさにそれをしたのが、図 7.7 にあります。この図を見るとわかるように、5 つの IQ スコアの平均は、普通 90 から 110 の間に入るようです。しかしより重要なこととして強調すべき点は、私たちがこの再現実験を何度も何度も繰り返すと、最終的には標本平均の分布を得られるということです！この分布は統計学において特別な

名前を持っていて、**平均の標本分布**といいます。

標本分布は統計学におけるもう 1 つの重要な理論的アイデアあり、小さいサンプルの振る舞いを理解するのに欠かせないものです。例えば、私が最初に行った“5 つの IQ スコア”実験では、標本平均は 96 でした。図 7.7 にある標本分布が教えてくれることは、この“5 つの IQ スコア”実験はそれほど正確ではないということです。実験を繰り返したとき、標本分布が教えてくれるのは標本平均が 80 から 120 の間のどこかにあるのかなあ、と想像できます。

7.3.2 どんな標本統計量にも標本分布は存在する!

標本分布を考える時に覚えておいてほしいことは、あなたが注目しようとしているあらゆる標本統計量について標本分布があるということです。たとえば、またしても“5 つの IQ スコア”実験を繰り返して、IQ スコアの最大値を書き出したとしましょう。これをするデータセットは次のようになります:

124 125 122 119 113 ...

これを繰り返すと、かなり変わった標本分布が得られます。言うならば**最大値の標本分布**です。5 つの IQ スコアの最大値の標本分布は、図 7.8 に示しました。おどろくなかれ、5 人をランダムに取り出して、IQ 最大値の人を見つけ出したら、その人は IQ の平均より大きくなるでしょう。ほぼ毎回、IQ が 100 から 140 の範囲で測定されたひとと一緒にになってしまうでしょう。

7.3.3 中心極限定理

ここまでくると、標本分布が何なのかについてのちょっとした感覚を掴んでもらったと思います。特に、平均の標本平均 $\bar{g}$ どんなものかについて。このセクションでは、平均の標本分布がサンプルサイズによってどのように変わるかについて説明していきましょう。直感的には、あなたは既に答えの一部を知っているはずです。観測度数が少ない時は、標本平均はそれほど正確ではありません。小サンプルの実験を繰り返し、平均を何度も計算すると、結構異なる答えを得ることになります。言い換えると、標本分布は非常に幅広いのです。大サンプルの実験を繰り返し、平均を何度も計算すると、同じような答えを得るでしょうし、標本分布は非常に狭くなるでしょう。このことは図 7.9 で見ることができます。より大きなサンプルサイズをもてば、より幅の狭い標本分布を得ることが f できるのですね。この効果を評価するためには標本分布の標準偏差を計算すればよく、この数字は**標準誤差**と呼ばれています。統計量の標準偏差は、SE と表記されることが多いです。また標本平均の標準誤差に興味があることが多いですから、SEM と書くことがあります。図を見たらわかるように、サンプルサイズ N が増加すると SEM は減少していくのです。

さて、それは話の一部にすぎません。これまで見逃してきたことが、ここにはあります。ここまで提示してきた例は全て、“IQ スコア” 実験に基づくものでした。というのも IQ スコアは、母集団分布が正規分布であると化したので、ほぼ正規分布に従うだろうと考えられるからです。もし正規分布じゃなかったら？ 平均の標本分布に何が起こるのでしょうか？ これについて躍るべきことに、母集団分布がどんな形であっても、 N が増えれば平均の標本分布はどんどん正規分布に近づいていくのです。これを理解してもらうために、シミュレーションしてみましょう。そのために、図 7.10 のヒストグラムで示したような“傾いた”分布から始めましょう。黒い線で示されたベルカーブと三角形のヒストグラムを比較すればわかるように、母集団分布は正規分布とは全く似ていないものになっています。次に、たくさんの実験結果をシミュレートします。各実験では、 $N = 2$ のサンプルを取ってきて、その標本平均を計算します。図 7.10b のプロットは、これらの標本平均ヒストグラムです（つまり $N = 2$ の平均の標本分布です）。今回、ヒストグラムは $\wedge$ 型の分布をしています。これはまだ正規分布の形ではありませんが、図 7.10a にある母集団分布よりは近づいています。サンプルサイズを $N = 4$ に増やしてみると、平均の標本分布はかなり正規分布に近くなり（図 7.10c）、サンプルサイズが $N = 8$ に至るとほとんど完璧に正規分布の形になります。言い方を変えると、サンプルサイズが小さすぎなければ、平均の標本分布は正規分布に近づいていくのです。あなたの考える母集団分布がどんな形であっても！

これらの図に基づいて、平均の標本分布について以下のような主張に対する根拠を手に入れたと言えるかもしれません。

- 標本分布の平均は母集団の平均と同じ。
- 標本分布の標準偏差（つまり標準誤差）はサンプルサイズが増えると小さくなる。
- 標本分布の形状はサンプルサイズが増えると正規分布になる。

実は、これらの主張は正しいだけでなく、統計学においてこれら 3 つ全てを証明した有名な定理があり、それが**中心極限定理**なのです。特に、中心極限定理は、もし母集団分布が平均 μ で標準偏差 σ であれば、平均の標本分布も平均 μ で、平均の標準誤差は

$$SEM = \frac{\sigma}{\sqrt{N}}$$

となることを示しています。母標準偏差 σ がサンプルサイズ N の平方根で割られているので、SEM はサンプルサイズが大きくなるとどんどん小さくなります。これはまた、標本分布の形状が正規分布になることも教えてくれます*4

*4いつものように、私はここで少し手抜きをしています。中心極限定理は、このセクションで述べていることよりももう少し一般的な含みを持っています。統計学のもっと入門的なテキストのように、私は中心極限定理が成立するある状況について議論してきました。すなわち、同じ分布からそれぞれ独立して生じた事象について平均を取っている、ということです。しかし、中心極限定理はこれよりも広い範囲をカバーしています。例えば、“U-統計”と呼ばれるものがありますが、そこに含まれるのは全て中心極限定理を満たしますから、大きなサンプルサイズであれば正規分布になります。平均はそうした統計量の一つですが、唯一のものではないのです。

この結果はあらゆることについて便利なものです。これはなぜ大きな実験が小さな実験よりも信頼できるのかを教えてください、標準誤差の明示的な公式を与えてくれますから、より大きな実験がどのくらい信頼できるのかについて教えてください。また、なぜ正規分布が正規なのかも教えてください。実際の実験では、私たちが測定したいと思っていることの多くが異なる量の平均を取ります（例えば、IQ で測定されるような“一般的な”知能は、多くの“特別な”技術や能力の平均であるでしょう）、そうした時に平均化された量が正規分布に従うことになります。この数学的な法則によって、正規分布は実際のデータにおいて何度も何度も出てくることになるのです。

7.4

母数の推定

前のセクションでお見せした全ての IQ の例においては、母集団におけるパラメータを事前に知っていたのでした。知能の測定を最初に学ぶ学部学生はみな、IQ スコアが平均 100 で標準偏差 15 に定義されていることを学びます。しかし、それはちょっと嘘です。IQ スコアの真の母集団平均が 100 であることをどうやって知り得るのですか？ そう、私たちがこれを知っているのは、テストを設計した人たちがとても多くのサンプルを取って、その標本平均が 100 になるようにスコアリングルールを“仕組んだ”からです。もちろんこれは悪いことではなくて、心理学的測定を設計する上で重要なことでもあります。しかし、この理論的な平均が 100 であるというのが、このテスト設計者がテストを作る時に使った母集団に合うようにしたものである、ということを心に留めておくことはじゅうようです。良いテスト設計者は、多くの異なる母集団（年齢層や国籍が異なる集団など）に適用できるように“テストの基準”を提供しようとしています。

これは便利なことではありますが、もちろんほぼ全ての研究プロジェクトにおいて、テストを基準化するのに使ったのとは異なる母集団を調査することになります。たとえば、鉛製錬所がある南オーストラリアの工業都市ポートピリーで、低レベルの鉛中毒が認知機能に及ぼす影響を測定しようとしたとしましょう。あなたはポートピリー在住の人の IQ スコアを、製鉄所のある南オーストラリア

の工業都市ワイアラのサンプルと比較するでしょう*5どちらの町について考えるにしても、単に真の IQ 母集団平均が 100 であると想定するのは意味がありません。私の知る限り、南オーストラリアの工業地帯に’自動的に適用できる、正規化されたデータを作っている人はいません。私たちはデータのサンプルから母集団を推定する必要があるのです。どうやればいいでしょう？

7.4.1 母平均を推定する

ポートピリーにいて、100 人の地元民に IQ テストを受けてもらったと考えてください。この人たちの IQ スコアの平均は、 $\bar{X} = 98.5$ であることがわかったとします。ポートピリーの住民全体の、真の平均 IQ はどうなるでしょう？明らかに、この質問に対する答えは知りようがないのです。97.2 かもしれないし、103.5 かもしれないわけです。私たちのサンプリングは網羅的なものではないのですから、明確な答えを与えることができません。とはいえ、“一番ましな推測”をすることに狙いを定めたら、それは 98.5 ではないかと私なら言うでしょう。これが統計的推測のエッセンスです。つまり、一番ましな推測をする、ということ。

今回の例で未知の母数を推定するのは、直接的なやり方でした。標本平均を計算して、これで**母平均の推定**としたわけです。とてもシンプルで、次のセクションではこの直感的な答えの統計学的な正当化を与えようと思います。しかし、私がここでやろうとしていることは、標本統計とお数の推定値は概念的に異なるものだということを、あなたにしっかり理解してもらうことなのです。推定値が母集団についての推測であるのに対して、標本統計はあなたのデータを記述するものです。心にとどめておいてほしいのは、統計学者はこれらに言及する時違う書き方をするということ。たとえば、真の母平均が μ と書き表されるとすると、母平均の推定値を $\hat{\mu}$ とします。これに対して、標本平均は $\bar{X}$ や m と書いたりします。しかし、単純無作為抽出したとき、母平均の推定値は標本平均と同じです。標本平均が $\bar{X} = 98.5$ のとき、母平均の推定値もまた、 $\hat{\mu} = 98.5$ なのです。この表現をはっきりさせておくために、かんたんな表を用意しました。

*5もしあなたが実際にこの問題を扱おうとするなら、私がここでやろうとしていることよりもっと注意深くやらなければならないことに注意してください。ワイアラとポートピリーの IQ スコアだけを比較して、その違いがすべて鉛中毒のせいだというわけにはいかないのです。もし 2 つの都市の違いが製油所の違いだけにあったとしても（長期的はそうでなかったとしても）、人々が既に汚染が認知的な障害につながると信じているという事実を説明する必要があります。第 2 章を思い出してください、つまりポートピリーサンプルとワイアラのサンプルでは需要の影響が異なることを意味しています。言い換えるなら、人が実際に違いがあると考えていることが、あなたのデータに幻の差を作り出したのかもしれないのです。もし研究者の団がポートピリーに白衣で現れて IQ テストを始めたとなると、地元の人たちがあなた方がやろうとしていることについて全く何も気づかないとは思えませんし、多くの人があなたがやろうとしていることに腹を立てることさえあり得るでしょう。そういう人たちはテストに協力的ではないでしょう。ポートピリー以外の人はずっとさうまくやろうと思うでしょう。自分達の街が悪くみられるのは嫌でしょうから。この動機の違いがワイアラではより弱いでしょう。人は“鉛中毒”の概念と同じ意味での“鉄鉍石中毒”の概念がないからです。心理学というのは難しいのです。

記号	これは何?	コレが何だかわかってる?
$\bar{X}$	標本兵器	もちろん、データから計算できますから
μ	母平均	おそらく決して知り得ないでしょう
$\hat{\mu}$	母平均の推定値	イエス、単純無作為標本の標本平均と一致します

7.4.2 母標準偏差を推定する

ここまで、推定はとてもシンプルで、あなたはなぜ私がこんなに面倒なサンプリング理論について話を読ませようとしているのか不思議に思っているかもしれません。母平均を推定したもの (すなわち $\hat{\mu}$) は、標本統計量 (すなわち $\bar{X}$) と同じことがわかっています。残念ながら、これが常に真だとはならないのです。これを見るために、**母標準偏差の推定**、つまり σ をどうするか考えてみましょう。今回は推定のために何を使いましょうか? まず思いつくのは、平均を推定した時と同じようにやあることで、標本標準偏差を推定値に使うことですよね。これはほとんどあっているのですが、厳密には違います。

なぜでしょうか。観測度数が 1 しかないサンプルを集めてきたと思ってください。この例では、母集団の真の値について全く直感が働かない時の標本を考えるのがよく、全くのフィクションの例を使うことにしましょう。私のシューズのクロミュランスを測定することにしたとします。私のシューズのクロミュランスが 20 であることがわかりました。これが私の標本です。

20

サンプルサイズが $N = 1$ でしかありませんが、これはまったく正当なものです。標本平均は 20 で、というのもこの標本のどれもが標本平均と同じだからです (当たり前ですが!)。そして標本標準偏差は 0 です。標本の記述として、これは全く正しいことです。というのも標本が一度数しかなく、標本の散らばりが無いからです。標本標準偏差が $s = 0$ となるのは、ここでは正しい答えです。しかし母集団の標準偏差を推定するとき、これでは意味がありませんね? たしかに、あなたも私も “クロミュランス” が何なのか全くわかりませんが、データについては知っているのです。標本について全く分散を読み取ることができない唯一の理由、それはいかなる分散も見ることができないほど小さなサンプルだからです! ですから、サンプルサイズ $N = 1$ のときの正しい答えは、“さっぱりわからない” というのが正しいように思えます。

注意してほしいのは、標本平均と母平均の時に、同じような洞察をすることは無いということです。母平均の最適な推定をしなければならない時、母平均が 20 であると推測することは、全く無意味なものではありません。もちろん、あなたはおそらくこの推定に十分な確信を持ってないでしょう。というのも、たった 1 つの観測しかしてないからですが、しかしベストな推定をしてことに変わりはないのです。

この例を少し拡張してみましょう。2 回目の観察をしたと思ってください。今やシューズのクロミュランスデータセットは $N = 2$ になり、サンプルが次のようになったとします。

20, 22

今回、私たちのサンプルは少しばかり大きくなり、ある程度の分散を認められるようにはなりました。すなわち、なんらかの分散を観測するのに最低限必要な数が、観測度数 2 ということです！この新しいデータセットによって、標本平均は $\bar{X} = 21$ であり、標本標準偏差は $s = 1$ になりました。母集団についてどういうことがわかるでしょう？繰り返しますが、母集団の平均については標本平均がベストな推定値なのです。標準偏差についてはどうでしょう？これはもう少し複雑です。標本標準偏差は、たった 2 つの観測に基づいて行われますが、もしあなたが私と同じような人であれば、たった 2 件の観測度数だけでは母集団の真の変動を明らかにするには、“十分な変動”とは言えないと直感的にわかるでしょう。推定が間違っているというだけでなく、たった 2 つの観測から推測するのはある程度間違っていることが予想されますね。このエラーについての不安はシステマチックなものです。特に、標本標準偏差が母標準偏差よりも小さくなるのでは、と予想できます。

この直感は正しいのですが、もう少しよいデモンストレーションをすることができます。この直感を数学的に証明できるというのも事実ですが、これは正しい数学的知識がなければあまり役に立ちません。そのかわりに、ある実験の結果をシミュレートしてみましょう。それを踏まえて、IQ 研究の話に戻しましょう。真の母平均が 100 で母標準偏差が 15 だとします。まず、 $N = 20$ の IQ スコアで実験を計画し、標本標準偏差を計算したとします。これを何度も繰り返し、標本標準偏差のヒストグラムをプロットすると、標準偏差の標本分布を得ることができます。これを図 7.11 にプロットしました。真の母標準偏差は 15 ですが、標本の標準偏差の平均は 8.5 にしかありません。図 7.9b にあるのは、これとは少し違って平均の標本分布をプロットしているのですが、そこには母平均が 100、標本平均の平均も 100 であることが示されています。

このシミュレーションを拡張してみましょう。 $N = 2$ に限定せず、サンプルサイズを 1 から 10 まで変えて実験を繰り返したとします。標本平均の平均と、標本標準偏差の平均をサンプルサイズの関数としてプロットした結果が、図 7.12 に示してあります。左の図 (パネル a) には標本平均の平均を、右の図 (パネル b) には標準偏差の平均をプロットしています。二つの図は平均でみると全く違うようで、標本平均の平均は母平均に等しくなります。これは**不偏推定量**で、だからこそ標本平均が母平均の最も良い推定値になりうる理由なのです*6 右の図は母平均からずれており、標本標準偏差 s は母標準偏差 σ よりちいさくなっています。

これが**偏った推定量**なのです。言い換えると、母標準偏差 σ についての“最も良い推定”である $\hat{\sigma}$

*6 ここで少し隠し事をしていることを打ち明けておきましょう。不偏性は推定量についての望ましい特徴ですが、偏り以外にも重要なことがあります。しかし、あらゆる細部にまでわたって議論するのは、この本の範疇を超えてしまいます。ですから、ここには複雑な背景が隠されていることを示唆するにとどめます。

をしたいという時は、標本標準偏差 s より少し大きめに推定するべきなのです。

この系統的なバイアスを修正するのは、実にシンプルなやり方でできます。ここにどうするか少しめしました。表分偏差を追いかける前に、分散を見てみましょう。セクション 4.2 を思い出してほしいのですが、標本標準偏差は標本平均からの偏差を二乗したものの平均として定義されたのでした。このように。

$$s^2 = \frac{1}{N} \sum_{i=1}^N (X_i - \bar{X})^2$$

標本分散 s^2 は母分散 σ^2 にバイアスのかかった推定量です。しかし、結局のところ、ちょっとした変換を行うだけで不偏推定量に変えることができます。やるべきことは、 N ではなく $N-1$ で割るようにするだけです。そうすると、次のような式になりますね。

$$\hat{\sigma}^2 = \frac{1}{N-1} \sum_{i=1}^N (X_i - \bar{X})^2$$

これが母分散 σ の不偏推定量です。さらに、これがセクション 4.2 で持ち上がった問いに対する最終的な答えになります。なぜ JASP はちょっと違う分散の答えを返すのか？ それは JASP が $\hat{\sigma}^2$ を計算していたから、というわけです。同じような話は、標準偏差にも関わります。母標準偏差の推定値にするには、 N ではなく $N-1$ で割ったものを使うのです。

$$\hat{\sigma} = \sqrt{\frac{1}{N-1} \sum_{i=1}^N (X_i - \bar{X})^2}$$

そして JASP の標準偏差に組み込まれている関数は、 s ではなく $\hat{\sigma}$ の計算をしているわけです。^a

^a オークイ、私はここでもあることを隠しています。奇妙で直感に反することですが、 $\hat{\sigma}^2$ は σ^2 の不偏推定量ですから、その平方根をとった $\hat{\sigma}$ は σ の不偏推定量だと思うでしょう。本当かな？ 実はそうではないのです。それだと $\hat{\sigma}$ に実際少しのバイアスが存在するのです。これはまさにおかしなことですよ。すなわち、 $\hat{\sigma}^2$ は母分散 σ^2 の不偏推定量なのですが、その平方根を取った $\hat{\sigma}$ は母標準偏差 σ の推定量としてバイアスがあるなんて。おかしいなあ、おかしいぞ、本当かな？ ではなぜ $\hat{\sigma}$ はバイアスがあるんでしょう？ これについての技術的な答えは、“(平方根のような) 非線形変換は、期待値と一致しないから” ですが、数理統計のコースを取ってない人にとってはよくわからないでしょうね。幸いにして、実践的な目的のためにはこれは大きな問題にならないのです。そのバイアスはとても小さくて、実際には $\hat{\sigma}$ を使っても問題ありません。ときどき数学というのは煩わしいだけのものですね。

最後にひとつ。実際には、多くの人が $\hat{\sigma}$ (つまり $N-1$ で割ったもの) を標本標準偏差といいがちです。技術的には、これは正しくありません。標本標準偏差は s (つまり N で割ったもの) に一致するべきです。概念的にも、計算上も、同じことではありません。一方は標本の特徴の一つであり、他方は母集団の特徴を推定したものです。しかし、実際に応用する時に我々が本当に気にしているのは、母集団のパラメータですから、人は報告する時に $\hat{\sigma}$ を s よりも使ってしまうのです。もちろん正しい数字を報告していることにはなります。ただちょっと、“標本標準偏差” が “母標準偏差の推定値” よりも短くて言いやすいので、文章化する時にちょっと正確でない用語を使ってしまいがちな

のですね。大問題ではないですし、実践上同じようなことを私もしてしまうことがあります。とはいえ、この2つの概念を区分しておくことは重要だと思うのです。“標本からわかること”と“それがやってきた母集団について推測したこと”を混乱させて使うことは良いことではないですね。あなたが s と $\hat{\sigma}$ について考えるのは同じことだと思った瞬間、まさにその間違いを犯し始めていると思ってください。

さてこのセクションを閉じるにあたって、これらの点をはっきりさせた一組の表を示しておきましょう。

記号	これは何?	これはわかるもの?
s	標本標準偏差	イエス、ローデータから計算できます。
σ	母標準偏差	たぶん永遠にわからないでしょう
$\hat{\sigma}$	母標準偏差の推定値	イエス、でも標本標準偏差と同じものではありません

記号	これは何?	これはわかるもの?
s^2	標本分散	イエス、ローデータから計算できます
σ^2	母分散	たぶん永遠にわからないでしょう
$\hat{\sigma}^2$	母分散の推定値	イエス、でも標本分散と同じものではありません

7.5

信頼区間を推定する

統計が意味するのは、あなたが確信していると言う必要がないこと
人知らず。^{*7}

– 読み

この章のポイントは、データの標本に基づいて母集団のパラメータを推測するのに必要な、統計学がよって立つサンプリング理論の基礎を大まかに説明することです。この議論からわかるのは、サンプリング理論が必要とする理由の1つが、あらゆるデータセットがある種の不確実さを残しており、我々の推定が完全に正確なものになることは決してないからです。この議論のなかで忘れられてきたことの1つが、我々の推定に伴う不確実さの量を評価する試みです。心理学の学生のIQは115です、と推測するだけでは不十分なのです（ええ、この数字は私が作りました）。この推測がもってい

^{*7}この詩はあちこちのTシャツやウェブサイト、いくつかの学術論文でさえ言及しているのを見かけるのですが（たとえば、<http://www.amstat.org/publications/jse/v10n3/friedman.html>），私は原典を見つけることができませんでした。

る不確かさの程度を表現する、なんらかの言い方が必要ですよね。たとえば、本当の平均は 109 から 121 の間に 95% の確率であります、というような言い方ができたらいいかもしれないですね。これが平均の**信頼区間**というやつです。

標本分布を理解するときに、平均の信頼区間を構成するのはごく簡単なことです。その仕組みはこうです。真の母平均 μ と、母標準偏差が σ だとしましょう。 N 人の参加者を募った研究が終わったところで、この参加者から計算した IQ の平均が $\bar{X}$ だとします。中心極限定理 (セクション 7.3.3) により、平均の標本分布は正規分布に近似することがわかっていますね。また、セクション 6.5 の議論を思い出すと、正規分布の 95% 確率は、真の平均のまわり 2 標準偏差の中にあることもわかっています。

もう少し正確に言いますと、正規分布の 95% の確率は真の平均まわり 1.96 標準偏差のなかにあるのです。次に、標本分布の標準偏差は標準誤差、とくに平均の標準誤差は SEM というのです。これらを併せて考えると、標本平均 $\bar{X}$ は、母平均の 1.96 標準誤差の中で観測される確率が 95% だということになります。

数学的には、このように表記します。

$$\mu - (1.96 \times \text{SEM}) \leq \bar{X} \leq \mu + (1.96 \times \text{SEM})$$

ここで SEM は $\sigma/\sqrt{N}$ に一致し、これが真であると 95% の確信をもって言えるのです。しかし私たちが本当に興味を持っている問いに対する答えにはなっていませんね。上の式は母集団パラメータがわかっている時に、標本平均に何が期待できるかを教えてくれるにすぎません。私たちが知りたいのは、これの逆の働きです。私たちが知りたいのは、特定の標本を観測することができた時に、母集団パラメータについて何が言えるかなのです。しかし、これはそれほど難しいことはありません。高校数学をちょっと使って、この式を次のように書き換えてみましょう。

$$\bar{X} - (1.96 \times \text{SEM}) \leq \mu \leq \bar{X} + (1.96 \times \text{SEM})$$

これが教えてくれることは、母平均 μ を 95% の確率で含む値の範囲です。この範囲のことを **95% 信頼区間**と呼び、 CI_{95} と表記します。要するに、 N が十分大きければ (平均の標本分布が正規分布であると信じるのに十分であれば)、この式を書いて 95% 確信区間とすることができるのです。

$$\text{CI}_{95} = \bar{X} \pm \left(1.96 \times \frac{\sigma}{\sqrt{N}} \right)$$

もちろん、1.96 という数字に特別な意味はありません。これはあなたが 95% 信頼区間を使おうと思った時にかけるための数字、というだけです。もし 70% 信頼区間が欲しければ、マジックナンバー 1.96 ではなく 1.04 をつかうでしょう。

7.5.1 式中のちょっとした間違い

いつものように、私は嘘をつきました。95% 信頼区間を算出する上の式は近似的に正しいのですが、議論の中で重要な詳細を見落としていたのです。平均の標準誤差、SEM に使った式をよく見ると、あなたは真の母標準偏差 σ を知っていなければなりません。そう、セクション 7.4 にあったように、私たちは真の母集団パラメータについて知り得ないという事実に悩まされるのです。真の値 σ を知らないのですから、その代わりに母標準偏差の推定値 $\hat{\sigma}$ を使うしかありません。これは真つ当なやり方に見えますが、そうすることでマジックナンバーを計算する時に正規分布ではなく t 分布のパー線タイルを使う必要があるのです。そしてその答えは、サンプルサイズに依存します。 N がとても大きいときは、 t 分布でも正規分布でも同じ値になります。そう、1.96 ですね。しかし N が小さいときは、 t 分布を使うともっと大きな数字、2.26 になります。

何が起こったのか、それはそんなにミステリアスなことではありません。大きな値になるということとは信頼区間が広がるということで、これは真の μ の値がどうなっているかについて我々はより不確実なことしかわからないのだ、ということです。正規分布の代わりに t 分布を使うときは、より大きな数字になるので、より不確実だということです。なぜ他の不確実さを持ってこないといけいないのでしょうか？ ふむう、母標準偏差の推定値 $\hat{\sigma}$ が何かおかしいに違いありません！ もしそれが間違っていれば、平均の標本分布が実際にどんな形になっているかについて、少しばかり確信が減ることになり、この不確実さがより広い信頼区間に反映されることになると言えるでしょう。

7.5.2 信頼区間の解釈

信頼区間について難しいのは、それが意味するものは何かを理解することです。人が初めて信頼区間に触れたとき、最初の直感は決まって、“信頼区間の内側に真の平均が 95% の確率で存在する”と思わせてくるのです。これはシンプルで、“95% の確実さ”という言葉が意味する常識的な意味を表していると思われます。残念ながら、これは少し正確ではないのです。この直感的定義は、母平均の値に関するあなたの個人的な信念に深く関わっていますね。私は 95% の確信があると言いましたが、それは私の信念だからです。日々の生活ではこれで問題ないのですが、もしセクション 6.2 に戻って考えれば、個人的な信念についての表現はベイズの発想であることに気づくでしょう。しかし信頼区間はベイズのツールではないのです。この章の他のところでもそうなのですが、信頼区間は頻度主義者のツールで、頻度主義者の手法を使うのであれば、ベイズ的解釈を与えるのは適切ではありませんね。頻度主義者のツールを使うのであれば、頻度主義者に適した解釈にしましょう！

オーケー、答えが正しくないというのであれば、正解はなんでしょう？ ここで頻度主義的確率とはなんだったかを思い出してみましょう。“統計的な表現”が唯一許されるのは、連続的な事象についてで、頻度主義者は異なる事象の頻度を数え上げるのでした。この見方からすると、95% の信頼区間の解釈は、なんらかの反復についてのものでなければなりません。今回の場合はもし私がこの実験を何度も何度も繰り返して、毎回 95% 確信区間の計算を続けるなら、その区間の 95% は真の平

均を含んでいる、ということになります。もっと一般的に言えば、全信頼区間の 95% は真の母平均を含むこの手続によって構成されたものです。この考え方を図 7.13 に示しました。ここでは “10 人の IQ スコア” 実験についての 50 の信頼区間 (上の図) と, “25 人の IQ スコア” 実験についての 50 の信頼区間 (下の図) を示しています。ちょっとした幸運がみられて、私がシミュレートした 100 回の反復実験を通じて、ちょうど 95 回が真の平均を含んでいました。

ここでの根本的な違いは、米事案は確立の言葉を母平均に対していうのですが (つまり、母平均についての我々の不確実さについての言及)、そうした言い方は頻度主義的な確率の解釈のもとでは許されないのです。なぜなら母集団を “繰返し” たりしないのですから! 頻度主義的に言えば、母平均は固定されたもので確率的な表現はあり得ないのです。しかし信頼区間は反復可能です。実験を繰り返すことができるのですから。ですから頻度主義者は (確率変数が) 真の平均を含む信頼区間について確率的に話すことができますが、その話は (反復イベントではない) 真の母平均が、信頼区間のなかに入る確率についてのことなのです。

これは少し術学的に見えることはわかりますが、重要なことです。問題になるのは、解釈が数学的な違いにつながるからです。信頼区間に代わるベイズ的なやりかたは、確信区間として知られています。ほとんどの場合、確信区間は信頼区間と同じようになりますが、時々まったく違うものになることがあります。約束しますが、ベイズ的なものの見方は第 15 章で論じます。

7.5.3 JASP における信頼区間の計算

JASP の今のバージョンでは、平均の信頼区間を計算するのに ‘記述統計’ の機能の一部として (まだ) 簡単にできるように実装されていません。ですが、‘記述統計’ に S.E. のチェックボックスがありますね。つまり、これを使って 95% 信頼区間の下限を次のように計算できます。Mean - (1.96 * S.E. Mean) そして 95% の上限は Mean + (1.96 * S.E. Mean) です。

95% 信頼区間は心理学における事実上の標準です。例えば、IQsim.jasp ファイルを読み込んで、‘記述統計’ から平均と S.E. を選択し、シミュレートされた平均 IQ の信頼区間を計算すると、次のようになります。

$$\text{Lower 95\% CI} = 100.107 - (1.96 * 0.150) = 99.813$$

$$\text{Upper 95\% CI} = 100.107 + (1.96 * 0.150) = 100.401$$

今回のシミュレートされた標本データは N=10,000 で、IQ の平均スコアは 100.107、95% 信頼区間は 99.813 から 100.401 になります。幸い、この解釈はとても簡単にできますね。‘記述統計’ オプションの一部として信頼区間を計算するような、簡単な方法がまだ JASP にはありませんが、ほんのちょっとした計算で求めることができます。

どのように、JASP で信頼区間をプロットするのも、(まだ)JASP の ‘記述統計’ オプションは対応していません。ですが、第 12 章で、ある統計的な検定について学んでいく中で、データ分析の一部として信頼区間をプロットすることができるようになっていきます。これは本当にかっこいいこと

で、これについては後ほど説明するとしましょう。

7.6

要約

この章で私は主に2つのトピックスについて話しました。この章の半分はサンプリング理論についてのもので、残りの半分は母集団パラメータの推定にサンプリング理論をどう使うかということについてでした。このセクションでは、次のようにまとめておきましょう。

- 標本, サンプリング, 母集団についての基本的な考え方 (Section 7.1)
- サンプリングの統計理論: 大数の法則 (セクション 7.2), サンプリング分布と中心極限定理 (セクション 7.3)。
- 平均と標準偏差を推定する (セクション 7.4)
- 信頼区間を推定する (セクション 7.5)

いつものように、この章でカバーできていない、サンプリングと推定についてのトピックスもたくさんありますが、心理学コースの導入としてはちょうどいい分量だと思っています。ほとんどの実践的研究者にとって、これ以上の理論が必要になることはありません。この章で触れていないある大きな問題としては、無作為標本のサンプルが手に入らなかった時のことです。この状況を乗り越えるための統計理論はいろいろあるのですが、この本の範疇を大きく超えてしまいます。




Figure7.5 JASP を使って正規分布から無作為抽出した例




Figure7.6 JASP を使って、 $\mu = 100$ で $\sigma = 15$ の正規分布から 5 つのランダムなサンプルを取り出す。




Figure7.7 “5 つの IQ スコア実験” の平均による標本分布。あなたが 5 人を無作為に取り出し、その IQ の平均を計算すると、数字はだいたい 80 から 120 の間に入るでしょう。ごく稀に、IQ が 120 より大きいとか 80 より低い人もいるかもしれませんが。比較のために、IQ スコアの母集団分布を黒い線で表現しました。




Figure7.8 “5つのIQ実験”における最大値の標本分布です。5人を無作為に選び出した標本で、IQスコアが最も高い人を選び出すとIQが100から140の間にいるひとがほとんどでしょう。




Figure7.9 平均の標本分布がいかにサンプルサイズに依存しているかを描いたもの。各パネルには、IQ データから 10,000 サンプル作り出した例と、各データセットにおける平均 IQ を計算したもの。これらのプロットのヒストグラムが示すのは、この平均の分布です (すなわち、平均の標本分布です)。一人ひとりの IQ スコアは平均が 100、標準偏差が 15 の正規分布から取り出したもので、それは黒い点線で描画しています。パネル a では、データセットには一人分のデータしかなく、各標本の平均はその人の IQ スコアです。結果として、平均の標本分布は垂 IQ スコアの母集団分布と同じになります。しかしこのサンプルサイズを 2 にあげると、どのサンプル平均も一人の IQ スコアよりも母平均に近づくので、ヒストグラム (標本分布です) は母集団分布よりも少し狭くなります。今度はサンプルサイズを 10 にしてみましょう (パネル c)。すると標本平均は母平均周りでかなり狭く分布する傾向がみてとれます。




Figure7.10 中心極限定理のデモンストレーション。パネル a では、正規分布でない母集団分布を示しています。パネル b から d はパネル a に示した分布から、それぞれ標本サイズ 2,4,8 のサンプルを取った平均の標本分布を示しています。ご覧のとおり、元の母集団分布が正規分布でなくても、平均の標本分布は正規分布に近づきます。サンプルの度数が 4 のときでも。




Figure7.11 “2つのIQスコア”についての標本標準偏差の標本分布。真の母標準偏差は15(点線)ですが、ヒストグラムから見て取れるように、実験のほとんどがそれより小さい標準偏差を示しています。平均的には、この実験では標本標準偏差は8.5にしかありません。これは真の値を下回っています! 言い換えれば、標本標準偏差は母標準偏差の推定値に基づいているのです。




Figure7.12 標本平均は母平均の不偏推定量であるのに対し (パネル a), 標本標準偏差は母標準偏差から偏りのある推定量になっている (パネル b) ことを描いた図。この図を書くために、観測度数 1 のデータセットを 10,000 点シミュレーションで作リ、観測度数 2 についても 10,000 点、同様にサンプルサイズ 10 まで順に増やしていったものです。それぞれのデータセットは偽の IQ データからできており、真の母平均が 100、標準偏差が 15 であるようにしています。平均については、サンプルサイズに関わらず標本平均は 100 になります (パネル a)。しかし、標本標準偏差は、サンプルサイズが小さい時は顕著ですが、一貫して小さめになります (パネル b)。




Figure7.13 95% 信頼区間。上の図 (パネル a) では、10 人の IQ を測定した実験を 50 回反復した例を示しています。点線は標本平均で、線は 95% 信頼区間です。50 回中 47 回の信頼区間が真の平均 (すなわち 100) を含んでいましたが、3 回はそうでなかったことをアスタリスクマークで示しています。下の図 (パネル b) では同じようなシミュレーションで、ここでは 25 人の IQ を測定した実験を反復したシミュレーションを示しています。

8. 仮説検定

推論のプロセスは、我々の経験と調和するもっとも単純な法則を見つけ出すプロセスです。しかし、このプロセスに論理的な基盤はなく、心理学的なものしかありません。もっとも単純なものが事象を引き起こすと信じるに足る、どのような根拠もないことは明らかなのです。明日太陽が登るというのも仮説にすぎず、日が昇るかどうかはわからないものです。

— ルードヴィッヒ・ヴィトゲンシュタイン^{*1}

この前の章で、推定の背後にある考え方に迫り論じました。それは推測統計学における2つの“大きな考え方”のひとつです。今度はもうひとつの大きな考え方、仮説検定をみることにしましょう。その最も抽象的な形でいうと、帰無仮説検定はとてもシンプルな考え方です。研究者は世界に対するある理論をもっており、実際のデータはその理論を支持するかどうかを判断したいと思っている、というだけです。しかし細かいところは面倒で、ほとんどの人は統計学の中で仮説検定が一番フラストレーションが貯まる場所だといいます。この章の構成は次のようになっています。まず、仮説検定の仕組みについて簡単な例を使って詳しく説明し、仮説検定がどのように“できあがっているか”をみることにします。このとき過度ににならないように注意しつつ、検定手続の背後にあるロジックに注目するようにします。^{*2}そのあと、仮説検定を取り巻くさまざまな問題点、ルール、異端の考え方を取り上げます。

8.1

^{*1} この一文はヴィトゲンシュタイン (1922) の書籍、*論理哲学論考*からのものです。

^{*2} 技術的な注意を。以下の説明は、標準的なテキストの記述とは少し違っています。オーソドックスな帰無仮説検定は、20世紀初頭にロナルド・フィッシャーとイェジ・ネイマンによって作られました。しかしフィッシャーとネイマンは、それがどのように機能するかについて全く異なる視点を持っていました。ほとんどのテキストで使われる標準的な仮説検定の扱いは、このふたつのアプローチを混ぜたものなのです。ここではオーソドックスなやり方よりややネイマンより、特に p 値の意味をどう考えるかについてはネイマンスタイルを取ろうと思います。

さまざまな仮説

結局、我々は狂気に負けてしまうものです。私にとって、その日は教授に昇格した時にやってくるでしょう。象牙の塔に安住し、幸運にも終身在職権に守られるようになれば、いよいよ(いわば)自分の感覚を捨てて、心理学研究のなかでも最も非生産的な分野である、超感覚(ESP)の研究に取り掛かろうと思います^{*3}。

さあこの輝かしい日がやってきたとしましょう。最初の研究はシンプルに、千里眼が存在するかどうかを検証するということにします。被験者は席について、実験者がカードを示します。カードの一方は黒で反対は白くなっています。実験者はそのカードを持って行き、隣の部屋のテーブルに置きます。カードは黒い面を上にするか白い面を上にするか完全にランダムに置かれ、そのランダム化は実験者が被験者のいる部屋を出たあとにはじめて行われます。そこへ2人目の実験者が入ってきて、いまカードのどちらの面が上を向いているかを被験者に尋ねます。これは完全に一発勝負の実験です。それぞれの人は1枚のカードしか見ませんし、答えるのも1回だけで、どの段階でも被験者が正解を知っている人と接触することはありません。ですからデータはとても単純です。N人に質問して、そのうちX人が正しく答えた、というだけです。具体的にするために、N = 100人を調べて、そのうちX = 62人が正解したとしましょう。確かに驚くほど大きな数ですが、ESPの証拠を見つかったと安心して主張できるほど大きいでしょうか。仮説検定が役に立つのは、こういう場面です。ただし仮説をどう検定するかを話す前に、仮説とは何を指すのかをはっきりさせておく必要があります。

8.1.1 研究仮説と統計的仮説

まず頭のなかではっきり区別しておかなければならないのが、研究仮説と統計的仮説です。私のESP研究では、全体としての科学的な目標は千里眼が存在することを示すことです。この場合、研究目標ははっきりしています。ESPの証拠を見つけないのです。別の場面ではもっと中立的な立場をとって、千里眼が存在するかどうかを明らかにすることが研究目標だ、と言うかもしれません。自分をどう見せたいかはさておき、ここで伝えたい基本的な点は、研究仮説とは実質的で検証可能な科学的主張をすることだ、ということです。あなたが心理学者なら、研究仮説は基本的に心理学的な構成概念についてのものになります。次のようなものはどれも**研究仮説**にあたります。

- 音楽を聴くと、他のことに注意を向ける能力が下がる。これは心理学的に意味のある2つの概念(音楽を聴くことと、物事に注意を向けること)のあいだの因果関係についての主張ですから、まったく妥当な研究仮説です。

^{*3}これを本気で信じている人には申し訳ないのですが、ESPについての文献を読むと、現実的であると考えるのは合理的ではありません。しかし、公平にみて、幾つかの研究は合理的にデザインされており、心理学研究デザインについて考えるいい分野であるとは言えます。そしてもちろんここは自由の国ですから、私が間違っていることを証明するためにあなたが時間と労力を費やすこともできますが、あなたの知性のいい使い方とは思えないですね。

- 知能はパーソナリティと関連している。これも前のものと同じく、2つの心理学的構成概念(知能とパーソナリティ)についての関係の主張ですが、主張はより弱いものです。因果ではなく相関だからです。
- 知能とは情報処理の速さである。この仮説はまったく性質が異なります。そもそも関係についての主張ではありません。知能の根本的な性質についての存在論的な主張です(そして私はこれが間違いだとかかなり確信しています)。これについては少し広げておく価値があります。“XはYに影響するか”という形の研究仮説を検証する実験を組み立てるほうが、“Xとは何か”という主張に取り組むよりもふつうは簡単です。そして実際には、存在論的な主張から導かれる関係の主張を検証する方法を見つける、ということになるのが普通です。たとえば、知能とは脳内の情報処理の速さであると信じているなら、実験では知能の指標と速さの指標の関係を探ることが多くなるでしょう。その結果、日常的な研究上の問いの多くは関係についてのものになりがちですが、その動機はほとんど常に、自然のありようについてのより深い存在論的な問いにあるのです。

実際には、研究仮説どうしがかなり重なりうることに注意してください。ESP 実験での最終的な目標は“ESPが存在する”という存在論的な主張を検証することかもしれませんが、操作的には“一部の人は千里眼のようなやり方で物を‘見る’ことができる”といったより狭い仮説に自分を制限するかもしれません。とはいえ、どんな意味でもまともな研究仮説とは言えないものもあります。

- 愛は戦場だ。これは漠然としすぎていて検証できません。研究仮説にある程度の曖昧さがあるのは構わないのですが、理論的な考えを操作化できる必要があります。私の発想力が足りないだけかもしれませんが、これをどうやって具体的な研究デザインに落とし込めるのか、私にはわかりません。もしそうだとすれば、これは科学的な研究仮説ではなく、ポップソングです。だからといって興味深くないという意味ではありません。人間が抱く深い問いの多くはこの部類に入ります。いつか科学が愛についての検証可能な理論を組み立てられるようになったり、神が存在するかどうかを検証できるようになったりするかもしれません。しかし今のところそれはできませんし、どちらについても満足のいく科学的アプローチが現れるほうに賭けようとは思いません。
- トートロジー・クラブの第一のルールは、トートロジー・クラブの第一のルールである。これはいかなる意味でも実質的な主張ではありません。定義上正しいのです。考えうるどんな自然のありようも、この主張と矛盾しえませんが、これは反証不可能な仮説と呼ばれ、そうであるがゆえに科学の領域の外にあります。科学で何をするにせよ、あなたの主張は間違っている可能性を持っていなければなりません。
- 私の実験では“いいえ”より“はい”と答える人のほうが多いだろう。これが研究仮説として失格なのは、心理についてではなくデータについての主張だからです(もちろん、本当の研究上の問いが人には“はい”と答える偏りがあるかどうか、というのであれば話は別ですが)。実

のところこの仮説は、研究仮説というより統計的仮説に近く聞こえてきます。

このように、研究仮説は時にいささか雑然としたものになりますし、結局のところ科学的な主張です。統計的仮説はそのどちらでもありません。統計的仮説は数学的に厳密でなければなりませんし、データを生成する仕組み（つまり“母集団”）の特性についての具体的な主張に対応していなければなりません。とはいえ、統計的仮説はあなたが関心を持っている実質的な研究仮説とはっきり関係していることが意図されています。たとえば私の ESP 研究では、研究仮説は「一部の人は壁の向こうか何かを見通せる」というものです。やりたいのは、これをデータがどう生成されたかについての言明へ“写像”することです。ではその言明がどうなるかを考えてみましょう。実験のなかで私が関心を持っている量は P (“正解”), つまり実験の参加者が質問に正しく答える、真ではあるが未知の確率です。この確率をギリシャ文字の θ (シータ) で表すことにしましょう。統計的仮説として、次の 4 つが考えられます。

- ESP が存在せず、実験がうまくデザインされているなら、参加者はただ当て推量しているだけです。ですから半分の割合で正解すると期待されますので、統計的仮説は「正しく選ぶ真の確率は $\theta = 0.5$ である」となります。
- 一方、ESP が存在して参加者にカードが見えるとしましょう。それが本当なら人々は偶然より良い成績をとりますので、統計的仮説は $\theta > 0.5$ となります。
- 3 つめの可能性は、ESP は存在するけれども色がすべて逆転していて、本人はそれに気づいていない、というものです（まあ変な話ですが、わからないものです）。もしそういう仕組みなら、成績は偶然より悪くなると期待されます。これは $\theta < 0.5$ という統計的仮説に対応します。
- 最後に、ESP は存在するけれども、人々が正しい色を見ているのか間違った色を見ているのかはわからない、としましょう。その場合にデータについて言えるのは、正解する確率が 0.5 と等しくないということだけです。これは $\theta \neq 0.5$ という統計的仮説に対応します。

これらはどれも統計的仮説の正当な例です。母集団のパラメータについての言明であり、かつ私の実験と意味のある形で関係しているからです。

この議論からはっきりしたと思いますが、統計的仮説検定を組み立てようとするとき、研究者はまったく異なる 2 つの仮説を考えることになります。まず研究仮説 (心理についての主張) があり、それが統計的仮説 (データを生成する母集団についての主張) に対応します。私の ESP の例では、次のようになるでしょう。

ダニの研究仮説: “ESP は存在する”

ダニの統計的仮説: $\theta \neq 0.5$

そしてここが肝心なところです。統計的仮説検定が検定しているのは統計的仮説であって、研究仮説

ではありません。研究のデザインが悪ければ、研究仮説と統計的仮説のあいだのつながりは壊れてしまいます。ばかげた例を挙げると、私の ESP 研究が、参加者に窓に映ったカードが実際に見えてしまう状況で行われたとしましょう。そうなれば $\theta \neq 0.5$ という非常に強い証拠が得られるでしょうが、それは“ESP が存在する”かどうかについて何も語ってくれません。

8.1.2 帰無仮説と対立仮説

ここまではよいでしょう。世界についてこう信じたいという研究仮説があり、それをデータがどう生成されたかについてこう信じたいという統計的仮説へ写像できました。多くの人にとって話が少し直感に反してくるのは、ここからです。というのもこれからやるのは、自分が信じたいことのちょうど正反対にあたる新しい統計的仮説(“帰無”仮説 H_0)をこしらえて、本当に関心のあるほう(これは“対立”仮説 H_1 と呼ばれます)をほとんど放っておいて、そちらばかりに注目する、ということだからです。ESP の例では、帰無仮説は $\theta = 0.5$ です。ESP が存在しなかった場合に期待されるのがこれだからです。もちろん私の願いは ESP が本当に実在することですから、この帰無仮説に対する対立仮説は $\theta \neq 0.5$ になります。要するにここでやっているのは、 θ がとりうる値を 2 つに分けることです。本当に真であってほしくない値(帰無仮説)と、そうだとわかったらうれしい値(対立仮説)です。そのうえで大事なのは、仮説検定の目的が対立仮説が(おそらく)正しいことを示すことではない、という点です。目的は、帰無仮説が(おそらく)誤りであることを示すことなのです。たいていの人はこれをかなり奇妙に感じます。

私の経験では、これを理解するいちばんよい方法は、仮説検定を刑事裁判^{*4}だと考えることです。つまり帰無仮説の裁判です。帰無仮説が被告人、研究者が検察官、そして統計的検定そのものが裁判官です。刑事裁判と同じように、無罪の推定があります。研究者であるあなたが、合理的な疑いを超えて誤りであることを証明できない限り、帰無仮説は真であるとみなされます。実験は好きなようにデザインしてかまいませんし(もちろん常識の範囲でですが)、そのときの目標は、誤りであるという罪で有罪判決が出る見込みをデータが最大にすることです。やっかいなのは、裁判のルールを決めるのは統計的検定であり、そのルールが帰無仮説を守るように作られている、という点です。具体的には、帰無仮説が実際に真である場合に冤罪の確率が低く抑えられることを保証しているのです。これはかなり重要です。なにしろ帰無仮説には弁護人が付きませんし、研究者が必死にそれを誤りだと証明しようとしているのですから、誰かが守ってやらなければならないのです。

8.2

^{*4}この比喩は、イギリス・アメリカ・オーストラリアのような当事者主義の法体系にいる場合にしか通じません。私の理解では、フランスの糾問主義の体系はかなり異なります。

要約

帰無仮説検定は、統計理論のなかでもっとも広く行き渡っている要素のひとつです。学術論文の大多数が、何らかの仮説検定の結果を報告しています。ですから p 値が何を意味するのかを少なくともざっと理解していなければ、科学の世界でやっていくのはほとんど不可能です。この章が本書でもっとも重要な章のひとつであるゆえんです。いつものように、話してきた重要な考え方を手短におさらいして章を終えることにします。

- 研究仮説と統計的仮説。帰無仮説と対立仮説 (セクション 8.1)。
- タイプ I エラーとタイプ II エラー (セクション 8.3)。
- 検定統計量と標本分布 (セクション 8.4)。
- 判断の過程としての仮説検定 (セクション 8.5)。
- “柔らかい” 判断としての p 値 (セクション 8.6)。
- 仮説検定の結果を書く (セクション 8.7)。
- 実際に仮説検定を実行する (セクション 8.8)。
- 効果量と検定力 (セクション 8.9)。
- 仮説検定について考えておくべきいくつかの問題 (セクション 8.10)。

本書の後のほう、Chapter 15 では、帰無仮説検定の理論をベイズの視点から捉え直し、正統的なアプローチがあまり好きになれない場合に使える新しい道具をいくつか紹介します。しかし今のところは、抽象的な統計理論はここまでとして、具体的なデータ分析の道具の話に入っていくことにしましょう。

8.3

2 種類のエラー

統計的検定がどのように構成されているのか、具体的に話し始める前に、その背後にある哲学について理解しておくといいでしょう。帰無仮説検定と刑事裁判の類似性を指摘した時にもヒントを出しましたが、今度はもっとはっきり扱ってみます。理想的には、検定を実施してもどんな間違いも犯すべきではありません。でも残念ながら、世界は混乱に満ちていて、決して理想通りにはいきません。時にあなたは不運としか言いようのない状況に陥ることもあるでしょう。たとえば、コインを 10 回トスして 10 回とも表になることもあるでしょう。これは、コインが偏っているという強い証拠のようにも思えますが、全く公平なコインであっても 1024 回に 1 回は偶然でも起こりうることです。言い換えると、現実にはつねに間違いを起こしうる偶然の可能性があるということを受け入れなければならない、ということです。ですから、統計的仮説検定の目標はエラーを完全に無くすことではなく、それを最小化することにある、といえます。

さてここで、“エラー”とは何かをもう少し正確にしておく必要があるでしょう。まず、明らかなことから述べていきます。帰無仮説は正しいか間違っているかのどちらかであり、我々の検定は帰無仮説を支持するか棄却するかのどちらかです。^{*5} ですから、以下の表に示したように、検定をしたあとには、生じた以下4つのうちどれかを選ぶことになるでしょう。

	保持 H_0	棄却 H_0
H_0 が真	正しい決定	エラー (type I)
H_0 が偽	エラー (type II)	正しい決定

結果的に、ここにはふたつの異なる種類の間違い方があることになります。帰無仮説を棄却した時に、実際それが正しかったという場合は、**type I error** を犯したことになります。一方、帰無仮説を保持した時、実際はそれが間違えていたというのであれば、**type II error** だったことになります。

統計的検定は刑事裁判のようだと覚えていますか？ そうまさにそうなのです。刑事裁判では“合理的な疑いを超えて”，被告がやったことを立証しなければなりません。証拠のルールというのはすべて（少なくとも理論的には），無実の被告を不当に有罪にする可能性を（ほとんど）なくすように設計されています。裁判は被告の権利を守るように設計されています。英国の法学者ウィリアム・ブラックストーンが言ったように、「無実のひと1人が傷つけられるより、有罪の10人が逃げってしまう方がマシである」ということです。いいかえると、刑事裁判では二種類のエラーを同じようには扱わないということです。無実の人を投獄するのは、有罪の人を自由にしてしまうよりもずっと悪いことだと考えられているのです。統計的検定も大体同じです。検定の唯一重要な設計規則は、タイプ1エラーの確率を制御するというもので、それを固定された確率以下に保持することにあります。この確率、これは α で表現されますが、これが検定の**有意水準**といいます。もう一度言いますが、これが全体的な設計の中心ですから、仮説検定はタイプ1エラーの確率が α を超えない場合、有意水準 α をもつと言えるのです。

さて、ではタイプ2エラーの確率はどうでしょう？ これも制御下におきたいところで、この確率は β と表します。しかしその確率は、帰無仮説が本当は偽だった時にそれを棄却する確率、 $1 - \beta$ で表される検定の**検定力**として参照されるほうが一般的です。これを直接表現できるように、関係する

^{*5}余談ですが、帰無仮説検定における言葉遣いについて考えておきます。まず、避けるべき言葉は“証明する”です。統計的な検定は、帰無仮説の真偽を証明することは決してありません。証拠は確実なことを意味しますが、ことわざが言うように、統計は決して確実であるとは言わないものです。これについてはほとんどの人が同意してくれると思います。しかしそれ以上に、非常に混乱することがあります。人によっては、“帰無仮説が棄却された”，“帰無仮説の棄却に失敗した”とか、“帰無仮説を保持した”といった文章しか許さないでしょう。この線に沿って考えると、あなたは“対立仮説を採択した”とか“帰無仮説を採択した”とは言えないことになります。個人的には、それはやり過ぎだと思います。私の考えでは、これは帰無仮説検定をカール・ポパーの、科学的手続の反証主義の考えを誤って捉えているのです。反証主義と帰無仮説検定の間には類似性がありますが、同じものではありません。私個人的には、仮説を採択するという言い方をしてもいい（ただし、“採択する”というのは本質的に真であるということの意味するものではないこと、特に帰無仮説の場合には）と思うのですが、多くの人は同意してくれないでしょう。さらにいえば、このように変な現象が存在することを知っていれば、あなたが自分の結果を記述する時に不意打ちを喰らわなくて済みます。

数字を同じ表に書き込んでおくことにしましょう。

	保持 H_0	棄却 H_0
H_0 が真	$1 - \alpha$ (正しく保持する確率)	α (タイプ 1 のエラー率)
H_0 が偽	β (タイプ 2 のエラー率)	$1 - \beta$ (検定力)

「強い」仮説検定とは、 α がある (小さな) 望ましい水準を維持したままで、 β の値が小さいことです。簡便的に、下 g 区 sh は 3 つの α 水準を使います。 .05, .01 と .001 です。ここに非対称性があることに注意してください。すなわち、検定は α 水準をなるべく小さくするように設計されていますが、 β についてはこれに対応する何かを保証するわけではありません。私たちはもちろんタイプ 2 エラーの確率を小さくしたいと思いますし、検定に際してそれを小さくしておこうと考えますが、タイプ 1 エラーをコントロールするという圧倒的な必要性の前では、二次的な要望になってしまいます。ブラックストーンが統計学者であったなら言ったとおもいますが、これはつまり「1 つの真の帰無仮説を棄却するより、10 回の間違った帰無仮説を採択した方が良い」ということです。正直なところ、私がこの哲学に同意しているかどうかわかりません。これが理にかなっていると思える状況もありますし、そうでないと思う状況もありますが、どちらでもないとも思います。これが検定のしくみです。

8.4

検定統計量と標本分布

ここからは、仮説検定がどう組み立てられるのかを具体的に話していく必要があります。そのために ESP の例に戻りましょう。実際に得られたデータはひとまず脇に置いて、実験の構造について考えてみます。実際の数値がどうであれ、データの形は「N 人のうち X 人が隠されたカードの色を正しく当てた」というものです。さらに、帰無仮説が本当に正しい、つまり ESP は存在せず、正しい色を選ぶ真の確率がちょうど $\theta = 0.5$ である、と仮定してみましょう。データはどうなると期待されるでしょうか。当然ながら、正解した人の割合は 50% にかなり近くなると期待されます。もう少し数学的に言えば、 X/N がおよそ 0.5 になる、ということです。もちろん、この割合がちょうど 0.5 になるとは期待しません。たとえば $N = 100$ 人を調べて $X = 53$ 人が正解したなら、データは帰無仮説とかなり整合していると認めざるをえないでしょう。一方、参加者のうち $X = 99$ 人が正解したなら、帰無仮説は誤りだとかなり確信するでしょう。同じように、正解したのが $X = 3$ 人だけだったとしても、やはり帰無仮説は誤りだと確信するはずで。これをもう少し専門的に言いましょう。データを見ることで計算できる量 X があります。 X の値を見たうえで、帰無仮説が正しいと信じるか、帰無仮説を棄却して対立仮説をとるかを判断します。このように判断の指針にするために計算する量のことを、**検定統計量**と呼びます。




Figure8.1 帰無仮説が正しいときの検定統計量 X の標本分布。今回の ESP の場面では二項分布になる。帰無仮説は正答の確率を $\theta = .5$ としているので、当然ながら標本分布ではもっとも起こりやすい値が (100 人中)50 人の正答となる。確率の大部分は 40 から 60 のあいだにある。

.....

検定統計量を選んだら、次のステップは、検定統計量のどの値なら帰無仮説を棄却し、どの値なら保持するのかを正確に述べることです。そのためには、帰無仮説が実際に正しかった場合に**検定統計量の標本分布**がどうなるかを決める必要があります (標本分布についてはセクション 7.3.1 で述べました)。なぜこれが必要なのでしょう。それは、この分布が、帰無仮説のもとで X のどんな値が期待されるかを正確に教えてくれるからです。ですからこの分布を、帰無仮説がデータとどれだけよく合っているかを評価する道具として使えるわけです。

検定統計量の標本分布は、実際にはどうやって決めるのでしょうか。多くの仮説検定ではこの段階はかなり込み入っていて、本書の後のほうでは、いくつかの検定について私が少しごまかしているのを見ることになるでしょう (なかには私自身が理解していないものもあります)。しかし、とても簡単な場合もあります。そして幸いなことに、ESP の例はそのもっとも簡単な部類にあたります。母集団のパラメータ θ は、質問されたときに人が正しく答える全体的な確率にすぎませんし、検定統計量 X は、標本サイズ N のうち正しく答えた人数の数です。このような分布はセクション 6.4 で見たことがありますし、まさにそれこそが二項分布の表すものです。ですからそのセクションで導入した記法と用語を使えば、帰無仮説は X が二項分布にしたがうと予測している、ということになり、

次のように書けます。

$$X \sim \text{Binomial}(\theta, N)$$

帰無仮説は $\theta = 0.5$ としていますし、実験の人数は $N = 100$ ですから、必要な標本分布が手に入りました。この標本分布を図 8.1 に描いてあります。とくに驚きはありません。帰無仮説によれば $X = 50$ がもっとも起こりやすい結果であり、正答数は 40 から 60 のあいだのどこかになるとほぼ確実に言えるわけです。

8.5

判断を下す

さて、もうすぐ完成です。検定統計量 (X) を作りました。この検定統計量は、 X が $N/2$ に近ければ帰無仮説を保持すべきで、そうでなければ棄却すべきだとかなり確信できるように選んであります。残っている問題はこうです。検定統計量のどの値を帰無仮説に対応させ、どの値を対立仮説に対応させればよいのでしょうか。たとえば私の ESP 研究では、 $X = 62$ という値が観測されました。どう判断すべきでしょうか。帰無仮説を信じるべきでしょうか、対立仮説を信じるべきでしょうか。

8.5.1 棄却域と臨界値

この問いに答えるには、検定統計量 X についての**棄却域**という考え方を導入する必要があります。検定の棄却域とは、帰無仮説を棄却することになる X の値の範囲のことです。この棄却域はどうやって見つけるのでしょうか。わかっていることを整理してみましょう。

- 帰無仮説を棄却するには、 X がとても大きいか、とても小さいかでなければなりません。
- 帰無仮説が正しければ、 X の標本分布は $\text{Binomial}(0.5, N)$ です。
- $\alpha = .05$ なら、棄却域はこの標本分布の 5% を覆っていなければなりません。

最後の点をきちんと理解しておくことが大切です。棄却域は帰無仮説を棄却することになる X の値の範囲であり、いま問題にしている標本分布は、帰無仮説が実際に正しい場合に X がある値をとる確率を表しています。ここで、標本分布の 20% を覆う棄却域を選んだとして、帰無仮説が実際に正しいとしましょう。帰無仮説を誤って棄却してしまう確率はどうなるのでしょうか。もちろん 20% です。つまり α 水準が 0.2 の検定を作ってしまったことになります。 $\alpha = .05$ にしたいなら、棄却域が覆ってよいのは検定統計量の標本分布の 5% だけ、ということになります。

実は、この 3 つの条件で問題は一意に解けます。棄却域は、分布の**裾**として知られる、もっとも極端な値の部分になります。これを図 8.2 に示しました。 $\alpha = .05$ にしたいなら、棄却域は $X \leq 40$

Critical Regions for a Two-Sided Test




Figure8.2 有意水準 $\alpha = .05$ の検定における, ESP 研究の仮説検定の棄却域。図は帰無仮説のもとでの X の標本分布 (つまり図 8.1 と同じもの) を示している。灰色のバーは帰無仮説を保持することになる X の値, 青い (濃い) バーは帰無仮説を棄却することになる X の値, すなわち棄却域である。対立仮説は両側 ($\theta < .5$ と $\theta > .5$ の両方を許す) なので, 棄却域は分布の両裾を覆う。 α 水準を .05 にするには, 2 つの領域がそれぞれ標本分布の 2.5% を含むようにする必要がある。

と $X \geq 60$ になります*⁶。つまり “当たり” と答えた人数が 41 から 59 のあいだなら帰無仮説を保持すべきです。0 から 40 のあいだ, あるいは 60 から 100 のあいだなら, 帰無仮説を棄却すべきです。40 と 60 という数値は棄却域の境目を定めるものですので, **臨界値**と呼ばれます。

*⁶厳密に言うと, いま作った検定の α は .057 で, 少し甘すぎます。しかし棄却域の境界を 39 と 61 にすると, 棄却域は分布の 3.5% しか覆いません。 $\alpha = .05$ にいちばん近いのはこちらですから, 40 と 60 を臨界値として使い, 5.7% のタイプ I エラー率を受け入れるほうが理にかなっていると考えました。

ここまでで、仮説検定は本質的に完成しています。

1. (1) α 水準を選ぶ (たとえば $\alpha = .05$)。
2. (2) H_0 と H_1 を比較するのに (何らかの意味で) うまく働く検定統計量 (たとえば X) を考え出す。
3. (3) 帰無仮説が正しいという仮定のもとで検定統計量の標本分布を求める (今回の場合は二項分布)。
4. (4) 適切な α 水準になる棄却域を計算する (0 から 40 と 60 から 100)。

あとは実際のデータについて検定統計量の値を計算し (たとえば $X = 62$)、臨界値と比べて判断するだけです。62 は臨界値の 60 より大きいので、帰無仮説を棄却することになります。少し言い方を変えれば、検定は統計的に有意な結果を出した、ということになります。

8.5.2 統計的“有意性”についての注意

他の占いのオカルト的技法と同じく、統計的方法にも、その手法を門外漢から覆い隠すためにわざわざこしらえられた仲間内の専門用語がある。

– G. O. Ashley の言葉とされる^{*7}

ここで“有意”という語について、ごく短い脱線をしておきましょう。統計的有意性という概念は実のところとても単純なのですが、名前がひどく不幸なことになっています。データによって帰無仮説を棄却できる場合、“結果は統計的に有意である”と言い、しばしば“結果は有意である”と短縮されます。この用語はかなり古く、“significant”が“重要である”に近い現代的な意味ではなく、単に“示された”といった意味だった時代にさかのぼります。その結果、現代の多くの読者は統計を学び始めたときにひどく混乱します。“有意な結果”は重要な結果に違いがないと思ってしまうからです。まったくそんな意味ではありません。“統計的に有意”が意味するのは、データによって帰無仮説を棄却できた、ということだけです。その結果が現実世界で本当に重要かどうかはまったく別の問題で、ほかのさまざまなことに左右されます。

8.5.3 片側検定と両側検定の違い

いま作った仮説検定について、もうひとつ指摘しておきたいことがあります。これまで使ってきた統

^{*7}インターネット上では Ashley がこう言ったということはかなり一致しているのですが、どうしても出典を挙げてくれる人が見つかりません。

計的仮説を少し考えてみると、

$$H_0: \theta = .5$$

$$H_1: \theta \neq .5$$

対立仮説が $\theta < .5$ の可能性と $\theta > .5$ の可能性の両方を含んでいることに気づきます。ESP によって偶然より良い成績も偶然より悪い成績も生じうると本当に考えているなら、これは理にかなっています (実際そう考える人もいます)。統計の言葉で言えば、これは**両側検定**の例です。そう呼ばれるのは、対立仮説が帰無仮説の両“側”の領域を覆っているからで、その結果として検定の棄却域は、先ほど図 8.2 に示したように、標本分布の両裾を覆うことになります ($\alpha = .05$ ならそれぞれ 2.5% ずつ)。

しかし可能性はそれだけではありません。偶然より良い成績が出た場合にだけ ESP を信じる気になる、ということもあるでしょう。その場合、対立仮説は $\theta > .5$ の可能性だけを含むことになり、帰無仮説は $\theta \leq .5$ になります。

$$H_0: \theta \leq .5$$

$$H_1: \theta > .5$$

こうなると**片側検定**と呼ばれるものになり、棄却域は標本分布の片方の裾だけを覆います。これを図 8.3 に示しました。

8.6

検定の p 値

ある意味で、仮説検定はもう完成しています。検定統計量を作り、帰無仮説が正しい場合の標本分布を求め、検定の棄却域を作りました。とはいえ、いちばん重要な数値である **p 値**を省いてきました。これからその話に移ります。 p 値の解釈にはやや異なる 2 つのやり方があり、ひとつは Ronald Fisher 卿が、もうひとつは Jerzy Neyman が提案したものです。どちらも正当なものですが、仮説検定についてのまったく異なる考え方を反映しています。入門的な教科書のほとんどは Fisher のほうしか載せない傾向がありますが、これは少し残念なことだと思います。私の考えでは、Neyman のほうがすっきりしていますし、帰無仮説検定の論理をよりよく反映しています。とはいえ異論もあるでしょうから、両方を載せておきます。まず Neyman のほうから始めましょう。

8.6.1 もう少し柔らかい判断の見方

ここまで説明してきた仮説検定の手続きの問題点のひとつは、“かろうじて有意”な結果と“きわめて有意”な結果をまったく区別しないことです。たとえば私の ESP 研究では、得られたデータはぎりぎり棄却域に入りましたので、有意な効果は得られたものの、かなり際どいところでした。これに対して、 $N = 100$ 人の参加者のうち $X = 97$ 人が正解する研究を行ったとしましょう。これも当

Critical Region for a One-Sided Test




Figure8.3 片側検定の棄却域。この場合，対立仮説は $\theta > .5$ なので， X が大きい場合にだけ帰無仮説を棄却する。その結果，棄却域は標本分布の上側の裾，具体的には分布の上位 5% だけを覆う。図 8.2 の両側検定版と比べてほしい。

然有意になりますが，ずっと大きな余裕をもって有意であり，まったく曖昧さがありません。すでに説明した手続きは，この 2 つを区別しません。許容できるタイプ I エラー率として $\alpha = .05$ を認めるという標準的な慣例をとるなら，どちらも有意な結果なのです。

ここで p 値が役に立ちます。仕組みを理解するために，同じデータに対して α の値をいろいろ変えながら，たくさんの仮説検定を行ったとしましょう。もとの ESP データでそれをやると，次のようになります。

α の値	0.05	0.04	0.03	0.02	0.01
帰無仮説を棄却するか	する	する	する	しない	しない

ESP のデータ ($N = 100$ の観測のうち $X = 62$ が正解) を， α 水準.03 以上で検定すると，常に帰無仮説を棄却することになります。 α 水準が.02 以下なら，常に帰無仮説を保持することになります。ですから.02 と.03 のあいだのどこかに，このデータで帰無仮説を棄却できる α の最小値があるはずです。これが p 値です。実際，ESP データの p 値は $p = .021$ です。つまり，

p とは，帰無仮説を棄却したいときに受け入れなければならないタイプ I エラー率 (α) の最小値である，と定義されます。

実質的に p は、ありうるすべての α の値にわたって、実行できたはずのすべての仮説検定を要約したものです。その結果として、判断の過程を“柔軟かく”する働きを持ちます。 $p \leq \alpha$ となる検定では帰無仮説を棄却していたはずですし、 $p > \alpha$ となる検定では帰無仮説を保持していたはずです。私の ESP 研究では $X = 62$ が得られ、結果として $p = .021$ になりました。ですから受け入れなければならないエラー率は 2.1% です。これに対して、実験の結果が $X = 97$ だったとしましょう。 p 値はどうなるのでしょうか。今度は $p = 1.36 \times 10^{-25}$ まで縮みます。とてつもなく小さな*8タイプ I エラー率です。この 2 つめの場合には、はるかに大きな確信をもって帰無仮説を棄却できます。棄却するという判断を正当化するのに受け入れ“なければならない”タイプ I エラー率が、 10^{25} 分の 1 程度でしかないからです。

p 値の 2 つめの定義は Ronald Fisher 卿によるもので、入門的な統計の教科書でよく見かけるのは実はこちらのほうです。棄却域を作ったとき、それが標本分布の裾(つまり極端な値)に対応していたことに気づいたのでしょうか。これは偶然ではなく、ほとんどすべての“良い”検定がこの性質を持っています(ここで良いというのは、タイプIIエラー率 β を最小にするという意味です)。その理由は、良い棄却域はほとんど常に、帰無仮説が正しい場合にもっとも観測されにくい検定統計量の値に対応するからです。このルールが正しいなら、p 値を「実際に得られたものと少なくとも同じくらい極端な検定統計量が観測される確率」と定義できます。言い換えれば、帰無仮説のもとでデータがきわめてありそうにないのなら、帰無仮説はおそらく誤りだ、ということです。

ここまでで、 p 値にはかなり異なるけれども正当な 2 つの解釈があること、つまり Neyman の仮説検定のアプローチにもとづくものと Fisher のものにもとづくものがあることがわかったと思います。残念ながら、とくに統計を学び始めたときに人がしばしば口にする 3 つめの説明があり、それはまったくもって完全に間違っています。その誤ったやり方とは、 p 値を“帰無仮説が正しい確率”と言ってしまうことです。直感的には魅力的な考え方ですが、2 つの重要な点で間違っています。第一に、帰無仮説検定は頻度論の道具であり、頻度論的な確率の考え方では帰無仮説に確率を割り当てることはできません。この確率観では、帰無仮説は正しいか正しくないかのどちらかであって、正しい“確率が 5%”ということはありません。第二に、仮説に確率を割り当てられるベイズ的な

- 177 -

アプローチの中でさえ、 p 値は帰無仮説が正しい確率には対応しません。この解釈は、 p 値がどう計算されるかという数学とまったく整合しないのです。はっきり言えば、そう考えなくなる直感的な魅力があるにもかかわらず、 p 値をそう解釈することに正当性はまったくありません。決してやらないでください。

8.7

仮説検定の結果を報告する

仮説検定の結果を書くときには報告すべき情報がいくつかありますが、それは検定によってかなり異なります。本書の残りの部分では、それぞれの検定の結果をどう報告するかについて少しずつ触れていきますので(とくに詳しい例はセクション 9.1.9 を見てください)、普通どうやるのかの感覚がつかめるでしょう。ただし、どの検定をする場合でも必ずやらなければならないのは、 p 値について述べ、結果が有意だったかどうかを述べることです。

これが必要なのは驚くことではありません。検定をする目的そのものだからです。驚くかもしれないのは、それを具体的にどうやるべきかについて、いささかの論争があるということです。帰無仮説検定の枠組みそのものに全面的に反対している人たちはさておき、得られた p 値を正確に報告すべきか、それともあらかじめ選んだ有意水準について $p < \alpha$ と述べるだけにすべきか(たとえば $p < .05$)、という点をめぐって一定の緊張があるのです。

8.7.1 何が問題なのか

なぜこれが問題になるのかを理解する鍵は、 p 値がとてつもなく便利だという点にあります。実際のところ、 p 値を計算できるということは、検定を実行するのに α 水準をまったく指定しなくてよい、ということの意味します。そのかわりに、 p 値を計算してそれを直接解釈すればよいわけです。 $p = .062$ が得られたなら、帰無仮説の棄却を正当化するには 6.2% のタイプ I エラー率を受け入れなければならない、ということです。あなた個人が 6.2% は受け入れがたいと思うなら、帰無仮説を保持します。だったら実際の p 値を報告して、許容できるタイプ I エラー率がどれくらいかは読者自身に判断してもらえばいいではないか、という議論になります。このやり方には、判断の過程を“柔軟かく”できるという大きな利点があります。実際、 p 値の Neyman の定義を受け入れるなら、それこそが p 値の存在意義です。 $\alpha = .05$ という固定した有意水準が“採択”と“棄却”を分ける明確な線であることをやめれば、 $p = .051$ と $p = .049$ を根本的に違うものとして扱わざるをえない、というかなり病的な問題も消えます。

この柔軟さは、 p 値の利点であると同時に欠点でもあります。多くの人が正確な p 値を報告するという考えを好まないのは、それが研究者に少し自由を与えすぎるからです。とくに、データを見たあ

とで、どのくらいの誤りを受け入れるかについて考えを変えられてしまいます。たとえば私の ESP 実験で考えてみましょう。検定を実行したところ p 値が .09 になったとします。採択すべきでしょうか、棄却すべきでしょうか。正直なところ、“本当に”受け入れられるタイプ I エラーの水準がどれくらいかなど、まだ考えてもいません。その点について私は意見を持っていないのです。しかし ESP が存在するかどうかについては意見を持っていますし、自分の研究がまともな学術誌に載るべきかどうかについては間違いなく意見を持っています。そして驚いたことに、データを見たいまとなつては、9% のエラー率もそんなに悪くない気がしてきました。実験が失敗したと世間に認めなければならぬ煩わしさに比べれば、なおさらです。そこで、後づけででっちあげたように見えないよう、10% のタイプ I エラー率もそう悪くはないという理屈をつけて、 α は .1 だと言うことにします。その水準なら検定は有意です。私の勝ちですね。

つまりここでの心配は、こちらにどれだけ善意があり、どれだけ正直な人間であっても、あちこちで少しずつ“ぼかす”誘惑が本当に、本当に強い、ということです。実験をやったことがある人なら誰でも証言できるでしょうが、実験は長く困難な過程であり、自分の仮説にとっても愛着が湧いてしまうものです。それを手放して、実験が望んだものを見つけられなかったと認めるのは難しいことです。そこに危険があります。“生の” p 値を使うと、人はデータが実際に語っていることではなく、自分が信じたいことにもとづいてデータを解釈し始めます。それを許すのなら、そもそも何のために科学をやっているのでしょうか。事実がどうであれ、誰もが何でも好きなように信じればいいではありませんか。まあ、これは少し極端ですが、心配の出どころはそこにあります。この立場からすれば、 α の値をあらかじめ指定し、検定が有意だったかどうかだけを報告しなければならないということになります。自分たちを正直に保つ方法はそれしかない、というわけです。

8.7.2 提案されている 2 つの解決策

実際には、研究者が α 水準をひとつだけあらかじめ指定することはかなりまれです。そのかわり、科学者は .05・.01・.001 という 3 つの標準的な有意水準を使う、というのが慣例になっています。結果を報告するときには、この有意水準のうちどれで帰無仮説を棄却できるか（あるいはどれでもできないか）を示します。これを表 8.1 にまとめました。 $p < .01$ は $p < .05$ よりも強い証拠の基準を満たしていることを意味しますので、これによって判断のルールを少し柔らかくできます。それでいて、これらの水準は慣例によってあらかじめ固定されていますので、データを見てから α 水準を選ぶことは防げます。

とはいえ、正確な p 値を報告するほうを好む人もかなり多くいます。多くの人にとっては、 $p = .06$ をどう解釈するかを読者自身に判断してもらえる利点のほうが、欠点を上回るのです。ただし実際には、正確な p 値を好む研究者のあいだでも、 p が小さい場合には正確な値を報告せず $p < .001$ とだけ書くことがよくあります。これはひとつには、多くのソフトウェアがそこまで小さい p 値を実際には出力しないから（たとえば SPSS は $p < .001$ のとき単に $p = .000$ と書きます）であり、またひ

Table8.1 p 値の報告について広く採用されている慣例。多くの場面では、下に示す 4 つのうちのいずれか (たとえば $p < .05$) を報告するのが慣例になっている。統計ソフトの出力で見かけることがあるので、“有意性の星”の記法 (つまり*が $p < .05$ を示す) も入れてある。また、 $p > .05$ と書くかわりに *n.s.*(有意でない) と書く人もいることも覚えておくとよい。

通常の記法	有意性の星	日本語での言い方	帰無仮説は
$p > .05$		検定は有意でなかった	保持
$p < .05$	*	$\alpha = .05$ では有意だが $\alpha = .01$ や $\alpha = .001$ では有意でない	棄却
$p < .01$	**	$\alpha = .05$ と $\alpha = .01$ では有意だが $\alpha = .001$ では有意でない	棄却
$p < .001$	***	すべての水準で有意だった	棄却

とつには、非常に小さな p 値がある種の誤解を招きうるからです。人間は.0000000001 のような数値を見ると、対立仮説を支持する証拠がほぼ確実だという直感を抑えるのが難しくなります。しかし実際には、たいていそれは間違いです。世の中は大きく、雑然としていて複雑ですし、これまでに考案されたどの統計的検定も、単純化と近似と仮定に依存しています。ですから、どんな統計分析であれ、 $p < .001$ が意味する以上に強い確信をもって立ち去るのは、おそらく妥当ではありません。言い換えれば、 $p < .001$ というのは“この検定に関する限り、証拠は圧倒的である”ということを表す符牒なのです。

こうしたことを踏まえると、結局どうすればよいのか迷うかもしれません。この点についてはかなり矛盾した助言があり、正確な p 値を報告すべきだと言う人もいれば、表 8.1 に示した段階的なやり方を使うべきだと言う人もいます。ですから私にできる最善の助言は、自分の分野で書かれた論文や報告書を見て、どんな慣例になっているかを確かめてみることです。一貫したパターンが見当たらないようなら、好きなほうを使ってください。

8.8

実際に仮説検定を実行する

ここまで来ると、これは“本物の”仮説検定なのか、それとも私がでっちあげたおもちゃの例なのか、と思う人もいるかもしれません。本物です。これまでの議論では、現実に出会いうるもっとも単純な問題だと考えて、検定を原理から組み立ててきました。しかしこの検定はすでに存在していま

す。二項検定と呼ばれるもので、JASP では 'Frequencies' のボタンを押すと使える統計分析のひとつとして実装されています。反応の確率が2分の1であるという帰無仮説 $p = .5^{*9}$ を検定してみましょう。 $n = 100$ 人のうち $x = 62$ 人が正しく反応したデータ (`binomialtest.jasp` データファイルにあります) を使うと、図 8.4 のような結果が得られます。




Figure 8.4 JASP での二項検定の分析と結果

いまのところこの出力は見慣れないものかもしれませんが、だいたい正しいことを伝えてくれているのはわかると思います。具体的には、 p 値の 0.02 は通常選ばれる $\alpha = .05$ より小さいので、帰無仮説を棄却できます。この種の出力の読み方については今後さらに詳しく扱っていきますので、しばらくすれば読んで理解するのがかなり簡単になっているはずです。

8.9

効果量，標本サイズ，検定力

これまでの節では、統計的仮説検定の背後にある主な設計原理がタイプ I エラー率の統制にある、ということを強調してきました。 $\alpha = .05$ と定めるとき、私たちは正しい帰無仮説のうち誤って棄却されるものが 5% だけになるようにしているわけです。とはいえ、タイプ II エラーを気にしていな

^{*9} ここでの p は p 値とは何の関係もないことに注意してください。JASP の二項検定における p という引数は、帰無仮説のもとで正しく反応する確率に対応しています。つまり θ の値です。

いという意味ではありません。実際、研究者の立場からすれば、帰無仮説が本当は誤りなのに棄却できないという誤りは、きわめて腹立たしいものです。そうしたわけで、仮説検定の副次的な目標はタイプIIエラー率 β を最小にすることなのですが、ふつうはタイプIIエラーを最小にするという言い方はしません。そのかわりに、検定の検定力を最大にする、と言います。検定力は $1 - \beta$ と定義されますので、同じことです。

8.9.1 検定力関数




Figure8.5 母集団のパラメータが $\theta = 0.55$ である場合の、対立仮説のもとでの標本分布。分布のかなりの部分が棄却域に入っている。

タイプIIエラーが実際どういうものを少し考えてみましょう。タイプIIエラーは、対立仮説が正しいのに帰無仮説を棄却できないときに起こります。理想を言えば、タイプIエラー率について $\alpha = .05$ と設定できるのと同じように、タイプIIエラー率を表すひとつの数値 β を計算できるとよいのですが。残念ながら、これはずっと厄介です。それを理解するために、私のESP研究では対立仮説が θ のたくさんの値に対応していることに注目してください。実のところ対立仮説は、0.5を除く θ のすべての値に対応しています。正しく反応する真の確率が55%(つまり $\theta = .55$)だとしましょう。そうするとXの真の標本分布は帰無仮説が予測するものとは違ってきます。Xのもっとも起こりやすい値が100中55になるからです。それだけでなく、図8.5に示すように標本分布全体が

ずれています。もちろん棄却域は変わりません。定義上、棄却域は帰無仮説が予測することにもとづいているからです。この図が示しているのは、帰無仮説が誤っている場合には標本分布のずっと大きな部分が棄却域に入る、という事実です。そしてもちろん、そうなるべきなのです。帰無仮説が実際に誤っているときには、それを棄却する確率が大きくなるわけですから。ただし、対立仮説と整合する可能性は $\theta = .55$ だけではありません。今度は θ の真の値が 0.7 だとしてみましょう。この場合、標本分布はどうなるでしょうか。答えは図 8.6 に示すとおりで、標本分布のほぼ全体が棄却域に移動しています。ですから $\theta = 0.7$ なら、帰無仮説を正しく棄却する確率（つまり検定力）は $\theta = 0.55$ の場合よりずっと大きくなります。要するに、 $\theta = .55$ も $\theta = .70$ もどちらも対立仮説の一部ですが、タイプ II エラー率は異なるのです。




Figure8.6 母集団のパラメータが $\theta = 0.70$ である場合の、対立仮説のもとでの標本分布。分布のほとんどすべてが棄却域に入っている。

ここからわかるのは、検定の検定力（つまり $1 - \beta$ ）が θ の真の値に依存する、ということです。これを示すために、 θ のすべての値について帰無仮説を棄却する期待確率を計算し、図 8.7 に描きました。このプロットは、ふつう検定の**検定力関数**と呼ばれるものを表しています。 θ のとりうるすべての値について検定力 $(1 - \beta)$ を教えてくれますので、検定の良し悪しをうまく要約したものになっています。見てのとおり、 θ の真の値が 0.5 にとても近いときには検定力が急激に落ち、離れているときには大きくなります。




Figure 8.7 帰無仮説を棄却する確率を、 θ の真の値の関数として描いたもの。当然ながら、 θ の真の値が帰無仮説の指定する値 (つまり $\theta = .5$) と大きく異なるほど、検定力は高くなる (正しく棄却できる見込みが大きくなる)。 θ が実際に .5 と等しい場合 (黒い点で示した) には帰無仮説は真であり、このとき帰無仮説を棄却することはタイプ I エラーになることに注意。

8.9.2 効果量

すべてのモデルは間違っているのだから、科学者は何が重要な意味で間違っているのかに注意を払わなければならない。外に虎がいるときにネズミを気にするのは適切ではない。

– George Box ([Box 1976](#), p. 792)

図 8.7 のプロットは、仮説検定についてのかかなり基本的な点をとらえています。世界の真のありようが帰無仮説の予測と大きく異なるなら検定力はとても高くなりますが、帰無仮説と似ている (ただし同一ではない) なら検定力はとても低くなります。ですから、世界の真のありようが帰無仮説にどれだけ “似ている” かを数量化する方法があると便利です。それを行う統計量は**効果量**の指標と呼ばれます (たとえば [Cohen 1988](#); [Ellis 2010](#))。効果量は文脈によって少しずつ違うように定義されます (ですからこの節では一般的な話にとどめます) が、とらえようとしている質的な考え方は常に同じです。真の母集団パラメータと、帰無仮説が仮定するパラメータの値との差はどれくらいか、ということです。ESP の例で言えば、帰無仮説が仮定する値を $\theta_0 = 0.5$ 、真の値を θ とすると、効果量

Table8.2 統計的有意性と効果量の関係を理解するための大雑把な指針。基本的に、有意な結果が得られていないなら、そもそもそれが実在するという証拠がないのですから効果量はほとんど意味を持たない。一方、有意な効果が得られていても効果量が小さいなら、その結果は(実在するとしても)さほど興味深いものではない可能性が高い。ただしこの指針はきわめて大雑把なものである。何を研究しているかに大きく依存する。小さな効果が実務上きわめて重要になる場面もある。だからこの表をあまり真に受けないでほしい。せいぜい大まかな目安である。

	効果量大きい	効果量小さい
有意な結果	差は実在し、 実務上も重要である	差は実在するが、 興味深くないかもしれない
有意でない結果	効果は観測されなかった	効果は観測されなかった

.....

の単純な指標は真の値と帰無仮説の値の差(つまり $\theta - \theta_0$) や、その差の大きさ $abs(\theta - \theta_0)$ といったものになるでしょう。

なぜ効果量を計算するのでしょうか。実験を行い、データを集め、仮説検定をしたら有意な効果が得られたとしましょう。有意な効果が得られたと言うだけでは足りないのでしょうか。それこそが仮説検定の目的ではないのでしょうか。まあ、ある意味では。確かに仮説検定をする目的は帰無仮説が誤りだと示そうとすることですが、私たちの関心はそれだけではありません。帰無仮説が $\theta = .5$ と主張していて、それが誤りだと示したとしても、話の半分しか語っていないのです。帰無仮説を棄却するということは $\theta \neq .5$ だと考えるということですが、 $\theta = .51$ と $\theta = .8$ では大違いです。 $\theta = .8$ だとわかったなら、帰無仮説が誤りであるだけでなく、大幅に誤っているようだ、ということになります。一方、帰無仮説の棄却には成功したものの、 θ の真の値は.51 にすぎないようだ、という場合を考えてみましょう(これは非常に大規模な研究でなければ起こりません)。確かに帰無仮説は誤りですが、効果量がとても小さいので、それを気にする必要があるのかどうかはまったくはっきりしません。私の ESP 研究の文脈なら、本物の超能力が示されるというのはなかなか痺れる話ですから、それでも気にするかもしれません^{*10} が、他の文脈では、たとえ本物の差であっても 1% の差はふつうあまり興味深くありません。たとえば高校の試験成績の男女差を見ていて、女性の得点が平均して男性より 1% 高いとわかったとしましょう。何千人もの生徒のデータがあれば、この差はほぼ確実に統計的に有意になりますが、p 値がどれだけ小さくしようと、あまり興味深い話ではありません。こんな小さな差をもとに男子教育の危機だと触れ回りたいとは思わないでしょう。こうした理由から、仮説検定の結果とあわせて何らかの標準的な効果量の指標を報告することが、ゆっくりとではあれ確実に標準になりつつあります。仮説検定そのものは、観測された効果が実在すると信じてよいか(つ

^{*10} もっとも実際には、効果量が非常に小さいのは心配なことです。ごく些細な方法論上の欠陥がその効果の原因かもしれませんし、完璧な実験など存在しませんから、方法論上の懸念は常にあるのです。

まり単なる偶然ではないか) を教えてくださいますが、効果量はそれを気にすべきかどうかを教えてくださいます。

8.9.3 研究の検定力を高める

当然のことながら、科学者は自分の実験の検定力を最大にすることにかなり執着します。実験がうまくいってほしいのですから、帰無仮説が誤りである場合にそれを棄却できる見込みを最大にしたいわけです(そしてもちろん、たいていは誤りであってほしいと思っています)。見てきたように、検定力に影響する要因のひとつが効果量です。ですから検定力を高めるためにまずできるのは、効果量を大きくすることです。実際には、効果量が大きくなるように研究をデザインしたい、ということになります。たとえば私の ESP 研究なら、超能力は静かで暗く、心を曇らせる雑音の少ない部屋でいちばんよく働くと考えられるかもしれません。ですからそういう環境で実験をやろうとするでしょう。なんらかの形で人々の ESP 能力を強められれば、 θ の真の値は上がります^{*11} ので、効果量も大きくなります。要するに、賢い実験デザインは効果量を変えられますので、検定力を高める方法のひとつなのです。

残念ながら、最良の実験デザインをもってしても効果が小さいまま、ということはよくあります。たとえば ESP は本当に存在するけれども、最良の条件でもきわめて弱い、ということもあるでしょう。そうした状況で検定力を高めるいちばんの手は、標本サイズを大きくすることです。一般に、使える観測が多いほど、2つの仮説を区別できる見込みは高くなります。ESP 実験を 10 人でやって 7 人が隠されたカードの色を当てたととしても、あなたはたいして感心しないでしょう。しかし 10,000 人でやって 7,000 人が正解したなら、私が何かを発見したと考える可能性はずっと高くなるはずで、つまり検定力は標本サイズとともに大きくなります。これを図 8.8 に示しました。帰無仮説が $\theta_0 = 0.5$ を予測するとして、真のパラメータが $\theta = 0.7$ の場合の検定力を、標本サイズ N が 1 から 100 までのすべてについて描いたものです。

検定力は重要ですから、実験をやろうと考えているときには、どれくらいの検定力が見込めるかを知っておくとかかなり役に立ちます。本当の効果量を知ることはできませんので、確実に知ることは決してできません。しかし、どれくらいの大きさになるかを推測できることはよく(まあ、ときどき)あります。そうであれば、必要な標本サイズを推測できるわけです。この考え方は**検定力分析**と呼ばれ、実行可能であればとても役に立ちます。実験をうまくやり切るだけの時間や資金があるかどうかを教えてくださいます。検定力分析は実験デザインに必須とすべきだと主張する人も増えていきますので、知っておく価値はあります。ただし本書では検定力分析を扱いません。これはひとつにはつまらない理由から、ひとつには実質的な理由からです。つまらない理由は、検定力分析について書く

^{*11} 真の母集団パラメータ θ が、必ずしも自然の不変の事実に対応しているわけではないことに注意してください。この文脈での θ は、別の部屋にあるカードの色を人が正しく当てる真の確率にすぎません。ですから母集団パラメータはさまざまなものの影響を受けます。もちろん、これはすべて ESP が実際に存在するという前提の上での話ですが。




Figure 8.8 検定力を標本サイズ N の関数として描いたもの。この場合、 θ の真の値は 0.7 だが、帰無仮説は $\theta = 0.5$ である。全体として、 N が大きいほど検定力は高い。(この関数に見られる小さなギザギザは、 θ と α 、そして二項分布が離散的であることとの奇妙な相互作用によるもので、まじめな目的には影響しない。)

時間がまだないからです。実質的な理由は、私が検定力分析をまだ少し疑っているからです。研究者としての実感では、検定力分析ができる立場に置かれたことはめったにありません。たいていは (a) 自分の実験が少し標準から外れていて効果量をどう定義すればよいかわからないか、(b) 効果量がどうなるか本当に見当がつかず、答えをどう解釈すればよいかわからないか、のどちらかなのです。それだけでなく、統計コンサルティングを生業にしている人 (たまたま私の妻です) とさんざん話をきて気づかざるをえないのは、実際に検定力分析を頼まれるのが、助成金の申請書を書く手伝いをしているときだけだ、ということです。つまり現実には科学者が検定力分析を求めるのは、お役所的な手続きによってやらされるときだけのように見えるのです。誰の日常の仕事の一部にもなっていません。要するに私は、検定力は重要な概念だけれども、検定力分析は世間で言われるほど有用ではない、とずっと考えてきました。例外は、(a) あなたの実際の実験デザインについて検定力の計算法が誰かによって明らかにされていて、かつ (b) 効果量がどれくらいになるかについてかなりよい見通し

がある、というまれな場合だけです*¹²。私よりよい経験をしている人もいるかもしれませんが、個人的には (a) と (b) の両方が成り立つ状況に置かれたことは一度もありません。将来は考えが変わるかもしれませんが、本書の将来の版では検定力分析をもっと詳しく論じることになるかもしれませんが、いまのところこの話題について気持ちよく言えるのはこのくらいです。

8.10

考えておくべきいくつかの問題

この章で説明してきたのは、帰無仮説有意性検定 (NHST) の正統的な枠組みです。NHST の仕組みを理解することは絶対に必要です。20 世紀初頭に台頭して以来、推測統計の支配的なアプローチであり続けてきたからです。現役の科学者の大多数がデータ分析でこれに頼っていますので、嫌いであっても知っておく必要があります。とはいえ、このアプローチに問題がないわけではありません。枠組みにはいくつかの癖がありますし、成立の経緯には歴史的な奇妙さがあり、枠組みが正しいかどうかをめぐる理論的な論争もあり、うっかりすると陥る実践的な罠もたくさんあります。この話題を詳しく扱うつもりはありませんが、いくつかの問題については簡単に触れておく価値があると思います。

8.10.1 Neyman と Fisher

まず知っておくべきなのは、正統的な NHST が実際にはかなり異なる 2 つの仮説検定のアプローチ、つまり Ronald Fisher 卿が提案したものと Jerzy Neyman が提案したものの寄せ集めだ、ということです (歴史的な要約は [Lehmann 2011](#), を参照)。歴史がややこしいのは、Fisher も Neyman も生身の人間であり、その意見は時とともに変わりましたし、何十年もあとの私たちが彼らの仕事をどう解釈すべきかについて “決定的な言明” を残したことは一度もなかったからです。そのうえで、この 2 つのアプローチについての私の理解を手短にまとめておきます。

まず Fisher のアプローチから話しましょう。私の理解する限り、Fisher は仮説はひとつ (帰無仮説) しかなく、やりたいのは帰無仮説がデータと矛盾するかどうかを調べることだ、と考えていました。彼の見方では、やるべきことは帰無仮説のもとでデータが “十分にありそうにない” かどうかを確かめることです。実際、先ほどの議論を思い出せば、それが Fisher の p 値の定義でした。Fisher によれば、帰無仮説がデータをうまく説明できないなら、安心してそれを棄却できます。しかし比較する他の仮説がないのですから、“対立仮説を採択する” ことはできません。明示的に述べられた対立仮説が必ずしもないからです。だいたいそれで全部です。

*¹² これに対するひとつの例外は、研究者が新しい医療的治療の効果を調べていて、たとえば既存の治療を上回るものとして、検出すべき重要な効果量をあらかじめ指定する場合でしょう。このやり方であれば、新しい治療の潜在的な価値についてある程度の情報が得られます。

これに対して Neyman は、仮説検定の眼目は行動の指針にあると考えており、そのアプローチは Fisher よりいっくらか形式的でした。彼の見方では、取りうる行動は複数あり (帰無仮説を採択するか対立仮説を採択するか)、検定の眼目はデータがどちらを支持しているかを教えることにあります。この立場からすると、対立仮説をきちんと指定することが決定的に重要です。対立仮説が何かわからなければ、検定の検定力もわかりませんし、どの行動が理にかなうのかもわかりません。彼の枠組みは、異なる仮説どうしの競争を本当に必要とするのです。Neyman にとって p 値は、帰無仮説のもとでのデータ (あるいはより極端なデータ) の確率を直接測るものではなく、どの “ありうる検定” が帰無仮説の採択を告げ、どの “ありうる検定” が対立仮説の採択を告げるかについての、より抽象的な記述でした。

このように、今日私たちが手にしているのは 2 つの奇妙な混ぜ物です。帰無仮説と対立仮説の両方があるという話をしますが (Neyman), p 値はたいてい^{*13} 極端なデータという言葉で定義します (Fisher)。それでいて α の値もあります (Neyman)。統計的検定のなかには対立仮説が明示されているもの (Neyman) もあれば、その点がかなり曖昧なもの (Fisher) もあります。そして少なくとも一部の人のによれば、対立仮説を採択するという言い方は許されません (Fisher)。ごちゃごちゃしていますが、なぜごちゃごちゃしているのかは少なくとも説明できたと思います。

8.10.2 ベイズ主義者と頻度主義者

この章の前のほうで、 p 値を帰無仮説が正しい確率として解釈することはできないと強く述べました。NHST は根本的に頻度論の道具であり (Chapter 6 参照), そうであるがゆえに仮説に確率を割り当てることを許しません。帰無仮説は正しいか正しくないかのどちらかです。統計へのベイズ的アプローチは確率を信念の度合いとして解釈しますので、帰無仮説が正しい確率は 10% だ、と言ってもまったく問題ありません。それはその仮説に対してあなたが持っている確信の度合いを表しているだけです。頻度論的なアプローチの中では、これは許されません。思い出してください。頻度主義者にとって確率は、独立な繰り返しを多数行った後に何が起こるか (つまり長期的な頻度) によってしか定義できません。この確率の解釈をとるなら、帰無仮説が正しい “確率” について語るのはまったくの戯言です。帰無仮説は正しいか誤りかのどちらかなのですから。この言明について長期的な頻度を語る方法などありません。“帰無仮説の確率” について語ることは、“自由の色” について語るのと同じくらい無意味です。そんなものはないのです。

もっとも重要なのは、これが純粋にイデオロギーの問題ではないということです。自分はベイズ主義者であり、仮説について確率を語ってよいと決めたのなら、その確率を計算するためのベイズのルールにしたがわなければなりません。これについては Chapter 15 でさらに述べますが、いま指摘

*13本書は Neyman と Fisher の両方の p 値の定義を説明していますが、ほとんどの本はそうしません。入門的な教科書のほとんどは Fisher のほうしか載せません。

しておきたいのは、 p 値が H_0 の正しい確率の近似としてはひどいものだ、ということです。帰無仮説の確率が知りたいのなら、 p 値はあなたの探しているものではありません。

8.10.3 罨

このように仮説検定の背後にある理論はごちゃごちゃしていて、いまなお統計学の中ではそれが“どう”あるべきかについての議論があります。とはいえ、統計学者どうしの意見の相違はここでの本当の関心事ではありません。本当の関心事は実践的なデータ分析です。帰無仮説有意性検定の“正統的な”アプローチには多くの欠点がありますが、私のような筋金入りのベイズ主義者でさえ、責任をもって使えば有用でありうることは認めます。たいていの場合はまともな答えを出しますし、それを使って興味深いことを学べます。これまで論じてきたさまざまなイデオロギーや歴史的な混乱はさておき、統計全体でいちばん危険なのは考えないことだという事実は変わりません。愚かさという意味ではなく、文字どおり考えないということです。それぞれの検定がデータについて実際に何を語っているのかを時間をかけて考え、自分の解釈がそれと整合しているかを確かめることなく、結果の解釈へ急いでしまうことです。そこにいちばん大きな罨があります。

その例として、次のようなものを考えてみましょう (Gelman and Stern 2006, を参照)。ESP 研究を実施していて、男性参加者と女性参加者でデータを別々に分析することにしたとします。男性参加者では、50 人中 33 人がカードの色を正しく当てました。これは有意な効果です ($p = .03$)。女性参加者では、50 人中 29 人が正しく当てました。これは有意な効果ではありません ($p = .32$)。これを見ると、超能力に男女差があるのはなぜだろうと考え始めたくなる誘惑がきわめて強くなります。しかしこれは間違いです。考えてみれば、男性と女性を明示的に比較する検定を実際には実行していません。やったのは男性を偶然と比べること (二項検定は有意) と、女性を偶然と比べること (二項検定は有意でない) だけです。男性と女性のあいだに本当に差があると主張したいのなら、差がないという帰無仮説の検定を実行すべきでしょう。別の仮説検定^{*14}を使えばそれができますが、やってみると男性と女性が有意に異なるという証拠は得られません ($p = .54$)。それでも 2 つの群のあいだに根本的な違いがあると思うのでしょうか。もちろん思わないはずですが。ここで起きているのは、両方の群 (男性と女性) のデータがどちらもかなり境界線上にある、ということです。純粋な偶然によって、一方が $p = .05$ という線の魔法の側にたまたま落ち、もう一方は落ちなかったのです。それは男性と女性が異なるということを意味しません。この誤りはとてもよくあるものですので、常に警戒しておくべきです。有意と有意でないの違いは、本当の差の証拠ではありません。2 つの群のあいだに差があると言いたいのなら、その差を検定しなければならないのです。

上の例はあくまで一例にすぎません。とてもよくある誤りなので取り上げましたが、大きく言えば、データ分析を正しく行うのは厄介だということです。何を検定したいのか、なぜそれを検定したいのか、そして検定の出す答えが現実世界で何らかの意味をなすのかを、よく考えてください。

^{*14} この場合は Pearson のカイ二乗独立性検定です (Chapter 9)。

Part IV.

統計の道具

9. カテゴリカルデータの分析

仮説検定に関する基本的なことを学んだうえで、今度は心理学でよく使われる検定について見ていきましょう。では、どこから始めればよいのでしょうか。全ての教科書がスタート地点に関する合意を持つわけではないのですが、ここでは“ χ^2 検定”（この章では、“カイ二乗（にじょう）chi-square”と発音します^{*1}）と“t-検定”（Chapter 10）から始めます。これらの検定は科学的実践において頻繁に使用されており、“回帰”（Chapter 11）や“分散分析”（Chapter 12）ほど強力ではないのですがそれらよりはるかに理解しやすいものとなっています。

“カテゴリカルデータ”という用語は“名義尺度データ”の別名に過ぎません。説明していないことなく、ただデータ分析の文脈では、“名義尺度データ”よりも“カテゴリカルデータ”という言葉を使う傾向があるのです。なぜかは知りません。なににせよ、**カテゴリカルデータの分析** はあなたのデータが名義尺度の際に適用可能なツールの集合を指示しています。しかし、カテゴリカルデータの分析に使用できるツールには様々なものがあり、本章では一般的なツールの一部のみを取り上げます。

9.1

The χ^2 (カイ二乗) 適合度検定

χ^2 適合度検定は、最も古い仮説検定の一つです。この検定は世紀の変わり目に Karl Pearson 氏が考案したもので（Pearson 1900）、Ronald Fisher 氏によっていくつかの修正が加えられました（Fisher 1922a）。名義尺度変数に関する観測度数分布が期待度数分布と合致するかどうかを調べます。例えば、ある患者グループが実験的処置を受けており、彼・彼女らの状況が改善されたか、変化がないか、悪化したかを確認するために健康状態が評価されたとします。各カテゴリー（改善、変化なし、悪化）の数値が、標準的な処置条件で期待される数値と一致するかどうかを判断するために、

^{*1}また“カイ二乗（にじょう）chi-squared”とも呼ばれる

適合性検定は適用できます。もう少し、心理学を交えて考えてみましょう。

9.1.1 カードデータ

何年にもわたる多くの研究が、人が完全にランダムにふるまおうとすることの難しさを示しています。ランダムに「行動」しようとしても、我々はパターンや構造に基づいて考えてしまいます。そのため、「ランダムになにかをしてください」と言われたとしても人々が実際に行うことはランダムなものにはなりません。結果として、人のランダム性 (あるいは非ランダム性) に関する研究は、我々が世界をどのように捉えているのかについての深遠な心理学的問いを数多く投げかけます。このことを念頭に置いて、非常に簡単な研究について考えてみましょう。シャッフルされたカードのデッキを想像して、このデッキの中から「ランダムに」一枚のカードを頭の中で選ぶようお願いしたとします。一枚目のカードを選んだ後、二枚目のカードを心の中で選択してもらいます。二つの選択に関して、注目するのは選ばれたカードのマーク (ハート、クラブ、スペード、ダイヤモンド) です。これをたとえば $N = 200$ にやってもらうよう依頼した後、選択されようとしたカードが本当にランダムに選ばれているかどうかをデータを確認して調べてみましょう。データは `randomness.csv` に入っており、JASP で開くと 3 つの変数が表示されるでしょう。変数 `id` は各参加者に対する一意識別子であり、二つの変数 `choice_1` と `choice_2` は参加者が選択したカードのマークを意味しています。

今回は、参加者の選んだ最初の選択肢に注目してみましょう。'Descriptives' - 'Descriptive Statistics' の下にある [Frequency tables](#) オプションを選択して、選択された各マークの数をカウントしてみましょう。以下が得られたものです:

クラブ	ダイヤモンド	ハート	スペード
35	51	64	50

この小さな度数分布表はとても有益です。この表を見れば、人はクラブよりもハートを選びやすい *it* かもしれないというわずかなヒントを得られますが、それが実際にそうであるのか偶然の賜物であるのかどうかは見るだけでは明らかではありません。なので、それを知るためにはなんらかの統計分析をしなければならないでしょう。それが、次のセクションでお話することになります。

よろしい。ここからは、先ほどの表を分析対象のデータとして扱います。しかしながら、このデータについて数学的に語らなければならないために、表記の意味について明確にしておくことは大事でしょう。数学的表記では、人が読める単語である "observed (観測された)" を文字 O に短縮して、観測位置を示すために下付き文字を使用します。なので、この表における二番目の観測変数は数学では O_2 として記述します。日本語表記と数学記号の関係を以下に示します:

ラベル	インデックス, i	数学. シンボル	数値
クラブ, ♣	1	O_1	35
ダイヤモンド, ◇	2	O_2	51
ハート, ♥	3	O_3	64
スペード, ♠	4	O_4	50

これではっきりしたでしょう。また、数学者は特定の事柄よりも一般的な事柄について話したがるので、 O_i という表記が見られるでしょう。これは、 i 番目のカテゴリーに属する観測変数を意味します (i は 1、2、3、4 のいずれか)。最後に、観測された頻度数に言及したい場合、統計家は観測値をベクトル^{*2}に分類します。これは、太字を使用して $\mathbf{bmO}$ とします。

$$\mathbf{O} = (O_1, O_2, O_3, O_4)$$

繰り返しますが、これは新しいものでも興味深いものでもありません。ただの表記です。 $\mathbf{O} = (35, 51, 64, 50)$ ということ、私がしているのは観測された度数表の記述 (i.e., *observed*) ですが、数学表記を用いてそれを参照します。

9.1.2 帰無仮説と対立仮説

先ほどのセクションで指摘したように、我々の研究仮説は「人はカードをランダムに選択しない」です。これから行いたいことはこれを統計的仮説に変換してから、それらの仮説に関する統計検定を構築することです。説明予定のテストはピアソンの χ^2 (カイ二乗) 適合度検定であり、よくあることですが、まずは帰無仮説の注意深い構築から始めなければなりません。今回はかなり簡単です。まず、帰無仮説を言葉にしてみましょう:

H_0 : 4 つ全てのマークは同じ確率で選択される

さて、これは統計学なので、同じことを数学っぽく言えなければなりません。これをするために、 j 番目のマークが選ばれる場合の真の確率を参照するときには表記 P_j を用いましょう。もし帰無仮説が真であれば、4 つのマークがそれぞれ 25% の確率で選択されます。言い換えれば、帰無仮説は $P_1 = .25, P_2 = .25, P_3 = .25$ そして $P_4 = .25$ としたものです。ただし、観測された頻度数をデータ全体の要約ベクトル $\mathbf{O}$ として分類するように、帰無仮説と対応する確率として $\mathbf{P}$ を用います。そのため、帰無仮説を記述する確率の集合を $\mathbf{P} = (P_1, P_2, P_3, P_4)$ とすると、以下のようになります:

H_0 : $\mathbf{P} = (.25, .25, .25, .25)$

この例では、帰無仮説は全ての確率が互いに等しい確率のベクトル $\mathbf{P}$ と対応します。しかし、常に

^{*2}ベクトルは同じ基本型のデータ要素のシーケンスです

そうである必要はありません。例えば、もし実験課題で他のマークの2倍クラブが含まれているデッキを想像してもらう場合には、帰無仮説は $P = (.4, .2, .2, .2)$ となるでしょう。確率がすべて正の値であり、その合計が1である限りは、それは帰無仮説として正当な選択です。ですが、適合度検定では一般的に全てのカテゴリーが同様の確率である帰無仮説を用います。そのため、ここではそれに固執します。

対立仮説 H_1 はどうでしょうか？ 我々の関心は、関係する確率が全て同じではないこと（つまり、人々の選択が完全にランダムではなかったこと）を実証することです。その結果、「人にやさしい（負担の小さい）」バージョンの仮説はこんな感じです：

H_0 : 4つのマークが同じ確率で選択される

H_1 : 少なくとも1つのマークの選択確率が0.25ではない

そして「数学者にやさしい」バージョンはこうです：

H_0 : $P = (.25, .25, .25, .25)$

H_1 : $P \neq (.25, .25, .25, .25)$

9.1.3 “適合度” 検定の統計量

この段階で、観測された頻度数 O と検定予定の帰無仮説と対応する確率の集合である P を我々は手にしています。ここでしたいことは、帰無仮説検定の構築です。いつものように、 H_1 に対して H_0 を検定したい場合には、検定統計量が必要です。適合度検定の基本的なトリックは、データが帰無仮説にどれだけ「近いのか」を測定する検定統計量を組み立てることです。もし帰無仮説が真であるときの「期待値」がデータと似ていなければ、帰無仮説は真ではないでしょう。オーケー、帰無仮説が真であるならどうなるだろう？ 正しい言い方をすれば、「期待度数」とは何かということです。 $N = 200$ の観測データがあり、（もし帰無仮説が真であれば）ハートの選択確率は $P_3 = .25$ で、ハートの期待値は $200 \times .25 = 50$ ですね？ より具体的には、もし E_i が、「帰無仮説が真であるときにカテゴリー i の選択数の期待値」とすると次のようになります。

$$E_i = N \times P_i$$

この計算はとても簡単です。もし4つのカテゴリーに分類されうる200個の観測データがあって、カテゴリー全ての選択確率が同じだとすれば、各カテゴリーの観測データは50であると期待されますよね？

さて、これをどのように検定統計量に変換するのでしょうか？ 明らかに、我々のしたいことは各カテゴリーの期待値 (E_i) と観測値 (O_i) の比較です。そしてこの比較に基づいて、我々は良い検定統計量を導き出すことができるはずです。まずは、帰無仮説が期待した結果と我々が実際に得られた結果との差を計算しましょう。つまり、「観測値から期待値を引いた」差得点である $O_i - E_i$ を計算

します。これを図示すると次の表のようになります。

		♣	◇	♡	♠
期待度数	E_i	50	50	50	50
観測度数	O_i	35	51	64	50
差得点	$O_i - E_i$	-15	1	14	0

つまり我々の計算によって、帰無仮説の予測よりも人はハートを多く、クラブを少なく選択していることがわかりました。しかし、ちょっと考えてみると、この素朴な違いは、私たちが求めているものとはちょっと違うようです。直観的に、帰無仮説の予測が少なすぎた場合（ハート）も予測が多すぎた場合（クラブ）も同程度によくないことに感じられます。なので、クラブではマイナスでハートではプラスだというのはちょっと変な感じです。これを解決する一つの簡単な方法は全てを二乗することで、ここでは二乗された差を計算します $(O_i - E_i)^2$ 。前回同様、これは手作業でできます：

		♣	◇	♡	♠
期待度数	E_i	50	50	50	50
観測度数	O_i	35	51	64	50
差得点	$O_i - E_i$	-15	1	14	0
二乗差	$(O_i - E_i)^2$	225	1	196	0

さあ、これで一步前進です。今手にしているものは、帰無仮説が悪い予測をしたときには大きく（クラブとハート）、良い予測をしたときには小さくなる数の集合です。次は、後述予定の技術的理由により、それらの数を期待度数 E_i で割って、調整された二乗値 $\frac{(E_i - O_i)^2}{E_i}$ を計算しています。今回の例では全てのカテゴリーで $E_i = 50$ となるので、あまり面白い計算ではないですが、とりあえずやってみましょう：

		♣	◇	♡	♠
期待度数	E_i	50	50	50	50
観測度数	O_i	35	51	64	50
差得点	$O_i - E_i$	-15	1	14	0
二乗差	$(O_i - E_i)^2$	225	1	196	0
調整済み二乗差	$(O_i - E_i)^2 / E_i$	4.50	0.02	3.92	0.00

要するに、ここで得たのは4つの「エラー」得点で、それぞれが観測度数に対する帰無仮説の予測から生じた「間違い」の大きさを示しています。そして、これを一つの有用な検定統計量に変換するためには、それらの数を単に足し合わせることが一つのやり方です。その結果を **適合度:goodness-of-fit** とよび、慣習的には χ^2 (カイ二乗) または (頭文字をとって) GOF とよばれています。4.50 + 0.02 + 3.92 + 0.00 = 8.44 として計算可能です。

k をカテゴリーの総数だとすれば (i.e., カードデータの例だと $k = 4$)、 χ^2 統計量は以下のように与えられます：

$$\chi^2 = \sum_{i=1}^k \frac{(O_i - E_i)^2}{E_i}$$

直観的に、もし χ^2 が小さければ観測データ O_i が帰無仮説の予測する E_i に近づき、帰無仮説を棄却するためには大きな χ^2 が必要となるはずです。

計算の結果、カードデータセットでは $\chi^2 = 8.44$ という値が得られました。次の疑問はこれが帰無仮説を棄却するのに十分な値なのか、ということです。

9.1.4 適合度の標本分布

χ^2 の値が帰無仮説を棄却するほどに大きいかどうかを決めるために、帰無仮説が真である場合の χ^2 に関する標本分布はどうなるかを理解する必要があります。ということで、今回のセクションではそれをやっていきます。この標本分布がどのように構成されるかの詳細をお見せして、次のセクションではそれを仮説検定の構築に用います。さて本題。標本分布が $k - 1$ の自由度を持つ χ^2 (カイ二乗) 分布であると喜んで受け入れる人は、このセクションの残りをスキップできます。しかし、もし適合度検定の仕組みを理解したいひとは、ぜひこの先をお読みください。

よし、帰無仮説が実際に真であると仮定しましょう。もしそうであれば、ある観測変数が i 番目のカテゴリーに属する真の確率は P_i となります。まあ結局、それはほぼほぼ帰無仮説の定義です。これが意味するところについて考えます。これは、「自然」が、重み付きのコイン (i.e., 表が出る確率は P_i) を裏返すことで観測値がカテゴリー i に含まれるかどうかを決定するというようなものです。したがって、自然がこれらのコインの N を反転させること (データセット内の観測ごとに1つ) を想像して、正確に O_i を頭に浮かべることで、観測された頻度 O_i を考えることができます。明らかに、これは実験を考える上ではかなり奇妙なやり方です。ですが、このシナリオには見覚えがありますね (と私は期待してますよ)。セクション 6.4、二項分布のケースとまったく同じ設定です。言い換えれば、帰無仮説が真であれば、観測された度数は二項分布のサンプリングによって生成されたことになります。

$$O_i \sim \text{Binomial}(P_i, N)$$

中心極限定理 (Section 7.3.3) の説明を思い出すと、特に N が大きく P_i が 0 または 1 に近すぎない時に、二項分布は正規分布と近似して見えるようになります。いいかえれば、 $N \times P_i$ が十分に大きければいいのです。また、別の言い方をすれば、期待度数 E_i が十分に大きい場合 O_i の理論的な分布は近似的に正規分布となります。さらにいえば、 O_i が正規分布していれば、そのとき $(O_i - E_i)/\sqrt{E_i}$ も正規分布します。 E_i は固定の値なので、 E_i を引いて $\sqrt{E_i}$ で割ることで正規分布の平均と標準偏差が変化しますが、それだけです。では早速、適合度統計量とはなにかについて見て

いきましょう。今しているのは正規分布するものをたくさん集めて、二乗して、それからそれらを足し合わせているのです。おっと。これも見たことがありますね！ セクション 6.6 でお話ししたように、標準正規分布 (i.e., 平均 0, 標準偏差 1) を持つものをたくさん集めて二乗してから足し合わせると、その結果はカイ二乗分布となります。これで適合度統計量の標本分布がカイ二乗分布であることを帰無仮説が予測している、ということがわかりました。イイね。

最後にもう一つ、いわゆる自由度についてお話しときましょう。セクション 6.6 を思い返せば、足し合わせるものの数は k 、結果として生じるカイ二乗分布の自由度は k になると言いましたね。しかし、このセクションの冒頭で述べたのはカイ二乗適合度検定の自由度は $k - 1$ であるということです。どうしたのでしょうか？ ここでの答えは、私たちが注目しているのは、純粋に独立したものが同時に足し合わされている数だということです。また、次のセクションでお話ししますが、たとえ k 個分追加したとしても真に独立しているのは $k - 1$ 個のみであり、自由度は $k - 1$ だけです。それが次のセクションでの話題です。^{*3}

9.1.5 自由度

セクション 6.6 でカイ二乗分布を紹介したときに、「自由度」が実際に意味するところは少し曖昧でした。明らかに、そこは重要な点です。Figure 9.1 を見ると、自由度を変化させるとカイ二乗分布の形がかなり大きく変わっています。しかし、それはなんなのでしょう？ 分布を紹介して正規分布との関係性を説明したときに、ある答えを提供しました：私が二乗して足し合わせた「正規分布する」数です。ですが、多くの人にとって、それは抽象的でちっとも参考になりません。ここで本当に目指すべきなのは、我々の持つデータを用いて自由度を理解することです。ではいってみましょう。

自由度の基本的な考え方はとてもシンプルです。データの記述に使用する明確な「量」を数え上げることで計算して、それらのデータが満たさなければならない「制約」をすべて引き算します。^{*4} これでは少し曖昧なので、具体的な例としてのカードデータを使いましょう。4 カテゴリー（ハート、クラブ、ダイヤモンド、スペード）の観測度数に対応する O_1, O_2, O_3, O_4 の 4 つを用いてデータを記述します。それら 4 つの数が今回の実験でのランダムな結果です。しかし、実験には固定の制約が組み込まれています：サンプルサイズが N 。^{*5} つまり、ハートを選んだ人の数、ダイヤモンドを

^{*3}もし適合度統計量の式を $k - 1$ の独立したものの数の和として書き直すと、 $k - 1$ の自由度を持つカイ二乗の「適切な」標本分布を得られます。その数学の詳細を示すことは入門書の範囲を逸脱しています。ここでしたいのは、なぜ適合度統計量がカイ二乗分布と関連しているのかについて理解してもらうことです。

^{*4}これは単純すぎると指摘せざるを得ないとは思っています。大体はその説明でうまくいくんですが、整数ではない自由度の値に出くわすこともあります。気にしすぎることはありません；そんなときは「自由度」が少し厄介な概念であり、私がここでしているような単純なストーリーがすべてではないことを思い返してください。入門編では単純なストーリーに固執するのがいいんですが、このストーリーが崩壊することは事前に警告しておくのがベストだと思います。もし警告がなければ $df = 3.4$ みたいなのを目にしたときに混乱してしまい、(正確に) 私が教えなかったことに気付くのではなく (不正確に) 私が教えたことを誤解したんじゃないかと考えてしまいます。

^{*5}実際問題として、サンプルサイズは常に固定されていません。例えば、一定期間にわたって実験をする際に参加者数は参加する人数に依存しているかもしれません。まあそれは今の目的には関係ないです。




Figure9.1 「自由度」の異なる χ^2 (カイ二乗) 分布。

選んだ人の数、クラブを選んだ人の数がわかれば、スペードを選んだ数は正確に把握できます。言い換えれば、4つの数を用いてデータが記述されますが、実際には $4 - 1 = 3$ の自由度にしか対応していません。ちょっと違う考え方は、関心のある4つの確率があること(ここでも4つのカテゴリに対応します)に注意することですが、それらの確率の合計値は1でなければならないという制約が課されます。そうすると自由度は $4 - 1 = 3$ になります。観測度数の観点から考えたいのか、確率の観点から考えたいのかに関係なく、答えは同じです。一般的に、 k グループを含む実験で χ^2 (カイ二乗) 適合度検定を実行すると、自由度は $k - 1$ になります。

9.1.6 帰無仮説検定

仮説検定を構築するプロセスの最終段階は、棄却域とは何なのかを理解することです。いわば、 χ^2 の値によって帰無仮説が棄却されます。以前のように、 χ^2 の値が大きいということは帰無仮説が実験データの予測を行うのに不十分であったことを意味します。一方で χ^2 の値が小さいということは帰無仮説が支持されていることを意味します。したがって、 χ^2 が棄却値よりも大きいければ帰無仮説を棄却し、 χ^2 が棄却値よりも小さければ帰無仮説を保持する、というのは非常に賢明なやり方です。チャプター 8 で紹介した言語を使えば、カイ二乗適合度検定は常に **片側検定** です。そのとおり。あとはこの重要な値が何であるかを考えればいいわけです。そしてそれはとても簡単です。もし




Figure 9.2 χ^2 (カイ二乗) 適合度検定で仮説検定がどのように機能するのかを示す図。

有意水準を $\alpha = .05$ と設定して (すなわち、Type1 エラーを 5% で許容する) 検定を行いたい場合、帰無仮説が真である際に χ^2 がその値を超える可能性が 5% になるように、棄却値を選択する必要があります。これを示したのが図 9.2 です。

ああ、ですが、あなたの質問が聞こえてくるようです、 $k - 1$ の自由度を持つカイ二乗分布の棄却値はどのように見つけましょうか？ 何年も前に私が最初に心理統計の講義を受講した際に、図 9.3 のような棄却値表でそれらの棄却値を調べていました。この図を見ると、 $p=0.05$ で自由度 3 の χ^2 分布の棄却値は 7.815 であることがわかります。

なので、もし計算された χ^2 統計量が棄却値 7.815 よりも大きければ、帰無仮説を棄却できます (帰無仮説 H_0 は 4 つのマークが同じ確率で選択される、ということを思い出してくださいね)。以前実際に計算したので (i.e., $\chi^2 = 8.44$)、帰無仮説は棄却できます。基本的にはこれで終わりです。いまや「適合度に関するピアソンの χ^2 検定」がわかりましたね。ラッキーですね。

9.1.7 JASP でのやり方

当然ですが、JASP はこれらの計算を行う分析を提供します。メインの 'Analyses' ツールバーから 'Frequencies' - 'Multinomial Test' を選択しましょう。次に、表示される分析ウィンドウで、分

Degrees of Freedom	Probability								
	0.95	0.90	0.70	0.50	0.30	0.10	0.05	0.01	0.001
1	0.004	0.016	0.148	0.455	1.074	2.706	3.841	6.635	10.828
2	0.103	0.211	0.713	1.386	2.408	4.605	5.991	9.210	13.816
3	0.352	0.584	1.424	2.366	3.665	6.251	7.815	11.345	16.266
4	0.711	1.064	2.195	3.357	4.878	7.779	9.488	13.277	18.467
5	1.145	1.610	3.000	4.351	6.064	9.236	11.070	15.086	20.515
6	1.635	2.204	3.828	5.348	7.231	10.645	12.592	16.812	22.458
7	2.167	2.833	4.671	6.346	8.383	12.017	14.067	18.475	24.322
8	2.733	3.490	5.527	7.344	9.524	13.362	15.507	20.090	26.124
9	3.325	4.168	6.393	8.343	10.656	14.684	16.919	21.666	27.877
10	3.940	4.865	7.267	9.342	11.781	15.987	18.307	23.209	29.588
	Non-significant						Significant		

Figure9.3 カイ二乗分布の棄却値表

析したい変数 (*choice_1*) を 'Factor' ボックスに移動します。また、'Descriptives' のチェックボックスをクリックして、結果の表に期待度数を表示しましょう。これら全てを実行すると、図 9.4 のように JASP 上で分析結果が表示されます。JASP では上記で手計算したのと同じ期待度数と統計量が得られ、自由度 3 の χ^2 値はもちろん 8.44 となります。そこで $p=0.038$ です。JASP が 自由度 3 の χ^2 値による p 値を出してくれるので、棄却する p 値のしきい値を見る必要がなくなりました。

9.1.8 異なる帰無仮説の指定

適合度検定をしたいけれど、全てのカテゴリーが同じように選択されないという帰無仮説を持っている場合にはどうしたらいいか、現段階では疑問に思うかもしれません。例えば、赤のカードを 60%、黒のカードを 40% で選ぶはずだ、という理論的予測をした人がいて (なぜそんな予測をしたのかはわかりませんが)、他の好みがなかったとしましょう。もしそうであれば、ハート、ダイヤモンドが 30%、スペード、クラブが 20% で選択される確率を持った帰無仮説になります。いいかえればハートとダイヤモンドはそれぞれ 60 回 (200 回中の 30% なので 60 回です) 選択され、スペードとクラブはそれぞれ 40 回 (200 回中の 20% なので 40 回です) 選択されるでしょう。ばかばかしい理論ではありますが、それでも、この明示的に指定された帰無仮説を JASP のデータでテストするのは非常に簡単です。分析ウィンドウ (図 9.4 を見てください) で、'Expected Proportions (χ^2 test)' のラジオボタンをクリックできます。これをすれば、選択した変数に関する期待度数を入力するための選択肢が存在していて、我々の場合だとこれは *choice_1* です。図 9.5 にあるように新しい帰無




Figure9.4 JASP の χ^2 適合度検定で観測・期待度数を示しています。

仮説を反映した数に変化して、結果の変化を確認しましょう。




Figure9.5 JASP での χ^2 適合度検定における期待割合の変更

期待された度数はこの通りです：

	♣	◇	♥	♠
期待度数 E_i	40	60	60	40

そして自由度 3 の χ^2 統計量は 4.742 で $p = 0.192$ です。では、更新された仮説と期待度数の結果は前回のものとは異なっています。結果として χ^2 検定統計量と p 値は異なるものになっています。残念ながら p 値は .192 なので、帰無仮説を棄却できません (セクション 8.6 を振り返って、理由を思い出してください)。帰無仮説はばかばかしいものであるにもかかわらず、データはそれに対する十分なエビデンスを提供していません。

9.1.9 検定結果の報告方法

これで検定がどのように機能するのか、そして素晴らしい JASP 風味な魔法の計算箱を用いて検定を行うやり方がわかったでしょう。次に知る必要があることは結果をどのように報告するのかです。せっかく実験を設計・実行してデータを分析したのにそれをだれにも伝えなければ意味がありませんよ！ 分析を報告する際に必要なことについてお話ししましょう。これまでどおりカードマークの例で説明します。この結果をある論文なりなんなりに記述したいのであれば、通常の報告方法では次のように書きます：

実験に参加した 200 人のうち、最初にハートを選択したのが 64 人、ダイヤモンドを選択したのが 51 人、スペードを選択したのが 50 人、クラブを選択したのが 35 人でした。全マークの選択確率が同一であるかどうかを検定するために、カイ二乗適合度検定を行った。結果は有意であり ($\chi^2(3) = 8.44, p < .05$)、人は完全にランダムなマークの選択をしなかったことがわかります。

これはかなりわかりやすいですし、うまくいけば非常に無難な感じになります。とはいえ、この記述にはいくつか注意すべき点があります：

- 記述統計は統計的検定に先行する。つまり、検定を行う前にデータがどのようなものかを読み手に伝えたのです。一般的には、これは良い実践です。読み手があなたのデータをあなたのように理解しているわけではないことを常に念頭に置きましょう。あなたがデータを適切に記述しなければ、読み手は統計的検定の意味が理解できず泣き寝入りすることでしょう。
- 検定に用いた帰無仮説について記述する。正直に言うと、書き手は常にこれをする必要はありませんが、曖昧さが存在するような状況や読み手を使用されている統計ツールを熟知しているとは限らないときにはしばしばそれはいい考えなのです。ほとんどの場合、読み手はあなたの用いる検定の詳細について承知していない (あるいはおぼえていない) ので、それらを「思い出させる」のは一種の礼儀ですよ！ 適合度検定である限りは、科学者なら持っているであろう検定の知識に頼れるはずですが (統計学の入門でほとんどカバーされてますので)。しかし、帰

無仮説を（簡潔に！）明言化しておくのはそれでもいい考えです。なぜなら帰無仮説はあなたが検定に利用するものによっては異なる可能性がありますからね。これまでのカードの例でいえば、帰無仮説は4つのマークを選択する確率が同一（i.e., $P_1 = P_2 = P_3 = P_4 = 0.25$ ）というものでしたが、その仮説が特別なものというわけではありません。適合度検定に $P_1 = 0.7$ で $P_2 = P_3 = P_4 = 0.1$ という帰無仮説を適用することも簡単にできました。なので帰無仮説を説明しておくのは読み手にとって助かります。また、帰無仮説を数式でなく言葉に記述しましたが、それは全く問題ありません。もしお望みであれば、数式で記述することはできます。ですが、多くの読み手は記号よりも単語のほうが読みやすいので、書き手は帰無仮説をできる限り言葉で表現しがちです。

- 「統計ブロック」が含まれている。検定結果を報告するときには、結果がただ有意であったというだけでなく、「重要な」統計情報全てを報告する「統計ブロック」（i.e., 括弧の中にある数学っぽい部分）を含めました。カイ二乗適合度検定に関しては、報告された情報は検定統計量（適合度統計量が8.44）、検定に用いた分布（自由度3の χ^2 で $\chi^2(3)$ と短く表現される）、結果が有意であったかどうか（今回は $p < .05$ ）の情報です。統計ブロックに含める必要のある情報は検定によって異なり、新しい検定を紹介するたびに統計ブロックがどんな感じになるべきかを紹介します。^{*6}しかし、常に読み手が望めばその検定結果を確認できるように十分な情報を常に提供しておくというのは一般的な原則です。
- 結果が解釈されている。結果が有意であったことを示すのに加えて、結果の解釈を提供しました（i.e., 人はランダムなマークの選択をしなかった）。これもまた読み手に対する優しさです。なぜなら、それはデータに何が起きたのか、何を信じればいいかについての情報を読み手に伝えるからです。もしこういうのを含めなければ、何が起きているのかを読み手が理解するのは非常に困難でしょう。^{*7}

なんでもそうなんですが、読み手に対して説明することを第一に考えてください。結果を報告することは他の人間とコミュニケーションすることであることを常に覚えておくようにしましょう。私はこれまでに、書き手が全ての数字が含まれているかだけに専念して読み手とコミュニケーションすることを失念してしまったために、何度もレポート・論文・科学的文献でさえも結果セクション

^{*6}まあまあ。統計をどのように報告するべきかという慣習は学問分野によって多少異なりがちです。私は心理学者なので、心理学分野での報告方法にこだわる傾向があります。ですが、結果を確認できるように読み手に対して十分な情報を提供するという一般的な原則は極めて普遍的だと、私は思います。

^{*7}一部の人のにとっては、このアドバイスは奇妙に聞こえるか、少なくともテクニカルレポートの書き方における「一般的な」アドバイスとは矛盾するものであるかもしれません。よくあることとして、学生は「結果」セクションはデータの記述と統計分析の報告用であり、「考察」セクションは解釈を提供するためのものであると言われます。確かにその通りなのですが、あまりにも文字通りに解釈してしまう人が多いのではないのでしょうか。わたしがよくやっているのは結果セクションにデータの迅速かつ単純な解釈を提供することです。それにより、読み手はデータが示していることを理解できます。そして考察では、自分の結果がどのようにこれまでの科学的文献と整合するのかについてより大きなストーリーを語るようにしています。要するに、「解釈は考察の中で行う」というアドバイスで結果セクションを解釈できないゴミにさせてはいけません。読み手による理解こそがより重要なのです。

が難解になってしまったものを目にしてきました。

9.1.10 統計的表記についてのコメント

サタンは統計も聖句を引用することも同じように楽しむ

– H.G. Wells

もしあなたがよく読んでいて、私と同じくらい数学的の学者であれば、前のセクションで書いたカイ二乗検定に関して少しだけ気になっているかもしれないことが一つあります。“ $\chi^2(3) = 8.44$ ”と書くのはなにか違和感がある、と思われるかもしれません。結局のところ、8.44 になるのは適合度統計量なので、 $X^2 = 8.44$ あるいは $GOF = 8.44$ と書くべきだったのではないのでしょうか？ これは標本分布 (i.e., $df = 3$ の χ^2) と 検定統計量 (i.e., X^2) を混同しているようです。 χ と X はとても似ているので、タイプミスだと思った人もいるでしょう。奇しくも、そうではありません。 $\chi^2(3) = 8.44$ という記述は本質的に、「検定統計量の標本分布は $\chi^2(3)$ であり、検定統計量の値が 8.44 です」という記述を非常に凝縮した方法です。

ある意味で、これはばかげたことです。カイ二乗の標本分布を持つ検定統計量なんてごまんとあるのです。適合度検定で用いた X^2 統計量はその中の一つにすぎません (一番エンカウント率の高いものではありませんが)。賢明で完全に組織化された世界の中では、常に検定統計量と標本分布には別々の名前がつけられます。そうすれば、統計ブロック自体が研究者が計算したものを正確に伝えてくれます。時々こういうことが起こります。例えば、ピアソンの適合度検定で用いられた検定統計量は X^2 ですが、G-検定として知られる密接に関連した検定があります^{*8}が (Sokal and Rohlf 1994)、そこでは検定統計量が G です。偶然にも、ピアソンの適合度検定と G 検定はともに同じ帰無仮説を検定し、標本分布も全く同じものです (i.e., $k-1$ の自由度を持つカイ二乗分布)。もしカードデータに対して適合度検定でなく G 検定を行った場合、最終的に検定統計量は $G = 8.65$ となり、以前に獲得した $X^2 = 8.44$ とは少し異なり、 p 値も少し小さくなります $p = .034$ 。検定統計量、標本分布、 p 値の順に報告するのが慣例と仮定しましょう。もしそうであれば、二つの状況で異なる統計ブロックができます：オリジナルの結果は $X^2 = 8.44, \chi^2(3), p = .038$ 、一方で G 検定の新しいバージョンは $G = 8.65, \chi^2(3), p = .034$ と記述されます。しかし凝縮報告基準を用いると、オリジナルの結果だと $\chi^2(3) = 8.44, p = .038$ 、新しい方だと $\chi^2(3) = 8.65, p = .034$ と書かれるので、実際にどちらの検定を行ったのかは不明瞭です。

では、統計ブロックの中身が行った検定を一意に特定する世界に住んでみたくないませんか？ 人生はごちゃごちゃしてますもの。我々は (統計ツールのユーザーとして) キレイで整理整頓されている状態を望みます。プロダクトのようにその状態をデザインされたものが欲しいのですが、人生はそ

^{*8}複雑なことに、 G 検定とは尤度比検定として知られる一連の検定の特殊なケースです。この本では尤度比検定はカバーしていませんが、知っておくとかなり便利なものです。

うはいきません。統計学は他と同じように知的学問であり、そのため、誰も完全に理解していない、大規模に分散され、部分的に協調的だったり競争的だったりするプロジェクトです。私とあなたがデータ分析ツールとして用いるものは統計学の神様による所業から作られたものではなかったのです。それらは多くの人たちによって発明され、学術雑誌に論文として出版され、他の人たちによって実装・訂正・修正され、他のだれかが教科書を通して学生に説明しました。結果として名前さえない検定統計量がたくさん存在し、対応する標本分布と同じ名前がつけられています。のちに見るように、 χ^2 分布に従う検定統計量は「カイ二乗統計量」と呼ばれ、t 分布の場合は「t 統計量」などと呼ばれます。ですが、 χ^2 と G の例で示したように、同じ標本分布を持つ二つの異なるものは、やはり、異なるものになります。

最終的に、実際に行った検定がなんであるかを明確にすることはしばしば良い考えです。特に一般的でないものを行っているときには。「カイ二乗検定」というだけでは、あなたが話している検定がどういうものかは不明瞭です。二つの有名なカイ二乗検定が適合度検定と独立性検定 (Section 9.2) であるために、多くの統計訓練を受けている読み手は推測できるでしょう。とはいえ、気を付けなければならないことなんです。

9.2

独立性 (もしくは連関) に関する χ^2 検定

GUARDBOT 1: 動くな!

GUARDBOT 2: あなたはロボットですか、それとも人間ですか?

LEELA: ロボット…私たちはね。

FRY: ええと、うん! たった 2 台のロボットがそれをロボット化しています! え?

GUARDBOT 1: テストを実施しましょう。

GUARDBOT 2: 次のうち、どれが一番いいですか?

A: 子犬、B: いとしいあの娘からの可愛い花、

もしくは C: 適切にフォーマットされた大きなデータファイル。

GUARDBOT 1: 選びなさい!

— フューチャラマ、*“Fear of a Bot Planet”*

先日、私はチャペック 9 という惑星に住む人々の風変わりな習慣を紹介するドキュメンタリーアニメを見てたんです。どうやら、首都にアクセスするためには訪問者は自身が人間でなくロボットであることを証明しなければならないようです。訪問者が人間であるかどうかを判断するために、ネイティブは子犬、花、大きく適切にフォーマットされたデータファイルのうちどれが好ましいかを尋

ねます。「こいつぁ賢い」と思いました。「しかし人間とロボットが同じ好みを持っていたら？ そうなると、あまりいいテストにはならないのではないだろうか？」たまたま、チャペック 9 の権限を持つ市民がこれをチェックするために使用したテストデータを手にすることができました。彼らがしたことはとてもシンプルであったことがわかりました。彼らは多くのロボットと人間を見つけて、彼らに何が好きかを尋ねました。彼らのデータを `chapek9.csv` というファイルに保存しておいたので、JASP で読み込むことができるようになってます。個人を特定する `ID` 変数と同じように、二つの名義変数が存在します、`species` と `choice`。このデータセットには、選択を求められた人（ロボットと人の両方を「人」として数えます）ごとで計 180 のデータがあります。具体的には、人間のデータが 93 人、ロボットのデータが 87 人であり、圧倒的にデータファイルのが好まれています。これを自分で確かめたいときには、'Descriptives' - 'Descriptive Statistics' ボタンをクリックして、JASP に頻度表を求めることができます。しかし、この要約は我々の興味がある疑問にこたえるものではありません。その疑問を明らかにするために、データのより細かい記述が必要でしょう。ここでは `species` /it によって分類された `choices` を見ていきます。すなわち、データをクロス集計する必要があります。JASP では、'Frequencies' - 'Contingency Tables' ボタンを使って、'Columns' ボックス内に `species` を、'Rows' ボックス内に `choice` を移動させることでこれができます。この手続きは以下のような表が作成されるはずです：

	ロボット	人間	合計
子犬	13	15	28
お花	30	13	43
データ	44	65	109
合計	87	93	180

ここから、人間の多くがデータファイルを選択している一方で、ロボットは好みが大きく分かれる傾向にあることがわかります。なぜ人間がデータファイルを選びがちなのかという疑問はいまは脇に置いておくとして（確かに、これはかなり奇妙に思えますが）、まず最初にデータセット内の人間とロボットによる選択の違いが統計的に有意であるかどうかを判断します。

9.2.1 仮説検定の構築

このデータをどう分析しましょうか？ 具体的には、私の研究仮説は「人間とロボットでは答え方が違う」というものなので、「人間とロボットが答え方が同じ」という帰無仮説を検証するにはどうすればよいでしょうか？ 前回と同様に、データを記述するための表記法を確立することから始めます。

	ロボット	人間	合計
子犬	O_{11}	O_{12}	R_1
お花	O_{21}	O_{22}	R_2
データ	O_{31}	O_{32}	R_3
合計	C_1	C_2	N

この表記では、 O_{ij} は選択を求められたときには i (子犬、お花、データ) という回答を行った j (ロボット、人間) という種族の回答者の数 (観測度数) であるとしています。観測の総数はいつものように N と書きます。最後に、行の合計を R_i (例: R_1 はお花を選択した人の総数)、列の合計を C_j (例: C_1 はロボットの総数) で記述します。^{*9}

では次に、帰無仮説がなにをいっているのか考えてみましょう。ロボットと人間が同じような答え方をするのであれば、「ロボットが子犬という」確率は「人間が子犬という」確率と同じであり、他の二つの可能性についても同じであるということです。つまり、 P_{ij} を「種 j が i の反応をする確率」とする、帰無仮説は次のようになります：

$$\begin{aligned}
 H_0: \quad & \text{以下のすべてが真である：} \\
 & P_{11} = P_{12} \text{ (“子犬” という確率が同じ),} \\
 & P_{21} = P_{22} \text{ (“お花” という確率が同じ), and} \\
 & P_{31} = P_{32} \text{ (“データ” という確率が同じ).}
 \end{aligned}$$

そして実は、帰無仮説では真の選択確率が選択する人の種に依存していないということを主張しているので、 P_i がその確率を指すものとします (例: P_1 は子犬を選択する真の確率)。

次に、適合度検定のときと大部分は同じように、期待度数を計算する必要があります。つまり、各観測度数 O_{ij} に関して、帰無仮説が何を期待しているのかを把握する必要があります。この期待度数は E_{ij} と表現しましょう。今回は、ちょっとしたコツが必要です。種 j に属す人数が C_j で選択肢 i を選択する真の確率が (種族に関係なく) P_i であれば、期待度数はちょうど：

$$E_{ij} = C_j \times P_i$$

さて、これですべてといえはそりゃそうなのですが、ある問題があります。適合度検定のときとは違い、帰無仮説は P_i に関する値を特定していません。それはデータから推定 (Chapter 7) しなければならないのです！ 幸いなことに、これはとても簡単にできます。もし 180 人中 28 人が花を選択したのであれば、花を選ぶ確率は $28/180$ であり、およそ .16 になります。もしこれを数学的に表

^{*9}技術的メモです。検定を説明した方法では、列の合計は固定されていて (i.e., 研究者はロボット 87 人と人間 93 人を調査しようとしていた)、行の合計は変動する (i.e., 28 人が子犬をえらんでいることがわかった) というふりをしてます。私が持っている数理統計学の教科書 (Hogg, McKean, and Craig 2005) の用語を使うと、私は技術的には同質性のカイ二乗検定という用語、行列の合計値が実験の結果によって変動するものである場合には独立性のカイ二乗検定という用語を用いるべきです。この本の初稿では、まさにそのようにしていました。しかし、この 2 つのテストは同一のものであることが判明したので、まとめています。

現すると、「選択肢 i を選ぶ確率の推定値は行の合計を全サンプルサイズで割ったものである」ということです：

$$\hat{p}_i = \frac{R_i}{N}$$

したがって、期待度数は行の合計と列の合計の積（ようは掛け算）を観測値の合計で割ったものとして書くことができます。^{*10}

$$E_{ij} = \frac{R_i \times C_j}{N}$$

期待度数の計算方法が分かったので、適合度検定で用いたのと同じ戦略に従って、検定統計量を定義するのは簡単です。実際、それはほとんど同じ統計量です。

r 行と c 行を持つ分割表の場合、 X^2 統計量を定義する式は

$$X^2 = \sum_{i=1}^r \sum_{j=1}^c \frac{(E_{ij} - O_{ij})^2}{E_{ij}}$$

唯一の違いは、行と列の両方を合計していることを示すために 2 つの総和記号 (i.e., $\sum$) を含めなければいけないところです。

前回と同様に、 X^2 の値が大きいことは帰無仮説がデータの記述に不十分であることを示しており、 X^2 の値が小さいことは帰無仮説がデータを十分に説明できていることを示します。したがって、もし X^2 が十分に大きければ帰無仮説を棄却したいと思います。

当然、この統計量は χ^2 分布しています。ここで知る必要があるのは関与している自由度の数ですが、それはそれほど難しいことはありません。以前にも言った通り、(大抵) 自由度は分析しているデータポイントの数から制約の数を引いたものに等しいと考えることができます。 r 行と c 列の分割表には $r \times c$ の観測度数が含まれるので、これが観測数の合計になります。制約はどうでしょう？ ここでは、少しトリッキーです。答えは常に同じで

$$df = (r - 1)(c - 1)$$

なのですが、自由度がこの値をなぜとるのかについての説明は実験計画によって異なります。議論の便宜上、ロボット 87 人と人間 93 人を対象に調査するとし (列の合計は実験者が固定)、行の合計は自由に変更できるようにしたとしましょう (行の合計は確率変数)。ここで適用する制約について考えてみましょう。さて、実験者によって列の合計を意図的に固定したので、 c のほうに制約があります。しかし、実はそれだけではありません。帰無仮説にいくつかのフリーパラメータがあったことを覚えていますか (すなわち、 P_i を推定しなければならなかった)？ これらも同様に重要です。この本ではその理由を説明はしませんが、帰無仮説の全フリーパラメータは追加の制約みたいなもので

^{*10}技術的には、ここでの E_{ij} は推定値なので、 $\hat{E}_{ij}$ と書くべきでしょう。でも、誰もやらないから、私もやりません。ふふ。

す。ではそれはいくつあるのでしょうか？ ふむ、それらの確率の合計は1でなければならないので、それらは $r - 1$ になります。なので、自由度はこうなります：

$$\begin{aligned} df &= (\text{観測数}) - (\text{制約の数}) \\ &= (rc) - (c + (r - 1)) \\ &= rc - c - r + 1 \\ &= (r - 1)(c - 1) \end{aligned}$$

代わりに、合計サンプルサイズ N のみが実験者によって固定されていると仮定しましょう。つまり、最初に見た 180 人に質問したところ、87 人がロボットで、93 人が人間であることがわかりました。今回の論法は少し異なるものですが、それでも同じ答えを導き出します。帰無仮説には選択確率と対応する自由パラメータは $r - 1$ ですが、種の確率に対応する自由パラメータもまた $c - 1$ になります。ランダムにサンプリングした人がロボットである確率も推定しなければなりませんからね。^{*11}最後に、観測数の合計は N に固定したので、それがもう一つの制約になります。なので、今は rc の観測データと $(c - 1) + (r - 1) + 1$ の制約があります。それは何をもたすのでしょうか？

$$\begin{aligned} df &= (\text{観測数}) - (\text{制約の数}) \\ &= rc - ((c - 1) + (r - 1) + 1) \\ &= rc - c - r + 1 \\ &= (r - 1)(c - 1) \end{aligned}$$

すばらしい。

9.2.2 JASP での検定

オーケー、検定の仕組みが分かったところで、JASP での実装方法を見ていきましょう。面倒な計算をして長い時間をかけて学んでもらいたいのはやまやまですが、それは意味がないと思ってます。前回のセクションでは長い時間をかけて適合度検定のやり方を紹介しました。独立性の検定は概念的には違いがないので、わざわざ新しいことを学ぶことはありません。その代わり、簡単なやり方をご紹介します。JASP で検定を実行した後 (‘Frequencies’ - ‘Contingency Tables’)、JASP の結果ウィンドウで分割表の下を見れば χ^2 統計量が表示されます。

2 d.f. の χ^2 統計量は 10.722 で p -値 = 0.005 です。

簡単でしょう？ JASP に期待度数を見せるようお願いだってできますよ - ‘Cells’ オプションの ‘Counts’ - ‘Expected’ を押せば、分割表に期待度数が出てきます。その際には、効果量があると便利です。‘Statistics’ オプションのチェックボックスから Cramer’s V を選択すれば、Cramer’s V の値である 0.244 が得られます。これについては、もう少し詳しく説明します。

この出力は、結果を書き出すのに十分な情報を与えてくれます：

^{*11} 私たちの多くが実生活で心配している問題

Pearson's χ^2 が種と選択の間の有意な連関を明らかにしました ($\chi^2(2) = 10.7$, $p < .01$)。ロボットは「花が好き」と答える人が多いようですが、人は「データが好き」と答える人が多いようです。

ここでも、データに何が起きているのかを理解するのに役立つようなほんの少しの解釈を提供します。後ほどディスカッションパートにて、背景をもうちょっと説明します。違いを説明するため、後ほど私が言うであろうことを紹介しておきます：

人はロボットよりもデータファイルを好むようであるという事実は、いくらか直観に反します。しかし、チャベック 9 の権限を持つ市民は、人間を見つけると殺して解剖するという残念な傾向があるので、文脈上その回答傾向にはある程度意味があります。そのため、潜在的に望ましくない結果を回避するために、人間の参加者が質問に正直に答えなかったというのは十分ありうることです。これは方法論的に、相当な弱点であるといえるでしょう。

これは反応効果の極端な例として分類されるんじゃないかと思います。明らかにこの事例は問題が深刻なものなので、人とロボットの間の好みの違いを理解するための道具としては、この研究にはほとんど価値がありません。しかし、この例こそが統計的に有意な結果を得る (帰無仮説を棄却して対立仮説を支持する) ことと科学的価値のあるものを見つけること (データには大きな方法論的問題があるため、研究仮説にとって興味深い情報は提供しない) の違いを示していることでしょう。

9.2.3 追伸

後になってそのデータは作り物で、私は仕事をせずただアニメを見ていただけだったということが判明しました。

9.3

連続性の補正

さて、ちょっとした余談です。これまでほんの少しウソをついていました。自由度が 1 のみである場合には、計算方法を少し変える必要があります。以前指摘していたことを思い出しましょう： χ^2 検定は近似に基づいており、特に大きな N で二項分布が正規分布のように見えるようになるという仮定に基づいています。これの問題点は、特に自由度が 1 しかない場合には上手くいかないことが多いです (例： 2×2 の分割表で独立性の検定を行うとき)。主な理由は χ^2 統計量の真の標本分布は実際には離散的ですが (カテゴリカルデータを扱ってますからね)、 χ^2 分布は連続的だからです。

これにより、系統的な問題が生じる可能性があります。特に N が小さく $df = 1$ のとき、適合度統計量は“大きくなりすぎる”傾向があります。つまり、予想よりも大きい α の値になります (あるいは、 p 値が小さくなりすぎます)。

Yates (1934) は、適合度統計量を次のように再定義する簡単な補正方法を提案しました：

$$\chi^2 = \sum_i \frac{(|E_i - O_i| - 0.5)^2}{E_i}$$

基本的には、どこでも 0.5 を引いていくだけです。

Yates の論文を読んだ限りでは、補正は基本的にハックです。それは何か原理的な理論に基づいているわけではありません。むしろ、テストの動作を検証し、補正版がうまく機能することを確認しています。JASP では、'Statistics' オプションの ' χ^2 continuity correction' というチェックボックスで、この補正を指定できます。

9.4

効果量

先に述べたように (Section 8.9)、研究者は効果量の大きさを報告するのが一般的になってきます。なので、カイ二乗検定を実施し、それが有意であることがわかったとします。これで、変数間の連関 (独立性の検定) あるいは指定された確率からの逸脱 (適合度検定) が存在することがわかりました。ここでは、効果量を報告しましょう。つまり、連関や逸脱があるとして、それはどの程度の強さなのでしょう？

報告するために選択可能な指標と、それらを計算可能な道具が存在します。それらのすべてを説明するつもりはないですが、最も一般的に報告されている効果量に焦点を当てます。

デフォルトでは、頻繁に報告されがちな二つの指標は ϕ 統計量と Cramér's V として知られるやや優れたバージョンです。

数学的に、それはとても単純です。 ϕ 統計量を計算するために、 X^2 の値をサンプルサイズで割って、その平方根をとるのです：

$$\phi = \sqrt{\frac{X^2}{N}}$$

ここでの考え方は ϕ 統計量は 0 (まったく関連がない) から 1 (完全な関連) の間の範囲をとるというものですが、分割表が 2×2 よりも大きい場合にはうまくいかず、これはとても面倒です。より大きな表の場合、実際には $\phi > 1$ を得ることができますが、これはかなりよくないです。

そこで、これを補正するために、通常は [Cramer \(1946\)](#) によって提案された V 統計量を報告することが好まれます。これは ϕ に対するかなり簡単な調整です。 r 行と c 列の分割表がある場合、二つの数のうちでより小さい値となる $k = \min(r, c)$ を定義します。そうすれば、**Cramér's V** 統計量は以下ようになります。

$$V = \sqrt{\frac{X^2}{N(k-1)}}$$

これで完了です。これはとても人気な指標のようです。計算が簡単で、完全にばかげていない答えが得られるからでしょうね。**Cramér's V** では、その値は 0 (まったく関連がない) から 1 (完全な関連) までの範囲をとります。

9.5

検定的前提条件

どのような統計検定にも前提条件があり、その条件が満たされているかを確認することは通常良い考え方です。このチャプターでこれまで取り上げてきたカイ二乗検定の場合、前提条件は以下の通りです：

- 期待度数が十分に大きい。前のセクションで、二項分布は正規分布とよく似ているために生じた χ^2 の標本分布がどのように見えたか覚えていますか？ さて、チャプター 6 で説明したように、これは観測数が十分に大きい場合にのみ成立します。これが実際に意味していることは、期待度数のすべてを適度に大きくする必要があるということです。適度な大きさとはどのくらいなのでしょう？ 意見が分かれますが、標準的な前提は期待度数のすべてを約 5 以上であることが望ましいとされているようです。ただし、より大きな表の場合は期待度数の少なくとも 8 割が 5 以上で、1 以下のものがなければ問題ないでしょう。しかし、私が調べた限りではそれらは大まかなガイドラインとして提案されている (e.g., [Cochran 1954](#)) だけで、厳格なルールではなく、やや保守的なものなようです ([Larntz 1978](#))。

- データは互いに独立している。カイ二乗検定のやや隠れた前提条件の一つは、観測値が独立していると純粋に信じなければならないことです。これが私の言いたいことです。特定の病院で生まれた男の子の割合に関心があるとします。産科病棟を歩き回り、20人の女の子と10人の男の子を観察します。かなり説得力のある違いじゃないですか？ しかし後になって、実は私が同じ病棟を10回分ただ歩き回っていたことがわかり、実際には女の子2人と男の子1人しか見ていなかったみたいです。そうだと説得力に欠けますよね？ 私が最初に行った30回分の観測はほとんどが独立していないものであり、実際には3回分の独立した観測を行っただけのようです。明らかにこれは極端な（そして非常にばかばかしい）例ですが、基本的な問題点を示しています。非独立性は“物事を難しくする”のです。愚かな病院の例で示したように、帰無仮説を誤って棄却を引き起こす場合もあればその逆の場合もあります。もう少し馬鹿げた例を挙げると、もし私がカード実験をちょっと違うやり方で行ったときにどうなるかを考えてみましょう。200人がランダムにカードを1枚選ぶのを想像する代わりに、50人に4枚のカードを選ぶようお願いしたとします。一つの可能性は、全員がハート、クラブ、ダイヤ、スペードを一つずつ選択することです（“代表制ヒューリスティック”；Tversky & Kahneman 1974）。これはきわめてランダムでない行動ですが、この場合4つのマークに関する観測頻度は50になるはずです。この例では、観測が独立していないという事実は（4枚のカード選択だとそれらが互に関連するため）逆効果をもたらし、誤って帰無仮説を保持してしまうことになります。

もし独立性の仮定が満たされない場合に、McNemar 検定や Cochran 検定のようなノンパラメトリック検定を用いることができるかもしれません。同じように、もしセル内の期待度数が小さすぎるのであれば、Fisher 正確性検定を確認してください。現時点では、JASP はこれらのテストを実装してませんが、後で確認してみてください！今のところ、これらのテストが存在するという言及のみにとどめますが、その説明は本書の範囲を超えています。

9.6

Summary

この章で説明する重要なアイディアは：

- さまざまなカテゴリーの観測度数に関する表があり、帰無仮説がそれらを比較するための“既知”の確率を提供している場合に、 χ^2 （カイ二乗）適合度検定（Section 9.1）が使用されます。
- χ^2 （カイ二乗）独立性の検定（Section 9.2）は二つのカテゴリーカル変数を分割表（クロス集計）があるときに使用されます。帰無仮説は、変数の間に関係性や連関がないというものになります。

- 分割表に関する効果量は様々な方法で測定できる (Section 9.4)。特に注目したのは、Cramér's V 統計量です。
- 二種類の Pearson の検定は二つの前提に依拠している：期待度数が十分に大きく、観測が独立していること (Section 9.5)。ある種の独立性や計数性の違反に対して、様々なノンパラメトリック検定が使用できます。

もしあなたがカテゴリーカルデータ分析についてもっと勉強したいのであれば、タイトルが示すように *Introduction to Categorical Data Analysis* Agresti (1996) が最初の選択肢として良いでしょう。もし入門書では物足りない (あるいは取り組んでいる問題を解決できそうもない) 場合には、Agresti (2002) の *Categorical Data Analysis* はいかがでしょうか。後者はより高度なテキストなので、本書からいきなりそっちにいてしまうのはちょっときついかもしれません。

10. 二つの平均の比較

第 9 章では、アウトカムと予測変数のどちらもが名義尺度である場合について説明しました。この世には実際にそのような場面がたくさんあるので、カイ二乗検定が非常に広く使用されていることがよくわかるでしょう。しかしながら、アウトカムが間隔尺度以上であり、ある群のアウトカム変数の平均値が他の群の平均値よりも高いかどうかに関心をもつ場合がそれ以上に多いかもしれません。例えば、心理学者は、子どものいる親は子どもがいない人よりも不安のレベルが高いかどうかを、あるいは音楽を聴くことで（音楽を聴かないことと比べると）ワーキングメモリー容量が低下するかどうかを知りたいと思うかもしれません。医療の場面では、新薬が血圧を上昇あるいは低下するかどうかを知りたいと思うかもしれません。農業の科学者は、オーストラリアの原生植物にリンを加えることでそれら植物が死滅するかどうかを知りたいかもしれません。^{*1}これらの全ての例で、アウトカム変数はまさに連続尺度、間隔尺度、あるいは比率尺度の変数であって、予測変数は 2 値の“グループ化”変数です。言い換えるならば、2 群の平均を比較したいのです。

平均を比較する問題は、通常 t 検定を用いて答えることができます。t 検定には、解きたい問題に応じて亜型が存在します。そこで、本章では t 検定の種類の違いに焦点を当てて説明します: 1 標本の t 検定は 10.3 で、独立した標本の t 検定は 10.4 と 10.5 で、対応のある標本の t 検定は 10.6 で述べられます。続いて、片側検定 (セクション 10.7) について説明した後で、t 検定の標準化された効果量の指標である Cohen の d について簡単に説明します (セクション 10.8)。章の後半では、t 検定の前提と、その前提を逸脱した場合の対処の仕方に焦点をあてます。それらの役立つ事項について論じる前に、まずは z 検定についての理解を深めることから始めます。

10.1

^{*1}私用の庭で行った非公式な実験によると、リンの付加するとオーストラリア原生植物は死滅することが分かりました。オーストラリアの植物は地球上の他のどの場所よりもリンの濃度が低い地域に適応しています。なので、もし、家を買って庭に外国産の植物と一緒に原生植物を植えたい場合には、それらを分けて植えなければいけません。ヨーロッパの植物にとって栄養となるものがオーストラリアの植物にとって毒になるのです。

1 標本 z 検定

この節では、統計のなかでもっとも役に立たない検定のひとつ、 z 検定について説明します。本当の話です。この検定が実際に使われることはほとんどありません。唯一の存在意義は、統計を教えるときに、おそらく統計でもっとも (使われすぎるほど) 使われている t 検定へ向かう途中の、とても便利な踏み台になることです。

10.1.1 この検定が扱う推測の問題

z 検定の背後にある考え方を紹介するために、簡単な例を使いましょう。私の友人の Zeppo 博士は、統計学入門の授業を相対評価で採点しています。彼のクラスの平均点が 67.5、標準偏差が 9.5 だとしましょう。何百人もいる受講生のうち、20 人は心理学の授業も取っていることがわかりました。好奇心から、心理学の学生は他の全員と同じような成績 (つまり平均 67.5) をとる傾向があるのか、それとも高めか低めなのかが気になってきました。彼が `zeppo.csv` ファイルをメールで送ってくれたので、JASP でその学生たちの成績を見てみます (変数 `x` に入っています)。

50 60 60 64 66 66 67 69 70 74 76 76 77 79 79 79 81 82 82 89

そして 'Descriptives' - 'Descriptive Statistics' で平均を計算します。平均値は 72.3 です。

ふむ。心理学の学生は普通より少し高い点をとっているのかもしれませんが。標本平均の $\bar{X} = 72.3$ は仮定された母平均 $\mu = 67.5$ よりかなり高いのですが、一方で標本サイズ $N = 20$ はそれほど大きくありません。単なる偶然かもしれません。

この問いに答えるには、自分が知っていると思っていることを書き出してみると役に立ちます。まず、標本平均が $\bar{X} = 72.3$ であることはわかっています。心理学の学生の標準偏差がクラスの他の学生と同じだと仮定してよいなら、母標準偏差は $\sigma = 9.5$ だと言えます。また、Zeppo 博士が相対評価で採点しているので、心理学の学生の成績は正規分布にしたがうと仮定しておきます。

次に、データから何を知りたいのかをはっきりさせておく役に立ちます。今回の研究仮説は、心理学の学生の成績の母平均 μ に関わるもので、これは未知です。具体的には、 $\mu = 67.5$ かどうかを知りたいわけです。これだけわかっているとして、問題を解く仮説検定を考え出せるでしょうか。データと、それが生じたと考えられる仮定された分布を図 10.1 に示しました。正解が何かは、そう自明ではありませんね。そのために統計の出番になります。




Figure10.1 心理学の学生の成績 (棒) が生成されたと想定される理論的な分布 (実線)。

10.1.2 仮説検定を組み立てる

仮説検定を組み立てる第一歩は、帰無仮説と対立仮説が何かをはっきりさせることです。これはさほど難しくありません。帰無仮説 H_0 は「心理学の学生の成績の真の母平均 μ は 67.5% である」で、対立仮説は「母平均は 67.5% ではない」です。これを数式で書くと、次のようになります。

$$H_0 : \mu = 67.5$$

$$H_1 : \mu \neq 67.5$$

正直なところ、この記法が問題の理解を深めてくれるわけではありません。データから何を知ろうとしているのかをコンパクトに書き下しただけです。この検定の帰無仮説 H_0 と対立仮説 H_1 を、どちらも図 10.2 に示しました。これらの仮説に加えて、先ほどの場面設定は、役に立ちそうな背景知識をかなり与えてくれています。具体的には、次の 2 つの特別な情報を加えられます。

1. 心理学の学生の成績は正規分布にしたがう。
2. これらの得点の真の標準偏差 σ は 9.5 であるとわかっている。

ここではひとまず、これらが絶対に信頼できる事実であるかのように扱います。現実には、こんな絶

対に信頼できる背景知識など存在しませんので、これらの事実に頼りたいなら、それらが真であるという仮定を置くしかありません。ただしこの仮定は正当化できるとは限りませんので、確認が必要になるかもしれません。とはいえ今のところは、話を単純にしておきます。




Figure10.2 1 標本 z 検定 (両側版) が仮定する帰無仮説と対立仮説の図示。帰無仮説も対立仮説も母集団の分布が正規分布であることを仮定し、さらに母標準偏差が既知である (ある値 σ_0 に固定されている) ことを仮定する。帰無仮説 (左) は母平均 μ が指定された値 μ_0 と等しいというもの。対立仮説は母平均がこの値と異なる、つまり $\mu \neq \mu_0$ というものである。

次のステップは、 H_0 と H_1 を区別する助けになるような、診断のための検定統計量として何がよいかを考えることです。仮説がどれも母平均 μ に関わるものですから、標本平均 $\bar{X}$ から始めるのがよさそうだとかなり確信できるでしょう。やれることは、標本平均 $\bar{X}$ と、帰無仮説が母平均について予測する値との差を見ることです。今回の例では $\bar{X} - 67.5$ を計算するということになります。より一般に、帰無仮説が母平均だと主張する値を μ_0 とすれば、計算したいのは次の量です。

$$\bar{X} - \mu_0$$

この量が 0 に等しいか、とても近ければ、帰無仮説にとって都合のよい状況です。0 から大きく離れていけば、帰無仮説を保持する価値は薄れてきます。しかし H_0 を棄却するには、0 からどれだけ離れていけばよいのでしょうか。

それを知るには少しずる賢くならなければなりませんし、先ほど書き出した 2 つの背景知識、つまり生のデータが正規分布にしたがうことと、母標準偏差 σ の値がわかっていることに頼る必要があります。帰無仮説が実際に正しく、真の平均が μ_0 だとすると、この 2 つを合わせればデータの母集団分布が完全にわかることになります。平均 μ_0 、標準偏差 σ の正規分布です。セクション 6.5 の記法を使えば、統計学者はこれを次のように書くでしょう。

$$X \sim \text{Normal}(\mu_0, \sigma^2)$$

さて、これが正しいとすると、 $\bar{X}$ の分布について何が言えるでしょうか。先に述べたように (セクション 7.3.3 参照), 平均 $\bar{X}$ の標本分布もまた正規分布で、その平均は μ です。そしてこの標本分布の標準偏差 $SE(\bar{X})$ は平均の標準誤差と呼ばれ、次のようになります。

$$SE(\bar{X}) = \frac{\sigma}{\sqrt{N}}$$

つまり帰無仮説が正しいければ、平均の標本分布は次のように書けます。

$$\bar{X} \sim \text{Normal}(\mu_0, SE(\bar{X}))$$

ここでひと工夫です。標本平均 $\bar{X}$ を標準得点に変換できます (セクション 4.5)。慣例的には z と書きますが、ここでは $z_{\bar{X}}$ と呼ぶことにします。(この長めの記法を使うのは、 z 得点が普通指すような 1 つの観測値の標準化ではなく、標本平均の標準化を計算しているのだ、ということを覚えておいてもらうためです。) そうすると、標本平均の z 得点は次のようになります。

$$z_{\bar{X}} = \frac{\bar{X} - \mu_0}{SE(\bar{X})}$$

あるいは、同じことですが、

$$z_{\bar{X}} = \frac{\bar{X} - \mu_0}{\sigma/\sqrt{N}}$$

この z 得点が検定統計量です。これを検定統計量として使うことの良い点は、すべての z 得点と同じように、標準正規分布にしたがうということです。

$$z_{\bar{X}} \sim \text{Normal}(0, 1)$$

(なぜそうなるか忘れてしまったら、またセクション 4.5 を見てください。) つまり、もとのデータがどんな尺度であろうと、 z 統計量そのものの解釈は常に同じです。観測された標本平均 $\bar{X}$ と、帰無仮説が予測する母平均 μ_0 とを隔てている標準誤差の個数に等しいのです。さらに良いことに、生の得点の母集団パラメータが実際どうであろうと、 z 検定の 5% の棄却域は常に同じで、図 10.3 のようになります。そしてこれは、統計をすべて手計算していた昔の時代には、誰かが次のような表を出版できるということを意味していました。

望む α 水準	z の臨界値	
	両側検定	片側検定
.1	1.644854	1.281552
.05	1.959964	1.644854
.01	2.575829	2.326348
.001	3.290527	3.090232

これはつまり、研究者が z 統計量を手で計算して、教科書で臨界値を調べればよかった、ということです。




Figure 10.3 両側 z 検定 (パネル a) と片側 z 検定 (パネル b) の棄却域。

10.1.3 手計算による例

先に述べたように、z 検定が実際に使われることはほとんどありません。あまりに使われないので、JASP には組み込みの機能すらありません。しかしこの検定はきわめて単純ですので、手作業でやるのはとても簡単です。Zeppo 博士のクラスのデータに戻りましょう。grades のデータを読み込んだら、まず標本平均を計算します。これはすでにやりました (72.3)。既知の母標準偏差 ($\sigma = 9.5$) と、帰無仮説が指定する母平均の値 ($\mu_0 = 67.5$) はすでに手元にありますし、標本サイズ ($N = 20$) もわかっています。

次に平均の (真の) 標準誤差を計算しましょう (電卓で簡単にできます)。

$$\begin{aligned} se(\bar{X}) &= \frac{\sigma}{\sqrt{N}} \\ &= \frac{9.5}{\sqrt{20}} \\ &= 2.124265 \end{aligned}$$

ここから z 得点を計算します。

$$\begin{aligned}
 z_{\bar{X}} &= \frac{\bar{X} - \mu_0}{sd(\bar{X})} \\
 &= \frac{72.3 - 67.5}{2.124265} \\
 &= 2.259606.
 \end{aligned}$$

ここで、伝統的には 2.26 という値を臨界値の表で調べます。もとの仮説は両側でした (心理学の学生が他の学生より統計が得意か不得意かについて、特に理論があったわけではありません) ので、仮説検定も両側 (両裾) になります。先ほどの小さな表を見ると、2.26 は $\alpha = .05$ で有意になるのに必要な臨界値 1.96 より大きく、 $\alpha = .01$ の水準で有意になるのに必要な 2.58 より小さいことがわかります。ですから有意な効果が得られたと結論でき、次のように書くことになるでしょう。

心理学の学生の標本における平均成績は 73.2 であり、真の母標準偏差を 9.5 と仮定すると、心理学の学生の統計の得点はクラス平均と有意に異なると結論できる ($z = 2.26$, $N = 20$, $p < .05$)。

10.1.4 z 検定の仮定

これまでも述べてきたように、すべての統計的検定は仮定を置いています。妥当な仮定を置く検定もあれば、そうでない検定もあります。いま説明した 1 標本 z 検定は、3 つの基本的な仮定を置いています。次のとおりです。

- 正規性。通常の説明では、z 検定は真の母集団分布が正規分布であることを仮定します*2。これはたいてい妥当な仮定ですし、心配なら確認することもできます (セクション 10.9 参照)。
- 独立性。2 つめの仮定は、データの観測値どうしが相関していない、あるいは何か妙な形で関連していない、ということです。これは統計的に確認するのがそう簡単ではなく、良い実験デザインに頼る部分があります。この仮定を破る明らかな (そしてばかげた) 例は、同じ観測値をデータファイルの中で何度も “コピー” して、本物の観測値は 1 つしかないのに巨大な “標本サイズ” になっているデータです。より現実的には、それぞれの観測値が関心のある母集団からの完全にランダムな標本だと考えるのが本当にもっともらしいかどうかを、自問しなければなりません。実際にはこの仮定が満たされることはありませんが、関連したデータの問題を最小にするような研究デザインを心がけるわけです。

*2 実のところこれは強すぎます。厳密には、z 検定が要求するのは平均の標本分布が正規分布であることだけです。母集団が正規分布なら、平均の標本分布も必然的に正規分布になります。しかし中心極限定理の話で見たように、母集団分布そのものが正規でなくても標本分布が正規になることは十分ありえます (むしろよくあります)。とはいえ、真の標準偏差が既知だという仮定のばかばかしさを考えれば、この点を詳しく述べる意味はありません。

- 標準偏差が既知。z 検定の 3 つめの仮定は、母集団の真の標準偏差を研究者が知っている、というものです。これはただのばかげた話です。現実のデータ分析で、母集団の標準偏差 σ はわかっているのに平均 μ についてはまったく知らない、などという場面はありません。つまりこの仮定は常に誤りです。

σ が既知だと仮定することのばかばかしさを踏まえて、それなしでやっていけるかどうかを見てみましょう。これによって z 検定という陰気な領域を抜け出し、t 検定という魔法の王国へ入っていくことになります。

10.2

要約

- 1 標本 t 検定は、ひとつの標本平均を仮定された母平均の値と比較するために使う (セクション 10.3)。
- 独立標本 t 検定は 2 群の平均を比較するために使い、両群の平均が等しいという帰無仮説を検定する。2 つの形があり、Student の検定 (セクション 10.4) は両群の標準偏差が等しいと仮定するが、Welch の検定 (セクション 10.5) は仮定しない。
- 対応のある標本の t 検定は、各人から 2 つの得点が得られていて、その 2 つの得点の平均が等しいという帰無仮説を検定したいときに使う。各人について 2 つの得点の差をとり、その差の得点に 1 標本 t 検定を実行することと同等である (セクション 10.6)。
- 片側検定は、あらかじめ計画されている限りまったく正当である (セクション 10.7)。
- 平均の差についての効果量は、Cohen の d 統計量によって計算できる (セクション 10.8)。
- 標本の正規性は、QQ プロット (現在の JASP では利用できない) と Shapiro-Wilk 検定で確認できる (セクション 10.9)。
- データが正規でない場合は、t 検定かわりに Mann-Whitney 検定や Wilcoxon 検定を使える (セクション 10.10)。

10.3

1 標本 t 検定

少し考えてみて、心理学の学生の成績が Zeppo 博士のクラスの他の学生と必ず同じ標準偏差を持つと仮定するのは危ないかもしれない、と思いました。そもそも平均が同じではないという仮説を検討しているのに、標準偏差だけは絶対に同じだと信じる理由がどこにあるのでしょうか。ですから、 σ の真の値を知っているという仮定はやめるべきです。これは z 検定の仮定を破りますので、ある

意味で振り出しに戻ったことになります。とはいえ、手立てがまったくないわけではありません。生のデータは手元にありますし、そこから母標準偏差の推定値が得られます。9.52 です。つまり $\sigma = 9.5$ であると知っているとは言えませんが、 $\hat{\sigma} = 9.52$ であるとは言えるのです。

なるほど。すぐ思いつくのは、真の標準偏差が 9.5 だという仮定に頼るかわりに、推定された標準偏差 9.52 を使って z 検定を実行することでしょう。そしてそれでも有意な結果が出ると聞いても、おそらく驚かないはずです。このやり方は惜しいのですが、完全に正しいわけではありません。いまや母標準偏差の推定値に頼っているのですから、真の母標準偏差が実際どうなのかについての不確かさを、何らかの形で調整する必要があります。データがたまたまそうなかっただけかもしれません。たとえば真の母標準偏差は 11 かもしれないのです。しかしもしそれが本当で、 $\sigma=11$ と仮定して z 検定を実行したとすると、結果は有意でなくなってしまう。これは問題です、対処しなければならぬ問題です。




Figure10.4 (両側の)1 標本 t 検定が仮定する帰無仮説と対立仮説の図示。 z 検定 (図 10.2) とよく似ていることに注意。帰無仮説は母平均 μ が指定された値 μ_0 と等しいというもので、対立仮説はそうでないというもの。 z 検定と同じくデータが正規分布にしたがうことは仮定するが、母標準偏差 σ があらかじめ既知であるとは仮定しない。

10.3.1 t 検定の紹介

この曖昧さは厄介ですが、1908 年に William Sealy Gosset という人物によって解決されました (Student 1908)。彼は当時ギネス醸造所で化学者として働いていました (Box 1987, を参照)。ギネスは従業員が統計分析を公表することを快く思っていなかった (企業秘密だと考えていたようです)




Figure10.5 自由度 2(左) と自由度 10(右) の t 分布。比較のため、標準正規分布 (つまり平均 0・標準偏差 1) を点線で描いてある。 t 分布は正規分布より裾が重い (尖鋭的: 尖度が高い) ことに注意。この効果は自由度がとても小さいときにはかなり誇張されるが、値が大きくなると無視できる。つまり自由度 df が大きければ、 t 分布は正規分布と本質的に同じである。

ので、彼は “A Student” という筆名でこの仕事を発表しました。そのため今日に至るまで、 t 検定の正式名称は **Student の t 検定** なのです。Gosset が明らかにした肝心な点は、真の標準偏差が完全にはわからないという事実をどう取り込むか、ということでした^{*3}。答えは、それによって標本分布が微妙に変わる、というものです。 t 検定では、 t 統計量と呼ばれる検定統計量が、先ほど述べたのとまったく同じやり方で計算されます。帰無仮説が「真の平均は μ である」で、標本の平均が $\bar{X}$ 、母標準偏差の推定値が $\hat{\sigma}$ なら、 t 統計量は次のようになります。

$$t = \frac{\bar{X} - \mu}{\hat{\sigma}/\sqrt{N}}$$

式で変わったのは、既知の真の値 σ のかわりに推定値 $\hat{\sigma}$ を使う、という点だけです。そしてこの推定値が N 個の観測から作られているなら、標本分布は**自由度 (df) $N - 1$** の t 分布になります。 t 分布は正規分布とよく似ていますが、セクション 6.6 で述べ、図 10.5 に示したように、裾が “重く” なっています。ただし自由度が大きくなるにつれて、 t 分布は標準正規分布とほとんど同じに見えてくることに注意してください。そうなるべきなのです。標本サイズが $N = 70,000,000$ なら、標準偏差の “推定値” はほぼ完璧でしょう。ですから N が大きければ t 検定は z 検定とまったく同じよう

にふるまうはずです。そして実際そうなります。

10.3.2 JASP で検定を実行する

予想どおり、 t 検定の仕組みは z 検定の仕組みとほとんど同じです。ですから低水準のコマンドで計算する方法を延々と見せる意味はあまりありません。推定された標準偏差を使い、正規分布ではなく t 分布で仮説を検定する、という点を除けば、先ほどの計算とほぼ同じです。ですから 2 度目の退屈な計算の詳細は飛ばして、 t 検定が実際にどう行われるかを見せることにします。JASP には t 検定専用の分析が用意されていて、とても柔軟です (いろいろな種類の t 検定を実行できます)。使い方はごく素直です。‘T-Tests’-‘One Sample T-Test’ を指定し、関心のある変数 (x) を ‘Variables’ のボックスに移し、帰無仮説の平均値 (‘67.5’) を ‘Test value’ のボックスに入力するだけです。簡単ですね。図 10.6 を見てください。あとで触れる他の情報とあわせて、 t 統計量が 2.25、自由度が 19、対応する p 値が 0.036 であることが示されています。




Figure10.6 JASP による 1 標本 t 検定。

標本平均の 95% 信頼区間を計算するのも簡単です。‘Additional Statistics’ の下にある ‘Location parameter’ とそれに付随する ‘Confidence interval’ のオプションを選ぶと、JASP の出力に ‘Mean difference’ が 4.800、95% 信頼区間が [0.344, 9.256] と表示されます。これは単に、標本と仮定され

*3まあ、ある意味では、ですが。私の理解する歴史では、Gosset は部分的な解決を与えたにすぎず、この問題の一般的な解決は Ronald Fisher 卿によって与えられました。

た平均 67.5 との差の推定値が 0.344 から 9.256 のあいだにあると 95% の確信をもって言える、という意味です。この“端点”を仮定された平均に足すと、95% 信頼区間は $[67.5+0.344, 67.5+9.256]$, 言い換えれば $[67.844, 76.800]$ になります。よくわからなくても心配しないでください。次の節でもう少し説明します。

さて、この出力をどう使えばよいのでしょうか。おもちゃの例を本気で気にかけているふりをしているので、結果が統計的に有意である (つまり p 値が .05 未満である) ことがわかって大喜びです。結果は次のように報告できるでしょう。

心理学の学生の平均成績は 72.3 であり、平均成績 67.5 をわずかに上回っていた ($t(19) = 2.25, p < .05$)。95% 信頼区間は 67.8 から 76.8 である。

ここで $t(19)$ は、自由度 19 の t 統計量を表す略記です。とはいえ、信頼区間を報告しない人も多いですし、ここで示したよりずっと圧縮した形で書く人もいます。たとえば、次のように統計量のかたまりの一部として信頼区間を入れるのもよく見かけます。

$t(19) = 2.25, p < .05, CI_{95} = [67.8, 76.8]$

これだけの専門用語が半行に詰め込まれていれば、さぞ賢そうに見えるでしょう*4。

10.3.3 1 標本 t 検定の仮定

さて、1 標本 t 検定はどんな仮定を置いているのでしょうか。 t 検定は基本的に、標準偏差が既知だという仮定を取り除いた z 検定ですから、標準偏差についての仮定を除けば z 検定と同じ仮定を置いても驚くにはあたりません。つまり次のとおりです。

- 正規性。依然として母集団分布が正規分布であることを仮定しています*5。先に述べたように、この仮定が満たされているかを確認する標準的な道具がありますし (セクション 10.9), 破られている場合には代わりに使える検定もあります (セクション 10.10)。
- 独立性。ここでも、標本の観測値が互いに独立に生成されていることを仮定しなければなら

*4もっとまじめに言うと、私はむしろ逆だと思っています。結果の節を数値だけで埋め尽くした技術報告には、かなり疑いの目を向けます。私が傲慢なだけかもしれませんが、読者に対して分析を説明し解釈しようとしないう著者は、自分でも理解していないか、少し怠けているかのどちらかだとよく感じます。読者は賢いですが、無限に忍耐強いわけではありません。避けられるなら、苛立たせないようにしましょう。

*5技術的な注記です。 z 検定の仮定を弱めて標本分布についてだけ語れるようにできたのと同じように、 t 検定の仮定も弱めて母集団の正規性を仮定しなくてよいようにできます。ただし t 検定でこれやるのはより厄介です。先ほどと同じく、母集団の正規性の仮定は $\bar{X}$ の標本分布が正規であるという仮定に置き換えられます。しかし標準偏差の標本推定値にも頼っていることを思い出してください。ですから σ の標本分布がカイ二乗分布であることも要求されます。話が面倒になりますので、この版が実際に使われることはめったにありません。幸い、母集団分布が正規であれば、この 2 つの仮定はどちらも満たされます。

せん。詳しくは z 検定についての先ほどの議論を見てください (セクション 10.1.4)。

全体として、この 2 つの仮定はそれほど無理のあるものではありませんので、1 標本 t 検定は標本平均を仮定された母平均と比較する方法として、実際になりに広く使われています。

10.4

独立標本 t 検定 (Student の検定)

1 標本 t 検定にも使い道はありますが、 t 検定のもっとも典型的な例ではありません^{*6}。はるかによくあるのは、2 つの異なる観測の群がある場合です。心理学ではこれはたいてい 2 つの異なる参加者群に当たり、それぞれの群が研究の異なる条件に対応します。研究の各参加者について関心のある結果変数を測定し、2 つの群の母平均が同じかどうかを問うわけです。これが独立標本 t 検定の想定する場面です。

10.4.1 データ

Harpo 博士の統計の講義を受けている学生が 33 人いて、Harpo 博士は相対評価をしないとしましょう。実のところ Harpo 博士の採点は謎めいていて、クラス全体の平均点がどれくらいなのかは何もわかりません。このクラスには Anastasia と Bernadette という 2 人のチューターがいます。Anastasia のチュートリアルには $N_1 = 15$ 人、Bernadette のチュートリアルには $N_2 = 18$ 人の学生がいます。私の関心のある研究上の問いは、Anastasia と Bernadette のどちらが優れたチューターなのか、それともたいして違いはないのか、ということです。Harpo 博士が授業の成績を `harpo.csv` ファイルでメールしてくれました。いつものように JASP にファイルを読み込んで、どんな変数が入っているかを見てみます。ID, `grade`, `tutor` の 3 つの変数があります。当然ながら `grade` 変数には各学生の成績が入っています。`tutor` 変数は各学生のチューターが誰だったか、Anastasia か Bernadette かを示す要因です。

'Descriptives'-'Descriptive Statistics' の分析で平均と標準偏差を計算できます (必ず `tutor` で分割してください)。きれいな要約表ができました。

	平均	標準偏差	N
Anastasia の学生	74.53	9.00	15
Bernadette の学生	69.06	5.77	18

^{*6}ただしいちばん単純ではあるので、そこから始めたわけです。

何が起きているかをもう少し詳しくつかんでもらうために、両チューターの成績の分布を示すヒストグラム (図 10.7) と、両群の平均と対応する信頼区間を示すより単純なプロット (図 10.8) を描きました (JASP ではなく R を使っています)。




Figure 10.7 Anastasia のクラス (パネル a) と Bernadette のクラス (パネル b) の学生の成績の分布を示すヒストグラム。見た目には、Anastasia のクラスの学生のほうが平均してやや良い成績をとっているように見えるが、ばらつきも少し大きいようである。

10.4.2 検定の紹介

独立標本 t 検定には *Student* のものと *Welch* のものの 2 つの形があります。この節で説明するものと *Student* の t 検定は、2 つのうち単純なほうですが、*Welch* の t 検定よりずっと制約の強い仮定に頼っています。ひとまず両側検定を実行したいとすると、目的は 2 つの“独立な標本”が同じ平均を持つ母集団から得られたのか (帰無仮説)、異なる平均を持つ母集団から得られたのか (対立仮説) を判断することです。“独立な”標本というとき、ここで本当に意味しているのは、2 つの標本の観測値のあいだに特別な関係がない、ということです。いまはピンとこないかもしれませんが、あとで対応のある標本の t 検定の話をするときにはっきりするでしょう。いまのところは、参加者を 2 つの群のどちらかに無作為に割り当てる実験デザインで、何らかの結果指標について 2 群の平均を比べたいのなら、(対応のある標本の t 検定ではなく) 独立標本 t 検定が求めているものだ、と指摘しておくにとどめます。

それでは、群 1(たとえば Anastasia の学生) の真の母平均を μ_1 、群 2(たとえば Bernadette の学




Figure 10.8 Anastasia と Bernadette のチュートリアルの学生の平均成績。エラーバーは平均のまわりの 95% 信頼区間を表す。見た目には群間に本当の差がありそうだが、確かなことは言いにくい。

生) の真の母平均を μ_2 としましょう^{*7}。そしていつものように、この 2 群で観測された標本平均を $\bar{X}_1$ と $\bar{X}_2$ とします。帰無仮説は 2 つの母平均が等しい ($\mu_1 = \mu_2$) というもので、対立仮説はそうでない ($\mu_1 \neq \mu_2$) というものです。数式で書くと次のようになります。

$$H_0: \mu_1 = \mu_2$$

$$H_1: \mu_1 \neq \mu_2$$

この場面を扱う仮説検定を組み立てるにあたって、まず帰無仮説が正しければ母平均の差がちょうどゼロになること、つまり $\mu_1 - \mu_2 = 0$ であることに注目します。ですから診断のための検定統計量は、2 つの標本平均の差にもとづくものになります。帰無仮説が正しければ $\bar{X}_1 - \bar{X}_2$ はゼロにかなり近いと期待されるからです。ただし 1 標本の検定 (つまり 1 標本 z 検定と 1 標本 t 検定) で見たのと同じく、この差がゼロにどれだけ近ければよいのかを正確にしなければなりません。解決策はだいたい同じです。前回と同じく標準誤差の推定値 (SE) を計算し、平均の差をそれで割ります。で

^{*7} ここで必ずと言っていいほど妙な質問が出ます。この場合の母集団とはいったい何なのか、と。実際に Harpo 博士の授業を受けている学生の集合 (33 人全員) でしょうか。その授業を受けうる人々の集合 (人数は不明) でしょうか。それとも別の何かでしょうか。どれを選ぶかは問題になるのでしょうか。行動科学の統計入門の授業では、ここで口ごもるのが伝統なのですが、毎年学生に聞かれるので簡単に答えておきます。厳密に言えば、問題になります。“現実世界”の母集団が何かという定義を変えれば、観測された平均 $\bar{X}$ の標本分布も変わります。t 検定は、観測が無限に大きな母集団から無作為に抽出されたという仮定に頼っていますので、現実がそうでない分だけ t 検定は誤りうるのです。ただし実際には、たいがい大した問題にはなりません。この仮定はほとんど常に誤っているのですが、検定が病的なふるまいをすることにはあまりつながりませんので、無視してしまうのが普通です。




Figure10.9 Student の t 検定が仮定する帰無仮説と対立仮説の図示。帰無仮説は両群が同じ平均 μ を持つと仮定し、対立仮説は異なる平均 μ_1 と μ_2 を持つと仮定する。母集団分布が正規分布であることが仮定されていること、そして対立仮説は群が異なる平均を持つことを許すものの、標準偏差は同じであると仮定していることに注意。

すから t 統計量は次の形になります。

$$t = \frac{\bar{X}_1 - \bar{X}_2}{SE}$$

あとはこの標準誤差の推定値が実際どうなるかを考えるだけです。これはここまで見てきた2つの検定のどちらよりも少し厄介ですので、仕組みを理解するにはずっと注意深く追っていく必要があります。

10.4.3 標準偏差の“プールされた推定値”

もとの“Student の t 検定”では、2つの群が同じ母標準偏差を持つという仮定を置きます。つまり母平均が同じかどうかとは関係なく、母標準偏差は等しい ($\sigma_1 = \sigma_2$) と仮定するわけです。2つの標準偏差が同じだと仮定していますので、添字を落として両方とも σ と呼ぶことにします。これをどう推定すればよいのでしょうか。2つの標本があるとき、標準偏差のひとつの推定値をどう作ればよいのでしょうか。答えは、基本的には平均する、です。まあ、ある意味では。実際にやるのは、分散の推定値の重みつき平均をとることで、これをプールされた分散の推定値として使います。各標本に与えられる重みは、その標本の観測数から1を引いたものに等しくなります。

数式で書くと次のようになります。

$$\begin{aligned}w_1 &= N_1 - 1 \\w_2 &= N_2 - 1\end{aligned}$$

各標本に重みを与えたので、2つの分散の推定値 $\hat{\sigma}_1^2$ と $\hat{\sigma}_2^2$ の重みつき平均をとって、プールされた分散の推定値を計算します。

$$\hat{\sigma}_p^2 = \frac{w_1 \hat{\sigma}_1^2 + w_2 \hat{\sigma}_2^2}{w_1 + w_2}$$

最後に、平方根をとってプールされた分散の推定値をプールされた標準偏差の推定値に変換します。

$$\hat{\sigma}_p = \sqrt{\frac{w_1 \hat{\sigma}_1^2 + w_2 \hat{\sigma}_2^2}{w_1 + w_2}}$$

そしてこの式に $w_1 = N_1 - 1$ と $w_2 = N_2 - 1$ を頭の中で代入すると、とても見苦しい式が出てきます。その見苦しい式が、どうやらプールされた標準偏差の推定値を書き表す“標準的な”やり方らしいのです。とはいえ、これは私の好きな考え方ではありません。私はこう考えるほうが好きです。データは実際には、2つの群に振り分けられた N 個の観測の集まりです。そこで、 k 番目のチュートリアル群の i 番目の学生がとった成績を X_{ik} と書くことにしましょう。つまり X_{11} は Anastasia のクラスの1人目の学生の成績、 X_{21} は2人目の学生、という具合です。そして2つの群平均 $\bar{X}_1$ と $\bar{X}_2$ があり、これを“一般的に” $\bar{X}_k$ 、つまり k 番目のチュートリアル群の平均成績と書けます。ここまではよいでしょう。さて、どの学生も2つのチュートリアルのどちらかに属していますので、群平均からの偏差を次の差として書けます。

$$X_{ik} - \bar{X}_k$$

であれば、この偏差（つまり各学生の成績が自分のチュートリアルの平均成績とどれだけ違うか）をそのまま使えばよいのではないのでしょうか。分散とは偏差の二乗の平均にすぎないことを思い出して、やってみましょう。数式では次のように書けます。

$$\frac{\sum_{ik} (X_{ik} - \bar{X}_k)^2}{N}$$

ここで“ $\sum_{ik}$ ”という記法は“すべてのチュートリアルのすべての学生を見て合計を計算する”ということの横着な書き方です。それぞれの“ ik ”が1人の学生に対応しているからです⁴。しかし Chapter 7 で見たように、 N で割って分散を計算すると母分散の偏った推定値になってしまいます。そして以前は、これを直すために $N - 1$ で割る必要がありました。そのとき述べたように、この偏りが生じるのは分散の推定値が標本平均に頼っているからで、標本平均が母平均と等しくない分だけ、分散の推定値が系統的に偏りうるのです。しかし今回は2つの標本平均に頼っています。

ということは偏りが増えるのでしょうか。そのとおりです。では、プールされた分散の推定値を計算するには $N - 1$ ではなく $N - 2$ で割る必要があるのでしょうか。そのとおりです。

$$\hat{\sigma}_p^2 = \frac{\sum_{ik} (X_{ik} - \bar{X}_k)^2}{N - 2}$$

そしてこの平方根をとれば、プールされた標準偏差の推定値 $\hat{\sigma}_p$ が得られます。つまりプールされた標準偏差の計算は特別なものではありません。通常の標準偏差の計算とそれほど変わらないのです。

^aより正確な記法は Chapter 12 で導入します。

10.4.4 検定を完成させる

どちらの考え方をとるにせよ、これでプールされた標準偏差の推定値が手に入りました。これ以降は面倒な添字 p を落として、この推定値を単に $\hat{\sigma}$ と呼ぶことにします。よろしい。では例の仮説検定の話に戻しましょう。このプールされた推定値を計算したそもそもの理由は、標準誤差の推定値を計算するときに役立つとわかっていたからです。しかし何の標準誤差でしょうか。1 標本 t 検定では標本平均の標準誤差 $SE(\bar{X})$ であり、 $SE(\bar{X}) = \sigma/\sqrt{N}$ でしたから、 t 統計量の分母はその形をしていました。しかし今回は標本平均が 2 つあります。そして具体的に關心があるのは、その 2 つの差 $\bar{X}_1 - \bar{X}_2$ です。ですから割るべき標準誤差は、実は平均の差の標準誤差なのです。

2 つの変数が本当に同じ標準偏差を持っている限り、標準誤差の推定値は次のようになります。

$$SE(\bar{X}_1 - \bar{X}_2) = \hat{\sigma} \sqrt{\frac{1}{N_1} + \frac{1}{N_2}}$$

したがって t 統計量は次のとおりです。

$$t = \frac{\bar{X}_1 - \bar{X}_2}{SE(\bar{X}_1 - \bar{X}_2)}$$

1 標本の検定で見たのと同じく、帰無仮説が正しく検定の仮定がすべて満たされている限り、この t 統計量の標本分布は t 分布になります (驚きですね)。ただし自由度は少し異なります。いつものように、自由度はデータ点の数から制約の数を引いたものだと考えられます。今回は N 個の観測 (標本 1 に N_1 個、標本 2 に N_2 個) と 2 つの制約 (標本平均) があります。ですからこの検定の自由度は $N - 2$ になります。

10.4.5 JASP で検定を実行する

当然ながら、JASP では独立標本 t 検定を簡単に実行できます。この検定の結果変数は学生の *grade* で、群は各クラスの *tutor* によって定義されます。ですから JASP でやることは、図 10.10 のように該当の分析 ('T-Tests'-'Independent Samples T-Test') を開き、*grade* 変数を 'Variables' のボックスに、*tutor* 変数を 'Grouping Variable' のボックスに移すだけだと聞いても、たいして驚かないでしょう。




Figure10.10 JASP での独立標本 t 検定。有用な結果が得られるようオプションにチェックを入れてある

出力はとても見慣れた形をしています。まずどの検定が実行されたかと、使った従属変数の名前が示されます。次に検定の結果が報告されます。前回と同じく、結果は t 統計量、自由度、 p 値からなります。最後の部分では2つのこと、信頼区間と効果量が報告されます。効果量についてはあとで話します。ただし信頼区間についてはいま述べておくべきでしょう。

この信頼区間が実際に何を指しているのかをはっきりさせておくことは、かなり重要です。これは群平均の差についての信頼区間です。今回の例では、Anastasia の学生の平均成績は 74.533, Bernadette の学生の平均成績は 69.056 でしたから、2つの標本平均の差は 5.478 です。もちろん母平均の差はこれより大きいことも小さいこともありえます。図 10.10 に示された信頼区間は、この研究を何度も繰り返したとすると、95% の場合に平均の真の差が 0.197 から 10.759 のあいだに入る、ということを示しています。信頼区間が何を意味するかについては、セクション 7.5 を見返して

ください。

いずれにせよ 2 群の差は (かろうじて) 有意ですので、結果は次のように書けるでしょう。

Anastasia のクラスの平均成績は 74.5%(標準偏差 = 9.0), Bernadette のクラスの平均は 69.1%(標準偏差 = 5.8) であった。Student の独立標本 t 検定の結果、この 5.4% の差は有意であり ($t(31) = 2.1, p < .05, CI_{95} = [0.2, 10.8], d = .74$), 学習成果に本当の差が生じたことが示唆された。

統計量のかたまりに信頼区間と効果量を入れていることに注意してください。みんながいつもこうするわけではありません。最低限、t 統計量・自由度・p 値は載っていると期待されます。ですから最低でも $t(31) = 2.1, p < .05$ のようなものは入れるべきです。統計学者の思いどおりになるなら、みんなが信頼区間も、おそらく効果量の指標も報告することになるでしょう。知っておくと役に立つものだからです。しかし現実には統計学者の望みどおりには進みませんので、読者の助けになるかどうか、そして学術論文を書いているならその雑誌の編集方針にもとづいて判断すべきです。効果量の報告を求める雑誌もあれば、求めない雑誌もあります。信頼区間の報告が標準になっている学術コミュニティもあれば、そうでないところもあります。読み手が何を期待しているのかを見極める必要があります。ただしはっきりさせておくと、私の授業を取っているのであれば、私の基本的な立場は効果量も信頼区間も両方入れる価値がたいにある、というものです。

10.4.6 t 値の正と負

t 検定の仮定の話に移る前に、t 検定を実際に使うことについてもう 1 点述べておきたいことがあります。それは t 統計量の符号 (つまり正の数か負の数か) についてです。学生が初めて t 検定を実行するときにとってもよくある心配は、t 統計量が負の値になってしまい、どう解釈すればよいかわからない、というものです。実際、別々に作業した 2 人が、一方は負の t 値、他方は正の t 値という点を除いてほぼ同じ結果に行き着く、ということはまったく珍しくありません。両側検定を実行しているなら、p 値は同じになります。よく見ると、信頼区間も符号が逆になっていることに気づくでしょう。これはまったく問題ありません。こうなるのは、t 検定の実行のしかたが少し違っているからです。起きていることはとても単純です。ここで計算する t 統計量は常に次の形をしています。

$$t = \frac{(\text{平均 1}) - (\text{平均 2})}{(SE)}$$

“平均 1” が “平均 2” より大きければ t 統計量は正になり、“平均 2” のほうが大きければ t 統計量は負になります。同じように、JASP が報告する信頼区間は “(平均 1) 引く (平均 2)” の差についての信頼区間ですので、“(平均 2) 引く (平均 1)” の差について計算した場合は逆になります。

考えてみればごく素直な話ですが、では Anastasia のクラスと Bernadette のクラスを比べる t 検

定を考えてみましょう。どちらを“平均1”と呼び、どちらを“平均2”と呼ぶべきでしょうか。恣意的です。とはいえ、どちらかを“平均1”，もう一方を“平均2”と決めなければなりません。当然ながら、JASP がこれをどう扱うかもかなり恣意的です。本書の以前の版では説明しようとしていたのですが、そのうち諦めました。たいして重要ではありませんし、正直なところ私自身が覚えられないからです。有意な t 検定の結果が出て、どちらの平均が大きいかを知りたいとき、私は t 統計量を見て考えようとはしません。なぜそんな面倒なことをするのでしょうか。ばかげています。JASP の出力には実際の群平均が出ているのですから、それを見るほうが簡単です。

大事なのはここです。JASP が何を表示するかは本当にどうでもよいので、私はたいてい、数値が文章と合うような形で t 統計量を報告するようにしています。報告書に“Anastasia のクラスは Bernadette のクラスより成績が高かった”と書きたいとしましょう。この言い方は Anastasia の群が先に来ることを含意していますので、Anastasia のクラスを群1として t 統計量を報告するのが理にかなっています。その場合は次のように書きます。

Anastasia のクラスは Bernadette のクラスより成績が高かった($t(31) = 2.1, p = .04$)。

(実際には“高かった”に下線を引いたりはしません。“高い”が正の t 値に対応することを強調するためにやっているだけです。) 一方、Bernadette のクラスを先に挙げる言い方をしたい場合はどうでしょうか。その場合は彼女のクラスを群1として扱うほうが理にかなっていて、書き方は次のようになります。

Bernadette のクラスは Anastasia のクラスより成績が低かった($t(31) = -2.1, p = .04$)。

今回は一方の群の得点が“低い”という話をしているのですから、 t 統計量は負の形を使うほうが自然です。そのほうが読みやすくなります。

最後にひとつ。他の種類の検定統計量ではこれができないことに注意してください。 t 検定では通用しますが、カイ二乗検定や F 検定、実のところ本書で扱うほとんどの検定では意味をなしません。ですからこの助言を一般化しすぎないでください。ここで話しているのは t 検定のことだけです。

10.4.7 検定の仮定

いつものように、仮説検定はいくつかの仮定に頼っています。それは何でしょうか。Student の t 検定には3つの仮定があり、そのいくつかは1標本 t 検定の文脈ですで見えたものです(セクション 10.3.3 参照)。

- 正規性。1標本 t 検定と同じく、データが正規分布にしたがうことを仮定します。具体的には、両方の群が正規分布にしたがうと仮定します。正規性の検定についてはセクション 10.9

で、考えられる対処法についてはセクション 10.10 で述べます。

- 独立性。ここでも、観測が独立に抽出されていることを仮定します。Student の検定の文脈では、これには 2 つの側面があります。まず各標本内の観測が互いに独立であると仮定します (1 標本の検定とまったく同じです)。加えて、標本をまたいだ依存関係がないことも仮定します。たとえば研究の両方の実験条件に同じ参加者が入っていた (うっかり同じ人が異なる条件に申し込めてしまった, など) ことがわかったなら, 考慮しなければならない標本間の依存関係があることになります。
- 分散の等質性 ("等分散性" と呼ばれます)。3 つめの仮定は, 母標準偏差が両群で同じであるということです。この仮定は Levene の検定で検討できます。これについては本書の後のほうで述べます (セクション 12.8.1)。ただし心配な場合にはこの仮定に対するとても簡単な対処法があり, それを次の節で述べます。

10.5

独立標本 t 検定 (Welch の検定)

Student の検定を実際に使うときの最大の問題は, 前節に挙げた 3 つめの仮定です。両方の群が同じ標準偏差を持つと仮定しているのです。現実これが成り立つことはめったにありません。2 つの標本の平均が同じでないのなら, 標準偏差だけ同じだと期待する理由がどこにあるのでしょうか。この仮定が成り立つと期待する根拠は本当にありません。この仮定をどう確認するかについてはあとで少し述べます。t 検定だけでなく, いくつかの場面で出てくるからです。ここではまず, この仮定に頼らない別の形の t 検定 (Welch 1947) について話します。Welch の t 検定がデータについて何を仮定しているかを図 10.11 に示しました。図 10.9 の Student の検定版と対比してみてください。診断の話より先に治療の話をするのは少し変だと認めますが, たまたま Welch の検定は JASP の 'Independent Samples T-Test' のオプションのひとつとして指定できますので, ここで扱うのがおそらくいちばんよいでしょう。

Welch の検定は Student の検定とよく似ています。たとえば Welch の検定で使う t 統計量は, Student の検定とほぼ同じやり方で計算されます。つまり標本平均の差をとり, その差の標準誤差の推定値で割るのです。

$$t = \frac{\bar{X}_1 - \bar{X}_2}{SE(\bar{X}_1 - \bar{X}_2)}$$

主な違いは, 標準誤差の計算が異なることです。2 つの母集団の標準偏差が異なるなら, プールされた標準偏差の推定値を計算しようとするのはまったくの無意味です。りんごとみかんを平均してい




Figure 10.11 Welch の t 検定が仮定する帰無仮説と対立仮説の図示。Student の検定 (図 10.9) と同じく両方の標本が正規母集団から得られたと仮定するが、対立仮説はもはや 2 つの母集団が等しい分散を持つことを要求しない。

.....

るようなものだからです*8。

それでも標本平均の差の標準誤差を推定することはできて、ただ見た目が変わるだけです。

$$SE(\bar{X}_1 - \bar{X}_2) = \sqrt{\frac{\hat{\sigma}_1^2}{N_1} + \frac{\hat{\sigma}_2^2}{N_2}}$$

なぜこう計算するのかは本書の範囲を超えます。ここで重要なのは、Welch の t 検定から出てくる t 統計量が、Student の t 検定から出てくるものとは実際いくら異なる、ということです。

Welch と Student の 2 つめの違いは、自由度の計算のしかたがまるで異なることです。Welch の検定では“自由度”はもはや整数である必要がありませんし、ここまで使ってきた“データ点の数から制約の数を引く”という目安にもそれほど近くありません。

*8まあ、りんごとみかんを平均することはできて、おいしいフルーツスムージーができあがるでしょうけど。でも、フルーツスムージーがもとの果物をうまく言い表しているとは、誰も本気で思わないですね。

自由度は実際には次のようになります。

$$df = \frac{(\hat{\sigma}_1^2/N_1 + \hat{\sigma}_2^2/N_2)^2}{(\hat{\sigma}_1^2/N_1)^2/(N_1 - 1) + (\hat{\sigma}_2^2/N_2)^2/(N_2 - 1)}$$

実に素直で明快ですね。まあ、そうでもないかもしれません。ここでの目的にはたいして関係ありません。重要なのは、Welch の検定から出てくる “df” の値が Student の検定で使われるものより少し小さくなる傾向があること、そして整数である必要がないことです。

10.5.1 JASP で Welch の検定を実行する

先ほどの分析で Welch の検定のチェックボックスにチェックを入れると、次のような結果になります (図 10.12)。

Independent Samples T-Test ▼

Independent Samples T-Test ▼									
		Statistic	df	p	Mean Difference	SE Difference	95% CI for Mean Difference		Cohen's d
Test							Lower	Upper	
grade	Student	2.115	31.000	0.043	5.478	2.589	0.197	10.759	0.740
	Welch	2.034	23.025	0.054	5.478	2.693	-0.092	11.048	0.724

Figure10.12 JASP で既定の Student の t 検定とあわせて Welch の検定を表示した結果

この出力の解釈はかなり明白でしょう。Welch の検定の出力は、Student の検定と同じように読めばよいのです。記述統計、検定の結果、そのほかの情報が出ています。ですからここは簡単です。

ただし、ただし……結果はもう有意ではありません。Student の検定を実行したときには有意な効果が得られましたが、同じデータに対する Welch の検定では有意ではないのです ($t(23.02) = 2.03$, $p = .054$)。これはどういうことでしょうか。慌てるべきでしょうか。空が燃えているのでしょうか。おそらくそんなことはありません。一方の検定が有意で他方が有意でないという事実そのものは、たいした意味を持ちません。とくに、そうなるように私がデータを仕込んだのですから。一般的なルールとして、 p 値.049 と p 値.051 の差をわざわざ解釈したり説明したりしようとするのはよい考えではありません。現実にはこの種のことが起きたなら、 p 値のこの差はほぼ確実に偶然によるものです。重要なのは、どの検定を使うかを少し注意して考えることです。Student の検定と Welch の検定には、それぞれ長所と短所があります。2つの母集団が本当に等しい分散を持つなら、Student の検定のほうが Welch の検定よりわずかに検定力が高くなります (タイプIIエラー率が低くなります)。しかし分散が同じでないなら、Student の検定の仮定は破られますので信頼できないかもしれません

し、タイプⅠエラー率が高くなってしまうかもしれません。つまりトレードオフです。とはいえ現実には私は Welch の検定を好みます。母分散が等しいと本気で信じている人はほとんどいないからです。

10.5.2 検定の仮定

Welch の検定の仮定は Student の t 検定のもの (セクション 10.4.7 参照) とよく似ていますが、Welch の検定は分散の等質性を仮定しません。ですから残るのは正規性の仮定と独立性の仮定だけです。これらの仮定の中身は、Welch の検定でも Student の検定と同じです。

10.6

対応のある標本の t 検定

Student の検定であれ Welch の検定であれ、独立標本 t 検定は、2つの標本が互いに、まあ、独立である場面で使うことを想定しています。参加者が2つの実験条件のどちらかに無作為に割り当てられる場合には自然にこうなりますが、他の種類の研究デザインにはあまり当てはまりません。とくに、各参加者が (同じ結果変数について) 両方の実験条件で測定される反復測定デザインは、独立標本 t 検定による分析には向いていません。たとえば、音楽を聴くとワーキングメモリの容量が下がるかどうかに関心があるとしみましょう。そのために、音楽ありと音楽なしという2つの条件で、各人のワーキングメモリ容量を測ることになります。このような実験デザインでは、各参加者が両方の群に登場します。ですから**対応のある標本の t 検定**を使って、別のやり方で問題に取り組む必要があります。

10.6.1 データ

今回使うデータは Chico 博士のクラスのもので^{*9}。彼女のクラスでは学生が大きな試験を2回、学期の前半と後半に受けます。彼女の言い分では、これはとても厳しい授業で、ほとんどの学生がかなり手強いと感じるそうです。しかし彼女は、難しい評価を課すことで学生はより努力するようになるのだと主張します。彼女の理屈では、1回目の試験は学生にとって一種の“目覚まし”なのです。授業が本当はどれだけ厳しいかに気づけば、2回目の試験に向けてより努力し、よい点をとるだろう、というわけです。彼女は正しいのでしょうか。これを確かめるために、chico.csv ファイルを JASP に読み込みましょう。chico のデータには3つの変数があります。クラスの各学生を識別する *id* 変

^{*9} ここまでに Harpo 博士, Chico 博士, Zeppo 博士が登場しました。Groucho 博士が誰なのかを当てても賞品は出ません。

数, 1 回目の試験の成績を記録した `grade_test1` 変数, 2 回目の試験の成績が入った `grade_test2` 変数です。

JASP のスプレッドシートを見ると, 確かに厳しい授業のようですが (成績のほとんどが 50% から 60% のあいだです), 1 回目の試験から 2 回目の試験にかけて改善が見られるようです。




Figure10.13 chico データの 2 つの `grade_test` 変数の記述統計

図 10.13 の記述統計をざっと見ると, この印象は裏づけられているようです。20 人全員で見ると 1 回目の試験の平均成績は 57% ですが, 2 回目には 58% に上がっています。とはいえ標準偏差がそれぞれ 6.6% と 6.4% であることを考えると, この改善は錯覚かもしれない, 単なるランダムな変動かもしれない, と思えてきます。図 10.14a の平均と信頼区間のプロットを見ると, この印象はさらに強まります。このプロットだけに頼って, 信頼区間の広さを見れば, 学生の成績が改善したように見えるのは純粋な偶然だと考えたくありません。

しかし, この印象は誤りです。なぜかを見るために, 図 10.14b の, 試験 1 の成績に対する試験 2 の成績の散布図を見てください。このプロットでは, それぞれの点がある学生の 2 つの成績に対応しています。試験 1 の成績 (x 座標) と試験 2 の成績 (y 座標) が等しければ, 点は直線の上に乗ります。直線より上にある点は, 2 回目の試験のほうが成績のよかった学生です。重要なのは, ほとんどすべての点が対角線より上にあることです。わずかではあれ, ほとんどすべての学生が成績を伸ばし




Figure10.14 試験 1 と試験 2 の平均成績と、対応する 95% 信頼区間 (パネル a)。試験 1 と試験 2 の個々の成績を示す散布図 (パネル b)。Chico 博士のクラスの各学生の伸びを示すヒストグラム (パネル c)。パネル c では分布のほとんど全体がゼロより上にあることに注意。大多数の学生が 1 回目の試験から 2 回目の試験にかけて成績を伸ばしている

ているようだということです。これは、各学生が一方の試験から次の試験にかけてどれだけ伸びたかを見て、それを生のデータとして扱うべきだということを示唆しています。そのためには各学生の *improvement* (伸び) についての新しい変数を作り、*chico* のデータに加える必要があります。いちばん簡単なのは、新しい変数を計算することです。JASP では、データ列のいちばん右にある “+” をクリックし、変数名を *improvement* として “R” のボタンを選びます。‘Create column’ のボタンをクリックしたら、R のコード `grade_test2 - grade_test1` を入力できます (図 10.15 参照)。

この新しい *improvement* 変数を計算したら、図 10.14c のように、伸びの得点の分布を示すヒストグラムを描けます。ヒストグラムを見れば、ここに本当の改善があることははっきりしています。大多数の学生が試験 1 より試験 2 で高い点をとっており、それがヒストグラムのほぼ全体がゼロより上にあることに表れています。

10.6.2 対応のある標本の t 検定とは

ここまでの探索を踏まえて、適切な t 検定をどう組み立てるかを考えましょう。ひとつの可能性は、*grade_test1* と *grade_test2* を関心のある変数として独立標本 t 検定を実行することです。しかし独立標本 t 検定は 2 つの標本のあいだに特別な関係がないことを仮定していますので、これは明らかに誤りです。データが反復測定 of 構造を持っている以上、今回それが成り立たないのは明らかです。前節で導入した言い方をすれば、独立標本 t 検定をやろうとすると、検定したい被験者内の差と、関心のない被験者間の変動をごちゃまぜにしてしまうことになります。




Figure10.15 JASP で R のコードを使って `improvement` の得点を計算する。

前節ですでに面倒な作業は済ませていますので、解決策は明らかだと思います。`grade_test1` と `grade_test2` に対して独立標本 t 検定を実行するかわりに、被験者内の差の変数である `improvement` に対して 1 標本 t 検定を実行するのです。少し形式的に書くと、 i 番目の参加者が 1 つめの変数で得た得点を X_{i1} 、同じ人が 2 つめの変数で得た得点を X_{i2} とすれば、差の得点は次のようになります。

$$D_i = X_{i1} - X_{i2}$$

差の得点に変数 1 引く変数 2 であって逆ではないことに注意してください。ですから伸びを正の差に対応させたいなら、“試験 2”を“変数 1”にする必要があります。同じように、この差の変数の母平均を $\mu_D = \mu_1 - \mu_2$ と書きます。これを仮説検定に直すと、帰無仮説はこの平均差がゼロであるというもの、対立仮説はそうでないというものになります。

$$\begin{aligned} H_0 : \mu_D &= 0 \\ H_1 : \mu_D &\neq 0 \end{aligned}$$

ここでは両側検定を想定しています。これは 1 標本 t 検定で仮説を書いたやり方とほぼ同じです。唯一の違いは、帰無仮説が予測する具体的な値が 0 であることです。ですから t 統計量もほぼ同じように定義されます。差の得点の平均を $\bar{D}$ とすれば、

$$t = \frac{\bar{D}}{SE(\bar{D})}$$

つまり,

$$t = \frac{\bar{D}}{\hat{\sigma}_D / \sqrt{N}}$$

となります。ここで $\hat{\sigma}_D$ は差の得点の標準偏差です。これはごく普通の 1 標本 t 検定にすぎず、特別なところは何もありませんので、自由度は依然として $N - 1$ です。これで終わりです。対応のある標本の t 検定は、実のところ新しい検定でも何でもありません。2 つの変数の差に適用した 1 標本 t 検定なのです。実にとても単純です。これだけ長く論じる価値があるのは、対応のある標本の検定が適切なのはどんなときかを見分けられるようになり、独立標本 t 検定よりなぜよいのかを理解する必要があるからにすぎません。

10.6.3 JASP で検定を実行する

JASP で対応のある標本の t 検定はどうやるのでしょうか。ひとつは、いま述べた手順にしたがうことです。つまり “差” の変数を作り、それに 1 標本 t 検定を実行するのです。すでに *improvement* という変数を作っていますので、やってみて結果を見てみましょう。図 10.16 です。

One Sample T-Test

One Sample T-Test							
	t	df	p	Mean Difference	95% CI for Mean Difference		Cohen's d
					Lower	Upper	
improvement	6.475	19	< .001	1.405	0.951	1.859	1.448

Note. Student's t-test.
 Note. For the Student t-test, location parameter is given by mean difference *d*.
 Note. For the Student t-test, effect size is given by Cohen's *d*.

Figure10.16 対応のある差の得点に対する 1 標本 t 検定の結果

図 10.16 の出力は (当然ながら) 前回 ‘One Sample T-Test’ の分析を使ったとき (セクション 10.3) とまったく同じ形式で、私たちの直感を裏づけています。試験 1 から試験 2 にかけて平均 1.4 点の伸びがあり、これは 0 と有意に異なっています ($t(19) = 6.48, p < .001$)。

とはいえ、面倒くさくて新しい変数を作る手間をかけたくない場合もあるでしょう。あるいは、1 標本の検定と対応のある標本の検定の違いを頭のなかではっきりさせておきたいのかもしれない。その場合は JASP の ‘Paired Samples T-Test’ の分析を使えます。見てのとおり、数値は 1 標本の検定から出てくるものと同じです。対応のある標本の t 検定は中身が 1 標本の検定にすぎないので、当然そうなるはずです。

片側検定

帰無仮説検定の理論を紹介したとき、片側検定を指定するのが適切な場面があると述べました (セクション 8.5.3 参照)。ここまでの t 検定はすべて両側検定でした。たとえば Zeppo 博士のクラスの成績について 1 標本 t 検定を指定したとき、帰無仮説は真の平均が 67.5% であるというものでした。対立仮説は、真の平均が 67.5% より大きい小さいというものでした。真の平均が 67.5% より大きいかどうかだけにだけ関心があり、67.5% より低いかどうかを検定することにはまったく関心がない、としましょう。その場合、帰無仮説は真の平均が 67.5% 以下であるというもので、対立仮説は真の平均が 67.5% より大きいというものになります。JASP の 'One Sample T-Test' の分析では、'Alt. Hypothesis' の下にある '> Test Value' のオプションをクリックすることでこれを指定できます。そうすると図 10.17 のような結果が得られます。

One Sample T-Test ▼

One Sample T-Test							
	t	df	p	Mean Difference	95% CI for Mean Difference		Cohen's d
					Lower	Upper	
x	2.255	19	0.018	4.800	1.119	∞	0.504

Note. Student's t-test.
 Note. For the Student t-test, location parameter is given by mean difference d .
 Note. For the Student t-test, effect size is given by Cohen's d .
 Note. For all tests, the alternative hypothesis specifies that the mean is greater than 67.5.

Figure 10.17 仮説が片側、つまり真の平均が 67.5% より大きいというものである場合の、JASP の 'One Sample T-Test' の結果

前回見た出力からいくつか変わっていることに注意してください。もっとも重要なのは、検定が変わったことを反映して仮説そのものが変わっていることです。2 つめは、 t 統計量と自由度は変わっていないのに、 p 値が変わっていることです。これは片側検定の棄却域が両側検定と異なるからです。なぜそうなるのか、それが何を意味するのかを忘れてしまったなら、Chapter 8、とくにセクション 8.5.3 を読み返すとよいでしょう。3 つめは、信頼区間も変わっていることです。両側ではなく“片側”の信頼区間が報告されています。両側の信頼区間では、研究を何度も繰り返したときに 95% の場合に平均が a と b のあいだに入る、と確信できるような数 a と b を求めています。片側の信頼区間では、95% の場合に真の平均が a より大きいと確信できるような単一の数 a を求めます

(‘Alt. Hypothesis’ の欄で ‘< Test Value’ を選んだ場合は α より小さい、となります)。

これが片側の 1 標本 t 検定のやり方です。ただし、どの t 検定も片側にできます。独立標本 t 検定では、群 A が群 B より高い得点かどうかを検定することにだけ関心があり、群 B が群 A より高いかどうかには関心がない場合に、片側検定にできます。Harpo 博士のクラスについて、Anastasia の学生のほうが Bernadette の学生より成績が高いかどうかを見たいとしましょう。この分析では、‘Alt. Hypothesis’ のオプションで ‘Group 1 > Group2’ を指定します。図 10.18 のような結果が得られるはずです。

Independent Samples T-Test

Independent Samples T-Test								
	t	df	p	Mean Difference	SE Difference	95% CI for Mean Difference		Cohen's d
						Lower	Upper	
grade	2.115	31.000	0.021	5.478	2.589	1.087	∞	0.740

Note. Student's t-test.
Note. For all tests, the alternative hypothesis specifies that group Anastasia is greater than group Bernadette.

Figure10.18 仮説が片側、つまり Anastasia の学生のほうが Bernadette の学生より成績が高い
というものである場合の、JASP の ‘Independent Samples T-Test’ の結果

ここでも出力は予想どおりに変わります。対立仮説の定義が変わり、 p 値が変わり、両側ではなく片側の信頼区間が報告されています。

対応のある標本の t 検定はどうでしょうか。Chico 博士のクラスで試験 1 から試験 2 にかけて成績が上がるという仮説を検定したく、成績が下がるという考えは検討するつもりがない、としましょう。JASP では ‘Alt. Hypotheses’ のオプションで、`grade_test2`(対応のある変数のボックスに先にコピーしたので JASP では ‘Measure 1’ です) > `grade_test1`(JASP では ‘Measure 2’) と指定します。図 10.19 のような結果が得られるはずです。

ここでもまた、出力は予想どおりに変わります。仮説が変わり、 p 値が変わり、信頼区間は片側になっています。

10.8

効果量

t 検定の効果量としてもっともよく使われる指標が **Cohen の d** です (Cohen 1988)。原理としてはとても単純な指標ですが、細部を掘り下げ始めるとかなり厄介な点が出てきます。Cohen 自身は

Paired Samples T-Test

Paired Samples T-Test									
		t	df	p	Mean Difference	SE Difference	95% CI for Mean Difference		Cohen's d
							Lower	Upper	
grade_test2	- grade_test1	6.475	19	< .001	1.405	0.217	1.030	∞	1.448

Note. Student's t-test.
Note. All tests, hypothesis is measurement one greater than measurement two.

Figure10.19 仮説が片側、つまり `grade_test2('Measure 1') > grade_test1('Measure 2')` である場合の、JASP の 'Paired Samples T-Test' の結果

主に独立標本 t 検定、とくに *Student* の検定の文脈でこれを定義しました。その文脈では、効果量を定義する自然なやり方は平均の差を標準偏差の推定値で割ることです。つまり、次のような何かを計算しようとしているわけです。

$$d = \frac{(\text{平均 1}) - (\text{平均 2})}{\text{標準偏差}}$$

そして彼は、表 10.1 のような d の解釈の大まかな目安を提案しました。これで曖昧さはなくなりそうに思えますが、そうではありません。それは主に、標準偏差の指標として何を使うべきかについて *Cohen* があまり具体的に述べなかったからです (彼の名誉のために言えば、本の中でもっと大きな話をしようとしていたのであって、細部をつつくつもりはなかったのです)。McGrath and Meyer (2006) が論じているように、一般に使われている版がいくつもあり、著者ごとに少しずつ異なる記法をとる傾向があります。正確さより単純さを優先して、本書では標本から計算するどの統計量も d と呼び、理論的な母集団の効果量を δ と呼ぶことにします。当然ながら、これは d と呼ばれるものがあるということも意味します。

Cohen の d が欲しくなるのは t 検定を実行するときだけだろうと私は睨んでいますが、JASP には提供しているすべての種類の t 検定について効果量を計算するオプションがあります。

10.8.1 1 標本からの *Cohen* の d

いちばん単純なのは、1 標本 t 検定に対応する場面です。この場合、標本平均 $\bar{X}$ がひとつと、それと比べる (仮定された) 母平均 μ_0 がひとつあります。それだけでなく、母標準偏差を推定するまともなやり方もひとつしかありません。いつもの推定値 $\hat{\sigma}$ を使うだけです。ですから d の計算は次の通りだけになります。

$$d = \frac{\bar{X} - \mu_0}{\hat{\sigma}}$$

図 10.6 の結果を見返すと、効果量の値は *Cohen* の $d = 0.504$ です。つまり全体として、Zeppo 博

Table10.1 Cohen の d の解釈の (とても) 大まかな目安。個人的にはこれを鵜呑みにしないことをお勧めする。 d 統計量はそれ自体で自然な解釈を持っている。平均の差を、その平均どうしを隔てる標準偏差の個数として言い換えたものである。ですからそれが実務的に何を意味するのかを考えるほうがたいいよい。文脈によっては“小さい”効果が実務上きわめて重要なこともある。逆に“大きい”効果がさほど興味深くない場面もある。

d の値	大まかな解釈
0.2 くらい	“小さい” 効果
0.5 くらい	“中程度の” 効果
0.8 くらい	“大きい” 効果

士のクラスの心理学の学生は、他の学生と同じ水準であれば期待される値 (67.5%) より、標準偏差にして約 0.5 だけ高い成績 (平均 = 72.3%) をとっているということです。Cohen の大まかな目安に照らせば、これは中程度の効果量です。

10.8.2 Student の t 検定からの Cohen の d

Cohen の d についての議論の大部分は、Student の独立標本 t 検定にあたる場面に焦点を当てています。そしてこの文脈で話がややこしくなります。この場面で使いたくなる d の版がいくつもあるからです。 d に複数の版がある理由を理解するには、真の母集団の効果量 δ に対応する式を書き下してみると役に立ちます。ごく素直です。

$$\delta = \frac{\mu_1 - \mu_2}{\sigma}$$

ここでいつものように μ_1 と μ_2 はそれぞれ群 1 と群 2 に対応する母平均で、 σ は標準偏差 (両方の母集団で同じ) です。 δ を推定するわかりやすいやり方は、 t 検定そのものでやったのとまったく同じこと、つまり分子に標本平均を、分母にプールされた標準偏差の推定値を使うことです。

$$d = \frac{\bar{X}_1 - \bar{X}_2}{\hat{\sigma}_p}$$

ここで $\hat{\sigma}_p$ は、 t 検定に出てくるのとまったく同じプールされた標準偏差の指標です。これは Student の t 検定の結果に適用する場合にもっともよく使われる Cohen の d の版であり、JASP が提供しているものです。Hedges の g 統計量と呼ばれることもあります (Hedges 1981)。

とはいえ他の可能性もありますので、簡単に述べておきます。まず、標準偏差の計算の基礎として 2 群のうち一方だけを使いたい理由がある場合もあるでしょう。このやり方 (しばしば Glass の Δ 、デルタと読みます、と呼ばれます) がいちばん意味を持つのは、2 群のうち一方をもう一方より純粋に“自然な変動”を反映したものとして扱うもっともな理由がある場合だけです。たとえば 2 群のうち一方が統制群である場合などです。次に、プールされた標準偏差の通常の計算では、標本分散の偏

りを補正するために $N - 2$ で割ったことを思い出してください。Cohen の d のある版ではこの補正を省き、かわりに N で割ります。この版が意味を持つのは主に、母集団の効果を推定するのではなく標本における効果を計算しようとしている場合です。最後に、[Hedges and Olkin \(1985\)](#) にもとづく版があります。彼らは Cohen の d の通常の (プールされた) 推定に小さな偏りがあることを指摘しました。そこで通常の d の値に $(N - 3)/(N - 2.25)$ を掛ける小さな補正を導入しています。

いずれにせよ、使おうと思えば使えるこうした変種はさておき、JASP の既定の版を見てみましょう。図 10.10 では Cohen の $d = 0.740$ であり、Anastasia のクラスの学生の成績が Bernadette のクラスの学生の成績より平均して標準偏差 0.74 だけ高いことを示しています。Welch の検定でも、推定される効果量は同じです (図 10.12)。

10.8.3 対応のある標本の検定からの Cohen の d

最後に、対応のある標本の t 検定ではどうすべきでしょうか。この場合、答えは何をしようとしているかによります。JASP は差の得点の分布を基準に効果を測りたいものと想定しており、計算される d は次のようになります。

$$d = \frac{\bar{D}}{\hat{\sigma}_D}$$

ここで $\hat{\sigma}_D$ は差の標準偏差の推定値です。図 10.16 では Cohen の $d = 1.45$ であり、2 回目の成績が 1 回目の成績より平均して標準偏差 1.45 だけ高いことを示しています。

これが JASP の 'Paired Samples T-Test' の分析で報告される Cohen の d の版です。唯一やっかいなのは、これが自分の欲しい指標かどうかを見極めることです。研究の実務的な帰結を気にかけるのであれば、差の得点ではなくもとの変数を基準に効果を測りたいことが多いでしょう (たとえば Chico 博士のクラスでの 1 点の伸びは、学生間の成績のばらつきに照らせばかなり小さいものです)。その場合は Student や Welch の検定で使うのと同じ版の Cohen の d を使います。JASP でこれをやるのはそう簡単ではなく、本質的にはスプレッドシート画面でデータの構造を変える必要がありますので、ここでは立ち入りません。

10.9

標本の正規性を確認する

この章でここまで扱ってきた検定はすべて、データが正規分布にしたがうことを仮定していました。中心極限定理 (セクション 7.3.3) のおかげで、現実世界の多くの量は正規分布に近くなる傾向がありますので、この仮定はたいいてい十分に妥当です。自分の変数が実はいろいろなものの平均なのではないかと思うときには、それが正規分布にしたがうか、少なくとも t 検定を使ってもよい程度には正規に近い可能性がかなり高いでしょう。とはいえ人生に保証はありませんし、そもそも変数がひどく正規から外れてしまう道筋はいくらでもあります。たとえば、自分の変数が実はいろいろな

の最小値なのではないかと思うときには、かなり歪んだ分布になる可能性が非常に高くなります。心理学では反応時間 (RT) のデータがそのよい例です。人間の参加者から反応を引き起こしうるものがたくさんあるとすると、実際の反応はそうした引き金となる出来事のどれかが最初に起きたときに生じます^{*10}。ですから RT のデータは系統的に正規から外れることになります。さて、すべての検定が正規性を仮定していて、現実のデータは (少なくとも近似的には) たいいてい満たすけれども常にではない、というのなら、標本の正規性はどうか確認すればよいのでしょうか。この節では QQ プロットと Shapiro-Wilk 検定の 2 つの方法を扱います。

10.9.1 QQ プロット






Figure 10.20 100 個の観測からなる正規分布する標本 `normal.data` のヒストグラム (パネル a) と正規 QQ プロット (パネル b)。このデータの Shapiro-Wilk 統計量は $W = .99$ で、正規性からの有意な逸脱は検出されなかった ($p = .73$)。

標本が正規性の仮定を破っていないかを確認するひとつの方法は、“QQ プロット”(分位点-分位点プロット)を描くことです。これによって、系統的な違反が見られないかを視覚的に確認できます。QQ プロットでは、それぞれの観測が 1 つの点として描かれます。x 座標は、データが正規分布にしたがう (平均と分散は標本から推定) としたときにその観測が入るはずの理論的な分位点で、y 座標は標本の中でのそのデータの実際分位点です。データが正規なら、点は直線を描くはずで、たとえば正規分布から標本を取ってデータを生成し、QQ プロットを描くとどうなるかを見てみましょ


^{*10} これはほとんどない単純化です。




(a)



(b)



(c)



(d)

Figure10.21 上段は、`skewed.data`に含まれる 100 個の観測のヒストグラム (パネル a) と正規 QQ プロット (パネル b)。このデータの歪度は 1.94 で、それが QQ プロットの上向きの曲がりに表れている。その結果 Shapiro-Wilk 統計量は $W = .80$ となり、正規性からの有意な逸脱を示している ($p < .001$)。下段は、同じく 100 個の観測からなる裾の重いデータについての同じプロット。この場合はデータの重い裾によって尖度が高くなり (2.80)、QQ プロットは中央で平らになり、両端で急に曲がる。結果として Shapiro-Wilk 統計量は $W = .93$ となり、やはり有意な非正規性を示している ($p < .001$)。

う。結果は図 10.20 に示しました。見てのとおり、このデータはかなりまっすぐな直線を描いています。正規分布から取ったのですから驚くことはありません。これに対して、図 10.21 の 2 つのデータを見てください。上のパネルは大きく歪んだデータのヒストグラムと QQ プロットで、QQ プロットが上向きに曲がっています。下のパネルは裾の重い (つまり尖度の高い) データについての同じプロットで、この場合 QQ プロットは中央で平らになり両端で急に曲がります。

10.9.2 Shapiro-Wilk 検定

QQ プロットはデータの正規性を略式に確認するよい方法ですが、もう少し形式的なことをやりたくなることもあるでしょう。そのときに探しているのはおそらく **Shapiro-Wilk 検定** です (Shapiro and Wilk 1965)^{*11}。予想どおり、検定される帰無仮説は「N 個の観測が正規分布にしたがう」というものです。

計算される検定統計量は慣例的に W と書かれ、次のように計算されます。まず観測を小さい順に並べ替え、標本のなかで最小の値を X_1 、2 番目に小さい値を X_2 、という具合に置きます。すると W の値は次のように与えられます。

$$W = \frac{\left(\sum_{i=1}^N a_i X_i\right)^2}{\sum_{i=1}^N (X_i - \bar{X})^2}$$

ここで $\bar{X}$ は観測の平均で、 a_i の値は……ごによごによ……入門書の範囲を少し超える、何やら複雑なものです。

W 統計量の背後にある数学を説明するのは少し難しいので、そのふるまいを大づかみに述べるほうがよいでしょう。本書で出会う検定統計量の多くとは違って、正規性からの逸脱を示すのは W の小さい値のほうです。 W 統計量の最大値は 1 で、データが“完全に正規”に見えるときにそうなります。 W の値が小さいほど、データは正規から遠いということです。ただし W の標本分布は、Chapter 6 で論じた標準的なもののどれでもありませんし、実際扱うのがまったく面倒なしろものですが、標本サイズ N に依存します。この標本分布がどんな形か感覚をつかんでもらうために、図 10.22 に 3 つ描きました。標本サイズが大きくなるにつれて標本分布が $W = 1$ の近くにぎゅっと集まること、その結果として標本が大きい場合には W が 1 よりそれほど小さくなくても検定が有意になることに注意してください。

JASP の t 検定で Shapiro-Wilk 統計量を得るには、‘Assumption checks’の下にある ‘Normality’

^{*11}あるいは Kolmogorov-Smirnov 検定でしょう。こちらのほうが Shapiro-Wilk よりおそらく伝統的です。私が読んだものの多くは Shapiro-Wilk のほうが正規性の検定として優れていると示唆しているようですが、Kolmogorov-Smirnov は分布の同等性についての汎用の検定で、他の種類の分布の検定にも応用できます。JASP では Shapiro-Wilk 検定が採用されています。

Sampling distribution of W
(for normally distributed data)





Figure10.22 データが正規分布にしたがうという帰無仮説のもとでの、標本サイズ 10・20・50 の Shapiro-Wilk の W 統計量の標本分布。正規性からの逸脱を示すのは W の小さい値であることに注意。

.....

のオプションにチェックを入れます。QQ プロットに使った無作為抽出のデータ ($N = 100$) では、Shapiro-Wilk の正規性検定の統計量は $W = 0.99$, p 値は 0.69 でした。ですから当然ながら、このデータが正規性から逸脱しているという証拠はありません。Shapiro-Wilk 検定の結果を報告するときは、(いつものように) 検定統計量 W と p 値を必ず入れるべきですが、標本分布が N に大きく依存することを考えると、 N も入れておくのが親切でしょう。

10.9.3 例

ここで、データが正規でなかった場合に QQ プロットと Shapiro-Wilk 検定がどうなるかの例を示しておく価値があるでしょう。そのために、AFL の勝ち点差のデータの分布を見てみましょう。Chapter 4 を思い出せば、これはまったく正規分布から来たようには見えませんでした。QQ プロットは次のようになります。



そして AFL の勝ち点差のデータに *Shapiro-Wilk* 検定を実行すると、*Shapiro-Wilk* の正規性検定の統計量は $W = 0.94$ 、 p 値 = $9.481\text{e-}07$ となります。これは明らかに正規性からの有意な逸脱です。

10.10

正規でないデータを *Wilcoxon* 検定で検定する

さて、データがかなりはっきり正規から外れているのに、それでも t 検定のようなものを実行したい場合はどうすればよいでしょうか。この状況は現実によく起こります。たとえば AFL の勝ち点差のデータでは、*Shapiro-Wilk* 検定によって正規性の仮定が破られていることがはっきりしました。こうした場面で *Wilcoxon* 検定を使いたくなるわけです。

t 検定と同じく、*Wilcoxon* 検定にも 1 標本と 2 標本の 2 つの形があり、対応する t 検定とほぼまったく同じ場面で使われます。 t 検定と違って *Wilcoxon* 検定は正規性を仮定しません。これはありがたいことです。実際、どんな種類の分布であるかについて何の仮定も置きません。統計の専門用語では、これを**ノンパラメトリック検定**と呼びます。正規性の仮定を避けられるのはよいことです。が、欠点もあります。*Wilcoxon* 検定はふつう t 検定より検定力が低い (つまりタイプ II エラー率が高い) のです。*Wilcoxon* 検定を t 検定ほど詳しくは扱いませんが、概略を述べておきます。

10.10.1 2 標本の Mann-Whitney の U 検定

まず **Mann-Whitney の U 検定** から説明します。実は 1 標本版より単純だからです。10 人のある検査の得点を見ているとしましょう。もう想像力が完全に尽きましたので、これは “すごさの検査” だということにして、“A” と “B” の 2 つの群があるとしします。どちらの群がよりすごいのか知りたいわけです。データは `awesome.csv` ファイルに入っていて、いつもの `ID` 変数のほかに `scores` と `group` の 2 つの変数があります。

同順位 (つまりすごさの得点がまったく同じ人) がない限り、やりたい検定は驚くほど単純です。群 A のすべての観測を群 B のすべての観測と比較する表を作るだけです。群 A のデータのほうが大きいときには、表にチェックマークを入れます。

		群 B				
		14.5	10.4	12.4	11.7	13.0
群 A	6.4	.	.	.	.	.
	10.7	.	✓	.	.	.
	11.9	.	✓	.	✓	.
	7.3	.	.	.	.	.
	10.0	.	.	.	.	.

そしてチェックマークの数を数えます。これが検定統計量 W です^{*12}。 W の実際の標本分布はやや複雑ですので、詳細は省きます。ここでの目的には、 W の解釈が t や z の解釈と質的に同じだと知っておけば十分です。つまり両側検定なら W が非常に大きいのか非常に小さいときに帰無仮説を棄却し、方向性のある (つまり片側の) 仮説ならどちらか一方だけを使います。

JASP で ‘Independent Samples T-Test’ を、`scores` を従属変数、`group` を群分け変数として実行し、‘tests’ のオプションで ‘Mann-Whitney’ にチェックを入れると、 $U = 3$ (つまり上に示したチェックマークの数と同じ)、 p 値 = 0.05556 という結果が得られます。

10.10.2 1 標本の Wilcoxon 検定

1 標本の Wilcoxon 検定 (あるいは同じことですが、対応のある標本の Wilcoxon 検定) はどうでしょうか。統計の授業を受けることが学生の幸福感に影響するかどうかを知りたいとしましょう。データは `happiness.csv` ファイルに入っています。ここで測ったのは、授業を受ける `before` (前) と `after` (後) の各学生の幸福感で、`change` の得点はその 2 つの差です。 t 検定で見たのと同じく、`before` と `after` を使って対応のある標本の検定をすることと、`change` の得点を使って 1 標本の検定

^{*12}実は検定統計量には、定数分だけ異なる 2 つの版があります。ここで説明したのは JASP が計算するほうです。

をすることのあいだに、本質的な違いはありません。先ほどと同じく、この検定をいちばん単純に考えるには表を作ることです。今回のやり方は、正の差である変化の得点を取り、それを標本全体と突き合わせて表にすることです。できあがるのは次のような表です。

		すべての差									
		-24	-14	-10	7	-6	-38	2	-35	-30	5
正の差	7	.	.	.	✓	✓	.	✓	.	.	✓
	2	.	.	.	.	.	.	✓	.	.	.
	5	.	.	.	.	.	.	✓	.	.	✓

今回チェックマークを数えると、検定統計量は $W = 7$ になります。先ほどと同じく、両側検定なら W が非常に大きいのか非常に小さいときに帰無仮説を棄却します。JASP での実行は、だいたい予想どおりです。1 標本版では、'One Sample T-Test' の分析ウィンドウの 'Tests' の下にある 'Wilcoxon signed-rank' のオプションを指定します。すると Wilcoxon の $W = 7$, p 値 = 0.037 が得られます。これが示すように、有意な効果があります。どうやら統計の授業を受けることは幸福感に影響するようです。対応のある標本の版に切り替えても、もちろん違う答えにはなりません。図 10.23 をご覧ください。




Figure 10.23 1 標本および対応のある標本の Wilcoxon ノンパラメトリック検定の結果を示す JASP の画面

11. 相関と線形回帰

この章の目標は相関と線形回帰を導入することです。これらは連続的な予測変数と連続的な結果変数の間の関係を分析する時に使われる、標準的なツールなのです。

11.1

相関

このセクションでは、データの変数間の関係をどうやって記述するかについて論じようと思います。そのために、変数間の相関について主に話すことになります。でもまず、あるデータについて触れておかなければなりません。

11.1.1 データ

Table11.1 親子関係データの記述統計量

変数名	最小値	最大値	平均値	中央値	標準偏差	四分位範囲 (IQR)
ダンの不機嫌さ	41	91	63.71	62	10.05	14
ダンの睡眠時間	4.84	9.00	6.97	7.03	1.02	1.45
ダンの息子の睡眠時間	3.25	12.07	8.05	7.95	2.07	3.21

どの親でも身近な話題である、睡眠についてのトピックを見てみましょう。ここで使うデータセットは架空のものですが、事実に基づいたものです。幼い息子の睡眠習慣が私の気分になんくらい影響しているのかを知りたい、と思ったとしましょう。私の不機嫌さを、0(全く不機嫌でない) から100(非常に非常に不機嫌である) までのスケールで正確に評定できるとしましょう。さらに私の不機

嫌さをと、睡眠パターン、そして息子の睡眠パターンについて、測定していたとしましょう。そうですね、100 日分ぐらい。そして、マニアックなことに、私はそのデータを `parenthood.csv` というファイル名で保存したのです。そのデータを JASP に読み込むと、4 つの変数があることがわかります。`dan.sleep`, `baby.sleep`, `dan.grump` そして `day` です。初めて JASP セットに読み込むときは、それぞれのデータ変数型が正しく読み込まれないかもしれませんが、そのときは次のように修正してください。`dan.sleep`, `baby.sleep`, `dan.grump` そして `day` 変数は連続変数であると指定し、`ID` は名義的な I(整数の) 変数にするのです。

次に、基本的な記述統計量を見てみましょう。この興味深い三つの変数それぞれがどのようなになっているか、可視化した記述を与えてくれるのが、図 11.1 に示したヒストグラムのプロットです。もう一つ注意点を。JASP はいくつもの複数の異なる統計量を計算することができるからといって、全てをレポートする必要はありません。これをレポートにするときには、おそらくこれらの統計量の中から自分(と私の読者)にとって最も興味があるものをピックアップして、それを素敵で単純な表のような形にして示すでしょう。表 11.1 のようにね^{*1}。私がそれを表にする時には、全て“人間が読める”変数名を付与します。これはいいやり方です。私は十分に寝れていないことにも注意してください。これは良いやり方ではないですね。でも他の親御さんたちからはよくあることだと言われます。




Figure 11.1 `parenthood` データセットに含まれる 3 つの変数のヒストグラム

11.1.2 関連の強さと方向

2 つの変数がどれぐらい密接に関係しているかを表す一般的な方法として、散布図を描くことができます。理想を言えば、もうちょっと言葉を足したいところですが。例えば、`dan.sleep` と `dan.grump`

^{*1}実は、表にしてもまだ悩ましいものです。実際にほとんどの人は、中心化傾向の測度ひとつだけ、変数のある側面だけをピックアップします。




Figure 11.2 `dan.sleep` と `dan.grump` の関係を示す散布図 (左) と, `baby.sleep` と `dan.grump` の関係を表す散布図 (右)

(図 11.2, 左) の関係と, `baby.sleep` と `dan.grump` (図 11.2, 右) の関係を比較してみましょう。両者を並べてみてみたら, 明らかに両者が質的に同じであることがわかります。よく寝るとイラつきが減るのです! しかし, `dan.sleep` と `dan.grump` の関係が `baby.sleep` と `dan.grump` の関係よりもより強いこともまた, 明らかです。左側のプロットは右側のものよりも“弱い”のです。もし私の機嫌を予測したいと思ったのなら, 私の息子が何時間ぐらい寝たかを知ることによって多少の助けにはなりますが, それよりも私が何時間寝たかを知った方がより役に立つわけです。

比較として, 図 11.3 をみてみましょう。“`baby.sleep` と `dan.grump`” の散布図 (左) を, “`baby.sleep` v `dan.sleep`” の散布図 (右) と比べてみると, 全体的な関係の強さは同じですが, 方向が逆になっています。つまり, もし私の息子がよく寝てくれたら, 私はより多く寝ることができます (正の関係, 右側です), 彼がよく眠ると私のムカつきはより少なくなるのです (負の関係, 左側です)。

11.1.3 相関係数

この考え方を, もう少し正確にして **相関係数** の考え方を導入しましょう (もっと正確に言えば, ピアソンの相関係数です)。これは伝統的に, r で表されます。変数 X と Y の間の相関係数 (r_{XY} と表されます) は, 次のセクションでももう少し正確に定義しますが, その測度は -1 から 1 の間の値になります。もし $r = -1$ であれば, 完全に負の関係にあることになり, $r = 1$ であれば, 完全に正の関係にあると言えます。もし $r = 0$ であれば, 全くの無関係です。図 11.4 に異なる相関関係がどうい




Figure11.3 散布図が示すのは `baby.sleep` と `dan.grump` の関係 (左), それと `baby.sleep` と `dan.sleep` の関係 (右) です

う見え方をするか、いくつか示してあります。

ピアソンの相関係数の式は、いくつかの表記方法があります。その式を最も簡単に書き下す方法は、2つのステップに分けることだと思います。まず、**共分散**の考え方を導入します。変数 X と Y の共分散は分散の一般化として導入でき、数学的には2つの変数の関係を記述するものです。それほど有益なものではありません。

$$\text{Cov}(X, Y) = \frac{1}{N-1} \sum_{i=1}^N (X_i - \bar{X}) (Y_i - \bar{Y})$$

X に関する量と Y に関する量の掛け算をして(“積”), それを平均しています⁴。共分散の式は X と Y の “積和平均” だと考えることができます。

共分散は良い特徴を持っていて、もし X と Y が完全に関係ない場合、共分散はゼロになります。もしその関係が正であれば(図 11.4 に示したように), 共分散は正の値になりますし、その関係が




Figure11.4 相関の強さと方向を変えた影響を図示したもの。左の列は、相関が 0, .33, .66, そして 1 になっています。右側の列は、相関が 0, -.33, -.66, そして-1 のものです。

負であれば共分散の値もまた負になるのです。言い換えれば、共分散は相関の基本的な考え方をうまく捉えています。

残念ながら、共分散の大きさは簡単に解釈できません。というのもそれは X と Y の持っている単位に依存しますし、さらに悪いことに、共分散の実際の単位は少し奇妙なのです。例えば、もし X が `dan.sleep` 変数 (単位: 時間) で、 Y が `dan.grump` 変数 (単位: 不機嫌さ) のとき、その共分散は “時間 × 不機嫌さ” になります。これがどういう意味なのか、私にはさっぱりです。

ピアソンの相関係数 r は共分散を標準化するために解釈の問題を解決してくれます。まさに、元のデータを標準偏差で割った標準化した z スコアと同じように。しかし、2 つの変数が共分散に関わっていますので、標準化するのはそれぞれの標準偏差で割っていることになります^b。言い換えるなら、 X と Y の相関係数は次のように書くことができるのです。

$$r_{XY} = \frac{\text{Cov}(X, Y)}{\hat{\sigma}_X \hat{\sigma}_Y}$$

^a分散と標準偏差でもみてきましたが、実践的には N ではなく $N - 1$ で割るのです

^bこれはちょっと単純化しすぎですが、ここでの目的には合います。

共分散を標準化することによって、先ほど指摘した共分散の良い特徴を失うことなく、 r の値が強度を表すようになります。すなわち、 $r = 1$ は完全な正の相関を表しますし、 $r = -1$ は完全に負の相関を表すことになります。この点については後ほど、セクション 11.1.5 でもう少し広げます。でもその前に、JASP でどうやって相関を計算するのかをみておきましょう。

11.1.4 JASP で相関を計算する

JASP で相関を計算するのは、‘回帰’-‘相関行列’ ボタンをクリックするだけです。4 つの変数全てを右のボックスにうつし、図 11.5 の出力を得ます。各相関係数 (‘ピアソンの r ’ とあるもの) に、 p -値がついていることに注意してください。明らかに、なんらかの検定が行われていますが、今それは無視することにしましょう。それについては、近々お話しすることになるでしょう!

11.1.5 相関係数を解釈する

当然、実際の生活では相関係数が 1 になるのを目にすることはありません。では、例えば $r = .4$ であればどう解釈したら良いのでしょうか? 丁寧に答えるなら、あなたがそのデータをどう使うかによりますし、あなたのフィールドでどれくらい強いといえるのかによります。工学系の友人と相関係数と話した時、.95 以下であれば全く無意味だということでした (工学系の中でも、ちょっと話を盛ってる気がしますけど)。一方、心理学でもそうですが、それくらいの強さを期待できる相関係数




Figure11.5 parenthood.csv ファイルにある変数間の相関係数を示した JASP スクリーンショット

が実際にみられることもあります。たとえば、人はどのように類似性を判断するか¹の理論を検証するのに使うベンチマークデータセットは非常にクリーンで、少なくとも .9 の相関を達成しないようであれば成功したと言えないそうです。とはいえ、知能の基本的な相関 (たとえば、洞察の時間、反応時間) を探しているときは、相関係数が .3 を超えることがあればうまく行った方です。要するに、相関係数の解釈は文脈に依存するということです。とはいえ、表 11.2 が典型的な例です。

しかし、データにいかなる解釈をする場合でもその前に、常に散布図を確認しろというのは強調しすぎるということはありません。相関はあなたが思うような意味を持ってないかもしれないのです。“Anscombe の四人組” (Anscombe 1973) という 4 つのデータセットについての古典的な例が、このことを示しています。それぞれのデータは 2 つの変数 X と Y をもっています。4 つのデータセットは全て、 X の平均が 9 で Y の平均が 7.5 になっています。すべての X の標準偏差もほとんど同じで、 Y 変数についてもそうです。そしてどのデータセットも、 X と Y の相関係数は $r = 0.816$ になっています。ファイル `anscombe.csv` に用意したので、みなさん自身で確認してみてください。

この 4 つのデータセットがほとんど同じ性質であるとおもったでしょうか。ちがいますよ。4 つのデータセットすべてについて、 X と Y の散布図を描いたのが図 11.6 ですが、この 4 つはお互いまったく違うものであることがわかるでしょう。ここでの教訓は、実生活において我々がよく忘れてしま

Table11.2 相関を解釈する大雑把な目安。大雑把なものであると言っていることに注意。関係の強弱に明確なルールはありません。文脈に依存するものです。

相関	強さ	方向
-1.0 to -0.9	とても強い	負
-0.9 to -0.7	強い	負
-0.7 to -0.4	中程度	負
-0.4 to -0.2	弱い	負
-0.2 to 0	無視できるレベル	負
0 to 0.2	無視できるレベル	正
0.2 to 0.4	弱い	正
0.4 to 0.7	中程度	正
0.7 to 0.9	強い	正
0.9 to 1.0	とても強い	正

うことですが、“データはいつも図にする”(第 5 章)ということです。

11.1.6 スピアマンの順序相関

ピアソンの相関係数は便利な特徴が多くありますが、欠点もあります。ある問題点は特に目立ちます：それが表しているのは、二変数間の直線的な関係だということです。言い換えると、わかることはデータがひとつの完全なる直線に収まる程度の指標なのです。時にこれは私たちが“関係がある”という言葉で意味することの良い近似になりますし、ピアソンの相関はそれを計算するのにもってこいです。でも時には、そうならないのです。

ピアソンの相関係数が適切でない場合について、非常にありがちなケースは変数 X が他の変数 Y の増加を反映しているものの、本当の関係は線形ではないような場合です。例として、試験勉強の努力量と結果の関係を考えてみましょう。もし努力量 (X) がゼロなら、成績 (Y) も 0% になるでしょう。でも少し努力すれば、それはかなり改善されます。授業に合わせて勉強していくのは良いことですし、授業内容だけに絞って行ってもそれほどの努力なしで 35% ぐらいまでは成績が上がるでしょう。でも成績尺度の逆の端では、同じ効果を見込むことはできません。誰でも知っているように、55% の成績を取るよりも 90% の成績を取る方が、ぐっと多くの努力を必要とします。何が言いたいかというと、試験勉強と成績のようなデータをとったとすると、そこでピアソンの相関係数を見ることがミスリーディングであるという例になるのです。

これを示すために、図 11.7 を用意しました。ここでは 10 人の学生がある授業を履修していた時の、勉強時間と成績の関係をプロットしてあります。この (架空の) データセットで興味深い点は、




Figure11.6 Anscombe の四人組。この四つのデータセットはいずれも相関係数 $r = .816$ だが、それぞれ質の違うものである。

.....

努力するとかならず成績が上がるというところです。多かろうが少なかろうが、努力量を増やしさえすれば成績が下がることは決してありません。ピアソンの相関係数を計算してみると、勉強時間と成績との関係を表すことができ、その係数は 0.91 であることがわかります。しかし勉強時間を増やせばいつでも成績が上がるという関係を、実際に反映しているとは言えません。ここで本当に私たちが言いたいことは、相関は完全であるということなのですが、そのためには“関係”がどうなっているのかについて別の表現が必要だということです。私たちが探しているのはこの事実をうまく反映する何かであって、そこには完璧な**順序的な関係**があるということです。すなわち、学生 1 が学生 2




Figure 11.7 たった 10 人の学生からなる仮想データセットで、労働時間と成績の関係をしめしたもの (各円が 1 人の学生を表しています)。真ん中にある点線は二変数の線形関係を表しています。ピアソンの相関は強くて $r = .91$ です。でもここで注目すべきは、二変数が完全に単調なかんけいにあるということです。この小さなサンプルでは、労働時間の上昇が常に成績の上昇を意味していて、これが点線で描かれています。これはスピアマンの相関で言うと $\rho = 1$ であることを意味します。でも、このような小さなデータセットでは、どちらのバージョンがより良く実際の関係を表しているといえるのかは、未解決の問題です。

よりもたくさん勉強したら、学生 1 の成績の方が良くなるということを保証したいわけです。相関が $r = .91$ である、という言い方ではなくね。

どうしたらいいでしょう？ 実は簡単なことなんです。順序的な関係を見る時、データセットが順序尺度水準であるとして扱えばいいのです！ つまり、“勉強時間”という言葉ではなく、10 人の学英の勉強時間順についての順位だといえればいいのです。つまり、学生 1 は誰よりも勉強時間が少ない (2 時間) おですから、最低ランクであるといえます ($\text{rank}=1$)。学生 4 はその次で、半期全体でも 6 時間しか勉強していないのですから、その次に低いランク ($\text{rank}=2$) とします。ここで“ $\text{rank}=1$ ”が“低い順位”を意味していることに注意してください。日常用語で私たちが“1 位だ”というと、“最下位だ”ではなく“最上位だ”ということの意味しますよね。だから注意してほしいのですが、“一番小さな値から一番大きな値にむけて”順序づける (小さいことは $\text{rank } 1$ とする) こともできますし、“一番大きな値から一番小さな値に向けて”順序づける (大きいことを $\text{rank } 1$ とする) こともできます。今回のケースでは小さい方から大きい方に順序づけていきましたが、どういう設定にしたか忘れ

がちなので、ちょっと注意して覚えておいてください!

さて、では努力量と結果について最下位から一位まで順序づけた学生データを見てみましょう。

	順位 (勉強時間)	順位 (試験の成績)
学生 1	1	1
学生 2	10	10
学生 3	6	6
学生 4	2	2
学生 5	3	3
学生 6	5	5
学生 7	4	4
学生 8	8	8
学生 9	7	7
学生 10	9	9

ふむ。両者が一致しましたね。もっとも勉強時間が多かった学生は最も良い成績をもらっていますし、勉強時間が最も少なかった学生は成績も最も悪い、などとなっています。上の表に示したように、2つの順位は一致しているので、その相関を今度みてみると完全な関係、相関係数 **1.0** となります。

ここで再導入したものは**スピアマンの順位相関係数**と呼ばれ、ピアソンの相関係数 r と区別するために ρ で表されます。スピアマンの ρ を JASP で計算するには、単に '相関行列' の画面で 'スピアマン' のチェックボックスをクリックするだけです。

11.2

回帰分析の仮定

線形回帰モデルはいくつかの仮定の上に成り立っています。セクション **11.3** では、この仮定に合致しているかどうかをチェックする方法について説明しますが、まずはそれらを見ておきましょう。

- 正規性の仮定。統計における多くのモデルと同じように、単回帰であれ重回帰であれ、正規性の仮定お上に成立しています。特にその残差が正規分布していることを仮定しています。予測変数 X と結果変数 Y が正規分布に従っていてもいいのですが、残差 ε は正規分布に従っていないければなりません。これはセクション **11.3.3** をみてください。
- 線形性。線形回帰モデルの基本的な仮定ですが、変数 X と Y の間には線形関係がなければなりません! 単回帰であれ重回帰であれ、その関係は線形でなければならないのです。

- 分散の均一性。厳密に言うなら、回帰モデルは各残差 ε_i が平均 0 の正規分布、そして(ここでの目的では特に重要なことですが) ひとつひとつの残差について同じ標準偏差 σ の正規分布であることが重要です。実際には、各残差が同じ分布からきているかどうかを検証するのは不可能です。その代わり、残渣の標準偏差が全ての $\hat{Y}$ について同じであることをみることはできますし、(強いて言えば) モデルにおける全ての予測変数 X についてもそうか、と考えることはできます。
- 予測変数が相関しないこと。重回帰分析においては、説明変数同士があまりにも強く相関しないようにすることが重要です。これは重回帰分析の“理論的な”仮定ではありませんが、実際には求められることです。予測変数が互いに強く相関すると(これは“共線性”と呼ばれます)、モデルの評価の時に影響が出ます。
- 残差が互いに独立していること。これは“包括的な”仮定であり、“残差に何も面白いことは起こっていない”という効果のことです。もし何かおかしいことがあれば(例えば、全ての残差が観測されてない他の変数に強く依存しているなど)、物事を歪めてしまうのです。
- “悪さをする”外れ値がないこと。改めて、これもモデルの理論的な仮定ではありませんが(あるいはむしろ、他の全てに共通する種類の話かもしれませんが)、回帰モデルが 1 つ 2 つの異常なデータ点に強く影響されているというようなことがないようにしなければなりません。なぜなら、モデルの適切さに関わりますし、いくつかのケースがもつデータの信憑性に関わるからです。これについてはセクション 11.3.2 を参照してください。

11.3

モデルのチェック

このセクションの主な狙いは、**回帰分析の診断**で、回帰モデルの仮定が満たされているかチェックしたり、もしその過程が満たされていないのであればどのようにモデルを修正すれば良いか、なにも“おもしろいこと”が起きていないことをチェックするにはどうすれば良いか、という職人芸を考えることです。ここでモデルチェックの“職人芸”といったのには理由があります。これは簡単なことではなくて、診断に利用できる標準的なツールはたくさんあるし、あなたのモデルの問題点(もし何かあれば、と言うことですが)を修正してくれたりもするんですが、これらを実行する時にかなりの判定をすることになるので、あなたが本当にやらなければならないことはその練習なのです。微に入り細に入り細に入って詳細を検証すると迷子になっちゃいますし、細々としたこと全てを覚えておこうとすると疲れてしまいます。ツールの全てを学ぼうとすると、非常にフラストレーションが貯まるという副作用がありますので、あらゆるモデルチェックを対象にするのは諦めよう、となるのです。これはちょっとまずいですねえ!

このセクションでは、あなたの回帰モデルが想定していたことをチェックするための、いくつかの

異なる方法を提示します。あなたがすべきこと全てをカバーするものではありませんが、多くの人が実践することよりも多少くわしく解説します。本来導入のクラスでこの全てをやることはないんですけどね。ですが、どんなツールが使えるのかを知ってもらうことは重要だと思いますので、そのいくつかを紹介したいと思います。最後に、このセクションは [Fox and Weisberg \(2011\)](#) のテキストに多くを負っていることを指摘しておきましょう。これは、R で回帰分析を実行するときに使う `car` パッケージについての本です。`car` パッケージは、回帰分析の診断に優れたいくつかのツールを提供するのですが、その本を見れば見事にわかりやすく解説してくれています。あまり大それたことは言いたくないのですが、JASP にはなくて R にだけあるより優れた診断技術を見るためだけでも、[Fox et al. \(2011\)](#) を読む価値があると思いますよ。

11.3.1 3 種類の残差

回帰分析の診断の主なものは、残差を見ることで行われます。ここまでの話で、あなたは頭の中で悲観的な統計学理論を作り上げ、残差をしっかりと見ないといけないということならば考えないといけない残差にはいくつかの種類があるのでは、という推測ができるようになっているでしょう。このセクションでは以下の 3 種類の残差について考えます。“普通の残差”、“標準化された残差”、そして“Student 化された残差”です。図にあるように、第 4 の“ピアソン残差”というものもあります。しかしこの章で考えるモデルについては、ピアソン残差は普通の残差とおなじものになります。

第一の、最も単純な残差が**普通の残差**です。これは実際に生の残差で、この章でこれまで話してきたものと同じです。普通の残差とは、単に予測値 $\hat{Y}_i$ と観測値 Y_i の差分のことです。第 i -番目の普通の残差を示すために、これまで ε_i という表記を使ってきましたが、これからもそうしていきたいと思います。これを覚えておいていただいて、ごく単純な方程式から、

$$\varepsilon_i = Y_i - \hat{Y}_i$$

とすることができます。もちろんこれは以前見たことがあると思いますし、特に残差の種類に言及しない限り、残差といえばこれのことです。ここに目新しいものはありません。ただ繰り返しただけです。普通の残差の欠点は、結果変数が何であるか、回帰モデルがどれほど良いものであったかに依存した、毎回異なる単位で現れることです。つまり、切片なしで回帰モデルを実行すると、普通の残差の平均は 0 ですが、分散は毎回の回帰モデルごとに変わってしまうわけです。たいていの文脈では、特に残差のパターンにのみ興味があってその実際の値には興味がないという場合は、**標準化された残差**を考えるほうが便利です。それは標準偏差が 1 になるように標準化されているのですから。

これを計算するには、普通の残差をこれらの残差から推定された (母集団の) 標準偏差で割ること

になります。技術的な理由から、かくかくしかじかあって、次のような形になります。

$$\varepsilon'_i = \frac{\varepsilon_i}{\hat{\sigma}\sqrt{1-h_i}}$$

ここで $\hat{\sigma}$ は推定された母集団における普通の残差の標準偏差で、 h_i は i 番目の観測における“推定値”です。推定値とは何であるかについては説明していませんが²、それほど大きな意味はありません。今のところは、普通の残差を z スコアに変換するための標準化された残差だ、と思っていただければ十分です。事実、それ以上でもそれ以下でもなくて、ちょっとファンシーになったぐらいのものですよね。

²あるいは望まれないかもしれませんが、その機会があるかも

3 番目の残差は **Student 化された残差** (別名 “ジャックナイフ残差” です) であり、標準化された残差よりもファンシーな感じです。ここでのアイデアは、あらためて、普通の残差をある量で割ったものになります。ねらいは残差のある標準化された推定値にすることです。

この計算をするときの式は、ちょっと異なっていて次のようになります。

$$\varepsilon_i^* = \frac{\varepsilon_i}{\hat{\sigma}_{(-i)}\sqrt{1-h_i}}$$

ここでの推定された標準偏差が $\hat{\sigma}_{(-i)}$ になっていることに注意してください。これが意味することは、第 i 番目の観測がデータから削除された時に、あなたが手に入れるであろう残差の標準偏差を推定するということです。悪夢のような計算をしているように思えるかもしれません。だって、 N 回の新しい回帰分析をやれと言われてるようにみえるからです (最近の計算機でも、大きなデータセットであれば少し文句を言うかもしれません)。ところが幸い、とにかく頭のいい人たちが、この標準偏差は実際次のような計算で得られることを示してくれました。

$$\hat{\sigma}_{(-i)} = \hat{\sigma} \sqrt{\frac{N-K-1-\varepsilon_i'^2}{N-K-2}}$$

これなら軽いものでしょ？

先に進む前に、この残差はほとんど全ての回帰診断の中心にあるとはいえ、自分で求める必要はそんなにない、ということは伝えておきたいと思います。ほとんどの場合、さまざまな診断や仮定のチェックが提供され、これらの計算の面倒を見てくれるでしょう。とはいえ、標準的でない手法が必要になるかもしれないことを考えて、実際にどう計算するかを知っていることはいつだっていいことではあります。

11.3.2 3 種類の異常値




Figure11.8 外れ値の図。点線が外れ値を含まない時の回帰線とそれに対応する残差 (標準化された残差) です。実線は異常値も含んだ回帰直線。外れ値は結果変数 (y 軸上) における普通でない値であって、予測変数 (x 軸上) のものではなく、回帰線から大きく離れているものです。

線形回帰分析をする時に危険な問題の 1 つは、ごく少ない“普通でない”，あるいは“異常な”観測値のせいでかなり敏感になってしまっていることです。これについては以前，セクション 5.2 の外れ値の文脈で議論しました。そこでは‘探索’-‘記述統計’のところにあるボックスプロットのオプションを使って，自動的に特定されるものでしたが，今回もう少し正確に話を進めたいと思います。線形回帰の文脈では，“異常値”と呼ばれるものは，概念上 3 つに区別されます。いずれも興味深いものですが，分析においては異なる意味合いをもたらすものです。

最初の異常な観測値は**外れ値**です。外れ値の定義は (この文脈では)，回帰モデルの予測するものから大きく外れる観測値ということです。その例を図 11.8 に示しました。実際には，外れ値はかなり大きな標準化された残差， ϵ_i^* を持っているものとするとして，この概念を操作化できます。外れ値は興味深いものです。大きな外れ値はデータのコミかもしれません。つまりデータセットで正しく記録されなかったのかもしれないし，他の欠陥が検出される可能性があります。外れ値だからと言




Figure11.9 高いレバレッジ点の図。この時の異常値は、予測変数 (x 軸) と結果変数 (y 軸) のどちらにおいても普通じゃない値ですが、この異常さはその他の観測値間に見られる相関パターンとかなり一貫したものです。観測値は回帰線の近くにありますが、それを邪魔するものではありません。

う理由で、この観測データを取り除くべきではありません。これが外れ値であるという事実は、そのケースをじっくり見て、なぜ違いが生じたのかを見つける手がかりでもあるのです。

普通じゃない観測値を見つける 2 つめの方法は、それが高いレバレッジを持っているかどうかです。これは他のすべての観測値からぐっと異なる観測が生じた時に生じます。これは必ずしも大きな残差を伴って生じるものではありません。他のすべての観測値からぐっと異なる、ということを正確に言いかえるなら、それは回帰直線にはとても近いところにあるのに、といえます。この例を図 11.9 に示しました。観測値のレバレッジとは、そのハット値の言葉で操作的に定義され、 h_i と表されます。ハット値の式は、少し複雑ではありますが^{*2}が、その解釈はそれほど複雑ではありません。 h_i は i -番目の観測値が回帰線がぐっと伸びた時の行き着く先を“制御”しているもののなのです。

^{*2}あらためて、線形代数マニア向けのせつめいです。“予測値行列”が行列 H で表すとすると、観測値ベクトル $\mathbf{y}$ を予測値ベクトル $\hat{\mathbf{y}}$ に変換する、 $\hat{\mathbf{y}} = H\mathbf{y}$ として定義されます。この名前は“ $\mathbf{y}$ にハットをかぶせる”行列であることから来ています。第 i -番目のハット値は、行列の i -番目の対角要素です (技術的なことですが、これは h_i より h_{ii} で表すべきことです)。オウ、これをどうやって計算するかお分かりになるところですかね。こうです: $H = X(X'X)^{-1}X'$. あらかわいい。ですよ？

一般に、ある変数が、予測変数からなる項の他の変数から遠く離れているなら、大きなハット値をもっていることになります (非常に大雑把に説明するなら、高いレバレッジは平均の 2-3 倍以上ということです。そしてハット値の総和は $K + 1$ に制限されています)。高いレバレッジ点についてはもっと細かく見る価値がありますが、それが異常値でない限り、懸念材料になる可能性は低いでしょう。

ここで第 3 の普通じゃなさが出てきます。観測の**影響度**です。これは高いレバレッジ点を持っている外れ値のことです。すなわち、ある面では他のすべての点から大きく外れており、また回帰線からも遠く離れているのです。この状況を図 11.10 に示しました。以前の 2 つの図と比較してみてください。外れ値は回帰線からそれほど多く離れていませんし、それほど高いレバレッジも持っていません。しかし外れ値でもあり高いレバレッジも持っているようであれば、回帰直線に大きな影響を与えます。なぜこの点が高い影響力を持っているか、そしてなぜそれが大きな問題になるかということの理由がこれです。影響度の測度として知られているのは、**Cook の距離** です。




Figure 11.10 高い影響度を持つ点の図。この場合は、異常値は予測変数 (x 軸) においてかなり異常な値で、回帰線から遠く離れてしまっています。結果的に、回帰線はかなりそれに影響されてしまいます。結果変数 (y 軸) でみてみれば、全体的に典型的な観測点なのですが。

$$D_i = \frac{\varepsilon_i^{*2}}{K+1} \times \frac{h_i}{1-h_i}$$

これは外れ値の測度 (左の項) とレバレッジの測度 (右の項) をかけたものであることに注意してください。

Cook の距離が大きくなるのは、実際かなり外れ値の状態、かつ大きなレバレッジを持っている時、ということになります。大まかに言うと、Cook の距離が 1 以上であれば大きいと言えるでしょう (私がよく使う手っ取り早いルールです)。

JASP では、Cook の距離についての情報は '統計量' メニューの下にある 'ケースごとの診断' をクリックすることで計算できます。このデータを可視化するには 2 つの方法があります。まず、それぞれのケースについて (つまり、データの行ごとに) Cook の距離を見るために、'全て' を選択します。すると図 11.11 のようになります。あるいは、Cook の距離がある閾値を超えた時だけ表示させることもできます。JASP のデフォルトの閾値は 1 です。どちらの場合も、この閾値を超えるデータのケースがないことがわかりますね。

Case Number	Std. Residual	dan.grump	Predicted Value	Residual	Cook's Distance
1	-0.497	56.000	58.140	-2.140	0.002
2	1.104	60.000	55.292	4.708	0.017
3	0.464	82.000	80.045	1.955	0.005
4	-0.477	55.000	57.060	-2.060	0.001
5	0.168	67.000	66.281	0.719	0.000
6	-0.095	72.000	72.407	-0.407	0.000
7	0.053	53.000	52.773	0.227	0.000
8	-0.393	60.000	61.700	-1.700	0.001
9	0.047	60.000	59.797	0.203	0.000
10	0.890	71.000	67.148	3.852	0.003
11	0.959	72.000	68.001	3.999	0.027
12	-1.139	65.000	69.912	-4.912	0.008

Figure11.11 JASP の出力で各ケース/データの行ごとに Cook の距離を表示する

次に出てくる質問はもし大きな Cook の距離が得られたらどうするべきか、ということですね。普通、これに対してバッチリ素早く適用できるルールはありません。おそらく最初にするべきことは、Cook の距離が最大のケース^{*3}を除外して回帰分析を実行し、モデルパフォーマンスと回帰係数がどうなるかを見ることです。もし大きな違いがあるのなら、データセットやあなたが研究中に書き散らしたであろうノートを掘り返して考え直すべき時です。そしてなぜこんなに違いが出たのかを明らかにしましょう。もしあるデータ点が結果を歪めていると言うことが明らかになったら、それを除外することを考えてもいいですが、なぜこのケースが特に質的に他と異なるのか、別に取り分けて分析

^{*3}これを簡単に JASP で実行する方法はいまのところないので、R のもつ **car** パッケージのような、よりパワフルな回帰プログラムから、より発展的な回帰分析を実行するといいでしょう。

しなければならないかをしっかりと説明しなければ、良いやり方とはいえないでしょう。

11.3.3 残差の正規性をチェックする

本書で議論してきた多くの統計ツールと同じように、回帰モデルも正規性の仮定に依存しています。今回の場合は、残差が正規分布に従っていると仮定したことになります。最初にすべきことは、JASPでQQプロットを書くことで、'プロット'-'Q-Qプロット'から標準化された残差のオプションを選んでください。出力は図 11.12 に示した通りで、標準化された残差が回帰分析の理論的な値に対応した関数としてプロットされています。




Figure 11.12 モデルの理論的な値に対して標準化された残差の量を JASP でプロットしたもの。

.....

チェックすべきもう 1 つのことは、予測値と残差の関係をみることです。JASP でこれをするには、さまざまな '残差プロット' をえらぶことで、それぞれ予測変数、結果変数、予測値と残差の関係を散布図にしたものを提供してくれます。図 11.13 を参照してください。これらのプロットでは、'点' の一様分布が得られており、'点' の塊やパターンがはっきり見えないことがわかります。これらのプロットを見ると、プロット全体に点が均一に広がっていることから、特に心配すべきことはない

ように思います。プロット (b) ではやや一様分布でない傾向が見られますが、強い逸脱でもないですしそれほど心配することではないでしょう。




Figure11.13 JASP で作成した残差プロット

もし心配なら、この問題 (およびその他の多くの問題) に対する解決策のひとつは、一つ以上の変数を変換することです。変換はこのテキストの範囲を超えていますが。

11.4

モデル選択

残っている大きな問題の 1 つが、“モデル選択” です。すなわち、データセットの中に複数の変数がある場合、どれを説明変数にしてどれを含めないのがいいのでしょうか。言い換えるなら、**変数選択**の問題です。一般的に、選択は複雑な問題ですが、モデルに含むべき変数のサブセットを選択すると

言う問題に限れば、すこしシンプルになります。とはいえ、この限定的なトピックでもそこまで詳細に語るつもりはありません。そのかわり、これ居ついて考えるための2つの広範囲にわたる原則、そしてあなたのモデルの中に含めるべき変数のサブセットを選択する助けになるような、あるしつかりしたツールについての議論を展開したいと思います。まず、2つの原則についてみてみましょう。

- 自分の選択に実質的な根拠があるのはいいことです。つまり、多くの場合、研究者たるあなたはあり得る回帰モデルの中で理論的に興味のある少数のモデルを取り上げる理由があるはずです。そのモデルはあなたの研究領域において、意味のある解釈ができるものでしょう。このことの重要性を低く見積もってはいけません。統計家は化学的な問題の手助けをするものであって、その逆ではないのです。
- あなたの選択が統計的推測に関するものである場合、単純化と適合度との間にトレードオフがあります。多くの予測変数をモデルに追加すると、モデルは複雑になります。各予測変数は新しい自由パラメータ（つまり新しい回帰係数）を追加することになり、新しいパラメータはそれぞれモデルが確立変数を“吸い取る”容量を増やすことになります。結果的に、あなたがどんな変数を追加しようとも、適合度（たとえば R^2 ）は時には明らかに、時には偶然に増加していきます。もしあなたのモデルを新しいデータに対して一般化したいのであれば、あまりにも変数が多くなるのは避けるべきなのです。

この後ろの原則は、**オッカムの剃刀**と呼ばれることがあり、次のようなことわざで言い表されます。必要以上に中身を増やすな。これの意味は、 R^2 をぶち上げるためだけにあんまり関係のない予測変数を入れるのはやめましょう、ということです。ふむう。んー、もとの方が良さそうですね。

ともあれ、我々が必要としているのは数学的な基準で、回帰分析における変数選択という文脈におけるオッカムの剃刀を実現するための量的な原則です。いくつかのやり方があることがわかっています。そのうちの1つは、**赤池情報量規準** (AIC; [Akaike 1974](#)) というものです。これは現在、JASPの標準的な出力にはなっていませんが、JASPがモデルのデータフィットを計算する手続きの中でごく簡単に計算できます。

線形回帰モデルの文脈では、AIC は n 件の観測データを持ち、 K 個の予測変数（切片は含まない）をもつモデルにたいして、次のようにして計算されます^a。

$$AIC = n \ln(SS_{res}) + 2K$$

^a厳密に言えば、この表現は完璧に正確というわけではありません。赤池の元の定義は、モデルの**最尤推定**についての話についてであり、そのため計算には他の項も入ってきます。しかし、そのほとんどはモデルに依存しておらず、AICの目的としては**モデル比較**なので、それら全てのモデルに含まれる項は数学的には“洗い流され”てしまいます。ですから、ここでの目的に十分な‘骨格’バージョンを提示したのです。

ここで AIC をモデル比較するときの基本的な原則を示しましょう。すなわち、AIC の値が小さい

方がモデルのパフォーマンスがよいということです。細かいレベルでの詳細を無視すれば、AIC が何をしているかははっきりしています。左側の項はモデルの予測が良くなると減少します。右の項はモデルの複雑さが増すと大きくなります。ベストなモデルというのはモデルがデータにフィットして (左側の項, SS_{res} が小さい), より少ない予測変数であること (右の項, K が小さい), この両方の性質を持っているものです。要するに, これはオッカムの剃刀を数学的に組み上げたものになっているということです。

では AIC をどのように使うかのデモンストレーションとして, この章で扱った 2 つの回帰モデルを比較してみましょう。最初の回帰モデルは 1 つの予測変数, `dan.sleep` だけのモデルです (図 11.17 参照)。このモデルでは, $n = 100$ の観測データと, $K = 1$ 個の予測変数, そして $SS_{res} = 1838.714$ でしたから,

$$\begin{aligned} AIC_1 &= n \ln(SS_{res}) + 2K \\ &= 100 \ln(1838.714) + 2(1) \\ &= 753.68 \end{aligned}$$

となります。

つぎに第二のモデル, 2 つの予測変数, `dan.sleep` と `baby.sleep` を持っているモデルです (図 11.20 参照)。このモデルでは, $n = 100$ の観測データと $K = 2$ 個の予測変数, そして $SS_{res} = 1838.685$ でした。ここから,

$$\begin{aligned} AIC_2 &= n \ln(SS_{res}) + 2K \\ &= 100 \ln(1838.685) + 2(2) \\ &= 755.68. \end{aligned}$$

となります。

$AIC_1 < AIC_2$ でしたので, モデル 1 がより良くデータに適合しており, 我々の直感を確かめてくれました。変数 `baby.sleep` を追加したことは, モデルフィットにそれほど貢献せず, 複雑さを増したことになります。AIC は 2 つの要請のバランスをとるものです。追加されたパラメータがモデルの改良にちゃんと貢献しないようであれば, ペナルティを与えることになります。

11.5

要約

- 2 つの変数間関係の強さを知るにはどうすればいいか知りたければ, 相関を計算しましょう (セクション 11.1)。

- 散布図を書きましょう (セクション 11.6)。
- 線形回帰の基本的な考え方と、回帰モデルがどのように推定されるかをそれぞれみました (セクション 11.7 と 11.8)。
- 重回帰を扱いました (セクション 11.9)。
- 回帰モデルの全体的なパフォーマンスを R^2 をつかって測りました (セクション 11.10)。
- 回帰モデルの仮説検定について扱いました (セクション 11.11)。
- 回帰係数の信頼区間と標準化係数について論じました (セクション 11.12)。
- 回帰分析の仮定について (セクション 11.2) と、それをどうチェックするかについて学びました (セクション 11.3)。
- 回帰モデルの選択について扱いました (セクション 11.4)。

11.6

散布図

散布図はシンプルですが効果的なツールで、関連のセクション (セクション 11.1) でみたように、2つの変数間関係を可視化してくれます。“散布図”という言葉を使う時、私たちが普通思いつくのは応用例です。この種のプロットでは、各データ点がある点に対応しています。ドットのプロットの水平の位置は一方の変数における値で、垂直方向の位置はもうひとつの変数における値です。多くの状況では、その因果的な関係 (すなわち、A が B の原因、あるいは B が A の原因である、あるいは他の変数 C が A と B を統制しているなど) がどうなっているかについて、はっきりした意見を言うことは難しいでしょう。そうした状況では、どの変数を x 軸において、どの変数を y 軸に置くべきかと言うことは本質的な問題ではありません。しかしある変数が原因になっているに違いないとか、少なくとも方向性についてある見通しがある、と言う幾分強いアイデアがあることも多いでしょう。もしそうなら、原因変数を x 軸に、影響される変数を y 軸におくといいでしょう。これを覚えておいて、JASP でどうやって散布図を書くかみていきます。使うデータは同じく `parenthood` データセット (ファイルは `parenthood.csv`) で、関連の導入のときに使ったものです。

ここでのゴールは、私の睡眠時間 (`dan.sleep`) と、次の日どれくらい機嫌が悪いか (`dan.grump`) の全体的な関係を散布図で描くことです。JASP を使ってプロットを書くときは、‘回帰分析’-‘相関行列’の下にある‘プロット’オプションのボタンを押せばよく、図 `fig:scatterplot1` が得られます。JASP は点の中に線を引きますが、これは後ほど、セクション (11.7) で説明します。こうした散布図を描くとき、‘変数の記述統計量’も追加できて、変数がどのように分布しているかを示すヒストグラムや密度曲線を追加することができます。‘統計量’オプションを押すこともできて、そうすると相関係数の推定値の 95% 信頼区間も得られます。




Figure11.14 JASP で '相関行列' から散布図をかく

11.7

線形回帰モデルとは？

今から見る回帰モデルはとてもパワフルなツールなのですが、本質以外のものを削ぎ落としてみれば、線形回帰モデルは基本的にピアソンの相関 (セクション 11.1) の少し凝ったバージョンに過ぎません。

会期の基本的なアイデアは相関と密接に結びついているので、`parenthood.csv` ファイルにもどって相関がどういうものだったかを見直してみましょう。思いおこせば、このデータセットでなぜダンがいつも不機嫌なのかを見つけようとしていて、仮説としては睡眠が足りてないのではないかと、いうものでした。散布図を描いて睡眠時間と翌日の不機嫌さの関係を検証しようとし、図 11.14 で、この関係が相関係数 $r = -.90$ として表されることを見ましたが、私たちがこっそりイメージしていたのは図 11.15a のような何かだったのではないのでしょうか。つまり、我々はデータの真ん中を通る直線を心の中に描いていたのです。統計学では、この線のことを**回帰直線**と呼んでいます。わ

れわれは馬鹿ではないので、この回帰線はデータの真ん中を通っていることに注意してくださいね。
図 11.15b にあるような、馬鹿っぽいプロットを想像することはないのです。




Figure11.15 パネル a が示すのは、図 11.14 からきた睡眠と不機嫌さの散布図に、回帰直線を書き足したものです。驚くな彼、この線はデータの真ん中を通っているのです。それに比べて、パネル b が示すのは同じデータですが、回帰線を間違った書き方をしています。

これはそれほど驚くことではありません。図 11.15b に描いた直線はデータに“フィット”してないので、データを要約するという目的には役に立たないのです。これは非常にシンプルに見えますが、これに関する数学を少し見てみればとても強力なものであることがわかります。さてそのために、高校数学を少し思い出してみましょう。直線は一般に次のように表現されるのでした。

$$y = a + bx$$

少なくとも、私が何年も前に高校生だった頃はこうだったはずです。2つの変数は x と y で、2つの係数 a と b があります^{*4}。係数 a は直線の y 切片であり、係数 b は直線の傾きを表しています。高校時代の古ぼけた思い出を掘り返してみれば(すみません、私たちにとって随分前のことなのです)、切片は“ $x = 0$ のときの y の値”として解釈できるのでしたね。同様に、傾き b はもし x の値が1単位増加したら、 y の値が b 単位増加することを意味していますし、負の傾きであれば y の値が増加ではなく減少することを意味します。おうイエス、これで全て思い出しましたね。こうやって覚えていれば、回帰線も全く同じ式を使うのですから驚くことはありませんね。もし Y が結果変数(従属

^{*4}これは $y = mx + b$ とかけられることもあります。そのとき m が傾きの係数で b が切片(定数)の係数です

変数)で、 X が予測変数(独立変数)であれば、この回帰式は次のように描くことができます。

$$\hat{Y}_i = b_0 + b_1 X_i$$

ふむう。同じ数式に見えますが、ごくわずか、今回のバージョンは違うところがあります。これを理解してみましょう。まず、私は X_i と Y_i と書いています。ただの X, Y ではないですね。これはなぜかという、私たちは実際のデータを扱っているからです。この式では、 X_i は予測変数の第 i 番目の観測を表しています(つまり私のこの研究では、第 i 日目に寝た時間の数字です)。そして私はそこまで明示的に伝えていませんでしたが、私はこの式がデータセット全ての点(全ての i)について成立していると仮定しているのです。次に、 Y_i ではなく $\hat{Y}_i$ になっているところに気づいたでしょう。これがどうしてかという、実際のデータである Y_i と、予測値の $\hat{Y}_i$ (つまり回帰線によって成される予測)とを区別したいからです。3つ目に、係数を a, b から b_0, b_1 に書き換えました。これは回帰モデルにおける係数を表すのに統計学者が好むやり方だ、というに過ぎません。なぜ b が選ばれたのかわかりませんが、とにかくそうするようです。どんな場合でも b_0 は常に切片を表していて、 b_1 は傾きを表しています。

大変結構。次に言わずにいられないのは、良い回帰線であろうと悪い回帰線であろうと、データが完全に直線にのることはないということです。つまり言い方を変えれば、データ Y_i は回帰モデルの予測である $\hat{Y}_i$ に一致しないということです。統計家は文字を追加し、あらゆるものに文字と数字を付与するのが好きなので、モデルの予測と実際のデータ点との差分を残差として、 ε_i であらわします^{*5}。数学を使うと、残差の定義は次のようになります。

$$\varepsilon_i = Y_i - \hat{Y}_i$$

そうすると、完全な線形モデルは次のように書くことになります。

$$Y_i = b_0 + b_1 X_i + \varepsilon_i$$

11.8

回帰モデルの推定

オウケイ、図を見直してみましょう。でも今度は全ての観測度数に対して、残渣を表す線を追加してみます。もし回帰線が良いものであれば、残差(黒い点線の長さ)は全て小さくなっていることが、図11.16aに示されています。しかし回帰線が悪いものであれば、残差はいくぶん伸びてしまうことが図11.16bに見て取れます。ふむう。私たちが“ほしい”回帰モデルは、残差が小さいほうですね。そう、そうでないとおかしいのです。実際、“ベストフィット”する回帰線は、残差を最小にす

^{*5} ε はギリシア文字でイプシロンといいます。残差をあらわすのには、 ε_i か e_i を使うのがならわしです。




Figure11.16 最適なフィッティングをした回帰直線に伴う残差を描いたもの (パネル a) と、当てはまりの悪い回帰線に伴う残差を描いたもの (パネル b)。残差は良い回帰線の方がかなり小さくなります。もう一度、驚くことではないですが、良い直線というのはデータの中心を通るものだとを確認しましょう。

るものだといえるでしょう。あるいは、統計学者はあらゆるものの二乗を取るのが好きなので、次のように言えいいかもしれません。

推定された回帰係数、 $\hat{b}_0$ と $\hat{b}_1$ は、残差の平方を最小にするもので、 $\sum_i (Y_i - \hat{Y}_i)^2$ とか $\sum_i \varepsilon_i^2$ と書くことができる。

そうそう、これで良くなりました。そしてこのように位置をずらして書いたので、おそらくこれが正解なんでしょう。そしてこれツェ異界なので、回帰係数は推定値だという事実を書いておくのは大事なことでしょう (私たちは母集団のパラメータを推測しようとしていたのです!)。だから、小さなハットをつけて、 b_0 と b_1 ではなく $\hat{b}_0$ と $\hat{b}_1$ をつけましょう。最後にもう一つ言っておきたいことがあって、回帰モデルの推定する方法は 1 つだけではありませんから、この推定プロセスにより専門的な名前をつけておきます。最小二乗法 (OLS) です。

ここで、回帰係数 $\hat{b}_0$ and $\hat{b}_1$ の “ベストな” チョイスとは何かについて、はっきりと定義できるようになりました。当然次の質問は、もし最適な回帰係数というのが残差の平方を最小化するものだとしたら、どうやってその不思議な数字を見つけたらよいのかということです。この問いに答えるのは

実はちょっと複雑です、回帰のロジックを理解する助けになりません*6。今回は見逃してあげましょう。長くて面倒な方法を最初に見せてから、JASP がやってくれる素晴らしいショートカットを“ご開帳する”のでh なく、近道をしていきなり JASP でこの面倒な仕事をやっつけちゃいましょう。

11.8.1 JASP による線形回帰




Figure11.17 単純な線形回帰分析をする JASP のスクリーンショット

線形回帰を走らせるには、`parenthood.csv` データファイルを使って、JASP の‘回帰’-‘線形回帰’分析と進めましょう。‘従属変数’のところに `dan.grump` をして石、‘共変量’ボックスのところに `dan.sleep` を持っていきます。図 11.17 に示した結果より、切片 $\hat{b}_0 = 125.956$ と傾き $\hat{b}_1 = -8.937$ を得ます。言い換えると、図 11.15 にプロットしたような、ベストフィットした回帰線の式は次のようなものだったわけです。

$$\hat{Y}_i = 125.956 + (-8.937 X_i)$$

*6あるいは、少なくともほとんどの人にとって役に立たないと思っています。しかし万一、これを読んでいる人の中に、線形代数のカンフー師範がいれば（そして正直に言って、統計の導入クラスの中に数人はそういう人がいるのですが）、推定問題を解決するために次のように書き換えればその人の助けになるでしょう。 $\hat{\mathbf{b}} = (\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'\mathbf{y}$ とするのです。ここで、 $\hat{\mathbf{b}}$ は推定された回帰係数の入ったベクトル、 $\mathbf{X}$ は“デザイン行列”で予測変数（と、すべて 1 が入っている列を追加したもの。 $\mathbf{X}$ は厳密に回帰するものの変数で、その違いについてはまだ触れてませんが）のベクトルで、 $\mathbf{y}$ は結果変数を含んだベクトルです。他の人にとっては、これは役に立たないし恐ろしいものに見えるかもしれません。しかし、線形回帰の一部は線形代数の用語で書かれているので、この章のこれのように脚注の中で見てもらえればと思います。もしこの数学がわかれば、たいしたものです。そうでなかったら、無視してくれたらいいです。

11.8.2 推定されたモデルを解釈する

最も重要なことは、この機器係数を解釈する方法を理解することです。傾きの $\hat{b}_1$ から始めましょう。傾きの定義を覚えていれば、回帰係数 $\hat{b}_1 = -8.94$ が意味することは、もし X_i が1点上昇すれば、 Y_i は8.94点さがるといことです。つまり、もう一時間余分に寝ることができれば、私の気分は改善し、不機嫌さが8.94ポイントさがるといことです。切片はどうでしょうか？ $\hat{b}_0$ は“ X_i が0のときに期待される Y_i の値”ということなので、直感的にもわかりますね。もし私が一睡もしていなかったら ($X_i = 0$)、私の不機嫌さは尺度を飛び出して、 $Y_i = 125.96$ という非常識な値になるといことです。それは避けた方がいいと思いますねえ。

11.9

重回帰分析

既に述べてきた単純な回帰分析は、興味関心ある単一の予測変数、例では `dan.sleep` があることを前提としていました。実際、これまで話してきた統計ツールはいずれも、分析にはひとつの予測変数とひとつの結果変数を使うものでした。しかし多くの(たぶんほとんどの)研究では、複数の予測変数について検証したいと思うのでしよう。もしそうなら、線形回帰のフレームワークを複数の予測変数をもつものに拡張することができればいいと思いませんか。重回帰モデルがその目的に合うのでは、と思いませんか？

重回帰の考え方は非常に単純です。やるべきことは、回帰方程式に項を追加するだけです。興味がある変数が2つあるとしましょう。`dan.sleep` と `baby.sleep` の両方で、`dan.grump` 変数を説明したいとします。以前、 Y_i で i -日目の私の不機嫌さを表現したのでした。今度は2つの X 変数を持っています。最初の変数は私の睡眠時間に、第二の変数は息子の睡眠時間に対応しています。さて X_{i1} を私の i -日目の睡眠時間、 X_{i2} をその日の我が子の睡眠時間を表すものとしましょう。そうすると、重回帰モデルは次のように書くことができます。

$$Y_i = b_0 + b_1 X_{i1} + b_2 X_{i2} + \varepsilon_i$$

既に述べたように、 ε_i は i -番目の観測における残差を表しており、 $\varepsilon_i = Y_i - \hat{Y}_i$ です。このモデルでは、3つの係数を推定しなければなりません。切片 b_0 、私の睡眠時間に対応した係数 b_1 、私の子の睡眠時間に対応した係数 b_2 です。しかし、推定しなければならない係数の個数が変わったとて、どう推定するか的基本的な考え方に変化はありません。推定すべき係数 $\hat{b}_0$ 、 $\hat{b}_1$ そして $\hat{b}_2$ は、残差の平方を最小化するように求めれば良いのです。




Figure11.18 重回帰モデルの3次元の可視化。モデルには2つの説明変数、`dan.sleep`と`baby.sleep`があり、結果変数は`dan.grump`です。3つの変数を一緒にするので、3次元空間になります。各データ(点)は空間の位置を示します。単回帰モデルを2次元空間に線で示したのと同じように、重回帰モデルでは3次元空間に平面で表すことになります。回帰係数を推定する時は、全ての青い点ができるだけ近くに来るような平面を探すことになります。

11.9.1 JASP でやってみよう

重回帰をJASPでやる方法は、単回帰と違いがありません。JASPの‘共変量’ボックスに、変数を追加するだけです。たとえば、`dan.sleep`と`baby.sleep`の両方を予測変数として、不機嫌さの説明について書きたい時は、`baby.sleep`を`dan.sleep`の隣にある‘共変量’ボックスに持っていきます。JASPはデフォルトで切片の推定を含んでいます。今回得られる係数は次のようになります。

```
% (Intercept)    dan.sleep    baby.sleep
(切片)          ダンの睡眠時間  子の睡眠時間
```

125.966

-8.950

0.011

`dan.sleep` にかかる係数はかなり大きいようで、睡眠時間が減っていくたびに不機嫌さが増えていくようです。一方、`baby.sleep` の係数はすごく小さいので、私の息子がどれくらい寝るかというのは大した問題ではないようです。私の期限がどうなるかは、私がどれほど寝られるかにかかっているようです。重回帰モデルがどうなっているかの感覚を掴むために、図 11.18 を描いてみました。3次元プロットは3つの変数と重回帰モデルそのものを示しています。

11.9.2 式を一般化する

上で示した式は、2つの予測変数を含んでいるときの重回帰モデルです。おどろくなかれ、もしやりたいのならもっと多くの X と、係数 B を追加してもいいのです。言い換えると、もし K 個の予測変数をモデルの中に入れたいのなら、回帰方程式は次のようになるでしょう。

$$Y_i = b_0 + \left(\sum_{k=1}^K b_k X_{ik} \right) + \varepsilon_i$$

11.10

回帰モデルの適合を評価する

線形回帰モデルの係数をどうやって推定するのかをみてきました。問題は、この回帰 g どれくらい良いものなのかわからないということです。たとえば、セクション 11.8.1 で回帰モデルを作り、睡眠時間が長ければ私の気分が良くなると主張しましたが、これはまったく馬鹿げたことかもしれません。思い出してほしいのですが、回帰モデルは私の気分がどんなものかについての予測 $\hat{Y}_i$ を作りますが、それは実際の気分 Y_i ではないのです。もしこの2つがとても近ければ、回帰モデルはとても良い仕事をしてくれるでしょう。もしそれがあ違うものであれば、役に立たないでしょう。

11.10.1 R^2 値

もう一度、これの数学的表現を見てみましょう。まず、残差の二乗和を次のようにしたのでした。

$$SS_{res} = \sum_i (Y_i - \hat{Y}_i)^2$$

これが小さければいいんですけどね。特に、結果変数の分散全体にたいして小さいことが望まれます。

$$SS_{\text{tot}} = \sum_i (Y_i - \bar{Y})^2$$

ではここで、て計算ではなく、この値それぞれを計算してみましょう。JASP ファイル `parenthood_rsquared.jasp` を用意しましたので、これを本のデータフォルダから開いてください。データファイルには5つの変数があることに気づくでしょう。そのうち2つは元の `dan.sleep` と `dan.grump` 変数で、既に使ったものです。残りの3つは計算された変数です。

1. `Y.pred` は回帰方程式から予測された不機嫌さの値です。数式 '`125.97 + (-8.94 * dan.sleep)`' を使って計算されます。
2. `resid` は残差、 $\epsilon_i = Y_i - \hat{Y}_i$ で、回帰式からの予測された不機嫌さの値と、実際の不機嫌さの値の間の違いを表しています。数式 '`dan.grump - Y.pred`' で計算されます。
3. `sq.resid` は残差の平方で、数式 '`resid2`' で計算されます。

SS_{res} は残差の平方なので、JASP を使って `sq.resid` 列を探します。'記述統計'-'記述統計' をクリックし、`sq.resid` を '変数' ボックスに移します。次に '統計量' オプションから '合計' を選択します。すると '`1838.714`' という値を得ることができます。

すばらしい。大きな数字ですが、そこにそれほど意味はありません。どうせなら、二乗和を計算しちゃいましょう。これもかなりシンプルです。 SS_{tot} を同様に計算してみます。今度は、新しい計算列を作る必要があります。"+" の記号を選ぶところから始めましょう。'変数名' のところに '`sq.resid2`' とタイプします。(なぜかはすぐにわかります)。“R” ボタンを選択して、“列を作る” をクリックします。R コードとして、次のように入力します (図 11.19 をみてください)。

```
(dan.grump - mean(dan.grump))^2
```

それから“列を計算する” をクリックします。これは残差の値を生成するのですが、その残差 (誤差) は本当に良くない予測モデルからのものです。すなわち、ここでのモデルは単に全ての不機嫌さ値の平均を使うものだからです。 SS_{tot} にするには、上でやったのと同じように `sq.resid2` の平方和を計算する必要があります。

ここで '`9998.590`' という値が得られるでしょう。ふむう。さっきのよりさらに大きな数字になりましたが、これは私たちの回帰モデルが良い予測をした (すなわち平均値だけを予測変数としたモデルよりも残差をぐっと減らした) ことを意味します。でもわかりにくいですね。

たぶんもう少し改良できます。ここでやりたいことは、2つの意味をなさない数字から、1つの数字に置き換えることです。素敵で意味のわかる1つの数字は、特に理由はないですが R^2 と呼ぶことにします。 R^2 値が好ましい理由は、回帰モデルがデータを予測するときに誤差を全く生じないばあい、その値が1に等しくなるからです。言い換えると、そのとき残差は0になっているわけです。つまり $SS_{\text{res}} = 0$ なら $R^2 = 1$ であることが期待できます。同様に、もしモデルが全く使い物にならないのであれば、 R^2 は0に等しくなります。“使い物にならない” というのはどういうことでしょうか？




Figure11.19 Rで残差を計算する JASP のスクリーンショット

.....

回帰モデルが家からでて、髪を切って、仕事をして、ということを提案してくれるものならいいのですが、多分もう少し実用的な定義をしないといけません。今回の場合、残差の平方和が全平方和より小さくならない、つまり $SS_{res} = SS_{tot}$ ということです。まって、なんでそんなことが言えるの、って? それはこの式から、 R^2 値を次のように書き直すことができるからです。

$$R^2 = 1 - \frac{SS_{res}}{SS_{tot}}$$

そして、簡単に次のように手計算できます。

$$\begin{aligned} R^2 &= 1 - \frac{SS_{res}}{SS_{tot}} \\ &= 1 - \frac{1838.714}{9998.590} \\ &= 1 - 0.1839 \\ &= 0.8161. \end{aligned}$$

R^2 値は、ときどき**決定係数**と呼ばれることもあります^{*7}。これは簡単に解釈できるのです。すなわち、彫られた予測変数で結果変数の分散を説明する割合を表しているのです。今回は、 $R^2 = .8161$ が得られたわけですから、予測変数 (*dan.sleep*) は結果変数 (*dan.grump*) の分散の 81.61% を説明するのです。

当然ですが、回帰モデルから R^2 値がほしいときに、この計算をいつもやらなければならないということはないのです。JASP がデフォルトで計算してくれてますよ! 図 11.17 をもう一度見てください。‘モデルの要約’ と書かれた表に R^2 が既にあるじゃないですか!

11.10.2 回帰と相関の関係

ここにきて先ほどの回帰の結果に戻ってみましょう。この非常にシンプルな式は、基本的には相関と同じものなのです。以前、 r という記号を使ってピアソンの相関係数を表しました。相関係数 r と線形回帰からきた R^2 値の間にはなんらかの関係があるのではないのでしょうか? もちろんです。相関係数の二乗である r^2 は、予測変数が 1 つだけのとき R^2 と一致します。言い換えると、ピアソンの相関係数は線形回帰モデルを 1 つの説明変数で使ったときとほぼ同じことなのです。

11.10.3 自由度調整済み R^2 値

最後にもう 1 つ指摘しておきましょう。モデルの評価指標としてレポートに書くときに多いのは、少し違う“自由度調整済み R^2 ”として知られているものです。この調整済み R^2 を使うモチベーションは、モデルに説明変数を追加すると必ず R^2 値が増加してしまう (あるいは少なくとも減ることはない) からです。

調整済み R^2 値は以下にあるように、少し計算式が違います。N 件のデータからなる K 個の予測変数を持つ回帰モデルの場合、調整済み R^2 は次のようになります。

$$\text{adj. } R^2 = 1 - \left(\frac{SS_{\text{res}}}{SS_{\text{tot}}} \times \frac{N - 1}{N - K - 1} \right)$$

この調整は、自由度を計算に入れています。この調整済み R^2 をつかう大きな利点は、予測変数をモデルに追加することで偶然以上のパフォーマンスの向上が期待できるときにのみ、この調整済み R^2 が増加するようになっているところです。調整済み R^2 の大きな弱点は、 R^2 の時のようなエレガントな解釈ができないということです。 R^2 は回帰モデルによって、説明される結果変数の分散のうちモデルが説明する割合と解釈できるのでした。私の知る限り、調整済み R^2 にそれと同じように解

^{*7}そして“ときどき”というのは、“ほとんどない”ということでもあります。実際には、みんなこれを“R 二乗値”といいます。

釈できる筋道はありません。

R^2 と調整済み R^2 のどちらをレポートするべきか、という当然の質問が湧き上がってきますね。これはおそらく、個人的な好みだと思います。解釈できることを考えるなら、 R^2 の方が良いでしょう。バイアスを補正したいのなら、調整済み R^2 がよいでしょう。私自身のことについていうなら、私は R^2 のほうが好みます。私の感覚的には、モデルの性能を解釈できる速度である方がより重要だと思うからです。それに、セクション 11.11 でこの後見るように、 R^2 値をの改善が予測変数を追加したことだけによるもので、モデルを良いものにしたわけではないのではないかと心配するのであれば、仮説検定を使うことができます。

11.11

回帰モデルの仮説検定

回帰モデルがどんなものか、回帰係数をどのように推定するか、モデルのパフォーマンスをどう評価するかについて、説明してきました (最後の一つは、効果量の測定と同じです)。次に話す必要があるのは、仮説検定です。ここでは2つの異なる (しかし関係のある) 仮説検定について話さなければなりません。すなわち、回帰モデルが全体的にヌルモデルと比べて意味のあるパフォーマンスを見せているかどうか、そしてある回帰係数が0から有意に異なっているかどうか、です。

11.11.1 モデル全体を検定する

ではすでに、回帰モデルの推定が終わっているとしましょう。最初の検定の仮説は、予測変数と結果変数の間になんの関係もないという帰無仮説で、対立仮説はデータは回帰モデルが予測するように分布しているというものです。

フォーマルには、明らかに“回帰する”というモデルに対する“ヌルモデル”では、予測変数を一つも含んでおらず、切片 b_0 だけ含まれるというもので、以下のように表されます。

$$H_0 : Y_i = b_0 + \varepsilon_i$$

検証したい回帰モデルは K 個の予測変数を持ち、“対立モデル”は次のような重回帰モデルの式で表現されます。

$$H_1 : Y_i = b_0 + \left(\sum_{k=1}^K b_k X_{ik} \right) + \varepsilon_i$$

この2つの仮説を互いに戦わせるにはどうしたらいいでしょう？ そのひみつは、全分散 SS_{tot} を残差分散 SS_{res} と回帰モデルによる分散 SS_{mod} の和に分割できることにあります。技術的なところは後ほど、第 12 章の ANOVA で見るので省略します。次のことだけ見ておいてください。

$$SS_{mod} = SS_{tot} - SS_{res}$$

そして平方和を自由度で割ることで、平均平方に置き換えます。

$$MS_{mod} = \frac{SS_{mod}}{df_{mod}}$$

$$MS_{res} = \frac{SS_{res}}{df_{res}}$$

さて、自由度はいくらになるでしょう？ あなたが想像するように、モデルに伴う自由度 df は、予測変数の数に密接に関係します。事実、自由度は $df_{mod} = K$ であることがわかります。残差の全自由度は $df_{res} = N - K - 1$ です。

さて、平均平方を得たら次のように F 統計量を計算します。

$$F = \frac{MS_{mod}}{MS_{res}}$$

そしてこれに関する自由度は K と $N - K - 1$ になります。¥

F 統計量については第 12 章で詳しく見ることになりますが、今はたんに F が大きくなれば帰無仮説が対立仮説に比べて弱くなることを示している、と置いておけば結構です。JASP でこの検定をするためにはどうすれば良いか、お見せするのは簡単ですが、まずそれぞれの回帰係数の検定の方を見ておきましょう。

11.11.2 回帰係数の検定

ここで導入した F 検定は、モデル全体が偶然以上のパフォーマンスを示すかどうかをチェックするものでした。もしあなたの回帰モデルが F 検定で有意な結果にならないければ、とても良い回帰モデルとは言えない（あるいは、もしかするとですが、良いデータではなかったのかも）でしょう。しかし検定で有意にならなかったことがモデルに問題があることを強く主張していたとしても、有意になったことが（つまり帰無仮説を退けたことが）モデルが良かったことを示すわけではありません！なぜそうなるのか、不思議に思いませんか？ 答えは、重回帰モデルの回帰係数を見ればわかります。私たちは既に、上のセクション 11.9 で、次のような回帰係数を得たのでした。

% (Intercept)	dan.sleep	baby.sleep
切片	ダンの睡眠時間	赤ちゃんの睡眠時間
125.966	-8.950	0.011

推定された回帰係数が、赤ちゃんの睡眠時間 についてはわずか (0.011) で、ダンの睡眠時間 についてはもう少し大きい (-8.950) ことがわかります。この 2 つの変数が絶対的に同じ尺度で測定されているなら (これらはいずれも “寝た時間” で測定されていますが), この意味がわかるわけです。現に、私は自分の機嫌の悪さを予測するためには、私がどれくらい睡眠できたかということにのみ影響を受けていると推察しています。

ここで先ほど論じた、t 検定をもう一度使うことができます。この検定は、帰無仮説として真の回帰係数がゼロである ($b = 0$) とし、それに対する対立仮説はゼロではない ($b \neq 0$) とすることです。つまり、次のようになります。

$$\begin{aligned} H_0 : & b = 0 \\ H_1 : & b \neq 0 \end{aligned}$$

どうやってこの検定をしましょうか? ふむう。中心極限定理は推定された回帰係数 $\hat{b}$ の標本分布が、平均 b を中心にした正規分布になっているかも、と教えてくれます。これが意味するところは、もし帰無仮説が真であれば、 $\hat{b}$ の標本分布は平均がゼロで、標準偏差はわからないことになります。回帰係数の標準誤差についての良い推定値として、 $SE(\hat{b})$ があるとすれば、ラッキーですね。これはまさに、第 10 章でやった一標本の t-検定の状況です。ですから t 統計量を次のように定義できます。

$$t = \frac{\hat{b}}{SE(\hat{b})}$$

理由は後回しにしますが、ここでの自由度は $df = N - K - 1$ になります。悔しいことに、回帰係数の標準誤差 $SE(\hat{b})$ を推定するのは、第 10 章でやった t-検定の平均値の標準誤差の計算と同じように簡単にいくわけではありません。実際この計算式は変な形をしていますし、見たところでなんの助けにもなりません*8 我々の目的としては、推定された回帰係数に伴う標準誤差は、予測変数と結果変数のどちらにも依存していることと、分散の均質性の仮定 (簡単に説明しましたね) が破られることに幾分敏感であることを指摘すれば十分です。ともかく、t 統計量は第 10 章で説明した t 統計量と同じように解釈できます。両側検定を仮定していると思いますから (つまり、 $b > 0$ でも $b < 0$ でも気にしないとおもいますから), t の値が極端であれば (すなわち、0 よりずっと小さいか、0 よりずっと大きいとき), 帰無仮説を棄却するべきだということになります。

11.11.3 仮設検定を JASP でやってみる

ここまで話してきた統計量全てを計算するときにあなたがやるべきことは、JASP で関係するオプションをチェックして回帰分析を実行するだけです。幸にして、これらのオプションは普通デフォル




Figure11.20 重回帰分析と関係する仮説検定の JASP スクリーンショット

トで選ばれています。図 11.20 にあるように、便利なアウトプットがいっぱい出てきます。

JASP の出力結果の下にある '係数' が図 fig:reg2 に示されていますが、これが回帰係数を示しています。この表の各行が回帰モデルの係数それぞれに対応しています。最初の行は切片で、そのあとに各予測変数の係数が続きます。列に関する情報が示されています。最初の列 ('非標準化' というラベルがついています) は実際の係数 b です (切片は 125.966, ダンの睡眠時間という予測変数の係数は -8.950 です)。二列目は標準誤差 $\hat{\sigma}_b$ です。三列目は '標準化回帰係数' で、これについてはセクション 11.12 で説明します。四列目は t 統計量を提供しており、表中の数字はいつも $t = \hat{b}/\text{SE}(\hat{b})$ となっていることに注意しましょう。最後に、最終列がそれぞれの検定に対応する p 値を示しています。^{*9}

係数表は t 検定でつかう自由度をリスト化してくれないのですが、それは常に $N - K - 1$ で、'ANOVA' とラベル化された出力のなかに示されています。この表からモデルが偶然以上に有意なパフォーマンスを示したことがわかりますし ($F(2, 97) = 215.238, p < .001$)、それは驚くほどのことではありません。 $R^2 = .816$ という値は回帰モデルが結果変数の分散の 81.6% を説明することを示していますから。しかし、各係数についての t 検定結果を見てみると、赤ちゃんの睡眠時間 変数が有意

^{*8}より進んだ読者のために。残差ベクトルは $\epsilon = y - X\hat{b}$ になります。 K 個の予測変数と切片があるので、推定された残差分散は $\hat{\sigma}^2 = \epsilon'\epsilon / (N - K - 1)$ になります。推定された係数の分散共分散行列は $\hat{\sigma}^2(X'X)^{-1}$ で、これの対角項は $\text{SE}(\hat{b})$ であり、これが標準誤差になります。

^{*9}JASP は多重検定をしています、いかなる多重比較の補正もやっていません。これは標準的な一標本 t 検定で両側検定になっています。多重検定の補正をしたいのなら、自分でやらなければなりません。

な影響を持っていなかったことがわかります。このモデルのなかでうまく機能していたのは、**ダンの睡眠時間** 変数でした。これを併せて考えると、この回帰モデルはデータに対して実際にはいいモデルではなかった、といえるでしょう。説明変数全体の中から、**赤ちゃんの睡眠時間** 変数を取り除いた方がよさそうです。言い換えると、単純な回帰モデルがよりよさそうだということです。

11.12

回帰係数について

線形回帰の前提となる仮定とそれに合致しているかどうかをチェックする方法について説明する前に、短い2つの議論をしておこうと思います。いずれも回帰係数に関係することです。最初に言わなければいけないのは、係数の信頼区間の計算です。そのあとで、どの予測変数が最も重要なものなのかをどう判断するかという、やや不明確な問題について議論します。

11.12.1 係数の信頼区間

母数のように、回帰係数 b も標本データから完全な正確さでも止められるものではありません。これは、なぜ検定が必要なのかという問いに対する答えの一部です。このとき、 b の真の値についての不確かさを表現する信頼区間を報告できると、とても便利です。これは特に、研究の関心が X がどれぐらい Y に影響しているかを見つけることにある場合は大事なことです。そうした時は、回帰の重み b に一番関心があるのですから。

幸い、回帰係数についての信頼区間は便利なやり方で計算できます。

$$CI(b) = \hat{b} \pm (t_{crit} \times SE(\hat{b}))$$

ここで $SE(\hat{b})$ は回帰係数の標準誤差で、 t_{crit} は t 分布に関する臨界値です。たとえば、95% 信頼区間が欲しいとしたら、臨界値は自由度 $N - K - 1$ の t 分布における 97.5 パーセンタイル点になります。つまり以前考えた信頼区間の計算アプローチと同じだということです。

JASP で信頼区間を表示させるには、回帰モデル画面から '統計' メニューから '信頼区間' を選択します。デフォルトでは 95% CI になっていますが、簡単に好きな値、例えば 99% に変えることができます。

11.12.2 標準化した回帰係数を計算する

あなたに必要なかもしれないもうひとつのこととして、“標準化された”回帰係数を計算したいことがあるかもしれません。これはよく β で表わされます。標準化係数の根拠は次のようなものになります。多くの場合、分析に用いる変数が異なる単位に基づいています。たとえば、もし私のモデルが教育期間(何年教育を受けたか)と年収からIQスコアを予測しようとしていたとしましょう。あきらかに教育期間と年収は同じ単位ではありません。学校に行ってる期間というのは10数年ですし、年収は10,000ドルぐらいの単位で変化します。測定の単位は回帰係数に強く影響します。係数 b は単位に応じて解釈できます。2つの予測変数と、結果変数の両方について、です。しかし異なる予測変数間の係数を比較するのは難しいですね。違う係数間の比較がしたいという状況もあるのです。結果変数に最も強い影響を与える予測変数を知るための、標準化された測定が必要ですね。これこそ**標準化係数**がしようとしていることです。

基本的なアイデアは極めてシンプルです。標準化した係数は、回帰分析をする前に全ての変数を z -値にしたものを使うことで得られます^{*10}。ここでのアイデアは、全ての予測変数を z 値に変換し、同じ尺度で回帰変数にすることで、異なる単位を持つ変数をもたらす問題を取り除くというものです。元の変数がどんなものであれ、 β 値1つぶんは、予測変数が1標準偏差増加すると、それに応じて結果変数が1標準偏差分増加する間々ことを意味します。つまり、もし変数 A の β の絶対値が B のそれより大きければ、 A のほうが結果変数により強く関係しているということを意味します。少なくとも、そういうことです。ちょっと注意を促しておきますと、これは“1標準差分の変化”は基本的に全ての変数において同じである、という仮定に深く関わっているものです。これが本当かどうかは、それほど明白なことではありません。

解釈の問題は横に置いて、どのように計算するかを見てみましょう。あなたができることは、全ての変数をあなた自身が標準化することで、それから回帰分析をすることになりますが、もっと簡単なやり方があります。結論から言うと、予測変数 X と結果変数 Y に関する β 係数は非常に単純な数式で、次のように表せます。

$$\beta_X = b_X \times \frac{\sigma_X}{\sigma_Y}$$

ここで σ_X は予測変数の標準偏差、 σ_Y は結果変数 Y の標準偏差です。これは問題をグッと単純にしてくれますね。

同じぐらい単純なやり方ですが、JASPは β 係数をデフォルトで算出してくれますので、図 11.20 の‘係数’についての表で第3の列を見てください。これがはっきり示しているように、**ダンの睡眠時**

^{*10}厳密には全ての回帰変数を、です。。つまり、モデルに含まれる回帰係数に関係するあらゆる“もの”が対象です。回帰モデルは、既に述べたように、各予測変数に対応する1つの回帰変数がありますし、その逆もまた然りです。しかしこれは一般的に正しいわけではなく、その例については第13章で触れます。しかしこの区別について、今はそれほど気にしないでいいでしょう。

間変数は赤ちゃんの睡眠時間変数よりも強い影響を持っています。とはいえ、これは標準化係数 β よりも元の回帰係数 b を使った方がわかりやすい例でもあります。結局、私の睡眠時間と赤ちゃんの睡眠時間はすでに同じ尺度で測定されていたからです。眠った時間の長さですよね。これを z 値にすることで問題を複雑にする必要なんかありますか？

12. 平均を比較する (一元配置 ANOVA)

この章では心理統計の中で最も広く使われているツールの一つ、“分散分析”として知られている手法を紹介します。普通は ANOVA と呼ばれています。基本的な技術はロナルド・フィッシャー卿によって 20 世紀初頭に開発されたもので、不便な用語を使っているのも彼によるところです。ANOVA という用語は、二つの意味で若干ミスリーディングです。第一に、この技術名は分散といっていますが、ANOVA は平均の違いを検証することに興味があるのです。第二に、いくつかの異なる手法が全て ANOVA として引用されていますが、中には関係が薄いものもあるのです。この本の後の方では、全く違う状況に適用される異なる手法の ANOVA に出会すことになりますが、この章の目的は最も単純な形式の ANOVA についてだけ考えることにします。ここでは異なる群について観測しており、これらの群の違いが関心のある結果変数において差があるかどうかに興味があります。これは一元配置 ANOVA と呼ばれる問いの立て方になります。

この章の構造は次のようになっています。：セクション 12.1 ではこの章を通じて例として利用することになる、架空データについて紹介します。データの導入が終われば、一元配置 ANOVA が実際どのように働くのか、そのメカニクスを記述し (セクション 12.4) , それから JASP でどのように実行するかに注目していきます (セクション 12.5)。この二つのセクションが、この章の中核となります。この章の残りの箇所では、ANOVA を実行するときには避けられない重要なトピックの範囲について議論します。例えば効果量をどう計算するのかとか (セクション 12.6)、事後検定や多重比較の補正 (セクション 12.7)、ANOVA が依存している仮定 (セクション 12.8) などです。私たちはまた、これらの仮定をチェックする方法や、もし仮定が満たされなかったら何ができるのかについても論じます (セクション 12.8.1 から 12.9)。それから、反復測定 ANOVA についてセクションもカバーしていきます (セクション 12.8.1 から 12.9)。この章の終わりには、ANOVA とほかの統計的ツールとの関係についても少し紹介します (Section 12.2)。

12.1

データセットについて

あなたが Joyzepam と呼ばれる新しい抗うつ剤をテストする臨床試験に参加するとしましょう。薬の性能を公平に検証するために、この試験では 3 つの異なる薬を含めて検証することにします。一つはプラセボ、もう一つは既に抗うつ/抗不安剤として知られている Anxifree です。最初のテストでは、抑うつを抑えるのに変化があるのかを検証するために 18 人の参加者が集められました。薬は心理学的セラピーと一緒に用いられることがありますから、あなたの研究では 9 人が認知行動療法 (CBT) を受けていて、残りの 9 人は受けていないという状況にあります。参加者の処遇はランダムに割り当てられているので (もちろん二重盲検法で、です)、3 種類の薬それぞれについて、3 人が CBT を受け、3 人がセラピーを受けていない人ということになります。心理学者は各薬の処方後 3 ヶ月たったあとで、個々人の気分を査定し、個々人の気分が全体的に改善されたかどうかを -5 点から +5 点の尺度で評定してもらいました。この研究デザインのデータファイルを `clinicaltrial.csv` にアップロードしてあります。データセットには三つの変数、`drug`, `therapy`, `mood.gain` が含まれています。

この章の目的として、私たちが本当に興味を持っているのは、`mood.gain` に対して `drug` の効果があるかどうかです。最初にやるべきことは、記述統計を計算していくつかのグラフを描くことです。第 4 章で、これを JASP でどのようにするか、‘Descriptives’ – ‘Descriptive Statistics’ の中の ‘Split’ ボックス’ を使う方法をお見せしました。その結果を図 12.1 に示してあります。

プロットがはっきり示しているように、Joyzepam 群は Anxifree やプラセボ群よりも大きな改善が見られています。Anxifree 群は統制群よりも大きな気分の向上がみられますが、その差は大きくありません。私たちが知りたい答えは、これらの差が“本当に”あるものかどうか、あるいはそれがただの偶然なのか?ということなのです。

12.2

ANOVA と Student の t-検定との関係

さて、ANOVA の話を終わらせる前に一つ指摘しておきたいことがあります。多くの人が驚くと思うんですが、知っておいて損はありません。2 群の ANOVA は Student の t 検定と同じものなのです。いや、ほんと。似ているというのではなくて、実際あらゆる意味で等価なのです。これが常に真であることを証明しようとは思いませんが、一つ具体的な例を示しましょう。我々の `mood.gain ~ drug` というモデルを、ANOVA で実行する代わりに、`therapy` を予測変数として使うことを考えてみましょう。ANOVA を走らせると、F 統計量は $F(1, 16) = 1.71$ であり、p 値は 0.21 になります。ここには 2 群しかありませんから、実際には ANOVA に頼る必要はなく、Student の t 検定をすることにします。こうすることで何が起こるかみてくださいよ。: t-統計量は $t(16) = -1.3068$ で p 値は 0.21 になります。不思議なことに、p 値は一致します。もう一度 $p = .21$ になったのです。しか




Figure12.1 記述統計と mood gain について薬の設定ごとに分けて描いたボックスプロットの JASP のスクリーンショット。

し、検定統計量はどうでしょう？ ANOVA の代わりに t 検定をしたときには、ちょっと違う答えが出ていて、 $t(16) = -1.3068$ でした。しかしこれには、かなり直接的な関係があるのです。 t 統計量を二乗すると、先ほどの F 統計量を得ます。ほら、 $-1.3068^2 = 1.7077$ でしょ。

12.3

要約

この章には多くのことが含まれていますが、まだいくつも取りこぼしたものがあります。わかり切ったことですが、一つ以上のグループ化変数がある状況に興味がある場合の ANOVA をどうやるかについては説明していません。これは第 13 章で論じることになります。議論してきた内容について、キートピックスと言えば次のようになるでしょう。

- ANOVA がどのように働くかについての基本的なロジック (セクション 12.4) と、それを JASP でどう実行するか (セクション 12.5)。

- ANOVA での効果量をどうやって計算するか (セクション 12.6)。
- 事後の検定と多重比較の時の補正 (セクション 12.7)。
- ANOVA の仮定 (セクション 12.8)
- 分散の均一性の過程をどうやってチェックするか (セクション 12.8.1) と、その仮定が破られたときにどうするか (Section 12.8.3)。
- 正規性の仮定をどうやってチェックするか (セクション 12.8.3) と、その仮定が破られたときにどうするか (Section 12.9)。
- 反復測定 ANOVA (セクション 12.10) とそれに等価なノンパラメトリックな Friedman 検定 (セクション 12.11)。

この本の全てのチャプターについてそうですが、私が依拠しているいくつかの異なるソースがあります。が、最も影響を受けている一冊を挙げるとすれば、[Sahai and Ageel \(2000\)](#) です。この本は初心者向けではありませんが、ANOVA の背後にある数学的な側面を理解しようとする、少し進んだ読者にとっては素晴らしい本だと言えるでしょう。

12.4

ANOVA のしくみ

私たちの臨床試験データに与えられた問いに答えるために、一元配置分散分析をすることになります。まずは一から統計的ツールを組み立てる難しい方法を見せるところからはじめ、JASP に組み込まれているかっこいい ANOVA 関数にアクセスできなくても計算できることを示します。注意深く読み解いて欲しいと思います。そして ANOVA がどういう仕組みなのかを本当に理解するために、1,2 回はこの長い道のりに挑戦してみてください。あなたがこのやり方を掴み取ったら、なにがあっても二度と同じやり方でやらなくても構いませんから。

前のセクションで私が示した実験デザインは、三つの異なる薬による気分の変化の平均を比較することに興味があるということを示していましたが、私たちがやろうとしている分析は t 検定 (第 10 章) に似ていますが、二つ以上のグループが含まれていることになります。ここで μ_P をプラセボによって作られた気分変容の母平均を示していきましょう。そして μ_A と μ_J がそれぞれ Anxifree と Joyzepam、この二つの薬による平均だとします。それから (すこし悲観主義的ですが) 私たちが検証しようとしている帰無仮説は、これら三つの母平均が同じだということです。つまり二つの薬のどちらも、プラセボに比べてもなんの効果もない、ということです。この帰無仮説は次のように書くことができます。

$$H_0 : \text{次の式が正しい ; } \mu_P = \mu_A = \mu_J$$

結果的に、私たちの対立仮説は、三つの異なる処遇の少なくとも一つは、他とは異なるということに

なります。これを数学的に書くと少しトリッキーに見えます。というのも(この後議論するように), 帰無仮説が間違っている時でもほんのちょっとした違いしかないからです。対立仮説は次のように書くことができます。

$$H_1 : \text{次の式が正しく ない ; } \mu_P = \mu_A = \mu_J$$

帰無仮説は私たちがこれまで見てきた検定のどれと比べても, トリッキーな感じ満載です。どうしたらよいのでしょうか? この章のタイトルからして, “分散分析をする” というのが妥当な推測になりますが, “分散を分析する” のが平均についてなんらかの有用な知識を得る助けになるのが何故か, というのがあまりはつきりしません。実際のところ, これが, 人が初めて ANOVA に会うときに感じる最大の概念的な困難なのです。ANOVA がどのように働くかをみるためには, 分散について話を始めるのが最も良いことを私は見つけました。実際, 分散を記述する数式を使った, ある種の数学ゲームをプレイしながら話をしたいと思います。すなわち, 分散の周りで遊ぶところから始めると, これが興味の対象である平均にとって便利なツールになるということがわかります。

12.4.1 Y の分散についての二つの式

まず, いくつかの表記法を導入するところから始めましょう。ここではグループの総数を表すのに, G を使います。三つの薬に関するデータの場合は, $G = 3$ 群あることになります。次に, 全体のサンプルサイズを N とします; つまり, 私たちのデータセットには全部で $N = 18$ 人いることになります。同様に, 第 k 番目の群にいる人は, N_k と書くことにします。私たちの仮想的臨床検査の場合, サンプルサイズは三つの群全てにおいて $N_k = 6$ です。^{*1}最後に, 結果変数を Y と書くことにします。私たちの例では, Y は気分の変化です。特に, 第 k 群の第 i 番目のメンバーに生じた気分変化は, Y_{ik} と書きます。同様に, この実験における 18 人全員について, 気分変化の平均を撮ったものを $\bar{Y}$ とし, 第 k 群における 6 名の気分変化の平均は, $\bar{Y}_k$ とします。

^{*1}全ての群で同じ数の観測がなされている場合, その実験デザインは“バランス (のとれている)” デザインだといいます。バランスはこの章のトピックである, 一元配置 ANOVA の時にはそれほど問題になりません。もっと複雑な ANOVA をやろうとすると, より重要な問題になってきます。

さて、これで表記法が出揃ったので、式を書き始めることができます。始めるにあたって、セクション 4.2 で使われていた分散の式を思い出しましょう。私たちが記述統計を行っていた、あの懐かしい日々に戻って。Y の標本分散は次のように書くのでした。

$$\text{Var}(Y) = \frac{1}{N} \sum_{k=1}^G \sum_{i=1}^{N_k} (Y_{ik} - \bar{Y})^2$$

この数式はセクション 4.2 の分散の式と、ほとんど同じように見えます。違いは今回二つの添字があることだけです：私は群ごと (すなわち、k の値) に足し合わせて、それから群内の人 (すなわち i の値) について足し合わせました。これは本当に表面的な違いです。もしここで、サンプルにおけるある人 p の結果変数の値として Y_p を使っていたら、添字は一つだけになったでしょう。二つの添字を使っている唯一の理由は、私が人を群に分けたからであり、群の中の人の番号を割り当てたからです。

ここで具体的な例を見るとわかりやすいでしょう。N = 5 人の人がそれぞれ G = 2 群に分類された、次の表を見てみましょう。適当に “イケてる” グループを群 1, “イケてない” グループを群 2 としましょう。ここには 3 人のイケてる人 ($N_1 = 3$) と、2 人のイケてない人 ($N_2 = 2$) がいます。

名前	人	群	群番号	群の中の番号	ダサさ
	p		k	i	Y_{ik} or Y_p
Ann	1	cool	1	1	20
Ben	2	cool	1	2	55
Cat	3	cool	1	3	21
Dan	4	uncool	2	1	91
Egg	5	uncool	2	2	22

ここでは、2 種類の異なるラベリング技術が使われていることに注意してください。“人” 変数は p で表しますので、サンプルの中の p 番目の人のダサさを Y_p として表現することができます。例えば、この表では Dan は 4 番目なので、 $p = 4$ とすることができます。さて、この “Dan” なる人物のダサさ Y について話すとき、彼がどんな人であったとしても、彼のダサさを $Y_p = 91$ で $p = 4$ である、という参照をすることができます。しかし、Dan を参照する方法はこれだけではありません。もう一つの方法として、Dan が “イケてない” グループ ($k = 2$) に所属しており、イケてない群 ($i = 1$) のリストの最初の人だということもできます。ですから同じように Dan のダサさを参照するのに、 $Y_{ik} = 91$ で $k = 2$ かつ $i = 1$ ということもできるのです。

言い換えると、各対象者 p が一つの組み合わせ k に対応しているので、上で挙げた式は実質的に元の分散の式と同じ、つまり次のようになります。

$$\text{Var}(Y) = \frac{1}{N} \sum_{p=1}^N (Y_p - \bar{Y})^2$$

どちらの式でも、サンプルにおける全ての観測例を足し上げることになります。ほとんどの場合、より単純な表記である Y_p という書き方をします。 Y_p という式は二つの中で明らかに単純な方の書き方ですね。しかし、ANOVA をするときは各対象者がどちらの群に所属しているかを保持した書き方であることが重要になるため、 Y_{ik} をつかってこれを書き表すこともあるのです。

12.4.2 分散から平方和へ

オウケイ、分散がどのように計算されるかを大体掴んだところで、**平方の総和**と呼ばれるものを定義しましょう。表記は SS_{tot} です。これはとても単純です。分散を計算する時には平均偏差の二乗を平均するわけですが、その代わりにそれを単に足し合わせます。

ですので平方の総和の数式は、分散の式とほとんど同じです。

$$SS_{\text{tot}} = \sum_{k=1}^G \sum_{i=1}^{N_k} (Y_{ik} - \bar{Y})^2$$

ANOVA の文脈で分散を分析することについて話をするときは、実際の分散ではなく平方の総和をつかって実行していることになります。平方の総和を使う利点の一つは、それを異なる二種類の変動に分解することができる点です。

まず、**群内平方和**について話しましょう。そこでは群平均から個々人がどれほどずれているかを見ることができます。

$$SS_w = \sum_{k=1}^G \sum_{i=1}^{N_k} (Y_{ik} - \bar{Y}_k)^2$$

ここで $\bar{Y}_k$ は群平均です。例えば、 $\bar{Y}_k$ は k 番目の薬を与えられた人による、気分変容の平均値です。ですから、実験に参加した全員の平均と個々人を比較するのではなく、おなじ群にいる人の平均と比較していることになります。結果的に、 SS_w の値は平方和の総和よりも小さくなります。というのも、そこには群の違い、すなわち薬が人の気分に与える影響の違いがあるかどうかを完全に除外しているからです。




Figure12.2 “群間”変動 (パネル a) と “群内”変動 (パネル b) を図示したもの。左の図では、矢印が群間平均の差を示しています。右図では矢印が群内の変動を強調しています。

次に、群の違いだけを捉えた変動を記述する第3の表記を定義しましょう。これは全体平均 $\bar{Y}$ と群平均 $\bar{Y}_k$ の間のずれを見ることになります。

この変動の大きさを評価するために、**群間平方和**を計算することになります。

$$\begin{aligned} SS_b &= \sum_{k=1}^G \sum_{i=1}^{N_k} (\bar{Y}_k - \bar{Y})^2 \\ &= \sum_{k=1}^G N_k (\bar{Y}_k - \bar{Y})^2 \end{aligned}$$

実験におけるすべての人の中にある全変動 SS_{tot} を示すことはそれほど難しくありません。実際には、群間の変動 SS_b と群内の変動 SS_w を足しあわせるのですすなわち、

$$SS_w + SS_b = SS_{tot}$$

イエイ。

さて、何がわかったのでしょうか？ 結果変数に伴う変動全体 (SS_{tot}) は “異なる群の標本平均の違いに伴う変動” (SS_b) と、 “その残りの変動” (SS_w) を足し合わせたものに切り分けられるということです。^{*2}では母平均が群ごとに異なっているかどうかを検証するには、どうすれば良いのでしょうか？ フムウ。待てよ。ちょっとまってください。今思うに、これこそまさに私たちが探していたものです。もし帰無仮説が真であるとすれば、全ての平均はそれぞれほとんど同じものになると思いませんか？ そしてそれが意味するのは、 SS_b が非常に小さい、少なくとも “それ以外の全ての変動” である SS_w

^{*2} SS_w は AVOVA では誤差、すなわち SS_{error} と表されることもあります。

よりは小さいことが期待できるでしょう。ムムッ。仮説検定が始まる予感がします。

12.4.3 平方和から F-検定へ

最後のセクションでみたように、ANOVA の背後にある本質的なアイデアは SS_b と SS_w という二つの平方和の値を比較するところにあります。群間変動の SS_b が群内変動 SS_w に比べて大きい時、違う群の母平均は互いに等しいとは言えない、という推論をする根拠をもつことになります。これを実際の帰無仮説検定に変換するために、“ちょっといじくり回す” が必要です。最初にお見せするのは、検定統計量として何を計算するのかであり、それは **F 比** です。それからなぜ私たちがそんな風にするのかを理解してもらおうと思います。

平方和の値を F 比に変換するために最初にしなければならないのは、 SS_b と SS_w に関する**自由度**を計算することです。普通は、自由度はある計算に関わるユニークな“データ点”の数から、満たす必要のある“制約”の数を引いたものに対応しています。私たちが計算している群内変動は、群平均 (G 個の制約) の周りにある個々人の観測による変動 (N データ点) です。対して私たちが興味のある群間変動は、全体平均 (1 個の制約) の周りにある群平均 (G データ点) の変動です。つまり、ここでの自由度は次のようになります。

$$\begin{aligned}df_b &= G - 1 \\df_w &= N - G\end{aligned}$$

オーケー、とても単純ですね。次にすることは、平方和を“平均平方”に変換することで、これは自由度で割ることで計算できます。

$$\begin{aligned}MS_b &= \frac{SS_b}{df_b} \\MS_w &= \frac{SS_w}{df_w}\end{aligned}$$

最後に F 比を計算するために、群間平均平方を群内平均平方で割ります。

$$F = \frac{MS_b}{MS_w}$$

非常に一般的な意味で、F 統計量の背後にあるものは直感的にわかります。F の値がより大きいことは、群間変動が群内変動よりも相対的に大きいことを意味します。結果的に、F の値が大きいことは、帰無仮説に対立するより大きな証拠を得たことになります。しかし、F がどれくらい大きければ、実際に H_0 を棄却できるのでしょうか？ これを理解するためには、ANOVA が何であるか、平均平方とは何なのかを、もう少し深く理解しなければなりません。次のセクションではこの詳細について説明していきますが、実際に検定が何をしているかに興味のない読者のために、ここではそれを省略しましょう。帰無仮説検定を完成させるために、帰無仮説が真である時の F の標本分布について知らなければなりません。驚くなかれ、帰無仮説のもとでの F 統計量の標本分布は **F 分布** です。第 6 章での F 分布についての議論を思い出してもらいたいのですが、F 分布は二つのパラメータを持っ

Table12.1 分散分析の中に含まれる重要な全ての数字は，“標準的な”分散分析表の中に組み込まれます。この形式では全ての数字 (p 値と呼ばれる奇妙な数式とコンピュータがないと計算できないものを除いて) が示されています。

	自由度 (df)	平方和 (SS)	平均平方 (MS)	F-統計量	p-値
群間	$df_b = G - 1$	$SS_b = \sum_{k=1}^G N_k (\bar{Y}_k - \bar{Y})^2$	$MS_b = \frac{SS_b}{df_b}$	$F = \frac{MS_b}{MS_w}$	[複雑]
群内	$df_w = N - G$	$SS_w = \sum_{k=1}^G \sum_{i=1}^{N_k} (Y_{ik} - \bar{Y}_k)^2$	$MS_w = \frac{SS_w}{df_w}$	-	-

ていて、それが二つの自由度に対応しています。最初の自由度 df_1 は群間の自由度 df_b 、第二の自由度 df_2 は群内の自由度 df_w です。

一元配置分散分析に含まれる、全ての重要な数字の要約を、計算に使った数式とともに、表 12.1 に示しました。

12.4.4 データのためのモデルと F の意味

ANOVA の根本的なレベルでは、二つの異なる統計モデルである H_0 と H_1 が競合します。帰無仮説と対立仮説をこのセクションの冒頭で論じた時、これらのモデルが実際に何を表すのかについては少し不完全なまま紹介しました。今からそれを撤回して詳述していきますが、たぶんあなたはそんなことをする私のことが嫌いになるでしょう。思い出してもらいたいのですが、私たちの帰無仮説は全ての群平均は相互に等しいというものでした。もしそうであるなら、結果変数 Y_{ik} について考える自然な方法は、一つの母平均 μ に、その変動を加えたものとして、個々のスコアを記述することです。この変動というのは普通 ϵ_{ik} で表され、伝統的にそれは観測に伴う誤差とか**残差**と呼ばれています。でも気を付けてください。“有意差”という言葉を見た時と同じように、“エラー (誤差)”には統計における専門的な意味を持っていて、日常的な定義とは異なります。日常用語で言う“エラー”は、ちょっとした失敗と言う意味ですが、統計的にはそうではありません (少なくとも、必ずしもそうではありません)。それを考慮すると、“残差”の方が“エラー (誤差)”よりも良い言葉かもしれません。統計学ではどちらの言葉も、“残っている変動”，すなわちこのモデルが説明できない“あまりもの”を意味しています。

いずれにせよ、帰無仮説を統計モデルとして書き表すと、こんな感じになります。

$$Y_{ik} = \mu + \varepsilon_{ik}$$

ここで (後ほど議論する) ある仮説を立てます。それは残差の値 ε_{ik} は正規分布に従うというもので、その平均は 0、標準偏差 σ はすべての群を通じて同じであるというものです。第 6 章で導入した表記法を使うと、この仮定は次のように書くことができます。

$$\varepsilon_{ik} \sim \text{Normal}(0, \sigma^2)$$

対立仮説 H_1 についてはどうでしょうか？ 帰無仮説と対立仮説の唯一の違いは、各群は異なる母平均を持ちうるということです。ですから、実験における第 k 番目の群の母平均を μ_k とするなら、 H_1 に対応する統計モデルは次のようになります。

$$Y_{ik} = \mu_k + \varepsilon_{ik}$$

ここでもう一度、誤差項が平均 0、標準偏差 σ の正規分布に従うと仮定します。すなわち、対立仮説もまた次のように書けるわけです。

オウケイ、さあ H_0 と H_1 を支える統計モデルについて記述してきましたが、そろそろ平均平方の値が何を測っているのか、そして F の解釈にそれがどう関係するのかを、もう少しはっきりいうべき段階にきました。照明を初めてあなたを退屈がらせることはしませんが、群内平均平方である MS_w が、誤差分散 σ^2 の推定量 (専門的な意味は、第 7 章を参照) とみなすことができることがわかります。群間平均平方 MS_b も推定量ですが、それが推定しているのは誤差分散に加えて、群平均間の真の差分についての量も入っています。もしこの量を Q と書くなら、 F 統計量は基本的に次のようになっています^a。

$$F = \frac{\hat{Q} + \hat{\sigma}^2}{\hat{\sigma}^2}$$

ここで、もし帰無仮説が正しいければ、真の値は $Q = 0$ ですし、もし対立仮説が正しいければ $Q > 0$ でしょう (e.g., [Hays 1994](#), ch. 10). つまり、少なくとも F の値は 1 よりも大きくならなければ、帰無仮説を棄却する可能性がないのです。これは、 F 値が 1 よりも小さくなることがないことを意味するのではないことに注意してください。これが意味するのは、帰無仮説が真であれば、 F 比の標本分布の平均は 1^b であり、安全に帰無仮説を棄却するためには F の値は 1 よりも大きくなければならないということです。標本分布についてもう少し正確にいうと、帰無仮説が正しい時、 MS_b も MS_w も残差 ε_{ik} の分散推定量であることに注意してください。もしこれらの残渣が正規分布に従っていたとすると、 ε_{ik} の分散の推定値がカイ二乗分布に従うのではないかと考えるかもしれません。というのも (セクション 6.6 で論じたように)、それこそカイ二乗分布そのものだからです。すなわち、正規分布するものを二乗して足し合わせたものだからです。そして、 F 分布は (もう一度、その定義に戻りますが) 二つの χ^2 分布の比を取ったものであり、それが私たちの標本分

布なわけです。明らかに、私は多少これをいうときに大袈裟に表現していますが、大まかに言って、本当に私たちの標本分布からきたものになります。

^a第 13 章まで読めば、要因の水準 k における“操作の影響”がどのように α_k の値で定義されるかを目にするでしょう (セクション 13.5)。そこでは、 Q は重みづけられた操作の影響の平方、つまり $Q = (\sum_{k=1}^G N_k \alpha_k^2)/(G-1)$ となっていることがわかります。

^bあるいは、もし正確さにこだわるのであれば、 $1 + \frac{2}{df_2-2}$ 。

12.4.5 実例

ここまでの議論はかなり抽象的で、少し理論的な話でしたので、今度は実際の例を見ることでもう少し有用な話をみていこうと思います。そのために、私がこの章の始めに導入した臨床試験データに戻しましょう。最初に計算した記述統計量からわかるのは、群平均でした。つまり、気分の向上はプラセボで 0.45 高、Anxifree で 0.72、Joyzepam で 1.48 でした。それを念頭に置いて、1899 年のようなパーティーをしましょう^{*3}、そして紙と鉛筆で計算をするのです。最初の五人についてだけ計算することにします。だって地獄の 1899 年じゃないし、私はとっても怠け者ですから。群内平方和、 SS_w を計算するところから始めるとしましょう。まず、計算しやすくするために便利な表を作るこ

	群	アウトカム
	k	Y_{ik}
とにします。	プラセボ	0.5
	プラセボ	0.3
	プラセボ	0.1
	anxifree	0.6
	anxifree	0.4

この段階で表に含めることができるのは、ロウデータそのものでしかありません。つまり群化変数 (すなわち *drug*) と結果変数 (すなわち *mood.gain*) を各人についてのものだけ、です。結果変数が私たちの式表現によると、 Y_{ik} に対応していることに注意してください。次の計算ステップはこの研究の一人におけるひとりについて、対応する群平均 $\bar{Y}_k$ に書き下すことです。これは少し繰り返しになりますが、記述統計を行う際にグループの平均値を計算しているので、特に難しいことはありません。

^{*3}あるいは、もう少し正確に、“1899 年の、友達もいないし 1899 年にはなんの意味もなかった計算をするしかないことをしましょう。だって ANOVA は 1920 年代になるまで出てこないんですから”

せん。

群 k	アウトカム Y_{ik}	群平均 $\bar{Y}_k$
プラセボ	0.5	0.45
プラセボ	0.3	0.45
プラセボ	0.1	0.45
anxifree	0.6	0.72
anxifree	0.4	0.72

さて、これらを書き出したので、再び一人一人について、対応する群平均からのズレを計算する必要があります。つまり、 $Y_{ik} - \bar{Y}_k$ の引き算をしたいのです。そうした上で、それらを二乗します。そうすると、ここにあるような数字を得ることができます。：

群 k	結果 Y_{ik}	群平均 $\bar{Y}_k$	群平均からの偏差 $Y_{ik} - \bar{Y}_k$	偏差の平方 $(Y_{ik} - \bar{Y}_k)^2$
プラセボ	0.5	0.45	0.05	0.0025
プラセボ	0.3	0.45	-0.15	0.0225
プラセボ	0.1	0.45	-0.35	0.1225
anxifree	0.6	0.72	-0.12	0.0136
anxifree	0.4	0.72	-0.32	0.1003

最後のステップは結構ストレートです。群内平方和を計算するために、全ての観測に対して偏差平方を足し合わせて行きます。

$$\begin{aligned} SS_w &= 0.0025 + 0.0225 + 0.1225 + 0.0136 + 0.1003 \\ &= 0.2614 \end{aligned}$$

もちろん、実際にはデータセットの中にある全 18 人分についてこの計算をした、正しい答えが欲しいわけですね。最初の 5 人分だけじゃなくてね。そうしたければ、神とペンを使って計算し続けてもらってもいいんですけど、それはちょっと面倒ですね。その代わりとして、専用のスプレッドシート・アプリである OpenOffice や Excel を使うと随分と楽に計算できます。是非ご自身でやってみてください。そうすると、群内平方和の値が 1.39 になるはずですね。

オーケー。群内分散 SS_w の計算が終わったので、群間平方和、 SS_b に向き合う時が来ました。この計算は非常によく似ています。大きな違いは、全ての観測に対して群平均 $\bar{Y}_k$ と観測値 Y_{ik} の差分を計算する代わりに、全体平均 $\bar{Y}$ (この回は 0.88 ですが) と群平均 $\bar{Y}_k$ の差を全ての群に対して計算

するところです。

群 k	群平均 $\bar{Y}_k$	全体平均 $\bar{Y}$	偏差 $\bar{Y}_k - \bar{Y}$	偏差平方 $(\bar{Y}_k - \bar{Y})^2$
プラセボ	0.45	0.88	-0.43	0.19
anxifree	0.72	0.88	-0.16	0.03
joyzepam	1.48	0.88	0.60	0.36

ただし、群間の計算をするときは、この偏差平方にその群に含まれる観測度数 N_k をかけなければなりません。というのも、ある群における観測はどれも (すべての N_k について)、群間の差を作るのに貢献しているからです。ですから、プラセボ群に 6 人いて、プラセボ群平均の全体平均からの差が 0.19 であれば、全体としてこの 6 人が関わった群間分散は $6 \times 0.19 = 1.14$ になります。ということで、計算のための表を少し拡張しなければなりません。

群 k	...	偏差平方 $(\bar{Y}_k - \bar{Y})^2$	サンプルサイズ N_k	重み付き偏差平方 $N_k(\bar{Y}_k - \bar{Y})^2$
placebo	...	0.19	6	1.14
anxifree	...	0.03	6	0.18
joyzepam	...	0.36	6	2.16

そして、今やこの研究における全ての群に関する群間平方和が、“重み付き偏差平方”を足し合わせることによって得られるわけです。

$$\begin{aligned} SS_b &= 1.14 + 0.18 + 2.16 \\ &= 3.48 \end{aligned}$$

みてきたように、群間の計算は短かったですね。さて、平方話の計算は SS_b and SS_w になりましたので、ANOVA の残りはたいしたことありません。次のステップは自由度の計算です。私たちのデータは $G = 3$ の群、そして $N = 18$ 人の観測度数をもっていますから、全体の自由度は簡単な引き算で算出できます。

$$\begin{aligned} df_b &= G - 1 = 2 \\ df_w &= N - G = 15 \end{aligned}$$

次に、群内分散と群間分散それぞれについて、平方和と自由度を計算したので、前者を後者で割ることで平均平方が計算できますね。

$$\begin{aligned} MS_b &= \frac{SS_b}{df_b} = \frac{3.48}{2} = 1.74 \\ MS_w &= \frac{SS_w}{df_w} = \frac{1.39}{15} = 0.09 \end{aligned}$$

ほとんど終わったようなもんです。この平均平方は、我々の興味ある検定統計量である F 値を計

算するのに使われます。群間 MS の値を群内 MS の値で割ることによってその数字が得られます。

$$F = \frac{MS_b}{MS_w} = \frac{1.74}{0.09} = 19.3$$

イヤッホーイ！興奮してきましたね？さてこの検定統計量を手に入れたわけですから、最後のステップはこの検定が有意な結果を出してくれたかどうかを見極めることです。第 8 章で議論したように、“昔”に戻って統計のテキストを開いたり、後ろの方のセクションに載ってる大きな表のをペラペラめくると、特定のアルファの値 (帰無仮説が棄却される範囲)、たとえば 0.05, 0.01, 0.001 など、に対応した、自由度 2 と 15 の F 値の閾値を見つけることができます。

そうすると、アルファが 0.001 のときの F の閾値は 11.34 であることがわかりました。これは私たちが計算した F よりも小さいので、 $p < 0.001$ と言うことができます。しかしこれは昔ながらのやり方であって、今では賢い統計ソフトウェアがあなたのために正確な p 値を計算してくれますよ。実際、正確な p 値は 0.000071 になります。さて、タイプ I のエラー率について極めて保守的であったとしても、我々は帰無仮説を棄却するのに十分な保証が得られたと言えるでしょう。この時点で、基本的に終了です。計算を終えたらば、これら全ての数字を表 12.1 のようにして、分散分析表にまとめるのが伝統的なやり方です。我々の臨床試験データについての、分散分析表は次のようになります。

	自由度	平方和	平均平方	F-統計量	p-値
群間	2	3.48	1.74	19.3	0.000071
群内	15	1.39	0.09	-	-

今日では、こうした表を自分で作る理由がないように思うかもしれませんが、ほとんどの統計ソフトウェア (JASP もそうです) は ANOVA の結果をこうした表にまとめる傾向があることに気づくと思います。なので、読み方に慣れていた方がいいでしょう。とはいえ、ソフトウェアが完全な分散分析表を出力してくれますが、あなたが書くときに全部を含める理由はある限りありません。この結果をレポートする標準的な方法は、次のように書くことです。

一言配置の分散分析では、投薬による気分の向上の有意な効果が示された ($F(2, 15) = 19.3, p < .001$)。

ふー。短い一文を書くために、たいした苦勞をするもんだ。


12.5

ANOVA を JASP で実行する

あなたがこのセクションの最後を読んだときに、特にあなたが私のアドバイスに従って紙とペンで(あるいはスプレッドシートで)計算したのであれば、どんなふうを感じるかは手に取るようにわかります。ANOVA の計算を自分でやることは最悪です。手順通りに計算する量がとてもおおいので、ANOVA をしようと思うたびに何度も何度も計算するのは面倒なのです。

12.5.1 あなたの ANOVA のための JASP

あなたの人生を楽しむために、JASP は ANOVA を実行してくれます.... 万歳! ‘ANOVA’-‘ANOVA’ 分析, とすすみ, *mood.gain* 変数を ‘従属変数’ ボックスに移動させ, それから *drug* 変数を ‘固定効果’ ボックスに動かします。こうすると図 12.3 のような結果が示されます。^{*4} ‘追加オプション’ の ‘効果量の推定’ の下にある, η^2 チェックボックスにもチェックを入れたので, 結果の表にもそれが反映されています。効果量についてはあとで触れることにします。



ANOVA - mood.gain						
Cases	Sum of Squares	df	Mean Square	F	p	η^2
drug	3.453	2.000	1.727	18.611	< .001	0.713
Residual	1.392	15.000	0.093			

Note. Type III Sum of Squares

Figure12.3 気分の向上と投薬の関係についての JASP による分散分析表

JASP の結果の表には, 平方和, 自由度, そのほか今は興味のないいくつかの統計量が示されます。しかし, JASP には “群間” とか “群内” といった表示はしていません。その代わりに, もっと意味のある名前がついています。今回の例では, 群間分散は投薬がアウトカム変数に及ぼした影響に対応しており, 群内分散は残差誤差とも呼ばれる “残った” 変動分に対応しています。これらの数字を, セクション 12.4.5 で手計算した数字と比較すると, 四捨五入によるズレを除いてほぼ同じであることがわかんと思います。群間平方和は $SS_b = 3.453$ で, 群内平方和は $SS_w = 1.392$, そしてそれぞれの自由度は 2 と 15 です。F-値と p-値も計算されていて, それも四捨五入によるズレを除い

^{*4}JASP の結果は, 丸め誤差のあった上の文章で述べたものより正確です。

て、先程の長く面倒な方法で計算したものと同じになっていることがわかります。

JASP の結果の表には、平方和、自由度、そのほか今は興味のないいくつかの統計量が示されます。しかし、JASP には“群間”とか“群内”といった表示はしていません。その代わりに、もっと意味のある名前がついています。今回の例では、群間分散は**投薬**がアウトカム変数に及ぼした影響に対応しており、群内分散は残差誤差とも呼ばれる“残った”変動分に対応しています。これらの数字を、セクション 12.4.5 で手計算した数字と比較すると、四捨五入によるズレを除いてほぼ同じであることがわかんと思います。群間平方和は $SS_b = 3.453$ で、群内平方和は $SS_w = 1.392$ 、そしてそれぞれの自由度は 2 と 15 です。F-値と p-値も計算されていて、それも四捨五入によるズレを除いて、先程の長く面倒な方法で計算したものと同じになっていることがわかります。

12.6

効果量

ANOVA において効果量を測定するには、二つの異なる方法がありますが、最も一般的に使われているのは η^2 (**eta squared**) と偏 η^2 です。一要因の分散分析では、どちらも同じになりますので、今はとりあえず η^2 について説明します。 η^2 は実際のサンプルについて、次のように定義されます。

$$\eta^2 = \frac{SS_b}{SS_{tot}}$$

これだけです。図 12.3 の分散分析表についてみると、 $SS_b = 3.45$ で $SS_{tot} = 3.45 + 1.39 = 4.84$ です。ここから、 η^2 の値は次のように計算できます。

$$\eta^2 = \frac{3.45}{4.84} = 0.71$$

η^2 の解釈も、実に直接的です。アウトカム変数 (**mood.gain**) において、予測変数 (**drug**) が説明する分散の比率をあらわしているわけです。値が $\eta^2 = 0$ であれば、両者になんの関係もないことを表しますし、 $\eta^2 = 1$ であれば完璧な関係にあることになります。さらに良いことに、 η^2 の値は、セクション 11.10.1) で説明した R^2 にかなり近いもので、それと同じように解釈することができます。

多くの統計的教科書では η^2 を ANOVA における基本的な効果量の測度だと説明していますが、Daniel Lakens がブログで興味深いことを言っています。それによると、 η^2 はデータ分析業界における最適な効果量測度ではない、なぜなら推定量のバイアスがあるからだ、ということです (<http://daniellakens.blogspot.com.au/2015/06/why-you-should-use-omega-squared.html>)。ありがたいことに、JASP にはオメガの二乗 (ω^2) という選択肢もついていて、これはよりバイアスが少なく、イータの二乗と並んで使われているものです。

多重比較と事後の (Post hoc) 検定

2 群以上で ANOVA をして有意な影響をみたときは、実際はどの群がどの群と差があったのか知りたくなるでしょう。投薬の例では、帰無仮説は三つの薬 (プラセボと Anxifree と Joyzepam) が十分に与える影響は同じというものでした。しかし考えてみると、帰無仮説は実際には三つの異なることを同時に主張しているのです。つまり、主張は次の通りです。

- あなたの競争相手である薬 (Anxifree) はプラセボと変わらない (つまり, $\mu_A = \mu_P$)。
- あなたの薬 (Joyzepam) はプラセボと変わらない (つまり, $\mu_J = \mu_P$)。
- Anxifree と Joyzepam の効果は同じぐらい (i.e., $\mu_J = \mu_A$)。

この三つの主張のどれかが偽であれば、帰無仮説も偽になります。ですから、我々が帰無仮説を棄却するとき、このなかの少なくとも一つは真であることになります。でもどれでしょう？ 三つの命題全てに興味がありますよね。あなたが本当に知りたいのは、あなたの新薬 Joyzepam がプラセボより良いはずだ、というものですから、既存の一般的な代替品 (つまり Anxifree) と比べてどの程度の効果があるのかを知っておくのは良いことでしょう。Anxifree がプラセボにくらべてどれぐらい効果があるのかをチェックするのもまた、いいことのはずです。Anxifree は既に他の研究者によって、プラセボに対する効果の検証がしっかり行われているはずですが、あなたの研究でも先行研究と同じ結果が出ることを示すかどうかのチェックをするのも、いいことのはずです。

この三つの異なる命題を使って帰無仮説を特徴付けるとしたら、8 つのあり得た“世界の状態”を区別する必要があります。

可能性:	$\mu_P = \mu_A?$	$\mu_P = \mu_J?$	$\mu_A = \mu_J?$	どの仮説か?
1	✓	✓	✓	帰無仮説
2	✓	✓		対立仮説
3	✓		✓	対立仮説
4	✓			対立仮説
5		✓	✓	対立仮説
6		✓		対立仮説
7			✓	対立仮説
8				対立仮説

帰無仮説を棄却することで、我々は #1 が真である世界を信じることはできないと決めたわけですが。次の質問は、残る 7 つの可能性のうち我々が正しいと考えることができるのはどれか？ ということです。この状況に置かれた時にも、データを見るのが助けになります。例えば、図 12.1 をみる

と、Joyzepam はプラセボや Anxifree より良いようですが、Anxifree とプラセボに実質的な違いはないように思えます。しかし、これにはっきりと答えるのは難しくいので、いくつかの検定をして助けてもらうことにします。

12.7.1 “ペアごとの pairwise” t-検定

さて問題解決のために、何をすべきでしょう？ それぞれの平均のペア (プラセボ vs. Anxifree, プラセボ vs. Joyzepam, Anxifree vs. Joyzepam) は既にあるのですから、それぞれに t 検定をしてどうなるかみてみるというのはどうでしょう？ それを JASP でするのは簡単です。ANOVA の ‘事後の検定’ オプションへ行き、‘drug’ 変数を右側のアクティブボックスに動かします。するとすぐに、*drug* の三つのレベルに対して、ペアごとの t-検定全てが表示されます。図 12.4 のように。

Post Hoc Tests

Post Hoc Comparisons – drug

		Mean Difference	SE	t	Pbonf	Pholm
anxifree	joyzepam	-0.767	0.176	-4.360	0.002	0.001
	placebo	0.267	0.176	1.516	0.451	0.150
joyzepam	placebo	1.033	0.176	5.876	< .001	< .001

Figure12.4 JASP による事後のペアごとの t-検定結果

12.7.2 多重検定のための補正

前のセクションでは、ここでの問題についてたくさんの t 検定で対応するというヒントを与えました。これらの分析を実行するときに懸念されるのは、“釣り探検”に出かけてしまったのではないかということです。何か有意になるんじゃないかと期待しながら、理論的なガイダンスなしにたくさんのたくさんの検定を行ってしまいました。このような理論無視の群間比較は、**事後検定 post hoc analysis** と言われます (“post hoc” はラテン語で “after this” という意味です)。*5

事後の検定をするのはいいのですが、注意が必要なのです。例えば、前のセクションでやったような分析は、それぞれ個別に行われた t-検定ですが、これは 5% のタイプ I エラー (つまり $\alpha = 0.5$)

*5 もしあなたが、ある箇所を比較して他のところはしない、という理論的な基盤を持っていれば、話は違ってきます。そういうときは、あなたは “post hoc な” 分析をしようとしているのではなくて、“計画された比較” をしようとしているわけです。こういう状況については本書の後半 (セクション 13.2) で行いますが、今は話を単純化しておきましょう。

で三つの検定を行ったことになります。もし私の ANOVA が 10 群について行われていたのだとしたら、わたしは 45 回の “事後の” t 検定をして、ある一つの水準が他の一つと有意に異なるかどうか、それぞれ検証することになります。あなたはそのうちの 2 つか 3 つぐらいが、偶然有意になってしまいかも、と思うかもしれません。第 8 章でみたように、帰無仮説検定の背後にある原則は、タイプ I エラーをコントロールしたいというものであったのですが、今や私はたくさんの t 検定を一度に、ANOVA の結果に基づいて判断する目的で実施しており、この時、一連の検定を通じた実際のタイプ I エラーは、完全に制御不能になっています。

この問題についての一般的な解決策は、p 値を調整することです。これは一連の検定全体を通じたエラー発生率をコントロールすることが目的です。(see [Shaffer 1995](#)). 事後の検定をする時は、普通はこのやり方で補正され(いつもではありません)、この手続きは**多重比較の補正**と呼ばれます。時には“同時推論の補正”と言われることもあります。いずれにせよ、この補正のやり方にはいくつかの異なる方法があります。このセクションとセクション 13.11 では、これらのいくつかについて取り上げますが、多くの他のやり方があるんだということは知っておいてください。(see, e.g., [Hsu 1996](#))

12.7.3 Bonferroni の補正

最も単純な補正は **Bonferroni の補正**と呼ばれるもので、それは実にとーーーーってもシンプルなものです。(Dunn 1961) m 個それぞれの検定をするような事後分析を想像してみましょう。どれかがタイプ I エラーを引き起こす確率の合計が、最大でも α になることを保証するようにしたいと思っています。^{*6}このとき、Bonferroni の補正は単に“あなたのもとの p 値を m で割れ”というだけです。もし元の p 値を表すのに p と表記するなら、 p'_j を補正した値の書き方として、Bonferroni の補正は次のようになります。:

$$p' = m \times p$$

ですから、もしあなたが Bonferroni の補正を使おうとするのなら、 $p' < \alpha$ の時に帰無仮説を棄却するようにしてください。この補正の裏にあるロジックはとても直接的ですよ。m 個の異なる検定をするなら、各検定のタイプ I エラーは大きくても α/m になるはずで、全体的なタイプ I エラーは α 以上になり得ないので。これはとても単純なことなので、元の論文で筆者は次のように書いています。

ここで述べた手法はとてもシンプルで一般的なものですから、以前にも誰かが使っていたでしょう。しかし、先行例を見つけることはできませんでしたので、おそらくこの超単純さのせいで、統計学者はいい方法だと気づけなかったのだと思います。(Dunn 1961, pp 52-53)

^{*6}すべての調整法がそうしようとしているわけではない、ということに注意しておきましょう。ここで私が述べているのは、“ファミリーワイズのタイプ I エラー”をコントロールするアプローチというやつです。しかし、他の事後分析では、“偽検出率”のコントロールを目指しているものもあり、ちょっと違うものです

Bonferroni の補正を JASP で使うためには、'補正' オプションの 'Bonferroni' のチェックボックスをクリックします。そうすると、ANOVA の結果の表の中に、Bonferroni の方法で補正された p 値の列を見つけることができるでしょう (12.4)。

12.7.4 Holm の補正

Bonferroni の補正がとてもシンプルなものだったわけですが、それが常にベストなものというわけではありません。代わりによく使われるのが、Holm の補正というものです (Holm 1979)。Holm の補正のアイデアは、あなたが検定を順番にやっていく時に、最も小さい (元の) p 値から初めて、最大のものに進んでいくというものです。第 j 番目の大きさを持つ p 値は、次のいずれかになります。

$$p'_j = j \times p_j$$

(つまり、最大の p 値は変化させないままにしておいて、二番目に大きな p 値は 2 倍に、三番目に大きな p 値は 3 倍に... というふうにしていきます)。あるいはまた、

$$p'_j = p'_{j+1}$$

どれか一つでも大きくなったときにこうします。これはちょっと混乱させるような書き方ですので、もう少しゆっくり説明しましょう。Holm の補正が何をするか、というのは次の通りです。まず、p 値を小さいものから大きいものへと、並べ替えてください。一番小さな p 値について、m 倍して終わりです。しかし、他のどれも二段階プロセスを経ていませんね。たとえば、もしあなたが二番目に小さな p 値を動かしたら、それを m - 1 倍しなければなりません。このかけられた数が、あなたが最後に手に入れた補正された p 値よりも大きければ、取っておきましょう。しかし最後のそれよりも小さければ、最後の p 値をコピーします。これがどういう働きをするかを見るために、次の表を見てください。ここには 5 つの p 値についての Holm の補正計算が示されています。

元の p	順序 j	p × j	Holm p
.001	5	.005	.005
.005	4	.020	.020
.019	3	.057	.057
.022	2	.044	.057
.103	1	.103	.103

これでわかったでしょうか？

少し計算が面倒ですが、Holm の補正はいくつかの良い特性を持っています。Bonferroni よりも良く (つまり、タイプ II エラーがより低く)、直感に反してタイプ I エラーについては同じなのです。結果として、実践ではよりシンプルな Bonferroni の補正を使う理由がなくなります。常に、より洗練

された Holm の補正が効率的だからです。ですから、あなたが多重比較の補正をする時は Holm 法でいくべきでしょう。図 12.4 には Bonferroni と Holm の補正された p 値が示されています。

12.7.5 事後検定の記載

最後に、どの群が他と比べて有意に異なっていたかを定める事後分析を行ったら、あなたが書くだろう結果の文章はこんなふうになります。：

事後検定 (Holm の補正された p を使った) では、Joyzepam が Anxifree ($p = 0.001$) とプラセボ ($p < 0.001$) よりも有意に大きな気分変容をもたらすことが示された。Anxifree はプラセボに比べて良いという証拠は見つからなかった ($p = .15$)。

あるいはもし、あなたが $p < 0.001$ とだけ書くのは嫌だというのであれば、‘設定’-‘結果’にいき、‘正確な p 値を表示する’を選択しておけば、正確な p 値を計算することができます。どちらにせよ、あなたが使った Holm の補正による調整済み p 値を使ったことを書いておくことが肝要です。そしてもちろん、既に関係する記述統計量 (すなわち、群平均や標準偏差) をどこかに書いてあることを想定しています。だって p 値だけではほとんど情報がありませんからね。

12.8

一要因 ANOVA の仮定

あらゆる統計的検定と同じように、分散分析もデータについて、特にその残差についての仮定の上に成り立っています。知っておくべき仮定は次のとおりです。：正規性、分散の均一性、独立性

セクション 12.4.4 のことを思い出して欲しいのですが、全体を読んでいなくても、せめて斜め読みぐらいはして欲しいのですが、私は ANOVA を支える統計モデルについて次のように説明したのでした。

$$\begin{aligned} H_0 : & \quad Y_{ik} = \mu + \varepsilon_{ik} \\ H_1 : & \quad Y_{ik} = \mu_k + \varepsilon_{ik} \end{aligned}$$

これらの式で、 μ は一つの全体平均を表していてすべての群を通じて同じものです。また μ_k は第 k 番目の群の母平均を表しています。ここで注目しなければならないのは、我々のデータが一つの全体平均で表現できる (帰無仮説) のか、異なる群特有の平均値があるのか (対立仮説) ということです。これはもちろん、実際の研究仮説にとって重要なことです！ しかし、検定の手続きはいず

れも、暗に、残差についてもある仮定を置いていて、そこでは ε_{ik} が次のようになっているのです。

$$\varepsilon_{ik} \sim \text{Normal}(0, \sigma^2)$$

このちょっとした仕掛けがないと、数式がうまく働かないのです。つまり、正確にいうなら、計算して最後に F 統計量を出すことはできますが、F 統計量が実際にあなたが測ろうとしたものをちゃんと測っていたかどうか保証できず、F 検定に基づいて引き出したものが間違っていることになるのです。

さて、では残差についての仮定が正しいかどうかをどうやってチェックしたらいいでしょう？ そうですね、上で述べたように、一つの文章には三つの要素がふめ込まれているので、個別に対応することを考えましょう。

- **分散の均一性**。私たちは母標準偏差 (すなわち σ) について一つの値しか用意していないことに注意してください。各群に個別の値 (つまり σ_k) を考えることもできるのです。これは分散の均一性の仮定として知られています (等分散性ということもあります)。ANOVA は母標準偏差について、すべての群で同じであるという仮定をしているのです。これについてはセクション 12.8.1 で大々的に論じます。
- **正規性**。残差は正規分布することが仮定されています。セクション 10.9 で見たように、これは QQ プロットをみることで (あるいは Shapiro-Wilk 検定をすることで) 検査できます。ANOVA の文脈におけるこれの話は、セクション 12.8.4 で論じます。
- **独立性**。独立性の仮定は少しトリッキーです。これが意味することは基本的に、ある残差について知っていても、それは他のどんな残差についてなにも語らないというものです。すべての ε_{ik} 値は他のどの残差について、どんな“配慮”もしないし、“関係”も持たないことが仮定されています。これを検証する単純明快な方法というのはないのですが、この仮定を明らかに満たさない状況というのはあるのです。例えば、もしあなたが反復測定デザインをしているとすると、各被験者は二つ以上の状況に晒されるわけですが、この時独立性は保持されていません。いくつかの観測値関係に何らかの関係があるのは、同じ人に対応しているのですから明らかです！ この時は、反復測定 ANOVA (セクション 12.8.4 を参照) のような手法を使わなければなりません。

12.8.1 分散の均一性についての仮定をチェックする

分散について予備的な検定を行うことは、波が船の定期便が出向するのに適した状態かどうかを確認するために、手漕ぎボートで海に出かけるようなものだ。

– George Box (Box 1953)

諺にあるように、猫の皮を剥ぐ方法は一つではありませんし、分散の均一性の過程を献呈するものいくつかの方法があります(何らかの理由で、誰もそれを口にしません)。私がこの話で見たことのある、最も一般的に使われる検定は、**Levene の検定 (Levene 1960)** で、これは **Brown-Forsythe 検定 (Brown and Forsythe 1974)** に関わりのある方法です。

標準的な Levene 検定や Brown-Forsythe 検定をやると、どちらであれ検定統計量として F あるいは W で表されるものが出てきますが、これは Y_{ik} の代わりに Z_{ik} を使うだけで、あとは普通の ANOVA で計算される F 統計量と同じやり方で計算されます。これを念頭において、JASP でこの検定をどうやるかを見ていきましょう。

Levene 検定は本当にシンプルなんです。アウトカム変数として Y_{ik} があるとしましょう。新しい変数として、 Z_{ik} を定義します。これは群平均からの偏差の絶対値で、次のように定義されます。

$$Z_{ik} = |Y_{ik} - \bar{Y}_k|$$

オーケー、こうすることで何がいいんでしょう？ では Z_{ik} が実際に何を意味していて、我々は何を検定しようとしているのかを考えていきましょう。 Z_{ik} の値は第 k 群における i 番目の観測がその群平均からどの程度離れているかの測度です。そしてここでの帰無仮説は、群が同じ分散を持っている、すなわち群平均からの全体的な偏差が同じであるというものでした。ですから、Levene 検定における帰無仮説は、 Z の母平均が全群で同じであるというものです。ふむう。ところで私たちが今知りたいのは、全部の群平均が同じであるという帰無仮説の統計的な検定でした。どこかでみたことありましたっけ？ そうです、これこそ ANOVA で、Levene 検定は新しい変数 Z_{ik} について ANOVA をすることそのもののなのです。

Brown-Forsythe 検定のほうはどうでしょうか？ 何が違うんでしょう？ 何にもです。Levene 検定との唯一の違いは、変換された変数 Z の作られ方で、これが少し違います。群の平均ではなく群の中央値からの偏差を使うだけです。つまり、Brown-Forsythe 検定は

$$Z_{ik} = |Y_{ik} - \text{median}_k(Y)|$$

ここで $\text{median}_k(Y)$ は群 k の中央値です。

12.8.2 Levene 検定を JASP で行う

オーケー、ではどうやって Levene 検定をすれば良いのでしょうか。本当に簡単なんですが - ANOVA の下にある '仮定のチェック' オプション、これの '均一性の検定' チェックボックスをクリックするだけです。そうして結果を見てみると、図 12.5 に示しましたが、検定結果が非有意 ($F_{2,15} = 1.45, p = .266$) であることがわかります。ですから、分散の均一性の過程は満たされて

いる、と言えそうです。しかし、外見だけでは騙されます！もしサンプルサイズが大きかったら、ANOVA の頑健性に問題を与えるような分散の均一性の仮定が破られていない時でも、Levene 検定は有意な効果を示しうるのです。これは上の引用にある George Box が指摘したことです。同様に、もしサンプルサイズがとても小さければ、分散の均一性の過程は満たされず、Levene 検定も非有意 (i.e. $p > .05$) になることがあるかもしれません。これが意味するのはつまり、仮定についてのあらゆる統計的検定は、群/カテゴリーごとの平均周りにある標準偏差をプロットしてみないとわからない、ということです...それが似通っている (つまり分散が均一である) かどうかを見ないとね。

Assumption Checks

Test for Equality of Variances (Levene's)

F	df1	df2	p
1.450	2.000	15.000	0.266

Figure12.5 JASP における一要因 ANOVA の Levene 検定結果出力

12.8.3 分散の均一性についての仮定を取り除く

今回の例では、分散の均一性の仮定は大丈夫だったことがわかりました。Levene 検定は非有意 (標準偏差のプロットも見ながら) で、心配することはないようです。しかし、実際にはこんな幸運ばかりではありませんよね。分散の均一性の仮定が破られた時、どうやって ANOVA を救えば良いのでしょうか？ここで t 検定についての議論を思い出せば、この問題に以前出会っていたことに気づきます。Student の t 検定は等分散を仮定していますが、仮定が成り立たない時の解決策は Welch の t 検定を使う、というものでした。実際、Welch (1951) は ANOVA についてのこの問題をどうやって解決するかを示してくれています (the Welch one-way test)。JASP にも One-Way ANOVA 分析が組み込まれています。Welch の補正を組み込むためには、'仮定のチェック'-'均一性の補正'の下にある 'Welch' オプションを選択するだけでいいのです。この結果は図 12.6 に示しています。

ここで何が起きているかを理解するために、前のセクション 12.5 で最初にやった ANOVA で得られた数字と比較してみましょう。後戻りする面倒を避けるために、前回の最後に得られた数字を書きおきます。: $F(2, 15) = 18.611$, $p < 0.001$ ですね。これは図 12.6 に示された One-Way ANOVA の Homogeneity Correction の下、None に示されています。

ANOVA - mood.gain

Cases	Homogeneity Correction	Sum of Squares	df	Mean Square	F	p	η^2
drug	None	3.453	2.000	1.727	18.611	< .001	0.713
drug	Welch	3.453	2.000	1.727	26.322	< .001	0.713
Residual	None	1.392	15.000	0.093			
Residual	Welch	1.392	9.493	0.147			

Note. Type III Sum of Squares

Figure12.6 JASP の一要因 ANOVA の一部としての, Welch's 均一性の補正

オーケー, もとの ANOVA では結果として $F(2, 15) = 18.6$ が得られてましたが, Welch の補正をしたら $F(2, 9.49) = 26.32$ になってますね。言い換えると, Welch の補正は群内自由度が 15 から 9.49 に減っていて, 結果の F 値が 18.6 から 26.32 に増えています。

12.8.4 正規性の仮定をチェックする

正規性の検定はもう少し直接的です。知っておくべきことはセクション 10.9 にほとんど書いてあります。やるべきことは, QQ プロットを描く, これだけです*7 JASP で QQ プロットをするには, '仮定のチェック' に行き, '残差 Q-Q プロット' をチェックします。その結果は図 12.7 に示したとおりで, 私にはちゃんと正規分布しているように見えます。

12.9

正規性の仮定を取り除く

さて正規性のチェックの仕方を見たところで, 正規性が破られた時にどうしたらいいか, と疑問を抱くのは当然ですよね。一要因 ANOVA の文脈では, 最も簡単な解決策はノンパラメトリックな検定 (すなわち, 確率分布のもつ特別な仮定を一切含まないものに立脚したもの) に切り替えることです。ノンパラメトリック検定については以前, 第 10 章でやりました。二つの群があるときは, Mann-Whitney か Wilcoxon 検定が, あなたの必要としたノンパラメトリックな代替品を提供してくれます。三つ以上の群があるばあいは, Kruskal-Wallis 順位和検定 (Kruskal and Wallis 1952) を使うことができます。そう, これこそ次に説明しようとしているものです。

*7 Shapiro-Wilk 検定も行うべきですが, これは今の JASP に実装されてません。Shapiro-Wilk 検定が有意でなければ (つまり $p < .05$ なら), この正規性の仮定は破られていないことを示しています。しかし, Levene 検定と同様に, もしサンプルサイズが大きければ Shapiro-Wilk の検定で有意になっても, 偽陽性である可能性があります。分析にあたって実質的な問題がないような, 正規性の仮定が破られていない状況であっても。そして同様に, とても小さいサンプルでは, 偽陰性になってしまうかもしれません。だから目で見てわかる WQQ プロットが重要なのです。

12.9.1 Kruskal-Wallis 検定の背後にあるロジック

Kruskal-Wallis 検定はある意味 ANOVA によく似ています。ANOVA では Y_{ik} から話を始めました。ここでアウトカム変数は第 k 群の i 番目の人を意味しています。Kruskal-Wallis 検定では、これら Y_{ik} の値を全て順位付けして、順序データの分析をするのです。

R_{ik} を第 k 群の i 番目のメンバーに与えられた順位だとしましょう。ここで $\bar{R}_k$ を計算し、第 k 群における観測値の平均順位を考えます。

$$\bar{R}_k = \frac{1}{N_k} \sum_i R_{ik}$$

そして全体平均 $\bar{R}$ も計算します。

$$\bar{R} = \frac{1}{N} \sum_i \sum_k R_{ik}$$

これで、全体平均 $\bar{R}$ からの偏差平方を計算することができるようになりました。個々のスコアについてこれを計算する、つまり $(R_{ik} - \bar{R})^2$ を計算することで、 ik 番目の観測値が全体平均の順位からどれだけずれているかについての、“ノンパラメトリックな” 測度を手に入れたことになります。次に全体平均から群平均の偏差平方を計算する、つまり $(\bar{R}_k - \bar{R})^2$ を算出すると、その群が全体平均の順位からどれくらいずれているかのノンパラメトリックな測度を手に入れたことになります。覚えておいて欲しいのは、いまから ANOVA と同じロジックを辿っていき、以前やったようにここでの順序の平方和を定義するということです。まず“全体の順序平方和”を計算します。

$$RSS_{\text{tot}} = \sum_k \sum_i (R_{ik} - \bar{R})^2$$

それから“群間順序平方和”を次のように算出します。

$$\begin{aligned} RSS_b &= \sum_k \sum_i (\bar{R}_k - \bar{R})^2 \\ &= \sum_k N_k (\bar{R}_k - \bar{R})^2 \end{aligned}$$

さて、もし帰無仮説が真で群間にどんな差も認められないなら、群間平方和 RSS_b はとても小さくなり、全体順序和 RSS_{tot} よりもグッと小さくなると思われるでしょう。質的には、これは ANOVA で F 統計量を出そうとした時と同じようなものなのですが、技術的な理由から Kruskal-Wallis 検定統計量は普通 K で表され、少し違った方法で計算します。すなわち、

$$K = (N - 1) \times \frac{RSS_b}{RSS_{\text{tot}}}$$

として、もし帰無仮説が真なら K の標本分散は近似的に $G - 1$ の自由度 (ここで G は群の数です) を持ったカイ二乗分布に従います。より大きな K の値が出れば、帰無仮説とより一貫性がないということになります。これは一方向検定です。 K が十分大きければ、 H_0 を棄却することになります。

12.9.2 補足

前のセクションで書いたのは、 *Kruskal-Wallis* 検定の背後にあるロジックです。概念的なレベルでは、この検定がどういう働きをするのかを考えた方がいいでしょう。しかし、純粋に数理的な側面を考えるのは不必要に複雑です。その導出をして見せようとは思いませんが、ちょっとした代数のごまかし⁴を使って、 K の式が次のように書けることを示しておきましょう。

$$K = \frac{12}{N(N-1)} \sum_k N_k \bar{R}_k^2 - 3(N+1)$$

これは、あなたが K を算出する時にみる数式の最後の形です。この形式は、先ほどのセクションで示したもののよりも簡単ですが、全体的に意味をなさないように見えますね。前に示した K の考えの方が、順位に基づいた *ANOVA* のアナロジーとして良いように思えます。しかし最後に得られた検定統計量は、元の *ANOVA* で使われるものから見ると随分違うものに見える、ということとは知っておいて欲しいのです。

いやまて、もっとあります！ なぜいつももっとあるんでしょうね？ 今までの話は、ローデータに紐づけられていない時は、常に真なのです。すなわち、同じ値を持つ変数が二つとない場合は、です。もし同順位があれば、この計算に補正項を入れなければなりません。こうなると、もっとも勤勉な読者でさえも気にしなくなったと思います (あるいは、同順位の項は今すぐ注目しなければ、という意見にはならないと思います)。ですから、さっさとどうやって計算するかを示して、なぜこれがこんな風になるのかというつまらない証明はパスしちゃいましょう。ローデータの度数分布表を作ったとして、 f_j を j 番目の一つしかない数字だとします。ちょっと抽象的ですから、度数分布表の具体例、 *mood.gain* をデータセット *clinicaltrials.csv* から取り出しましょう。

```
0.1 0.2 0.3 0.4 0.5 0.6 0.8 0.9 1.1 1.2 1.3 1.4 1.7 1.8
1   1   2   1   1   2   1   1   1   1   2   2   1   1
```

この表を見ると、三番目の要素は2という数字を持っていることがわかります。これは *mood.gain* が0.3というのに対応しているので、二人の気分が0.3ポイント上昇したことがわかります。もうひとつ。先ほど導入した数式的に表現するなら、 $f_3 = 2$ ということですね。イエイ。さて、こうなってくると補正項は次のようになります。

$$TCF = 1 - \frac{\sum_j f_j^3 - f_j}{N^3 - N}$$

Kruskal-Wallis 統計量の同順位値は、 K をこの量で割った時に得られます。JASP が計算するのは、この同順位補正版です。やっとなき、Kruskal-Wallis 検定の理論についての話を終えることができます。Kruskal-Wallis 検定の同順位補正項の計算の仕方を知らない時に感じる不安を取り除けたので、一息つけたのではないかと思います。違います？

^ajiggery-pokery. 専門用語です。

12.9.3 Kruskal-Wallis 検定を JASP で実行する

Kruskal-Wallis 検定が実際にどうなるのかを理解しようとして大変怖い思いをしたわけですが、この検定を実行するのはごく簡単です。というのも、JASP は ANOVA に ‘ノンパラメトリック’ パートを持っているからです。あなたがすべきことは、グループ変数 *drug* をアクティブボックスに動かすことだけです。そうすると Kruskal-Wallis は図 12.8 にあるように、 $\chi^2 = 12.076$, $df = 2$, p -値 = 0.002であることを示します。

12.10

反復測定の一要因 ANOVA

一要因反復測定 ANOVA 検定は、三群以上の間の有意な差異を検定するもので、そこでは各群において同じ実験参加者が使われます (あるいは各実験参加者が他の実験群における参加者と密接に関係がある場合です)。このため、各実験群には常に同じ数のスコア (データ点) があることとなります。このタイプの実験デザインと分析は、‘対応のある ANOVA’ とか ‘Within 計画の ANOVA’ と呼ばれます。

反復測定 ANOVA の背後にあるロジックは、独立した ANOVA (‘Between 計画の ANOVA’ と呼ばれることもあります) と非常に似ています。前のことを思い出して欲しいのですが、Between 計画の ANOVA では全分散が二つの要素、群間分散 (SS_b) と群内分散 (SS_w) に切り分けられ、それぞれを対応する自由度で割ることで、 MS_b と MS_w にして (Table 12.1 参照), F -ratio を次のようにして計算するのでした。

$$F = \frac{MS_b}{MS_w}$$

反復測定 ANOVA では、 F -ratio は同じように計算されますが、独立した ANOVA では分母にくる MS_w のもとになった群内分散 (SS) ですが、反復測定では SS_w が二つのパートに分離します。各群で同じ被験者を使いますから、個々人の間にある個人差に伴う分散 (SS_{subjects} と表されるもの) を、群内分散から取り除くことができるのです。これがどうやって計算されるかと言う、技術的な細部に

についてはこれ以上分け入ることはしませんが、要するに各被験者が被験者要因の各水準になるということです。この被験者内要因の分散はほかの被験者間要因と同じように計算されます。 SS_w から SS_{subjects} を引き算することで、 SS_{error} の項はより小さいものになります。

$$\text{独立 ANOVA: } SS_{\text{error}} = SS_w$$

$$\text{反復測定 ANOVA: } SS_{\text{error}} = SS_w - SS_{\text{subjects}}$$

この SS_{error} の項についての変化は、より強い統計的検定を引き出してくれますが、これは SS_{error} の減少分と誤差項の自由度の減少が相殺しあった上での話 (自由度は $(n - k)^{*8}$ から $(n - 1)(k - 1)$ になります。(独立 ANOVA 計画にはより多くの被験者がいることを思い出して))。

12.10.1 JASP による反復測定 ANOVA

まずデータが必要ですね。[Geschwind \(1972\)](#) が言ったように、脳卒中の後に生じる言語障害を正確に把握するためには、ダメージを受けた脳の特定の領域を診断する必要があります。ある研究者は、ブロッカの失語症 (脳卒中のあとに一般的に経験される言語障害) を患っている 6 人の患者が経験したある言語障害を特定することに興味があるとします。

Table12.2 3つの実験課題において成功した試行の数

患者	スピーチ	概念	文法
1	8	7	6
2	7	8	6
3	9	5	3
4	5	4	5
5	6	6	2
6	8	7	4

患者は三つの言語再任課題をやるように言われます。最初の課題 (スピーチ生成) では、患者は一つの単語が実験者によって大声で読み上げられた後、それを反復するように求められました。第二の課題 (概念) では、言葉の理解のテストで、患者はたくさんの写真とその名前を対応させるよう求められました。第三の課題 (文法) では、正しい言葉の順序についての知識を検証するようなテストで、患者は文法的に正しくない文章を並べ替えるよう求められました。各被験者は全ての課題をや

^{*8} $(n - k)$: (被験者の数 - 群の数)

りました。患者が課題をする順番は、患者間でカウンターバランスが取られました。それぞれの課題は 10 回試行されます。各患者が課題に成功した数が、表 12.2 に示されています。これらのデータは `broca.csv` ファイルにあり、JASP に読み込むことができます。

一元配置反復測定 ANOVA を JASP で実行するには、'ANOVA' から '反復測定 ANOVA' をクリックし、次のように進めてください (図 12.9 を参照。),

- 反復測定要因名を入力してください。これは全ての被験者に反復された条件を記述するラベルを、選べるようにするためのものです。例えばスピーチ、概念、文法の課題が全ての被験者に課されたのですから、適切なラベルは '課題' でしょうか。この新しい用意名は、分析における独立変数を意味します。JASP でこれを実行するには、単に 'RM Factor 1' をクリックして、名前を入れるだけです; そこは強調表示されて、新しい名前の入力を待っていると思います – 打ち込むだけ!
- 次に '課題' 要因のそれぞれの水準名を入れたいと思います。反復測定要因テキストボックスに、三つの水準を追加する必要があることに注意してください。この三つの水準は、三つの課題を意味しています。: `speech`, `conceptual`, and `syntax` です。水準に対応するラベルに変えてください。それぞれをクリックして、新しい名前を入力するだけです。
- それから変数を左のボックスに移動させ、'反復測定のセル' テキストボックスに入れます。変数名がさっき入力した水準名と合致しているか確認してください。
- 最後に、仮定チェックのオプションの下、'球面性のチェック' テキストボックスをクリックします (今はひとまず私を信じて!)

反復測定 ANOVA の JASP の出力は図 12.10 のようになります。結果を見る前に、Mauchly の球面性の検定をしなければなりません。これは条件間の分散が等しいという仮定を検定するものです (実験条件間の異なるスコアの広がり、ほとんど同じだという意味です)。図 12.10 にあるように、Mauchly の検定は有意水準が $p = .720$ です。Mauchly の検定は有意ではなかった (つまり今回の研究例では $p > .05$ だった) ので、分散の間に有意な違いがない (つまり大体等しく、球面性を仮定できる) と結論づけるのが妥当だということになります。

ところで、もし Mauchly の検定が有意 ($p < .05$) であれば、分散間には有意に異なっていることになるので、球面性の仮定が満たされていないことになります。この場合、一要因 ANOVA で得られた F 値の補正をする必要があります。すなわち、

- “球面性の検定” 表の Greenhouse-Geisser の値が $> .75$ であれば、Huynh-Feldt の補正を使うべきです。
- Greenhouse-Geisser の値が $< .75$ であれば、Greenhouse-Geisser の補正を使うべきです。

補正された F 値はどちらも、仮定のチェックオプションの下にある球面性の補正チェックボックスにチェックを入れることで得られます。補正された F 値は図 12.11 の結果の表に示されています。

この分析では、Mauchly の球面性検定の p 値は $p = .720$ (つまり $p > 0.05$) でした。ですから、球面性の仮定が守られていると考えて、 F 値の補正は必要ないことになります。そこで、球面性補正の出力にある 'なし' の反復測定 of '課題' の値を使います。: $F = 6.93, df = 2, p = .013$ で、スピーチ、理解、文法という各言語課題の成功回数は有意に異なっている、ということができます ($F(2, 10) = 6.93, p = .013$)。

普通、結果を解釈するために記述統計量をレビューするべきです。'追加オプション' のメニューに行き、'課題' を '周辺平均' の下にあるアクションボックスに入れることで、JASP 上でこれらの数値を算出できます。この結果が図 12.12 にありますが、各条件の平均だけでなく 95%CI も示されています。被験者が達成した課題数の平均を比較すると、ブロッカの失語症はスピーチ (平均 = 7.17) と言語理解 (平均 = 6.17) の課題ではそれなりの成績を上げています。しかし、文法課題ではかなりパフォーマンスが悪く (平均 = 4.33)、事後検定でもスピーチと文法のパフォーマンスには有意な差があります。

12.11

反復測定 ANOVA についての Friedman ノンパラメトリック検定

Friedman 検定は反復測定 ANOVA のノンパラメトリック版です。それぞれの群に同じ参加者がいる場合、あるいは各参加者が他の条件の参加者と厳密に対応づけられている場合に、3 つ以上の群の差を検定するのであれば、Kruskal-Wallis 検定の代わりにこちらを使うことができます。従属変数が順序尺度である場合や、正規性の仮定が満たされない場合にも、Friedman 検定を使うことができます。

Kruskal-Wallis 検定の時のように、背後にある数学的な意味は複雑ですので、ここでそれを示そうとは思いません。この本の目的としては、JASP で同順位があるバージョンの Friedman 検定ができることを示せば十分でしょう。図 12.13 にはすでにみたブロッカ失語症データを使った例が示されています。

JASP で Friedman 検定をやるのは本当に簡単です。'ノンパラメトリック' メニューにいき、'課題' を 'RM Factor' ボックスに動かすだけです。`Conover の事後検定' オプションもクリックしておきましょう。

JASP の結果が図 12.13 には、自由度と p 値、Kendall の W の値が示されています。 p 値は有意性を決めるのに使われる水準 ($p < .05$) より低いですから、課題の 3 水準間には差があると結論づけることができます。Conover の事後検定は、スピーチ課題の成績 (mean = 7.2) と言語理解 (mean = 6.2) が良いパフォーマンスであったことを示しています。一方、文法のパフォーマンス

(median = 4.3) は悪く、スピーチと文法課題に比べて事後検定で有意差がありました。この有意差は、補正のない p 値のときだけ現れていることに注意してください。Bonferroni の補正や Holm の補正をすると、 p 値は有意ではありません (いずれも $p = 0.081$)。

Assumption Checks

Q-Q Plot




Figure12.7 JASP で作った QQ プロット

Kruskal-Wallis Test

Factor	Statistic	df	p
drug	12.076	2	0.002

Figure12.8 JASP における一要因ノンパラメトリック ANOVA である, Kruskal-Wallis 検定




Figure12.9 JASP における反復測定 ANOVA

Assumption Checks

Test of Sphericity

	Mauchly's W	Approx. χ^2	df	p	Greenhouse-Geisser ϵ	Huynh-Feldt ϵ	Lower Bound ϵ
Task	0.849	0.657	2	0.720	0.868	1.000	0.500

Figure12.10 一要因反復測定 ANOVA の出力: Mauchly の球面性テスト

Within Subjects Effects

	Sphericity Correction	Sum of Squares	df	Mean Square	F	p
Task	None	24.778	2.000	12.389	6.925	0.013
	Greenhouse-Geisser	24.778	1.737	14.265	6.925	0.018
	Huynh-Feldt	24.778	2.000	12.389	6.925	0.013
Residual	None	17.889	10.000	1.789		
	Greenhouse-Geisser	17.889	8.685	2.060		
	Huynh-Feldt	17.889	10.000	1.789		

Note. Type III Sum of Squares

Figure12.11 一要因反復測定 ANOVA の出力: 被験者内効果の検定

Marginal Means

Marginal Means – Task

Task	Marginal Mean	SE	95% CI	
			Lower	Upper
speech	7.167	0.624	5.825	8.509
conceptual	6.167	0.624	4.825	7.509
syntax	4.333	0.624	2.991	5.675

Figure12.12 反復測定 ANOVA の出力: ‘周辺平均’ ダイアログより, 記述統計量が表示されます。

Friedman Test

Factor	Chi-Squared	df	p	Kendall's W
Task	6.636	2	0.036	0.490

Conover's Post Hoc Tests

Conover's Post Hoc Comparisons – Task

		T-Stat	df	W _i	W _j	p	P _{bonf}	P _{holm}
speech	conceptual	1.065	10	16.000	12.500	0.312	0.936	0.318
	syntax	2.586	10	16.000	7.500	0.027	0.081	0.081
conceptual	syntax	1.521	10	12.500	7.500	0.159	0.477	0.318

Figure12.13 JASP における反復測定 ANOVA の Friedman ノンパラメトリック検定

13. 多元配置分散分析

ここまでの章で、我々は多くの統計解析について学んできました。1つの名義的な予測変数を用いて、2つのグループの差 (e.g. t 検定, Chapter 10) や、3つ以上のグループの差 (e.g. 一元配置分散分析, Chapter 12) について統計的検定を行う方法について見てきました。回帰分析の章 (Chapter 11) では、複数の量的な予測変数を用いて単一の結果変数を説明するモデルを建てるという、強力で新しいアイデアが紹介されました。回帰モデルを用いることで、例えば、ある生徒のテスト勉強の時間や IQ テストの得点に基づいて、その生徒の読解テストの誤答数を予測することができます。

本章の目的は、複数の予測変数を使用するというアイデアを、分散分析の枠組みへと拡張することです。例えば、我々が、読解テストを用いて3つの異なる学校における生徒の成績を測定しようとしていると考えてみましょう。加えて、我々は、女子と男子が異なる速度で発達している (したがって、成績も平均的に異なることが予想される) と想定しています。各生徒は、彼／彼女らの性別と、所属する学校という2つの異なる変数によって分類されます。我々の目的は、これらのグループ化変数の両方に基づいて、読解テストの成績を分析することです。これを実現するための手法が、いわゆる**多元配置分散分析**です。ここでは2つのグループ化変数があるため、この手法は Chapter 12 で登場した一元配置分散分析に対して、二元配置分散分析と呼ばれることもあります。

13.1

多元配置分散分析 1: 釣合型デザイン, 交互作用なし

分散分析について述べた Chapter 12 では、かなり単純な実験計画が想定されていました。各個人は特定のグループに属しており、我々の目的は、いくつかの結果変数について、これらのグループ間で平均値が異なるかどうかを明らかにすることでした。この節では、**多元配置デザイン**と呼ばれる、2つ以上のグループ化変数を持つより広範な実験デザインについて見ていきます。先ほど、こうしたデザインが必要となるような例を1つ挙げました。Chapter 12 で登場した別の例では、各個人の経験した**気分の向上**に対する異なる薬の影響に注目しました。この例では薬の有意な効果が見出されま

したが、章の終盤では、それに加えてセラピーの効果を確認するための分析を行いました。セラピーの効果は見出されませんでした。同じ結果変数を予測する2つの分析を別個に行ったことに対する若干の懸念があります。おそらく、実際にはセラピーによる気分の向上効果はあるのですが、その効果は薬の効果によって「隠されて」いたために見つけられなかったのではないのでしょうか？言い換えれば、我々は薬とセラピーの両方の予測変数を含む、単一の分析を行う必要があります。この分析では、各個人は、投与された薬(3水準の要因) および受けたセラピーの種類(2水準の要因)という2つの要因によって分類されます。こうした分析は3×2 要因デザインと呼ばれます。

JASP の「頻度」→「分割表」の分析を用いて薬とセラピーのクロス集計表を作成すると、Figure 13.1 のような表が得られます。

Contingency Tables			
drug	therapy		Total
	CBT	no.therapy	
anxifree	3	3	6
joyzepam	3	3	6
placebo	3	3	6
Total	9	9	18

Figure13.1 薬とセラピーによる分割表

集計表から、2つの要因のあらゆる組み合わせに参加者が属している、すなわちこの分析が**完全交差**デザインであることだけでなく、各グループに同数の参加者が属していることが分かります。言い換えれば、この分析は**釣合型**デザインだということです。これは最も単純なケースであるため、この節では、釣合型デザインのデータをどのように分析するかを見ていきます。非釣合型デザインに関する説明はかなり冗長なので、ここでは一旦置いておくことにします。

13.1.1 検定したい仮説はどんなものか？

多元配置分散分析は、一元配置分散分析と同様に、母集団の平均値に関する仮説を検定するための手法です。したがって、この分析の仮説が実際にはどのようなものであるかを明確にすることから始めるのが賢明でしょう。しかし、このことについて議論するにあたって、母集団の平均の簡潔な表記法があると非常に便利です。観測値は2つの異なる要因に応じて分類されているため、分析者が関心を持ちうる、非常に多くの平均値があります。これを確かめるために、今回のデザインにおいて計

算可能なあらゆるサンプル平均について考えてみましょう。まず、我々は明らかに、以下のようなグループごとの平均値に関心があります：

```

%drug      therapy      mood.gain
薬の種類   セラピーの種類   気分の向上
%placebo   no.therapy    0.300000
プラセボ   セラピーなし    0.300000
%anxifree  no.therapy    0.400000
アンザイフリー セラピーなし  0.400000
%joyzepam  no.therapy    1.466667
ジョイゼパム セラピーなし  1.466667
%placebo    CBT          0.600000
プラセボ    CBT          0.600000
%anxifree   CBT          1.033333
アンザイフリー CBT          1.033333
%joyzepam   CBT          1.500000
ジョイゼパム CBT          1.500000

```

この出力は、2つの要因のあらゆる組み合わせ (e.g., プラセボ群でセラピーなし, プラセボ群で CBT を実施, など) におけるグループごとの平均値のリストになっています。これらの数値に加えて、行と列の平均および全体の平均を、以下のように1つの表で示しておくくと便利です：

	セラピーなし	CBT	合計
プラセボ	0.30	0.60	0.45
アンザイフリー	0.40	1.03	0.72
ジョイゼパム	1.47	1.50	1.48
合計	0.72	1.04	0.88

これらの平均値のそれぞれは、当然ながらサンプル統計量です。これらの値は、我々の研究において行われた特定の観察に依存しています。我々が推定したいのは、これらの値と対応する母集団のパラメータです。すなわち、より広範な母集団の中に存在する真の平均です。これらの母平均も同様に表として整理することができますが、そのためには少々、数学的な表記が必要です。ここでは一般的な表記にしたがって、 μ を母平均の記号として用います。ただし、表中には様々な平均値があるため、添字を使ってこれらを区別する必要があります。

表記法は次の通りです。この表は2つの要因によって構成されています。各行は要因 A(ここでは薬) のそれぞれの水準に対応し、各列は要因 B(ここではセラピー) のそれぞれの水準に対応します。R が表中の行数を、C が列数を表すとき、この分析は $R \times C$ 要因の分散分析と表現することができます。ここでは $R = 3$, $C = 2$ となります。小文字を使って特定の行と列を表します。したがって、

μ_{rc} は要因 A の第 r 水準 (i.e. r 行目), 要因 B の第 c 水準 (c 行目) の母平均を表します。^{*1} 母平均は以下のように表すことができます:

	セラピーなし	CBT	合計
プラセボ	μ_{11}	μ_{12}	
アンザイフリー	μ_{21}	μ_{22}	
ジョイゼパム	μ_{31}	μ_{32}	
合計			

さて、残りの組み合わせについてはどうでしょうか？例えば、CBT を受けるかどうかに関わらず、今回のような実験においてジョイゼパムを投与される可能性のある (仮想的な) 母集団全体の平均的な気分の向上について、どのように記述すれば良いのでしょうか。これは”ドット”記法によって表すことができます。先ほどのジョイゼパムの例に関しては、表の第 3 行目の値を平均すれば求められることが分かります。すなわち、2 つのセルの平均値 (i.e., μ_{31} および μ_{32}) を平均化するという事です。この平均化の結果は**周辺平均**と呼ばれ、この場合には $\mu_{3.}$ と表記されます。CBT の周辺平均は、表の第 2 列目についての母平均と対応するため、 $\mu_{.2}$ と表記されます。総平均は、行と列の両方を平均化 (周辺化^{*2}) することによって得られる平均値であるため、 $\mu_{..}$ と表記されます。母平均についての完全な表は、以下のように書くことができます:

	セラピーなし	CBT	合計
プラセボ	μ_{11}	μ_{12}	$\mu_{1.}$
アンザイフリー	μ_{21}	μ_{22}	$\mu_{2.}$
ジョイゼパム	μ_{31}	μ_{32}	$\mu_{3.}$
合計	$\mu_{.1}$	$\mu_{.2}$	$\mu_{..}$

この表記法によって、仮説を定式化して表現することが容易になります。以下の 2 点を明らかにすることを目指すと考えてみましょう。まず、薬の選択が気分は何らかの影響を及ぼすか？次に、CBT は気分は何らかの影響を及ぼすか？もちろん、定式化することができる仮説はこれらだけではありません。Section 13.5 において、これらとは別の、非常に重要な仮説の例が示されます。しかし、これらは検定における最も単純な 2 つの仮説であるため、まずはこの 2 つから始めましょう。まず、最初の検定について考えます。もし薬が何の効果も持たないとする、すべての行平均は同じに

^{*1}添字を使った表記法の良いところは、その一般化可能性です。もし、この実験に 3 つ目の要因が加わったとしても、単に 3 つ目の添字を追加するだけで済みます。原理的には、添字は実験に加えたい要因の数に応じていくつでも拡張することができますが、本書では 2 つ以上の要因を含む分析を扱うことはほとんどないため、添字が 3 つを超えることはありません

^{*2}技術的には、周辺化は一般的な平均と全く同一ではありません。周辺化は、平均化しようとする様々なイベントの頻度を加味した加重平均です。しかし、釣合型デザインにおいては、すべてのセルの頻度が定義上等しいため、これらは同じ値になります。後に非釣合型デザインについて説明する際に、この計算が非常に頭痛の種になるものだということが分かるでしょう。ですが、今の所は忘れて構いません。

なるはずですね？ したがって、これが帰無仮説になります。一方で、薬が何らかの効果を持つとすると、行平均は異なるものになることが予想されます。正式には、これらの帰無仮説および対立仮説は、周辺平均の等価性の考え方に沿って書き表されます：

帰無仮説, H_0 : 行平均が等しい, i.e., $\mu_{1.} = \mu_{2.} = \mu_{3.}$

対立仮説, H_1 : 少なくとも 1 つの行平均が異なる

これらの統計的仮説が、Chapter 12 でこれらのデータに対して一元配置分散分析を行った際の仮説と全く同じであることは注目に値します。その際には、プラセボ群の平均的な気分の向上を表す表記として μ_P を、2 つの薬のグループ平均を表す表記として μ_A と μ_J を用い、帰無仮説は $\mu_P = \mu_A = \mu_J$ で表されました。ここでも同じ仮説について説明しているのですが、複数のグループ化変数を持つより複雑な分散分析においては、より丁寧な表記が必要なため、ここでは帰無仮説は $\mu_{1.} = \mu_{2.} = \mu_{3.}$ と表されます。しかしながら、後述のように、仮説は同じであるものの、2 つ目のグループ化変数が存在することによって、仮説の検定の仕方は微妙に異なります。

もう一方のグループ化変数に話を移して、2 つ目の仮説検定も同様の方法で定式化できることに気付いたとしても、もはや驚かないでしょう。ただし、今度は薬の効果ではなく心理療法に注目するため、帰無仮説は列平均の等価性に対するものになります：

帰無仮説, H_0 : 列平均は等しい, i.e., $\mu_{.1} = \mu_{.2}$

対立仮説, H_1 : 列平均は異なる, i.e., $\mu_{.1} \neq \mu_{.2}$

13.1.2 JASP による分析の実行

先ほどの節で説明した帰無仮説と対立仮説には、随分と見覚えがあるように思えます。これらは基本的に、Chapter 12 の一元配置分散分析において検定した仮説と同じです。そのため、多元配置分散分析で用いられる仮説の検定も、Chapter 12 で登場した F 検定と本質的には同じであると期待しているのではないのでしょうか。平方和 (SS), 平均平方 (MS), 自由度 (df), そして最終的には p 値に変換することのできる F 統計量を参照する方法が、ここでも使えると思っているのではないですか？ まさにその通りです。そういうわけなので、ここでは前章までとは異なるアプローチを取りたいと思います。本書を通じて、まずは特定の分析の基礎となるロジック (およびある程度の数学的な記述) を説明し、その後に JASP による分析方法の解説を行うアプローチを取ってきました。今回は、これとは逆に、まず JASP でどのように分析を行うかを示します。その理由は、Chapter 12 で説明した単純な一元配置分散分析と、この章で使用するより複雑な分散分析との類似点を強調したいからです。

分析しようとしているデータが釣合型の要因計画に対応している場合、分散分析の実施は容易にな

ります。どれほど容易であるかを確認するため、Chapter 12で行った分析を再現することから始めましょう。忘れてしまった読者のために、この分析では1つの要因(i.e., 薬)によって結果変数(i.e., 気分の向上)を予測しようとし、Figure 13.2のような結果を得ている。

ANOVA - mood.gain					
Cases	Sum of Squares	df	Mean Square	F	p
drug	3.453	2.000	1.727	18.611	< .001
Residual	1.392	15.000	0.093		

Note. Type III Sum of Squares

Figure13.2 JASP による気分の向上を結果変数、薬を予測変数とする一元配置分散分析

加えて、ここではセラピーが気分の向上と関係しているかどうか知りたいと考えます。Chapter 11で行われた重回帰分析に関する議論を踏まえると、セラピーの変数を2番目の‘固定効果’として加えるだけでこの分析ができると知っても驚かないでしょう。Figure 13.3を見てください。

ANOVA - mood.gain					
Cases	Sum of Squares	df	Mean Square	F	p
drug	3.453	2.000	1.727	26.149	< .001
therapy	0.467	1.000	0.467	7.076	0.019
Residual	0.924	14.000	0.066		

Note. Type III Sum of Squares

Figure13.3 JASP による気分の向上を結果変数、薬およびセラピーを予測変数とする二要因分散分析

先ほどと同様に、この出力も非常に分かりやすくなっています。表の最初の行は、薬の要因に関する群間平方和(SS)と、対応する群間のdfを表しています。平均平方(MS)とF統計量およびp値も示されています。同様に、セラピーの要因に対応する行と、残差(i.e., 群内変動)に対応する行があります。

これらの数値はそれぞれ見覚えのあるものでしょうし、これらの数値の関係もまた、一元配置分散分析を行ったときと変わっていません。平均平方は、SSを対応するdfで割ることによって計算されていることに注意してください。したがって、また薬やセラピー、残差については言及していません。

んが、

$$MS = \frac{SS}{df}$$

という関係がここでも成り立ちます。これを確認するために、平方和がどのように計算されるかを気にかける必要はありません。代わりに、JASP が SS を正しく計算してくれたことを信じて、その他の数値の意味についても考えてみましょう。まず、薬の要因に関して、3.453 を 2 で割ると、平均平方は 1.727 という値になります。セラピーの要因に関しては、自由度が 1 しかなく、計算も容易になります：0.467(SS) を 1 で割ると、0.467(MS) が得られます。

F 統計量と p 値を見ると、それぞれ 2 つずつあることに気づきます；1 つは薬の要因に対応し、もう 1 つはセラピーの要因に対応しています。どちらの場合も、F 統計量は要因に対応する平均平方の値を残差に対応する平均平方の値で割ることで計算されます。最初の要因 (要因 A；今回の場合は薬) を表す省略表記として “A” を、残差を表す省略表記として “R” を用いる場合、要因 A に対応する F 統計量は F_A で表され、以下のように計算されます：

$$F_A = \frac{MS_A}{MS_R}$$

また、要因 B(i.e., セラピー) についても同様の計算ができます。先ほど表中の行数を表す文字としても R を使用しているので、残差の表記として “R” を用いるのは少し紛らわしいですが、 SS_R や MS_R といった文脈でのみ、“R” を残差を表すものとして使用するので、混乱しないよう願います。ともかく、この式を薬の要因に適用すると、要因の平均平方 1.727 を残差の平均平方の値 0.066 で割ることになり、26.149 という F 統計量が得られます。セラピーの変数については、0.467 を 0.066 で割ることで、7.076 という F 統計量が計算されます。当然ですが、これらは先ほど JASP が分散分析表で報告した値と同じです。

分散分析表には p 値も含まれています。これもまた、特に目新しいことはありません。2 つの要因のそれぞれについて、要因と結果変数の間に関係は無いという帰無仮説を検定します (これについては後ほど詳しく説明します)。そのため、分散分析を行ったとき (明らかに) 同様の方法で、これらの仮説に関する F 統計量を計算しました。これらを p 値に変換するには、帰無仮説 (検討している要因の影響はない) のもとでの F 統計量の度数分布である F 分布が必要です。2 つの自由度の値は要因と残差にそれぞれ対応していることにも注目してください。薬の要因については、自由度 2 と 14 の F 分布を参照することになります (自由度については後ほど詳しく説明します)。一方、セラピーの要因については、自由度 1 と 14 の F 分布を参照することになります。

ここで、このより複雑な要因計画のもとでの分散分析表は、単純な一元配置の分散分析の分散分析表と、ほぼ同様の方法で読み取れることに気づくでしょう。要するに、 3×2 要因の多元配置分散分析の結果、薬の有意な効果 ($F_{2,14} = 26.15, p < .001$) およびセラピーの有意な効果 ($F_{1,14} = 7.08, p = .02$) が見出されたことが分かります。あるいは、より専門的で正確な用語を用いると、薬とセラピーの効果という 2 つの主効果があるといえます。現時点では、これらを “主” 効果

と呼ぶことはやや冗長に思えますが、これには意味があります。この後、2つの要因の間に“交互作用”があるという可能性を検討するため、通常は主効果と交互作用効果を区別するのです。

13.1.3 平方和はどのように計算されるか？

ここまでの説明には2つの目的がありました。まず、多元配置分散分析をJASPで実行する方法は、一元配置分散分析とほとんど同じであることを示すことです。唯一の違いは、2つ目の要因の追加です。次に、多元配置分散分析の分散分析表を参照することで、多元配置分散分析の背後にある基本的なロジックと構造が、一元配置分散分析の背後にあるものと同じであることを示すことです。その感覚を大切にしてください。まさしく、多元配置分散分析は、一元配置分散分析とほとんど同じ方法で構成されているのです。分析の詳細について掘り下げ始めると、この感覚は揺らいでいきます。得てして、この心地よい感覚は、次第に統計学の教科書の著者に対する恨み辛みへと変わっていきます。

それでは、詳細について見ていくことにしましょう。先ほどの節では、主効果(ここでは薬およびセラピーの)に関する仮説検定がF検定であることは説明しましたが、平方和(SS)がどのように計算されるかは示されていませんでした。同様に、自由度(df)の計算方法も説明されていませんが、こちらは比較的単純です。要因Aと要因Bの2つの予測変数があると仮定しましょう。結果変数をYで表すとき、グループrc(i.e., rは要因Aに対応する行の水準、cは要因Bに対応する列の水準)に属するi番目の参加者の反応は Y_{rci} で表すことができます。したがって、 $\bar{Y}$ を用いてサンプル平均を表す場合、同様の表記法でグループ平均、周辺平均、総平均を表すことができます。すなわち、 $\bar{Y}_{rc}$ は要因Aの第r水準、要因Bの第c水準に対応するサンプル平均を表し、 $\bar{Y}_{r.}$ は要因Aの第r水準に関する周辺平均を、 $\bar{Y}_{.c}$ は要因Bの第c水準に関する周辺平均を、そして $\bar{Y}_{..}$ は総平均を表します。言い換えれば、サンプル平均は母平均と同様の表で整理することができます。今回のデータでは、以下ようになります：

	セラピーなし	CBT	合計
プラセボ	$\bar{Y}_{11}$	$\bar{Y}_{12}$	$\bar{Y}_{1.}$
アンザイフリー	$\bar{Y}_{21}$	$\bar{Y}_{22}$	$\bar{Y}_{2.}$
ジョイゼパム	$\bar{Y}_{31}$	$\bar{Y}_{32}$	$\bar{Y}_{3.}$
合計	$\bar{Y}_{.1}$	$\bar{Y}_{.2}$	$\bar{Y}_{..}$

先ほど示したサンプル平均は、 $\bar{Y}_{11} = 0.30$, $\bar{Y}_{12} = 0.60$ などです。今回の例では、薬の要因には3つの水準が、セラピーの要因には2つの水準があるため、 3×2 要因の多元配置分散分析を実行しようとしていました。より一般的な書き方では、要因A(行方向の要因)がR水準、要因B(列方向の要

因) が C 水準を持ち、R × C 要因の多元配置分散分析を行うと表現できます。

表記が定まったことで、2つの要因それぞれの平方和の値を比較的馴染みのある方法で計算することができます。要因 A についての群間の平方和は、(行の) 周辺平均 $\bar{Y}_{1.}$, $\bar{Y}_{2.}$ などが総平均 $\bar{Y}_{..}$ とどの程度異なるかを評価することで計算されます。これには一元配置分散分析と同様の方法が用いられます： $\bar{Y}_{i.}$ と $\bar{Y}_{..}$ の平方和の差を計算するのです。具体的には、各グループに N 人の参加者が属する場合、以下のように計算されます

$$SS_A = (N \times C) \sum_{r=1}^R (\bar{Y}_{r.} - \bar{Y}_{..})^2$$

一元配置分散分析と同様に、この数式の中で最も興味深い^a部分は $(\bar{Y}_{r.} - \bar{Y}_{..})^2$ という部分であり、水準 r についての偏差の 2 乗に関連しています。この式が行なっているのは、要因の R 水準すべての偏差の二乗を計算し、足し合わせ、その結果を N × C に掛けるという計算です。最後の計算を行う理由は、このデザインでは要因 A において r 水準を持つセルが複数あるためです。実際に、要因 B のそれぞれの水準に対応する C 通りのセルがあります。例えば、この例では、薬の**アンザイフリー**という水準に対応する 2 つの異なるセルがあります：1 つは**セラピーなし**のグループ、もう 1 つは **CBT** のグループです。それだけでなく、これらのセルのそれぞれについて、N 個の観測値があります。したがって、SS の値を「観測値ごと」の群間の平方和を表す量に変換するためには、N × C を掛ける必要があるのです。要因 B についての式は、もちろん、いくつかの添え字が異なる点を除いて同じものになります

これらの式が得られたことで、先ほどの節の JASP の出力と照らし合わせることができます。繰り返しになりますが、こういった計算には専用のスプレッドシートプログラムが役立ちます。

まずは、薬の主効果について平方和を計算しましょう。各グループについて、合計 N = 3 の参加者がおり、C = 2 の異なる種類のセラピーがあります。見かたを変えると、特定の薬を投与された 3 × 2 = 6 の参加者がいることになります。スプレッドシートプログラムでこれらの計算を行うと、薬の主効果に関する平方和の値は 3.45 となります。驚くべきことではありませんが、これは先ほど Figure 13.3 で示した分散分析表における薬の要因の SS と同じ値です。

治療の効果についても、同様の計算を行うことができます。先ほどと同じく、各グループには N = 3 の参加者がいますが、今度は R = 3 の異なる種類の薬があるため、CBT を受けた 3 × 3 = 9 の参加者と、セラピーを受けなかった 9 名の参加者がいます。**セラピー**の主効果に関する平方和は、0.47 と計算されます。繰り返しになりますが、計算結果が Figure 13.3 の分散分析表と同じになることは驚くべきことではありません。

以上が、2つの主効果の SS の値を計算する方法です。これらの SS の値は、Chapter 12 で一元配置分散分析を行ったときに計算した群間平方和の値と類似しています。ただし、今回は 2 つの異

なるグループ化変数があることで混乱しやすくなるため、それらを群間の SS 値として捉えることはお勧めできません。F 検定を行うためには、群内平方和も計算する必要があります。回帰分析の章 (Chapter 11) で使用した用語と、そして JASP が分散分析表で出力する用語と合わせるため、群内 SS 値は残差平方和 SS_R で表すことにしましょう。

この文脈において、残差 SS 値について考える最も簡単な方法は、それを結果変数における周辺平均の違いを取り除いた (i.e., SS_A および SS_B を取り除いた) 後の、残りの変動として捉えることです。すなわち、 SS_T というラベルの付いた、平方和の合計の計算から始めることになります。この計算式は、一元配置分散分析の場合とほぼ同じになります。各観測値 Y_{rci} と総平均 $\bar{Y}_{..}$ の差をとり、差の二乗を合計します

$$SS_T = \sum_{r=1}^R \sum_{c=1}^C \sum_{i=1}^N (Y_{rci} - \bar{Y}_{..})^2$$

ここでの「三重総和」は実際以上に複雑に見えます。最初の 2 つの総和は、要因 A のすべての水準 (i.e., 表中の r のすべての行) および要因 B の全ての水準 (i.e., 表中の c のすべての列) を合計しています。各 rc の組み合わせは 1 つのグループに対応し、各グループには N 人の参加者が含まれているため、これらの参加者 (i.e., すべての i の値) を合計する必要があります。つまり、ここで行っているのは、データセット内の全ての観測値 ((i.e., rci の全ての組み合わせ) を合計することです。

ここで、結果変数の総合的な変動である SS_T が明らかになり、その変動のうちどれだけが、要因 A (SS_A) および要因 B (SS_B) に起因するかを知ることができます。したがって、残差平方和は 2 つの要因のいずれにも起因しない Y の変動であると定義されます。言い換えれば、

$$SS_R = SS_T - (SS_A + SS_B)$$

もちろん、残差 SS を直接計算するための公式もありますが、上記のように考えることには、より概念的な意味があります。残差という言葉は、それが変動の残りの部分であることを示しており、上記の式はそれを明確にします。「分散分析モデル」に起因する変動である $SS_A + SS_B$ を、(回帰分析の章で用いられていたように) SS_M と表記することも一般的であり、このことから、平方和の総和はモデルの平方和に残差の平方和を加えたものに等しい、という表現がよく使われます。この章の後半において、これは単なる表面的な類似性ではないことが分かります：分散分析と回帰分析が内部で行っていることは、実際に、同じなのです。

いずれにせよ、この式を用いて SS_R を計算し、JASP の出力した分差分析表と同じ答えが得られることを確認することには、時間を割くだけの価値があるでしょう。繰り返しますが、スプレッドシートを利用すると計算は非常に簡単です。上述の式を用いて SS の総和を算出し (SS の総和 = 4.85 となります)、次に、残差の SS (= 0.92) を求めます。JASP の出力と同じ答えになるはずです。

^a訳：「最も退屈な」

13.1.4 自由度はどのように求めるか？

自由度は、一元配置分散分析とほぼ同じ方法で計算されます。ある要因について、自由度は水準数から 1 を引いたものに等しくなります (i.e., 行方向の要因 A については $R - 1$, 列方向の要因 B については $C - 1$)。したがって、**薬**の要因については $df = 2$, **セラピー**の要因については $df = 1$ となります。後ほど、回帰モデルとしての分散分析モデルの解釈について説明する際に (Section 13.9 を参照), この数値の算出方法について詳しく説明します。当面の間は、自由度の単純な定義、すなわち、自由度は観測値の数から制約の数を引いたものに等しいという定義を利用できます。このことから、**薬**の要因については、3 つの個別のグループ平均値が観測されていますが、これらは 1 つの総平均によって制約されるため、自由度は 2 となります。残差の自由度の計算方法は、ロジックは似ていますが、全く同じではありません。今回の実験における観測値の総数は 18 です。制約は、総平均に関するものが 1 つ、**薬**の要因の追加のグループ平均に関するものが 2 つ、**セラピー**の要因の追加のグループ平均に関するものが 1 つあるため、この場合の自由度は 14 となります。式で表すと $N - 1 - (R - 1) - (C - 1)$ となり、 $N - R - C + 1$ のように簡略化されます。

13.1.5 多元配置分散分析と一元配置分散分析

ここまで、多元配置分散分析がどのように行われるかについて見てきました。ここまでの経過を、一元配置分散分析の結果と比較することには、時間を割くだけの価値があります。そうすることで、なぜ多元配置分散分析を行わなければならないかが明らかになります。Chapter 12 では、まず使用した薬による差異を検討するための一元配置分散分析を実行し、次いでセラピーの違いによる差異を検討するための一元配置分散分析を実行しました。Section 13.1.1 で述べたように、一元配置分散分析で検定される帰無仮説および対立仮説は、多元配置分散分析で検定される仮説と全く同じです。分散分析表をさらに注意深く見ると、それぞれの分析において、要因に関する平方和の値 (**薬**の要因については 3.45, **セラピー**の要因については 0.92) および自由度の値 (**薬**の要因については 2, **セラピー**の要因については 1) が同じであることが分かります。しかしながら、結果は同じではありません！最も注目すべき点は、Section 12.2 において**セラピー**の要因について一元配置分散分析を行った際には、有意な効果は得られなかったことです (p 値は .21 でした)。

一方で、2 要因分散分析における**セラピー**の主効果に着目すると、有意な効果 ($p = .019$) が得られています。これら 2 つの分析は、明らかに同じではありません。

なぜこのようなことが起こるのでしょうか？ その答えは、残差の計算方法を理解することで明らかになります。F 検定の背後にある考え方は、特定の要因に起因する変動と、それらで説明できない変動 (残差) の比較であったことを思い出してください。**セラピー**についての一要因分散分析を実行することは、すなわち、**薬**の効果を無視することになり、**薬**の要因に由来する変動を残差へと放り込

んでしまうことになります！ これによって、データは実際以上に煩雑になり、2 要因分散分析においては正しく有意な効果が見出されている**セラピー**の要因が、有意ではなくなってしまう。

何かの影響を評価しようとするとき、他の重要な何か (e.g., **薬**の要因) を無視してしまうと、分析が歪んでしまいます。もちろん、関心のある現象とはまったく関係のない変数は、無視してしまっても問題ありません。実験室の壁の色を記録しておいて、3 要因分散分析の結果、その要因が重要でないことが判明した場合には、その無関係な要因を除外した、より単純な 2 要因分散分析の結果を報告するだけで十分です。重要なのは、実際には差を生じさせる要因を、分析から除外しないことです！

13.1.6 この分析からどのような結果が得られるか？

ここまで説明してきた分散分析モデルは、我々がデータから発見する可能性のあるさまざまなパターンをカバーしています。例えば、2 要因分散分析デザインでは、4 通りの可能性があります：(a) 要因 A の効果のみがある場合、(b) 要因 B の効果のみがある場合、(c) 要因 A と要因 B の両方の効果がある場合、(d) どちらの要因の効果もない場合です。これら 4 つの可能性のそれぞれの例が、Figure 13.4 に示されています。

13.2

計画的比較の方法

分散分析における対比と事後検定の節に続く内容として、計画的比較の方法は取り上げるに値する重要な手法だと思います。前節および Chapter 12 における多重比較についての議論では、実行したい検定は、純粋に事後的なものであると仮定してきました。例えば、薬の効果についての例では、薬が気分に対してそれぞれ異なる効果を及ぼすと考えた (i.e., 薬の主効果を仮定した) かもしれませんが、どのように異なるかについての具体的な仮説はなく、ましてやどのペアワイズの比較を行う必要があるかについて具体的なアイデアはありませんでした。こういったケースでは、Tukey の HSD 検定のような方法を用いて全てのペアワイズ比較を行う必要があります。

しかし、どの比較に関心があるのかについて具体的な仮説を持っており、前もって指定した比較以外のものを見るつもりがないとしたら、状況はかなり違ってくるでしょう。このことが真実であり、他の比較はしない (たとえそのデータが、仮説検定を行わない部分において興味深い、有意な効果を示しているように見えても) という崇高な考えを正直かつ厳格に守っている場合、Tukey の HSD 検定のような方法を実行してもあまり意味がありません。なぜなら、気にしたこともなく、検討するつもりもなかった比較に関して補正を行ってしまうことになるからです。こういった状況では、多重比較の調整を行わなくとも、(限られた数の) 仮説検定を安全に実行することができます。これは**計画的比較の方法**と呼ばれ、臨床試験で用いられることがあります。これ以上の説明は、この入門書の範囲を超えていますが、少なくともこういった方法があることは知っておいた方が良いでしょう。




Figure13.4 交互作用のない 2×2 要因の分散分析における 4 つの出力。パネル (a) は要因 A の主効果があり、要因 B の主効果がない場合。パネル (b) は要因 A の主効果がなく、要因 B の主効果がある場合。パネル (c) は要因 A、要因 B のどちらの主効果もある場合。パネル (d) はどちらの要因の主効果もない場合。

多元配置分散分析 3: 非釣合型デザイン

多元配置分散分析は、知っておくととても便利なものです。何十年ものあいだ実験データを分析するための標準的な道具のひとつであり続けてきましたし、心理学の論文を2つか3つも読めば、どこかで分散分析に出くわさずにはいられないことがわかるでしょう。しかし、実際の学術論文で目にする分散分析と、ここまで説明してきた分散分析とのあいだには、ひとつ大きな違いがあります。現実には、完全に釣り合いのとれたデザインが手に入るという幸運はめったにありません。あれこれの理由で、あるセルの観測数が他のセルより多くなってしまうのが普通です。言い換えるなら、**非釣合型デザイン**になってしまうということです。

非釣合型デザインは釣合型デザインよりもずっと慎重に扱う必要がありますし、その背後にある統計理論もずっとごちゃごちゃしています。このごちゃごちゃのせいなのか、それとも時間が足りないせいなのか、私の経験では、心理学の学部の研究法の授業ではこの問題が完全に無視されるという困った傾向があります。統計の教科書の多くも、この点をさらっと流してしまいがちです。その結果として、現役の研究者の多くが、非釣合型の分散分析にはいくつかの異なる“タイプ”があって、それぞれがまったく異なる答えを出すということを実は知らない、ということになっているのだと思います。実際、心理学の文献を読んでいると、非釣合型の多元配置分散分析の結果を報告している人のほとんどが、その分析を再現できるだけの詳細を書いていないという事実、いささか驚かされます。ひそかに疑っているのですが、ほとんどの人は、自分の使っている統計ソフトが、データ分析についての実質的な判断を山ほど自分の代わりに下していることにすら気づいていないのではないのでしょうか。考えてみると、これは少し恐ろしいことです。というわけで、データ分析の主導権をおぼかなソフトウェアに明け渡したくないのであれば、このまま読み進めてください。

13.3.1 コーヒーのデータ

いつものように、実際のデータを使って考えるとわかりやすくなります。coffee.csv ファイルには、非釣合型の 3×2 の分散分析になる架空のデータが入っています。コーヒーを飲みすぎたときに人がぺらぺら喋りだす (babble) 傾向は、純粹にコーヒーそのものの効果なのか、それともコーヒーに入れるミルク (milk) や砂糖 (sugar) にも何らかの効果があるのか、を知りたいとしましょう。18 人にコーヒーを飲んでもらったとします。コーヒーの量つまりカフェインの量は一定にしておき、ミルクを入れるかどうかを変えました。ですから milk は "yes" と "no" の 2 水準からなる 2 値の要因です。砂糖の種類も変えました。コーヒーには本物の砂糖 ("real") が入っているかもしれませんし、偽物の砂糖 ("fake", つまり人工甘味料) かもしれませんし、まったく入っていない ("none") かもしれません。ですから sugar 変数は 3 水準の要因です。結果変数は連続変数で、その人がどのくらい

“ぺらぺら喋っている”かを心理学的に意味のある形で測ったもの，ということにしておきます。細かいことはここでの目的には関係ありません。図 13.5 のように，JASP のスプレッドシート画面でデータを見てみましょう。

Results

Descriptive Statistics

Descriptive Statistics		
	babble	
	no	yes
Valid	10	8
Missing	0	0
Mean	5.320	4.750
Std. Deviation	0.796	0.962
Minimum	3.900	3.500
Maximum	6.600	5.900

Descriptive Statistics

Descriptive Statistics			
	babble		
	fake	none	real
Valid	6	5	7
Missing	0	0	0
Mean	5.033	4.440	5.543
Std. Deviation	0.814	1.038	0.637
Minimum	3.900	3.500	4.600
Maximum	5.900	5.800	6.600

Figure13.5 coffee.csv データセットの記述統計。milk と sugar のそれぞれで分割したもの。

図 13.5 の平均値の表を見ると、グループ間に差がありそうだという強い印象を受けます。標準偏差を見るとなおさらです。グループごとに、標準偏差はかなりばらついています*3。一見するとこれは素直な多元配置分散分析に見えますが、各グループの観測数を見ると問題が出てきます。図 13.5 で、グループごとに N が違っているのを見てください。これは、各グループの人数が同じであるという、もともとの仮定のひとつを破っています。この状況にどう対処するかについては、まだきちんと議論していませんでした。

13.3.2 非釣合型デザインに“標準的な分散分析”は存在しない

非釣合型デザインを扱うと、標準的な分散分析と呼べるようなものは実はひとつも存在しない、という少し落ち着いた発見に行き着きます。実のところ、非釣合型デザインで分散分析を行うやり方には、根本的に異なる 3 つの方法があるのです*4。釣合型デザインであれば 3 つの方法はまったく同じ結果を出しますし、平方和も F 値もすべて、この章のはじめに示した式のとおりになります。しかしデザインが非釣合型の場合には、同じ答えにはなりません。さらに、どの状況でも 3 つが等しく適切だというわけでもありません。あなたの状況に、より適した方法とそうでない方法があります。ですから、分散分析にはどんなタイプがあり、それらがどう違うのかを理解しておくことが重要になります。

1 つめの分散分析は、慣例的に**タイプ I の平方和**と呼ばれています。残りの 2 つが何と呼ばれるかは、きっと想像がつくでしょう。名前の“平方和”の部分は統計ソフトの SAS が導入したもので、いまでは標準的な呼び方になっていますが、いくつかの点で少し誤解を招くものです。異なるタイプの平方和と呼ぶ理屈は、出力される分散分析表を見たときに、数値の違いの中心にあるのが SS の値だから、ということなのでしょう。自由度は変わりませんし、MS の値も相変わらず SS を自由度で割ったものとして定義されます。しかしこの用語のまずいところは、SS の値がなぜ互いに違ってくるのか、その理由を隠してしまう点です。そのため、3 種類の分散分析は、3 つの異なる仮説検定の戦略だと考えたほうがずっと役に立ちます。確かに戦略が違えば SS の値も違いますが、ここで重要なのは戦略のほうであって、SS の値そのものではありません。セクション 13.9 で述べたように、どんな F 検定も、2 つの線形モデルの比較として考えるのがいちばんよいのです。ですから

*3 標準偏差のこのばらつきを見ると、分散の等質性の仮定が破られているのではないかと思うかもしれません（そう思うべきです）。Levene の検定のオプションを使ってこれを確認するのは、読者の練習問題としておきましょう。

*4 正直に言うと、これは少し嘘です。分散分析には、本書で論じたもの以外にもさまざまな種類があります。たとえば、要因の水準が実験者や世界によって“固定”されている固定効果モデルと、水準がありうる水準のより大きな母集団からの無作為標本である変量効果モデルとの違いを、私は完全に無視してきました（本書は固定効果モデルしか扱いません）。本書が、あるいは他のどんな本であれ、統計について“知っておくべきことのすべて”を教えてくれるなどと思わないでください。1 冊の本が心理学や物理学や哲学について知っておくべきことのすべてを教えられないのと同じことです。人生はそんなことが成り立つには複雑すぎるのです。とはいえ、絶望する必要はありません。ほとんどの研究者は、本書の範囲を超えない程度の基本的な分散分析の知識でなんとかやっています。ただ、本書はとても長い物語のほんの始まりにすぎず、物語の全体ではないのだ、ということは心に留めておいてほしいのです。

分散分析表を見るときには、そこにあるそれぞれの F 検定が、比較されているモデルの組に対応していることを思い出すと役に立ちます。そうすると当然、どのモデルの組が比較されているのか、という疑問が出てきます。これこそが分散分析のタイプ I, II, III の根本的な違いです。つまり、検定のためのモデルの組の選び方が、それぞれ異なるのです。

13.3.3 タイプ I の平方和

タイプ I の方法は“逐次的”平方和と呼ばれることがあります。モデルに項を 1 つずつ追加していく手続きをとるからです。たとえばコーヒーのデータで考えてみましょう。交互作用項も含めた 3×2 の多元配置分散分析をフルに実行したいとします。フルモデルには、結果変数 `babble`、予測変数 `sugar` と `milk`、そして交互作用項 `sugar*milk` が含まれます。これは `babble ~ sugar + milk + sugar*milk` と書けます。タイプ I の戦略は、考えうるもっとも単純なモデルから出発して少しずつ項を追加していくことで、このモデルを逐次的に組み上げていきます。

このデータについて考えうるもっとも単純なモデルは、ミルクも砂糖もおしゃべりに何の効果も持たないと仮定するモデルでしょう。そのモデルに含まれる項は切片だけで、`babble ~ 1` と書かれます。これが最初の帰無仮説です。次に単純なモデルは、2 つの主効果のうち片方だけを含めたものになります。コーヒーのデータでは、ミルクを先に入れるか砂糖を先に入れるかを選べますので、ここには 2 つの選択肢があります。あとで見るように、この順序は実際に問題になるのですが、ここではとりあえず適当に選んで砂糖にしておきましょう。そうすると、モデルの系列の 2 番目は `babble ~ sugar` となり、これが最初の検定の対立仮説になります。これで最初の仮説検定ができました。

帰無モデル: `babble ~ 1`

対立モデル: `babble ~ sugar`

この比較が `sugar` の主効果の仮説検定になります。モデル構築の次のステップは、もう一方の主効果の項を追加することですので、系列の次のモデルは `babble ~ sugar + milk` になります。そして 2 番目の仮説検定は、次のモデルの組を比較することで作られます。

帰無モデル: `babble ~ sugar`

対立モデル: `babble ~ sugar + milk`

この比較が `milk` の主効果の仮説検定になります。ある意味でこのやり方はとてもエレガントです。最初の検定の対立仮説が、2 番目の検定の帰無仮説になっているのですから。タイプ I の方法が厳密に逐次的だというのは、この意味においてです。どの検定も、直前の検定の結果の上に直接組み上げられていきます。しかし別の意味では、これはまったくエレガントではありません。2 つの検定のあいだに強い非対称性があるからです。`sugar` の主効果の検定 (最初の検定) は `milk` を完全に無視していますが、`milk` の主効果の検定 (2 番目の検定) のほうは `sugar` を考慮に入れているのです。いずれにせよ、系列の 4 番目のモデルはフルモデル `babble ~ sugar + milk + sugar*milk` になり、対応す

る仮説検定は次のようになります。

帰無モデル: `babble ~ sugar + milk`

対立モデル: `babble ~ sugar + milk + sugar*milk`

JASP の分散分析で既定になっている仮説検定の方法はタイプ III の平方和ですので、タイプ I の平方和による分析を実行するには、JASP の 'ANOVA'-'モデル' のオプションにある '平方和' の選択ボックスで 'タイプ I' を選ぶ必要があります。そうすると図 13.6 のような分散分析表が得られます。

ANOVA

ANOVA - babble

Cases	Sum of Squares	df	Mean Square	F	p
sugar	3.558	2.000	1.779	6.749	0.011
milk	0.956	1.000	0.956	3.628	0.081
sugar * milk	5.944	2.000	2.972	11.277	0.002
Residual	3.162	12.000	0.264		

Note. Type I Sum of Squares

Figure13.6 JASP でタイプ I の平方和を使った分散分析の結果表

タイプ I の平方和を使うときの大きな問題は、変数を投入する順序に結果が本当に依存してしまうことです。しかし多くの場面で、研究者にはある順序を別の順序より優先すべき理由などありません。ミルクと砂糖の問題も、おそらくそうでしょう。ミルクを先に入れるべきでしょうか、砂糖を先に入れるべきでしょうか。データ分析の問題としても、コーヒーの淹れ方の問題としても、まったく同じくらい恣意的に感じられます。順序について確固たる意見を持っている人も実際にいるでしょうが、この問いに原理的な答えがあるとは考えにくいのです。それなのに、図 13.7 のように順序を変えると何が起こるかを見てください。

両方の主効果の項の p 値が、しかもかなり劇的に変わっています。とりわけ *milk* の効果が有意になってしまいました (ただし、これまで述べてきたように、ここから強い結論を引き出すのは避けるべきです)。このふたつの分散分析のどちらを報告すべきなのでしょう。すぐにはわかりません。

“1 番目”の主効果と“2 番目”の主効果を定義するのに使われている仮説検定を見てみれば、この 2 つが質的に異なるものであることは明らかです。最初の例で見たように、*sugar* の主効果の検定は *milk* を完全に無視しているのに対し、*milk* の主効果の検定は *sugar* を考慮に入れています。つまりタイプ I の検定戦略は、1 番目の主効果が 2 番目の主効果に対して一種の理論的な優位性を持っているかのように扱っているわけです。私の経験では、2 つの主効果を非対称に扱うことを正当化できるような理論的優位性というものは、あったとしてもきわめてまれです。

ANOVA ▼

ANOVA - babble

Cases	Sum of Squares	df	Mean Square	F	p
milk	1.444	1.000	1.444	5.479	0.037
sugar	3.070	2.000	1.535	5.824	0.017
milk * sugar	5.944	2.000	2.972	11.277	0.002
Residual	3.163	12.000	0.264		

Note. Type I Sum of Squares

Figure13.7 JASP でタイプ I の平方和を使った分散分析の結果表。ただし要因の投入順を変えたもの (milk が先)

.....

以上のことから、タイプ I の検定が興味深いものになることはめったにありません。ですからタイプ II の検定とタイプ III の検定の話に進むことにしましょう。

13.3.4 タイプ III の平方和

タイプ I の検定の話が終わったところですので、次はタイプ II の検定の話をするのが自然だと思われるかもしれませんが、しかし実際には、やや厄介なタイプ II の検定の前に、単純で JASP の既定にもなっているタイプ III の検定を論じるほうが、少し自然だと思います。タイプ III の検定の背後にある考え方は、きわめて単純です。どの項を評価しようとしている場合でも、対立仮説はユーザが指定した分散分析のフルモデルとし、帰無モデルはそこから検定したい項だけを取り除いたもの、として F 検定を実行するのです。たとえばコーヒーの例では、フルモデルが `babble ~ sugar + milk + sugar*milk` でしたので、`sugar` の主効果の検定は次の 2 つのモデルの比較に対応します。

帰無モデル: `babble ~ milk + sugar*milk`

対立モデル: `babble ~ sugar + milk + sugar*milk`

同じように、`milk` の主効果は、フルモデルを `milk` の項を取り除いた帰無モデルと比較することで評価されます。

帰無モデル: `babble ~ sugar + sugar*milk`

対立モデル: `babble ~ sugar + milk + sugar*milk`

最後に、交互作用項 `sugar*milk` もまったく同じやり方で評価されます。やはり、フルモデルを

$sugar* milk$ の交互作用項を取り除いた帰無モデルと比較して検定します。

帰無モデル: $babble \sim sugar + milk$

対立モデル: $babble \sim sugar + milk + sugar* milk$

この基本的な考え方は、より高次の分散分析にも一般化されます。たとえば A , B , C という 3 つの要因からなる分散分析を実行しようとしていて、3 次の交互作用 $A*B*C$ も含めて、ありうるすべての主効果とすべての交互作用を考えたいとしましょう。この場合のタイプ III の検定がどうなるかを、下の表に示します。

検定される項	帰無モデル $outcome \sim \dots$	対立モデル $outcome \sim \dots$
A	$B + C + A*B + A*C + B*C + A*B*C$	$A + B + C + A*B + A*C + B*C + A*B*C$
B	$A + C + A*B + A*C + B*C + A*B*C$	$A + B + C + A*B + A*C + B*C + A*B*C$
C	$A + B + A*B + A*C + B*C + A*B*C$	$A + B + C + A*B + A*C + B*C + A*B*C$
$A*B$	$A + B + C + A*C + B*C + A*B*C$	$A + B + C + A*B + A*C + B*C + A*B*C$
$A*C$	$A + B + C + A*B + B*C + A*B*C$	$A + B + C + A*B + A*C + B*C + A*B*C$
$B*C$	$A + B + C + A*B + A*C + A*B*C$	$A + B + C + A*B + A*C + B*C + A*B*C$
$A*B*C$	$A + B + C + A*B + A*C + B*C$	$A + B + C + A*B + A*C + B*C + A*B*C$

表の見た目はごちゃごちゃしていますが、中身はかなり単純です。どの場合も、対立仮説は 3 つの主効果の項 (たとえば A)、3 つの 2 次の交互作用 (たとえば $A*B$)、そして 1 つの 3 次の交互作用 (つまり $A*B*C$) を含むフルモデルに対応しています。帰無モデルは常にこの 7 つの項のうち 6 つを含み、欠けている 1 つが、有意性を検定しようとしている項なのです。

一見すると、タイプ III の検定はよい考えのように思えます。まず、タイプ I の検定で問題を引き起こしていた非対称性が取り除かれています。そしてすべての項を同じように扱っていますので、仮説検定の結果が項を指定する順序に依存することはありません。これは間違いなくよいことです。しかし検定結果を解釈するとき、とくに主効果の項について、大きな問題が生じます。コーヒーのデータで考えてみましょう。タイプ III の検定で $milk$ の主効果が有意でなかったとします。これが言っているのは、 $babble \sim sugar + sugar* milk$ のほうがフルモデルよりもデータをよく表すモデルだ、ということです。しかしそれはいったい何を意味しているのでしょうか。もし交互作用項 $sugar* milk$ も有意でなかったなら、重要なのは $sugar$ だけだとデータが言っている、と結論したくなるでしょう。しかし、交互作用項は有意なのに $milk$ の主効果が有意でない、という場合を考えてみてください。この場合、“砂糖の効果”と“ミルクと砂糖の交互作用”は本当にあるけれども“ミルクの効果”はない、と考えるべきなのでしょうか。そんなのはおかしい話です。正しい答えは、交互作用が有意であれば主効果について語ることは無意味だ^{*5}、ということでなければならないはずです。一般に、これはほとんどの統計学者が助言していることのようにですし、私も正しい助言だと思います。しか

^{*5}少なくとも、興味深いものになることはめったにありません。

し、有意な交互作用があるときに有意でない主効果について語るのが本当に無意味なのだとしたら、タイプ III の検定が、交互作用は含むのにそれを構成する主効果の 1 つを欠いたモデルを帰無仮説として認めてよい理由は、まったく明らかではありません。このように特徴づけてみると、帰無仮説は実のところほとんど意味をなしていないのです。

のちほど、タイプ III の検定が文脈によっては見直されうることを見ますが、まずはタイプ III の平方和による分散分析の結果表を見てみましょう。図 13.8 です。

ANOVA

ANOVA - babble

Cases	Sum of Squares	df	Mean Square	F	p
milk	1.004	1.000	1.004	3.810	0.075
sugar	2.132	2.000	1.066	4.045	0.045
milk * sugar	5.944	2.000	2.972	11.277	0.002
Residual	3.163	12.000	0.264		

Note. Type III Sum of Squares

Figure13.8 JASP でタイプ III の平方和を使った分散分析の結果表

ただし気をつけてください。タイプ III の検定戦略のひねくれた性質のひとつは、結果が要因のコード化に使う対比に依存するのが普通だ、ということです (対比にどんな種類があったか忘れてしまった場合はセクション 13.10 を見てください)*6。

さて、タイプ III の分析から出てくる p 値が対比の選び方にそれほど敏感なのだとしたら、タイプ III の検定は本質的に恣意的で信用できない、ということになるのでしょうか。ある程度まではそのとおりですし、タイプ II の検定の議論に移れば、タイプ II の分析がこの恣意性を完全に回避していることがわかります。しかし、そう結論するのは強すぎると思います。まず、対比の選び方によっては常に同じ答えが出る、ということを認識しておくのが重要です (ああ、JASP で起きているのはこれなのですね)。とくに重要なのは、対比行列の列の合計がすべてゼロになるように制約されていれば、タイプ III の分析は常に同じ答えを出す、という事実です。

*6ただし JASP では、タイプ III の平方和による分散分析の結果は、どの対比を選んでも同じになります。ですから JASP は明らかに何か違うことをしているわけです。

13.3.5 タイプIIの平方和

さて、これでタイプIとタイプIIIの検定を見てきました。どちらもかなり素直なものです。タイプIの検定は項を1つつずつ追加していくことで行われ、タイプIIIの検定はフルモデルから各項を取り除いたときに何が起こるかを見ることで行われます。しかし、どちらにも限界があります。タイプIの検定は項を投入する順序に依存しますし、タイプIIIの検定は対比をどうコード化するかに依存します。タイプIIの検定は説明が少し難しいのですが、このふたつの問題をどちらも回避しますので、結果として解釈が少し容易になります。

タイプIIの検定は、大枠ではタイプIIIの検定に似ています。“フル”モデルから出発し、特定の項をそのモデルから削除することでその項を検定します。ただしタイプIIの検定は**周辺性の原理**にもとづいています。これは、ある低次の項に依存する高次の項がモデルにあるなら、その低次の項をモデルから外してはいけなく、というものです。ですからたとえば、モデルに2次の交互作用 $A*B$ (2次の項) が含まれているなら、主効果 A と B (1次の項) も含まれているべきなのです。同じように、3次の交互作用項 $A*B*C$ が含まれているなら、主効果 A , B , C に加えて、より単純な交互作用 $A*B$, $A*C$, $B*C$ もモデルに含まれていなければなりません。タイプIIIの検定は、この周辺性の原理を日常的に破っています。たとえば、ありうるすべての交互作用項を含む3要因の分散分析における、 A の主効果の検定を考えてみましょう。タイプIIIの検定にしたがえば、帰無モデルと対立モデルは次のようになります。

帰無モデル: $outcome \sim B + C + A*B + A*C + B*C + A*B*C$

対立モデル: $outcome \sim A + B + C + A*B + A*C + B*C + A*B*C$

帰無仮説が A を外しているのに、 $A*B$, $A*C$, $A*B*C$ はモデルの一部として含んでいることに注意してください。タイプIIの検定の立場からすれば、これは帰無仮説の選び方としてよくありません。そうではなく、 A が $outcome$ に関係していないという帰無仮説を検定したいのであれば、交互作用としてであっても A をいっさい含まないモデルのうち、もっとも複雑なものを帰無仮説として指定すべきなのです。対立仮説は、この帰無モデルに A の主効果の項を加えたものになります。これは、ほとんどの人が直感的に“ A の主効果”として思い浮かべるものにずっと近く、 A の主効果についてのタイプIIの検定は次のようになります^{*7}

帰無モデル: $outcome \sim B + C + B*C$

対立モデル: $outcome \sim A + B + C + B*C$

ともあれ、タイプIIの検定がどう展開するか感覚をつかんでいただくために、3要因の多元配置分散分析で適用される検定の一覧を挙げておきます。

^{*7}もちろんこれは、ユーザが指定したモデルに依存します。もとの分散分析のモデルに $B*C$ の交互作用項が含まれていなければ、当然それは帰無モデルにも対立モデルにも現れません。しかしこれはタイプI, II, IIIのいずれについても言えることです。どのタイプも、あなたが含めなかった項を勝手に入れることはありませんが、あなたが含めた項についての検定をどう組み立てるかについては、異なる選択をします。

検定される項	帰無モデル <i>outcome ~ ...</i>	対立モデル <i>outcome ~ ...</i>
<i>A</i>	<i>B + C + B*C</i>	<i>A + B + C + B*C</i>
<i>B</i>	<i>A + C + A*C</i>	<i>A + B + C + A*C</i>
<i>C</i>	<i>A + B + A*B</i>	<i>A + B + C + A*B</i>
<i>A*B</i>	<i>A + B + C + A*C + B*C</i>	<i>A + B + C + A*B + A*C + B*C</i>
<i>A*C</i>	<i>A + B + C + A*B + B*C</i>	<i>A + B + C + A*B + A*C + B*C</i>
<i>B*C</i>	<i>A + B + C + A*B + A*C</i>	<i>A + B + C + A*B + A*C + B*C</i>
<i>A*B*C</i>	<i>A + B + C + A*B + A*C + B*C</i>	<i>A + B + C + A*B + A*C + B*C + A*B*C</i>

コーヒーのデータで使ってきた 2 要因の分散分析の文脈では、仮説検定はもっと単純になります。*sugar* の主効果は、次の 2 つのモデルを比較する F 検定に対応します。

帰無モデル: *babble ~ milk*

対立モデル: *babble ~ sugar + milk*

milk の主効果の検定は次のとおりです。

帰無モデル: *babble ~ sugar*

対立モデル: *babble ~ sugar + milk*

最後に、交互作用 *sugar*milk* の検定は次のようになります。

帰無モデル: *babble ~ sugar + milk*

対立モデル: *babble ~ sugar + milk + sugar*milk*

検定の実行は、これもまた簡単です。JASP の 'ANOVA'-'モデル' のオプションにある '平方和' の選択ボックスで 'タイプ 2' を選ぶだけです。そうすると図 13.9 のような分散分析表が得られます。

ANOVA

ANOVA - babble

Cases	Sum of Squares	df	Mean Square	F	p
milk	0.956	1.000	0.956	3.628	0.081
sugar	3.070	2.000	1.535	5.824	0.017
milk * sugar	5.944	2.000	2.972	11.277	0.002
Residual	3.163	12.000	0.264		

Note. Type II Sum of Squares

Figure13.9 JASP でタイプ II の平方和を使った分散分析の結果表

タイプIIの検定には、タイプIやタイプIIIの検定に対する明らかな利点はいくつかあります。タイプIと違って要因を指定する順序に依存しませんし、タイプIIIと違って要因の指定に使う対比にも依存しません。最後の点については意見が分かれるかもしれませんが、データで何をしようとしているかにもよりますが、タイプIIが指定する仮説検定のほうが、あなたが本当に関心を持っていることに対応している可能性が高いと私は思います。その結果として、タイプIIの検定の結果は、タイプIやタイプIIIの結果よりも解釈しやすいことが多いと感じています。ですから私のとりあえずの助言は次のとおりです。研究上の問いに直接対応するような明らかなモデル比較が思いつかないけれども、それでも非釣り合い型デザインで分散分析を実行したいのであれば、タイプIIの検定はおそらくタイプIやタイプIIIよりよい選択でしょう^{*8}。

13.3.6 効果量 (および加法的でない平方和)

JASP では、オプションを選べば効果量 η^2 と偏 η^2 も出力されます。しかし非釣り合い型デザインの場合には、話が少しややこしくなります。

分散分析のごく初期の議論を思い出していただければ、平方和の計算の背後にある重要な考え方のひとつは、モデル中の効果に対応する SS の項をすべて足し合わせ、それに残差の SS を加えると、全体の平方和になるはずだ、というものでした。そのうえで、 η^2 の考え方全体は、SS の項のひとつを全体の SS の値で割っているのだから、 η^2 の値は特定の項によって説明される分散の割合として解釈できる、というものでした。しかし非釣り合い型デザインでは、分散の一部が“行方不明”になってしまいますので、そう単純にはいきません。

最初は少し奇妙に思えますが、理由はこうです。非釣り合い型デザインでは要因どうしが相関してしまい、要因 A の効果と要因 B の効果を区別するのが難しくなります。極端な場合として、各グループの参加者数が次のようになった 2×2 のデザインを実行したとしましょう。

	砂糖あり	砂糖なし
ミルクあり	100	0
ミルクなし	0	100

これは見事なまでの非釣り合い型デザインです。ミルクと砂糖の両方を入れた人が 100 人、ミルクも砂糖も入れない人が 100 人、それだけです。ミルクありで砂糖なしの人は 0 人、砂糖ありでミルクな

^{*8}おもしろいことに、R の既定はタイプ I で、SPSS、JASP、jamovi の既定はタイプ III です。私にはどちらもさほど魅力的には思えません。関連して気が滅入るのは、心理学の文献で、どのタイプの検定を実行したかを報告する人がほとんどいないことです。変数の順序 (タイプ I の場合) や使った対比 (タイプ III の場合) ならなおさらです。どのソフトウェアを使ったかも報告しないことがよくあります。人が普通に報告している内容を理解する唯一の方法は、補助的な手がかりからどのソフトウェアを使っていたかを推測し、既定の設定を変えていないと仮定することなのです。どうかこんなことはしないでください。この問題を知ったからには、使ったソフトウェアを必ず明記してください。非釣り合い型データの分散分析の結果を報告するなら、どのタイプの検定を実行したかを明記し、タイプ I なら順序の情報を、タイプ III なら対比を明記してください。あるいはもっとよいのは、本当に関心のあることに対応する仮説検定を行って、それを報告することです。

しの人も 0 人です。さてデータを集めてみたら、“ミルクと砂糖”のグループと“ミルクも砂糖もなし”のグループのあいだに大きな(そして統計的に有意な)差があったとします。これは砂糖の主効果でしょうか。ミルクの主効果でしょうか。それとも交互作用でしょうか。判断することは不可能です。砂糖の有無とミルクの有無が完全に対応してしまっているからです。今度は、デザインがもう少し釣り合っていたとしましょう。

	砂糖あり	砂糖なし
ミルクあり	100	5
ミルクなし	5	100

今回は、片方だけを入れた人が少しはいますので、ミルクの効果と砂糖の効果を区別することが技術的には可能です。とはいえ、それでもかなり難しいでしょう。砂糖とミルクの対応関係は依然としてきわめて強いですし、2つのグループの観測数があまりにも少ないからです。ここでもまた、予測変数(ミルクと砂糖)が結果(おしゃべり)と関係していることはわかるけれども、その関係の性質が、どちらかの予測変数の主効果なのか交互作用なのかはわからない、という状況になりがちです。

この不確かさこそが、分散が行方不明になる理由です。“行方不明”の分散は、明らかに予測変数に帰属できるけれども、モデル中のどの効果のせいなのかがわからない、という結果変数の変動に対応しています。タイプⅠの平方和を計算する場合、分散が行方不明になることはありません。タイプⅠの平方和は逐次的な性質を持っていますので、分散分析はこの分散を、先に投入された効果のほうへ自動的に割り当ててしまうのです。しかしタイプⅡとタイプⅢの検定は、より保守的です。特定の効果にはっきり帰属できない分散は、どの効果にも割り当てられず、行方不明になってしまうのです。

13.4

要約

- 釣合型デザインの多元配置分散分析。交互作用なしの場合 (Section 13.1) と交互作用を含む場合 (Section 13.5)
- 多元配置分散分析における効果量、推定周辺平均、信頼区間 (Section 13.6)
- 分散分析における仮定のチェック (Section 13.7)
- 共分散分析 (ANCOVA) (Section 13.8)
- 分散分析の背後にある線形モデルの理解。さまざまな対比も含めて (Section 13.9 と 13.10)
- Tukey の HSD による事後検定 (Section 13.11) と、計画的比較についての簡単な解説 (Section 13.2)
- 非釣合型デザインの多元配置分散分析 (Section 13.3)

多元配置分散分析 2: 釣合型デザイン, 交互作用あり

Figure 13.4 に示されている 4 つのパターンは、いずれも現実的なものです。これらのパターンを生じさせるようなデータセットも非常にたくさん存在します。しかしながら、生じうる結果のパターンはこれで全てではなく、また、ここまで説明してきた分散分析モデルは、あらゆるグループ平均のパターンを網羅しているわけではありません。何故でしょうか？ それは、これまでの説明では、薬が気分に影響を与える、セラピーが気分に影響を与える、ということについては議論できますが、両者の交互作用を扱うことができないからです。要因 A と要因 B の交互作用は、要因 A の効果が要因 B の水準に応じて異なる場合には、いつでも生じうると言われています。2×2 要因の分散分析における、いくつかの交互作用効果の例を Figure 13.10 に示します。より具体的な例を挙げると、アンザイフリーとジョイゼパムの作用機序が、全く異なる生理学的メカニズムに依存していると仮定します。ここから、ジョイゼパムがセラピーの有無に関わらず気分に対してほぼ同じ影響をもたらす一方で、アンザイフリーは CBT と組み合わせて投与された場合にはるかに効果的であると考えます。前の章で説明した分散分析では、このアイデアを検討できません。交互作用が生じているかどうかを確かめるには、グループ平均を図示することが有効です。JASP では、分散分析の「Descriptives Plots」オプションを用いて行うことができます – 単に、薬を「Horizontal axis」のボックスに、セラピーを「Separate Lines」のボックスに移動するだけです。Figure 13.11 と同様の図になるはずです。特に注目すべき点は、2 本の線が並行ではないということです。ジョイゼパムが投与された場合 (中央) の CBT の効果 (黒丸の線と白丸の線の差) はゼロに近く、プラセボが用いられた場合の CBT の効果 (右側) よりもさらに小さいようです。しかしながら、アンザイフリーが投与されると、CBT の効果はプラセボよりも大きくなります (左側)。この効果は真実でしょうか、それともランダムな変動による単なる偶然なののでしょうか？ 前章までの分散分析では、この問いに答えることができません。なぜなら、交互作用が存在するというアイデアが含まれていないからです！ 本章では、この問題点を修正していきます。

13.5.1 相互作用とは正確にはどのようなものか？

この節では、交互作用効果という重要なアイデアを紹介します。ここまで見てきた分散分析モデルでは、モデルに含まれる 2 つの要因 (i.e., 薬およびセラピー) にしか着目していませんでした。交互作用を投入することで、モデルに新たな要素が追加されることになります：薬 と セラピー の組み合わせです。直観的には、交互作用効果の背後にある考え方は非常に単純です。交互作用は単に、要因 A の影響が、要因 B の水準に応じて変化することを意味しています。しかし、このことは我々のデー

タに対してどのような意味を持っているのでしょうか？ Figure 13.10 に示したいいくつかの図は、それぞれ全く見た目が異なりますが、すべて交互作用効果として扱われます。したがって、この定性的なアイデアを、統計学者が扱うような数学的な記述に変換することは非常に困難です。

結論として、交互作用効果の概念を、対立仮説と帰無仮説の観点から定式化することは困難であり、ましてやこの本の読者の多くは、それほど興味がないと思います。それでも、基本的なアイデアを示しておこうと思います。

まずは、主効果についてももう少し明示的にする必要があります。要因 A(今回の分析例では薬)の主効果について考えます。そもそも主効果は、2つの周辺平均 $\mu_{r.}$ が全て等しいという帰無仮説の観点に基づいて定式化されていました。これらの周辺平均の全てが等しいとすると、それらは総平均 $\mu_{..}$ と等しくなければなりませんね？したがって、ここでは水準 r における要因 A の効果を、周辺平均 $\mu_{r.}$ と総平均 $\mu_{..}$ との差に等しいものとして定義します。

この効果を α_r で表し、以下のように表記します

$$\alpha_r = \mu_{r.} - \mu_{..}$$

ここで、周辺平均 $\mu_{r.}$ の平均値が総平均 $\mu_{..}$ になることと同様の理由で、定義上、すべての α_r の値は合計がゼロになる必要があります。同じように、水準 i における要因 B の効果を、列方向の周辺平均 $\mu_{.c}$ と総平均 $\mu_{..}$ の差として定義することができます。

$$\beta_c = \mu_{.c} - \mu_{..}$$

繰り返しになりますが、これらの β_c の合計はゼロにならなければなりません。統計学者が α_r や β_c の値を用いて主効果について説明することを好む理由は、交互作用効果がないということの意味を正確に伝えることができるからです。交互作用がまったくない場合、 α_r および β_c の値を用いて、グループ平均 μ_{rc} を完全に記述することができます。具体的には以下ようになります

$$\mu_{rc} = \mu_{..} + \alpha_r + \beta_c$$

これは、グループ平均に関して特別なことは何もない、すなわち、すべての周辺平均が明らかになっても、完全な予測ができないということを意味します。これはまさに、帰無仮説を表しています。対立仮説は、表中の少なくとも一つのグループ rc において

$$\mu_{rc} \neq \mu_{..} + \alpha_r + \beta_c$$

が成り立つこと、と表現できます。統計学者はしばしば、上記の式をやや異なる形式で表現します。彼らは通常、グループ rc に関連づけられた交互作用をいくつかの番号によって定義し、厄介

なことに $(\alpha\beta)_{rc}$ と表現し、そして対立仮説を次のように表します

$$\mu_{rc} = \mu_{..} + \alpha_r + \beta_c + (\alpha\beta)_{rc}$$

ここで、少なくとも 1 つのグループの $(\alpha\beta)_{rc}$ は非ゼロです。この表記法はやや見苦しいですが、次の節で説明するように、二乗和の計算方法を説明する際には便利です。

13.5.2 交互作用の二乗和の計算

交互作用項 $SS_{A:B}$ の二乗和はどのように計算すれば良いのでしょうか？ まず、先ほどの節において、実際のグループ平均が周辺平均から予測された値とどの程度異なるかという観点から、交互作用効果をどのように定義したかについて確認すると良いと思います。もちろん、これらの式はすべて、サンプル統計量ではなく母集団のパラメータに関するものであるため、実際にそれらがどのようなものであるかは分かりません。しかしながら、母平均の代わりにサンプル平均を用いることで、それらを推定することができます。要因 A に関して、水準 r における主効果を推定するための良い方法は、サンプルの周辺平均 $\bar{Y}_{rc}$ とサンプルの総平均 $\bar{Y}_{..}$ の差に着目することです。そこで、これを効果の推定値として用います

$$\hat{\alpha}_r = \bar{Y}_{r.} - \bar{Y}_{..}$$

同様に、水準 c における要因 B の主効果の推定値は、以下のように定義できます

$$\hat{\beta}_c = \bar{Y}_{.c} - \bar{Y}_{..}$$

ここで、2 つの主効果の SS の値について説明した式を改めて見てみると、それらの効果に関する項は二乗され足し合わされているということに気づくでしょう！ それでは、交互作用項ではどうなっているのでしょうか？ その答えは、以下のように、対立仮説のもとでグループ平均 μ_{rc} に関する式を再変形することで明らかになります

$$\begin{aligned}(\alpha\beta)_{rc} &= \mu_{rc} - \mu_{..} - \alpha_r - \beta_c \\&= \mu_{rc} - \mu_{..} - (\mu_{r.} - \mu_{..}) - (\mu_{.c} - \mu_{..}) \\&= \mu_{rc} - \mu_{r.} - \mu_{.c} + \mu_{..}\end{aligned}$$

そして、母平均の代わりにサンプル統計量を代入すると、グループ rc における交互作用効果の推定は以下ようになります

$$(\hat{\alpha}\hat{\beta})_{rc} = \bar{Y}_{rc} - \bar{Y}_{r.} - \bar{Y}_{.c} + \bar{Y}_{..}$$

ここで、これらの要因 A における R 水準、および要因 B における C 水準のすべての推定値を足

し合わせることで、全体的な相互作用に関する二乗和の式が得られます

$$SS_{A:B} = N \sum_{r=1}^R \sum_{c=1}^C (\bar{Y}_{rc} - \bar{Y}_{r.} - \bar{Y}_{.c} + \bar{Y}_{..})^2$$

各グループについて N 個の観測値があるため、 N が掛けられています。SS の値には、グループ間の変動ではなく、交互作用によって説明される観測値間の変動が反映されていると期待されます。

$SS_{A:B}$ の計算式が準備できたので、交互作用項がモデルの一部であることを認識する必要があります（当然のことですが）。モデルにおける全体の平方和である SS_M は、関連する 3 つの SS 値の合計 $SS_A + SS_B + SS_{A:B}$ に等しくなります。残差平方和 $SS_T - SS_M$ は、残りの変動、すなわち $SS_T - SS_M$ として定義されますが、交互作用項があることから、以下のようになります

$$SS_R = SS_T - (SS_A + SS_B + SS_{A:B})$$

結果として、残差平方和 SS_R は、交互作用を含まない分散分析よりも小さくなります。

13.5.3 交互作用における自由度

交互作用における自由度の計算は、主効果における計算よりも少しだけ複雑です。まずは、分散分析モデルの全体について考えてみましょう。モデルに交互作用効果が含まれる場合、すべてのグループに、独自の平均 μ_{rc} を持つことが許されます。 $R \times C$ 要因の分散分析の場合には、これはモデル中に $R \times C$ 通りの統計量と、総平均はすべてのグループ平均の平均値であるという、たった 1 つの制約があることを意味します。そのため、モデル全体としては $(R \times C) - 1$ の自由度が必要です。しかし、要因 A の主効果には $R - 1$ の自由度が、要因 B の主効果には $C - 1$ の自由度があります。このことは、交互作用に関する自由度が、

$$\begin{aligned} df_{A:B} &= (R \times C - 1) - (R - 1) - (C - 1) \\ &= RC - R - C + 1 \\ &= (R - 1)(C - 1) \end{aligned}$$

という式で表されるように、行の要因と列の要因の自由度の積にすぎないということを示します。残差の自由度についてはどうでしょうか？ 交互作用項によってある程度の自由度が吸収されるため、残りの自由度は少なくなります。具体的には、交互作用を含むモデルが全部で $(R \times C) - 1$ の自由度を持ち、1 つの総平均を満たすよう制約されているデータセット内に N 個の観測値があると

き、残差の自由度は $N - (R \times C) - 1 + 1$ 、あるいは単に $N - (R \times C)$ となる。

13.5.4 JASP による分散分析の実行

JASP の分散分析モデルに交互作用項を加えることは難しくありません。というよりも、交互作用項は分散分析のデフォルトのオプションであるため、何もする必要はありません。すなわち、例えば **薬とセラピー** という 2 要因の分散分析を実行すると、これらの交互作用項- `drug*therapy` -が自動的にモデルに追加されるということです。^{*9} 交互作用項を含めた分散分析を実行すると、13.12 のような結果が得られます。

結局、今回の分析では、有意な薬の主効果 ($F_{2,12} = 31.7, p < .001$) とセラピーの主効果 ($F_{1,12} = 8.6, p = .013$) が見出されますが、交互作用は有意ではありません ($F_{2,12} = 2.5, p = 0.125$)。

13.5.5 結果の解釈

多元配置分散分析の結果の解釈の際には、いくつかの非常に重要なポイントがあります。まずは、仮に (例えば) 薬の有意な主効果が得られたとしても、どの薬が他と異なるかについては何も分からないという、一元配置分散分析と同様の問題です。これを明らかにするためには、追加の分析を行う必要があります。Sections 13.10 および 13.11 において、この追加の分析のいくつかを紹介します。交互作用効果についても、同様のことがいえます。有意な交互作用がみられたとしても、どのようなパターンの交互作用が存在しているかについては何も分かりません。ここでも、追加の分析を行う必要があります。

次に、有意な交互作用効果が得られているが、主効果が有意ではないという場合に、解釈が非常にややこしくなるという問題があります。このような結果はときどき生じます。例えば、Figure 13.10 で示されている交差したパターンの交互作用が、実際の結果でも生じる可能性があります。このケースでは、主効果はいずれも有意ではありませんが、交互作用効果が存在します。これは解釈が難しい状況であり、多くの分析者を混乱させます。こうした状況に対して、統計学者が行いがちな一般的なアドバイスは、交互作用が存在する場合、主効果にはあまり注目すべきでないということです。彼らがこのように述べる理由は、主効果の検定は数学的観点から全く正しいものですが、有意な交互作用がみられる場合には、主効果が重要な仮説を検定していることは稀だからです。Section 13.1.1 を思い出してみると、主効果の帰無仮説は周辺平均が相互に等しいというものであり、周辺平均はいくつかの異なるグループ間の値を平均することで計算されていました。交互作用が有意であるということは、周辺平均を構成するグループが同種ではないということが自明になるため、これらの周辺平均について気にする必要は無くなります。

つまり、こういうことです。改めて、臨床的な例を用いて説明しましょう。2 × 2 要因デザインで、

^{*9}先ほどの節で説明した、主効果に関する分析を実際に JASP で再現してみた読者は、すでにこの出力を目にしているかもしれません。説明を単純にするため、先述のモデルからは交互作用項を除外しています

2種類の恐怖症の治療法 (e.g., 系統的脱感作法と暴露療法), および2種類の不安軽減薬 (e.g., アンザイフリーとジョイゼパム) の比較を行うと考えてみましょう。そして、治療として脱感作法を行った場合、アンザイフリーには効果がなく、治療として暴露療法を行った場合、ジョイゼパムには効果がないという結果が見出されたと仮定します。いずれの薬も、もう一方の治療においては効果的であるとして。これは古典的な交差パターンの交互作用であり、分散分析を実行すると、薬の主効果はありませんが、有意な交互作用が見出されます。さて、主効果がないということは、一体何を意味するのでしょうか？ もちろん、2つの異なる治療法を平均すると、アンザイフリーとジョイゼパムの平均的な効果は同じであるということです。しかし、なぜ誰もがこのことを気にかけるのでしょうか？ 恐怖症の治療において、暴露療法と脱感作法を「平均的に」使用することなどできません。これはあまり意味のない考え方です。暴露療法か脱感作法のどちらかを選ぶことになります。一方の治療法では一方の薬が効果的であり、もう一方の治療法ではもう一方の薬が効果的なのです。ここで重要なのは交互作用であり、主効果はある意味で無関係です。

このような事態はしばしば生じます。主効果は周辺平均の検定であり、交互作用が存在する場合には、周辺平均には注目する必要がなくなることがよくあります。なぜなら、周辺平均が、本来平均すべきではないものを平均化してしまっていることが、交互作用によって示されるからです！ もちろん、交互作用が存在するからといって、主効果が無意味であるとは限りません。多くの場合、大きな主効果と、非常に小さな交互作用が得られます。このとき、「薬 A は一般に薬 B よりも効果的である」(大きな薬の主効果があるため) と主張することができますが、次のような表現を加えて主張を微修正する必要があります。「A と B の薬の効果の差は、治療法によって異なった」。いずれにせよ、ここでの主要なポイントは、有意な交互作用が得られたときには、常に一度立ち止まって、その分析の文脈において、主効果が実際には何を意味しているのかを考えることです。主効果が重要であると自動的に思い込んではいけません。

13.6

効果量

多元配置分散分析の効果量の計算は、一元配置分散分析で用いられるものとかかなり似ています (Section 12.6 を参照)。具体的には、特定の項に対する全体的な効果がどれほど大きいかを測る簡単な方法として、 η^2 を利用できます。前回同様、 η^2 はその項に関連づけられた平方和を、総平方和で割ることで定義されます。例えば、要因 A の主効果の効果量を求めるには、以下の式が用いられます：

$$\eta_A^2 = \frac{SS_A}{SS_T}$$

この値が、回帰分析における R^2 とほぼ同様に解釈できるという点も、前回と同じです。^{*10} この値は、要因 A の主効果によって説明することができる結果変数の分散の割合を表しています。したがって、この値は 0(影響なし) から 1(結果変数の変動の全て) の範囲を取ります。さらに、モデル内の全ての項から得られる全ての η^2 値の合計は、分散分析モデルの合計の R^2 と等しくなります。例えば、分散分析モデルが完全に適合している場合 (i.e., グループ内の変動が全くない場合!), η^2 値は 1 になります。もちろん、このような事態が実生活で生じることは滅多にありません。

ただし、多元配置分散分析を行う際には、偏 η^2 という 2 つ目の効果量の指標が好んで報告されます。偏 η^2 ($\rho\eta^2$ もしくは η_p^2 と表記される場合もあります) の背後にある考え方は、特定の項についての効果量 (例えば、要因 A の主効果) を求める場合に、モデル内の他の効果 (e.g., 要因 B の主効果) を意図的に無視するというものです。すなわち、これらの他の全ての項の効果がゼロであると仮定して、 η^2 値がどうなるかを計算するということです。これは実際には非常に計算が簡単です。分母から他の項に関する平方和を削除すればよいのです。つまり、要因 A の主効果についての偏 η^2 を求める際には、分母は要因 A の SS 値と残差の合計になります。

$$\text{partial } \eta_A^2 = \frac{SS_A}{SS_A + SS_R}$$

この結果は常に η^2 よりも大きな数値となります。私は皮肉屋なので、これが偏 η^2 の人気の理由だと考えています。偏 η^2 値もまた 0 から 1 の範囲となり、0 は効果がないことを表します。ただし、偏 η^2 値の大きさについての解釈は少々ややこしくなります。特に、各項の偏 η^2 値を直接比較することができない点には注意が必要です! たとえば、グループ内の変動性が全くないとすると、 $SS_R = 0$ となります。このことが意味するのは、すべての項の偏 η^2 値が 1 になるということです。しかしながら、これはモデル内のすべての項が等しく重要である、あるいは、それらの大きさが等しいということではありません。これは、モデル内のすべての項のが、残差の変動と比べて大きな効果量を持つことを意味します。各項について比較することはできません。

このことは、具体例を見てみると分かりやすいでしょう。まず、Figure 13.3 において、交互作用項を含まない分散分析の効果量について見てみましょう：

	<i>eta.sq</i>	<i>partial.eta.sq</i>
%drug	0.71	0.79
薬	0.71	0.79
%therapy	0.10	0.34
セラピー	0.10	0.34

^{*10} この章は、文字 R で様々なものを表現することに関して、新記録を打ち立てているかもしれません。これまでのところ、ソフトウェアパッケージ、平均値の表における行の数、モデルの残差、そして回帰における相関係数を指して、R という文字を使っています。大変申し訳ないと思っています。アルファベットの文字数が十分ではないことは明らかです。我々も、R がそれぞれの文脈において指示しているものを明確にするために、かなりの努力を要しているということを申し添えます

η^2 の値に着目すると、薬の要因が気分の向上の分散の 71%(i.e. $\eta^2 = 0.71$) を占めているのに対し、セラピーは 10% です。これにより、合計で 19% の変動が考慮されないままとなります (つまり、結果の変動の 19% が残差で構成されます)。全体的に見て、この結果は薬には非常に大きな効果^{*11}があり、セラピーにはわずかな効果があったことを意味します。次に、Figure 13.3 に示されている偏 η^2 値を見てみましょう。

セラピーの効果はそれほど大きくないため、それを調整しても大きな違いはありません。したがって、薬の偏 η^2 は、 $p\eta^2 = 0.79$ とそれほど増加しません。対照的に、薬の効果は非常に大きかったため、調整することで大きな違いが生じます。セラピーの偏 η^2 を計算すると、 $p\eta^2 = 0.34$ まで上昇していることが分かります。自問しなければならないのは、これらの偏 η^2 の値が実際に何を意味するのか？ということです。要因 A の主効果に対する偏 η^2 を解釈する一般的な方法は、それを要因 A のみを変化させた仮想実験の記述として解釈することです。実際の実験では要因 A と B の両方を変化させましたが、要因 A のみを変化させた実験についても簡単に想像することができます。偏 η^2 統計量は、そのような実験で得られることが予想される、結果変数の分散の量を表します。ただし、このような解釈は、その他の主効果に関する多くの事項と同様に、有意な交互作用効果が存在する場合には、あまり意味がないということに注意が必要です。

交互作用効果といえば、Figure 13.12 のように、交互作用項を含むモデルの効果量を計算したときに得られるものです。JASP では、単に 'Additional Options' - 'Estimates of effect size' を選択し、必要な変数を選ぶことで計算されます。見ての通り、主効果の η^2 値は変化しませんが、偏 η^2 値は変化します：

	<i>eta.sq</i>	<i>partial.eta.sq</i>
%drug	0.71	0.84
薬	0.71	0.84
%therapy	0.10	0.42
セラピー	0.10	0.42
%drug*therapy	0.06	0.29
薬*セラピー		

13.6.1 推定グループ平均

多くの場合、分散分析の結果と、それに関連する信頼区間に基づいて、すべてのグループ平均の推定値を報告する必要があります。JASP では、Figure 13.13 にあるように、分散分析の 'Additional Options' - 'Marginal Means' の機能を用いてこれを行うことができます。交互作用項薬*セラピーを、

^{*11}信じられないほどの大きさです。このデータの不自然さが見えてきましたね！

アクションボックスに移動するだけです。実行した分散分析が**飽和モデル** (i.e., 考えられるすべての主効果と交互作用効果を含むモデル) である場合、グループ平均の推定値はサンプル平均とまったく同じになります。重要なのは、信頼区間は、グループごとの個別の標準誤差を使用するのではなく、プールされた標準誤差の推定値を用いるということです。

結果を見ると、セラピーを行わなかったプラセボ群における気分向上の推定平均は 0.300 であり、95% 信頼区間は 0.006 から 0.594 でした。各グループについて信頼区間を計算しても、同じ値にはならないということに注意してください。これは、分散分析モデルが分散の均一性を仮定しているので、プールされた標準偏差の推定値を使用するためです。

13.7

仮定の確認

一元配置分散分析と同様に、多元配置分散分析においても、分散の等質性 (すべての群の標準偏差が等しい)、残差の正規性、観測の独立性の 3 つが主要な仮定となります。前の 2 つの仮定については、確認することができます。3 つ目の仮定については、測定値間に何らかの特別な関係性が存在するかどうか、自分自身で評価しなければなりません。例えば、時間を独立変数とする反復測定では、時点 1 と時点 2 の観測変数は同じ人物から測定されているため、関係があります。加えて、飽和モデルを使用していない場合 (例えば、交互作用項を省略している場合) には、省略されている項は重要ではないという仮定を置いていることになります。この最後の仮定については、省略された項を含めた分散分析を実行し、それらが有意であるかどうかを確認できるため、チェックすることは比較的容易です。分散の等質性と残差の正規性についてはどうでしょうか？ 結論からいうと、これらをチェックするのはとても簡単です。一元配置分散分析で行ったチェックの方法となんら変わりません。

13.7.1 分散の等質性

Section 12.8.1 で述べたように、異なる群やカテゴリ間で標準偏差のプロットを視覚的に比較し、Levene の検定の結果と一致するかどうかを確認するのは良いアイデアです。Levene の検定の理論については、Section 12.8.1 で説明したのでここでは触れません。この検定では、モデルが飽和モデル (i.e., すべての項を含む) であることが期待されています。なぜなら、この検定は主に群内の分散に関係しており、飽和モデル以外について適用しても、実際のところあまり意味がないからです。Levene の検定は、JASP の 'Assumption Checks' - 'Homogeneity tests' オプションで指定でき、その結果は Figure 13.14 のようになります。Levene の検定が有意でないということは、標準偏差のプロットの目視による確認との矛盾がなければ、分散の等質性の仮定には違反していないと考えて良

いことになります。

13.7.2 残差の正規性

一元配置分散分析と同様に、残差の正規性を簡単な方法で検定できます (Section 12.8.4 を参照)。しかし、一般的には、QQ プロットを用いて残差を視覚的に調べるのが良いと思います。Figure 13.14 を見てください。

13.8

共分散分析 (ANCOVA)

共分散分析は、分散分析の応用として、従属変数に関連していると思われる、追加の連続変数があるような場合に用いられる分析です。この追加の変数は、共分散分析 (ANCOVA) という名が示す通り、共変量として分析に加えることができます。

共分散分析では、従属変数の値を共変量の影響力によって”調整”し、”調整後”の得点の平均値について、通常の方法で群間での検定を行います。この手法は、実験の精度を高めることができるため、従属変数における群の平均値の同等性について、より”強力な”検定を行うことができます。共分散分析はどのようにしてこれを行うのでしょうか？共変量そのものに関しては、通常、実験的にはなんの関心もありますが、共変量を調整することにより、実験的な誤差の推定値を減少させることができます。そして、誤差分散を減少させることで、精度を高めることができます。これはすなわち、帰無仮説を棄却できないエラー（偽陰性あるいは第二種の過誤）が起これにくいということを意味します。

このような利点に対して、共分散分析には群間の真の差を見えなくしてしまうというリスクもあり、これは避けなければなりません。例えば、年齢ごとに統計に対する不安をプロットした Figure 13.15 を見てみると、文系と理系という異なる背景あるいは専攻を持つ学生からなる、2つの群があることが分かります。このとき、年齢を共変量とした共分散分析では、統計に対する不安は両群で差がないという結論になるかもしれません。この結論は妥当なものでしょうか？2つの群の年齢は重なっておらず、分散分析は本質的に、”データの無い範囲に外挿された” (Everitt 1996, p. 68) ことになるため、おそらく妥当ではないでしょう。

異なる群に対して共分散分析を適用する際には、慎重に検討する必要があることは明らかです。共分散分析は一元配置と多元配置のどちらのデザインにも使用できるため、どちらの計画でも注意が必要です。

13.8.1 JASP による共分散分析の実行

ある健康心理学者が、年齢を共変量として、日常的なサイクリングとストレスが幸福度に与える影響に関心を持っているとします。このデータセットは `ancova.csv` で見ることができます。このファイルを JASP で開き、共分散分析を行うには、'ANOVA' - 'ANCOVA' を選択して、共分散分析のウィンドウを開きます (Figure 13.16)。従属変数 'happiness' を選択し、'従属変数' ボックスに投入します。独立変数 'stress' と 'commute' を '固定要因' ボックスに投入します。共変量 'age' を '共変量' ボックスに投入します。次に、'追加のオプション' - '周辺平均' をクリックし、交互作用項 `stress*commute` をボックスに投入します。

結果ウィンドウに共分散分析表が表示されます (Figure 13.16)。共変量 'age' の F 値は $p = .023$ で有意であり、年齢が従属変数 `happiness` の重要な予測因子であることが示唆されました。推定された周辺平均値を見ると、今回の共分散分析には共変量に年齢が含まれているため、(共変量なしの分析と比較して) 調整が行われています。結果のプロット (Figure 13.17) は、有意な効果を視覚化して解釈するのに適した方法です。

主効果 'stress' の F 値 (52.61) に付随する確率は $p < .001$ です。主効果 'commute' の F 値 (42.33) に付随する確率は $p < .001$ となっています。これらはいずれも、検定結果が有意であるかどうかを判断する際に一般的に用いられる確率 ($p < .05$) よりも小さいため、ストレスの主効果 ($F(1, 15) = 52.61, p < .001$) と通勤方法の主効果 ($F(1, 15) = 42.33, p < .001$) が有意であったと結論づけることができます。また、ストレスと通勤方法の間には有意な交互作用も見られます ($F(1, 15) = 14.15, p = .002$)。

Figure 13.17 は、年齢を共変量とした共分散分析によって調整された、周辺化した平均幸福度の得点を示しています。この分析では、有意な交互作用効果があり、自転車で通勤するストレスの低い人は、車で通勤するストレスの低い人や、自転車でも車でもストレスの高い人よりも幸福度が高いという結果になりました。また、ストレスの主効果が大きく、ストレスの少ない人はストレスが多い人より幸福であることが分かります。加えて、通勤方法の主効果も大きいことから、自転車で通勤する人は車で通勤する人よりも平均して幸福度が高いことも分かります。

13.9

線形モデルとしての分散分析

分散分析と回帰分析については、それらが基本的に同じものであるということを理解することが重要になります。表面的には、そんなことはないと思われるかもしれませんが。これまでの説明では、分散分析は主としてグループ間の差の検定を、回帰分析は主として変数間の相関関係の理解を目的としていました。これらの説明は完全に正しいといえます。しかし、フードの下を覗いてみれば、分

分散分析と回帰分析の基本的な仕組みは非常によく似通っています。実際、すでにその証拠については述べられています。分散分析と回帰分析はどちらも二乗和 (SS) に大きく依存し、またどちらも F 検定を利用しています。振り替えてみると、Chapters 11 および 12 の内容は、重複していた感じが否めません。

その理由は、分散分析も回帰分析も、どちらも線形モデルだからです。回帰分析については、このことは自明です。予測変数と結果変数の関係を定義するために用いる回帰式は線形方程式であり、これは明らかに線形モデルです。

$$Y_p = b_0 + b_1 X_{1p} + b_2 X_{2p} + \varepsilon_p$$

上記の式において、 Y_p は p 番目の観測値 (e.g., p 人目の参加者) における結果変数の値、 X_{1p} は p 番目の観測値における 1 つ目の予測変数の値、 X_{2p} は p 番目の観測値における 2 つ目の予測変数の値、 b_0 , b_1 , および b_2 の項は回帰係数、 ε_p は p 番目の残差を表します。残差 ε_p を無視して、回帰直線そのものに注目すると、以下ようになります：

$$\hat{Y}_p = b_0 + b_1 X_{1p} + b_2 X_{2p}$$

ここで、 $\hat{Y}_p$ は、実際に観測された値 Y_p ではなく、参加者 p について回帰直線に基づいて予測された Y の値になります。分散分析を線形モデルとして記述することもできます。少々イメージし難いかもしれませんが、実際には非常に簡単です。まず、極めて単純な例として、 2×2 要因の分散分析を線形モデルに書き換えてみましょう。

13.9.1 データ

具体例として、私の講義での学生の成績が結果変数であるとしましょう。これは 0% から 100% までの比率尺度の変数です。関心のある予測変数は、学生が講義に出席したかどうか (出席 変数)、および学生が教科書を読んだかどうか (予習 変数) の 2 つです。ここでは、講義に出席した場合を出席 = 1, 出席しなかった場合を出席 = 0 とします。同様に、学生が教科書を読んでいた場合は予習 = 1, 読んでいなければ予習 = 0 とします。

さて、ここまでは順調ですね。ここから、いくらか数学的な処理を施す必要があります (すみません!) 今回の例では、 Y_p がクラスの p 番目の学生の成績を表すとしします。これは、本章の前半で使用した表記法とは全く異なります。以前は、予測変数 1 (行の要因) の r 番目のグループと予測因子 2 (列の要因) の c 番目のグループにおける i 番目の参加者を指して Y_{rci} という表記を使っていました。この拡張された表記法は、SS 値の算出方法を説明するのに非常に便利だったのですが、現在の文脈においては面倒なので、表記を切り替えます。さて、 Y_p という表記は Y_{rci} よりも視覚的にシンプルですが、グループについての情報を含まないという欠点があります。例えば、 $Y_{0,0,3} = 35$ という表記であれば、それは講義に出席せず (i.e., 出席 = 0), 教科書を読まず (i.e., 予習 = 0), 落第して

しまった (成績 = 35) 学生のことである (そして、この学生は 3 人目である) とすぐに分かるでしょう。しかし、 $Y_p = 35$ という表記では、 p 番目の学生が良い成績を取れなかったということしか分かりません。重要な情報が失われてしまっているのです。これを解決することは、それほど難しくありません。この情報を記録するための、2 つの新しい変数 X_{1p} と X_{2p} を導入すればよいのです。この学生の場合、 $X_{1p} = 0$ (i.e., 出席 = 0), $X_{2p} = 0$ (i.e., 予習 = 0) であることが分かります。そのため、データは以下ようになります：

参加者, p	成績, Y_p	出席, X_{1p}	予習, X_{2p}
1	90	1	1
2	87	1	1
3	75	0	1
4	60	1	0
5	35	0	0
6	50	0	0
7	65	1	0
8	70	0	1

もちろん、これは特別なことではありません。まさに我々の期待するデータのフォーマットです！データファイルは `rtfm.csv` です。

13.9.2 二値の要因を用いた分散分析の回帰モデルとしての表現

さて、数学の話に戻りましょう。このデータには、連続変数 Y と 2 つの二値変数 X_1 および X_2 という 3 つの変数が含まれます。この 2×2 要因の分散分析は、まさに回帰モデルと同じであることに気付いていただきたいと思います。

$$Y_p = b_0 + b_1 X_{1p} + b_2 X_{2p} + \varepsilon_p$$

上記の式はもちろん、先ほど 2 つの予測変数の回帰モデルを表す際に用いたものと全く同じ式です。唯一の違いは、回帰分析では X_1 および X_2 は連続的な値ですが、この式では両者は二値変数 (i.e., 0 または 1 の値をとる) になっていることです。このことについて納得する方法はいくつかあります。1 つ目は、両者の式が等しいことを証明するための、長い長い数学的演習を行う方法です。ただ、おそらく本書の読者の多くは、それを参考にするとどころか、むしろ迷惑に感じるのではないかと思います。その代わりに、基本的な考え方について説明したうえで、分散分析と回帰分析が似ているというだけでなく、どこから見ても同じであるということを、JASP に頼って説明することにしましょう。まず、このデータを用いて分散分析を行ってみましょう。`rtfm` データセットを使用して、JASP で分散分析を行った結果を Figure 13.18 に示します。

分散分析表と平均値から主要な数値を読み取ると、授業に出席した方が ($F_{1,5} = 21.6, p = .006$),

また教科書を読んでいた方が ($F_{1,5} = 52.3, p < 0.001$), より高い成績を得られていることが分かります。この p 値と F 統計量をメモしておきましょう。

では、線形回帰の観点から同じ分析について考えてみましょう。`rtfm` データセットにおいて、**出席**および**予習**の変数は、あたかも数値的な予測変数であるかのようにコード化されています。今回の場合、これは全く問題ありません。授業に出席した学生 (i.e., `attend = 1`) は、そうでない学生 (i.e., `attend = 0`) と比べて、“より出席している” という意味になるのですから。したがって、これらを回帰モデルの予測変数として加えることは全く不合理ではありません。予測変数が2つの可能な値を取るため、少々変わってはいますが、線形回帰の仮定に反するものではありません。加えて、解釈も容易になります。**出席**の回帰係数が0より大きければ、講義に出席している学生の方が成績が良いことを意味します。もし0より小さければ、講義を受けている学生の方が成績が低くなります。**予習**の変数についても同様です。

しかし、ちょっと待ってください。これはなぜ正しいのでしょうか？ 統計学の講義を複数回受けたことがあり、数学に慣れている人にとっては直感的に分かることかもしれませんが、それ以外の人には初見では分かりません。その理由を知るために、特定の学生に目を向けてみましょう。まず、データセットの6番目と7番目の学生 (i.e., $p = 6$ および $p = 7$) について考えてみましょう。どちらの学生も教科書を読んでいないので、`予習 = 0` となっています。このことを数学的に表記すると、 $X_{2,6} = 0$ および $X_{2,7} = 0$ となります。しかしながら、7番の学生は講義に出席している (i.e., `attend = 1`, $X_{1,7} = 1$) のに対し、6番の学生は出席していません (i.e., `attend = 0`, $X_{1,6} = 0$)。それでは、これらの数値を回帰直線の一般式に当てはめるとどうなるか見てみましょう。6番の学生については、回帰式は以下のように予測します。

$$\begin{aligned}\hat{Y}_6 &= b_0 + b_1 X_{1,6} + b_2 X_{2,6} \\ &= b_0 + (b_1 \times 0) + (b_2 \times 0) \\ &= b_0\end{aligned}$$

したがって、この学生は切片項 b_0 の値に対応する成績を取ることが予測されます。7番の学生についてはどうでしょうか？ 回帰式に数値を代入すると、今度は以下ようになります。

$$\begin{aligned}\hat{Y}_7 &= b_0 + b_1 X_{1,7} + b_2 X_{2,7} \\ &= b_0 + (b_1 \times 1) + (b_2 \times 0) \\ &= b_0 + b_1\end{aligned}$$

この学生は授業に出席しているので、予測される成績は切片項 b_0 に**出席**変数 b_1 の係数を加えたものに等しくなります。つまり、 b_1 が1より大きければ、講義に出る学生は出ない学生より成績が良いと予測されるわけです。逆に、係数が負であれば、講義に出た学生の方が成績が悪くなることが予測されます。このことについて、もう少し掘り下げてみましょう。講義にも出席し ($X_{1,1} = 1$)、さらに教科書も読んできた ($X_{2,1} = 1$) 1番の学生の場合はどうなるのでしょうか？ これらの数値を回帰式に

代入すると、次のようになります。

$$\begin{aligned}\hat{Y}_1 &= b_0 + b_1X_{1,1} + b_2X_{2,1} \\ &= b_0 + (b_1 \times 1) + (b_2 \times 1) \\ &= b_0 + b_1 + b_2\end{aligned}$$

すなわち、授業に出席すると良い成績が取れ (i.e., $b_1 > 0$)、教科書を読んでおくことでも良い成績が取れるため (i.e., $b_2 > 0$)、1 番の学生は 6 番や 7 番の学生よりも高い成績を取ることが予測されます。

ここまで来れば、教科書は読んでいるが講義を受けなかった 3 番の学生の成績が $b_2 + b_0$ となるという回帰モデルの予測についても全く驚かないでしょう。わざわざ回帰式を書いて読者を退屈させるようなことはしません。その代わりに、以下のような予測された成績の表をお示します：

		read textbook?	
		no	yes
attended?	no	b_0	$b_0 + b_2$
	yes	$b_0 + b_1$	$b_0 + b_1 + b_2$

このように、切片項 b_0 は、講義に出席したり教科書を読んだりする時間を取らない学生から期待される、“ベースライン”としての成績のような役割を果たします。同様に、 b_1 は講義に出席すれば得られると期待される成績の向上を、 b_2 は教科書を読むことで得られる成績の向上を表しています。これが分散分析であれば、 b_1 を出席の主効果、 b_2 を予習の主効果として扱いたいと思うかもしれません！ 実際に、単純な 2×2 の分散分析では、まさにこれと同様なことが起こります。

さて、分線分析と回帰分析が、基本的に同じものであることが分かってきたところで、実際に JASP で `rtfm` データを用いた回帰分析を行い、本当にそうなのか納得してみましょ。通常の方法で回帰分析を実行すると、Figure 13.19 のような結果が得られます。

いくつか興味深い点があります。まず、切片項は 43.5 であり、教科書を読まず、講義にも出席しなかった 2 名の学生の“グループ”平均である 42.5 という値に近いことに注目してください。次に、出席変数の回帰係数が $b_1 = 18.0$ であることに注目してください。これは、講義に出席した学生は、出席しなかった学生よりも成績が 18 点高いということを示唆しています。つまり、教科書を読まずに講義に参加した学生の成績は $b_0 + b_1$ であり、 $43.5 + 18.0 = 61.5$ となることが予測されます。教科書を読んでいる学生についても、同様のことが生じていることが確認できます。

実は、分散分析と回帰分析の等価性を確かめるために、もう少し踏み込むことができます。回帰分析の出力において、出席変数と予習変数の p 値を見てみましょう。これらは、先ほど分散分析を実行したときに見たものと同じ値です。回帰モデルの検定では統計量 t が、分散分析では統計量 F が計算されるため、このことは少し意外に思われるかもしれません。しかし、思い返せば、Chapter 6 において t 分布と F 分布の間に関係があることは既に述べられています。自由度 k の t 分布に従って分布する量があるとき、それを二乗した量は自由度 1 と k の F 分布に従うことになります。このこ

とは、回帰モデルにおける統計量 t について確認することができます。出席変数の t 値は 4.65 です。これを二乗すると 21.6 となり、分散分析における対応する F 統計量と一致します。

13.9.3 対比を用いた非二値の要因の変換

ここまで、 2×2 の分散分析を線形モデルとして見る方法について述べてきました。このことは、 $2 \times 2 \times 2$ の分散分析や、 $2 \times 2 \times 2 \times 2$ の分散分析に対しても簡単に一般化することができます。ここまでの話と全く同じです。各要因に対応した新たな二値変数を追加するだけです。ただし、2 水準以上の要因について考えると、少々ややこしくなります。例えば、本章の前半で行った、`clinicaltrial.csv` データを用いた 3×2 の分散分析について考えてみましょう。3 つの水準をもつ薬要因を、回帰モデルに適した数値に変換するにはどうすればよいのでしょうか？

この間に対する答えは、実はとてもシンプルです。3 水準の要因が、2 つの二値変数によって記述しなおせることに気がさえすれば良いのです。例えば、薬：アンザイフリーという新たな二値変数と作るとしましょう。薬変数が"アンザイフリー"と等しいときに、薬：アンザイフリー = 1 となります。そうでない場合には薬：アンザイフリー = 0 となります。この場合、この変数はアンザイフリーと他の 2 つの薬との間に対比を設定します。もちろん、薬：アンザイフリーの対比だけでは薬変数に含まれるすべての情報を捉えるのに十分ではありません。ジョイゼパムとプラセボを区別できるような追加の対比が必要です。これを実現するために、薬がジョイゼパムであれば 1、そうでなければ 0 となるような、薬：ジョイゼパムという 2 つ目の二値変数を作成することができます。これら 2 つの対比により、3 種類の薬を完全に識別することが可能になります。下記の表はその様子を表したものです：

薬	薬：アンザイフリー	薬：ジョイゼパム
"プラセボ"	0	0
"アンザイフリー"	1	0
"ジョイゼパム"	0	1

もし患者に投与された薬がプラセボであれば、2 つの対比変数はいずれも 0 になります。薬がアンザイフリーの場合、薬：アンザイフリー変数は 1 に、薬：ジョイゼパムは 0 になります。ジョイゼパムの場合はその逆です。薬：ジョイゼパムが 1 に、薬：アンザイフリーは 0 になります。

対比変数を作成することは、JASP の '列の作成' 機能を使えば、さほど難しいことはありません。例えば、数式ボックスに次のような簡単な R コードを入力すれば、二値の薬：アンザイフリー変数を作成することができます：`ifelse(drug == 'anxifree', 1, 0)` 同様に、新しく薬：ジョイゼパム変数を作成するには、次のコードを使用します：`ifelse(drug == 'joyzepam', 1, 0)` セラピー：CBT 変数を作成するコードは次の通りです：`ifelse(therapy == 'CBT', 1, 0)` これらの新しい変数は、JASP のデータファイル `clinicaltrial2.jasp` で見るすることができます。これまで通り、" f_x " 記号をクリックすると、R コードも表示されます。

ここまで、3水準の要因を2つの二値変数で再コード化する方法を見てきました。更に、分散分析と回帰分析が、二値変数に関して同じように動作することも確認済みです。しかし、今回の場合、さらに複雑な問題が発生します。その問題については次章で説明します。

13.9.4 非二値の要因における分散分析と回帰分析の等価性

ここまでの処理で、同じデータセットに2種類のバージョンができました。薬変数を1つの3水準の要因として表現している `clinicaltrial.csv` ファイルのオリジナルデータ、およびこれを2つの二値の対比に変換した `clinicaltrial2.csv` ファイルの拡張データです。改めて強調しますが、ここで説明したいのは、最初に示した3×2の分散分析が、対比変数を用いた回帰モデルと等価であるということです。まずは、分散分析を再度実行してみると、Figure 13.20のような結果が得られます。交互作用は除外しておきましょう。'Model' に移動し、`drug*therapy` の項を 'Model Terms' ボックスから取り除きます。

当然、この出力は驚くべきものではありません。先ほどの分散分析と全く同じです。次に、予測変数として `CBTtherapy` を、説明変数として `druganxifree`, `drugjoyzepam` を投入した回帰分析を実行してみましょう。結果は Figure 13.21 のようになります。

ふーむ。前回とはかなり違った印象になっていると思います。当然のことですが、回帰分析の出力は、それぞれ別個に回帰分析を行った場合と同様に、3つの予測変数のそれぞれについて別々の結果が出力されています。`CBTtherapy` 変数の p 値は、元々の分散分析におけるセラピー要因の値と全く同じなので、回帰モデルと分散分析が同様のことを行っているのだと安心することができます。一方で、この回帰モデルは `druganxifree` および `drugjoyzepam` の対比を、あたかも全く関係のない2つの変数のように検定しています。もちろん、これは仕方のないことです。この可哀そうな回帰分析は、`drugjoyzepam` と `druganxifree` が、実際には我々が3水準の薬要因をコード化するために用いた2つの異なる対比であることを知る由もないのですから。それが知る限りでは、`drugjoyzepam` および `druganxifree` は、`drugjoyzepam` および `therapyCBT` と同じくらい相互に無関係なのです。しかし、我々はこのことをよく知っています。この段階では、これら2つの対比がそれぞれ有意であるかどうかを判断することには全く意味がありません。我々が知りたいのは、薬物による“総合的な”効果があるかどうかです。すなわち、我々が JASP に望むのは、2つの“薬物に関連した”対比を検定の目的に沿って一まとめにした、ある種の“モデル比較”のための検定です。見覚えはないでしょうか？ 今回の場合、Figure 13.22 のように、予測変数に `CBTtherapy` を含み、薬物に関連した2つの変数を除外した“ヌルモデル”を指定すれば良いのです。これを実行するためには、'Model' ボタンをクリックし、2つの薬物に関連する項について 'Add to null model' をチェックします。そして、両モデルについて AIC を求めることで、予測変数として薬をモデルに含めるべきかどうかを評価で

きます (Section 11.4 を参照) 値が小さい方がよい, ということを思い出してください。

13.10

対比の指定を行う別の方法

前節では, 要因をいくつかの対比に変換する方法を紹介しました。この方法では, 2 値変数の組み合わせによって, 以下の表のような定義を行いました

<i>drug</i>	<i>druganxiifree</i>	<i>drugjoyzepam</i>
"プラセボ"	0	0
"アンザイフリー"	1	0
"ジョイゼパム"	0	1

表の各行が要因の各水準に対応し, 各列がそれぞれの対比に対応しています。この表は, 常に列より行が 1 つ多く, 特別な名前を持っています。その名前とは, 対比行列です。しかし, 対比行列の指定には様々な方法があります。本節では, 統計学者が用いるいくつかの標準的な対比行列について, そしてそれらを JASP でどのように使用するかについて説明します。この後の非釣合型の分散分析の章 (Section 13.3) を読むのであれば, 本章によく目を通しておくことをお勧めします。そうでなければ, 読み飛ばしても構いません。釣合型デザインでは, 対比の選択はあまり重要ではないからです。

13.10.1 処理対比

先に述べたような特殊な対比では, 要因のある 1 つの水準が, ある種の “ベースライン” カテゴリー (i.e., 今回の例では プラセボ) として特別な意味を持ち, これに対応して他の 2 つの水準が定義されます。このような対比のことを処理対比といいます。“ダミーコーディング”とも呼ばれています。この対比では, 要因の各水準はベースとなる水準と比較されます。ベースとなる水準は切片の値です。

この名称は, 要因の中のあるカテゴリーが実際に特別な, ベースラインを表すものである場合に, 対比が極めて自然かつ感覚的であるという事実を反映しています。臨床試験の例では, このことは理にかなっています。プラセボ条件は被験者に投薬をしていない状況に相当する, 特別な条件です。他の 2 つの条件は, プラセボ条件との関係によって定義されています。すなわち, プラセボをアンザイフリーに置き換える場合と, ジョイゼパムに置き換える場合です。

上記の表は, 3 つの水準を持つ要因に対する処理対比行列です。もし 5 つの水準を持つ要因の処理対比行列が必要な場合には, 以下のように設定することができます:

%Level	2	3	4	5
水準	2	3	4	5
1	0	0	0	0
2	1	0	0	0
3	0	1	0	0
4	0	0	1	0
5	0	0	0	1

この例では、1つ目の対比が水準2と水準1の対比、2つ目の対比が水準3と水準1の対比、という具合になっています。デフォルトでは、要因の最初的水準が常にベースラインカテゴリとなることに注意してください (i.e., すなわち、その水準は、それ自身と対応づけられた明示的な対比を持たず、値はすべての水準について0となります)。JASP では、'Data Variable' ウィンドウに表示される変数の水準の順序を操作することで、どのカテゴリが要因の最初的水準になるかを変更することができます (スプレッドシートの変数名をダブルクリックして、'Data Variable' ビューを表示する必要があります)。

13.10.2 ヘルマート対比

処理対比は、様々なシーンで活躍します。しかし、この方法が最も有効なのは、本当の意味でベースとなるカテゴリが存在し、そのカテゴリとの関係によって他のすべての群を評価したい場合です。そのようなベースラインカテゴリが存在しないような状況では、各群を他の群の平均と比較する方が、より理にかなっているかもしれません。ここで、JASP の 'ANOVA' - 'Contrasts' 選択ボックスの 'helmert' オプションで実行されるヘルマート対比を紹介しましょう。ヘルマート対比は、各群を“その前の”群の平均と比較するというアイデアが根底にあります。すなわち、第1の対比は2つ目の群と1つ目の群の差、第2の対比は3つ目の群と1つ目および2つ目の群の平均値との差、といった具合です。5つの水準を持つ要因の場合、以下のような対比行列に変換されます：

1	-1	-1	-1	-1
2	1	-1	-1	-1
3	0	2	-1	-1
4	0	0	3	-1
5	0	0	0	4

ヘルマート対比の利点として、すべての対比の和が0になる (i.e., すべての列の和が0になる) という性質があります。この性質は、ヘルマート対比を利用すれば、分散分析を回帰として解釈する際に、切片項が大平均 $\mu_{..}$ に対応する、ということを意味します。処理対比においては、切片項はベースラインカテゴリの群平均に対応していました。この特性は、状況によっては非常に有効です。これまで仮定してきたような、釣合型デザインにおいてはそれほど重要ではありませんが、後に [Section 13.3](#)

で非釣り合い型デザインについて考える時、その有用性が明らかになります。実を言えば、わざわざ本章を設けているのは、非釣り合い型の分散分析を理解する際に、対比が重要になるからなのです。

13.10.3 零和対比

3 つ目のオプションとして、JASP では“単純”対比と呼ばれ、グループ間の一対比較を構成する“零和”対比について簡単に紹介します。具体的には、各対比はあるグループとベースラインカテゴリ（今回の場合は第 1 グループに相当）との差を符号化したものになります：

1	-1	-1	-1	-1
2	1	0	0	0
3	0	1	0	0
4	0	0	1	0
5	0	0	0	1

ヘルマート対比と同様に、各列の和が 0 になることが分かります。これは、分散分析を回帰モデルとして扱ったとき、切片項が大平均に対応することを意味しています。これらの対比を解釈する際に認識すべきことは、これらの対比がそれぞれ、グループ 1 と他の 4 つのグループのうちの 1 つとの一対比較であるということです。具体的には、対比 1 は“グループ 2 - グループ 1”の対比、対比 2 は“グループ 3 - グループ 1”の対比、といった具合です。^{*12}

13.10.4 JASP におけるその他の対比

JASP には、他にも様々な種類の対比を生成できるオプションが用意されています。これらは、分散分析のメインウィンドウの‘対比’オプションにあり、以下のようなタイプの対比がリストアップされています。

^{*12}処理対比と単純対比の違いは何かと聞かれることがあります。基本的な例として、男性=0、女性=1 とする性別の主効果を考えます。処理対比の場合、係数は女性と男性の平均の差の指標となり、切片は男性の平均値を表します。一方で、単純対比、すなわち男性=-1、女性=1 の場合、切片は平均値の平均であり、主効果は切片と各グループ平均の差となります。

対比のタイプ	
偏差	各水準（基準カテゴリを除く）の平均と全水準の平均（大平均）を比較します。
シンプル	単純対比では、処理対比と同様に各水準の平均を指定された水準の平均と比較します。このような対比は、対照群がある場合に有効です。デフォルトでは、最初のカテゴリが指定されています。ただし、単純対比では、切片は要因におけるすべての水準の太平均となります。
差	各水準（最初的水準を除く）の平均を、それ以前の水準の平均と比較します。（逆ヘルマート対比と呼ばれることもあります）
Helmert	要因の各水準（最後的水準を除く）の平均を、それ以降の水準の平均と比較します。
繰り返し	各水準（最後的水準を除く）の平均を、その後の水準の平均と比較します。
多項	線形効果と二次効果を比較します。1 つ目の自由度は全カテゴリを通しての線形効果を含んでおり、2 つ目の自由度は二次効果です。この対比は、多項式のトレンドを推定するためにしばしば用いられます。

13.11

事後検定

話題を切り替える時が来ました。対比を用いた事前に計画した比較ではなく、分散分析を行った結果、いくつかの有意な効果が見いだされたとします。F 検定は「群間に差がない」という帰無仮説を検定するだけの“オムニバス”検定なので、有意であったとしても、どの群が他のどの群と違うのかまでは分かりません。この問題については Chapter 12 で触れましたが、その際には、すべての可能な群のペアに対して t 検定を実行し、多重比較の補正 (e.g., Bonferroni の方法, Holm の方法)

を行うことで、すべての比較においてタイプ I エラーの確率を制御するという解決策を取りました。Chapter 12 で使用した方法は、比較的単純で、複数の仮説検定を行うような様々な状況において利用可能であるという利点がありますが、分散分析の文脈において効率的に事後検定を行いたい場合においては、必ずしも最良の選択肢とは言えません。統計学の文献 (Hsu 1996) を見ると、多重比較の方法は実に様々であり、その全てを詳細に論じることは、本書のような入門書では不可能でしょう。

とはいえ、1 つだけ注目に値する手法があります。Tukey の “Honestly Significant Difference” 検定、略して **Tukey の HSD 検定** と呼ばれる方法です。今回は、数式は割愛し、定性的な説明に留めます。Tukey の HSD 検定の基本的な考え方は、グループ間の関連するペア同士の比較をすべて検討することであり、したがって、ペアワイズの差に関心がある場合には、Tukey の HSD 検定は本当の意味で適切な手法となります。^{*13} 例えば、以前の章で実施した `clinicaltrial.csv` データセットを用いた分散分析において、薬およびセラピーの主効果を指定し、以下の 4 通りの比較を行いました：

- アンザイフリーを投与した人と偽薬を投与した人の気分の高揚の違い。
- ジョイゼパムを投与した人と偽薬を投与した人の気分の高揚の違い。
- アンザイフリーを投与した人とジョイゼパムを投与した人の気分の高揚の違い。
- CBT を実施した人とセラピーを実施しなかった人の気分の高揚の違い。

これらの比較のいずれにおいても、我々は (母集団の) 群平均の真の差に関心があります。Tukey の HSD 検定では、これら 4 つの比較の全てについて、**同時信頼区間** を求めます。95% “同時” 信頼区間とは、この研究を何度も繰り返した場合に、95% の研究結果において、信頼区間に該当の真値が含まれる、という意味です。さらに、この信頼区間を用いて、任意の特定の比較のための修正済み p 値を算出することができます。

JASP の **TukeyHSD** 関数は、かなり使いやすいものになっています。事後検定を行いたい分散分析の項を指定するだけです。例えば、主効果の事後検定は行いたい、交互作用の事後検定は行いたくない場合、分散分析の画面の ‘事後検定’ のオプションを開き、**薬** および **セラピー** の変数を右側のボックスに移動し、適用可能な事後検定リストの一覧から ‘チューキー (Tukey)’ のチェックボックスを選択することになるでしょう。この分析は、対応する結果の表とともに、Figure 13.23 に示されています。

‘事後検定’ の結果の出力は、(望み通りの) 非常に分かりやすいものです。例えば、最初の比較はアンザイフリー対プラセボの差で、出力の最初の部分には観測された群平均の差が .27 であることが示されています。次の数値は差の標準誤差であり、この値から 95% 信頼区間を計算することができます (‘信頼区間’ のチェックボックスを選択すると、実際にこの 95% 信頼区間を表示することがで


^{*13} 例えば、グループ A の平均がグループ B およびグループ C の平均と有意に異なるかどうかを知りたい場合には、別の手法 (e.g., Scheffe の方法、この方法は本書の範囲を超えていますが、より保守的な方法です) を用いる必要があります。しかし、ほとんどの場合、ペアワイズの群間差に関心があると思いますので、Tukey の HSD 検定は覚えておくとかかなり便利です。

きます)。さらに、自由度を表す列、t 値を表す列、最後に p 値を表す列が続きます。最初の比較における修正済み p 値は .21 です。一方、次の行を見ると、ジョイゼパムとプラセボの条件の観測された差は 1.03 であり、この結果は有意 ($p < .001$) であることが分かります。


ここまでは良いでしょう。モデルに交互作用項が含まれる場合はどうでしょうか？例えば、JASP のデフォルトのオプションは、薬とセラピーの要因間に交互作用があることを許容するものです。このような場合、考慮しなければならない比較の数が増え始めます。前回と同様に、薬の主効果に関連する 3 つの比較と、セラピーの主効果に関連する 1 つの比較を検討する必要があります。しかし、有意な交互作用の可能性を検討したい (そして、その有意な交互作用を支える群間差を見付けたい) のであれば、次のような比較を含める必要があります：

- アンザイフリーを投与し CBT で治療した人と、偽薬を投与し CBT で治療した人の気分の高揚の違い。
- アンザイフリーを投与し治療を受けなかった人と、偽薬を投与し治療を受けなかった人の気分の高揚の違い。
- etc


このように、比較検討すべきものがかなり多くなります。この分散分析モデルに対して Tukey の事後検定を実行すると、Figure 13.24 に示す通り、ペアワイズの比較が沢山 (計 19 個) 行われていることが分かります。先ほどとかなりよく似ていますが、比較の数が多くなっていることがお分かりいただけるでしょう。




(a)



(b)



(c)



(d)

Figure13.10 2×2 要因の分散分析における様々な交互作用




Figure13.11 臨床試験データに対して分散分析の「Descriptives Plot」オプションを使用した際の JASP の出力

ANOVA - mood.gain

Cases	Sum of Squares	df	Mean Square	F	p
drug	3.453	2.000	1.727	31.714	< .001
therapy	0.467	1.000	0.467	8.582	0.013
drug * therapy	0.271	2.000	0.136	2.490	0.125
Residual	0.653	12.000	0.054		

Note. Type III Sum of Squares

Figure13.12 交互作用項 drug*therapy を含む、完全な多元配置モデルの出力

Marginal Means

Marginal Means – drug * therapy

drug	therapy	Marginal Mean	SE	95% CI	
				Lower	Upper
anxifree	CBT	1.033	0.135	0.740	1.327
	no.therapy	0.400	0.135	0.106	0.694
joyzepam	CBT	1.500	0.135	1.206	1.794
	no.therapy	1.467	0.135	1.173	1.760
placebo	CBT	0.600	0.135	0.306	0.894
	no.therapy	0.300	0.135	0.006	0.594

Figure13.13 飽和モデルの周辺平均を示す JASP のスクリーンショット, i.e. clinicaltrial データセットの交互作用コンポーネントを含む

Assumption Checks ▼

Test for Equality of Variances (Levene's)

F	df1	df2	p
0.206	5.000	12.000	0.954

Q-Q Plot ▼




Figure13.14 分散分析モデルの仮定の確認




Figure13.15 2つの群の年齢ごとの統計に対する不安のプロット

.....




Figure13.16 JASP による共分散分析の実行画面




Figure13.17 ストレスと通勤方法の関数としての平均幸福度のプロット

ANOVA – grade

Cases	Sum of Squares	df	Mean Square	F	p
attend	648.000	1.000	648.000	21.600	0.006
reading	1568.000	1.000	1568.000	52.267	< .001
Residual	150.000	5.000	30.000		

Note. Type III Sum of Squares

Figure13.18 JASP の rtfm.csv データセットを用いた交互作用項のない分散分析

Coefficients

Model		Unstandardized	Standard Error	Standardized	t	p
1	(Intercept)	43.500	3.354		12.969	< .001
	attend	18.000	3.873	0.523	4.648	0.006
	reading	28.000	3.873	0.814	7.230	< .001

Figure13.19 JASP の rtfm.csv データセットを用いた交互作用項を含まない回帰分析

ANOVA – mood.gain

Cases	Sum of Squares	df	Mean Square	F	p
drug	3.453	2.000	1.727	26.149	< .001
therapy	0.467	1.000	0.467	7.076	0.019
Residual	0.924	14.000	0.066		

Note. Type III Sum of Squares

Figure13.20 JASP による交互作用を含まない分散分析の出力

Coefficients						
Model		Unstandardized	Standard Error	Standardized	t	p
1	(Intercept)	0.289	0.121		2.385	0.032
	druganxifree	0.267	0.148	0.242	1.797	0.094
	drugjoyzepam	1.033	0.148	0.939	6.965	< .001
	therapyCBT	0.322	0.121	0.311	2.660	0.019

Figure13.21 JASP による対比変数 druganxifree および drugjoyzepam を用いた回帰分析, with contrast variables druganxifree and drugjoyzepam

Linear Regression ▼

Model Summary ▼

Model	R	R ²	Adjusted R ²	RMSE
0	0.844	0.713	0.674	0.305
1	0.900	0.809	0.768	0.257

Note. Null model includes druganxifree, drugjoyzepam

ANOVA

Model		Sum of Squares	df	Mean Square	F	p
0	Regression	3.453	2	1.727	18.611	< .001
	Residual	1.392	15	0.093		
	Total	4.845	17			
1	Regression	3.921	3	1.307	19.791	< .001
	Residual	0.924	14	0.066		
	Total	4.845	17			

Note. Null model includes druganxifree, drugjoyzepam

Coefficients

Model		Unstandardized	Standard Error	Standardized	t	p
0	(Intercept)	0.450	0.124		3.619	0.003
	druganxifree	0.267	0.176	0.242	1.516	0.150
	drugjoyzepam	1.033	0.176	0.939	5.876	< .001
1	(Intercept)	0.289	0.121		2.385	0.032
	druganxifree	0.267	0.148	0.242	1.797	0.094
	drugjoyzepam	1.033	0.148	0.939	6.965	< .001
	therapyCBT	0.322	0.121	0.311	2.660	0.019

Figure13.22 JASP の回帰分析におけるモデル比較。0 はヌルモデル, 1 は対立モデル

Post Hoc Tests ▼

Post Hoc Comparisons – drug ▼

		Mean Difference	SE	t	P _{Tukey}
placebo	joyzepam	-1.033	0.148	-6.965	< .001
	anxifree	-0.267	0.148	-1.797	0.206
joyzepam	anxifree	0.767	0.148	5.168	< .001

Post Hoc Comparisons – therapy

		Mean Difference	SE	t	P _{Tukey}
CBT	no.therapy	0.322	0.121	2.660	0.019

Figure13.23 JAPS による Tukey の HSD 検定

.....

Post Hoc Tests ▼

Post Hoc Comparisons – drug * therapy ▼

		Mean Difference	SE	t	P _{Tukey}
placebo,CBT	joyzepam,CBT	-0.900	0.191	-4.724	0.005
	anxifree,CBT	-0.433	0.191	-2.275	0.275
	placebo,no.therapy	0.300	0.191	1.575	0.628
	joyzepam,no.therapy	-0.867	0.191	-4.549	0.007
	anxifree,no.therapy	0.200	0.191	1.050	0.892
joyzepam,CBT	anxifree,CBT	0.467	0.191	2.449	0.214
	placebo,no.therapy	1.200	0.191	6.299	< .001
	joyzepam,no.therapy	0.033	0.191	0.175	1.000
	anxifree,no.therapy	1.100	0.191	5.774	< .001
anxifree,CBT	placebo,no.therapy	0.733	0.191	3.849	0.022
	joyzepam,no.therapy	-0.433	0.191	-2.275	0.275
	anxifree,no.therapy	0.633	0.191	3.324	0.053
placebo,no.therapy	joyzepam,no.therapy	-1.167	0.191	-6.124	< .001
	anxifree,no.therapy	-0.100	0.191	-0.525	0.994
joyzepam,no.therapy	anxifree,no.therapy	1.067	0.191	5.599	0.001

Figure13.24 JASP による交互作用項を含む分散分析における Tukey の HSD 検定

.....

14. 因子分析

ここまでの章では、2 つ以上のグループ間の差についての統計的検定を扱ってきました。しかし研究をしていると、複数の変数がどのように共変するかを調べたくなることがあります。つまり、変数どうしがどう関連しているのか、そしてその関連のパターンが何か興味深く意味のあることを示唆していないか、ということです。たとえば、データセットの中で観測された、直接測定された変数の背後に、観測されていない**潜在因子**があるかどうかを探りたい、ということはよくあります。統計学でいう潜在因子とは、もともと隠れている変数のことで、直接観測されるのではなく、観測された (直接測定された) 他の変数から (統計的分析を通じて) 推測されるものです。

この章では、因子分析とその関連手法をいくつか取り上げます。まずは探索的因子分析 (EFA) から始めましょう。EFA は、データセットの背後にある潜在因子を特定するための統計的手法です (セクション 14.1)。次にセクション 14.2 では主成分分析 (PCA) を扱います。これはデータを縮約するための手法で、厳密に言えば背後にある潜在因子を特定するものではありません。PCA は単に、観測変数の線形結合を作り出すだけのものです。続く確認的因子分析 (CFA) のセクション (14.3) では、EFA とは違って、CFA ではデータの中の変数がどう関連しているかについての考え、つまりモデルから出発することを示します。そのうえで、そのモデルを観測データに対して検証し、モデルの当てはまりがどのくらいよいかを評価します。CFA をさらに洗練させたものが、いわゆる多特性多方法 (MTMM) アプローチです (セクション 14.4)。ここでは潜在因子と方法による分散の両方をモデルに含めます。これは、測定に異なる方法論的アプローチが使われていて、方法による分散が重要な検討事項になる場合に役立ちます。最後に、関連する分析として内的整合性による信頼性分析を取り上げます。これは、ある尺度が心理学的な構成概念をどれだけ一貫して測定しているかを検討するものです (セクション 14.5)。

14.1

探索的因子分析

探索的因子分析 (EFA) は、観測データから推測できる隠れた潜在因子を明らかにするための統計的手法です。この手法は、測定された変数の集まり、たとえば V_1, V_2, V_3, V_4, V_5 が、背後にある潜在因子の測定値としてどの程度表現できるかを計算します。この潜在因子は、たったひとつの観測変数で測ることはできず、観測変数の集まりのあいだに生じる関係として現れてきます。

図 14.1 では、それぞれの観測変数 V が、背後にある潜在因子 (F) によってある程度 “引き起こされて” おり、それが b_1 から b_5 の係数 (因子負荷量とも呼ばれます) で描かれています。それぞれの観測変数には、 e_1 から e_5 までの誤差項も付いています。それぞれの誤差項は、対応する観測変数 V_i の分散のうち、背後にある潜在因子では説明されない部分を表しています。




Figure14.1 複数の観測変数の関係の背後にある潜在因子

心理学では、潜在因子は直接観測したり測定したりするのが難しい心理現象や構成概念を表します。たとえばパーソナリティ、知能、思考スタイルなどです。図 14.1 の例では、行動や態度についての具体的な 5 つの質問をしたことになりますが、そこからたとえば外向性と呼ばれるパーソナリティ構成概念の姿をつかむことができます。別の具体的な質問群からは、その人の内向性や誠実性の姿がつかめるかもしれません。

もうひとつ例を挙げましょう。統計不安を直接測ることはできないかもしれませんが、質問紙のいくつかの質問によって、統計不安が高いか低いかを測ることはできます。たとえば “Q1: 統計の授業

の課題をやる”，“Q2: 学術論文に書かれている統計を理解しようとする”，“Q3: 授業でわからないことを先生に質問する”といった項目に対して、それぞれ不安が低いから高いまでで評定してもらうわけです。統計不安の高い人は、その不安の高さゆえに、これらの観測変数に対して同じように高い反応をする傾向があります。同じように、統計不安の低い人は、その不安の低さゆえに、これらの変数に対して同じように低い反応をすることになります。

探索的因子分析 (EFA) がやっているのは、本質的には、観測変数間の相関を探索することで、観測変数が共変するときに特定される、興味深く重要な背後の (潜在) 因子を見つけ出すことです。統計ソフトを使えば潜在因子を推定し、どの変数がどの因子に高い負荷量^{*1}を持つか (たとえば負荷量が > 0.5) を特定できます。負荷量が高い変数は、その潜在因子の有用な測定値、つまり指標であることを示唆します。この過程には回転と呼ばれる手続きが含まれています。正直に言うとかかなり奇妙な考え方なのですが、幸いなことに私たちがそれを理解しようと悩む必要はありません。因子ごとの負荷量のパターンをずっとはっきりさせてくれるので役に立つ、ということだけ知っておけば十分です。つまり回転は、どの変数がどの因子と実質的に結びついているかをよりはっきり見えるようにしてくれます。また、手元のデータからしていくつの因子が妥当なのかも決めなければなりません。ここで役に立つのが固有値と呼ばれるものです。

14.1.1 EFA は何の役に立つのか

EFA がよい解 (つまり因子モデル) を与えてくれたなら、次は手に入れたびかびかの新しい因子をどうするかを決めなければなりません。研究者は心理尺度を開発するときに EFA をよく使います。1 つ以上の心理学的構成概念に関係すると思われる質問項目のプールを作り、EFA を使ってどの項目が潜在因子として“まとまる”かを見て、そのうえで、潜在因子を有効に、あるいは明確に測っていない項目を削除すべきかどうかを判断するのです。

この考え方に沿って、EFA のもうひとつの帰結は、それぞれの因子に負荷する変数をまとめて因子得点、尺度得点と呼ばれることもあるもの、にすることです。変数をまとめて尺度得点にするには 2 つのやり方があります。

- その因子に寄与する各項目の因子負荷量で重みづけした得点として、新しい変数を作る。
- その因子に寄与する各項目にもとづいて、ただしすべて等しく重みづけして新しい変数を作る。

1 つめのやり方では、合成得点への各項目の寄与は、その項目が因子とどれだけ強く関係しているかによって決まります。2 つめのやり方では、ふつうは因子に実質的に寄与するすべての項目を単純に平均して、合成尺度得点の変数を作ります。どちらを選ぶかは好みの問題ですが、1 つめのやり方

^{*1}ありがたいことに、因子負荷量は標準化回帰係数のように解釈できます。

には、負荷量が標本ごとにかなり変わりうるという欠点があります。行動科学や健康科学では、異なる研究や異なる標本にまたがって使える合成尺度得点を開発し利用したいことが多いのです。その場合には、別の標本から得られた標本固有の負荷量で重みづけするよりも、実質的な項目が等しく寄与する合成指標を使うほうが理にかなっています。いずれにせよ、合成変数を項目の平均として理解するほうが、標本固有の最適重みづけによる合成を使うよりも単純で直感的です。

本書の範囲を超えるより進んだ統計手法として、潜在因子を別の潜在因子の予測モデルに用いる回帰モデリングがあります。これは“構造方程式モデリング”と呼ばれ、このアプローチに特化したソフトウェアや R パッケージがあります。しかし先を急ぐのはやめましょう。いま集中すべきなのは、JASP で EFA をどうやるか、です。

14.1.2 JASP での EFA

まずデータが必要です。International Personality Item Pool(<http://ipip.ori.org>) から取られた 25 個のパーソナリティ自己報告項目 (図 14.2 参照) が、Synthetic Aperture Personality Assessment(SAPA) というウェブベースのパーソナリティ測定プロジェクト (SAPA: <http://sapaproject.org>) の一部として使われました。この 25 項目は、協調性、誠実性、外向性、神経症傾向、開放性という想定される 5 つの因子によって構成されています。

項目データは 6 件法の反応尺度で収集されました。

1. まったく当てはまらない
2. あまり当てはまらない
3. やや当てはまらない
4. やや当てはまる
5. かなり当てはまる
6. 非常によく当てはまる

N = 250 の回答からなる標本が、データセット `bfi_sample.csv` に入っています。研究者としての私たちの関心は、`bfi_sample.csv` データファイルの 25 の観測変数によってそれなりにうまく測定されている潜在因子があるかどうかを、データを探索して確かめることです。データセットを開いて、25 の変数が連続変数としてコード化されていることを確認してください (厳密には順序変数ですが、JASP で EFA を行う分にはたいい問題になりません。ただし重みづけ因子得点を計算する場合には連続変数である必要があります)。JASP で EFA を実行するには、次のようにします。

- JASP のメインのボタンバーから **Factor - Exploratory Factor Analysis** を選び、EFA の分析ウィンドウを開きます (図 14.3)。
- 25 のパーソナリティ項目を選択し、‘Variables’ のボックスに移します。
- ‘Assumption Checks’ をはじめ、回転の ‘Method’, 抽出する ‘Number of Factors’, ‘Additional

Variable name	Question / Item (short phrases that you should respond to by indicating how accurately the statement describes your typical behaviour or attitudes)	Coding (R: reverse)
A1	<u>Am</u> indifferent to the feelings of others.	R
A2	Inquire about others' well-being.	
A3	Know how to comfort others.	
A4	Love children.	
A5	Make people feel at ease.	
C1	<u>Am</u> exacting in my work.	
C2	Continue until everything is perfect.	
C3	Do things according to a plan.	
C4	Do things in a half-way manner.	R
C5	Waste my time.	R
E1	Don't talk a lot.	R
E2	Find it difficult to approach others.	R
E3	Know how to captivate people.	
E4	Make friends easily.	
E5	Take charge.	
N1	Get angry easily.	
N2	Get irritated easily.	
N3	Have frequent mood swings.	
N4	Often feel blue.	
N5	Panic easily.	
O1	<u>Am</u> full of ideas.	
O2	Avoid difficult reading material.	R
O3	Carry the conversation to a higher level.	
O4	Spend time reflecting on things.	
O5	Will not probe deeply into a subject.	R

Figure14.2 データセット bfi_sample.csv に含まれる、想定される 5 つのパーソナリティ因子で構成された 25 の観測変数項目

.....

Output' などの適切なオプションにチェックを入れます。この例示のための EFA で推奨されるオプションは図 14.3 を見てください。なお、回転の 'Method' と抽出する 'Number of Factors' は、後述するように、最良の結果を見つけるために分析の途中で研究者が調整していくのが普通です。

これでいくつの因子を使うか (データから “抽出” するか) の検討を始められます。3 つの異なるやり方があります。




Figure14.3 JASP の探索的因子分析のウィンドウ

- ひとつの慣例は、固有値が 1 より大きい成分をすべて選ぶというものです*2。今回のデータでは 4 因子になります (実際に試してみてください)。
- 図 14.4 のようなスクリープロットを調べると“変曲点”を見つけることができます。これはスクリー曲線の傾きがはっきりと平らになる点で、“肘”の下にあたります。今回のデータでは 5 因子になります。スクリープロットの解釈は少し職人芸的なところがあります。図 14.4 では 5 因子から 6 因子にかけてははっきりした段差がありますが、他のスクリープロットではここまではっきりしないこともあります。
- 平行分析という手法を使い、得られた固有値をランダムなデータから得られるであろう固有

*2固有値は、その因子が観測変数の分散のどれだけを説明するかを示します。固有値が > 1 の因子は、観測変数 1 つ分より多くの分散を説明していることになります。

値と比較します。抽出される因子数は、ランダムなデータで得られる値より大きい固有値を持つ因子の数になります。

Scree Plot ▼




Figure14.4 JASP の EFA によるパーソナリティデータのスクリープロット。5 の地点 (“肘”) ではっきりした変曲と平坦化が見られる

.....

[Fabrigar, Wegener, MacCallum, and Strahan \(1999\)](#) によれば 3 つめのやり方がよいということですが、実際には研究者は 3 つすべてを見たうえで、もっとも解釈しやすい、あるいは解釈に役立つ因子数を判断する傾向があります。これは“意味の解釈可能性による基準”と理解できます。研究者はふつう、上のいずれかのやり方で得られた解に加えて、因子数を 1 つか 2 つ増やした解や減らした解も検討します。そのうえで、もっとも納得のいく解を採用するのです。

同時に、最終的な解をどう回転させるのがよいかも考える必要があります。回転には大きく 2 つのやり方があります。直交回転 (たとえば ‘varimax’) は選ばれた因子が無相関になるように強制するのに対し、斜交回転 (たとえば ‘oblimin’) は因子間に相関があることを許します。心理学者や行動科学者が関心を持つ次元は、直交していると期待できるようなものであることはあまりありませんので、

Factor Statistics

Summary			
Factor	SS Loadings	% of Variance	Cumulative %
1	2.578	10.313	10.313
2	2.380	9.518	19.831
3	2.246	8.985	28.816
4	2.337	9.349	38.165
5	1.878	7.514	45.679

Correlation Matrix					
	1	2	3	4	5
1	—	-0.195	0.015	0.208	-0.128
2		—	0.184	-0.398	0.261
3			—	-0.300	0.303
4				—	-0.311
5					—

Figure14.5 jamovi の EFA による 5 因子解の因子要約統計量と因子間相関

.....

斜交解のほうが理にかなっていると言えるでしょう^{*3}。

実際には、斜交回転で因子間にかなりの相関 (正でも負でもよく、 > 0.3) が見られた場合、たとえば図 14.5 で抽出された因子のうち 2 つの相関が -0.398 であるような場合には、斜交回転を選ぶという直感が裏づけられたことになります。因子が実際に相関しているのであれば、斜交回転のほうが直交回転よりも真の因子のよい推定値と、よりよい単純構造を与えてくれます。そして、斜交回転の結果、因子間の相関がほぼゼロだとわかったのであれば、研究者はそのまま直交回転を実行すればよいのです (その場合、斜交回転とほぼ同じ解が得られるはずです)。

抽出された因子間の相関を確認したところ、少なくともひとつは 0.3 を超えていました (図 14.5) ので、抽出された 5 因子には斜交回転 ('oblimin') を使うのがよさそうです。図 14.5 からは、5 因子

^{*3}斜交回転では 2 つの因子行列が得られます。ひとつは構造行列、もうひとつはパタン行列と呼ばれるものです。jamovi では結果にパタン行列だけが表示されます。解釈にはこちらがもっとも有用なのが普通だからですが、専門家のなかには両方を見るとよいと言う人もいます。構造行列の係数は、その因子と他のすべての因子との関係を見捨てるうえで、変数と因子の関係を示します (つまり 0 次の相関です)。パタン行列の係数は、その変数に対する他の因子の効果を統制したうえで、ある因子がその変数に対して持つ独自の寄与を示します (標準化偏回帰係数に似たものです)。直交回転のもとでは、構造係数とパタン係数は同じになります。

がデータ全体の分散の 46% を説明していることもわかります。第 1 因子が分散の約 10%, 第 2 因子から第 4 因子がそれぞれ約 9%, 第 5 因子が 7% 強を説明しています。これはあまり立派な数字ではありません。解全体がデータの分散のもっと大きな割合を説明していればよかったのですが。

どんな EFA でも、原理的には観測変数と同じ数だけ因子を取ることができますが、因子を 1 つ増やすごとに、追加で説明される分散の量は小さくなっていくということに注意してください。最初のいくつかの因子がもとの 25 変数の分散のかなりの部分を説明しているなら、それらの因子は 25 変数の代わりになる、明らかに有用でより単純なものだということになります。残りは、もとの変動をそれほど失うことなく捨てられるわけです。しかし、25 変数の分散の大部分を説明するのにたとえば 18 個の因子が必要なのであれば、もとの 25 変数をそのまま使えばよい、ということになります。

図 14.6 は因子負荷量を示しています。つまり、25 のパーソナリティ項目が、選ばれた 5 つの因子のそれぞれにどう負荷しているかということです。0.3 未満の負荷量は非表示にしてあります(図 14.3 のオプションで設定します)。

第 1, 第 2, 第 3, 第 4 因子については、因子負荷量のパターンが図 14.2 で想定されていた因子とよく一致しています。やれやれ。そして第 5 因子もかなり近く、“開放性”を測ると想定されていた 5 つの観測変数のうち 4 つが、この因子にきれいに負荷しています。ただし変数 O4 はどうも収まりが悪いようです。図 14.6 の因子解を見ると、この変数は(比較的低い負荷量ではありますが)第 3 因子に負荷しており、第 5 因子には実質的に負荷していません。

もうひとつ注目すべきは、図 14.2 で“R: 逆転項目”と示されていた変数が、負の因子負荷量を持っているということです。項目 A1(“他人の気持ちに無関心である”)と A2(“他人の様子を気にかける”)を見てください。A1 の得点が高いことは協調性が低いことを意味するのに対し、A2 の得点が高いこと(そのほかの“A”の変数すべてについても同様です)は協調性が高いことを意味します。ですから A1 は他の“A”の変数と負の相関を持つことになり、図 14.6 にあるように負の因子負荷量を持つわけです。

図 14.6 では、各変数の“独自性”も見ることができます。独自性とは、その変数に“固有”で因子によって説明されない分散の割合のことです^{*4}。たとえば、‘A1’の分散の 74% は 5 因子解の因子では説明されていません。これに対して‘N1’は、因子解で説明されない分散が比較的小さくなっています(31%)。“独自性”が大きいほど、その変数の因子モデルにおける関連性や寄与は小さいということに注意してください。

正直なところ、EFA でこれほどきれいな解が得られるのは珍しいことです。ふつうはもっとごちゃごちゃしていますし、因子の意味を解釈するのももっと骨が折れます。ここまではっきりと切り分けられた項目プールを持っていることは、そう多くありません。たいていの場合は、いくつかの潜在因子の指標かもしれないと思われる観測変数の山を抱えているものの、どの変数がどこに行くのかに

^{*4}因子分析では“共通性”が報告されることもあります。これは、その変数の分散のうち因子解によって説明される量のことです。独自性は $(1 - \text{共通性})$ に等しくなります。

Factor Loadings						
	Factor					Uniqueness
	1	2	3	4	5	
A1			-0.465			0.738
A2			0.702			0.502
A3			0.687			0.444
A4			0.453			0.667
A5			0.543			0.515
C1		0.720				0.478
C2		0.664				0.542
C3		0.501				0.753
C4		-0.647				0.469
C5		-0.571				0.536
E1				0.561		0.663
E2				0.697		0.352
E3				-0.441	0.419	0.486
E4			0.390	-0.569		0.426
E5				-0.391		0.587
N1	0.818					0.309
N2	0.814					0.359
N3	0.687					0.477
N4	0.461			0.483		0.463
N5	0.451					0.649
O1					0.576	0.626
O2					-0.487	0.689
O3					0.704	0.407
O4			0.307			0.745
O5					-0.493	0.698

Note. 'oblimin' rotation was used

Figure14.6 jamovi の EFA による 5 因子解の因子負荷量

.....

ついてそこまで強い見通しは持っていない、というものです。

さて、全体として説明される観測分散の割合は比較的低いものの、かなりよい 5 因子解が得られたようです。この解に満足していて、これらの因子をさらに別の分析に使いたいとしましょう。いち

ばん素直なやり方は、その因子に実質的に負荷している各変数の得点を合計し、変数の数で割ること
で、因子ごとの全体的な (平均) 得点を計算することです。データセットの各人について、たとえば
協調性因子であれば、 $A1 + A2 + A3 + A4 + A5$ を合計して 5 で割る、ということになります^{*5}。
つまり、こうして計算した因子得点は、含まれる各変数の得点を等しく重みづけしたものにもとづい
ている、ということです。jamovi では 2 つのステップでこれができます。

1. jamovi の変数変換コマンドを使って、A1 の値を逆転 (つまり $6 = 1; 5 = 2; 4 = 3; 3 = 4; 2 = 5; 1 = 6$) し、“A1R” として再コード化します (図 14.7 参照)。
2. A1R, A2, A3, A4, A5 の平均を計算して、“Agreeableness” という新しい変数を作ります。
これは jamovi の新変数計算コマンドで行います (図 14.8 参照)。




Figure14.7 jamovi の Transform コマンドによる変数の再コード化

もうひとつのやり方は、最適に重みづけした因子得点の指標を作ることです。jamovi の Rj エディ
タを使えば、R でこれを行えます。これも 2 つのステップに分かれます。

^{*5}必要なら、先に一部の変数を逆転処理しておくのを忘れずに。




Figure14.8 jamovi の Computed variable コマンドによる新しい尺度得点変数の計算

1. *Rj* エディタを使い、jamovi で行ったのと同じ指定 (つまり 5 因子・oblimin 回転) で *R* 上の EFA を実行し、最適重みづけ因子得点を計算します。因子得点を含む新しいデータセットをファイルに保存します。図 14.9 を参照してください。
2. その新しいファイルを jamovi で開き、変数の型が正しく設定されているか確認します。新しい因子得点変数に、対応する因子名や定義にしたがってラベルを付けます (なお、因子が期待した順序で並んでいないこともありますので、必ず確認してください)。

これで、因子にもとづく得点 (平均尺度得点のやり方) を使うか、*Rj* エディタで計算した最適重みづけ因子得点を使うかして、さらに分析を進められます。どちらを使うかは好み次第です。たとえば、パーソナリティの各尺度に性差があるかどうかを見てみたくなるかもしれません。因子にもとづく得点のやり方で計算した協調性の得点についてこれを行ってみたところ、プロット (図 14.11) では男性のほうが女性より協調性が低いように見えたが、有意な差ではありませんでした (Mann-Whitney の $U = 5760.5$, $p = .073$)。




Figure14.9 5 因子解の最適重みづけ因子得点を作成するための Rj エディタのコマンド

Data		Analyses																							
Exploration		T-Tests		ANOVA		Regression		Frequencies		Factor		Base R		Statkat		Linear Models		TOSTER		jpower		R		distrAC	
1	6	3	Females	27	0.063	-0.147	-0.656	0.768	-0.061																
2	6	1	Females	24	-0.767	-1.812	1.166	1.087	-0.206																
3	6	2	Females	19	-0.064	2.037	0.694	3.262	1.179																
4	6	2	Females	22	-0.070	0.966	2.388	2.924	1.308																
5	6	1	Females	32	0.965	-3.880	2.267	1.423	2.388																
6	4	1	Males	24	-2.003	0.071	-3.646	2.090	2.354																
7	5	3	Females	29	-1.684	-1.356	0.563	-0.776	-0.480																
8	5	5	Females	14	2.100	-0.700	-0.487	-2.038	-0.401																
9	5	4	Females	23	-0.772	-1.511	1.704	0.649	-1.940																
10	6	1	Females	51	0.588	-1.309	0.826	-1.745	-0.195																

Figure14.10 Rj エディタで作成された、5 つの因子得点変数を含む新しいデータファイル “bfiifactscores.csv”。新しい因子得点変数はそれぞれ、因子負荷量の表に並んでいる因子の順序に対応してラベルが付けられていることに注意




Figure14.11 因子にもとづく協調性得点の男女差の比較

14.1.3 EFA の結果をどう書くか

ここまでで、EFA とは何か、jamovi で EFA をどう実行するかについて、ある程度の感覚をつかんでいただけたのではないかと思います。では、EFA を終えたあと、それをどう書けばよいのでしょうか。EFA の書き方に公式の標準があるわけではなく、実例は分野や研究者によってまちまちです。とはいえ、書くときに含めるべきかなり標準的な情報というものはあります。

1. 研究している領域、とくに EFA によって明らかにしようとしている構成概念について、どのような理論的裏づけがあるのか。
2. 標本の記述 (たとえば人口統計学的情報、標本サイズ、標本抽出の方法)。
3. 使用したデータの種類 (たとえば名義尺度か連続量か) と記述統計。
4. EFA の仮定をどのように検討したか。球面性の確認と標本妥当性の指標についての詳細を報告すべきです。
5. どの因子抽出法 (たとえば最尤法) を使ったかの説明。
6. 最終的な解で因子をいくつ抽出するか、どの項目を選ぶかを決めるのに用いた基準と過程の説明。EFA の過程における重要な判断の根拠をはっきり説明してください。
7. どの回転法を試したか、その理由、そして結果の説明。

8. 最終的な因子負荷量は、結果のなかで表として報告すべきです。この表には各変数の独自性 (または共通性) も (最後の列に) 入れます。因子負荷量は項目番号だけでなく、内容のわかるラベルとともに報告してください。因子間相関も、この表の下部か別表として含めるべきです。
9. 抽出された因子には意味のある名前を付けるべきです。以前から使われている因子名を使ってもよいのですが、実際の項目と因子を検討した結果、別の名前のほうが適切だと思うこともあるでしょう。

14.2

主成分分析

前の節では、EFA が背後にある潜在因子を特定するために働くことを見ました。そして見てきたように、ひとつの使い方として、少数の潜在因子を何らかの合成因子得点の形にして、さらに別の統計分析に使うことができます。

このようなとき EFA は “データ縮約” の手法として使われています。データ縮約の手法にはもうひとつ、EFA の仲間とみなされることもある**主成分分析 (PCA)** があります。ただし PCA は、背後にある潜在因子を特定するものではありません。そうではなく、より多数の測定変数から線形の合成得点を作り出すものです。

PCA は、変数がどう共変するかについての仮定を置かずに、もとのデータに数学的な変換を施すだけのものです。PCA のねらいは、情報をあまり失わずに観測データを要約できるような、もとの変数の少数の線形結合 (成分) を計算することにあります。しかし、背後にある構造を特定することが分析の目的なのであれば、EFA のほうを選ぶべきです。そして見てきたように、EFA は主成分得点と同じようにデータ縮約の目的に使える因子得点を出してくれます (Fabrigar et al. 1999)。

PCA はいくつかの理由から心理学で広く使われてきましたので、取り上げる価値はあります。もっとも、いまではデスクトップ計算機の性能からすれば EFA も同じくらい簡単に実行できますし、とくに因子数や変数の数が少ない場合には、EFA のほうが PCA よりバイアスを受けにくいこともあります。先ほどと同じ `bfi_sample.csv` のデータを使います。手順の多くは EFA と似ていますので、概念的な違いはあるものの、実際の操作は同じです*⁶。そして標本が大きく、因子と変数の数が十分にあれば、PCA と EFA の結果はかなり似たものになるはずです。

*⁶... ということは、次の節で説明する PCA の手順にはかなりの繰り返しがあるということです。申し訳ありませんが、そこまでひどくはないと思いたいところです。

14.2.1 jamovi で PCA を実行する

`bfi_sample.csv` のデータを読み込んだら、jamovi のメインのボタナバーから *Factor - Principal Component Analysis* を選び、PCA の分析ウィンドウを開きます (図 14.12)。次に 25 のパーソナリティ項目を選択し、'Variables' のボックスに移します。'Assumption Checks' をはじめ、回転の 'Method'、抽出する 'Number of Factors'、'Additional Output' などの適切なオプションにチェックを入れます。この PCA で推奨されるオプションは図 14.12 をご覧ください。なお、回転の 'Method' と抽出する 'Number of Factors' は、後述するように、最良の結果を見つけるために分析の途中で調整していくのが普通です。

Principal Component Analysis

Variables

Method

Rotation: Oblimin

Hide loadings below: 0.3

Number of Components

Based on parallel analysis

Based on eigenvalue

Eigenvalues greater than: 1

Fixed number

1 component(s)

Assumption Checks

Bartlett's test of sphericity

KMO measure of sampling adequacy

Additional Output

Component summary

Component correlations

Initial eigenvalues

Scree plot

Figure14.12 jamovi の PCA 分析ウィンドウ

まず仮定を確認すると、(1) Bartlett の球面性検定が有意ですので、この仮定は満たされています。(2) 標本妥当性の KMO 指標 (MSA) は全体で 0.81 であり、標本妥当性は非常に良好だと言えます。ここでは問題なさそうですね。

次に確認すべきなのは、いくつの成分を使うか (データから “抽出” するか) です。EFA と同じく、3 つの異なるやり方があります。

- ひとつの慣例は、固有値が 1 より大きい成分をすべて選ぶというものです。今回のデータでは 2 成分になります。
- 図 14.14 のようなスクリープロットを調べると “変曲点” を見つけることができます。これはスクリー曲線の傾きがはっきりと平らになる点で、“肘” の下にあたります。これも、第 2 成分のあとではっきりと平坦になっていますので、2 成分ということになります。
- 平行分析という手法を使い、得られた固有値をランダムなデータから得られるであろう固有値と比較します。抽出される成分数は、ランダムなデータで得られる値より大きい固有値を持つ成分の数になります。

Fabrigar et al. (1999) によれば 3 つめのやり方がよいということですが、実際には研究者は 3 つすべてを見たうえで、もっとも解釈しやすい、あるいは解釈に役立つ成分数を判断する傾向があります。これは “意味の解釈可能性による基準” と理解できます。研究者はふつう、上のいずれかのやり方で得られた解に加えて、成分数を 1 つか 2 つ増やした解や減らした解も検討します。そのうえで、もっとも納得のいく解を採用するのです。

同時に、最終的な解をどう回転させるのがよいかも考える必要があります。これも EFA と同じで、回転には大きく 2 つのやり方があります。直交回転 (たとえば “varimax”) は選ばれた成分が無相関になるように強制するのに対し、斜交回転 (たとえば “oblimin”) は成分間に相関があることを許します。心理学者や行動科学者が関心を持つ次元は、直交していると期待できるようなものであることはあまりありませんので、斜交解のほうが理にかなっていると言えるでしょう。実際には、斜交回転で成分間にかなりの相関 (つまり > 0.3) が見られた場合には、斜交回転を選ぶという直感が裏づけられたことになります。成分が実際に相関しているのであれば、斜交回転のほうが直交回転よりも真の成分のよい推定値と、よりよい単純構造を与えてくれます。そして、斜交回転の結果、成分間の相関がほぼゼロだとわかったのであれば、研究者はそのまま直交回転を実行すればよいのです (その場合、斜交回転とほぼ同じ解が得られるはずです)。図 14.15 を見ると相関はどれも > 0.3 ではありませんので、直交回転 (varimax) に切り替えるのが適切です。

図 14.15 には、2 つの成分が説明するデータ全体の分散の割合も出ています。第 1 成分と第 2 成分は、それぞれ分散の 12% 強を説明しています。合わせると、5 成分解は観測データの分散の半分強 (56%) を説明していることになります。どんな PCA でも、原理的には観測変数と同じ数だけ成分を取ることができますが、成分を 1 つ増やすごとに、追加で説明される分散の量は小さくなって

Assumption Checks

Bartlett's Test of Sphericity

χ^2	df	p
2183.322	300	<.00001

KMO Measure of Sampling Adequacy

	MSA
Overall	0.809
A1	0.568
A2	0.838
A3	0.808
A4	0.837
A5	0.858
C1	0.804
C2	0.797
C3	0.754
C4	0.809
C5	0.851
E1	0.834
E2	0.843
E3	0.854
E4	0.870
E5	0.911
N1	0.737
N2	0.714
N3	0.762
N4	0.819
N5	0.800
O1	0.840
O2	0.688
O3	0.823
O4	0.742
O5	0.738

Figure14.13 パーソナリティ項目データについての jamovi PCA の仮定チェック

Scree Plot




Figure14.14 jamovi PCA によるパーソナリティ項目データのスクリープロット。第 5 成分のあとに平坦化の点, “肘”が見られる

いくということに注意してください。最初のいくつかの成分がもとの 25 変数の分散のかなりの部分を説明しているなら、それらの成分は 25 変数すべての代わりになる、明らかに有用でより単純なものだということになります。残りは、もとの変動をそれほど失うことなく捨てられるわけです。しかし、25 変数の分散の大部分を説明するのに 18 個の成分が必要なのであれば、もとの 25 変数をそのまま使えばよい、ということになります。

図 14.16 は成分負荷量を示しています。つまり、25 のパーソナリティ項目が、選ばれた成分のそれぞれにどう負荷しているかということです。実質的な負荷量を持つ項目に関心があったこと、また閾値を 0.4 と高めに設定したほうがすっきりしたわかりやすい解になったことから、0.4 未満の負荷量は非表示にしてあります (図 14.12 のオプションで設定します)。

第 1, 第 2, 第 3, 第 4 成分については、成分負荷量のパターンが図 14.2 で想定されていた因子とよく一致しています。そして第 5 成分もかなり近く, “開放性” を測ると想定されていた 5 つの観測変数のうち 4 つが、この成分にきれいに負荷しています。ただし変数 04 はどうも収まりが悪いようです。図 14.16 の成分解を見ると、この変数は (比較的低い負荷量ではありますが) 第 4 成分に負荷しており、第 5 成分には実質的に負荷していません。

図 14.16 では、各変数の “独自性” も見ることができます。独自性とは、その変数に “固有” で成

Component Statistics

Summary				
Component	SS	Loadings	% of Variance	Cumulative %
1		3.136	12.542	12.542
2		3.090	12.361	24.903
3		2.856	11.425	36.328
4		2.682	10.729	47.056
5		2.272	9.086	56.143

Correlation Matrix					
	1	2	3	4	5
1	—	−0.136	−0.124	0.025	−0.090
2		—	0.259	0.175	0.136
3			—	0.091	0.108
4				—	0.118
5					—

Figure14.15 jamovi PCA による 5 成分分解の成分要約統計量と成分間相関

分によって説明されない分散の割合のことです。たとえば、'A1' の分散の 58% は 5 成分分解の成分では説明されていません。これに対して 'N1' は、成分分解で説明されない分散が比較的小さくなっています (30%)。"独自性" が大きいほど、その変数の成分モデルにおける関連性や寄与は小さいということに注意してください。

ここまでで、jamovi で PCA をどう実行するか、そして PCA が概念的には EFA と異なるものの、実際には (適切なデータであれば) かなり似たものであることについて、おおよその見当がついたのではないかと思います。

成分得点の作成も、EFA とほぼ同じやり方で進められます。ただし、最適に重みづけした成分得点の指標を作る道を選んだ場合には、jamovi の Rj エディタでのコマンドと文法が少し異なります。図 14.17 を見てください。

Component Loadings

	Component					Uniqueness
	1	2	3	4	5	
A1				-0.554		0.581
A2				0.743		0.411
A3				0.735		0.384
A4				0.515		0.544
A5				0.597		0.463
C1			0.746			0.392
C2			0.741			0.395
C3			0.621			0.582
C4			-0.673			0.399
C5			-0.634			0.430
E1		-0.664				0.547
E2		-0.746				0.318
E3		0.656				0.387
E4		0.661		0.409		0.362
E5		0.585				0.492
N1	0.809					0.298
N2	0.812					0.314
N3	0.785					0.370
N4	0.652	-0.405				0.386
N5	0.592					0.503
O1					0.634	0.486
O2					-0.632	0.505
O3					0.673	0.361
O4				0.429		0.557
O5					-0.669	0.496

Note. 'varimax' rotation was used

Figure14.16 jamovi PCA による 5 成分分解の成分負荷量

.....

14.3




Figure14.17 5 成分分解の最適重みづけ成分得点を作成するための Rj エディタのコマンド

確認的因子分析

さて、パーソナリティの項目プールから注意深く選んだ質問を使い、EFA で背後の潜在因子を特定しようとした試みは、かなりうまくいったように見えました。役に立つパーソナリティ測定尺度を開発するという道のりの次のステップは、最初の EFA で特定した潜在因子を、別の標本で確認することです。その因子が持ちこたえるかどうか、別のデータでその存在を確認できるかどうかを見たいのです。これから見るように、こちらはより厳密な確認になります。これは**確認的因子分析 (CFA)**と呼ばれます。当然といえば当然ですが、あらかじめ指定した潜在因子構造を確認しようとするからです*7。

CFA では、探索的な意味でデータがどうまとまるかを見る分析をするのではなく、図 14.18 のような構造をデータに課したうえで、あらかじめ指定した構造にデータがどれだけよく当てはまるかを見ます。この意味で、あらかじめ指定した**モデル**が観測データによってどれだけ確認されるかを見

*7余談ですが、最初の“想定される”因子についてかなりしっかりした見通しを持っていたのですから、EFA の段階を飛ばしていきなり CFA に進むこともできました。EFA をやってから CFA に進むか、いきなり CFA に進むかは判断の問題で、モデル (因子数と変数について) がおおそ正しいという確信が最初にどれだけあるかによります。尺度開発の初期や、背後にある潜在的な構成概念を特定する段階では、研究者は EFA を使う傾向があります。その後、最終的な尺度に近づいてきた段階や、確立された尺度を新しい標本で確認したい場合には、CFA がよい選択肢になります。

る、確認的な分析を行っているわけです。

ですからパーソナリティ項目の素直な確認的因子分析 (CFA) は、図 14.18 に示したように 5 つの潜在因子を指定し、それぞれが 5 つの観測変数で測定される、という形になります。各変数は、背後にある潜在因子の測定値です。たとえば A1 は、背後にある潜在因子である協調性によって予測されます。そして A1 は協調性因子の完全な測定値ではありませんので、誤差項 e が付いています。つまり e は、A1 の分散のうち協調性因子では説明されない部分を表しています。これは測定誤差と呼ばれることもあります。

次に考えるべきは、モデルの中で潜在因子どうしが相関することを許すかどうかです。先に述べたように、心理学や行動科学では構成概念どうしが関連していることが多いですし、今回のパーソナリティ因子のいくつかも互いに相関しているだろうと考えられます。ですからモデルでは、図 14.18 の双方向の矢印で示されているように、これらの潜在因子が共変することを許すべきです。

同時に、誤差項のいくつかが互いに相関することについて、何かもっともな系統的理由があるかどうかもあるべきです。その理由のひとつは、観測変数の特定の部分集合に共通する方法論的な特徴があって、実質的な潜在因子ではなく方法論的な理由で観測変数が相関している、という場合でしょう。この可能性についてはあとの節で扱いますが、いまのところ、誤差項どうしを相関させることを正当化できるような明らかな理由は見当たりません。

誤差項の相関がないとすると、観測データとの当てはまりを検討するモデルは、図 14.18 に指定したとおりのものになります。モデルに含まれるパラメータだけがデータに存在すると想定されますので、CFA ではそれ以外のありうるパラメータ (係数) はすべてゼロに固定されます。ですから、それらのパラメータがゼロでない場合 (たとえば観測データでは A1 が潜在因子である外向性にかなり負荷しているのに、モデルにはその経路がない場合)、モデルと観測データの当てはまりは悪くなるでしょう。

それでは、この CFA 分析を jamovi でどう設定するかを見ていきましょう。

14.3.1 jamovi での CFA

bfi_sample2.csv ファイルを開き、25 の変数が順序尺度 (あるいは連続量。この分析では違いはありません) としてコード化されていることを確認してください。jamovi で CFA を実行するには、次のようにします。

- jamovi のメインのボタンバーから **Factor - Confirmatory Factor Analysis** を選び、CFA の分析ウィンドウを開きます (図 14.19)。
- 5 つの A 変数を選んで 'Factors' のボックスに移し、"Agreeableness" というラベルを付けます。
- 'Factors' のボックスに新しい因子を作り、"Conscientiousness" というラベルを付けます。5




Figure14.18 CFA で用いる, 5 因子パーソナリティ尺度の潜在因子構造の当初の事前指定

- つの **C** 変数を選び, “Conscientiousness” のラベルの下に移します。
- さらに新しい因子を作り, “Extraversion” というラベルを付けます。5 つの **E** 変数を選び, “Extraversion” のラベルの下に移します。
 - さらに新しい因子を作り, “Neuroticism” というラベルを付けます。5 つの **N** 変数を選び, “Neuroticism” のラベルの下に移します。
 - さらに新しい因子を作り, “Openness” というラベルを付けます。5 つの **O** 変数を選び, “Openness” のラベルの下に移します。
 - そのほかのオプションも適宜チェックします。最初にひととおりやってみる分には既定のままで問題ありませんが, ‘Plots’ の下にある “Path diagram” のオプションにチェックを入れると, 図 14.18 とかなりよく似た図を jamovi が描いてくれます。

分析の設定ができれば, jamovi の結果ウィンドウに目を移して, どうなっているかを見ていきましょう。まず見るべきは**モデル適合度** (図 14.20) です。これがモデルと観測データの当てはまりのよさを教えてくれます。なお今回のモデルでは, あらかじめ指定した共分散だけが推定されます。既定では因子間相関も含まれます。それ以外はすべてゼロに固定されています。

モデル適合度の評価にはいくつかのやり方があります。ひとつめはカイ二乗統計量で, 値が小さければモデルがデータによく当てはまっていることを示します。しかしモデル適合度の評価に使うカイ二乗統計量は標本サイズにかなり敏感です。つまり標本が大きければ, モデルとデータの当てはまりが十分によくても, ほとんど常に大きく有意 ($p < .05$) なカイ二乗値が出てしまうということです。

ですから, モデル適合度を評価する別のやり方が必要になります。jamovi では既定でいくつか提供されています。比較適合度指標 (CFI), Tucker-Lewis 指標 (TLI), そして近似の平均二乗誤差平方根 (RMSEA) と, その RMSEA の 90% 信頼区間です。役に立つ経験則としては, $CFI > 0.9$, $TLI > 0.9$, RMSEA が 0.05 から 0.08 程度であれば満足できる当てはまりだとされます。よい当てはまりは, $CFI > 0.95$, $TLI > 0.95$, RMSEA と RMSEA の信頼区間上限が < 0.05 です。

さて図 14.20 を見ると, カイ二乗値は大きく, 非常に有意です。標本サイズはそれほど大きくありませんので, これは当てはまりが悪いことを示しているのかもしれませんが。CFI は 0.762, TLI は 0.731 で, モデルとデータの当てはまりが悪いことを示しています。RMSEA は 0.085, 90% 信頼区間は 0.077 から 0.092 で, これもよい当てはまりを示すものではありません。

がっかりですね。とはいえ, 先ほど似たデータセットで行った EFA(セクション 14.1) でも, 5 因子モデルが説明していたのはデータの分散の半分程度でしたから, それほど驚くことでもないかもしれません。

続いて, 図 14.21 と図 14.22 に示された因子負荷量と因子間共分散の推定値を見てみましょう。これらのパラメータの Z 統計量と p 値を見ると, どれもモデルにそれなりの寄与をしている (つまりゼロではない) ことがわかりますので, 指定した変数と因子のあいだの経路や, 因子間の相関をモデルから取り除く理由はなさそうです。標準化推定値のほうが解釈しやすいことが多く, これは




Figure14.19 jamovi の CFA 分析ウィンドウ

Model Fit

Test for Exact Fit				
χ^2	df	p		
739.726	265	<.00001		

Fit Measures				
CFI	TLI	RMSEA	RMSEA 90% CI	
			Lower	Upper
0.762	0.731	0.085	0.077	0.092

Figure14.20 今回の CFA モデルについての jamovi CFA のモデル適合度の結果

.....

‘Estimates’ のオプションで指定できます。これらの表は、報告書や学術論文にそのまま載せるのに便利です。

どうすればモデルを改善できるでしょうか。ひとつの選択肢は、何段階か戻って、使っている項目や測定について、どう改善したり変更したりできるかを考え直すことです。もうひとつの選択肢は、当てはまりをよくするためにモデルへ事後的な手直しを加えることです。そのやり方のひとつが“修正指標”を使うことで、jamovi では ‘Additional output’ のオプションで指定します (図 14.23 参照)。

探すのは、もっとも大きい修正指標 (MI) の値です。そのうえで、事後的な理由づけによって、その項をモデルに追加することが理にかなっているかどうかを判断します。たとえば図 14.23 を見ると、まだモデルに入っていない因子負荷量のうち MI が最大なのは、N4(“よく気分が落ち込む”) の潜在因子である外向性への負荷で、値は 28.786 です。これは、この経路をモデルに追加すればカイ二乗値がおおよそ同じだけ減る、ということを示しています。

しかし今回のモデルでこの経路を追加することは、理論的にも方法論的にもあまり意味がないと言えますので、よい考えではありません (“よく気分が落ち込む” が神経症傾向と外向性の両方を測っているという説得力のある議論を思いつけるなら別ですが)。私にはもっともな理由が思いつきません。とはいえ議論のために、意味があるということにして、この経路をモデルに追加してみましよう。CFA の分析ウィンドウ (図 14.19 参照) に戻り、N4 を外向性の因子に追加します。すると CFA の結果が変わります (結果は省略します)。カイ二乗値は 709 程度まで下がり (約 30 の減少で、MI の大きさとだいたい同じです)、他の適合度指標も少しではありますが改善します。しかしそれでは足りません。依然としてよく当てはまるモデルではないのです。

Factor Loadings						
Factor	Indicator	Estimate	SE	Z	p	Stand. Estimate
Agreeableness	A1	-0.468	0.099	-4.727	<.00001	-0.328
	A2	0.771	0.079	9.761	<.00001	0.621
	A3	1.061	0.082	13.002	<.00001	0.788
	A4	0.749	0.096	7.830	<.00001	0.516
	A5	0.941	0.082	11.443	<.00001	0.711
Conscientiousness	C1	0.802	0.076	10.531	<.00001	0.670
	C2	0.747	0.087	8.558	<.00001	0.569
	C3	0.539	0.087	6.191	<.00001	0.421
	C4	-1.067	0.086	-12.414	<.00001	-0.760
	C5	-1.121	0.104	-10.775	<.00001	-0.678
Extraversion	E1	-0.898	0.106	-8.512	<.00001	-0.550
	E2	-1.261	0.100	-12.667	<.00001	-0.761
	E3	0.911	0.092	9.889	<.00001	0.627
	E4	1.040	0.092	11.278	<.00001	0.692
	E5	0.778	0.083	9.370	<.00001	0.596
Neuroticism	N1	1.339	0.094	14.174	<.00001	0.821
	N2	1.215	0.093	13.067	<.00001	0.765
	N3	1.217	0.097	12.487	<.00001	0.747
	N4	0.956	0.110	8.715	<.00001	0.574
	N5	0.842	0.110	7.631	<.00001	0.494
Openness	O1	0.665	0.082	8.119	<.00001	0.580
	O2	-0.653	0.115	-5.660	<.00001	-0.403
	O3	0.999	0.088	11.301	<.00001	0.831
	O4	0.233	0.085	2.735	0.00624	0.197
	O5	-0.514	0.093	-5.521	<.00001	-0.405

Figure14.21 今回の CFA モデルについての jamovi CFA の因子負荷量の表

MI の値を使ってモデルに新しいパラメータを追加していく場合には、追加のたびに必ず MI の表を確認し直してください。MI は毎回更新されるからです。

jamovi は残差共分散の修正指標の表も出力します (図 14.24)。つまり、どの誤差間相関をモデルに追加すればモデル適合度がもっとも改善するかを示す表です。2 つの MI の表を同時に見渡して最大の MI を見つけ、示されたパラメータの追加が妥当に正当化できるかどうかを考え、できるならモデルに追加する、というやり方がよいでしょう。そして再計算された結果で、また最大の MI を探し始めるわけです。

最大の MI にもとづいてパラメータを追加していけば、好きなだけこのやり方を続けられますし、

Factor Covariances		Estimate	SE	Z	p	Stand. Estimate
Agreeableness	Agreeableness	1.000 ^a				
	Conscientiousness	0.335	0.074	4.507	<.00001	0.335
	Extraversion	0.581	0.063	9.213	<.00001	0.581
	Neuroticism	-0.164	0.077	-2.140	0.03233	-0.164
	Openness	0.424	0.071	5.948	<.00001	0.424
Conscientiousness	Conscientiousness	1.000 ^a				
	Extraversion	0.504	0.065	7.756	<.00001	0.504
	Neuroticism	-0.289	0.074	-3.917	0.00009	-0.289
	Openness	0.277	0.081	3.440	0.00058	0.277
Extraversion	Extraversion	1.000 ^a				
	Neuroticism	-0.238	0.076	-3.122	0.00179	-0.238
	Openness	0.532	0.067	7.949	<.00001	0.532
Neuroticism	Neuroticism	1.000 ^a				
	Openness	-0.182	0.078	-2.320	0.02033	-0.182
Openness	Openness	1.000 ^a				

^a fixed parameter

Figure14.22 今回の CFA モデルについての jamovi CFA の因子間共分散の表

いずれは満足のいく当てはまりに到達するでしょう。しかしそうしているうちに、怪物を作り出してしまふ可能性も大いにあります。醜くゆがんでいて、理論的な意味も純粋さも持たないモデルです。つまり、くれぐれも気をつけてください。

ここまでで、EFA で得られた因子構造を、第 2 の標本と CFA を使って検討してきました。残念ながら、EFA で得られた因子構造が CFA で確認されるという結果にはなりませんので、このパーソナリティ尺度の開発については振り出しに戻る、ということになります。

修正指標を使って CFA を手直しすることもできたのですが、示された追加の因子負荷量や残差共分散を含めるもっともな理由は (私が思いつく限り) 本当にありませんでした。とはいえ、残差の共変 (相関) を許すもっともな理由がある場合もあります。そのよい例が、次の節で扱う**多特性多方法 (MTMM)** の CFA です。その前に、CFA の結果をどう報告するかを見ておきましょう。

14.3.2 CFA の結果をどう報告するか

CFA の書き方に公式の標準があるわけではなく、実例は分野や研究者によってまちまちです。とはいえ、書くときに含めるべきかなり標準的な情報というものがあります。

1. 仮定したモデルの理論的・経験的な正当化。

Factor Loadings – Modification Indices

	Agreeableness	Conscientiousness	Extraversion	Neuroticism	Openness
A1		11.138	14.214	1.532	0.391
A2		1.203	1.018	3.645	0.534
A3		1.760	4.695	2.952	0.001
A4		6.992	4.152	0.060	2.299
A5		3.843	11.412	8.179	3.501
C1	4.215		1.962	0.545	0.147
C2	1.399		0.009	12.077	0.007
C3	0.849		1.542	12.774	0.863
C4	0.960		1.053	2.708	0.214
C5	0.226		1.028	4.746	0.206
E1	13.545	0.501		1.357	3.139
E2	5.360	1.670		19.013	2.334
E3	4.395	5.853		6.202	28.017
E4	22.831	1.511		0.302	9.370
E5	2.400	8.775		2.507	2.894
N1	1.147	0.591	1.083		0.147
N2	1.034	9.833	7.580		3.178
N3	0.207	0.007	0.013		0.009
N4	1.653	14.031	28.786		0.652
N5	1.129	0.028	0.843		2.896
O1	0.069	0.190	1.889	0.280	
O2	6.429	2.426	8.060	6.849	
O3	2.711	2.093	7.699	1.037	
O4	1.851	13.387	10.541	8.873	
O5	1.584	4.494	2.974	2.188	

Figure14.23 jamovi CFA の因子負荷量の修正指標

2. モデルをどう指定したかの完全な記述 (たとえば各潜在因子の指標変数, 潜在変数間の共分散, 誤差項間の相関)。図 14.20 のようなパス図も入れるとよいでしょう。
3. 標本の記述 (たとえば人口統計学的情報, 標本サイズ, 標本抽出の方法)。
4. 使用したデータの種類 (たとえば名義尺度か連続量か) と記述統計。
5. 仮定の検討と, 用いた推定法。
6. 欠測データの記述と, 欠測データをどう扱ったか。
7. モデルの推定に用いたソフトウェアとそのバージョン。
8. モデル適合度の判断に用いた指標と基準。

Residual Covariances – Modification Indices																									
	A1	A2	A3	A4	A5	C1	C2	C3	C4	C5	E1	E2	E3	E4	E5	N1	N2	N3	N4	N5	O1	O2	O3	O4	O5
A1																									
A2	7.930																								
A3		4.452																							
A4			0.082																						
A5				0.012																					
C1					3.049																				
C2						1.326																			
C3							1.987																		
C4								1.010																	
C5									3.241																
E1										5.870															
E2											0.040														
E3												0.102													
E4													0.835												
E5														0.057											
N1															6.913										
N2																1.660									
N3																	1.165								
N4																		0.946							
N5																			0.200						
O1																				1.771					
O2																					1.171				
O3																						0.846			
O4																							0.803		
O5																								8.111	
																									0.210
																									12.008
																									0.424
																									2.739
																									2.700
																									0.059
																									0.168
																									0.056
																									8.834
																									0.692
																									4.285
																									4.085
																									5.080
																									6.374
																									6.642
																									0.926
																									0.027
																									0.017
																									11.442
																									2.860
																									0.597
																									1.115
																									0.043
																									10.044
																									0.419
																									0.017
																									16.896
																									2.672
																									1.115
																									0.300
																									0.233
																									0.419
																									0.895
																									0.210
																									0.753
																									0.088
																									0.817
																									0.090
																									0.021
																									6.966
																									10.891
																									0.742
																									1.919
																									0.128
																									3.257
																									0.332
																									4.687
																									0.060
																									3.045
																									12.948
																									3.236
																									2.928
																									0.173

Figure14.24 jamovi CFA の残差共分散の修正指標

9. モデル適合度や修正指標にもとづいて当初のモデルに加えた変更。
10. すべてのパラメータ推定値 (つまり負荷量, 誤差分散, 潜在変数の分散・共分散) とその標準誤差。おそらく表の形で。

14.4

多特性多方法 CFA

この節では、測定の技法や質問の違いが、データの変動の重要な源になりうることを考えます。これは**方法分散**として知られています。そのために、“帰属スタイル”についてのデータを含む、別の心理学のデータセットを使います。

帰属スタイル質問紙 (ASQ) を用いた [Hewitt, Foxcroft, and MacDonald \(2004\)](#) は、イギリスとニュージーランドの若者から心理的ウェルビーイングのデータを集めました。彼らが測定したのはネガティブな出来事に対する帰属スタイル、つまり自分の身に起きた悪い出来事の原因を人が習慣的にどう説明するか、というものです ([Peterson and Seligman 1984](#))。帰属スタイル質問紙 (ASQ) は、帰属スタイルの 3 つの側面を測定します。

- 内在性は、悪い出来事の原因が自分自身の行動によるものだと、その人がどの程度信じているかです。
- 安定性は、悪い出来事の原因が時間を通じて安定していると、その人がどの程度習慣的に信じているかです。
- 全般性は、ある領域での悪い出来事の原因が生活の他の領域にも影響すると、その人がどの程度習慣的に信じているかです。

仮想的な場面が 6 つあり、各場面について回答者は (a) 内在性, (b) 安定性, (c) 全般性をねらった質問に答えます。ですから全部で $6 \times 3 = 18$ 項目になります。詳しくは図 [14.25](#) をご覧ください。

研究者の関心は、ASQ の 18 の観測変数によってそれなりにうまく測定されている潜在因子があるかどうかを、データを確認して調べることにあります。

まず彼らはこの 18 変数で EFA を試してみますが (結果は省略します)、どう抽出しても、どう回転しても、よい因子解が見つかりません。帰属スタイル質問紙 (ASQ) の背後にある潜在因子を特定しようという試みは、実を結びませんでした。こうした結果が出た場合、理論が間違っている (帰属スタイルには潜在因子構造など存在しない、というのはありうる話です) か、標本が不適切である (イギリスとニュージーランドの若年成人からなるこの標本の大きさと特性からすると、これは考えにくいでしょう) か、あるいは分析手法がこの仕事に適した道具ではなかった、のいずれかです。ここでは 3 つめの可能性を見ていくことにします。

1. YOU HAVE BEEN LOOKING FOR A JOB UNSUCCESSFULLY FOR SOME TIME

(a) Is the cause of your unsuccessful job search due to something about you or something about other people or circumstances?

Totally due to other people or circumstances 1 2 3 4 5 6 7 **Totally due to me**

(b) In the future, when looking for a job, will this cause again be present?

Will never again be present 1 2 3 4 5 6 7 **Will always be present**

(c) Is the cause something that just influences looking for a job, or does it also influence other areas of your life?

Influences just this particular situation 1 2 3 4 5 6 7 **Influences all situations in my life**

Other hypothetical scenarios, each answered with (a), (b) and (c) in the same sort of way

2. A FRIEND COMES TO YOU WITH A PROBLEM AND YOU DON'T TRY TO HELP

3. YOU GIVE AN IMPORTANT TALK IN FRONT OF A GROUP AND THE AUDIENCE REACTS NEGATIVELY

4. YOU MEET A FRIEND WHO IS HOSTILE TOWARDS YOU

5. YOU CAN'T GET ALL THE WORK DONE THAT OTHERS EXPECT OF YOU

6. YOU GO OUT ON A DATE AND IT GOES BADLY

Figure14.25 ネガティブな出来事についての帰属スタイル質問紙 (ASQ)

ASQ で測定されていた次元は内在性・安定性・全般性の3つで、図 14.26 に示すように、それぞれ6つの質問で測られていたことを思い出してください。

Internality	Stability	Globality
Q1a	Q1b	Q1c
Q2a	Q2b	Q2c
Q3a	Q3b	Q3c
Q4a	Q4b	Q4c
Q5a	Q5b	Q5c
Q6a	Q6b	Q6c

Figure14.26 ASQ における内在性・安定性・全般性の各次元の6つの質問




Figure14.27 ASQ の潜在因子構造の当初の事前指定

探索的な意味でデータがどうまとまるかを見る分析をするのではなく、図 14.26 のような構造をデータに課したうえで、あらかじめ指定した構造にデータがどれだけよく当てはまるかを見る、としたらどうでしょうか。この意味で、あらかじめ指定したモデルが観測データによってどれだけ確認されるかを見る、確認的な分析を行うことになります。

ですから ASQ の素直な確認的因子分析 (CFA) は、図 14.26 の列に示したように 3 つの潜在因子を指定し、それぞれが 6 つの観測変数で測定される、という形になります。

これは図 14.27 のように描くことができます。各変数が背後にある潜在因子の測定値であることが示されています。たとえば INT1 は、背後にある潜在因子である内在性によって予測されます。そして INT1 は内在性因子の完全な測定値ではありませんので、誤差項 $e1$ が付いています。つまり $e1$ は、INT1 の分散のうち内在性因子では説明されない部分を表しています。これは“測定誤差”と呼ばれることもあります。

次に考えるべきは、モデルの中で潜在因子どうしが関連することを許すかどうかです。先に述べたように、心理学や行動科学では構成概念どうしが関連していることが多いですし、内在性・安定性・全般性も互いに関連しているだろうと考えられますので、モデルでは、図 14.28 に示すようにこれらの潜在因子が共変することを許すべきです。

同時に、誤差項のいくつかが互いに関連することについて、何かもっともな系統的理由があるかどうかとも考えるべきです。ASQ の質問を思い返すと、主要な質問 (1 から 6) のそれぞれに、3 つの下位質問 ($a \cdot b \cdot c$) がありました。Q1 は就職活動がうまくいかないことについての質問でしたので、この質問には他の質問 (2 から 5) にはない独特の人工的あるいは方法論的な側面が、おそらく就職活動に関わる何かとして、あると考えるのはもっともです。同じように Q2 は、困っている友人を助けなかったことについての質問でしたので、他の質問 (1 と 3 から 5) にはない、友人を助けないことに関わる独特の人工的あるいは方法論的な側面があるかもしれません。

つまり ASQ には複数の因子だけでなく、複数の方法論的特徴もあるわけです。質問 1 から 6 はそれぞれ少しずつ異なる“方法”を持っていますが、その“方法”は下位質問 $a \cdot b \cdot c$ で共有されています。こうした異なる方法論的特徴をモデルに取り込むために、特定の誤差項どうしが関連していると指定することができます。たとえば INT1, STAB1, GLOB1 に付いている誤差は、 $Q1a \cdot Q1b \cdot Q1c$ に固有で共有されている方法論的分散を反映して、互いに関連しているとすべきです。図 14.26 で言えば、列で表される潜在因子に加えて、表の各行の変数について測定誤差が関連している、ということになります。

図 14.27 に示したような基本的な CFA モデルを観測データに対して検討することもできますが、実際には図 14.28 に示すような、より洗練されたモデルにたどり着きました。この洗練された CFA モデルは**多特性多方法 (MTMM)** モデルとして知られており、これを jamovi で検討していきます。




Figure14.28 CFA MTMM モデルにおける，ASQ の潜在因子構造の最終的な事前指定。潜在因子間の相関と，観測変数 INT1・STAB1・GLOB1 について共有された方法による誤差項の相関を含む。見やすさのため，そのほかの事前指定された誤差項の相関は示していない。

14.4.1 jamovi での MTMM CFA

ASQ.csv ファイルを開き、18 の変数 (“内在性”6 つ, “安定性”6 つ, “全般性”6 つ) が連続変数として指定されていることを確認してください。

jamovi で MTMM CFA を実行するには、次のようにします。

- jamovi のメインのボタンバーから **Factor - Confirmatory Factor Analysis** を選び、CFA の分析ウィンドウを開きます (図 14.29)。
- 6 つの INT 変数を選んで ‘Factors’ のボックスに移し, “Internality” というラベルを付けます。
- ‘Factors’ のボックスに新しい因子を作り, “Stability” というラベルを付けます。6 つの STAB 変数を選び, “Stability” のラベルの下に移します。
- さらに新しい因子を作り, “Globality” というラベルを付けます。6 つの GLOB 変数を選び, “Globality” のラベルの下に移します。
- **Residual Covariances** のオプションを開き, あらかじめ指定した相関のそれぞれについて, 該当する変数を右の ‘Residual Covariances’ のボックスに移します。たとえば INT1 と STAB1 の両方を選択して矢印をクリックし, 移動させます。同じことを INT1 と GLOB1, STAB1 と GLOB1, INT2 と STAB2, INT2 と GLOB2, STAB2 と GLOB2, INT3 と STAB3, という具合に続けていきます。
- そのほかのオプションも適宜チェックします。最初にひととおりやってみる分には既定のままでも問題ありませんが, ‘Plots’ の下にある “Path diagram” のオプションにチェックを入れると, 図 14.28 とかなりよく似た図を, ただし上で追加した誤差項の相関をすべて含んだ形で, jamovi が描いてくれます。

分析の設定ができれば, jamovi の結果ウィンドウに目を移して, どうなっているかを見ていきましょう。まず見るべきは “Model fit” です。これがモデルと観測データの当てはまりのよさを教えてくれます。なお今回のモデルでは, あらかじめ指定した共分散だけが推定され, それ以外はすべてゼロに固定されています。ですからモデル適合度は, あらかじめ指定した “自由な” パラメータがゼロでないかどうかと, 逆にデータの中のそれ以外の関係, つまりモデルで指定しなかった関係をゼロのままにしておけるかどうかの, 両方を検討していることになります。

モデル適合度の評価にはいくつかのやり方があります。ひとつめはカイ二乗統計量で, 値が小さければモデルがデータによく当てはまっていることを示します。しかしモデル適合度の評価に使うカイ二乗統計量は標本サイズに非常に敏感です。つまり標本が大きい (300 から 400 ケースを超える) 場合, モデルとデータの当てはまりが十分によくても, ほとんど常に大きく有意なカイ二乗値が出てしまうということです。

ですから, モデル適合度を評価する別のやり方が必要になります。jamovi では既定でいくつか提供されています。比較適合度指標 (CFI), Tucker 適合度指標 (TFI), そして近似の平均二乗誤差




Figure14.29 jamovi の CFA 分析ウィンドウ

平方根 (RMSEA) と、その RMSEA の 90% 信頼区間です。先に述べたように、役に立つ経験則としては、 $CFI > 0.9$, $TLI > 0.9$, RMSEA が 0.05 から 0.08 程度であれば満足できる当てはまりだとされます。よい当てはまりは、 $CFI > 0.95$, $TLI > 0.95$, RMSEA と RMSEA の信頼区間上限が < 0.05 です。

さて図 14.30 を見ると、カイ二乗値は非常に有意ですが、標本サイズが大きい ($N = 2748$) ことを考えれば驚くことではありません。CFI は 0.98, TLI も 0.98 で、非常によい当てはまりを示しています。RMSEA は 0.02, 90% 信頼区間は 0.02 から 0.02 で、かなり狭いですね。

全体として、あらかじめ指定したモデルが観測データに非常によく当てはまっていると考えて満足してよいでしょう。ASQ についての MTMM モデルは支持されたわけです。

Model Fit

Test for Exact Fit				
χ^2	df	p		
243.97	114	<.00001		

Fit Measures				
CFI	TLI	RMSEA	RMSEA 90% CI	
			Lower	Upper
0.98	0.98	0.02	0.02	0.02

Figure14.30 今回の CFA MTMM モデルについての jamovi CFA のモデル適合度の結果

続いて、図 14.31 のように因子負荷量と因子間共分散の推定値を見ていきましょう。標準化推定値のほうが解釈しやすいことが多く、これは ‘Estimates’ のオプションで指定できます。これらの表は、報告書や学術論文にそのまま載せるのに便利です。

図 14.31 を見ると、あらかじめ指定した因子負荷量と因子間共分散はすべてゼロと有意に異なっていることがわかります。つまりどれもモデルに有用な寄与をしているようです。

今回の分析は運がよく、最初の試みで非常によい当てはまりが得られました。これはかなり珍しいことで、CFA では当てはまりをよくするために、モデルへ事後的な手直しを加えられることがよくあります。そのやり方のひとつが “修正指標” を使うことで、jamovi では ‘Additional output’ のオプションで指定します。

探すのは、もっとも大きい修正指標 (MI) の値です。そのうえで、事後的な理由づけによって、そ

の項をモデルに追加することが理にかなっているかどうかを判断します。たとえば図 14.32 を見ると、まだモデルに入っていない因子負荷量のうち MI が最大なのは、INT6 の潜在因子である全般性への負荷で、値は 24.52 です。これは、この経路をモデルに追加すればカイ二乗値がおよそ 25 減る、ということを示しています。しかし今回のモデルでこの経路を追加することは、理論的にも方法的にもあまり意味がありませんので、修正版のモデルにこの経路を含めることはしません。

Confirmatory Factor Analysis

Factor Loadings						
Factor	Indicator	Estimate	SE	Z	p	Stand. Estimate
Internality	INT1	0.55	0.05	12.28	<.00001	0.34
	INT2	0.50	0.05	10.52	<.00001	0.28
	INT3	0.61	0.04	13.95	<.00001	0.38
	INT4	0.64	0.05	13.45	<.00001	0.36
	INT5	0.54	0.04	12.52	<.00001	0.33
	INT6	0.66	0.04	16.50	<.00001	0.45
Stability	STAB1	0.53	0.04	14.97	<.00001	0.35
	STAB2	0.48	0.03	14.54	<.00001	0.34
	STAB3	0.69	0.03	20.20	<.00001	0.46
	STAB4	0.65	0.03	20.72	<.00001	0.47
	STAB5	0.67	0.03	21.47	<.00001	0.49
	STAB6	0.66	0.03	22.17	<.00001	0.51
Globality	GLOB1	0.71	0.04	18.16	<.00001	0.40
	GLOB2	0.73	0.04	20.32	<.00001	0.44
	GLOB3	0.93	0.04	25.10	<.00001	0.54
	GLOB4	0.83	0.03	24.99	<.00001	0.53
	GLOB5	0.76	0.03	22.71	<.00001	0.48
	GLOB6	0.96	0.03	27.66	<.00001	0.59

Factor Estimates

Factor Covariances						
		Estimate	SE	Z	p	Stand. Estimate
Internality	Internality	1.00 ^a				
	Stability	0.52	0.03	17.10	<.00001	0.52
	Globality	0.45	0.03	14.96	<.00001	0.45
Stability	Stability	1.00 ^a				
	Globality	0.70	0.02	35.47	<.00001	0.70
Globality	Globality	1.00 ^a				

^a fixed parameter

Figure14.31 今回の CFA MTMM モデルについての jamovi CFA の因子負荷量と共分散の表

同じように残差項の MI(図 14.33) を見ると、最大の MI は INT1 と INT3 の誤差の共変を許す、つまりモデルに含めることについての 13.48 です。しかしこれはとくに高い MI ではありませんし、このパラメータをモデルに含める妥当な根拠もありませんし、すでにより当てはまりが得られています。ですからここでも答えは、修正しない、です。

MI を使ってモデルに新しいパラメータを追加していく場合には、追加のたびに (あるいは除外のたびに。ソフトウェアによっては、モデル適合度を改善するために取り除くべきパラメータを MI が示すこともあります) 必ず MI の表を確認し直してください。MI は毎回更新されるからです。

Factor Loadings – Modification Indices			
	Internality	Stability	Globality
INT1		1.41	0.16
INT2		4.86e-4	0.03
INT3		5.47	6.61
INT4		1.05e-6	2.66
INT5		0.24	1.68
INT6		12.60	24.52
STAB1	1.48		1.62
STAB2	3.06		0.12
STAB3	1.31		1.08
STAB4	3.10		2.88
STAB5	0.01		8.40
STAB6	1.31		1.05
GLOB1	0.52	0.23	
GLOB2	0.60	0.53	
GLOB3	2.85	0.04	
GLOB4	4.33	12.72	
GLOB5	7.23	0.12	
GLOB6	3.44	6.03	

Figure14.32 jamovi CFA の因子負荷量の修正指標

14.5

Residual Covariances – Modification Indices																		
	INT1	INT2	INT3	INT4	INT5	INT6	STAB1	STAB2	STAB3	STAB4	STAB5	STAB6	GLOB1	GLOB2	GLOB3	GLOB4	GLOB5	GLOB6
INT1		0.85	13.48	0.57	11.62	11.83												
INT2			1.17	2.99e-4	0.22	1.32	4.33	0.02	2.16	0.18	0.05	0.11	0.09	0.13	1.04	1.51	1.76	0.02
INT3				2.43	0.26	1.52	0.04	1.67	0.02	0.15	1.73	0.21	4.24	0.02	0.13	0.07	2.85	0.84
INT4					1.08	0.30	2.73	3.24	0.46	1.53	0.01	0.26	0.05	0.86	0.43	1.27	0.89	5.99
INT5						2.79	0.74	0.00	1.82	1.86	1.70	0.14	0.05	0.86	0.43			1.73
INT6							0.29	2.92e-4	1.84	0.37	0.01	1.96	0.03	0.22	0.18	0.20		
STAB1								5.21	8.32	9.64	2.07	2.54	6.10e-6	0.14	2.75	0.74	1.72	
STAB2									2.20	11.04	0.04	0.23	3.32	2.45	0.35	1.34	0.66	1.67
STAB3										7.41	11.37	1.38	4.36		0.06	2.16	1.88	
STAB4											0.03	1.99		0.72	0.78	0.04	10.30	0.82
STAB5												1.14	0.94	0.11	0.95	0.09	0.09	
STAB6													3.21	3.49	7.63	4.34	1.64	
GLOB1														0.02	0.49	0.68	1.34	
GLOB2															1.67	1.66	0.16	0.56
GLOB3															0.88	2.48	1.82	4.37
GLOB4																3.30	0.94	2.20
GLOB5																	0.41	3.60
GLOB6																		1.49e-6

Figure14.33 jamovi CFA の残差共分散の修正指標

内的整合性による信頼性分析

EFA と CFA を使った最初の尺度開発の過程を経ると、異なる標本を使った CFA でも尺度がしっかり持ちこたえる段階に到達しているはずです。この段階でもうひとつ関心を持ちそうなのが、観測変数を合成した尺度によって因子がどれだけうまく測定されているかを見ることです。

心理測定では、ある尺度が心理学的な構成概念をどれだけ一貫して測定しているかについての情報を得るために、信頼性分析を用います(セクション 2.3 参照)。ここで問題にするのは**内的整合性**で、これは測定尺度を構成する個々の項目すべてにわたる一貫性のことです。ですから V1, V2, V3, V4, V5 という観測項目変数があるとき、これらの項目が背後の構成概念を測るうえでどれだけ内的に整合しているかを示す統計量を計算できます。

尺度の内的整合性を確認するのによく使われる統計量が **Cronbach のアルファ** です (Chronbach 1951)。Cronbach のアルファは等価性の指標です(尺度項目の異なる組み合わせが同じ測定結果を与えるかどうか、ということです)。等価性は、尺度項目を2つのグループに分け(“折半法”), その2つの部分の分析が同程度の結果を与えるかどうかを見ることで検討されます。もちろん項目の分け方はいくつでもありますが、ありうるすべての分割を行えば、折半係数の全体的なパターンを反映した統計量を作ることができます。Cronbach のアルファ (α) がまさにその統計量で、尺度のすべての折半係数の関数になっています。ある構成概念を測る項目群(たとえば外向性尺度)のアルファが 0.80 であれば、その尺度の誤差分散の割合は 0.20 です。つまり、アルファが 0.80 の尺度にはおよそ 20% の誤差が含まれているということです。

ただし(そしてこれは大きな“ただし”です), Cronbach のアルファは次元性の指標ではありません(つまり尺度が複数の関連する構成概念ではなく単一の因子や構成概念を測っていることを示すもの、ではないということです)。多次元的な尺度は、次元ごとに別々に評価しなければアルファを過小推定させますが、アルファが高いからといって次元性の証拠になるわけではありません。ですからアルファが 0.80 であっても、背後にある単一の構成概念の 80% が説明されているという意味にはなりません。その 80% が、複数の背後の構成概念から来ている可能性もあるのです。だからこそ、先に EFA や CFA をやっておくことが役に立つわけです。

さらにアルファのもうひとつの特徴は、標本固有になりやすいことです。つまり尺度の性質というより、その尺度が使われた標本の性質なのです。偏った標本、代表性のない標本、小さな標本は、大きく代表的な標本とはまるで違うアルファ係数を出すことがあります。大きな標本どうしてもアルファは変わりうるのです。それでもこうした限界にもかかわらず、Cronbach のアルファは内的整合性による信頼性の推定として心理学で広く使われてきました。計算も理解も解釈もかなり簡単ですので、たとえば別の場面や母集団の別の標本に尺度を実施したときに、尺度の性能を最初に確認するのに役立ちます。

代わりになるのが **McDonald のオメガ** (ω) で、jamovi はこの統計量も出力します。アルファは (a) 残差間に相関がない, (b) 項目の負荷量が等しい, (c) 尺度が次元である, という仮定を置きま

すが、オメガはこれらを置きませんので、より頑健な信頼性の統計量になります。これらの仮定が破られていなければアルファとオメガは似た値になりますが、破られているならオメガを使うべきです。

アルファやオメガについて、“十分によい”値の目安となる閾値が示されることがあります。たとえばアルファが0.70なら“許容できる”，0.80なら“よい”信頼性だ，といったものです。しかしこれは，その尺度が何を測ろうとしているかによりますので，こうした閾値は慎重に使うべきです。アルファやオメガが0.70なら尺度の誤差分散は30%，0.80なら20%である，と単純に述べるほうがよいかもしれません。

アルファは高すぎる可能性があるでしょうか。おそらくあります。アルファ係数が0.95を超えている場合，項目間の相関が高く，測定に冗長すぎる特殊性が入り込んでいる可能性を示しており，測定している構成概念が狭すぎるおそれがあります。

14.5.1 jamovi での信頼性分析

信頼性分析を行うための第3のパーソナリティデータの標本が，`bfi_sample3.csv` ファイルにあります。ここでも，25のパーソナリティ項目変数が連続量としてコード化されていることを確認してください。jamoviで信頼性分析を実行するには，次のようにします。

- jamovi のメインのボタンバーから **Factor - Reliability Analysis** を選び，信頼性分析のウィンドウを開きます (図 14.34)。
- 5つのA変数を選んで 'Items' のボックスに移します。
- “Reverse Scaled Items” のオプションで，“Normal Scaled Items” のボックスにある変数 **A1** を選び，“Reverse Scaled Items” のボックスへ移します。
- そのほかのオプションも図 14.34 のように適宜チェックします。

終わったら，jamovi の結果ウィンドウに目を移してください。図 14.35 のようなものが見えるはずです。これは協調性尺度の Cronbach のアルファ係数が0.70であることを示しています。つまり協調性尺度得点の30%弱が誤差分散だということです。McDonald のオメガも出ていて，こちらは0.72で，アルファとあまり変わりません。

特定の項目を尺度から落とした場合にアルファやオメガがどれだけ改善するかも確認できます。たとえば項目A1を落とすと，アルファは0.72に，オメガは0.74に上がります。大きな増加ではありませんので，おそらくやる価値はないでしょう。

尺度の統計量 (アルファとオメガ) を計算して確認する手順は，他のすべての尺度でも同じです (結果は省略します)。誠実性 (アルファ = 0.73, オメガ = 0.74)，外向性 (アルファ = 0.76, オメガ = 0.76)，神経症傾向 (アルファ = 0.81, オメガ = 0.82)，開放性 (アルファ = 0.60, オメガ = 0.62) となりました。つまり開放性については尺度得点の誤差分散が40%あり，これは高い値です。開放




Figure14.34 jamovi の信頼性分析ウィンドウ

.....

性は、パーソナリティ特性の信頼できる測定として、他のパーソナリティ尺度よりかなり一貫性が低いということを示しています。

14.6

Reliability Analysis

Scale Reliability Statistics

	mean	sd	Cronbach's α	McDonald's ω
scale	4.650	0.900	0.701	0.720

Item Reliability Statistics

	mean	sd	item-rest correlation	if item dropped	
				Cronbach's α	McDonald's ω
A1 ^a	4.628	1.374	0.287	0.722	0.735
A2	4.676	1.237	0.544	0.619	0.652
A3	4.640	1.301	0.608	0.588	0.607
A4	4.828	1.422	0.404	0.676	0.701
A5	4.480	1.327	0.474	0.645	0.664

^a reverse scaled item

Figure14.35 協調性因子についての jamovi の信頼性分析の結果

要約

因子分析とその関連手法を扱ったこの章では、データセットの中の関係のパターンを検討する統計分析を紹介し、実際にやってみました。具体的には次のものを扱いました。

- 探索的因子分析 (EFA)。EFA はデータセットの背後にある潜在因子を特定するための統計的手法です。各観測変数は、因子負荷量で示される程度に潜在因子を表しているものとして概念化されます。研究者は EFA をデータ縮約の手段としても使います。つまり、後続の分析のために新しい因子変数へまとめられる観測変数を特定するのです (セクション 14.1)。
- 主成分分析 (PCA) はデータ縮約の手法で、厳密に言えば背後にある潜在因子を特定するものではありません。PCA は単に、観測変数の線形結合を作り出すだけのものです (セクション 14.2)。
- 確認的因子分析 (CFA)。EFA とは違い、CFA ではデータの中の変数がどう関連しているかについての考え、つまりモデルから出発します。そのうえでモデルを観測データに対して検証し、モデルがデータにどれだけよく当てはまるかを評価します (セクション 14.3)。
- 多特性多方法 (MTMM) の CFA では、潜在因子と方法分散の両方をモデルに含めます。異なる方法論的アプローチが使われていて方法分散が重要な検討事項になる場合に役立つやり方です (セクション 14.4)。
- 内的整合性による信頼性分析。この形の信頼性分析は、ある尺度が測定しようとしている (心

理学的) 構成概念をどれだけ一貫して測定しているかを検討します (セクション [14.5](#))。

Part V.

結び，代替案，そして展望

15. ベイズ統計学

現実の問題に関する我々の推論には、想像可能なあらゆる確信の度合いが存在する。最も確からしいものから、道徳的な証拠という最も不確かなものまで。ゆえに、賢人は信念を証拠に釣り合わせる。

– David Hume^{*1}

本書で私がこれまでに紹介してきたアイディアは、頻度主義の立場から見た推測統計学でした。このようなやり方を採用しているのは私だけではありません。実際、心理学の学部生向けに書かれたほぼ全ての教科書では、推測統計学の理論として頻度主義の統計学者の意見が紹介されています。これはひとつの正しいやり方です。私は実用上の理由からこの教育方法を用いてきました。頻度主義の考え方は20世紀の大半に渡って統計学の学術領域を席卷しました。この席卷は応用科学者の間で殊更顕著でした。頻度主義の手法は昔も今も心理学者たちの間で使われています。頻度主義の手法は科学論文の至るところで用いられているため、統計学を学ぶ全ての学生は頻度主義の手法を理解しなければならず、さもなくば科学論文の内容を理解できません。しかし残念なことに、少なくとも私の意見では、心理学における現行の統計手法は誤用を招きやすいものであり、頻度主義への依存には批判されるべき点もあります。

この章では、私がそうように考える理由を説明した上でベイズ統計学の紹介をします。ベイズ統計学は伝統的なアプローチよりも一般に優れたアプローチであると私は考えています。

この章は2つのパートに分かれています。

セクション 15.1 から 15.3 ではベイズ統計学の全てについて説明します。ベ이지アンアプローチが有用である理由だけでなく、基本となる数学の公式もカバーしています。その後で、t 検定のベイズ版を実行する方法を簡単に説明します (セクション 15.4)。

^{*1}http://en.wikiquote.org/wiki/David_Hume.

合理的エージェントによる確率的推論

ベイジアン立場では、統計的推測は信念の修正に他なりません。まずは、この世界に関する仮説の候補 h の集合について考えてみましょう。どの仮説が真であるかは分かりませんが、どの仮説が正しそうで、どの仮説が正しくなさそうかについての信念を私は多少なり持っています。データ d を観測したとき、私は元々持っていた信念を修正しなければなりません。もしある仮説とデータが整合的であれば、その仮説についての私の信念は強められます。もしその仮説とデータが整合的でなければ、その仮説についての私の信念は弱められます。これが全てなのです！ このセクションの最後にはベイジアン推論がどのように作用するかを正確に記述するつもりですが、まずは鍵となるアイデアを紹介するために簡単な例を示したいと思います。以下の推論問題を考えてみましょう。

私は傘を持ち歩いています。あなたは雨が降ると思いますか？

この問題では、私はあなたに一片のデータ (d = 私は傘を持ち歩いている) を提示しています。そして、雨が降るかどうかに関するあなたの信念あるいは仮説を私に教えてくれることを求めています。あなたが選ぶことのできる 2 つの選択肢 h は、今日雨が降るか、降らないかです。どうやってこの問題を解決しますか？

15.1.1 事前確率: 以前あなたが信じていたもの

あなたが最初にするべきことは、私が傘について話したことを無視して、雨についてあなたが事前に抱いていた信念を書き出すことです。これは重要なことです。新しい証拠 (データ) に照らして信念がどのように修正されたのかについてあなたが正直でありたいのであれば、あなたは絶対に、そのデータが現れる前に信じていたことについて何かを言わねばなりません！ では、あなたは今日雨が降るかどうかについて何を信じているのでしょうか？ 私がオーストラリアに住んでいること、そしてオーストラリアの多くの地域が暑くて乾燥しているということを、おそらくあなたは知っていることでしょう。私が住んでいるアデレード市は地中海性気候に属しており、南カリフォルニアや南ヨーロッパや北アフリカと非常によく似た気候です。私は 1 月にこの文章を執筆しているので、真夏であることをあなたは仮定できるでしょう。実際に、あなたは Wikipedia^{*2} をざっと見て、アデレード市では 1 月の 31 日間に平均 4.4 日雨が降るという情報を見つけたかもしれませんね。他に何も知らないのであれば、アデレード市で 1 月に雨が降る確率はおおよそ 15% であり、乾燥した日である確率はおおよそ 85% であるとあなたは結論付けることでしょう。もしこれが本当にアデレード市の降水

^{*2}http://en.wikipedia.org/wiki/Climate_of_Adelaide

についてあなたが信じていることだとしたら (それを私が今あなたに伝えたのだから、これこそが本当にあなたが信じていることであると私は確信しています), 私がここに書いたことがあなたの**事前分布**ということになります。これを $P(h)$ と書くことにしましょう。

仮説	信念の度合い
雨の日	0.15
乾燥した日	0.85

15.1.2 尤度: データに関する理論

この推論問題を解くためには私の行動についての理論が必要となります。ダンはいつ傘を持ていくのでしょうか？ あなたはおそらく、私が大馬鹿者ではないこと、^{*3}そして私が雨の日だけに傘を持ち歩こうとしていると推察するでしょう。一方で、私に幼い子どもがいることもあなたは知っていますし、私がこの種のことにかなり忘れっぽいと分かってもあなたは驚きはしないでしょう。

そこで、私が傘のことを思い出せるのは雨が降っている日のうちのおよそ 30% であると仮定してみましょう (私は本当にこれが苦手です)。対照的に、乾燥した日に傘を持っていくことはおよそ 5% しかないということにしましょう。こうすると、以下のような小さな表を作ることができます。

仮説	データ	
	傘あり	傘なし
雨の日	0.30	0.70
乾燥した日	0.05	0.95

この表の各セルは、特定の仮説 h が真であるという条件のもとでどのようなデータ d が観測されるかについてのあなたの信念を記述したものです。これを覚えておくことが大切です。

この“条件付き確率”は $P(d|h)$ と書き、“ h のもとでの d の確率 (the probability of d given h)”と読みます。ベイズ統計学ではこれを、仮説 h のもとでのデータ d の**尤度**と呼びます。^{*4}

^{*3}これは根拠のない盲信ですが、そういうことにして議論を進めていきましょう。

^{*4}うーん、この話はしたくないのですが、私がここで“尤度”という言葉を使うことに異を唱える統計学者もいることでしょう。“尤度”という言葉は頻度主義統計学では非常に特殊な意味を持っているので、ベイズ統計学における尤度の意味と完全に同じという訳ではない点が問題なのです。私が知る限りでは、ベイジアンにはもともと尤度に対する合意の取れた名称がなかったで、頻度主義の用語を使うことが一般的な慣習となってしまったのです。ベイジアンが頻度主義者とはずいぶん異なる使い方での言葉を使っていることが判明したという事実を除けば、このことは問題にはならなかったことでしょう。ここはさらにもうひとつの長い歴史について勉強する場所ではないのですが、大雑把に言えば、ベイジアンが“あるひとつの尤度関数”と言うときには、この表の行のひとつを指しているのが普通です。頻度主義者が同じことを言うときにも同じ表を参照するのですが、彼らにとっての“あるひとつの尤度関数”はほとんどいつでも列のひとつを指すのです。この区別は文脈によっては重要ですが、本章の目的においては重要ではありません。

15.1.3 データと仮説の同時分布

これで全ての要素が揃いました。

事前分布と尤度を書き出したので、あなたはベイズ推論に必要な全ての情報を手にしています。次に問題となるのは、この情報を私たちがどのように使うかです。結論から言えば、この状況で使うことのできる非常に簡単な等式があるのですが、重要なのは、なぜ私たちがその式を使うのかをあなたに理解してもらうことです。そこで、より基本的なアイディアからその式を構築することを試みてみたいと思います。

確率論の公式の1つから出発することにしましょう。私はその公式をかなり前に Table 6.1 に掲載したのですが、そのときはあまり大々的に取り上げなかったのも、おそらく無視されていたことでしょう。ここで取り上げるのは、2つのことが同時に真である確率について語る公式です。先ほどの例でいえば、今日雨が降り (i.e., 仮説 h が真である), かつ 私が傘を持っていく (i.e., データ d が観測される) 確率を計算したいということです。仮説とデータの同時確率を $P(d, h)$ と書きます。この同時確率は、事前確率 $P(h)$ と尤度 $P(d|h)$ の掛け算で計算できます。数学的には、

$$P(d, h) = P(d|h)P(h)$$

ということです。では、今日雨が降り、かつ私が傘を持っていく確率はどのくらいでしょうか？先ほど議論したように、事前確率が教えてくれるのは雨の日である確率が 15% であるということであり、尤度が教えてくれるのは雨の日に私が傘のことを思い出せる確率が 30% であるということです。したがって、これらが両方とも真である確率は、これら 2 つを掛け合わせて、

$$\begin{aligned} P(\text{雨, 傘あり}) &= P(\text{傘あり}|\text{雨}) \times P(\text{雨}) \\ &= 0.30 \times 0.15 \\ &= 0.045 \end{aligned}$$

と計算することができます。別の言い方をすれば、あなたは実際に何が起こったかを知らされるよりも前に、今日雨が降ってしかも私が傘のことを思い出す確率が 4.5% であると考えることになります。ただしもちろん、起こり得る可能性は 4 通りありますよね？なので、このエクササイズを全 4 通りについて繰り返してみましょう。すると、以下のような表ができます。

	傘あり	傘なし
雨の日	0.045	0.105
乾燥した日	0.0425	0.8075

この表には 4 つの可能性のうちどれが尤もらしいかに関する全ての情報が含まれていますが、全体像をきちんと把握するためには、この表に行と列の合計を加えるのが役に立ちます。そうすると次の表が得られます。

	傘あり	傘なし	合計
雨の日	0.0450	0.1050	0.15
乾燥した日	0.0425	0.8075	0.85
合計	0.0875	0.9125	1

この表はとても便利なので、この表に書かれた全ての数字が何を教えてくれるのかについて少し考えてみましょう。まずは、行の和が新しいことを何も語っていないことに注目してください。例えば一行目の和は、傘の問題を無視したときに、今日が雨の日である確率が15%であることを示しています。もちろんこれは私たちの事前確率なので、何も驚くことはありません。^{*5} 重要なのは数値そのものではありません。むしろ重要なのは、私たちの計算が理にかなったものであるという自信をこの数値が与えてくれることです。行の和から降水確率が分かるのと同様に、列の和からは、私が傘を持っていく確率が分かります。具体的には、一列目の和は、私が傘を持っていく確率が、平均的には(i.e., 雨の日かどうかを無視すれば) 8.75%であることを示しています。最後に、論理的に可能な4つの事象の総和が1になることに注目してください。つまり、私たちが書き下したこの表は、データと仮説の全ての可能な組み合わせに対して定義された、正則な (proper) 確率分布であるということになります。さて、この表はとても有用なので、全ての要素が何に対応しどのように書かれているのかをきちんと理解してもらいたいと思います。

	傘あり	傘なし	
雨の日	$P(\text{傘あり, 雨の日})$	$P(\text{傘なし, 雨の日})$	$P(\text{雨の日})$
乾燥した日	$P(\text{傘あり, 乾燥した日})$	$P(\text{傘なし, 乾燥した日})$	$P(\text{乾燥した日})$
	$P(\text{傘あり})$	$P(\text{傘なし})$	

最後に、“正しい (proper)” 統計的記法を用いてみましょう。雨の日の問題においてデータに対応するのは、私が傘を持っているか持っていないかという観測です。そこで d_1 を「私が傘を持っていところをあなたが観測する可能性」とし、そして d_2 を「私が傘を持っていないところをあなたが観測する可能性」とします。

同様に、 h_1 を「今日が雨の日であるという仮説」、 h_2 を「今日が雨の日ではないという仮説」とします。この記法を用いると、先ほどの表は次のようになります。

^{*5} ここではっきりさせておきたいのは、“事前” (prior) 情報とは既存の知識や信念のことであり、その情報を改善するためにデータを収集または使用する前に存在するものです。

	d_1	d_2	
h_1	$P(h_1, d_1)$	$P(h_1, d_2)$	$P(h_1)$
h_2	$P(h_2, d_1)$	$P(h_2, d_2)$	$P(h_2)$
	$P(d_1)$	$P(d_2)$	

15.1.4 ベイズの公式を使って信念を更新する

前節で作った表は、雨の日の問題を解くためのとても強力な道具です。論理的に可能な4通りをすべて考慮し、データを与えられる前にそれぞれをどれだけ確信しているかを正確に述べているからです。そろそろ、実際にデータを与えられたときに信念がどうなるかを考える番です。雨の日の問題では、私が実際に傘を持っていると告げられます。これはいささか驚くべき出来事です。表によれば、私が傘を持っていく確率は8.75%しかありません。しかしそれは納得のいく話でしょう。暑く乾燥した街の夏の日に傘を持っている男というのはかなり珍しいので、あなたはそんなことは予想していなかったのです。それでもデータは、それが本当だと告げています。どれだけありそうにないと思っていたにせよ、私が傘を持っているとわかったという事実を受け入れるように信念を調整しなければなりません^{*6}。この新しい知識を反映するには、修正した表は次の数値を持たなければなりません。

	傘あり	傘なし
雨の日		0
乾燥した日		0
合計	1	0

つまり事実が“傘なし”の可能性をすべて消し去りましたので、私が傘を持っていないことを意味するセルにはすべてゼロを入れなければなりません。また私が傘を持っていることは事実としてわかっていますので、 $P(\text{傘あり}) = 1$ という事実を正しく表すために、左の列の合計は1でなければなりません。

空いた2つのセルにはどんな数値を入れればよいのでしょうか。ここでも数学のことは気にせず、直感で考えてみましょう。最初に表を書き出したとき、この2つのセルはほとんど同じ数値でした。“雨で傘あり”の同時確率は4.5%，“乾燥していて傘あり”の同時確率は4.25%と計算しましたね。言い換えれば、私が実際に傘を持っていると告げる前なら、この2つの事象の確率はほとんど同じだと言ったはずですが。しかし、この2つの可能性はどちらも、私が実際に傘を持っているという事実と整合していることに注意してください。この2つの可能性の観点からすれば、ほとんど何も変

^{*6}もう少し凝るなら、傘について私が嘘をついている可能性も含めるように例を拡張できるでしょう。でも話は単純にしておきましょう。

わっていないのです。この2つの可能性が同じくらいもっともらしいということは依然として正しい、と同意していただけたと思います。ですから最終的な表に期待されるのは、“雨で傘あり”が“乾燥して傘あり”よりわずかにもっともらしいという事実を保ちつつ、表の数値の合計が合うような数値です。たとえばこんな具合でしょうか。

	傘あり	傘なし
雨の日	0.514	0
乾燥した日	0.486	0
合計	1	0

この表が語っているのは、私が傘を持っていると告げられたあとでは、今日が雨の日である確率を51.4%、そうでない確率を48.6%だとあなたが考える、ということです。これが問題の答えです。私が傘を持っているという条件のもとでの、雨の事後確率 $P(h|d)$ は51.4%になります。

この数値はどうやって計算したのでしょうか。おそらく想像がつくでしょう。“雨”の確率が0.514だと求めるためにやったのは、“雨で傘あり”の確率0.045を“傘あり”の確率0.0875で割ることだけです。こうすると、全体の合計が1になるという要請と、データと実際に整合する2つの事象の相対的なもっともらしさを損なわないという要請の両方を満たす表ができます。同じことを気取った統計用語で言えば、ここでやったのは仮説とデータの同時確率 $P(d, h)$ をデータの周辺確率 $P(d)$ で割ることであり、これによって観測されたデータを与えられたもとでの仮説の事後確率が得られます。これを式で書くと*7次のようになります。

$$P(h|d) = \frac{P(d, h)}{P(d)}$$

ただし前節のはじめに述べたこと、つまり同時確率 $P(d, h)$ が事前確率 $P(h)$ と尤度 $P(d|h)$ の積で計算されることを思い出してください。現実には書き下せるのは事前確率と尤度ですから、それを式に戻して代入してみましょう。そうすると、事後確率について次の式が得られます。

$$P(h|d) = \frac{P(d|h)P(h)}{P(d)}$$

そしてこの式こそが**ベイズの公式**として知られているものです。これは、学習者がさまざまな仮説のもっともらしさについての事前の信念から出発し、データに直面したときにその信念をどう改めるべきかを述べています。ベイズのパラダイムでは、すべての統計的推測がこのひとつの単純なルールから流れ出てくるのです。

*7 この式が実は、前節のはじめに挙げたのと同じ基本ルールの言い換えであることに気づいたかもしれません。式の両辺に $P(d)$ を掛ければ $P(d)P(h|d) = P(d, h)$ となり、これは同時確率の計算のルールそのものです。ですからここで“新しい”ルールを導入しているわけではなく、同じルールを違うやり方で使っているだけなのです。

ベイズ的仮説検定

Chapter 8 では、仮説検定への正統的なアプローチを説明しました。説明に 1 章まるごと必要だったのは、帰無仮説検定がとても入り組んだ仕掛けで、人々が理解に苦しむものだからです。これに対して、仮説検定へのベイズ的アプローチは驚くほど単純です。正統的な場面とよく似た設定を考えてみましょう。比較したい仮説が 2 つ、帰無仮説 h_0 と対立仮説 h_1 があります。実験を行う前に、どちらの仮説が正しいかについての信念 $P(h)$ を持っています。実験を行ってデータ d を得ます。頻度論の統計とは違い、ベイズ統計では帰無仮説が正しい確率について語ることが許されます。それどころか、ベイズの公式を使って**帰無仮説の事後確率**を計算できます。

$$P(h_0|d) = \frac{P(d|h_0)P(h_0)}{P(d)}$$

この式は、データ d を観測したあとに帰無仮説をどれだけ信じるべきかを正確に教えてくれます。同じように、本質的に同じ式を使って対立仮説をどれだけ信じるべきかも求められます。添字を変えるだけです。

$$P(h_1|d) = \frac{P(d|h_1)P(h_1)}{P(d)}$$

あまりに単純なので、こんな式をわざわざ書き下すのはばかげているようにさえ思えます。前節のベイズの公式をそのまま写しているだけなのですから*8。

15.2.1 ベイズファクター

実際には、ベイズ的なデータ分析者の多くは生の事後確率 $P(h_0|d)$ と $P(h_1|d)$ の形では語りません。そのかわりに**事後オッズ**比の形で語る傾向があります。賭けのようなものだと考えてください。たとえば帰無仮説の事後確率が 25%、対立仮説の事後確率が 75% だとしましょう。対立仮説は帰無仮説の 3 倍ありそうですので、対立仮説に有利なオッズが 3:1 である、と言います。数学的には、事後オッズを計算するには一方の事後確率をもう一方で割るだけです。

$$\frac{P(h_1|d)}{P(h_0|d)} = \frac{0.75}{0.25} = 3$$

*8 もちろん、これはきわめて単純化した話です。現実のベイズ的仮説検定の複雑さはすべて、仮説 h が複雑で漠然としたものである場合に尤度 $P(d|h)$ をどう計算するかに帰着します。本書ではその複雑さには触れませんが、この単純な話はそれ自体としては正しいものの、現実 は 入門的な統計の教科書で扱える範囲よりずっと雑然としている、ということは強調しておきたいと思います。

あるいは、同じことを上の式で書けば次のようになります。

$$\frac{P(h_1|d)}{P(h_0|d)} = \frac{P(d|h_1)}{P(d|h_0)} \times \frac{P(h_1)}{P(h_0)}$$

実のところ、この式は詳しく見ておく価値があります。ここには知っておくべき3つの項があります。左辺には事後オッズがあり、データを見たあとで帰無仮説と対立仮説の相対的なもってもらしさをどう信じているかを表します。右辺には**事前オッズ**があり、データを見る前にどう考えていたかを示します。その中間にあるのが**ベイズファクター**で、データが与える証拠の量を表します。

$$\begin{array}{ccccc} \frac{P(h_1|d)}{P(h_0|d)} & = & \frac{P(d|h_1)}{P(d|h_0)} & \times & \frac{P(h_1)}{P(h_0)} \\ \uparrow & & \uparrow & & \uparrow \\ \text{事後オッズ} & & \text{ベイズファクター} & & \text{事前オッズ} \end{array}$$

ベイズファクター (**BF** と略されることもあります) はベイズ的仮説検定のなかで特別な位置を占めています。正統的な仮説検定における p 値と似た役割を果たすからです。ベイズファクターはデータが与える証拠の強さを数量化しますので、ベイズ的仮説検定を実行したときに報告されるのはたいていベイズファクターです。事後オッズではなくベイズファクターを報告する理由は、研究者ごとに事前確率が異なるからです。帰無仮説が正しいと信じる強い偏りを持つ人もいれば、誤りだと信じる強い偏りを持つ人もいるでしょう。ですから応用研究者としての礼儀は、ベイズファクターを報告することです。そうすれば論文を読む人は誰でも、ベイズファクターに自分個人の事前オッズを掛けて、事後オッズがどうなるかを自分で求められます。いずれにせよ慣例として、帰無仮説と対立仮説を同等に扱っているふりをするのが好まれます。その場合、事前オッズは1になり、事後オッズはベイズファクターと同じになります。

15.2.2 ベイズファクターを解釈する

ベイズファクターの本当に良いところのひとつは、その数値がそれ自体で意味を持っていることです。実験を行ってベイズファクターが4と計算されたなら、データが与える証拠は対立仮説に有利な4:1の賭け率に相当する、ということです。とはいえ、科学的な文脈で意味があるとみなされる証拠の基準を数量化しようという試みもいくつかあります。もっとも広く使われているのは [Jeffreys \(1961\)](#) と [Kass and Raftery \(1995\)](#) によるものです。2つのうち、私は少し保守的な [Kass et al. \(1995\)](#) の表のほうを好みます。それがこちらです。

ベイズファクター	解釈
1 - 3	無視できる証拠
3 - 20	積極的な証拠
20 - 150	強い証拠
>150	非常に強い証拠

正直に言えば、[Kass et al. \(1995\)](#) の基準ですら少し甘いと思います。私に決めさせてもらえるなら、“積極的な証拠” の区分は “弱い証拠” と呼んだでしょう。私にとって 3:1 から 20:1 の範囲は、せいぜい “弱い” か “ささやかな” 証拠です。とはいえここに厳格なルールはありません。何を強い証拠とし何を弱い証拠とするかは、あなたがどれだけ保守的かと、ある知見を “真” と呼ぶためにあなたの属するコミュニティが求める基準に完全に依存します。

いずれにせよ、上に挙げた数値はベイズファクターが 1 より大きい場合 (つまり証拠が対立仮説に有利な場合) に意味を持つことに注意してください。とはいえ、正統的なアプローチに対するベイズ的アプローチの大きな実務上の利点のひとつは、帰無仮説を支持する証拠も数量化できることです。その場合、ベイズファクターは 1 より小さくなります。1 より小さいベイズファクターをそのまま報告することもできますが、正直なところ私には紛らわしく感じられます。たとえば帰無仮説のもとでのデータの尤度 $P(d|h_0)$ が 0.2、対立仮説のもとでの対応する尤度 $P(d|h_1)$ が 0.1 だとしましょう。上に示した式を使えば、ベイズファクターは次のようになります。

$$BF = \frac{P(d|h_1)}{P(d|h_0)} = \frac{0.1}{0.2} = 0.5$$

文字どおり読めば、この結果は対立仮説に有利な証拠が 0.5 対 1 だと言っていることになります。私にはこれが理解しにくいのです。私には、式を “ひっくり返して” 帰無仮説に有利な証拠の量を報告するほうがずっと納得がいきます。つまり次のように計算するわけです。

$$BF' = \frac{P(d|h_0)}{P(d|h_1)} = \frac{0.2}{0.1} = 2$$

そして帰無仮説に有利なベイズファクターが 2:1 である、と報告します。こちらのほうがずっとわかりやすいですし、上の表を使って解釈できます。

15.3

なぜベイズ主義者になるのか

ここまでは、ベイズ統計を支える論理だけに焦点を当ててきました。“信念の度合いとしての確率” という考え方と、それが合理的な主体が世界についてどう推論すべきかについて何を含意するかを話してきました。あなたが自分で答えなければならない問いはこうです。あなたは どうやって統計をやりたいのか。標本分布と p 値に判断を委ねる正統派の統計家になりたいのか。それとも事前の信念やベイズファクター、合理的な信念改訂のルールに頼るベイズ主義者になりたいのか。正直に言って、この問いに私が代わりに答えることはできません。結局は、あなたが何を正しいと考えるかによります。決めるのはあなたであり、あなただけです。そのうえで、私がベイズ的アプローチを好む理由については少し語れます。

15.3.1 思っているとおりの意味を持つ統計

あんたはその言葉を使い続けているが、それがあんたの思っている意味だとは思えないね。

– Inigo Montoya, プリンセス・ブライド^{*9}

私にとってベイズ的アプローチの最大の利点のひとつは、正しい問いに答えてくれることです。ベイズの枠組みでは、“仮説が正しい確率”について語ることがまったく理にかなっていませんし、許されてもいます。その確率を計算しようとするさえできます。結局のところ、それこそ統計的検定に教えてもらいたいことではないでしょうか。生身の人間からすれば、何が真で何がそうでないかを判断することこそ、統計をやる目的そのものに思えるはずです。真実が何かははっきりわからないときはいつでも、確率論の言葉を使って“理論 A が正しい確率は 80%, 理論 B が正しい確率は 20% だ”というように言うべきです。

人間にとってはあまりにも当たり前に見えるのに、正統的な枠組みではこれが明確に禁じられています。頻度主義者にとって、“理論が正しい”というのは繰り返し可能な事象ではありませんので、そうした言明は無意味なのです。理論は正しいか正しくないかのどちらかであり、どれだけ言いたくても確率的な言明は許されません。セクション 8.6 で、p 値を帰無仮説が正しい確率として解釈しないように繰り返し警告したのは理由があるのです。ほとんどすべての統計の教科書がその警告を繰り返さざるをえないのにも理由があります。それは、人々がその解釈であってほしいと切に願っているからです。頻度主義の教義はさておき、学部生を教え、日々データ分析をしてきた経験から私が思うのは、たいていの生身の人間は“仮説が正しい確率”が意味を持つと考えているだけでなく、それこそがもっとも関心のあることだと考えている、ということです。あまりに魅力的な考えなので、訓練を受けた統計家でさえ p 値をこう解釈しようとする誤りに陥ります。たとえば次は、2013 年の Newspann の公式報告からの引用で、彼らの (頻度論的な) データ分析をどう解釈するかを説明したものです^{*10}。

本報告書では、該当する箇所で統計的に有意な変化を記している。有意性検定はすべて 95 パーセントの信頼水準にもとづいている。これはつまり、ある変化が統計的に有意だと記されている場合、本当の変化が起きた確率が 95 パーセントであるということであり、単なる偶然の変動によるものではないということである。(強調は引用者による)

違います。それは $p < .05$ の意味ではありません。頻度論の統計家にとって 95% の信頼というのは、

^{*9}<http://www.imdb.com/title/tt0093779/quotes>。ついでに言っておくと、頻度論的な手法に文句を言うためにこの引用を使ったのは私が最初ではありません。Rich Morey らが先に思いつきました。この文脈で使うには最高の引用ですし、プリンセス・ブライドを引用する機会は逃したくないので、恥ずかしげもなく拝借しています。

^{*10}<http://about.abc.net.au/reports-publications/appreciation-survey-summary-report-2013/>

そういう意味ではありません。太字の部分は端的に誤りです。正統的な手法は“本当の変化が起きた確率は 95% である”と告げることはできません。これは頻度論的な確率を割り当てられる種類の事象ではないからです。イデオロギー的な頻度主義者にとって、この文は無意味であるはずです。より実用主義的な頻度主義者であっても、これは p 値の誤った定義です。正統的な統計の道具に頼りたいのであれば、これは単純に言うてはいけない、正しくない言い方なのです。

一方、あなたがベイズ主義者だとしましょう。太字の箇所は p 値の定義としては誤りですが、ベイズ主義者が対立仮説の事後確率が 95% を超えると言うときの意味とほぼぴったり一致します。そしてここが肝心なところですよ。本当に報告したいのがベイズの事後確率なのだとしたら、なぜ正統的な手法を使おうとするのでしょうか。ベイズ的な主張をしたいのなら、ベイズ主義者になってベイズの道具を使えばよいだけです。

私自身について言えば、ベイズの立場に移って何がいちばん解放感があったかという点、この点でした。いったん飛び移ってしまえば、 p 値の直感に反する定義に頭を悩ませる必要はもうありません。真の平均がある区間に入ると 95% の確信をもって言えない理由を、わざわざ覚えておく必要はありません。やるべきことは、研究を行う前に何を信じていたかを正直に述べ、それによって何を学んだかを報告することだけです。よさそうでしょう。私にとって、これがベイズ的アプローチの大きな約束です。本当にやりたい分析をやり、データが語っていると本当に信じることを述べるのです。

15.3.2 信頼できる証拠の基準

[p が].02 を下回るなら、[帰無] 仮説が事実の全体を説明できていないことが強く示唆される。慣例的な線を .05 に引き、[それより小さい p の値が] 本当の食い違いを示していると考えたら、我々が道を誤ることはそう多くないだろう。

– Sir Ronald Fisher (1925)

上の Ronald Fisher 卿の言葉について考えてみましょう。彼は今日の正統的な統計のアプローチの創始者のひとりです。 p 値が本来果たすべき役割について意見を述べる資格のある人がいるとすれば、それは Fisher です。古典的な手引き *Statistical Methods for Research Workers* からのこの一節で、彼は $p < .05$ で帰無仮説を棄却することが何を意味するかをかなりはっきり述べています。彼の考えでは、 $p < .05$ を“本当の効果がある”という意味にとるなら“我々が道を誤ることはそう多くない”のです。この見方は珍しいものではありません。私の経験では、実務家の多くが Fisher とよく似た見方を口にします。要するに $p < .05$ という慣例は、かなり厳しい証拠の基準を表していると思われるわけです。

では、それはどこまで本当でしょうか。この問いに迫るひとつの方法は、 p 値をベイズファクターに変換してみて、両者を比べることです。 p 値はベイズファクターとは根本的に異なる種類の計算ですし、測っているものも同じではありませんので、これは簡単ではありません。とはいえ両者の関

係を明らかにしようという試みはいくつかあり、その結果はいささか驚くべきものです。たとえば [Johnson \(2013\)](#) は、(少なくとも t 検定については) $p < .05$ という閾値が、対立仮説に有利な 3:1 から 5:1 程度のベイズファクターにおおよそ対応する、というかなり説得力のある議論を示しています。もしそれが正しいなら、Fisher の主張は少し無理があります。帰無仮説が半分くらいの割合で正しい (つまり H_0 の事前確率が 0.5) として、この数値から $p < .05$ で棄却されたという条件のもとでの帰無仮説の事後確率を求めてみましょう。[Johnson \(2013\)](#) のデータを使うと、 $p < .05$ で帰無仮説を棄却したとき、正しいのは 80% 程度だとわかります。あなたはどうか知りませんが、私に言わせれば、判断の 20% で間違えることが確実な証拠の基準では不十分です。Fisher の主張とはまったく逆に、 $p < .05$ で棄却していればかなり頻繁に道を誤る、という事実は変わりません。まったく厳しい証拠の閾値ではないのです。

15.3.3 p 値は嘘である

ケーキは嘘だ。

ケーキは嘘だ。

ケーキは嘘だ。

ケーキは嘘だ。

– Portal^{*11}

さて、ここまで読んで、本当の問題は正統的な統計そのものではなく $p < .05$ という基準だけだ、と思っているかもしれません。ある意味ではそのとおりです。[Johnson \(2013\)](#) の推奨は“誰もが今すぐベイズ主義者になるべきだ”というものではありません。そうではなく、慣例的な基準を $p < .01$ の水準あたりに移すほうが賢明だろう、という提案です。これは無理のない見方ですが、私の見るところ問題はもう少し深刻です。私の意見では、ほとんどの (すべてではありませんが) 正統的な仮説検定の組み立て方には、かなり大きな問題が組み込まれています。人間が実際にどう研究しているかについてあまりにも素朴であり、そのせいでほとんどの p 値は誤っているのです。

ばかげた主張に聞こえるでしょう。では次の場面を考えてみてください。とてもわくわくする研究仮説を思いついて、それを検証する研究をデザインしました。あなたはとても几帳面なので、標本サイズを決めるために検定力分析を行い、研究を実施します。仮説検定を実行すると、 p 値 0.072 が出てきました。実に腹立たしいですね。

どうすべきでしょうか。いくつか可能性を挙げてみます。

1. 効果はないと結論し、帰無の結果として発表しようとする。
2. 効果があるかもしれないと考え、“有意傾向”の結果として発表しようとする。

^{*11}<http://knowyourmeme.com/memes/the-cake-is-a-lie>

3. あきらめて新しい研究に取りかかる。
4. データをもう少し集めて、 p 値が上がるか、あるいは (できれば) $p < .05$ という“魔法の”基準を下回るかを見る。

あなたはどれを選ぶでしょうか。読み進める前に、少し時間をとって考えてみてください。自分に正直に。とはいえ気に病みすぎないでください。どれを選んでも詰んでいるからです。著者・査読者・編集者としての自分の経験と、人から聞いた話にもとづくと、それぞれの場合に起こるのは次のようなことです。

- まず選択肢 1 から。帰無の結果として発表しようとする、論文はなかなか通りません。 $p = .072$ は本当の帰無の結果ではないと考える査読者もいるでしょう。有意傾向だと主張するはず。帰無の結果だと認めつつ、発表に値する帰無の結果もあるけれどもあなたのものはそうではない、と言う査読者もいるでしょう。1 人か 2 人は味方になってくれるかもしれませんが、通すには相当な苦戦を強いられます。
- では選択肢 2 を考えてみましょう。有意傾向の結果として発表しようとする、これは帰無の結果だから発表すべきでない主張する査読者もいれば、証拠が曖昧なのではっきり有意な結果が出るまでデータを集めるべきだと主張する査読者もいるでしょう。ここでも出版の過程はあなたに味方しません。
- $p = .072$ のような“曖昧な”結果を発表する難しさを考えると、選択肢 3、つまりあきらめて別のことをやる、が魅力的に見えるかもしれません。しかしそれはキャリアの自殺行為です。曖昧さに直面するたびにあきらめて新しいプロジェクトに移っていたら、あなたの仕事は決して発表されません。そして学術界で業績がなければ職を失いかねません。ですからこの選択肢もなしです。
- どうやら選択肢 4 しか残っていないようです。決定的な結果が出ていないので、データをもう少し集めて分析をやり直すことにします。もっともらしく思えますが、あいにくそうすると、あなたの p 値はすべて誤りになります。すべてです。この研究で計算した p 値だけではありません。全部です。過去に計算したすべての p 値も、これから計算するすべての p 値もです。幸いなことに、誰も気づきません。あなたの論文は掲載され、そしてあなたは嘘をついたことになります。

えっ、何ですって。最後の部分がどうして本当なのでしょう。まったく理にかなった方針に聞こえますよね。データを集めたけれども結果が決定的でなかった、決定的になるまでデータを集めた、というだけです。何がいけないのでしょうか。

正直なところ、何もいけなくはありません。理にかなった、まっとうで合理的な行いです。現実には、まさにどの研究者もそうしています。残念ながら、Chapter 8 で説明した帰無仮説検定の理論

は、これを禁じています^{*12}。理由は、この理論が実験は終了しデータはすべて揃っていると仮定しているからです。実験が終わっていると仮定していますので、考えられる判断は2つしかありません。慣例的な $p < .05$ の閾値を使っているなら、その判断は次のとおりです。

結果	行動
p が .05 未満	帰無仮説を棄却する
p が .05 より大	帰無仮説を保持する

あなたがやっているのは、判断の問題に3つめの行動を加えることです。具体的には、 p 値そのものを実験を続ける理由として使っているわけです。その結果、判断の手続きは次のようなものになります。

結果	行動
p が .05 未満	実験をやめて帰無仮説を棄却する
p が .05 から .1 のあいだ	実験を続ける
p が .1 より大	実験をやめて帰無仮説を保持する

帰無仮説検定の“基本的な”理論は、少なくとも Chapter 8 で説明した形では、こうしたことを扱えるようには作られていません。現実には“データをもっと集める”ほうを選ぶような人であれば、あなたは帰無仮説検定のルールにしたがって判断していないということになります。たまたま仮説検定と同じ判断に至ったとしても、その含意する判断の過程にはしたがっていません。そして問題を引き起こしているのは、この過程にしたがっていないことなのです^{*13}。あなたの p 値は嘘です。

さらに悪いことに、それは危険な形の嘘です。どれも小さすぎるからです。どれほどひどくなりうるかの感覚をつかんでもらうために、次の(最悪の)場面を考えてみてください。予算の乏しい、きわめて熱心な研究者で、しかも上の警告をまったく気にしていない、としましょう。2つの群を比較する研究をデザインします。 $p < .05$ の水準で有意な結果をどうしても見たいけれども、(高くつくので)必要以上のデータは集めたくありません。費用を抑えるためにデータを集め始め、新しい観測が届くたびにデータに t 検定を実行します。 t 検定が $p < .05$ と言えば実験をやめ、有意な結果を報告します。そうでなければデータを集め続けます。この実験のためにあらかじめ決めた支出の上限に達するまで、これを続けます。その上限が $N = 1000$ の観測だとしましょう。実のところ、真実は「見つかるべき本当の効果などない」、つまり帰無仮説が正しいのです。では、実験の最後まで到達し

^{*12}完全に正直であるために断っておくと、正統的な統計的検定のすべてがこのばかげた仮定に頼っているわけではありません。臨床試験などで使われることのある逐次解析の道具がいくつもあります。これらの手法はデータが到着するたびに分析されるという前提の上に作られていますので、ここで私が文句を言っているようなひどい壊れ方はしていません。ただし逐次解析の手法は、“標準的な”帰無仮説検定とはまったく異なる形で組み立てられています。入門的な教科書には載りませんし、心理学の文献でもあまり広く使われていません。ここで挙げている懸念は、これまで示したすべての正統的な検定と、私が読む論文で報告されているほとんどすべての検定に当てはまります。

^{*13}関連する問題: <http://xkcd.com/1478/>。




Figure15.1 新しいデータが届くたびに検定をやり直すと、どれだけひどいことになるのか。頻度主義者であれば、答えは“きわめてひどいことになる”である。

.....

て(正しく)効果はないと結論する確率はどれくらいでしょうか。理想的な世界なら、答えは95%のはずです。そもそも $p < .05$ という基準の眼目はタイプIエラー率を5%に抑えることですから、この状況で帰無仮説を誤って棄却する確率は5%しかないと期待したいところです。しかしそうなる保証はありません。あなたはルールを破っているのです。有意な結果が出たかどうかを見るためにデータを“覗き見”しながら検定を繰り返しているのですから、何の保証もありません。

では、どれだけひどいのでしょうか。答えは図 15.1 の黒い実線に示してあり、驚くほどひどいものです。1つ観測が増えるたびにデータを覗き見していると、タイプIエラーを犯す確率は49%になります。これは、まあ、本来あるべき5%よりかなり大きいですね。比較のために、次のような方針をとった場合を想像してみてください。データを集め始めます。観測が届くたびにベイズ的なt検定(セクション 15.4)を実行し、ベイズファクターを見ます。Johnson (2013) が正しいと仮定して、3:1のベイズファクターを p 値.05 とおおよそ同等に扱うことにします^{*14}。今回、この撃ちたがりの

^{*14} Johnson (2013) は $p = .05$ がその範囲のどこかにあると示唆しているのに、なぜ5:1ではなく3:1を選んだのかと思う読者もいるでしょう。 p 値に対して寛大であろうとしたからです。5:1のベイズファクターを選んでいたら、結果はベイズ的アプローチにとってさらに有利に見えたはずですよ。

研究者は次の手続きを使います。バイズファクターが帰無仮説に有利な 3:1 以上なら、実験をやめて帰無仮説を保持する。対立仮説に有利な 3:1 以上なら、実験をやめて帰無仮説を棄却する。それ以外なら検定を続ける。さて、先ほどと同じく帰無仮説が正しいとしましょう。どうなるでしょうか。この場面についてもシミュレーションを走らせてあり、結果は図 15.1 の破線に示してあります。タイプ I エラー率は、正統的な t 検定で得られていた 49% よりはるかに低くなります。

ある意味でこれは注目に値します。正統的な帰無仮説検定の眼目はタイプ I エラー率を抑えることそのものです。バイズの手法はそもそもそれを目指して設計されてはいません。それなのに、データが入るたびに仮説検定を実行し続ける“撃ちたがりの”研究者を前にすると、バイズ的アプローチのほうがはるかに効果的なのです。ほとんどのバイズ主義者が受け入れがたいほど緩いと考える 3:1 という基準でさえ、 $p < .05$ のルールよりずっと安全です。

15.3.4 本当にそこまでひどいのか

前節で挙げた例は、かなり極端な状況です。現実には、新しい観測が届くたびに仮説検定を実行する人はいません。ですから $p < .05$ という閾値が“実際には”49% のタイプ I エラー率 (つまり $p = .49$) に対応する、と言うのは公平ではありません。しかし、 p 値を正直なものにしたいなら、仮説検定のやり方をまったく別のものに切り替えるか、覗き見禁止という厳格なルールを徹底するかしかない、という事実は変わりません。実験をいつ終わるかデータをもとづいて決めることは許されません。“境界線上”の p 値を見てデータをもっと集めると決めることも許されません。データを見たあとで分析の方針を変えることすら許されません。これらのルールに厳格にしたがうことが求められ、さもなければ計算した p 値は無意味になります。

そう、このルールは驚くほど厳格です。数年前に授業の演習として、学生に次の場面を考えてもらいました。N = 80 人を集めるつもりで研究を始めたとします。研究の初めのうちはルールを守り、データを見ることも検定を実行することも拒んでいます。しかし N = 50 に達したところで意志が折れて……覗き見してしまいます。どうでしょう、有意な結果が出ています。確かに標本サイズ N = 80 まで研究を続けると言ったのは覚えていますが、いまとなっては無意味に思えますよね。N = 50 の標本サイズで結果が有意なのですから、データを集め続けるのは無駄で非効率ではないでしょうか。やめたい誘惑に駆られませんか。ほんの少しでも。しかし覚えておいてください。そうすると $p < .05$ のタイプ I エラー率は 8% まで膨れ上がるのです。論文で $p < .05$ と報告するとき、本当は $p < .08$ と言っていることになります。“たった一度の覗き見”の結果は、それほどひどいものになりうるのです。

さらに考えてみてください。学術文献は t 検定・分散分析・回帰・カイ二乗検定であふれています。本書を書くとき、私はこの検定を適当に選んだわけではありません。この 4 つの道具がほとんどの入門的な統計の本に登場するのは、これらが科学の主食だからです。そのどれもが“データの覗

き見”に対処する補正を含んでいません。どれもあなたがそれをしていないと仮定しているのです。しかしその仮定はどれだけ現実的でしょうか。現実には、実験が終わる前にデータを“覗き見”して、データの様子を見てからその後の行動を変えた人がどれだけいると思いますか。標本抽出の手続きが外的な制約で固定されている場合を除けば、答えは“ほとんどの人がやっている”だろうと私は推測します。それが起きているなら、報告された p 値は誤りだと推論できます。さらに悪いことに、彼らが実際にどんな判断過程にしたがったかがわかりませんので、 p 値が本来どうあるべきだったかを知る術がありません。研究者が使った判断の手続きがわからなければ、 p 値は計算できないのです。ですから報告された p 値は嘘のままです。

以上を踏まえて、持ち帰るべきメッセージは何でしょうか。ベイズの手法が万全だ、ということではありません。研究者がごまかそうと決めているなら、いつでもそうできます。ベイズの公式は人が嘘をつくの止められませんが、実験を仕込むのも止められません。私が言いたいのはそこではありません。私の言いたいことは、本書のいちばん初めのセクション 1.1 で述べたのと同じです。統計的検定を実行するのは、自分自身から自分を守るためなのです。そして“データの覗き見”がこれほど問題になるのは、正直な研究者にとってさえそれがあまりにも誘惑的だからです。統計的推測の理論はこれを認めなければなりません。 p 値を擁護して、適切に使わない研究者が悪いのだと言うこともできるでしょうが、私に言わせればそれは的外れです。研究者が自分のデータを見る可能性すら考慮しないほど人間について徹底的に素朴な統計的推測の理論は、持つ価値のある理論ではありません。要するに、私の言いたいことはこうです。

よき法は悪しき道徳から生まれる。

– Ambrosius Macrobius^{*15}

統計的検定のよいルールは、人間の弱さを認めなければなりません。罪のない者はいません。誘惑を超越した者もいません。統計的推測のよい体系は、生身の人間に使われてもなお機能すべきです。正統的な帰無仮説検定はそうではありません^{*16}。

15.4

^{*15}http://www.quotationspage.com/quotes/Ambrosius_Macrobius/

^{*16}さて、これを読んだ物知りの頻度主義者がこの節に文句を言い始めることはわかっています。いいですか、私はばかではありません。逐次解析の立場をとれば、正統的な枠組みの中でもこうした誤りを避けられることは百も承知です。中間解析を念頭に置いて研究を明示的にデザインできることも知っています。ですから確かに、ある意味で私は正統的な手法の“藁人形”版を叩いています。しかし私が叩いている藁人形は、ほとんどすべての実務家が使っているものなのです。逐次的な手法が実験心理学者のあいだで標準になり、きわめて怪しい分散分析を 1 日に 20 本読まされずに済むようになった暁には、この節を書き直して毒を弱めると約束します。しかしその日が来るまでは、現実に行われているデータ分析の慣行を前にすれば既定のベイズファクターの手法のほうがはるかに頑健である、という主張を貫きます。既定の正統的な手法はひどいものですし、それは誰もが知っていることです。

ベイズ的 t 検定

本書で扱う統計的推測の重要な問題のひとつが2つの平均の比較で、 t 検定の章 (Chapter 10) でやや詳しく論じました。そこまで思い出せるなら、 t 検定にはいくつかの版があったことを覚えているでしょう。この節では、独立標本 t 検定と対応のある標本の t 検定のベイズ版について少し話します。

15.4.1 独立標本 t 検定

もっともよくある t 検定は独立標本 t 検定で、先の t 検定の章 (Chapter 10) で使った `harpo.csv` のようなデータがあるときに出てきます。このデータには、Anastasia の授業を受けた学生と Bernadette の授業を受けた学生という2つの群がありました。答えたい問いは、この2群の学生が得た成績に差があるかどうかです。Chapter 10 では、この種のデータは JASP の独立標本 t 検定で分析できると述べ、図 15.2 の結果が得られました。p 値が 0.05 未満でしたので、帰無仮説を棄却します。

Results

Bayesian Independent Samples T-Test

Bayesian Independent Samples T-Test		
	BF ₁₀	error %
grade	1.755	7.565e -4

Independent Samples T-Test

Independent Samples T-Test			
	t	df	p
grade	2.115	31.000	0.043

Note. Student's t-test.

Figure15.2 JASP でのベイズ的独立標本 t 検定の結果

t 検定のベイズ版はどんなものでしょうか。‘T-Tests’-‘Bayesian Independent Samples T-Test’ のオプションを選べば、ベイズファクターの分析が得られます。ダイアログは先ほどの通常の t 検定と似ていますので、何をすればよいかはもうわかるはずです。ここでは JASP の既定の設定をそのまま受け入れましょう。そうすると図 15.2 の表の結果が得られます。この表で得られるのはベイズファクター 1.755 で、このデータが与える証拠は対立仮説に有利な約 1.8:1 だということです。

先へ進む前に、正統的な検定の結果とベイズの結果の違いを強調しておく価値があります。正統的な検定によれば、かろうじてではあれ有意な結果が得られました。それでも多くの人は $p = .043$ を効果のそれなりに強い証拠として喜んで受け入れるでしょう。これに対してベイズの検定は、効果に有利なオッズが 2:1 にすら届いておらず、せいぜい非常に弱い証拠とみなされることに注意してください。私の経験では、これはかなり典型的な結果です。ベイズの手法は、帰無仮説を棄却するのにふつうより多くの証拠を求めるのです。

15.4.2 対応のある標本の t 検定

セクション 10.6 では `chico.csv` のデータを扱いました。学生の成績が 2 回の試験で測定されていて、試験 1 から試験 2 にかけて成績が上がったかどうかに関心がありました。どの学生も両方の試験を受けていますので、データの分析に使った道具は対応のある標本の t 検定でした。図 15.3 は、通常の対応のある t 検定の結果表と、ベイズファクターの分析を並べた JASP の出力です。ここまで来れば、この出力を難なく読めるようになっていると思います。データは対立仮説に有利な約 6000:1 の証拠を与えています。かなりの確信をもって帰無仮説を棄却できそうです。

15.5

要約

この章の前半では、主にベイズ統計の理論的な土台に焦点を当てました。ベイズ推測がどう働くかの数学を紹介し (セクション 15.1)、ベイズ的仮説検定がふつうどう行われるかのごく基本的な概観を示しました (セクション 15.2)。最後に、ベイズの手法が使う価値のあるものだと私が考える理由に紙幅を割きました (セクション 15.3)。

そのうえで実践的な例として、ベイズ的 t 検定を示しました (セクション 15.4)。ベイズ的アプローチをもっと学びたいのであれば、読むとよい本がたくさんあります。John Kruschke の *Doing Bayesian Data Analysis* は出発点としてかなりよく (Kruschke 2011)、理論と実践のバランスがとれています。彼のアプローチはここで論じた “ベイズファクター” のアプローチとは少し異なりますので、同じ内容を繰り返すことにはなりません。認知心理学者であれば、Michael Lee と E.J. Wagenmakers の *Bayesian Cognitive Modeling* (Lee and Wagenmakers 2014) を見てみるとよいで

Results ▼

Paired Samples T-Test

Paired Samples T-Test

			t	df	p
grade_test2	-	grade_test1	6.475	19	< .001

Note. Student's t-test.

Bayesian Paired Samples T-Test ▼

Bayesian Paired Samples T-Test

			BF ₁₀	error %
grade_test2	-	grade_test1	5991.577	6.088e -8

Figure15.3 JASP での対応のある標本の t 検定とベイズファクターの結果

.....

しょう。この2冊を挙げたのは私の分野の人にとってとくに有用だと思うからですが、よい本は他にもたくさんありますので、ぜひ探してみてください。

16. エピローグ

“初めから始めよ”と王はいたって重々しく言った。
“そして終わりに来るまで進め。そこでやめるのだ”

– Lewis Carroll

この章を書くのはどこか奇妙で、しかもかなり場違いな感じがします。エピローグとは本が完成したときに書くものですが、この本はまだ完成していません。この本にはまだたくさんの欠落があります。索引がありません。参考文献も多く抜けています。“自分でやってみよう”という練習問題もありません。そして全般に、見せ方も構成も内容も、直すべきところが多いと感じています。そうであれば“きちんとした”エピローグを書こうとは思いません。中身をまだ書き終えていないのに、全体をまとめようとしても仕方がないからです。とはいえこの版は学生が使えるようにオンラインで公開されますし、冊子体を購入していただくこともあるでしょうから、せめて締めくくりらしい体裁だけは整えておきたいのです。では、やってみましょうか。

16.1

まだ見ぬ統計学

まず、この版に詰め込めればよかったと思っている内容について少し話します。統計学の世界に他にどんな考えがあるのかを感じ取ってもらうためです。これは、たとえこの本が完成に近づいていたとしても重要なことだと思います。学生がしばしば気づかないのは、統計学入門の授業はまさに入門にすぎない、ということです。より広い世界に出て本物のデータ分析をしたいのなら、学部講義の内容をさまざまな方向に拡張する新しい道具をたくさん学ばなければなりません。学部で扱わなかったからといって、それができないと思ひ込まないでください。学部の授業で扱ったからといって、それが正しいやり方だと思ひ込まないでください。そうした罫にはまらないように、世の中にある他の考えをざっと見渡しておくのは有用だと思います。

16.1.1 扱ったトピックのなかでの積み残し

本書で扱ったトピックのなかにも、将来の版で埋め合わせたい積み残しがたくさんあります。JASPに関わることでなく純粋に統計に関わることに絞っても、いつか詳しく書きたいトピックとして、代表的なものを(網羅的ではありませんが)挙げておきます。

- **ほかの種類の相関.** Chapter 4 では Pearson と Spearman という 2 種類の相関を扱いました。どちらも、2 つの連続変数があってその関係性を評価したい場合に使える方法です。では、2 つの変数がどちらも名義尺度の場合はどうでしょうか。あるいは一方が名義尺度で他方が連続量の場合は。そうした場合に相関を計算する方法も実際にあり(たとえばポリコリック相関)、それらを収録できるとよいと思っています。
- **効果量のより詳しい扱い.** 全体として、本書の効果量の扱いは本来あるべきよりやや駆け足だと思います。ほとんどの場面で効果量の指標をひとつ(たいていはもっとも一般的なもの)だけ選んで説明してきました。しかしほとんどすべての検定やモデルには効果量の考え方が複数あり、将来はもっと詳しく踏み込みたいところです。
- **仮定が破られたときの対処.** 検定やモデルの仮定が破れているとわかったときに何ができるかについては本書の何箇所かで触れましたが、もっと述べるべきだと思っています。とくに、問題を解決するために変数をどう変換できるかをずっと詳しく論じられればよかったと思います。JASP でも基本的なデータ変換はできますが、1 冊の本で語れる分量には限りがあります。
- **回帰における交互作用項.** Chapter 13 では分散分析に交互作用項を入れられることを述べ、分散分析が一種の線形回帰モデルとして解釈できることも指摘しました。ところが Chapter 11 で回帰を扱ったときには、交互作用にまったく触れませんでした。しかし回帰モデルに交互作用項を入れてはいけない理由はありません。ただ、2 つの連続な予測変数のあいだの交互作用となると“交互作用”が実際に何を意味するのかを見極めるのが少し複雑になりますし、やり方も一通りではないのです。とはいえ、これについても少し触れたかったところです。
- **計画的比較の方法.** Chapter 13 で述べたように、分散分析で Tukey の HSD のような事後的な補正を使うのが常に適切とは限りません。とくに、あらかじめ関心のある比較がはっきりと(そして限られた数だけ)決まっていた場合はそうです。これについても将来もっと述べたいと思います。
- **多重比較の方法.** 事後検定や多重比較の話のなかでも、それぞれの方法をもっと詳しく論じ、触れたいいくつかの選択肢以外にどんな方法があるのかを述べたかったところです。

16.1.2 本書に載せられなかった統計モデル

統計学は巨大な分野です。本書で説明した中心的な道具 (カイ二乗検定・t 検定・回帰・分散分析) は日々のデータ分析で広く使われる基本的な道具であり、たいていの統計入門書の中核をなしています。しかし世の中には他にもたくさんの道具があります。これらの道具では扱えないデータ分析の場面は実に多く、その先にどれだけ広がりがあるのかを感じ取ってもらえればと思います。たとえば次のようなものです。

- **非線形回帰.** Chapter 11 で回帰を論じたとき、回帰は予測変数と結果変数の関係が線形であることを仮定していると見ました。一方 Chapter 4 でより単純な相関の問題を扱ったときには、変数間の非線形な関係を評価できる道具 (たとえば Spearman の相関) があることも見ました。統計学には非線形回帰に使える道具がいくつもあります。たとえば、予測変数と結果変数の関係が単調であると仮定するもの (等調回帰など)、滑らかではあるが必ずしも単調ではないと仮定するもの (Lowess 回帰など)、関係が既知の非線形な形をしていると仮定するもの (多項式回帰など) があります。
- **ロジスティック回帰.** 回帰のもうひとつの変種は、結果変数が 2 値で予測変数が連続量である場合に登場します。たとえばソーシャルメディアを調べていて、ある人が Twitter を使っているかどうかを、収入や年齢などの変数から予測できるかを知りたいとしましょう。これは基本的に回帰モデルですが、結果変数が 2 値 (使っているか使っていないか) ですので通常の線形回帰は使えません。結果変数が 2 値である以上、残差が正規分布することはありえないからです。この状況に適用できる道具はいくつもあり、もっとも有名なのがロジスティック回帰です。
- **一般化線形モデル (GLM).** GLM は実のところ、ロジスティック回帰・線形回帰・(一部の) 非線形回帰・分散分析などを含むモデルの一族です。GLM の基本的な考え方は線形モデルを支えているものと本質的に同じですが、データが正規分布しないかもしれないことを許し、予測変数と結果変数の非線形な関係も許します。GLM の枠内で実行できる便利な分析はたくさんありますので、知っておくととても役に立ちます。
- **生存時間分析.** Chapter 2 では“脱落の偏り”，つまり人がランダムでない形で研究から離脱する傾向について述べました。あのときは方法論上の懸念として扱いましたが、脱落の偏りそのものが関心の対象になる場面もたくさんあります。たとえば、人が 1 回のセッションでどのくらいの時間さまざまな種類のコンピュータゲームを遊ぶかを知りたいとしましょう。人は FPS (一人称視点シューティング) より RTS (リアルタイムストラテジー) を長く遊ぶ傾向があるのでしょうか。研究はこう設計できます。参加者が実験室に来て、好きなだけ長く、あるいは短く遊びます。終わったら遊んでいた時間を記録します。ただし倫理上の制約から、2 時間を超えて遊ばせることはできないとしましょう。多くの人は 2 時間の上限より前にやめますので、遊んだ時間が正確にわかります。しかし一部の人は 2 時間の上限に達してしまい、研究を

続けられたならどれだけ遊び続けたかはわかりません。その結果、データは系統的に打ち切られることになります。非常に長い時間がすべて欠けているのです。このデータをどう分析すればよいのでしょうか。これが生存時間分析の解く問題です。研究が終わったせいでデータの片“側”が系統的に欠けている、というこの状況を扱うために作られた手法です。健康研究で非常に広く使われており、その文脈では文字どおり生存の分析に使われることもよくあります。たとえば、ある種のがんの患者を追跡し、一部は治療 A、一部は治療 B を受けているけれども、追跡できる資金は 5 年分しかない、という場合です。研究期間の終わりに生きている人もいれば、そうでない人もいます。この文脈で生存時間分析は、どちらの治療がより効果的かを判断し、人々が時間とともに直面する死亡リスクを教えてくれるので有用です。

- **混合モデル**。反復測定分散分析は、観測が実験単位の中かでまとまっている状況でよく使われます。よい例は、個々の人を複数の時点にわたって追跡する場合です。2 人の幸福感を時間を追って追跡しているとしましょう。Aaron の幸福感は 10 から始まり、8 に下がり、さらに 6 に下がります。Belinda の幸福感は 6 から始まり、8 に上がり、さらに 10 に上がります。この 2 人の“全体的な”幸福感の水準は同じ (3 時点の平均はどちらも 8) です。反復測定分散分析は Aaron と Belinda を同じように扱ってしまいます。しかしこれは明らかに誤りです。Aaron の幸福感は下がっており、Belinda の幸福感は上がっているのですから。人が時間とともに変化する実験のデータを最適に分析したいのなら、反復測定分散分析より強力な道具が必要です。この問題を解くために使われる道具は“混合”モデルと呼ばれます。個々の実験単位について (たとえば個々人の幸福感の時間変化) と、全体的な効果について (たとえばお金が幸福感の時間変化に与える影響) の両方を学べるように作られているからです。反復測定分散分析はおそらく混合モデルのもっとも単純な例ですが、混合モデルには反復測定分散分析ではできないことがたくさんあります。
- **多次元尺度構成法**。因子分析は“教師なし学習”のモデルの一例です。これは、これまで挙げてきた“教師あり学習”の道具の多くとは違って、変数を予測変数と結果変数に分けられないという意味です。回帰は教師あり学習ですが、因子分析は教師なし学習です。ただし教師なし学習のモデルはこれだけではありません。たとえば因子分析では変数間の相関の分析を問題にしますが、対象・項目・人のあいだの類似性や非類似性の分析に本当は関心がある、という場面もたくさんあります。この状況で使える道具はいくつもあり、もっともよく知られているのが多次元尺度構成法 (MDS) です。MDS の考え方は、項目の“幾何学的な”表現を見つけることにあります。各項目はある空間のなかの点として“布置”され、2 点間の距離がその項目どうしの非類似性の指標になります。
- **クラスタリング**。教師なし学習のモデルのもうひとつの例がクラスタリング (分類とも呼ばれます) で、似た項目が同じグループに割り当てられるように、すべての項目を意味のあるグループへ整理しようとするものです。クラスタリングの多くは教師なしで、グループが何なのかについて何も知らず、推測するしかありません。一方、他の変数にもとづいて所属グループを予測する必要がある、その所属が実際に観測できる“教師ありクラスタリング”の場面もあ

ります。ロジスティック回帰はこのように働く道具のよい例です。しかし所属グループが実際にはわからない場合には、別の道具 (k 平均法など) を使わなければなりません。さらには、一部の項目については所属がわかるけれども他はわからない“半教師ありクラスタリング”をやりたい場面さえあります。想像がつくと思いますが、クラスタリングはかなり大きなトピックですし、知っておくとかなり役に立ちます。

- **因果モデル**. 本書であまり触れなかったことのひとつが、統計モデリングを使って変数間の因果関係を学ぶ方法です。たとえば銃殺刑で人がどう死んだかを考えるときに関心を持ちそうな3つの変数を考えてみましょう。処刑命令が出されたかどうか (変数 A)、射手が銃を撃ったかどうか (変数 B)、その人が弾に当たったかどうか (変数 C) を測りたいとします。この3つの変数は互いに相関しています (たとえば銃が撃たれることと人が弾に当たることのあいだには相関があります) が、私たちが本当にしたいのは相関を語ることに強い主張です。因果について語りたいのです。処刑命令 (A) が射手の発砲 (B) を引き起こし、それが人が撃たれること (C) を引き起こす、と言えるようになりたいわけです。これは有向の矢印で $A \rightarrow B \rightarrow C$ と書けます。この“因果連鎖”は、まず射手が撃ち、それが発砲 $B \rightarrow C$ を引き起こし、さらに処刑人が“さかのぼって”処刑命令を出す $B \rightarrow A$ という説明とは根本的に異なります。この“共通原因”モデルは、 A も C も B によって引き起こされると言っています。両者が異なる理由はわかるでしょう。最初の因果モデルでは、処刑人が命令を出すのを止められていたら (A を変える介入をしていたら)、発砲は起こらなかったはずで、2つめのモデルでは、射手は処刑命令にしたがっていたわけではないのですから、いずれにせよ発砲は起きたことになります。変数間の因果関係を理解しようとする統計学の文献は膨大にあり、データについての異なる因果の物語を検証する助けになる道具もいくつもあります。そのなかで (少なくとも心理学で) もっとも広く使われているのが構造方程式モデリング (SEM) で、いつか本書を拡張して触れたいと思っています。

もちろん、この一覧すら不完全です。時系列分析、項目反応理論、マーケットバスケット分析、分類回帰木、そのほか膨大な数のトピックに触れていません。とはいえ上に挙げた一覧は、本書についての私の希望リストそのものです。確かに本の長さは倍になるでしょうが、そうすれば心理学の応用研究者が使う必要のあるほとんどのものを覆えるだけの範囲になるはずです。

16.1.3 推測のほかのやり方

本書が不完全であるもうひとつの意味は、推測統計をどうやるべきかについて、かなり狭く古風な見方に強く寄っていることです。Chapter 7 では不偏推定量や標本分布といった考えに少し触れました。Chapter 8 では帰無仮説有意性検定と p 値の理論を扱いました。これらの考えは20世紀初頭からあるもので、本書で扱った道具はその時代の理論的な考えに強く依存しています。科学における

データ分析の大多数もそれらの考えに頼っていますので、このトピックから離れないことに義務を感じてきました。しかし統計学の理論はそれらに限られませんし、実務上の重要性から誰もが知っておくべきではあるものの、多くの点でそれらの考えは現代のデータ分析の最善の実践を表してはいません。とくにうれしく思っているのは、そこから少しだけ先へ進めたことです。Chapter 15 ではベイズの視点をそれなりの分量で示していますが、本書全体としてはいまだ頻度論の正統にかなり偏っています。加えて、触れておく価値のある推測のアプローチが他にもいくつかあります。

- **ブートストラップ法.** 本書を通じて、仮説検定を紹介するたびに私は“なんとかの標本分布は t 分布である”といった断言をしがちでした。場合によってはその断言を正当化しようと試みてもいます。たとえば Chapter 9 で χ^2 検定を扱ったときには、正規分布と χ^2 分布のあいだの既知の関係 (Chapter 6 参照) に触れて、適合度統計量の標本分布が χ^2 になると仮定するに至る経緯を説明しました。しかし、こうした標本分布の多くが、まあ、間違っているというのも事実です。 χ^2 検定はそのよい例です。これはデータの分布についての仮定にもとづいていますが、その仮定は標本サイズが小さいと成り立たないことが知られています。20 世紀初頭には、この状況に対してできることはあまりありませんでした。統計学者は“データについてなんとかの仮定のもとで標本分布は近似的になんとかである”という数学的な結果を作り上げ、それが精一杯だったのです。それすらない場合も多くありました。必要な標本分布の数学的な解を誰も見つけていないデータ分析の場面はたくさんあります。ですから 20 世紀後半までは、対応する検定は存在しないか、機能しませんでした。しかしいまや計算機がそれをすべて変えました。これを回避するための凝った手、そしてさほど凝っていない手がたくさんあります。もっとも単純なのがブートストラップ法で、いちばん単純な形なら驚くほど簡単です。やることは、(a) 帰無仮説が正しい、(b) 未知の母集団分布は実際のところ手元の生データにかなり似ている、という 2 つの仮定のもとで、実験の結果を何度も何度もシミュレートすることです。つまりデータが (たとえば) 正規分布していると仮定するかわりに、母集団が手元の標本と同じ形をしていると仮定し、その仮定のもとでの検定統計量の標本分布を計算機でシミュレートするのです。やや怪しい仮定 (母集団分布が標本と同じ) に頼っているにもかかわらず、ブートストラップ法は手早く簡単で、多くのデータ分析の問題で実際に驚くほどうまく働きます。
- **交差検証.** 私の統計の授業でときどき、たいていは挑発しようとする学生から出てくる質問に“そもそもなぜ推測統計を気にするのですか。標本を記述するだけではだめなのですか”というものがあります。この問いへの答えはたいていこうです。“科学者としての本当の関心は過去に観測した特定の標本ではなく、将来観測するかもしれないデータについて予測したいからです”。統計的推測の問題の多くは、未来が過去と似てはいるが少し違うと常に予期していることから生じます。より一般に、新しいデータは古いデータとまったく同じにはなりません。多くの場面で私たちがやっているのは、古いデータをもっともよく記述する言明を選ぶのではなく、新しいデータについて正しい可能性がもっとも高い推測を導くのに役立つ数

学的なルールを導き出そうとすることです。たとえばモデル A と B があり、今日集めたデータ X があるとして、明日集める新しいデータ Y をもっともよく記述するモデルを選ぼうとする、といったことです。この過程をシミュレートすると便利なことがあり、それをやるのが交差検証です。データを X1 と X2 の 2 つの部分集合に分けます。X1 を使ってモデルを訓練し(たとえば回帰係数を推定し)、もう一方の X2 でモデルの性能を評価します。これによってモデルが古いデータから新しいデータへどれだけうまく一般化するか指標が得られ、データ X 全体に当てはめただけの場合よりもモデルの良さのよい指標になることが多いのです。

- **頑健統計.** 人生は雑然としていて、何ひとつ本来あるべきようには働きません。これは統計についても他の何についてと同じくらい当てはまり、データを分析しようとする、データが本来あるべきより雑然としているという類の問題にしょっちゅう行き当たります。正規分布するはずの変数が実際には正規分布していませんし、線形であるはずの関係が実際には線形ではありませんし、データのなかの観測のいくつかはほぼ確実にゴミです(つまり測るべきものを測っていません)。この雑然さは、本書で展開した統計理論のほとんどで無視されています。しかし問題を無視しても解決するとは限りません。とはいえ雑然さを無視してよい場合もあります。統計の道具のなかには“頑健”なもの、つまりデータが理論的な仮定を満たさなくてもそれなりにうまく働くものがあるからです。一方、頑健でない道具もあり、理論的な仮定からのわずかなずれでも壊れてしまいます。頑健統計はこの問いを扱う統計学の一分野で、統計量の“破綻点”といったことを論じます。つまり、データがどれだけ雑然とすると、その統計量が信用できなくなるのか、ということです。これには何箇所かで触れました。平均は変数の中心的傾向の頑健な推定量ではありませんが、中央値はそうです。たとえば私の親友 5 人の年齢が 34 歳・39 歳・31 歳・43 歳・4003 歳だと言ったとしましょう。平均すると何歳だと思いますか。つまりここでの真の母平均は何でしょうか。母平均の推定量として標本平均を使えば、答えは 830 歳になります。標本中央値を使えば、答えは 39 歳になります。2 つめの場合は“技術的には”間違っただけ(平均を推定するのに中央値を使うこと)をしているのに、実際にはよい答えが得られていることに注意してください。ここでの問題は、観測のひとつが明らかに嘘だということです。私に 4003 歳の友人はいません。おそらく打ち間違いで、43 と打つつもりだったのでしょう。しかし 43 のかわりに 53 と、あるいは 34 と打っていたらどうでしょう。それが打ち間違いかどうか、確信を持てるでしょうか。データの誤りは微妙なこともあり、標本を眺めただけでは検出できません。それでもデータを汚す誤りであることに変わりはなく、結論に影響します。頑健統計は、自分では気づいていない汚染に直面してもなお安全な推測をどう行えるかを扱います。なかなか格好いい分野です。

16.1.4 そのほかのトピック

- **欠測データ.** 運動と体重に関心があって調査をしているとしましょう。4 人に調査票を送りま

す。Adam はよく運動していて太っていないと答えます。Briony もよく運動していて太っていないと答えます。Carol は運動しておらず太っていると答えます。Dan は運動していないと答え、体重についての質問への回答を拒みます。Elaine は調査票を返してきません。これで欠測データの問題が生じました。調査票が 1 通まるごと欠け、別の 1 通では設問がひとつ欠けています。どうすればよいでしょうか。欠測データを無視するのは、一般に安全なことではありません。ここで Dan の調査票について考えてみましょう。まず、他の回答から見ると、私は Adam や Briony より Carol に似ている (どちらも運動していない) ように見えます。ですから私の体重を推測せよと言われたら、Adam や Briony より Carol に近いと推測するでしょう。Adam と私が男性で、Briony と Carol が女性であることを踏まえて補正するかもしれません。この種の推測を統計では“補完”と呼びます。補完を安全に行うのは難しいのですが、重要です。とくに欠測が系統的な形で生じている場合はそうです。太っている人は自分の体重について否定的に感じるよう圧力を受けがち (しばしば公衆衛生キャンペーンのおかげです) ですので、回答していない人は回答した人より太っている可能性が高いと疑う理由が実際にあります。Dan に体重を補完すると、標本のなかの太っている人の数はおそらく (Dan を無視すれば) 3 人中 1 人から、(Dan の体重を補完すれば) 4 人中 2 人に増えます。これが重要なのは明らかです。しかしこれをまっとうに行うのは、聞こえるより複雑です。先ほど私は、運動の質問に同じ答えをしたのだから Carol と同じように扱えばよいと示唆しました。しかしそれは正確ではありません。私たちのあいだには系統的な違いがあります。彼女は質問に答え、私は答えなかったのです。太っている人が直面する社会的圧力を考えれば、私は Carol よりもっと太っている可能性が高いのではないのでしょうか。そしてもちろんこれは、私の体重を実際に知っているかのようにひとつの値を補完するのがまっとうではない、という事実をまだ無視しています。そうではなく、Carol の体重よりも私の体重について不確かであるという事実をとらえるために、もっともらしい推測の範囲を補完する (多重代入と呼ばれます) 必要があります。Elaine が調査票を返さなかったことがもたらす問題については、触れないでおきましょう。想像がつくと思いますが、欠測データの扱いはますます重要なトピックです。実際、分野によっては、まっとうな多重代入の枠組みにしがたっていなければ欠測データのある研究を受理しない雑誌が多い、と聞いています。

- **検定力分析。** Chapter 8 では検定力の概念 (つまり効果が実際に存在する場合にそれを検出できる見込み) を論じ、研究の検定力がどれくらいかを評価するのに役立つ道具のまとまりとして検定力分析に触れました。検定力分析は研究の計画に役立ちます (たとえば必要な標本の大きさを見積もる) が、すでに集めたデータの分析でも有用な役割を果たします。たとえば有意な結果が得られ、効果量の推定値があるとしみましょう。この情報を使って、その研究に実際どれだけの検定力があったかを推定できます。これはなかなか有用で、とくに効果量が大きくない場合にそうです。たとえば $p < .05$ で帰無仮説を棄却したけれども、検定力分析をしてみると推定された検定力は .08 しかなかったとしみましょう。有意な結果は、帰無仮説が実際に正しかったならこのようなデータが得られる確率が 5% だったことを意味します。しかし検定

力が低いということは、帰無仮説が誤りで効果量が見た目どおり小さかったとしても、このようなデータが得られる確率は 8% しかなかったということです。これはかなり慎重になる必要があることを示しています。どちらに転んでも、結果に運が大きく関わっていたように見えるからです。

- **理論に着想を得たモデルによるデータ分析。** 本書の何箇所かで反応時間 (RT) のデータ、つまり誰かが何か (たとえば単純な判断) をするのにどれだけ時間がかかるかを記録したデータに触れました。RT のデータはほぼ例外なく正規分布せず、正に歪んでいると述べました。加えて、速さと正確さのトレードオフというものがあります。判断を急ぎすぎると (RT が短いと) 判断の質が下がる (正確さが落ちる) のです。ですから参加者の判断の正確さと RT の両方を測れば、速さと正確さが関係していることに気づくでしょう。もちろん話はこれだけではありません。どれだけ速く進めているかとは無関係に、他の人より良い判断をする人もいるからです。さらに速さは認知的な過程 (つまり考えるのに費やす時間) だけでなく生理的な過程 (たとえば筋肉をどれだけ速く動かせるか) にも依存します。このデータの分析が複雑な過程になりそうだと、思えてきたでしょう。実際そのとおりなのですが、心理学の文献を掘り下げてみるとわかることのひとつは、人が単純な判断をどう行うかを記述する数学的モデル (“逐次サンプリングモデル” と呼ばれます) がすでに存在し、そのモデルが上に挙げた要因の多くを考慮に入れている、ということです。こうした理論に着想を得たモデルは、標準的な統計の教科書には出てきません。標準的な統計の教科書が説明するのは標準的な道具、つまり心理学だけでなく多くの異なる分野で意味のある形で適用できる道具です。分散分析は、薬理学にも心理学にも同じように適用できる標準的な道具の例です。逐次サンプリングモデルはそうではなく、多かれ少なかれ心理学に特化しています。だからといって強力でないわけではありません。実際、人が素早く選択しなければならないデータを分析しているのなら、本当は逐次サンプリングモデルを使うべきなのです。分散分析でも回帰でも、それらを支える理論的な仮定がデータとうまく合っていないので、同じようにはうまくいきません。これに対して逐次サンプリングモデルは、まさにこの種のデータを分析するために明示的に設計されており、その理論的な仮定はデータときわめてよく合っているのです。

16.2

基礎を学ぶこと、そしてそれを JASP で学ぶこと

さて、長い一覧でした。そしてその一覧すら大幅に不完全です。本書で扱わなかった統計学の大きな考えは、本当にたくさんあります。500 ページ近い教科書を読み終えたところで、これはまだ始まりにすぎないと言われるのは、かなり気が滅入るかもしれません。とくに、教わったことの半分は間違っているのではないかと疑い始めたならなおさらです。たとえばこの分野には、古典的な分散分析

モデルの使用に強く反対する人がたくさんいるのに、私はそれに2章まるごとを割いています。標準的な分散分析はベイズの立場からも、頑健統計の立場からも、あるいは“端的に間違っている”という立場からも攻撃されえます(人は本当は混合モデルを使うべき場面で分散分析を使うことが実に多いのです)。では、そもそもなぜ学ぶのでしょうか。

私の見るところ、重要な論拠が2つあります。第一に、純粋な実用主義の論拠です。良かれ悪しかれ、分散分析は広く使われています。学術文献を理解したいのなら、分散分析を理解する必要があります。第二に“知識は積み上がる”という論拠です。多元配置分散分析を学ぶ前に一元配置分散分析を見ておくと役に立ったのと同じように、分散分析の理解はより進んだ道具の理解を助けます。そうした道具の多くは、基本的な分散分析の枠組みを何らかの形で拡張したり変形したりしたものだからです。たとえば混合モデルは分散分析や回帰よりはるかに有用ですが、分散分析と回帰をひととおりやらずに混合モデルの仕組みを学んだ人の話は聞いたことがありません。山に登る前に、まずはハイハイを覚えなければならないのです。

実のところ、この点をもう少し押し進めたいと思います。本書で私が多くやったことのひとつが、基礎について語ることです。確率論に多くの時間を割きました。推定と仮説検定の理論を、必要以上に詳しく論じました。なぜそんなことをしたのでしょうか。振り返って、確率分布とは何かを語るのにあれだけの時間を本当に使う必要があったのか、そもそもなぜ確率密度の節があったのか、と問いたくなるかもしれません。本書の目標がt検定や分散分析の実行のしかたを教えることだったのなら、あれは本当に必要だったのでしょうか。みんなの時間の壮大な無駄だったのではないのでしょうか。

答えは、同意していただけるとは思いますが、否です。統計学入門の目標は分散分析を教えることではありません。t検定でも、回帰でも、ヒストグラムでも、p値でもありません。目標は、熟練したデータ分析者になる道へあなたを送り出すことです。そして熟練したデータ分析者になるには、分散分析以上のこと、t検定や回帰やヒストグラム以上のことができなければなりません。データについてきちんと考えることができなければなりません。前節で述べたより進んだ統計モデルを学び、その土台にある理論を理解できなければなりません。そしてそれらの進んだ道具を使えるソフトウェアを手にしていなければなりません。少なくとも私の考えでは、基礎に費やした余分な時間が報われるのはここです。確率論を理解していれば、頻度論の分析からベイズの分析へ移るのがずっと容易になります。

要するに、このやり方で統計を学ぶことの大きな見返りは拡張可能性だと思います。データ分析のごく基礎しか扱っていない本にしては、本書は確率論などを学ぶという点で膨大な負担を課しています。本書が扱う個別の分析以外にも、学ぶよう促すことがたくさんあるのです。ですから最短時間で分散分析の実行のしかたを学ぶことが目標だったのなら、本書は良い選択ではありませんでした。しかし述べてきたように、それがあなたの目標だとは思いません。私はあなたがデータ分析のやり方を学びたいのだと思っています。そしてそれが本当に目標なら、統計学入門の授業で学ぶ技能が、現実のデータ分析で必要になるより複雑なモデルへ自然にきれいに拡張できるようにしておきたいは

ずです。本物のデータ分析者が使うのと同じ道具の使い方を学び、彼らのすることを学べるようにしておきたいはずです。ですからそう、確かにあなたはいま初学者です(あるいは本書を始めたときはそうでした)。しかしそれは、噛み砕きすぎた話、確率密度について語らない話、非釣り合型デザインの多元配置分散分析という悪夢について語らない話を与えられるべきだ、という意味ではありません。まっとうなデータ分析の道具のかわりに赤ちゃん用のおもちゃを与えられるべきだ、という意味でもありません。初学者はばかなのではなく、知識が足りないだけです。あなたに必要なのは、現実のデータ分析の複雑さを隠してもらうことではありません。必要なのは、その複雑さが現実世界で必ず待ち伏せしてくるときに、それを扱えるようにする技能と道具です。

そして私が願うのは、本書が、あるいはいつか本書が変わっていく完成した本が、そのために役立つことです。

17. References

- Adair, G. (1984). "The Hawthorne effect: A reconsideration of the methodological artifact". In: *Journal of Applied Psychology* 69, pp. 334–345 (page 40).
- Agresti, A. (1996). *An Introduction to Categorical Data Analysis*. Hoboken, New Jersey: Wiley (page 216).
- (2002). *Categorical Data Analysis*. 2nd. Hoboken, New Jersey: Wiley (page 216).
- Akaike, H. (1974). "A new look at the statistical model identification". In: *IEEE Transactions on Automatic Control* 19, pp. 716–723 (page 279).
- Anscombe, F. J. (1973). "Graphs in statistical analysis". In: *American Statistician* 27, pp. 17–21 (page 265).
- Bickel, P. J., E. A. Hammel, and J. W. O'Connell (1975). "Sex bias in graduate admissions: Data from Berkeley". In: *Science* 187, pp. 398–404 (pages 7, 9).
- Box, G. E. P. (1953). "Non-normality and tests on variances". In: *Biometrika* 40, pp. 318–335 (page 323).
- Box, George E. P. (1976). "Science and Statistics". In: *Journal of the American Statistical Association* 71, pp. 791–799 (page 184).
- Box, J. F. (1987). "Guinness, Gosset, Fisher, and Small Samples". In: *Statistical Science* 2, pp. 45–52 (page 225).
- Brown, M. B. and A. B. Forsythe (1974). "Robust tests for equality of variances". In: *Journal of the American Statistical Association* 69, pp. 364–367 (page 324).
- Campbell, D. T. and J. C. Stanley (1963). *Experimental and Quasi-Experimental Designs for Research*. Boston, MA: Houghton Mifflin (pages 15, 45).
- Chronbach, L. J. (1951). "Coefficient alpha and the internal structure of tests". In: *Psychometrika* 16(3), pp. 297–334 (page 437).
- Cochran, W. G. (1954). "The χ^2 test of goodness of fit". In: *The Annals of Mathematical Statistics* 23, pp. 315–345 (page 214).

- Cohen, J. (1988). *Statistical Power Analysis for the Behavioral Sciences*. 2nd. Lawrence Erlbaum (pages 184, 247).
- Cramer, H. (1946). *Mathematical Methods of Statistics*. Princeton: Princeton University Press (page 214).
- Dunn, O.J. (1961). "Multiple comparisons among means". In: *Journal of the American Statistical Association* 56, pp. 52–64 (page 320).
- Ellis, P. D. (2010). *The Essential Guide to Effect Sizes: Statistical Power, Meta-Analysis, and the Interpretation of Research Results*. Cambridge, UK: Cambridge University Press (page 184).
- Ellman, Michael (2002). "Soviet repression statistics: some comments". In: *Europe-Asia Studies* 54.7, pp. 1151–1172 (page 85).
- Evans, M., N. Hastings, and B. Peacock (2011). *Statistical Distributions (3rd ed)*. New York, NY: Wiley (page 129).
- Everitt, Brian S. (1996). *Making Sense of Statistics in Psychology. A Second-Level Course*. Oxford University Press (page 372).
- Fabrigar, L. R. et al. (1999). "Evaluating the use of exploratory factor analysis in psychological research". In: *Psychological Methods* 4, pp. 272–299 (pages 401, 409, 411).
- Fisher, R. A. (1922a). "On the interpretation of χ^2 from contingency tables, and the calculation of p ". In: *Journal of the Royal Statistical Society* 84, pp. 87–94 (page 193).
- (1922b). "On the mathematical foundation of theoretical statistics". In: *Philosophical Transactions of the Royal Society A* 222, pp. 309–368 (page 113).
- (1925). *Statistical Methods for Research Workers*. Edinburgh, UK: Oliver & Boyd (page 456).
- Fox, J. and S. Weisberg (2011). *An R Companion to Applied Regression*. 2nd. Los Angeles: Sage (page 271).
- Gelman, A. and H. Stern (2006). "The difference between "significant" and "not significant" is not itself statistically significant". In: *The American Statistician* 60, pp. 328–331 (page 190).
- Gelman, Andrew and Eric Loken (2014). "The statistical crisis in science". In: *American Scientist* 102.6, pp. 460+. ISSN: 0003-0996. DOI: [10.1511/2014.111.460](https://doi.org/10.1511/2014.111.460). URL: <http://mfkp.org/INRMM/article/13469628> (page 43).
- Geschwind, N. (1972). "Language and the brain". In: *Scientific American* 226(4), pp. 76–83 (page 330).
- Hays, W. L. (1994). *Statistics*. 5th. Fort Worth, TX: Harcourt Brace (page 311).
- Hedges, L. V. (1981). "Distribution theory for Glass's estimator of effect size and related estimators". In: *Journal of Educational Statistics* 6, pp. 107–128 (page 249).
- Hedges, L. V. and I. Olkin (1985). *Statistical Methods for Meta-Analysis*. New York: Academic Press (page 250).

- Hewitt, A. K., D. R. Foxcroft, and J. MacDonald (2004). "Multitrait-multimethod confirmatory factor analysis of the Attributional Style Questionnaire". In: *Personality and Individual Differences* 37(7), pp. 1483–1491 (page 426).
- Hogg, R. V., J. V. McKean, and A. T. Craig (2005). *Introduction to Mathematical Statistics*. 6th. Upper Saddle River, NJ: Pearson (page 209).
- Holm, S. (1979). "A simple sequentially rejective multiple test procedure". In: *Scandinavian Journal of Statistics* 6, pp. 65–70 (page 321).
- Hothersall, D. (2004). *History of Psychology*. McGraw-Hill (page 39).
- Hróbjartsson, A and PC Gøtzsche (2010). "Placebo interventions for all clinical conditions". In: *Cochrane Database of Systematic Reviews* 1. URL: <https://doi.org//10.1002/14651858.CD003974.pub3> (page 41).
- Hsu, J. C. (1996). *Multiple Comparisons: Theory and Methods*. London, UK: Chapman and Hall (pages 320, 384).
- Ioannidis, John P. A. (2005). "Why Most Published Research Findings Are False". In: *PLoS Med* 2.8, pp. 697–701 (page 44).
- Jeffreys, Harold (1961). *The Theory of Probability*. 3rd. Oxford (page 453).
- Johnson, Valen E (2013). "Revised standards for statistical evidence". In: *Proceedings of the National Academy of Sciences* 48, pp. 19313–19317 (pages 457, 460).
- Kahneman, D. and A. Tversky (1973). "On the psychology of prediction". In: *Psychological Review* 80, pp. 237–251 (page 39).
- Kass, Robert E. and Adrian E. Raftery (1995). "Bayes factors". In: *Journal of the American Statistical Association* 90, pp. 773–795 (pages 453, 454).
- Keynes, John Maynard (1923). *A Tract on Monetary Reform*. London: Macmillan and Company (page 141).
- Kruschke, J. K. (2011). *Doing Bayesian Data Analysis: A Tutorial with R and BUGS*. Burlington, MA: Academic Press (page 464).
- Kruskal, W. H. and W. A. Wallis (1952). "Use of ranks in one-criterion variance analysis". In: *Journal of the American Statistical Association* 47, pp. 583–621 (page 326).
- Kühberger, A, A Fritz, and T. Scherndl (2014). "Publication bias in psychology: A diagnosis based on the correlation between effect size and sample size". In: *Public Library of Science One* 9, pp. 1–8 (page 44).
- Larntz, K. (1978). "Small-sample comparisons of exact levels for chi-squared goodness-of-fit statistics". In: *Journal of the American Statistical Association* 73, pp. 253–263 (page 214).
- Lee, Michael D and Eric-Jan Wagenmakers (2014). *Bayesian cognitive modeling: A practical course*. Cambridge University Press (page 464).

- Lehmann, Erich L. (2011). *Fisher, Neyman, and the Creation of Classical Statistics*. Springer (page 188).
- Levene, H (1960). "Robust tests for equality of variances". In: *Contributions to Probability and Statistics: Essays in Honor of Harold Hotelling*. Ed. by I. Olkin et al. Palo Alto, CA: Stanford University Press, pp. 278–292 (page 324).
- McGrath, R. E. and G. J. Meyer (2006). "When effect sizes disagree: The case of r and d ". In: *Psychological Methods* 11, pp. 386–401 (page 248).
- Meehl, P. H. (1967). "Theory testing in psychology and physics: A methodological paradox". In: *Philosophy of Science* 34, pp. 103–115 (page 113).
- Pearson, K. (1900). "On the criterion that a given system of deviations from the probable in the case of a correlated system of variables is such that it can be reasonably supposed to have arisen from random sampling". In: *Philosophical Magazine* 50, pp. 157–175 (page 193).
- Peterson, C. and M. Seligman (1984). "Causal Explanations as a Risk Factor for Depression: Theory and Evidence". In: *Psychological Review* 91, pp. 347–74 (page 426).
- Pfungst, O. (1911). *Clever Hans (The horse of Mr. von Osten): A contribution to experimental animal and human psychology*. Trans. by C. L. Rahn. New York: Henry Holt (page 39).
- Rosenthal, R (1966). *Experimenter effects in behavioral research*. New York: Appleton (page 40).
- Sahai, H. and M. I. Ageel (2000). *The Analysis of Variance: Fixed, Random and Mixed Models*. Boston: Birkhauser (page 304).
- Shaffer, J. P. (1995). "Multiple hypothesis testing". In: *Annual Review of Psychology* 46, pp. 561–584 (page 320).
- Shapiro, S. S. and M. B. Wilk (1965). "An analysis of variance test for normality (complete samples)". In: *Biometrika* 52, pp. 591–611 (page 253).
- Sokal, R. R. and F. J. Rohlf (1994). *Biometry: the principles and practice of statistics in biological research*. 3rd. New York: Freeman (page 206).
- Stevens, S. S. (1946). "On the theory of scales of measurement". In: *Science* 103, pp. 677–680 (page 15).
- Stigler, S. M. (1986). *The History of Statistics*. Cambridge, MA: Harvard University Press (page 140).
- Student, A. (1908). "The probable error of a mean". In: *Biometrika* 6, pp. 1–2 (page 225).
- Welch, B. L. (1947). "The generalization of "Student's" problem when several different population variances are involved". In: *Biometrika* 34, pp. 28–35 (page 238).
- (1951). "On the comparison of several mean values: An alternative approach". In: *Biometrika* 38, pp. 330–336 (page 325).
- Wilkinson, Leland et al. (2006). *The grammar of graphics*. Springer (page 95).

Yates, F. (1934). "Contingency tables involving small numbers and the χ^2 test". In: *Supplement to the Journal of the Royal Statistical Society* 1, pp. 217–235 (page [213](#)).

